



POLITECNICO DI MILANO
DIPARTIMENTO DI ELETTRONICA, INFORMAZIONE E BIOINGEGNERIA
DOCTORAL PROGRAMME IN INFORMATION TECHNOLOGY

强化学习中的延迟

Doctoral Dissertation of:
Pierre Liotet

Supervisor:
Prof. Marcello Restelli

Tutor:
Prof. Nicola Gatti

The Chair of the Doctoral Program:
Prof. Luigi Piroddi

致谢

自然而真诚地，我衷心感谢我的导师 Marcello Restelli 教授，感谢他坚定的奉献和宝贵的帮助；我钦佩他在倾听他人时的专注和投入。没有他，这篇论文将不存在。

感谢 Konstantinos Katsikopoulos 教授和 Eitan Altman 教授的细致评审和富有洞察力的反馈。我可以坦然地说，多亏了他们，我在论文修改阶段加深了对延迟的理解。

同样感谢米兰理工大学的同事们，他们在研究和意大利文化方面教会了我很多。特别感谢 Luca、Lorenzo、Antonio 和 Edoardo，我与他们合作了许多激动人心的项目。真诚感谢 Mirco，我在 Covid-19 隔离前的好办公室伙伴。还要特别感谢我在米兰理工大学的合著者 Alberto、Davide 以及所有与我合作过的硕士生。

最后，同样重要的是，我感谢所有间接但同样重要地为这篇论文做出贡献的人。我的父母 Marie 和 Stephane，他们一直支持我，甚至在我论文答辩迟到时；Camille，她搬到米兰在我读博期间支持我；Alice、Iñigo 和 Iphigénie，我与他们在米兰共度美好时光。特别感谢 Kevin，我最亲密的朋友，总是随时提供快速的支持。最后但同样重要的是，衷心感谢 Alice，她与我分享了这三年来最难忘的时刻，支持我，并且凭直觉知道何时是最好的时机。

延迟 (delay) 是大多数动力系统固有的特性。除在时间上推移过程外, 延迟还会显著影响系统性能。因此, 研究延迟并对其加以考量通常很有价值。序贯决策问题 (如 Markov decision processes (MDPs)) 也是动力系统, 同样会受到延迟的影响, 这并不令人意外。这些过程是 reinforcement learning (RL) 的基础框架, 该范式的目标是创建能够通过与环境交互学习最大化效用的智能体 (agent)。

RL 已取得强大、有时甚至惊人的实证结果, 但延迟很少被明确纳入考量。关于延迟对 MDP 影响的理解仍很有限。本论文旨在研究智能体在状态观测 (state observation) 或动作执行 (action execution) 中的延迟。不断变换视角以揭示问题的结构和特性。考虑多种延迟, 并提出潜在解决方案。本文还旨在建立 RL 文献中的著名框架与延迟框架之间的联系。因此, 聚焦以下四个视角。

首先, 考虑常值延迟 (constant delay)。采用心理学启发的方法, 研究预测近期未来以估计智能体动作影响的作用。强调该方法与 RL 文献中模型的关系。借此机会, 正式证明一个看似显而易见的事实: 延迟越长, 性能越低。实验分析最终验证该方法的有效性。

作为第二视角, 考虑在延迟环境中模仿无延迟专家行为的简单方法。延迟最初保持恒定, 但之后扩展研究到更特殊的延迟类型, 如随机延迟 (stochastic delay)。尽管方法简单, 但展示了其强大的理论保证和实证结果。

第三视角同样针对常值延迟, 考虑采用非平稳 (non-stationary) 无记忆行为。虽然看似忽略延迟, 但该方法将延迟影响视为引导非平稳性的未观测变量。基于这一思想, 提出一种具有理论基础的算法来学习此类行为, 并在实际场景中测试。

最后, 第四个视角考虑比常值延迟更广泛的模型, 常值延迟作为其特例。该模型允许动作影响环境的多个未来转移 (transition)。研究其理论特性以理解其特殊性。基于这些特性, 一些 RL 算法被排除, 另一些则在多种实证研究中得到检验。作为更通用的延迟模型, 对其理解对前几章中的常值延迟框架具有启示意义。

Contents

CHAPTER 1

引言

对于machine learning (ML)爱好者来说，这是一个令人振奋的时代。Machine learning (ML)——构建学习机器的科学——正以前所未有的速度催生新算法。ML也在日常生活中占据更大比重，即使远离该领域的人也很难不注意到这一点。

为说明这一发展的范围和速度，分享以下个人经历。在开始撰写本论文前不久，我了解到新的 DALL-E [?] 算法，它能够根据用户提示生成高分辨率图像。这让我震惊于ML社区的能力，Twitter 上的大多数人也是如此，他们纷纷尝试创作最佳提示。除了精彩的模因和笑话之外，这类技术的前景和潜在应用——以及潜在风险——超乎我的想象。仅几周后，我便得知不同研究团队已开发出类似算法，如 Stable Diffusion [?] 和 Imagen [?]。我曾以为自己有幸见证了ML这一新方向的诞生。这一信念直到前几天还在——在撰写本论文时，我偶然发现了 Make-a-Video [?]。该算法可以根据用户提示生成高分辨率视频……仅几天后，Imagen 的视频扩展版——Imagen Video [?] 也发布了。我还没来得及思考图像生成算法的全部潜力，视频生成算法就已诞生。我无法想象这个领域的下一个发展将是什么¹。

本论文的核心主题——强化学习 (Reinforcement Learning, RL) [?]——是ML的一个子领域，知名度较低但同样有其显著成就。现在让我们深入这个充满活力的子领域。

1.1 强化学习范式

RL的主要目标是构想一个智能体 (*agent*)，通过与其环境 (*environment*) 交互学习最大化某种效用度量。交互过程建模为序贯决策问题。每一步，智能体在环境中执行一个动作 (*action*)。作为该动作和外部因素的结果，环境转换到新状态 (*state*) 并向智能体提供强化信号。该信号称为奖励 (*reward*)，对动作质量

¹这还没提到 ChatGPT，它是在我修改论文时发布的。

提供反馈。智能体的目标是最大化累积奖励和——即回报 (*return*)。环境遵循的序贯过程 (包括转移动态和奖励) 由 Markov decision process (MDP) 建模。为最大化奖励, 智能体必须自主平衡探索 (*exploration*) 和利用 (*exploitation*)。它需探索 MDP 的新区域以防止错过机会, 同时考虑利用已知有利区域以最大化效用。

RL 框架受心理学关于人类学习过程发现的启发。它足够通用以涵盖许多问题, 特别是 ML 的其他子领域——监督学习 (*supervised learning*) 和无监督学习 (*unsupervised learning*)。它也足够具体以产生有意义的理论结果指导算法设计。

在实证方面, 框架的有效性由其带来的突破性进展所支持。其中部分成就包括: 机器人运动 [?]; 自动驾驶 [?]; 在专家级别玩复杂视频游戏 [?]; 设计性能更高且能耗更低的计算机芯片 [?]; 控制托卡马克中等离子体形状 [?]

然而, 大多数这些应用需要对原始 RL 框架进行轻微扩展, 例如考虑状态的部分可观测性。原始框架的另一个限制可能是动力系统中存在延迟。下一节将解释为何考虑延迟是实现出色实证结果的关键。尽管 ML 和 RL 研究进展如此迅速, 但我们建议读者花些时间深入探讨延迟问题。

1.2 强化学习中的延迟

如前所述, RL 及其 MDP 模型是序贯决策的优质框架。然而, 如读者所知, 模型是对真实过程的简化, 有其自身局限。审视 RL 实际应用的文献可揭示这些局限所在。[?] 发现, 在真实机器人应用中, 从一系列候选障碍中, 学习的两大主要障碍是动作空间的选择和状态观测或动作执行中的延迟。这些延迟通过向智能体提供过时信息或延迟智能体对环境的控制来影响智能体-环境交互。这是支持延迟研究的有力论据。

我们认为延迟是任何序贯问题固有的。人类面临的最普遍延迟类型是大脑处理来自身体传感器信息所需的时间。例如, 运动信息从光感受器传递到大脑高级视觉区域所需时间估计约为 100 ms [?]. 在 RL 中, 此延迟类似于传感器采集时间导致的延迟。延迟也可能来自智能体根据环境观测计算下一个动作所需的时间。例如, 使用更复杂的策略 (如深度神经网络 (*deep neural network*)) 会加剧延迟, 这在主动流动控制中已有观察到 [?, ?]。

延迟自然出现的另一个例子是交易。在实践中, 信息收集和交易传输的速度极其重要。信息通过光纤走不同路径, 导致在不同地点的异步到达时间。这些延迟可被利用以获利 [?]. 此外, 通过抽象掉市场上的其他智能体, 单个交易智能体的回报受到延迟的负面影响 [?]. 使用 RL 智能体的外汇 (FX) 实验证实了引入延迟后的性能下降 [?]. 延迟影响的其他例子包括带半挂车的拖拉机紧急制动时间 [?]; 并行计算中计算节点可用信息 [?]; 机械臂控制 [?].

即使环境看似同步运行 (如围棋), 延迟仍隐藏在某处。在关于 AlphaGo [?] (与世界冠军李世石对弈的算法) 开发历程的纪录片中, AlphaGo 花费了超过 30 秒计算第一步。围棋比赛总时间有限, 过长的动作计算可能有害。在此例中延迟并未造成损害, 因为 AlphaGo 仍有充足时间并最终战胜了李世石。

在仿真中, 延迟可以人为去除, 但这可能带走重要的真实感。在 Atari 2600 等游戏中, 延迟显著影响 RL 智能体的性能 [?]. 一个简单解决方案是在智能体选择动作时暂停环境以消除延迟。然而, [?] 认为, 由于大多数游戏以 60Hz 显示图像, 且研究发现某些人群的平均反应时间约为 250 ms [?], 不为人工智能体建模延迟使其相对于人类获得不公平优势。

许多相关领域也考虑延迟问题。例如, 在控制理论 (*control theory*) 中 [?, ?, ?, ?, ?, ?], 延迟对系统稳定性有复杂影响 [?]. 该领域特别考虑了拥塞控制问题, 其

中数据包从多个源发送到网络 [?]. 在此问题中, 延迟自然产生, 因为数据包从不同源走不同路径 [?, ?, ?]. 在在线学习 (*online learning*) 中, 接收延迟反馈会减慢学习过程 [?, ?, ?]. 在实时 (*real-time*) RL 中, 智能体和环境之间的交互不再是同步的——即环境“等待”智能体选择动作——而是变成异步的。实际上, 智能体必须在环境持续演变的同时计算下一个动作, 且无法保证计算出的动作对新的环境状态仍然相关。有趣的是, 该子领域已被证明等价于延迟 RL [?, Theorem 1]。因此, 该领域的兴趣 [?, ?, ?, ?, ?] 也论证了延迟研究的价值。

基于所有上述原因, 我们认为延迟是 RL 实际应用中的核心研究方向。此外, 在传统框架中引入延迟所引发的理论问题也具有研究价值, 因为它们与 RL 的许多子领域相关, 如 partially observable Markov decision process (POMDP) 或实时 RL。

1.3 原创贡献

本论文聚焦 RL 场景中特有的两类延迟: 状态观测延迟 (state observation delay) 和动作执行延迟 (action execution delay)。目标是拓宽对此类延迟的理解并提供高效解决方案。特别关注文献中普遍存在且在许多情况下能很好近似实际延迟的常值延迟 (constant delay)。然而, 我们将反复研究将框架扩展到更原始延迟类型的理论和实证影响。本论文的贡献遵循四个目标: 提供 RL 中延迟的统一框架; 为更好理解延迟提供理论基础; 设计有理论依据且高效的算法以应对延迟环境; 对所提算法及文献中算法进行广泛实证评估。下文将详述每个目标的贡献, 然后引用本人合著的相关出版物。

延迟的统一框架

本文对 RL 及相关领域的延迟文献进行了广泛综述。重点放在 RL 中的状态观测和动作执行延迟, 但也讨论了其他类型延迟。值得注意的是, 我们将文献中的算法归纳为三类。第一类是增广状态 (*augmented state*) 方法。其思想是将最后观测到的状态与智能体已选择但尚未观察到结果的动作序列进行增广。使用这种新状态可将延迟问题重新转化为传统的无延迟 MDP 框架。第二类是无记忆 (*memoryless*) 方法, 智能体忽略延迟, 仅使用最后观测状态的信息。这一思想简单, 但在实践中可能高效。最后, 基于模型 (*model-based*) 方法学习环境模型以预测动作将施加时的环境状态。据我们所知, 此前尚无工作提供 RL 中延迟的综述。我们认为提供此信息对该领域有益, 因为文献中经常出现重叠结果。

此外, 我们提出延迟问题的统一数学框架。这一提议遵循同一思路, 即延迟文献可受益于更多结构化。我们的框架将所有最常见的延迟类型作为特例包含在内, 并与 MDP 模型自然衔接。

延迟的理论理解

首先, 分析延迟状态观测或动作执行对 MDP 的理论影响。第一个结果是正式证明一个看似显而易见但尚未被证明的事实: 延迟越长, 最大可达累积奖励 (即回报) 越低。同理, 展示延迟如何影响策略集所能实现的回报变异性。更长的延迟缩小了智能体可获得回报的范围, 但也降低了重复学习同一任务时回报的方差。然后, 将常值延迟框架扩展到多动作延迟 (multiple action delay) 框架, 其中单个动作可影响未来的多个转移。该框架从理论角度具有研究价值, 因为它将常延迟过程作为特例包含在内。此外, 它自然地将高阶 Markov chains (MCs) 模型扩展到 MDPs。我们展示多动作延迟过程可通过状态增广重新转化为 MDP, 与常

延迟过程类似。然后研究该框架相对于传统MDP的特性和特殊性。特别是，这有助于强调高阶MDP与延迟MDP之间的联系。值得注意的是，一些性质（如单链性（unichain））不会从底层MDP传递到基于它构建的延迟过程，而其他性质（如连通性（communicating））则会传递。

其次，将焦点转向延迟RL算法并研究其保证。分析处理延迟的三种方法：增广状态、无记忆和基于模型的方法。已知增广状态方法可为延迟问题找到最优策略。相反，我们展示基于模型方法可能过于严格而丢弃最优策略。然而，在平滑MDP（smooth MDP）——将在本文中定义的概念——背景下，我们证明基于模型方法能提供接近最优的策略。将上述保证扩展到非整数延迟（non-integer delay）。非整数延迟让人联想到实时RL的异步环境假设。智能体以给定频率观测状态，但只能以相位变化的方式执行动作。最后，推导出基于模型策略在常值延迟上训练但在随机延迟上测试时的性能界。

延迟强化学习算法

在算法方面，首先探索基于模型方法，设计一种能够学习当前状态概率分布（即信念（belief））的向量化表示的算法。为学习信念表示，第一个神经网络（Transformer）处理增广状态并为每个未来状态生成表示（直至无延迟状态）。该表示通过拟合分布的另一个网络（归一化流（normalising flow）网络）训练以对应信念。将该表示接入RL算法可提升性能并加速学习速度，效果在随机环境中尤为明显。此外，提供一种直接方法，使预训练于特定延迟的该算法能适应更短延迟。

然后探索一种不同的方法，通过模仿无延迟专家行为来学习策略。实际中，延迟智能体被训练为复制无延迟智能体基于当前状态选择的动作，但仅使用延迟信息——即增广状态。展示如何利用平滑MDPs的理论保证与模仿学习（imitation learning）的理论结果相结合来指导算法设计。实证表明该方法达到最先进性能，且足够通用以适用于常值、非整数和随机延迟。

作为第三种方法，探索无记忆方法。在此情形下，问题本质上变成非平稳（non-stationary）。因此，设计一种理论，通过优化未来性能估计的概率下界来适应未来非平稳性。该未来性能估计基于多重重要性采样（importance sampling）以考虑非平稳性导致的过去动态多样性。在平滑非平稳条件下，该估计器的偏差有界。为进一步考虑过程的随机性，利用浓度不等式获得估计的下界。这涉及前一估计器的方差上界。有趣的是，控制估计器的方差间接约束了策略的非平稳性。这防止对过去非平稳动态的过拟合并更好地泛化到未来动态。实际中，算法实现为一个超策略（hyper-policy），接受时间作为输入并输出每个时刻要查询的策略。实验展示该算法如何学习过程的非平稳性以适应它，包括当非平稳性由延迟引起时。

广泛实证评估

最后一个贡献是对本文提出的算法及文献中算法进行广泛实证评估。设计多种测试任务，从平衡摆到货币汇率交易。在这些任务中，改变延迟的长度和性质以研究算法的鲁棒性。考虑常值、非整数、随机和多动作延迟。这些实证评估有助于理解算法的特性和偏好设置。

相关出版物

上述贡献可在以下论文中找到。[?] 中提出基于模型的方法并分析其可能过于严格的问题。在该工作中，我设计了方法，进行了理论分析和大部分实验分析。模

仿学习方法及平滑MDPs中延迟的分析见 [?]. 我完成了常值延迟的部分理论分析以及向非整数和随机延迟的扩展，并进行了大部分实验分析。非平稳无记忆方法来自 [?]. 在该工作中，我进行了大部分理论分析、部分方法设计以及全部实证研究。最后，关于多动作延迟扩展及改变延迟分布对智能体性能影响的分析结果将作为待提交论文的基础。在该工作中，我完成了全部理论和实证分析。

1.4 论文概述

本论文前两章专注于介绍和定义RL的整体概念以及延迟文献中的特定概念。

- ?? 介绍后续章节使用的主要数学工具和算法素材。特别地，介绍MDP模型和RL的一般框架。
- ?? 深入探讨作为第一章所述原始RL框架扩展的延迟问题。引入相关符号和术语。随后详尽列举文献和实际应用中遇到的延迟类型。最后讨论RL及相关领域的延迟文献。

这些介绍性章节之后是四个章节，展示本论文的原创贡献。每章结构相同：第一部分正式介绍问题并详述提出的解决方案；第二部分提供理论分析以更好理解问题特性和解决方案的性质；第三部分通过彻底的实证分析支持前两部分的论断。

- ?? 聚焦状态观测和动作执行中的常值延迟。提出一种称为信念表征网络 (*Belief Representation Network*) 的概率方法，其中智能体预测近期未来以应对延迟。理论分析将提供对这类延迟问题及其对性能负面影响的理解。本章内容见 [?].
- ?? 与前一章处于相同框架。提出一个简单解决方案——DIDA——延迟智能体学习模仿无延迟专家行为。尽管简单，但证明了 DIDA 在平滑环境中的强大理论保证。该解决方案扩展到新框架，包括非整数和随机延迟。本章内容源自 [?].
- ?? 同样设定在常值延迟框架中，提出另一种方法。解决方案考虑无记忆智能体，即对延迟不可见。从智能体角度看，过程变为非平稳，因此设计非平稳策略以适应演化动态。通过优化智能体未来性能的估计来实现，称该方法为 POLIS。本章通过研究未来性能估计器的偏差和方差为 POLIS 设计提供理论基础。本章内容取自 [?].
- ?? 考虑包含常值延迟的延迟框架。其中，一个动作的执行可延伸至多个未来步骤，从而产生多动作延迟 (multiple action delay)。深入分析新框架的性质，特别关注理解延迟分布对智能体最佳性能的影响。本章材料尚未在其他地方发表。

最后，?? 总结论文的主要成果和要点以及局限性。重要的是，每个结果都将引导读者到论文中呈现该结果的部分。本章还将讨论潜在研究方向。

更多证明、实验细节和实证结果见附录 ??。

2.1 引言

本章介绍论文中将用到的重要概念。首先，?? 引入 Markov chain 概念，这将有助于理解后续介绍的 Markov decision process (??)。在此基础上，?? 阐述 RL 及其主要算法。最后，?? 简要介绍论文所需的其他重要概念，包括重要性采样和神经网络。

2.2 马尔可夫链

Markov chain (MC) (马尔可夫链) [?] 是一种离散时间随机过程，描述状态在空间 $\mathcal{X}$ (称为状态空间) 内的演化过程。每一步从状态 $x \in \mathcal{X}$ 转移到状态 $y \in \mathcal{X}$ 的概率由转移函数 P 给出，记为 $P(y|x)$ 。

文献中对 MCs 的性质已有广泛研究，但这些内容超出本文范围。本文仅给出以下三个对本文有用的定义。在下述定义中，用 X_t 表示当前状态的随机变量。

Definition 2.2.1 (常返状态). 状态 $x \in \mathcal{X}$ 是常返的，若

$$\mathbb{P}(\min\{t \geq 1 : X_t = x\} < \infty | X_0 = x) = 1$$

Definition 2.2.2 (暂态). 非常返的状态 $x \in \mathcal{X}$ 称为暂态。

Definition 2.2.3 (单链 MC). 有限状态 MC 称为单链，若它包含唯一一个常返类，但可包含任意数量的暂态。

MCs 框架涵盖了许多实际过程。然而，在某些情况下，可能需要表达当前转移对一组更早状态的依赖关系，这正是高阶马尔可夫链（或称带记忆的马尔可夫链）所允许的。在此框架中，转移可依赖于多个过去的状态。

2.2.1 高阶马尔可夫链

阶数为 l 的 MC 根据最近 l 个状态 $(x_{t-l}, \dots, x_{t-1})$ 的信息定义到状态 x_t 的转移:

$$\mathbb{P}(X_t = x_t | X_{t-l} = x_{t-l}, \dots, X_{t-1} = x_{t-1}) = P(x_t | x_{t-l}, \dots, x_{t-1}).$$

然而, 该模型需要大量参数来构造转移概率。实际上, 对于大小为 $|\mathcal{X}| = m$ 的状态空间, 集合 $(x_{t-l}, \dots, x_{t-1})$ 可取 m^l 个不同值, 因此概率 P 需要 $m^l(m-1)$ 个独立参数来定义 [?]. [?] 则提出了一种仅需 $m(m-1) + (l-1)$ 个独立参数的模型, 该模型在实践中保持良好的建模能力, 称为 mixture transition distribution (MTD) (混合转移分布), 如下所示。

Definition 2.2.4 (Mixture Transition Distribution (MTD) [?]). 混合转移分布 (MTD) 是阶数为 $l \in \mathbb{N}$ 、状态空间为 $\mathcal{X} = \{1, \dots, m\}$ 的 l 阶 MC, 具有以下性质。

$$\begin{aligned} \mathbb{P}(X_t = x_t | X_{t-l} = x_{t-l}, \dots, X_{t-1} = x_{t-1}) &= \sum_{g=1}^l \lambda_g \mathbb{P}(X_t = x_t | X_{t-1} = x_{t-1}) \\ &= \sum_{g=1}^l \lambda_g P(x_t | x_{t-g}), \end{aligned}$$

其中概率 $P(x_t | x_{t-g})$ 定义为某个一阶 MC 的转移, 且

$$\begin{aligned} \sum_{g=1}^l \lambda_g &= 1, \\ \lambda_g &\geq 0. \end{aligned}$$

该模型可通过引入额外独立参数来增强建模能力。这一新模型具有 $lm(m-1) + (l-1)$ 个独立参数, 定义如下。

Definition 2.2.5 (Mixture Transition Distribution (MTDg) [?, ?]). 多矩阵混合转移分布 (mixture transition distribution (MTDg)) 是转移矩阵经过修改的 MTD 模型:

$$\begin{aligned} \mathbb{P}(X_t = x_t | X_{t-l} = x_{t-l}, \dots, X_{t-1} = x_{t-1}) &= \sum_{g=1}^l \lambda_g \mathbb{P}(X_t = x_t | X_{t-g} = x_{t-g}) \\ &= \sum_{g=1}^l \lambda_g P^{(g)}(x_t | x_{t-g}), \end{aligned}$$

其中转移概率 $(P^{(g)})_{g \in [1, l]}$ 来自 l 个不同一阶 MCs 的转移概率。

然而, 已有研究表明 MTDg 模型过参数化 [?]. 事实上, 两组不同的参数集可能定义出相同的 MTDg 模型。

2.3 马尔可夫决策过程

Markov decision process (MDP) (马尔可夫决策过程) [?] 模型可视为一种 MC, 其转移受动作执行的影响。通常, 智能体负责选择动作, 从而能与 MDP 进行交互。此外, 转移过程关联着一个奖励函数, 为智能体提供反馈。

形式化地，MDP 定义为一个五元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, p, R, d_0)$ ： $\mathcal{S}$ 和 $\mathcal{A}$ 分别是状态和动作的可测集； $p(s'|s, a)$ 是通过执行动作 a 从状态 s 转移到状态 s' 的概率； $R(s, a)$ 是一个随机变量，表示智能体在施加动作 a 的状态 s 转移过程中获得的奖励； d_0 是智能体初始状态的分布。记 $r(s, a) = \mathbb{E}[R(s, a)]$ ，并在本文中做出以下假设。

Assumption 2.3.1 (有界奖励). 奖励是有界的，若 $\forall (s, a) \in \mathcal{S} \times \mathcal{A}$,

$$0 \leq r(s, a) \leq R_{\max}.$$

2.3.1 策略

智能体根据其与环境交互历史 $h_t = (s_0, a_0, \dots, s_{t-1}, a_{t-1}, s_t)$ 选择动作的方式称为策略。若记 $\mathcal{H}_t$ 为 t 时刻所有可能历史的集合，则可形式化地将智能体策略定义为从历史集到动作空间上概率集的映射：

$$\pi : \mathcal{H}_t \rightarrow \mathcal{P}(\mathcal{A}).$$

本文沿用 [?] 的符号，记所有策略的集合为 Π^{HR} ，其中“R”表示随机化，“H”表示历史依赖。

Π^{HR} 的不同子集因其性质而值得关注。马尔可夫策略子集考虑仅依赖于最近观测状态的策略。这是一个便利的性质，因为它避免了策略输入随时间增长维度。已有研究表明，对于后文将介绍的目标函数，该子集中包含最优策略 [?, Theorem 6.2.10 and Theorem 8.1.2]。使用上标“M”表示马尔可夫策略。当策略随时间固定（尽管可能随机）时，称其为平稳策略，并使用上标“S”。最后，当 $\mathcal{A}$ 上的概率测度退化、将所有质量集中于单一动作时，策略是确定性的。该子集用字母“D”标记。综上所述，这些集合的包含关系如下 [?, Section 2.1.5]：

$$\begin{aligned} \Pi^{\text{SD}} &\subset \Pi^{\text{SR}} \subset \Pi^{\text{MR}} \subset \Pi^{\text{HR}} \\ \Pi^{\text{SD}} &\subset \Pi^{\text{MD}} \subset \Pi^{\text{MR}} \subset \Pi^{\text{HR}} \\ \Pi^{\text{SD}} &\subset \Pi^{\text{MD}} \subset \Pi^{\text{HD}} \subset \Pi^{\text{HR}}. \end{aligned}$$

2.3.2 目标

MDP 可定义三种主要目标：期望总回报、期望折扣回报和平均奖励 [?]。本文将关注后两类回报。对于某个 MDP $\mathcal{M}$ ，令 $\mathbb{P}(S_t = s; \pi, d_0)$ 为在策略 π 和初始状态分布 d_0 下，表示 t 时刻状态的随机变量 S_t 取值为 s 的概率。对于某个策略 π ，折扣因子为 γ 的期望折扣回报定义为

$$J_{\gamma}^{\pi} = \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H \gamma^t r(s_t, a_t) \right]; \quad (2.1)$$

其中 H 是可能为无穷大的水平线。而平均奖励性能为¹

$$J_{\text{AVG}}^{\pi} = \lim_{H \rightarrow \infty} \frac{1}{H} \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H r(s_t, a_t) \right].$$

这些期望值针对初始状态分布 d_0 和策略诱导的转移分布计算。

¹ 此处沿用 H 而非更常用的 T ，以匹配折扣情形的符号约定，并将 T 保留用于表示跨回合的总步数。

2.3.3 状态-动作占用度量和分布

从理论角度来看，对智能体访问的状态具有某种度量或分布是有用的。实际上，策略的性能可直接从这些量推导得出。首先定义折扣回报准则下的状态-动作占用分布：

$$d_{\gamma}^{\pi}(s, a) = (1 - \gamma) \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H \gamma^t \mathbb{1}(S_t = s, A_t = a) \right]. \quad (2.2)$$

而平均奖励下的状态-动作占用分布为

$$d_{\text{AVG}}^{\pi}(s, a) = \lim_{H \rightarrow \infty} \frac{1}{H} \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H \mathbb{1}(S_t = s, A_t = a) \right].$$

从状态-动作分布可推导出状态分布如下：

$$\begin{aligned} d_{\gamma}^{\pi}(s) &= \int_{\mathcal{A}} d_{\gamma}^{\pi}(s, a) da, \\ d_{\text{AVG}}^{\pi}(s) &= \int_{\mathcal{A}} d_{\text{AVG}}^{\pi}(s, a) da. \end{aligned}$$

注意此处使用了相同的符号，但函数的输入可避免混淆。为简化符号，当目标不会引起混淆时，有时会省略下标“ γ ”或“AVG”。

最后，定义折扣情形下的状态-动作占用度量 [?]:

$$\begin{aligned} \mu_{\gamma}^{\pi}(s, a) &= \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H \gamma^t \mathbb{1}(S_t = s, A_t = a) \right] \\ &= \frac{d_{\gamma}^{\pi}(s, a)}{1 - \gamma}, \end{aligned}$$

以及平均奖励下的对应量：

$$\mu_{\text{AVG}}^{\pi}(s, a) = \lim_{H \rightarrow \infty} \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot | s_t, a_t) \\ a_t \sim \pi(\cdot | s_t) \\ s_0 \sim d_0}} \left[\sum_{t=1}^H \mathbb{1}(S_t = s, A_t = a) \right].$$

策略的折扣回报可从状态-动作占用度量推导如下 [?, Lemma 1]:

$$J_{\gamma}^{\pi} = \int_{\mathcal{S}, \mathcal{A}} r(s, a) d\mu_{\gamma}^{\pi}(ds, da).$$

2.3.4 价值函数

在 RL 中，量化策略性能的重要概念是价值函数。在折扣情形下，状态-动作价值函数是智能体从某个状态 s 出发、先执行动作 a 而后遵循策略 π 所获得的期

望折扣奖励总和。其形式为：

$$Q^\pi(s, a) = \mathbb{E}_{\substack{s_{t+1} \sim p(\cdot|s_t, a_t) \\ a_t \sim \pi(\cdot|s_t)}} \left[\sum_{t=0}^H \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a \right]. \quad (2.3)$$

该函数称为 Q 函数 (Q-function)。自然也可定义状态价值函数 (或简称价值函数)，它是智能体从某个状态 s 出发并立即遵循策略 π 所获得的期望折扣奖励总和。状态价值函数由 Q 函数定义为：

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)} [Q^\pi(s, a)].$$

用于比较动作效果的一个有用概念是优势函数 A 。它量化了仅在下一步偏离给定策略所获得的优势。形式化地，

$$A(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (2.4)$$

在 RL 中，关注的是状态-动作价值函数和状态价值函数所能达到的最大值。最优状态价值函数和最优状态-动作价值函数为：

$$\begin{aligned} V^*(s) &= \sup_{\pi \in \Pi^{\text{HR}}} V^\pi(s), \\ Q^*(s, a) &= \sup_{\pi \in \Pi^{\text{HR}}} Q^\pi(s, a). \end{aligned}$$

达到这些值的策略 $\pi \in \Pi^{\text{HR}}$ 记为 π^* 。注意 Π^{SR} 中存在最优策略 [?, Theorem 6.2.10]，因此可将最优策略的搜索限制在该集合中。

2.3.5 Bellman 方程

在 MDPs 中寻找最优价值函数的核心概念是动态规划 [?]，其思想是将问题分解为更小的子问题。应用于 RL 时，计算任意状态价值函数的问题被递归地分解为每一步的价值函数关于未来价值函数的计算。这得益于 *Bellman* 期望算子 [?]

Definition 2.3.1 (Bellman 期望算子). 考虑一个 MDP 和策略 $\pi \in \Pi^{\text{SR}}$ ，令 $\mathcal{B}(\mathcal{S})$ 为 $\mathcal{S}$ 上有界可测函数的集合。状态价值函数的 *Bellman* 期望算子 $T_V^\pi : \mathcal{B}(\mathcal{S}) \mapsto \mathcal{B}(\mathcal{S})$ 对 $f \in \mathcal{B}$ 和 $s \in \mathcal{S}$ 定义如下：

$$(T_V^\pi f)(s) = \int_{\mathcal{A}} \pi(da|s) \left(r(s, a) + \gamma \int_{\mathcal{S}} p(ds'|s, a) f(s') \right). \quad (2.5)$$

类似地，状态-动作价值函数的 *Bellman* 期望算子 $T_Q^\pi : \mathcal{B}(\mathcal{S} \times \mathcal{A}) \mapsto \mathcal{B}(\mathcal{S} \times \mathcal{A})$ 对 $f \in \mathcal{B}$ 、 $s \in \mathcal{S}$ 和 $a \in \mathcal{A}$ 定义如下：

$$(T_Q^\pi f)(s, a) = r(s, a) + \gamma \int_{\mathcal{S}} p(ds'|s, a) \int_{\mathcal{A}} \pi(da'|s') f(s', a'). \quad (2.6)$$

若 $\gamma < 1$ ，这些算子是 L_∞ -范数下的 γ -压缩映射 [?, Proposition 6.2.5]。回忆 L_∞ -范数下的 γ -压缩映射是指算子 $T : X \mapsto X$ 对 $f, g \in X$ 满足：

$$\|Tf - Tg\|_\infty \leq \gamma \|f - g\|_\infty.$$

Bellman 期望算子的这些性质使其满足 Banach 不动点定理的条件，意味着递归应用这些算子将收敛到唯一的不动点。 Q 函数是 Q 的不动点，状态价值函数是 V 的不动点。由此定义 Bellman 期望方程：

$$Q^\pi = r(s, a) + \gamma \int_S p(ds'|s, a) V^\pi(s'), \quad (2.7)$$

$$V^\pi = \int_{\mathcal{A}} \pi(da|s) Q^\pi(s, a). \quad (2.8)$$

有趣的是，最优状态-动作价值函数和状态价值函数也是类似算子的不动点，这些算子称为 Bellman 最优性算子，定义如下。

Definition 2.3.2 (Bellman 最优性算子). 考虑一个 MDP，令 $\mathcal{B}(\mathcal{S})$ 为 $\mathcal{S}$ 上有界可测函数的集合。状态价值函数的 Bellman 最优性算子 $T_V^* : \mathcal{B}(\mathcal{S}) \mapsto \mathcal{B}(\mathcal{S})$ 对 $f \in \mathcal{B}$ 和 $s \in \mathcal{S}$ 定义如下：

$$(T_V^* f)(s) = \sup_{a \in \mathcal{A}} \left\{ r(s, a) + \gamma \int_S p(ds'|s, a) f(s') \right\}. \quad (2.9)$$

类似地，状态-动作价值函数的 Bellman 期望算子 $T_Q^* : \mathcal{B}(\mathcal{S} \times \mathcal{A}) \mapsto \mathcal{B}(\mathcal{S} \times \mathcal{A})$ 对 $f \in \mathcal{B}$ 、 $s \in \mathcal{S}$ 和 $a \in \mathcal{A}$ 定义如下：

$$(T_Q^* f)(s, a) = r(s, a) + \gamma \int_S p(ds'|s, a) \sup_{a' \in \mathcal{A}} \{f(s', a')\}. \quad (2.10)$$

这些算子也是 γ -压缩映射 [?, Proposition 6.2.4]，根据 Banach 不动点定理，分别以最优状态价值函数和最优状态-动作价值函数为不动点 [?, Proposition 6.2.5]。

类似地，最优价值函数满足以下 Bellman 最优性方程：

$$Q^*(s, a) = r(s, a) + \gamma \int_S p(ds'|s, a) V^*(s'), \quad (2.11)$$

$$V^*(s) = \sup_{a \in \mathcal{A}} Q^*(s, a). \quad (2.12)$$

2.3.6 光滑马尔可夫决策过程

考虑所有 MDPs 意味着需要考虑一些非常复杂、难以高效求解的问题。对 MDPs 施加假设以缩小范围，可以大幅降低复杂度，同时保持模型的现实性。在 RL 中普遍存在的一个假设是关于 MDP 的光滑性。为定义光滑性，首先回顾 Lipschitz 性质的概念。

Definition 2.3.3 (Lipschitz 连续性). 考虑 (X, d_X) 和 (Y, d_Y) 两个度量空间，以及函数 $f : X \rightarrow Y$ 。若对于 $L > 0$ 有

$$\forall x, x' \in X, d_Y(f(x), f(x')) \leq L d_X(x, x'),$$

则称 f 是 L -Lipschitz 连续的 (L -LC)。

在本文中，对于 $X \subset \mathbb{R}^n$ 的集合 X ，考虑 Euclidean 距离，定义为 $d_X(x, x') = \|x - x'\|_2$ 。对于概率分布，将考虑 L_1 -Wasserstein 距离²，其定义如下。

²为简洁起见，本文将 L_1 -Wasserstein 距离简称为 Wasserstein 距离。

Definition 2.3.4 (L_1 -Wasserstein 距离, [?]). 设 μ, ν 为样本空间 Ω 上的两个概率测度：

$$\mathcal{W}_1(\mu \| \nu) = \sup_{\|f\|_L \leq 1} \left| \int_{\Omega} f(\omega) (\mu - \nu) (d\omega) \right|,$$

其中 $\|f\|_L$ 是 f 的 *Lipschitz* 半范数：

$$\|f\|_L = \sup_{x, x' \in X, x \neq x'} \frac{d_Y(f(x), f(x'))}{d_X(x, x')}.$$

Lipschitz 性质可理解为某种光滑性概念，因为它限制了函数的增长速度。现准备描述 MDP 的光滑性。

Definition 2.3.5 (*Lipschitz* MDP, [?]). 若 $\forall (s, a), (s', a') \in \mathcal{S} \times \mathcal{A}$ 有

$$\begin{aligned} \mathcal{W}_1(p(\cdot | s, a) \| p(\cdot | s', a')) &\leq L_P (d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a, a')), \\ |r(s, a) - r(s', a')| &\leq L_r (d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a, a')), \end{aligned}$$

则称该 MDP 是 (L_P, L_r) -LC 的。

类似的光滑性假设也可施加于策略，如下定义所示。

Definition 2.3.6 (*Lipschitz* 策略). 一个平稳马尔可夫策略 π 是 L_{π} -LC 的，若 $\forall s, s' \in \mathcal{S}$

$$\mathcal{W}_1(\pi(\cdot | s) \| \pi(\cdot | s')) \leq L_{\pi} d_{\mathcal{S}}(s, s').$$

这些假设具有重要意义。例如，通过保证某个动作在状态空间的球域内占优，可以简化对主导动作的识别 [?]。同一文献还提供了关于 Q 函数 *Lipschitz* 性质的结果，如下所述。

Theorem 2.3.1 (Q 函数的 *Lipschitz* 性质, [?] 的定理 1). 考虑一个 (L_P, L_r) -LC 的 MDP 和一个 L_{π} -LC 的策略 π 。若 $\gamma L_P(1 + L_{\pi}) \leq 1$ ，则 Q^{π} 是 L_Q -LC 的，其中

$$L_Q = \frac{L_r}{1 - \gamma L_P(1 + L_{\pi})}.$$

最后，[?] 引入了关于时间的 *Lipschitz* 性质的更近期概念（假设 4.1）。该假设在延迟情况下尤其有用，因为轨迹的光滑性是智能体预测其动作效果的关键因素。

Definition 2.3.7 (时间 *Lipschitz* MDP, [?] 的假设 4.1). 若 $\forall (s, a) \in \mathcal{S} \times \mathcal{A}$ 有

$$\mathcal{W}_1(p(\cdot | s, a) \| \delta_s) \leq L_T,$$

其中 δ_s 由 *Dirac* 测度 δ 定义为 $\delta_s(x) = \delta(x - s)$ ，则称该 MDP 是 L_T -时间 *Lipschitz* 连续的 (L_T -TLC)。

该定义看似与传统的 *Lipschitz* 性质定义不一致，但本文将展示它可视为关于已历经步数的 *Lipschitz* 性质。实际上，右端可理解为 $L_T \cdot 1$ ，其中 1 对应于 MDP

的时间单位（即步）。对于左端，可将 $p(\cdot|s, a)$ 重写为 $p^1(\cdot|s, a)$ ，以强调转移发生在一步之内。考虑执行多个动作的情况，例如 n 个动作的序列 $\mathbf{a} = (a_1, \dots, a_n)$ ，可引入符号 $p^n(\cdot|s, \mathbf{a})$ 表示从状态 s 开始顺序执行 $\mathbf{a}$ 中的动作。进一步可将符号扩展为 $p^0(\cdot|s) = \delta_s$ ，表示在状态 s 不执行任何动作的效果。采用这一新符号后，TLC 定义中的等式变为：

$$\mathcal{W}_1(p^1(\cdot|s, a) \| p^0(\cdot|s)) \leq L_T \cdot (1 - 0).$$

此时更清晰地表明 Lipschitz 性质是针对 MDP 的步数而言的。将在 ?? 中证明 $p^n(\cdot|s)$ 与 $p^0(\cdot|s)$ 之间距离的推广结果。

2.3.7 POMDP

本小节简要介绍 partially observable Markov decision process (POMDP)（部分可观测马尔可夫决策过程）[?] 的概念，后文将看到它与延迟过程具有相似性。POMDP 扩展了 MDP 框架，用于处理智能体无法观测当前状态、只能获取部分信息的情形。更形式化地，POMDP 是一个七元组 $(\mathcal{S}, \mathcal{A}, p, R, d_0, \Omega, O)$ ，与 MDP 相比增加了两个元素。首先， Ω 是智能体可能接收到的观测集（而非状态本身）。其次， $O : \mathcal{S} \times \mathcal{A} \mapsto \mathcal{P}(\Omega)$ 称为观测函数，定义了 Ω 上的概率分布。具体而言，若智能体通过执行动作 a 到达状态 s' ，则 $O(o; s', a)$ 是智能体收到观测 o 的概率。奖励函数和转移函数仍依赖于环境的当前状态，但该状态对智能体是未知的。优化目标仍为 ?? 所定义的目标。

求解 POMDP 的传统方法是维护当前状态的概率分布（称为置信状态），并通过每次收集到的新观测更新该概率。如此可将问题转化回 MDP，其中状态即为上述置信状态。类似概念在控制理论文献 [?] 中称为信息状态（information state），后文将在 ?? 中看到，该概念也被用于延迟问题。关于 POMDP 的更多信息，请参阅 [?, ?]。

2.4 强化学习

RL（强化学习）是 ML 的一个分支，旨在由 MDP 建模的序贯决策问题中学习最优策略。强化学习的主要难点在于通过与环境交互收集数据并从中学习。样本复杂度（智能体通过与环境交互收集的样本数）是衡量强化学习算法的重要指标。从环境中采样在时间、计算资源或资金方面可能代价高昂。虽然可以用仿真代替，但这会引入模型从仿真迁移到现实时的问题³。因此，常用样本复杂度来衡量强化学习算法的效率。

尽管智能体的性能仍是设计者希望优化的最终目标，但最终目标与样本复杂度之间存在一定权衡：一个学习快速的智能体可能优于保证达到最优行为但需要极长时间的智能体。这一权衡称为探索-利用问题，其中智能体必须在执行已知收益较高的动作与执行收益不确定的动作之间权衡，以获取对环境的了解。

历史上，最早应用于 MDP 问题的方法是动态规划算法，如策略迭代 [?]。但这些方法需要了解转移动力学并在 MDP 的每个状态中维护价值函数，因此受到限制。向更现实的问题推进时，强化学习已去除了已知动力学的假设，并开始考虑更大的状态空间，最终扩展到连续空间，从而需要函数近似。本节后续部分将深入探讨其中一些解决方案，这些方案在本文中很有用，因为延迟强化学习中的许多算法都基于它们。将首先介绍针对折扣回报准则设计的算法，最后介绍针对平均奖励的算法。

³值得注意的是，延迟在仿真中通常被忽略，在现实世界测试时可能引发问题。

2.4.1 基于价值的方法

解决强化学习问题的第一种方法是学习价值函数 V 或动作价值函数 Q ，这正是基于价值的方法所做的。开创性方法包括 SARSA [?] 和 Q 学习 (Q-learning) [?], 它们基于动态规划。

Q 学习

Q 学习 [?] 是一种流行算法，通过与环境交互并利用最优 Bellman 方程 ?? 更新估计值, 递归地学习最优 Q 函数。该算法通过与环境交互采样形如 (s_t, a_t, r_t, s_{t+1}) 的四元组，并用于更新 Q 函数：

$$\hat{Q}(s_t, a_t)_i = \hat{Q}(s_t, a_t) + \alpha \delta_{TD,t}, \quad (2.13)$$

其中 $\delta_{TD,k}$ 称为当前 Q 函数与其一步自举之间的temporal difference (TD) (时序差分) 误差。形式化地，在第 t 步：

$$\delta_{TD,t} = r_t + \gamma \max_{a \in \mathcal{A}} \hat{Q}(s_{t+1}, a) - \hat{Q}(s_t, a_t). \quad (2.14)$$

Q 学习是一种离策略 (off-policy) 算法，因为它用于从环境采样的策略与用于更新的策略不同。通常使用关于 $\hat{Q}$ 的 ϵ -贪心策略进行采样，即该策略以 $1 - \epsilon$ 的概率选择最大化 $\hat{Q}$ 的动作，以 ϵ 的概率在 $\mathcal{A}$ 中均匀随机选择动作。而更新中 TD 误差项 (??) 使用的策略关于 $\hat{Q}$ 是贪心的，因为它始终选择最大化动作。采样的 ϵ -贪心策略 (或其变体) 对探索很有用，它确保 MDP 的每个状态-动作对将被无限频繁地访问，这是算法收敛性证明的要求 [?], 使智能体能评估不同动作的效果，从而可能获得更高奖励。

SARSA

SARSA [?] 算法与 Q 学习非常相似。它是一种在策略 (on-policy) 算法，智能体使用当前策略从环境中采样五元组 $(s_t, a_t, r_t, s_{t+1}, a_{t+1})$ 。使用这些样本，TD 误差表达式变为：

$$\delta_{TD,t} = r_t + \gamma \hat{Q}(s_{t+1}, a_{t+1}) - \hat{Q}(s_t, a_t).$$

注意， a_{t+1} 替换了 ?? 更新中最大化 Q 的动作。

深度 Q 网络

当状态空间 $\mathcal{S}$ 过大时，一种解决方案是对 Q 函数采用近似方法。一种选择是使用深度神经网络作为近似器，如 Deep Q Network (DQN) (深度 Q 网络) [?]。注意动作空间 $\mathcal{A}$ 仍保持离散，因此 ?? 中的最大值可计算。放宽离散动作空间假设的工作已由其他方法提出，如深度确定性策略梯度 (DDPG) [?]

在 DQN 中，Q 函数由参数 θ 参数化，目标是找到 $Q_\theta(s, a) \sim Q^*(s, a)$ 。给定当前参数集 θ_i ，下一参数集 θ_{i+1} 通过最小化以下 TD 误差获得：

$$\delta_{TD}(\theta_i, \rho) = \mathbb{E}_{(s,a,r,s') \sim \rho} \left[\left(r + \gamma \max_{a \in \mathcal{A}} Q_{\theta_i}(s') - Q_{\theta_{i+1}}(s, a) \right)^2 \right]. \quad (2.15)$$

其中 ρ 是 $\mathcal{S} \times \mathcal{A} \times [0, R_{\max}] \times \mathcal{S}$ 上的分布。通常在 ?? 最小化的每次迭代中，使用关于 $Q_{\theta_{i+1}}$ 的 ϵ -贪心策略收集新样本 (s, a, r, s') 。[?] 观察到，在回放缓冲区中

不仅保留最近采样的四元组，还保留较旧的样本来最小化 ??，可以使学习更平滑，并使问题更接近 supervised learning (SL) (监督学习)。这一技术称为经验回放 (experience replay)。因此，缓冲区中填充了来自许多不同策略的样本，将这些策略的混合称为 ρ 。

2.4.2 基于策略的方法

基于价值的方法的一个主要限制是智能体学习到关于环境的额外知识，这些知识可能不直接有用。最终，唯一关心的是学习最优行为，而学习 Q 函数只是实现这一目标的间接方式。相比之下，基于策略的方法直接从与环境的交互中学习策略。

通常，策略被视为参数化函数，从而将问题从函数集合上的搜索转化为参数集合上的搜索。这一框架称为 *policy optimization* (PO) (策略优化) [?], 将策略置于参数化集合 $\Pi_{\Theta} = \{\pi_{\theta} : \theta \in \Theta \subseteq \mathbb{R}^{n_{\theta}}\}$ 中考虑。

策略完全由其参数 θ 指定，因此简化其回报符号为 $J(\theta) = J_{\gamma}^{\pi_{\theta}}$ 。智能体的新目标变为：

$$\theta^* \in \arg \max_{\theta \in \Theta} J(\theta). \quad (2.16)$$

策略 π_{θ} 需要是随机化的，以提供足够的探索。若策略对 θ 可微，则策略优化的以下基本结论成立。

Theorem 2.4.1 (策略梯度定理). 设 $\pi_{\theta} \in \Pi_{\Theta}$ 是随机化策略，对 θ 可微，则其回报的梯度为

$$\nabla_{\theta} J(\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d_{\gamma}^{\pi_{\theta}} \\ a \sim \pi_{\theta}(\cdot|s)}} [Q^{\pi_{\theta}}(s, a) \nabla_{\theta} \log \pi_{\theta}(a|s)]$$

注意，许多工作（包括最先进的方法）使用梯度的近似，从状态分布中去除折扣，但保留在 Q 函数中。该量可能不再是任何函数的梯度 [?]，但提供了良好的实证结果。

策略梯度不需要访问 MDP 模型，可以从样本中估计。以下两段介绍两种主要估计器，它们的公式假设可以访问轨迹数据集 $(\tau_i)_{1 \leq i \leq n}$ ，其中每条轨迹长度为 H ，具体为 $\tau_i = (s_0^i, a_0^i, r_0^i, \dots, s_H^i)$ 。

REINFORCE

[?] 提出的 REINFORCE 估计器为：

$$\widehat{\nabla_{\theta} J(\theta)} = \frac{1}{n} \sum_{i=1}^n \sum_{t=1}^{H-1} \nabla_{\theta} \log \pi_{\theta}(a_t^i | s_t^i) \left(\sum_{t'=0}^{H-1} \gamma^{t'} r_{t'}^i \right).$$

该估计器通常方差过高，但可以从最右边项中减去常数基线 b ，而不引入偏差，同时允许控制方差 [?]

策略梯度定理

降低上述估计器方差的另一种方法是注意到未来动作不影响过去奖励。实际上，对于任意 $i > j$ ，记 $d_{\gamma,j:i}^\pi$ 为策略 π 下轨迹片段 $(s_j, a_j, \dots, s_i, a_i)$ 的分布，则有：

$$\begin{aligned}
& \mathbb{E}_{(s_j, a_j, \dots, s_i, a_i) \sim d_{\gamma,j:i}^\pi} [\nabla_{\theta} \log \pi_{\theta}(a_i | s_i) r(s_j, a_j)] \\
&= \mathbb{E}_{\substack{(s_j, a_j, \dots, s_{i-1}, a_{i-1}) \sim d_{\gamma,j:i-1}^\pi \\ s_i \sim p(\cdot | s_{i-1}, a_{i-1})}} \left[r(s_j, a_j) \int_{\mathcal{A}} \pi_{\theta}(a_i) \nabla_{\theta} \log \pi_{\theta}(a_i | s_i) da_i \right] \\
&= \mathbb{E}_{\substack{(s_j, a_j, \dots, s_{i-1}, a_{i-1}) \sim d_{\gamma,j:i-1}^\pi \\ s_i \sim p(\cdot | s_{i-1}, a_{i-1})}} \left[r(s_j, a_j) \int_{\mathcal{A}} \nabla_{\theta} \pi_{\theta}(a_i) da_i \right] \\
&= \mathbb{E}_{\substack{(s_j, a_j, \dots, s_{i-1}, a_{i-1}) \sim d_{\gamma,j:i-1}^\pi \\ s_i \sim p(\cdot | s_{i-1}, a_{i-1})}} [r(s_j, a_j) \nabla_{\theta} 1] \\
&= 0
\end{aligned}$$

由此得到策略梯度定理 (PGT) [?]:

$$\widehat{\nabla_{\theta} J(\theta)} = \frac{1}{n} \sum_{i=1}^n \sum_{t=1}^{H-1} \nabla_{\theta} \log \pi_{\theta}(a_t^i | s_t^i) \left(\sum_{t'=t}^{H-1} \gamma^{t'} r_{t'}^i - b(s_t) \right). \quad (2.17)$$

注意最右边项的和现在从 t 开始。与 REINFORCE 一样，此处也引入了基线 b 以进一步降低方差。在 PGT 中，基线可依赖于当前状态 s_t 而不引入偏差 [?]。[?] 讨论了基线选取的策略。

信任域策略优化

Trust Region Policy Optimization (TRPO) (信任域策略优化) [?] 是一种基于策略的算法，其思想是提供安全的改进步骤，即保证性能提升的策略更新。其理论基础依赖于著名的性能差异引理，在此回顾。

Lemma 2.4.1 (性能差异引理, [?] 的引理 6.1). 设 $\pi, \pi' \in \Pi^{SR}$ ，其期望折扣回报分别为 J_{γ}^{π} 和 $J_{\gamma}^{\pi'}$ ，则

$$J^{\pi'} - J^{\pi} = \frac{1}{1 - \gamma} \mathbb{E}_{(s,a) \sim d_{\gamma}^{\pi'}} [A^{\pi}(s, a)].$$

基于该引理，[?] 构建了一个替代目标函数，其最大化保证了 $J_{\gamma}^{\pi'}$ 的提升。

令 $C = \frac{4\epsilon\gamma}{(1-\gamma)^2}$ 和 $\epsilon = \max_{s,a} A^{\pi}(s, a)$ ，[?] 证明：

$$J_{\gamma}^{\pi'} \geq \underbrace{J_{\gamma}^{\pi} + \frac{1}{1 - \gamma} \mathbb{E}_{(s,a) \sim d_{\gamma}^{\pi}} [A^{\pi'}(s, a)]}_{:= L^{\pi}(\pi')} - C \max_s D_{\text{KL}}^{\max}(\pi(\cdot | s), \pi'(\cdot | s)).$$

为简化优化，[?] 在最终目标中用平均 KL 散度替代最大 KL 散度，前者在实践中更易计算。此外， C 中的惩罚项被替换为约束，以允许更大但稳健的更新步

长。最大化问题变为：

$$\begin{aligned} & \underset{\pi'}{\text{maximise}} && L^\pi(\pi') \\ & \text{subject to} && \mathbb{E}_{s \sim d_\gamma^\pi} [D_{\text{KL}}(\pi(\cdot|s), \pi'(\cdot|s))] \leq \delta. \end{aligned}$$

TRPO 已被证明是一种经验高效的算法。

近端策略优化

尽管 TRPO 取得了实证成功，但其计算成本较高，因为需要计算 KL 散度的 Hessian 矩阵及其逆。相比之下，Proximal Policy Optimization (PPO) (近端策略优化) [?] 提出使用裁剪操作将问题还原为一阶优化方案，以保持策略在安全区域内。实证结果表明，PPO 与 TRPO 至少同样高效，尤其在计算更简单方面表现更优。

基于参数的优化

从参数化 PO 出发，可以增加一层抽象，考虑优化超策略而非策略本身。基本上，超策略定义了智能体将遵循的策略的选择规则。在此设定中，策略的参数 θ 由超策略 ν_ρ 采样，超策略本身由参数向量 ρ 参数化，其中 ρ 属于 $\mathcal{V}_\rho = \{\nu_\rho : \rho \in \mathcal{P} \subseteq \mathbb{R}^{n_\rho}\}$ [?]。将随机性转移到超策略后，策略不再需要是随机化的。这对于降低估计器方差是一个巨大优势。实际上，只需采样单一 θ 即可收集一条轨迹，轨迹的随机性仅来自环境。此框架中的目标变为：

$$\rho^* \in \arg \max_{\rho \in \mathcal{P}} J(\rho) = \arg \max_{\rho \in \mathcal{P}} \mathbb{E}_{\theta \sim \nu_\rho} J(\theta). \quad (2.18)$$

将此设定称为基于参数的 PO，将原始设定称为基于动作的 PO。

2.4.3 Actor-Critic

在 ?? 的公式中，项 $\sum_{t'=t}^{H-1} \gamma^{t'} r_{t'}$ 实质上是 Q 函数 $Q(s_t, a_t)$ 的蒙特卡洛估计。Actor-Critic 方法提出将该估计替换为 TD 估计，如 TD(0)：

$$G_t^0 = r_t + \gamma V_\phi(s_{t+1}).$$

这里 V_ϕ 是使用参数 ϕ 对状态价值函数的当前近似。在 Advantage Actor-Critic (A2C) 算法 [?] 中，选择 $V_\phi(s_t)$ 作为 ?? 中的基线是一个有趣的选择。它将 ?? 中最右边的括号项变为：

$$\widehat{\nabla_{\theta} J(\theta)} = \frac{1}{n} \sum_{i=1}^n \sum_{t=1}^{H-1} \nabla_{\theta} \log \pi_{\theta}(a_t^i | s_t^i) \left(r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) \right). \quad (2.19)$$

注意新项对应于 $r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t) = A_\phi(s_t, a_t)$ ，这是优势函数的估计（参见 ??）。Actor-Critic 的名称源于该方法同时学习策略 π_{θ} (actor) 和状态价值函数 V_ϕ (critic)。该算法交替使用 ?? 的梯度估计更新策略，并使用以下目标最小化期望平方 TD 误差来更新价值函数（参见 ?? 作比较）：

$$\delta_{TD}(\phi_i, \rho) = \mathbb{E}_{(s, a, r, s') \sim \rho} \left[(r + \gamma V_{\phi_i}(s') - V_{\phi_i}(s))^2 \right]. \quad (2.20)$$

同样， ρ 是某个转移数据集 $\mathcal{D}$ 上的分布。Actor-Critic 相对于 PGT 和 REINFORCE 的一个主要优势是它支持离策略学习。

Soft Actor-Critic

本文中将使用的 Actor-Critic 算法示例是 Soft Actor-Critic (SAC) (Soft Actor-Critic) [?]. 其主要特点是在上述标准 A2C 的更新中增加了熵正则化。对于随机变量 X ，其概率为 $p(x) = \mathbb{P}(X = x)$ ，熵定义为：

$$H(X) = \mathbb{E}_{x \sim p} [-\log p(x)].$$

熵正则化 RL 在原始奖励函数中增加了策略熵的奖励。这意味着回报现在变为：

$$J_\gamma^\pi = (1 - \gamma) \mathbb{E} \left[\sum_{t=1}^H \gamma^t \mathbb{P}(S_t = s; \pi, \mu) \pi(a|s) (r(s, a)v + \alpha H(\pi(\cdot|s))) \right], \quad (2.21)$$

其中 $\alpha > 0$ 是控制正则化强度的参数。

根据这一新的回报，可提出新的状态价值函数和状态-动作价值函数，TD 误差也与 ?? 不同。因此，在 SAC 中，状态-动作价值函数通过最小化以下目标学习：

$$\delta_{TD}(\phi_i, \rho) = \mathbb{E}_{(s, a, r, s') \sim \rho} \left[(y(r, s') - Q_{\phi_i}(s, a))^2 \right], \quad (2.22)$$

其中

$$y(r, s') = \mathbb{E}_{a' \sim \pi_{\theta_i}} \left[r + \gamma \min_{j \in \{1, 2\}} Q_{\phi_{\text{target}, j}}(s', a') - \alpha \log \pi_{\theta_i}(a'|s') \right].$$

目标 Q 函数 $(Q_{\phi_{\text{target}, j}})_{j \in \{1, 2\}}$ 是最近几次迭代中 Q 函数参数的 Polyak 平均值，用于替代当前 Q 函数 Q_{ϕ_i} ，以避免实证中观察到的不稳定性。 $\min_{j \in \{1, 2\}}$ 是另一个避免过高估计的经验性技巧。完整算法参见 [?].

2.4.4 模仿学习

模仿学习这一范式源于以下观察：从示范中学习技能通常比从零开始学习更容易。实际上，在固定的观测集上学习模仿专家策略属于 *supervised learning (SL)* (监督学习) 框架，通常比 RL 更简单。因此，模仿学习旨在缩小 RL 与 SL 之间的差距。为更形式化地定义该框架，设 π_E 为专家策略；大多数模仿学习方法的目标是找到学习者的策略 π_I ，使得 $\mathbb{E}_{s \sim d_{\mu}^{\pi_E}} [l(s, \pi_I)]$ 最小化 [?]。函数 $l(s, \pi)$ 是一个损失函数，旨在使 π_I 更接近 π_E 。值得注意的是，该目标是在 π_E 诱导的状态分布下定义的。这可能带来问题，因为一旦学习者犯错，它可能进入一个对专家行为了解不足的状态，从而进一步犯错。因此，误差可能按有效水平线的平方传播 [?, Theorem 2.1] [?, Theorem 1]。

其他模仿学习方法旨在解决这一问题，但通常不实用，如 [?] 所述。例如，[?] 提出使用非平稳策略，这需要为每个时间步训练一个策略，对长水平线而言计算成本高昂。[?] 提出的另一种方法 SMILe 则考虑策略的混合，每次迭代增加一个策略。如 [?] 所述，这在实践中存在问题，因为混合中包含不同质量的策略，较弱策略可能犯错，而较强策略必须弥补这些错误，这显然会造成不稳定。

一个相当成功的解决方案称为数据集聚合 (DAGGER) [?]。该模仿算法在学习者的状态分布下计算损失 [?]，因此能够考虑学习者策略可能犯错所导致的分布偏移。后文将看到，在延迟情况下，延迟会加剧延迟策略与无延迟策略之间

状态分布的差异，因此这是模仿算法所需的一个理想性质。实际上，DAGGER 的思想很简单：根据与学习者相似的策略收集新样本，然后仅在这些样本上查询专家，了解专家本应采取的动作。这提供了与学习者状态分布相匹配的样本，是一个巨大优势。采样策略为 $\pi_i = \beta_i \pi_E + (1 - \beta_i) \hat{\pi}_i$ ，其中 β_i 是专家策略与学习者当前策略 $\hat{\pi}_i$ 混合的权重。通过将采样状态 s 与专家选择的动作 $\pi_E(s)$ 相结合，构建用于 SL 步骤的数据集 $\mathcal{D}$ 。然后在 $\mathcal{D}$ 上训练新的模仿策略 $\hat{\pi}_{i+1}$ 。序列 $(\beta_i)_{i \in [1, N]}$ 满足 $\beta_1 = 1$ （初始仅从 π_E 采样）和 $\beta_N = 0$ （最终仅从模仿策略采样）。

2.4.5 理论强化学习

在最后一小节中，介绍针对平均奖励准则设计的方法。这些方法通常更具理论性，关注平衡 MDP 的探索与已获取知识的利用。智能体必须学习在这两种策略之间权衡，以免相对于专家损失太多。损失可以理解为因缺乏探索而错失机会，或因缺乏利用而损失奖励。该设定属于在线学习范畴。为更好理解该设定，介绍在线学习的一个子领域：个体序列预测 [?]。该领域考虑一个智能体需要在 K 个动作（称为臂）之间反复选择。每个臂为智能体提供奖励，奖励可以随机方式或对抗方式产生。环境没有状态，智能体可随时在 K 个臂之间选择。该框架可表示为具有单一状态的 MDP，即 $|\mathcal{S}| = 1$ 。当智能体只能观察到所选臂的奖励，而无法观察到其他 $K - 1$ 个臂的奖励时，该设定称为多臂赌博机 [?]。当奖励是随机时，称为随机赌博机；当奖励是对抗性时，称为对抗赌博机。

在该领域中，一个重要的概念是遗憾 (regret)，即学习智能体收集的奖励与事后最优策略收集的奖励之间的期望差异。目标是获得次线性 (sub-linear) 的遗憾，表明智能体越来越接近专家策略。解决该问题的常用方法是在不确定性面前保持乐观。在估计量（臂的奖励）上计算上置信界，智能体选择具有最佳上界的臂。后文将在 ?? 中看到延迟在赌博机文献中是如何处理的。

上置信界的思想也已应用于 RL。先驱者是 UCRL 算法 [?]，它对奖励函数和转移函数维护置信界。在 RL 中，对于某个 MDP $\mathcal{M}$ ，遗憾定义为：

$$\mathcal{R}(T, s) := T \cdot \max_{\pi \in \Pi^{\text{MR}}} J_{\text{AVG}}^{\pi}(s) - \sum_{t=1}^T r(s_t, a_t)$$

其中 $J_{\text{AVG}}^{\pi}(s)$ 是具有初始状态分布 δ_s 的最优马尔可夫策略的平均奖励性能， $\sum_{t=1}^T r(s_t, a_t)$ 是学习算法在前 T 步中收集的奖励。UCRL 利用关于 MDP 混合时间的信息并假设过程的遍历性，以实现次线性遗憾。

后文将看到，后续方法在更小的遗憾和更弱的假设方面改进了 UCRL 的结果。从这些方法中，重点关注 UCRL2 [?]，它适用于连通 MDPs [?, Section 8.3.1]。下面回顾连通 MDPs 的定义。

Definition 2.4.1 (连通 MDP). MDP $\mathcal{M}$ 称为连通的，若对于任意状态 s 和 s' ，存在一个确定性平稳策略，使从 s 出发能以非零概率到达 s' 。

注意在连通 MDPs 中，平均奖励 $J_{\text{AVG}}^{\pi}(s)$ 不再依赖于 s 。UCRL2 的结果依赖于 MDP 的直径 (diameter) 概念，该概念与连通性密切相关。事实上，有限直径与连通 MDPs 是等价的 [?]。其定义如下。

Definition 2.4.2 (MDP 的直径 [?]). 设 $\mathcal{M}$ 为一个 MDP， π 为 $\mathcal{M}$ 上的一个平稳策略。令 $T(s'|s; \pi)$ 为测量策略 π 从 s 出发首次到达 s' 所需时间的随机变

量。则 $\mathcal{M}$ 的直径为：

$$D(\mathcal{M}) := \max_{s \neq s' \in \mathcal{S}} \min_{\pi \in \Pi^{\mathcal{S}}} \mathbb{E}[T(s'|s; \pi)].$$

利用直径的知识，[?] 提出了基于乐观主义的算法分析，证明了次线性遗憾。

2.5 其他预备知识

本节介绍论文中将遇到的其他统计和 ML 概念。

2.5.1 重要性采样

重要性采样 (*Importance Sampling* (IS)) [?] 是一种统计工具，用于在只能访问由另一个分布 Q (行为分布) 收集的样本时，估计某个函数 $f: X \mapsto \mathbb{R}$ 关于目标分布 P 的期望 $\mu = \mathbb{E}_{x \sim P}[f(x)]$ 。记 p 和 q 分别为 P 和 Q 的密度函数。若 P 关于 Q 绝对连续 (记作 $P \ll Q$)，则重要性采样按以下方式构建 μ 的无偏估计量：

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N \frac{p(x_i)}{q(x_i)} f(x_i)$$

其中 $\{x_i\}_{i=1}^N \sim Q$ 。

进一步，多重重要性采样 (*multiple importance sampling* (MIS)) 考虑一组行为分布 $(Q_j)_{j \in [1, J]}$ 而非单一分布 Q 。记 $(q_j)_{j \in [1, J]}$ 为 $(Q_j)_{j \in [1, J]}$ 的密度函数。设 N 为总样本数， N_j 为由 Q_j 采样的样本数，满足 $N = \sum_{j=1}^J N_j$ 。若对于所有 $j \in [1, J]$ 有 $P \ll Q_j$ ，则无偏的 MIS 估计量为：

$$\hat{\mu} = \sum_{j=1}^J \frac{1}{N_j} \sum_{i=1}^{N_j} \beta_j(x_{ij}) \frac{p(x_{ij})}{q_j(x_{ij})} f(x_{ij}),$$

其中 $\{x_{ij}\}_{i=1}^{N_j} \sim Q_j$ ，且 $(\beta_j(x))_{j \in [1, J]}$ 是 X 上的单位分割。该分割的选择是自由的，但常见的选择是平衡启发式 (BH) [?]，其设置为：

$$\beta_j(x) = \frac{N_j q_j(x)}{\sum_{k=1}^J N_k q_k(x)}.$$

BH 可视为将估计量还原为经典的重要性采样估计量，其中样本可视为来自混合分布：

$$\Phi = \sum_{k=1}^J \frac{N_k}{N} Q_k.$$

2.5.2 散度

统计学中的散度定义了概率分布之间距离的某种度量。本节定义本文中将使用的两种散度。

KL 散度 (Kullback-Leibler 散度) [?, Section 2.3]. 对于同一概率空间上的两个概率分布 P 和 Q , 且 $P \ll Q$, 它们之间的 KL 散度定义为:

$$D_{\text{KL}}(P\|Q) = \int_{\Omega} p(\omega) \log \frac{p(\omega)}{q(\omega)} d\omega.$$

Rényi 散度 [?]. 对于满足 $P \ll Q$ 的两个概率分布 P 和 Q , α -Rényi 散度对 $\alpha \in [0, \infty]$ 定义为:

$$D_{\text{R},\alpha}(P\|Q) = \frac{1}{\alpha - 1} \log \int_{\Omega} p(\omega)^{\alpha} q(\omega)^{1-\alpha} d\omega. \quad (2.23)$$

记 $D_{\text{R},\alpha}^{\text{exp}}(P\|Q) = \exp\{D_{\text{R},\alpha}(P\|Q)\}$ 为指数 α -Rényi 散度。Rényi 散度的意义在于它与重要性权重的 α 矩相关:

$$\mathbb{E}_{x \sim Q} \left[\left(\frac{p(x)}{q(x)} \right)^{\alpha} \right] = D_{\text{R},\alpha}^{\text{exp}}(P\|Q)^{\alpha-1}.$$

注意, 1-Rényi 散度虽未由 ?? 直接定义, 但可通过连续性得到 [?], 对应于 KL 散度。本文始终考虑 2-Rényi 散度, 为简洁起见, 省略指数符号 $D_{\text{R},2} = D_{\text{R}}$ 。

2.5.3 神经网络

neural network (NN) (神经网络) 是一种参数化函数 f , 由仿射映射与逐点非线性函数的堆叠构成。后者在神经网络逼近复杂函数的能力中起核心作用, 称为激活函数。常见的激活函数包括 sigmoid 或修正线性单元 (ReLU)。多年来, 神经网络架构层出不穷, 从简单的全连接网络 (也称为密集网络、线性网络或前馈网络) 到结构更复杂、层数和参数更多的深度神经网络 [?]. 全连接网络由参数矩阵 $W \in \mathbb{R}^{n \times m}$ (称为权重) 和激活函数 σ 组成。当应用于输入 $x \in \mathbb{R}^m$ 时, 网络输出 $y = \sigma(Wx) \in \mathbb{R}^n$ 。若仅应用一组线性函数和非线性函数的组合, 则称为一个层。多个这样的层堆叠起来可得到另一个网络。另一种普遍存在的层类型是卷积。卷积通过在输入的一维、二维甚至更多维度上递归地将核应用于输入的子集来扫描输入。核的大小称为感受野。由于核是固定的, 该操作类似于数学中卷积的定义, 故由此得名。卷积相对于全连接层的巨大优势在于权重的数量减少和输入的结构化映射, 这解释了卷积在实证上的巨大成功 [?]. 当应用于时间序列 (按时间索引的序列) 时, 卷积可以保持因果性, 称为时间卷积 [?, ?]. 下文深入介绍两种更复杂的网络, 它们将在本文后续中使用。

Transformer

Transformer [?] 是为序贯到序贯任务 (即编码一个序列然后解码为另一个序列) 而引入的网络。Transformer 利用注意力机制 [?] 与前馈层相结合来编码或解码序列。除了性能更优之外, Transformer 相对于以往序贯到序贯任务方法的一个主要优势在于其计算成本。以往方法依赖于循环神经网络, 后者顺序处理输入并执行随时间反向传播, 这大大降低了处理速度。Transformers 的另一个有用性质是它们可以保持输入序列的因果性。在结束这一简短介绍之前, 关注 Transformer 中的一个特定层——位置编码, 它在后文将特别有用。位置编码是 Transformer 的早期层, 允许向序列中元素的位置添加信息。它将该元素索引的向量表示计算为该索引的一组正弦变换。这种表示的一个有趣性质是, 无论索引值多大, 其输出都是正弦函数, 因此有界。此外, 向量表示的规模可由网络设计者控制。

基于流的模型

基于流的模型是一种生成模型，如生成对抗网络 (GAN) [?]. 生成模型是在数据集 $\mathcal{D}$ 上训练的 NN，用于生成具有与 $\mathcal{D}$ 相同统计特性的新数据点。然而，与 GAN 和大多数生成模型不同，基于流的模型不仅学习生成模型，还学习用于生成 $\mathcal{D}$ 的原始概率 p 。这一性质，加上基于流方法出色的实证结果 [?, ?]，是本文中它们的原因。

具体而言，将介绍 Masked-Autoregressive Flow (MAF) (掩码自回归流) [?] 网络，它结合了归一化流 [?] 和自回归密度估计 [?] 两种思想。MAF 所基于的自回归密度估计方法（如掩码自编码器分布估计器 MADE）[?] 的思想是递归地逐维生成样本。实际上，为了从概率分布 p 中采样向量 $\mathbf{x} \in \mathbb{R}^n$ ，自回归密度估计将 $p(\mathbf{x}) = \prod_{i=1}^n p(x_i | x_{1:i-1})$ 重写，每个条件概率 $p(x_i | x_{1:i-1})$ 可由 NN 近似。而归一化流通过学习将某个可逆函数 f 应用于从基分布 ρ 中采样的向量 $\mathbf{u} \in \mathbb{R}^m$ ，来生成样本 $\mathbf{x} \sim p$ 。该基分布通常很简单，如正态分布。所得概率可表示为：

$$p(\mathbf{x}) = \rho(f^{-1}(\mathbf{x})) \left| \det \left(\frac{\partial f^{-1}}{\partial \mathbf{x}} \right) \right|. \quad (2.24)$$

MAF 结合了这些方法，按以下方式逐维生成样本 $\mathbf{x}$ ：

$$x_i = u_i \exp(\alpha_i) + \mu_i \quad (2.25)$$

其中 $\mu_i = f_{\mu_i}(x_{1:i-1})$ 和 $\alpha_i = f_{\alpha_i}(x_{1:i-1})$ 由神经网络建模， $u_i \sim \mathcal{N}(0, 1)$ 。

如前所述，MAF 学习数据点 $\mathbf{x}$ 的密度，可使用 ?? 访问该密度。由于生成过程的递归结构，该方程中的逆函数具有简单的表达式： $\exp(\sum_{i=1}^n \alpha_i)$ [?]。归一化流层可以堆叠以近似更复杂的概率分布；同样的思想适用于 MAF。

将 p_θ 记为其学习到的概率，MAF 网络通过最小化 KL 散度 $D_{\text{KL}}(p, p_\theta)$ 来训练，该散度使用训练集 $\mathcal{D}$ 中的样本进行估计。实践中，网络通过以下目标进行训练：

$$\underset{\theta}{\text{maximise}} \sum_{\mathbf{x} \in \mathcal{D}} \log p_\theta(\mathbf{x}).$$

3.1 引言

尽管MDPs具有通用性，但仍无法把握许多序列决策问题的复杂性。例如，POMDP便是如此。本章旨在扩展原始框架，引入延迟（delay）概念。延迟可能出现在状态观测、动作执行或奖励收集中。状态观测延迟（state observation delay）指智能体观测到的状态并非环境当前状态，而是过去某一时刻的状态。但智能体仍须选择一个将施加于当前未观测状态的动作。在动作执行延迟（action execution delay）情形下¹，智能体所选择的动作将施加于未来某一状态。相反，施加于当前状态的动作是智能体在过去选择的。如上文所述，前两类延迟相似，而最后一种延迟——奖励收集延迟（reward collection delay）——则略有不同。奖励收集延迟指智能体在转换发生后若干步才获得该转换对应的奖励。将奖励分配至正确转换时，考虑此类延迟尤为重要。因此，这类延迟可能涉及信用分配（credit assignment）问题，主要在在线学习方法中研究，在奖励收集过程中高效学习至关重要。

延迟在RL应用中普遍存在，但通常未被考虑，从而导致次优行为。值得注意的是，在仿真中训练并针对现实问题测试是延迟可能产生危害的典型场景。在仿真中忽略物理传感器或执行器引入的延迟十分常见。然而，这些延迟可能是从仿真迁移到现实时性能下降的根源。

本章首先提出统一RL中延迟问题的符号表示。我们定义了延迟MDPs，即在MDP框架基础上引入延迟的序列决策过程扩展。然后，介绍文献和实践中的主要延迟类型。最后，讨论延迟RL及相关领域的文献。现有文献综述尚不完善，且先前工作中结果重叠现象普遍存在。

¹此处沿用 [?] 的命名法。




Figure 3.1: 无延迟MDP的表示。

3.2 符号表示

下面给出延迟MDP的通用定义，将文献中遇到的大多数延迟类型作为特例包含在内。记delayed Markov decision process (Δ MDP)为延迟MDP²。 Δ MDP源于一个MDP并附有三组序列变量：动作执行延迟 $(\Delta_t^a)_{t \in \mathbb{N}}$ ；状态观测延迟 $(\Delta_t^s)_{t \in \mathbb{N}}$ ；奖励收集延迟 $(\Delta_t^r)_{t \in \mathbb{N}}$ 。注意这一记号突出了延迟可能随时间变化。在文献中，延迟通常被假设为马尔可夫过程，即 $\Delta_t \sim P(\cdot | \Delta_{t-1}, s_{t-1}, a_{t-1})$ 。该定义包括 $\Delta_t \sim P(\cdot | s_{t-1})$ 时的状态相关延迟、 $\Delta_t \sim P(\cdot | \Delta_{t-1})$ 时的马尔可夫链延迟以及 $(\Delta_t)_{t \in \mathbb{N}}$ 为独立同分布时的随机延迟。

3.3 延迟的性质

从 Δ MDP的通用定义出发，可以研究许多子情形。本节旨在给出文献或实际RL应用中遇到的延迟类型概览。首先介绍定义延迟的不同属性。最后给出本论文关于延迟的假设。

3.3.1 常值延迟与随机延迟

如前所述，延迟是随机变量，但文献中通常假设常值延迟（constant delay）。这一简化模型对许多应用而言已足够现实，尤其是当延迟的潜在随机性相对于过程步长可忽略不计。例如，[?] 在自动驾驶仿真和连续机器人运动控制中考虑 1 步常值延迟；[?] 在自动驾驶中考虑 2 步延迟；[?] 在简单仿真任务（包括网格世界）中考虑 1 到 20 之间的各种延迟。在主动流动控制中，延迟甚至可达 63 步 [?]。然而，对于某些应用，必须对延迟的随机性进行建模。在 [?] 中，随机延迟（stochastic delay）由策略通过 WiFi 传输至飞行机器人以及观测数据回传所引起。[?] 研究了泊松分布延迟对 Q 学习的影响。总的来说，即使实际延迟通常非常值，假设常值延迟是为了简化问题，前提是延迟的变化对模型性能不关键。

3.3.2 状态观测延迟与动作执行延迟

当智能体无法获知当前状态但能访问MDP的历史状态时，即出现状态观测延迟（state observation delay）。这与POMDP形成对比：在POMDP中，历史状态通常不向智能体公开，而是揭示关于当前状态的某些部分信息。??展示了状态观测延迟的示例，与之对比的是??中的无延迟MDP。在图示中，读者可能注意到增广状态（augmented state）这一概念，即最后观测到的状态 $s_{t-\Delta}$ 与智能体在过去已选择但尚未观测到结果的所有动作 $a_{t-\Delta}, \dots, a_{t-1}$ 的拼接。这一概念是延迟

²记号 DMDP 可能更直观，但该缩写已在文献中广泛用于指代确定性MDPs或折扣MDPs。该缩写也由本文所用的延迟记号所佐证。




Figure 3.2: 具有状态观测延迟的 Δ MDP的表示。




Figure 3.3: 具有动作执行延迟的 Δ MDP的表示。

强化学习的核心。实际上，通过考虑增广状态，智能体汇集了关于延迟过程的所有可能信息。在马尔可夫性质下，考虑比 $s_{t-\Delta}$ 和 $a_{t-\Delta}$ 更早的状态或动作将是冗余的。

动作执行延迟（action execution delay）发生在智能体虽然观测到当前状态，但选择的动作将在未来若干步之后才执行的情况。??展示了动作执行延迟的示例。注意此情形下增广状态的定义。与状态观测延迟类似，增广状态穷尽描述了延迟环境。另一个有趣之处在于时间索引。对于动作执行延迟，智能体在时间 t 选择的动作记为 a_t 。由于延迟，该动作将在时间 $t + \Delta$ 施加于状态 $s_{t+\Delta}$ 。这与状态观测延迟形成对比：在状态观测延迟中，智能体在时间 t 选择的动作 a_t 将施加于当前未观测的状态 s_t 。对于常值延迟，可以将动作索引偏移 Δ ，使得动作 a_t 如无延迟MDP那样施加于 s_t 。但这仅对常值延迟MDP可行。若延迟为随机，则智能体在时间 t 选择的动作标签将是随机的。此外，若两个动作因随机延迟同时施加，它们将被赋予相同索引。这似乎不是良好的命名方式。因此，无论在何种情形下，本文使用智能体选择动作的时间作为该动作的索引。该记号的另一优势在于，如??和??所示，状态观测延迟和动作执行延迟的增广状态相同。

后文将看到，动作执行延迟和状态观测延迟是等价的，其效应可叠加 (??)。因此，在上图中刻意以类似方式表示这两类延迟。其增广状态遵循相似构造，且对于相同延迟量包含相同数量的项。然而，如下文所述，存在一些微小差异，但只要避免混淆就不影响理论分析。正如 [?] 所指出的，动作执行延迟可能引起一个小问题：延迟可分为两部分——动作选择和动作执行。前者是智能体在观测到最新状态后计算动作所需的时间。后者是智能体在环境中实际执行该动作所需的时间。后者来源是传统意义上的动作执行延迟，而前者来源在实践中可能造成问题。实际上，若环境在智能体仍在计算前一个动作时提供了新状态（即动作选择延迟长于环境步长），则智能体尚不知晓其前一个动作。这对之前介绍的增广方法构成问题，我们将在??中详细讨论。这些方法基于先前动作选择当前动作。因此，此处先前动作集合中缺失了一个动作。智能体可等待后再计算下一个动作，但延迟将累积，缺失动作的数量会增加。为避免此类情况，如 [?] 所述，

本文假设动作选择延迟小于MDP步长³。状态延迟与动作延迟的另一个区别在于奖励收集延迟对二者的影响。如 [?] 所述，在状态观测延迟情形下，若无奖励延迟，智能体观测到与当前未观测状态相关的随机变量的结果。事实上，当前奖励是当前未观测状态的函数。换言之，该设置提供了关于当前未观测状态的部分信息。相反，在动作执行延迟情形下，无奖励延迟不会向智能体提供额外信息，因为最新信息（当前状态）已经是已知的。

3.3.3 奖励收集延迟

此处可能需要澄清。在RL文献中，两类不同但相关的问题都可能被称为延迟奖励（delayed reward）。在许多实际问题中，定义每步奖励可能很困难，而将全部奖励集中到单个步骤中则更容易 [?]。例如，在棋类比赛中为每一步设计奖励很困难，而根据比赛结果给予 0 或 1 的奖励则简单得多。这是第一类延迟奖励，也称为稀疏奖励（sparse reward）。它通常涉及MDP的探索问题。相反，第二类奖励延迟——奖励收集延迟（reward collection delay）——出现在与转换相关联的奖励（此处定义每步奖励没有问题）在若干步之后才被收集的情况。后文将看到，这类延迟通常不影响RL算法的最终性能，而是影响学习速度。因此，这两种设定之间的主要区别在于初始奖励的设计方式。然而，第一种设定可视为第二种设定的特例，即所有奖励均被延迟并在最后一步同时收集。

3.3.4 匿名延迟与非匿名延迟

可区分匿名延迟（anonymous delay）和非匿名延迟（non-anonymous delay）。当延迟匿名时，智能体无法获知延迟量；观测状态的时戳可能未向智能体公开。因此，智能体不再知晓其观测到的所有状态中哪个最新；当前时刻实际执行的动作不明；所收集奖励对应的转换不可知。因此，匿名性引发信用分配问题。后文（见??）将看到，据我们所知，文献中尚无在RL中考虑状态观测或动作执行延迟匿名性的工作。然而，奖励收集延迟情形下确实考虑了匿名延迟。

3.3.5 非整数延迟

本小节描述延迟如何等于环境步长的非整数倍。为简化，假设常值延迟。为清晰起见，假设 $\Delta \in (0, 1)$ ，但 $\Delta \in \mathbb{R}_{\geq 0}$ 的一般情形可以类似扩展。考虑动作执行延迟，但后文将看到状态观测延迟与之等价，可类似定义。

为构建具有非整数延迟（non-integer delay）的过程，可以从连续时间平稳MDP出发。如 [?] 所述，若智能体仅能每隔一个单位时间观测环境，即在时刻 $0, 1, \dots, t, t+1, \dots$ 观测，则产生的离散过程是离散时间MDP。记为 $\mathcal{M}$ 。若智能体以相同频率但存在 Δ 的相位偏移进行观测，则时间索引变为 $\Delta, 1+\Delta, \dots, t+\Delta, t+1+\Delta, \dots$ 。类似地，这定义了一个离散时间MDP，记为 $\mathcal{M}_\Delta$ 。由于底层连续时间MDP的平稳性， $\mathcal{M}$ 和 $\mathcal{M}_\Delta$ 具有相同的转移和奖励分布。下面展示如何利用这两个交错的MDP构建 Δ 延迟过程。

由于动作执行延迟，智能体观测到来自 $\mathcal{M}$ 的状态 s_t ，但其动作 a_t 将施加于 $\mathcal{M}_\Delta$ 的状态 $s_{t+\Delta}$ ，产生奖励 $r(s_{t+\Delta}, a_t)$ 。转移概率当然也受影响。预见到??的记号，定义 $b_\Delta(s_{t+\Delta}|s_t, a)$ 为在连续时间MDP中从 s_t 施加动作 a 经过 Δ 时间单位转移到 $s_{t+\Delta}$ 的概率。

³若实践中不满足此条件，可将动作持续多个步长，以人工创建步长更长的MDP，如 [?] 中所述。




Figure 3.4: 具有非整数动作执行延迟的 Δ MDP的表示。

由于底层连续时间MDP平稳，有 $\forall (s, a, s') \in \mathcal{S} \times \mathcal{A} \times \mathcal{S}$,

$$p(s'|s, a) = \int_{\mathcal{S}} b_{1-\Delta}(s'|z, a) b_{\Delta}(z|s, a) dz. \quad (3.1)$$

非整数延迟的可视化表示见??。

3.3.6 状态相关延迟与动作相关延迟

在此设定中，延迟不再独立于智能体的行为。无论是直接通过动作还是间接通过状态，智能体都可能改变延迟值。据我们所知，RL文献中尚无处理状态相关或动作相关延迟的工作，但实际应用启发这一问题。例如，使用更复杂的策略选择动作可能获得更优回报，前提是该策略的计算时间合理；当计算时间过大时，使用轻量级策略选择动作则更为合理。再如，考虑 [?] 中 WiFi 传输至飞行机器人的设定，延迟很可能取决于机器人与策略计算机之间的距离。

3.3.7 关于延迟过程的初始化

读者可能会问延迟过程如何初始化。例如，在状态观测延迟中，如何定义初始状态集合，使得智能体从一开始就有效观测到延迟状态？

这一问题看似浅显，但后文将看到，它可能产生重要的实际影响。如果仅奖励收集存在延迟，则保持底层MDP的初始化方式不会造成问题。相反，对于动作执行延迟和状态观测延迟，初始化意味着在允许智能体选择任何动作之前，必须以某种方式采样初始的 Δ 个动作。对于离散或有界动作集，一种任意但合理的采样方案是均匀采样。这是本文所有实验采用的方法。

注意，取决于初始动作的采样方式以及初始阶段收集的奖励是否计入，智能体的最终回报可能发生显著变化。举例说明，考虑如下简单MDP：奖励等于智能体的速度，且只有一个动作——以固定量“加速”。在 Δ MDP中，初始化意味着“加速”动作在控制权交给智能体之前已经执行了若干次。这意味着，与初始化速度为 0 的无延迟智能体相比，延迟智能体在其当前未观测状态中已经累积了速度。即使初始化阶段的奖励不计入，延迟智能体也以更高的速度起步，从而比无延迟智能体获得更高奖励。此外，若初始化阶段的奖励计入，则延迟智能体累积更多奖励。因此，奖励的计入方式可能显著改变延迟智能体相对于无延迟智能体的回报。我们将这一效应称为延迟初始化偏移（delay initialisation shift）。

3.4 相关工作

以下相关工作在各种类型延迟存在时为折扣回报情形提供了理论和实践解决方案，奖励收集延迟除外（??主要关注平均奖励）。首先描述文献中解决常值状态观测或动作执行延迟的三种主要方法。分别是增广状态方法（??）、无记忆方法（??）和基于模型方法（??）。然后，将综述范围扩展至更广泛的延迟（仍涉及动作执行和状态观测）；??介绍随机延迟研究，??介绍非整数延迟研究。最后，在??中讨论奖励收集延迟。

3.4.1 常值延迟的增广状态方法

增广状态的定义

本节引入了常值状态观测和动作执行延迟的重要概念。[?] 和 [?] 分别指出，在动作执行延迟和状态观测延迟情形下，可以通过如下方式增广状态空间将 Δ MDP简化为MDP。考虑动作执行或状态观测延迟 Δ ；令 $(a_1, \dots, a_\Delta)$ 为智能体已选择但由于延迟尚未观测到结果的最近 Δ 个动作；令 s 为智能体最近观测到的状态。则增广状态（augmented state） $x = (s, a_1, \dots, a_\Delta)$ 包含该时刻智能体可能收集到的全部信息。在底层MDP的马尔可夫性质下，任何进一步的信息都是冗余的。[?, ?] 证明，通过增广状态得到的新过程确实是一个MDP。其新状态空间为 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^\Delta$ 。注意对延迟的指数依赖。记 $\tilde{\Pi}$ 为依赖于增广状态或增广状态历史的策略集合。换言之， $\tilde{\Pi}$ 包含 Π 中任何不依赖比增广状态所含信息更新信息的策略。增广状态及策略基于增广状态的方式如图??和??所示。下面刻画这一过程。对于增广状态 $x, x' \in \mathcal{X}$ ，满足 $x = (s, a_1, \dots, a_\Delta)$ 和 $x' = (s', a'_1, \dots, a'_\Delta)$ ，对于动作 $a \in \mathcal{A}$ ，新的转移函数为⁴

$$\tilde{p}(x'|x, a) = p(s'|s, a_1) \delta_a(a'_\Delta) \prod_{i=1}^{\Delta-1} \delta_{a_{i+1}}(a'_i),$$

其中 Dirac 函数的乘积确保动作序列正确地从上一个增广状态传递到下一个。奖励函数为

$$\tilde{r}(x, a) = r(s, a_1). \quad (3.2)$$

如 [?, Lemma 1] 所示，等价形式为

$$\tilde{r}(x, a) = \mathbb{E}_{z \sim b_\Delta(\cdot|x)} [r(z, a)], \quad (3.3)$$

其中 b_Δ 为已知增广状态 x 时当前未知状态 z 的概率。将此概率称为信念 (belief)，因其与POMDP文献中的信念概念相似。直观上，由于给定动作序列和最近观测状态就能完全确定当前未观测状态的分布，第一个过程在延迟 Δ 步后最终将与第二个过程在期望意义下收集相同奖励。因此，两个过程中的最优策略对应。但注意，由于??讨论的延迟初始化偏移，两个过程可能具有不同的回报。

为完整起见，给出已知增广状态 $x = (s_1, a_1, \dots, a_\Delta)$ 时未观测当前状态 $s_{\Delta+1}$ 的信念表达式，

$$b_\Delta(s_{\Delta+1}|x) = \int_{\mathcal{S}^{\Delta-1}} p(s_{\Delta+1}|s_\Delta, a_\Delta) \prod_{i=2}^{\Delta} p(s_i|s_{i-1}, a_{i-1}) ds_{2:\Delta}. \quad (3.4)$$

⁴记号“ $\sim$ ”将用于指代延迟量。

动作执行延迟与状态观测延迟的等价性

常值动作执行延迟和状态观测延迟的另一个重要结果归功于 [?]. 该结果指出这两类延迟是同一枚硬币的两面。

Proposition 3.4.1 (状态观测延迟与动作执行延迟的等价性, [?] 的结论 1). 具有常值动作执行延迟 Δ^a 和常值状态观测延迟 Δ^s 的 Δ MDP 可以通过用最近 $\Delta^s + \Delta^a$ 个动作增广状态简化为 MDP。

实际应用

一条相对直接的研究路线是将 RL 算法直接应用于增广状态 MDP。该方法可追溯至 [?]. 理论也支持该方法将问题还原为无延迟 MDP, 智能体可在原始 Δ MDP 中获得最优回报。但存在一个障碍: 增广状态空间随延迟呈指数增长, 因为 $|\mathcal{X}| = |\mathcal{S}||\mathcal{A}|^\Delta$ [?]. 这可能会显著影响学习速度。然而, 较新的工作提出重新审视该方法以加速学习。例如, 可以修改增广状态中动作缓冲区的动作, 模拟应用不同策略的效果, 而无需在环境中额外采样。这一巧妙技术由 [?] 提出, 提供了更好的样本效率。其算法 Delay-Correcting Actor-Critic (DCAC) 在 SAC [?] 的基础上增加了上述思想。实验结果清晰地展示了该方法的效率。SAC 算法似乎特别适合延迟问题, 其核心概念也被纳入其他方法, 如 RTAC [?], 一种使用增广状态作为输入的 actor-critic 算法。

增广状态方法也用于实时强化学习 (real-time RL)。在 [?] 中, 作者推导了考虑动作选择所需时间的连续时间 RL 的理论结果。在此设定中, 增广状态同样恢复了连续时间无延迟 MDPs 的性质。有趣的是, 实证研究表明, 增广状态中不需要 (因而理论上也不必要) 的额外信息反而提供了更高的回报。换言之, 额外信息虽然在理论上冗余, 但可能从学习角度使问题更简单。

3.4.2 常值延迟的无记忆方法

受 POMDP 文献启发, 第二条研究路线关注将 RL 算法应用于无记忆 (memoryless) 过程。该方法仅考虑最近观测到的状态, 丢弃增广状态中动作序列可能包含的信息。但注意, 该方法仍能以某种方式考虑延迟, 如 dSARSA 算法 [?]. 有趣的是, 作者受 SARSA 算法在 POMDPs 问题上取得良好结果的启发 [?], 将该 SARSA 变体 [?] 应用于无记忆状态。dSARSA 算法在 TD 更新中考虑延迟。令 t 为当前时间。传统 SARSA 将时间 t 收集的奖励分配给最近选择的动作 a_t 和最近观测的状态 $s_{t-\Delta}$, 而 dSARSA 则将同一奖励分配给同一最近观测状态, 但与增广状态中最旧的动作 $s_{t-\Delta}$ 相关联。实际上, 这才是施加于 $s_{t-\Delta}$ 的动作。这一修改恢复了??中奖励的定义。[?] 提供的实验表明, dSARSA 在实践中表现良好。

在实时 RL 文献中, [?] 考虑使用蒙特卡洛树搜索 (Monte Carlo Tree Search) 根据最近观测状态进行轨迹规划。注意, 该算法通过将动作选择与模型学习阶段分离, 专门设计用于减少动作选择中的延迟。实际上, 实时 RL 文献与延迟 RL 的一个重要区别在于, 修改用于学习策略的在线算法可以减少由策略计算导致的延迟 [?, ?, ?]. 而在本文中, 认为延迟是环境的固有特征, 智能体无法对其施加影响。

3.4.3 常值延迟的基于模型方法

文献中最后一种方法称为基于模型 (model-based) 方法。其思路是解决状态空间对延迟 Δ 的指数依赖所引入的计算成本。为降低这一成本, 这些方法从增广

状态计算当前未观测状态的某种替代量，并用作策略的输入。这种预测未来（或者说未观测的现在）的方式相对自然。如 [?] 引用实验心理学结果所指出的，大脑通过外推运动物体的未来位置来考虑观测与执行之间的潜在延迟 [?]。前述状态替代量的维度通常远小于增广状态。它可以是当前状态的任意统计量，例如期望值或众数。基于模型这一名称源于这些方法学习环境动态模型，以递归模拟缓冲区中动作的效果并获取对当前状态的预测。

相关工作评估了学习最可能当前状态 [?] 作为策略输入的方法。在确定性MDP情形下，假设模型完美，智能体可以计算精确的当前状态并应用最优无延迟策略。因此，所得延迟策略将与无延迟策略性能匹配。在延迟文献中，众所周知的事实是：确定性MDPs诱导的 Δ MDPs具有相同的最优回报。底层MDP的随机性导致延迟情况下最优性能较弱。随机性与延迟的联合效应在 [?, Remark 3.1] 中有很好的阐述。在 [?] 中，作者将算法扩展到轻度随机MDPs (mildly stochastic MDPs)，即存在 $0 \leq \epsilon < 1$ 使得 $\forall (s, a) \in \mathcal{S} \times \mathcal{A}, \exists s', p(s'|s, a) \geq 1 - \epsilon$ 。在此假设下，延迟策略的期望折扣价值函数 $\tilde{V}^\pi$ 与其所基于的无延迟策略 V^π 之间满足如下保证：

$$\|\tilde{V}^\pi - V^\pi\|_\infty \leq \frac{\gamma \epsilon R_{\max}}{(1 - \gamma)^2},$$

其中 $R_{\max}$ 为最大绝对奖励。注意到轻度随机MDP的假设相当强，且边界随有效视界 $\frac{1}{1-\gamma}$ 二次增长。

较新的方法尝试使用NN学习当前状态，包括线性层 [?] 或循环层 [?]。后者的工作训练环境模型逐分量预测当前状态，对连续元素使用 $L2$ 损失，对离散元素使用交叉熵。因此，模型学习预测连续元素的期望值。预测结果随后输入无延迟RL算法 IMPALA [?]。在 [?] 中，预测状态用作 Q 学习 [?] 的输入。

同样使用 Q 函数的 [?] 方法以有趣的方式区别于前述方法。作者提出选择在未观测当前状态的分布上最大化某个无延迟 Q 函数期望值的动作。该分布由信念给出，信念从增广状态获得（如??所示）。该算法称为期望最大化 Q 学习 (Expectation Maximization Q-Learning, EMQL)，显然受限于 Q 函数是针对无延迟策略计算的，且所得延迟策略能否收集相同奖励尚未可知。然而，作者提供了理论结果，表明在增广状态 $x \in \mathcal{X}$ 下，延迟策略 $\tilde{\pi}$ 的价值函数 $\tilde{V}$ 满足以下下界保证：

$$\tilde{V}^{\tilde{\pi}}(x) \geq \mathbb{E}_{s \sim b_\Delta(\cdot|x)} [V^*(s)] - \frac{R_{\max}}{(1 - \gamma)^2} \left(1 - \frac{1}{|\mathcal{A}|}\right),$$

其中 V^* 为最优无延迟策略的价值函数。

进一步，[?] 指出，学习模型可以更好地利用，例如，在未观测当前状态之外进行规划。这正是 [?] 所实现的内容。在其方法 DATS (Delay-Aware Trajectory Sampling) 中，MDP模型被学习为由概率神经网络表示的高斯分布集成。然后查询模型以采样未观测的当前状态，并进一步采样当前状态之后的若干步，以规划动作序列。该方法基于 PETS (probabilistic ensemble with trajectory sampling) [?], 这是一种基于模型的方法，其性能优于PPO等无模型方法。PETS 在延迟场景中的优势更为明显。

3.4.4 随机延迟

虽然上述大多数工作假设常值延迟，但也有些工作处理随机延迟。[?] 考虑服从几何分布的延迟。这意味着较新的观测可能先于较旧的观测到达。因此，当已有

更新的信息时，较旧的观测可能被收集。这可能带来问题，因为智能体会丢失最新观测的计数而使用较旧的信息。这一现象将导致匿名延迟问题。为避免此问题，[?] 为智能体提供观测的时间戳以恢复非匿名性。随机延迟也在 [?] 中研究，其中状态和动作延迟服从有界离散分布。作为解决方案，作者提出增广状态以将问题还原为MDP，类似于常值延迟情形。但不仅需要用最近 $\Delta^a + \Delta^s$ 个动作增广状态（以考虑总等效延迟），还需要用状态延迟和动作延迟的当前值进行增广。虽然该信息在常值延迟情形下无用，但在这里智能体可以用它来学习延迟过程。其 DCAC 算法在 WiFi 通信导致的逼真随机延迟测试中取得了优异的实证结果。

3.4.5 非整数延迟

据我们所知，RL文献中只有一项工作考虑了非整数延迟问题。在 [?]（前文已在无记忆方法中讨论过）中，作者展示了如何调整其算法以适应此问题。作者结果的一个重要假设是，连续时间过程的转移可以在任何状态 s 和任何动作 a 处线性化，即存在矩阵 B 和 C 使得

$$\dot{s}(t) = Bs(t) + Ca(t).$$

对于延迟 $\Delta \in (0, 1)$ ，在时间 t ，动作 a_{t-1} 仍在执行，而智能体在 t 选择的动作将在 $t + \Delta$ 时开始执行。那么，在线性化假设下，时间 t 到 $t + 1$ 之间的有效动作作为 $\hat{a}_t = \Delta a_t + (1 - \Delta)a_{t+1}$ 。因此，[?] 提出在此情形下更新状态-动作对 $(s_t, \hat{a}_t)$ 的 Q 函数。实验结果表明，该修改帮助 dSARSA 比 SARSA（即使 SARSA 使用增广状态）更快地学习到达目标状态。

3.4.6 奖励收集延迟

如??所述，延迟奖励收集问题不在本文讨论范围之内，但为感兴趣的读者提供一些参考文献。延迟奖励主要在学习阶段的性能方面产生影响。相反，若只关心智能体的最终性能，只要延迟非匿名，延迟奖励并不十分重要。奖励最终会被归因到正确的转换。所有实用的离线RL算法都不会受此问题影响。

因此，奖励收集延迟主要在在线学习（online learning）文献中讨论也是自然的。该领域考虑一个必须在 K 个臂之间反复选择的智能体。每个臂为智能体提供奖励，奖励可以是随机生成或对抗性生成。环境无状态，智能体可随时从 K 个臂中选择。该框架可表示为单状态的MDP，即 $|\mathcal{S}| = 1$ 。当智能体只能观测其所选臂的奖励而无法观测其他 $K - 1$ 个臂的奖励时，该设定称为多臂赌博机（multi-armed bandit）[?]。当奖励随机时，称为随机赌博机（stochastic bandit）；奖励对抗性时，称为对抗性赌博机（adversarial bandit）。在该领域，一个重要概念是遗憾（regret），即学习智能体收集的奖励与事后最优策略之间的期望差异。

在赌博机文献中，[?] 指出，在其期望值有限的条件下，延迟在随机赌博机设定中对遗憾产生加性效应，在对抗性赌博机设定中产生乘性效应。他们的解决方案基于著名的上置信界（Upper Confidence Bounds, UCB）[?]，简单地忽略尚未收集的奖励即可扩展该方法。此后衍生出许多有趣的方向。例如，[?] 研究随机赌博机中延迟依赖于当前奖励的效应。作者考虑了可能无界支撑集和期望分布的情形，推导了一种算法，其遗憾中有一个依赖于延迟分位数的加性惩罚项。该界也接近作者证明的下界。在其解决方案中，[?] 使用连续消除（successive elimination）算法，一旦确信某臂是次优的，就将其消除。有趣的是，他们证明该算法在应用于延迟时比 UCB 类算法具有更强的保证。在 [?] 中，提出了一种新的延迟设定。拉臂获得的奖励可以分散（即延迟）到未来多个步骤。作者将这

一性质称为时间分区奖励 (temporally-partitioned rewards)。因此, 智能体在每一步观测到来自多个历史拉臂的分批奖励 (或称轮次奖励)。注意, [?] 考虑的是智能体知道每个分批奖励来自哪个臂的情形。换言之, 该设定为无匿名延迟。为处理时间分区奖励, 作者假设存在最大延迟, 并认为奖励在最大延迟之前各步中平滑分布。他们提出的方案构建了臂期望奖励估计的上置信界, 其中估计器对未观测结果假设零轮次奖励。

关注学习阶段算法遗憾的RL分支——理论RL——更近期才关注延迟奖励收集问题。[?] 展示了 UCRL [?] 等经典算法在随机MDPs中的结果。有趣的是, 与 [?] 类似, 他们证明在大多数情况下遗憾具有与延迟成比例的加性项。在 [?] 中, 作者使用 Q 学习处理泊松分布奖励的问题。其思路是学习多个 Q 函数, 每个对应延迟分布均值 λ 的一个可能取值。这样, 每次收集到新奖励时, 所有 Q 值都可以按照奖励来自对应均值分布的方式更新。这些 Q 函数可视为将输入增广了 λ 值的单个 Q 函数。通过这种方式, 智能体在选择最大化该特定 Q 值的动作之前, 先对所有 λ 取最大值来选择下一步动作。作者证明了该算法的收敛性。

3.4.7 匿名延迟

首先讨论匿名奖励收集延迟。在赌博机文献中, [?] 研究了随机赌博机设定中具有挑战性的匿名延迟问题。若延迟期望已知, 作者提出了一种算法, 其延迟加性项还依赖于视界 H 的对数。有趣的是, 若延迟有界, [?] 证明了与 [?] 匹配的界。他们的解决方案在时间段内重复选择同一臂, 从而增加新奖励来自该臂的概率。通过精心选择时间段长度, [?] 能够推导臂期望奖励的置信区间。这使次优臂的消除成为可能。

如??所述, 文献中的延迟奖励可能指信用分配问题, 即将所有奖励分配给单个转换以简化环境设计。作为示例, 引用 [?] 中交通拥堵缓解问题。在该问题中, 为单个交通灯对交通拥堵的影响定义每步奖励是复杂的。然而, 使用平均行驶时间作为奖励更容易, 但该奖励只能在最后一步获得。这些信用分配问题可视为匿名延迟的实例, 因为单步奖励不明确, 最终只提供一个聚合奖励。文献中有许多工作处理此问题, 例如 [?] 或 [?]。但据我们所知, RL文献中尚无工作考虑具有良好定义的单步奖励但存在匿名延迟的问题。


最后, 关于RL中的状态观测或动作执行延迟, 据我们所知尚无相关工作。这确实可以构成一个有趣的研究方向。

3.4.8 强化学习中延迟的综述

在??中给出状态观测和动作执行延迟文献的综述。在??中提供类似表格, 但聚焦于已考虑的方法及其应用的延迟类型。这有助于发现缺失的研究结果。

3.4.9 控制理论中的延迟

以我们认为重要的文献综述扩展结束本节。控制理论与RL有许多共同之处, 两者都考虑决策过程, 控制理论也如??所述考虑延迟问题。因此, 利用该框架的结果和思路以应用于RL可能是有益的。尤其因为控制理论历史悠久, 其所考虑的延迟类型通常更为多样。例如, 延迟虽然常值, 但环境状态的每个维度都不同 [?, ?]。有趣的是, 在此情形下, 如同在RL中一样, 状态观测延迟和动作执行延迟已被证明是等价的。另一种延迟类型是分布延迟 (distributed delay), 当系统依赖于连续区间上的历史状态时出现 [?]。在控制理论中, 使用连续时间系统比在RL中更为常见。对于经典常值延迟, 如同在RL中一样, 可以增广状态以将



[?]	✓	-	✓	-	1	✓	-	-	✓	A
[?]	✓	-	✓	-	1 – 20	✓	-	-	✓	Mo
[?]	✓	-	✓	-	0 – 2	✓	✓	-	✓	Me
[?]	✓	-	✓	-	2	✓	-	-	✓	Me
[?]	✓	-	✓	-	1 – 7	✓	-	-	✓	Mo
[?]	✓	-	✓	-	1	✓	-	-	✓	A
[?]	✓	-	✓	✓	1 – 5	✓	-	-	✓	A
[?]	✓	-	✓	✓	2 – 4	✓	-	-	✓	Mo
[?]	✓	-	✓	-	1 – 25	✓	-	-	✓	Mo
[?]	✓	-	✓	-	1 – 16	✓	-	-	✓	Mo

Table 3.1: 相关文献及其考虑的延迟类型。排序按发表时间。延迟量对应实验中考考虑的延迟范围。对于随机延迟，仅给出平均延迟，因为延迟可能无限。不同方法标注为：**A** 为增广方法，**Me** 为无记忆方法，**Mo** 为基于模型方法。

延迟类型			增广	无记忆	基于模型
常值	整数	非匿名	[?] [?] [?]	[?] [?]	[?] [?] [?] [?] [?]
随机	整数	非匿名	[?]		[?]
常值	非整数	非匿名		[?]	
常值	非整数	非匿名			

Table 3.2: 文献如何处理不同类型的状态观测和动作执行延迟概述。

延迟系统还原为无延迟系统 [?]。常值延迟的另一种方法是 Smith Predictor 模型 [?]。它提出学习无延迟过程的模型，并利用该模型将问题还原为无延迟问题。可以建立这种方法与前述RL中常值延迟的基于模型方法之间的联系。

通过考虑多智能体框架中的延迟，可以增加另一层复杂性，即多个智能体可以同时（或不同时）在环境中行动。问题于是变为分散式（decentralized），由于每个智能体可能独立，各自可能有不同的延迟。控制文献中此类系统的一个模型是延迟共享信息模式（delayed sharing information pattern）。如 [?] 所定义的，该问题考虑一组 K 个智能体，每个具有状态 s_t^k ，共同组成环境在时刻 t 的状态 s_t 。每个智能体选择动作 a_t^k ，组成施加于环境的全局动作 a_t 。如同在POMDP (??) 中，智能体不直接观测环境状态，仅观测其部分信息 $\mathbf{o}_t = (o_t^k)_{1 \leq k \leq K}$ 。每个智能体是 n 延迟的，即它接收其他智能体的信息有 n 步延迟，而对其自身状态的访问无延迟。因此，在时刻 t ，智能体 k 观测到 $h \leq t$ 时的 o_h^k ，但对于 $j \neq k$ ，仅观测到 $h \leq t - n$ 时的 o_h^j 。该框架的两个关键概念是：时刻 t 所有智能体共享

的信息

$$A_t = \{(\mathbf{o}_h, \mathbf{a}_h) | h \leq t - n\},$$

以及时刻 t 智能体 k 可用的额外信息

$$B_t^k = \{(o_h^k, a_h^k) | t - n < h \leq t - 1\} \cup \{o_t^k\}.$$

注意在时刻 t 智能体无法获取动作 a_t^k ，因此上式中最后一项为 o_t^k 。[?] 猜想，并非考虑所有基于 $(A_t, B_t^1, \dots, B_t^k)$ 信息的策略，而是存在一种最优策略，其中基于 A_t 对当前状态 $\mathbf{s}_t$ 的信念将替代之前信息结构中的 A_t 项。这与基于模型的延迟RL算法类似。在控制理论中，对于大于 1 的延迟，该猜想已被 [?] 证明不正确。在RL中，类似结果成立，如??所示。与延迟RL的另一个相似性如下。当 $n = 0$ （即状态本身可观测）时，问题可表述为MDP，并且如同增广状态方法，已证明 1 步延迟共享信息模式问题可以通过用延迟动作增广状态还原为MDP [?]。然而，与延迟RL相反，一些结果表明并非所有历史都是设计最优策略所必需的，可以使用仅由不随时间增长的统计量组成的简化信息结构 [?, ?]。

尽管控制理论与RL具有相似性，但控制理论文献中考虑的延迟问题通常更为复杂，因此从理论角度来看更为深入。而RL框架及其MDP过程提供了一个更简单的框架，可以更容易地推导结构性结果。

3.5 本文中的延迟

为总结本章，描述本文中将考虑的延迟类型。延迟出现在状态观测或动作执行中。选择不考虑奖励收集延迟，因为它主要引发信用分配问题，且已在赌博机文献中得到广泛处理。状态和动作延迟是RL特有的，因为它们直接影响转移动态。但注意，根据??的观察，在考虑状态观测延迟时，假设奖励收集延迟等于状态观测延迟，以避免从奖励中收集部分信息。因此，后文认为奖励是“无延迟”的，即奖励总是随其对应状态一起被观测。

主要考虑非匿名、常值和整数延迟，但也会反复将设定扩展到非整数、匿名和随机延迟。

结合??所述，认为澄清问题的信息结构很重要。在常值延迟 Δ 的状态观测或动作执行情形下，考虑在时刻 t ，智能体可以访问历史 $h_t = (h_t^s, h_t^r, h_t^a)$ ，其中 $h_t^s = (s_i)_{0 \leq i \leq t-\Delta}$ 为状态历史， $h_t^r = (r_i)_{0 \leq i \leq t-\Delta}$ 为奖励历史， $h_t^a = (a_i)_{0 \leq i \leq t}$ 为动作历史。根据智能体所采用的方法，可能仅使用历史的某个子集。例如，基于增广状态的智能体可以使用整个历史 h_t 作为输入，但存在一个最优增广状态策略仅使用增广状态 $x_t = (s_{t-\Delta}, a_{t-\Delta}, \dots, a_t)$ 本身。类似地，基于模型的策略通常从增广状态计算某个统计量 $f(x_t)$ 作为输入。最后，无记忆方法仅使用最近观测的状态 $s_{t-\Delta}$ 作为输入。除理论考虑外，为避免输入维度随时间增长，不会设计使用 h_t 作为输入的智能体。

基于信念的方法

4.1 引言

本章考虑常值状态观测延迟或动作执行延迟。在基于模型的方法框架下，本文提出计算当前状态信念 (belief) 的表征 (representation)，并将其作为策略的输入。先前的基于模型方法计算当前状态信念的不同统计量，例如其期望值 $[?, ?, ?]$ ，或通过从概率模型采样进行规划 $[?]$ 。相反，本文考虑学习一种完整编码分布的信念表征。显然，访问信念比仅访问其部分统计量为策略提供更丰富的信息，因为这些统计量可以从信念计算得出。若能高效地学习基于信念的最优策略，该方法有望获得更高回报。

为学习信念表征，本文设计一种NN，可训练将信念（可能为无限维）编码为可控有限维向量 (??)。该网络可作为任何RL算法的输入预处理模块。在实验中，本文将其接入TRPO $[?]$ 。由此得到 Delayed-TRPO (D-TRPO)。该方法在确定性和随机环境中均取得令人满意的结果 (??)。本文提出一个简单技巧，利用D-TRPO 在特定延迟下学习的策略，将其应用于更小延迟的任务 (??)。该技巧在多个环境中成功通过测试。除上述算法贡献外，本文还对设定进行理论分析，并探讨基于模型的方法如何与POMDP关联 (??)。不幸的是，本文证明在某些环境中基于模型的方法相对于最优延迟策略必然是次优的 (??)。最后，本文对文献中从未正式证明的一个简单事实给出形式化证明：延迟越大，最优策略的回报越低 (??)。

4.2 学习信念表征

本节介绍针对常值延迟学习信念表征的方法。学习完成后，该表征可作为状态的替代与任何RL算法配合使用。随后通过一个简单技巧将该方法扩展为同时学习多个延迟。

4.2.1 信念表征网络

为了对某个增广状态 $x = (s, a_1, \dots, a_\Delta) \in x$ 学习信念 $b_\Delta(\cdot|x)$ ，需要预测增广状态中包含的动作的影响。一种方法是用循环函数近似转移动力学。循环NN可作为近似器，但此类网络训练和评估速度较慢。本文改用参数为 ϕ 的NN f_ϕ 直接处理整个输入，要求网络一次性输出所有未观测状态的信念表征。该网络有多种方式处理增广状态。本文选择从增广状态构造序列 $(s, a_i)_{i \in [1, \Delta]}$ 。该序列随后输入因果 Transformer (causal Transformer) [?] 的编码器网络 (见 ??)，记为 f_ϕ 。选择因果 Transformer 主要基于三个原因：Transformer 在序列到序列任务中取得优异实证结果 [?]; 可使用掩码保持因果性，这对过去信念不依赖未来信念的特性很有用；Transformer 中的位置编码可添加动作在序列中位置的信息，因此同一动作在增广状态中不同位置可产生不同影响。

为训练 f_ϕ 有效编码信念，本文使用MAF [?] 网络 (见 ??)。选择基于其近似概率分布的能力。该网络记为 f_θ ，将 f_ϕ 的输出作为其概率的条件。然后，该网络接受训练，仅从 f_ϕ 给出的条件近似未观测状态的概率。通过这种方式，所有关于信念的信息都将编码于 f_ϕ 中。注意，MAF网络的损失梯度可通过其条件传播，因此可同时用于训练 f_ϕ 。

下面更精确地考察信念网络内部的工作机制。设 $x = (s, a_1, \dots, a_\Delta)$ 为当前增广状态。首先，Transformer 为 $(s, a_i)_{i \in [1, \Delta]}$ 中的每个元素 (s, a_i) 输出一个向量 $f_\phi(x)_i \in \mathbb{R}^{n_b}$ 。记 n_b 为信念表征的维度。设 $(s_1, \dots, s_\Delta)$ 为将要近似信念的 Δ 个未观测状态， $b_i(\cdot|x)$ 为 s_i 的信念。如 ?? 所述，MAF递归地将参数化函数应用于基础密度 p_u ，将其变换为密度 p_θ 。基础密度 p_u 采用正态分布。与传统设定的不同之处在于，此处相对于 ?? 增加了对 $f_\phi(x)_i$ 的条件化。

$$p_\theta(s_i|f_\phi(x)_i) = p_u(f_\theta^{-1}(s_i, f_\phi(x)_i)) \left| \det \left(\frac{\partial f_\theta^{-1}}{\partial s_i} \right) \right|.$$

注意，MAF 的构建模块 MADE 层 (见 ??) 只需一次前向传播即可计算密度，而采样则需要与输出维度相同次数的前向传播。这一点在此处不构成限制，因为本文不需要从信念中采样状态，只需学习其近似。

然后训练MAF最小化其密度与训练集密度之间的 Kullback-Leibler 散度。此处损失函数为

$$\min_{\theta, \phi} \sum_{i=1}^{\Delta} D_{\text{KL}}(b_i(s_i|x) \| p_\theta(s_i|f_\phi(x)_i)).$$

该量天然可微，可通过基于梯度的优化方法最小化。对于 N 个增广状态的样本 $(x^k)_{1 \leq k \leq N}$ ，其中 $x^k = (s^k, a_1^k, \dots, a_\Delta^k)$ ，损失函数可近似为

$$\mathcal{L}_p = \sum_{k=1}^N \sum_{i=1}^{\Delta} \log p_\theta(s_i^k | f_\phi(x^k)_i). \quad (4.1)$$

信念表征网络的图形表示见??，其训练过程见??。在RL中，通常使用回放缓冲区补偿因训练而随时间演化的采样策略。这也使框架更接近监督学习。本文采用相同思路，将增广状态保存在回放缓冲区中。

信念表征网络可作为状态的预处理与任何RL算法配合使用。在实验部分，本文将该网络接入TRPO [?]，并将该方法称为 Delayed-TRPO (D-TRPO)。




Figure 4.1: D-TRPO 网络。从下至上：增广状态被拆分为序列 $(s, a_i)_{i \in [1, \Delta]}$ ；序列经过一个 *Transformer* 编码器层，返回信念编码 $f_\phi(x)_i \in \mathbb{R}^{n_b}$ ；MAF 层以前一个编码向量为条件学习后续 Δ 个状态的信念。最后，最后一个信念编码 $f_\phi(x)_\Delta$ 用作策略的输入。

4.2.2 同时学习多个延迟

本文提出一个简单思路，利用 D-TRPO 在给定整数延迟 $\Delta > 0$ 下学习的策略。尽管思路简单，但先前文献未曾考虑过此想法。本文提出通过模拟 Δ 延迟，将 D-TRPO 应用于更小的整数延迟 $0 < \Delta' < \Delta$ 。具体而言，除了延迟 Δ' 对应的增广状态 $x_t = (s_{t-\Delta'}, a_{t-\Delta'}, \dots, a_{t-1})$ 外，还考虑一个缓冲区，

$$(s_{t-\Delta}, a_{t-\Delta}, \dots, s_{t-\Delta'-1}, a_{t-\Delta'-1}),$$

包含 $t - \Delta'$ 之前最后 $\Delta - \Delta'$ 个状态和动作的历史记录。通过这种方式，智能体可以构造一个合成增广状态 $x'_t = (s_{t-\Delta}, a_{t-\Delta}, \dots, a_{t-1})$ 。这足以应用 D-TRPO 在延迟 Δ 下学习的策略。显然，该算法具有与延迟 Δ 的 D-TRPO 相同的性能保证。在??中提供实验验证该思路的有效性。

对于文献中的某些方法，可以做得比上述简单思路更好。例如，与 [?] 类似，可以不学习信念表征，而是学习未来所有 Δ 个状态的期望状态。本文设计一种方法实现这一目标，使用与 D-TRPO 相同的网络结构，但移除 MAF 层。网络训练以最小化其输出 $(f_\phi(\mathbf{x})_i)_{i \in [1, \Delta]}$ 与真实状态 $(s_1, \dots, s_\Delta)$ 之间的 L2 损失。将其接入 TRPO 后，称该方法为 L2-TRPO。在这种情况下，可以用另一种方式同时学习多个延迟。事实上，因果 Transformer 网络的一个有趣特性是它可以被裁剪到所需长度，因此可以应用于更短延迟 $0 < \Delta' < \Delta$ 的增广状态。根据设计，L2-TRPO 也已学习未来 Δ' 步的期望状态。因此，裁剪后 Transformer 的输出可作为 TRPO 的输入。值得注意的是，D-TRPO 无法做到这一点。尽管它学习了未来每个 Δ 状态的信念表征，但各自的编码可能遵循不同规则。因此，TRPO 可能无法理解较早状态的编码。

Algorithm 1 信念表征网络训练

Inputs: belief representation network parameters ϕ and θ , number of epochs K , batch size N , number of samples M , empty replay buffer $\mathcal{D}$.

Outputs: Trained parameters ϕ and θ .

- 1: **for** $k = 1, \dots, K$ **do**
 - 2: Collect M samples under some policy π
 - 3: Add couples of augmented states $x = (s, a_1, \dots, a_\Delta)$ and corresponding sequence states to be predicted $(s_1, \dots, s_\Delta)$ to $\mathcal{D}$
 - 4: Sample N such couples from $\mathcal{D}$
 - 5: Update parameters ϕ and θ by descending the gradient $\nabla_{\phi, \theta} \mathcal{L}_p$ (See ??)
 - 6: **end for**
-

此处提出的简单思路与 [?] 的论点一致：基于模型的方法更适合延迟场景，因为其模型可以复用。

4.3 理论分析

本节提供若干理论结果，帮助理解常值延迟 Δ MDP 问题。首先，本文形式化证明一个文献中通常视为理所当然的事实：延迟越长，最优回报越小。第二部分研究常值延迟 Δ MDP 的复杂度。最后，通过一个示例证明基于模型的策略在某些问题中可能出现次优性能。

4.3.1 延迟对性能的影响

对于平均奖励或期望折扣回报，在其他条件相同的情况下， Δ MDP 的延迟越大，其最优策略的性能越低，这似乎是合理的。尽管直观自然，但该结果尚未得到证明。下面给出证明。该结果需要以下假设，确保两个具有不同延迟的过程以相同方式初始化。

Definition 4.3.1 (一致 Δ MDPs). 设 $\widetilde{\mathcal{M}}$ 和 $\widetilde{\mathcal{M}}'$ 为两个 Δ MDPs，其延迟分别为 Δ 和 Δ' ，初始增广状态分布分别为 d_0 和 d'_0 。若 $\Delta \leq \Delta'$ ，则称 $\widetilde{\mathcal{M}}$ 和 $\widetilde{\mathcal{M}}'$ 是一致的，当且仅当：

$$\mathbb{P}(S_0 = s_0; d_0) = \mathbb{P}(S_0 = s_0; d'_0),$$

且 $\forall t \leq \Delta$,

$$\mathbb{P}(A_t = a_t; d_0) = \mathbb{P}(A_t = a_t; d'_0).$$

Theorem 4.3.1. 设 $\widetilde{\mathcal{M}}_1$ 和 $\widetilde{\mathcal{M}}_2$ 为两个一致 Δ MDPs，其延迟分别为 Δ_1 和 Δ_2 。考虑 J_1^* 和 J_2^* ，分别为它们的最优期望折扣回报或平均奖励。若 $\Delta_1 < \Delta_2$ ，则有：

$$J_2^* \leq J_1^*.$$

Proof. 为证明该结果，首先证明 $\widetilde{\mathcal{M}}_1$ 中存在一个非平稳的基于历史的策略，其具有与 $\widetilde{\mathcal{M}}_2$ 中最优马尔可夫策略 π_2^* 相同的增广状态分布。为定义该策略，将轨迹分为两个时间段。在第一时间段，当 $t \geq \Delta_2$ 时，记 $(s_{t-\Delta_2}, a_{\Delta_2}, \dots, s_{t-1}, a_{t-1}, s_t)$ 为最近 Δ_2 步的历史。 $\widetilde{\mathcal{M}}_2$ 中的智能体观测到增广状态

$$x'_t = (s_{t-\Delta_2}, a_{t-\Delta_2}, \dots, a_{t-1}).$$

由于 $\Delta_1 < \Delta_2$, $\widetilde{\mathcal{M}}_1$ 中的智能体可以观测到以下量

$$\bar{x}_t = (s_{t-\Delta_2}, a_{t-\Delta_2}, \dots, s_{t-\Delta_1}, a_{t-\Delta_1}, \dots, a_{t-1}),$$

该量属于 $\mathcal{S}^{\Delta_1-\Delta_2} \times \mathcal{A}^{\Delta_2}$ 。注意, 该“状态”包含 $\Delta_1 - \Delta_2$ 个状态和动作的历史, 这些在 $\widetilde{\mathcal{M}}_1$ 的马尔可夫策略中不会被使用。将候选策略 $(\pi_t)_{t \geq 0}$ 对 $t \geq \Delta_2$ 定义如下

$$\pi_t(\cdot | \bar{x}_t) = \pi_2^*(\cdot | x'_t).$$

当 $\Delta_1 \leq t < \Delta_2$ 时, $\widetilde{\mathcal{M}}_1$ 中的智能体尚不能观测到 Δ_2 步前的状态。然而, 已知 $\widetilde{\mathcal{M}}_2$ 的初始状态分布 $d_{0,2}$, 可以将策略定义为

$$\pi_t(a_t) = \mathbb{P}(A_t = a_t; d_{0,2}).$$

本质上, π_t 忽略增广状态, 以与 $\widetilde{\mathcal{M}}_{\Delta_2}$ 中初始动作分布相同的概率选择动作。

下面证明该策略在 $\widetilde{\mathcal{M}}_2$ 中诱导出相同的状态分布。记 d_t^π 为 $(\pi_t)_{t \geq 0}$ 在时刻 t 的未折扣状态分布, $d_t^{\pi^*}$ 为 π_2^* 的状态分布。对 $t = \Delta_2$, 注意到

$$\begin{aligned} d_t^{\pi^*}(x'_t) &= d_{0,2}(s_{t-\Delta_2}, a_{t-\Delta_2}, \dots, a_{t-1}) \\ &= d_{0,1}(s_{t-\Delta_2}, a_{t-\Delta_2}, \dots, a_{t+\Delta_1-\Delta_2-1}) \prod_{i=1}^{\Delta_2-\Delta_1} \mathbb{P}(A_{t-i} = a_{t-i}; d_{0,2}) \end{aligned} \quad (4.2)$$

$$\begin{aligned} &= d_{0,1}(s_{t-\Delta_2}, a_{t-\Delta_1}, \dots, a_{t+\Delta_1-\Delta_2-1}) \prod_{i=1}^{\Delta_2-\Delta_1} \pi_{t-i}(a_{t-i}) \\ &:= d_t^\pi(x'_t), \end{aligned} \quad (4.3)$$

其中 ?? 由一致性假设成立, ?? 由 $(\pi_t)_{t \geq 0}$ 在前 Δ_2 步的定义成立。然后, 假设对某个 $t \geq \Delta_2$ 有 $d_t^{\pi^*} = d_t^\pi$, 证明对 $t+1$ 等式也成立。需要引入一些记号以简化表述。首先, 对于 $\bar{x}_t, \bar{x}_{t+1} \in \mathcal{S}^{\Delta_1-\Delta_2} \times \mathcal{A}^{\Delta_2}$ 和 $a_t \in \mathcal{A}$, 记 $\bar{p}(\bar{x}_{t+1} | \bar{x}_t, a_t) = \mathbb{P}(X_{t+1} = \bar{x}_{t+1} | X_t = \bar{x}_t, A_t = a_t)$ 为从 $(\bar{x}_t, a_t)$ 到 $\bar{x}_{t+1}$ 的转移概率。还定义以下测度, 对 $x'_t \in \mathcal{S} \times \mathcal{A}^{\Delta_2}$

$$\delta_{x'_t}(\bar{x}_t) = \delta_{s'_{t-\Delta_2}}(s_{t-\Delta_2}) \prod_{i=1}^{\Delta_2} \delta_{a'_{t-i}}(a_{t-i}),$$

这确保 x'_t 中的状态和动作包含在 $\bar{x}_t$ 中。使用此记号，有

$$\begin{aligned}
 d_t^\pi(x'_{t+1}) &= \int_{\mathcal{S}^{\Delta_1-\Delta_2} \times \mathcal{A}^{\Delta_2}} d_t^\pi(\bar{x}_t) \bar{p}(\bar{x}_{t+1} | \bar{x}_t, a_t) \delta_{x'_{t+1}}(\bar{x}_{t+1}) \pi_t(a_t | \bar{x}_t) d\bar{x}_t ds_{t-\Delta_1+1} \\
 &= \int_{\mathcal{S}^{\Delta_1-\Delta_2} \times \mathcal{A}^{\Delta_2}} d_t^\pi(\bar{x}_t) \bar{p}(\bar{x}_{t+1} | \bar{x}_t, a_t) \delta_{s'_{t-\Delta_2+1}}(s_{t-\Delta_2+1}) \pi_2^\star(a_t | x'_t) \\
 &\quad \prod_{i=0}^{\Delta_2-1} \delta_{a'_{t-i}}(a_{t-i}) d\bar{x}_t ds_{t-\Delta_1+1} \\
 &= \int_{\mathcal{S}^{\Delta_1-\Delta_2-1} \times \mathcal{A}^{\Delta_2+1}} d_t^\pi(\bar{x}_t) \delta_{s'_{t-\Delta_2+1}}(s_{t-\Delta_2+1}) \pi_2^\star(a_t | x'_t) \prod_{i=0}^{\Delta_2-1} \delta_{a'_{t-i}}(a_{t-i}) d\bar{x}_t \\
 &\quad (4.4)
 \end{aligned}$$

$$\begin{aligned}
 &= \int_{\mathcal{S} \times \mathcal{A}^{\Delta_2}} d_t^\pi(x'_t) p(s_{t-\Delta_2+1} | s_{t-\Delta_2}, a_{t-\Delta_2}) \delta_{s'_{t-\Delta_2+1}}(s_{t-\Delta_2+1}) \\
 &\quad \cdot \pi_2^\star(a_t | x'_t) \prod_{i=0}^{\Delta_2-1} \delta_{a'_{t-i}}(a_{t-i}) dx'_t \\
 &\quad (4.5)
 \end{aligned}$$

$$\begin{aligned}
 &= \int_{\mathcal{S} \times \mathcal{A}^{\Delta_2}} d_t^{\pi_2^\star}(x'_t) \tilde{p}(x'_{t+1} | x'_t, a_t) \pi_2^\star(a_t | x'_t) dx'_t \\
 &= d_t^{\pi_2^\star}(x'_{t+1}),
 \end{aligned}$$

其中 ?? 成立是因为 Dirac 测度 δ 涉及的所有项已由 $\bar{x}_t$ 和 x'_{t+1} 固定，?? 成立是因为除 $d_t^\pi(\bar{x}_t)$ 外没有项依赖于 $s_{t-\Delta_2+2}, \dots, s_{t-\Delta_1}$ ，因此可以对这些项进行积分。

综上所述，我们在 $\widetilde{\mathcal{M}}_1$ 中找到了一个非平稳的基于历史的策略，其在任意时刻具有与 $\widetilde{\mathcal{M}}_2$ 中最优策略相同的增广状态分布。根据设计，该策略在任何状态下选择与 $\pi_2^\star$ 相同的动作，因此在任何时刻获得相同的奖励。这表明 (π_t) 和 $\pi_2^\star$ 具有相同的折扣期望回报或平均奖励。由于 (π_t) 只是 $\widetilde{\mathcal{M}}_1$ 的一个特定策略， $\widetilde{\mathcal{M}}_1$ 中的最优策略可能产生更高的回报或平均奖励。证明完毕。□

Remark 4.3.1. 从 [?, Theorem 6.2.10 and Theorem 8.1.2] 我们甚至知道 $\widetilde{\mathcal{M}}_1$ 中存在一个最优马尔可夫策略（即仅使用增广状态而非更多历史），产生 $J_1^\star$ 。

通过一个推论扩展上述结果：尽管证明中设计的策略是基于历史的，但 $\widetilde{\mathcal{M}}_1$ 中存在一个马尔可夫策略（同样仅使用增广状态而非更多历史），其状态分布与 $\widetilde{\mathcal{M}}_1$ 中最优策略相同。

Proposition 4.3.1. 设 $\widetilde{\mathcal{M}}_1$ 和 $\widetilde{\mathcal{M}}_2$ 为两个一致 Δ MDPs，其延迟向量分别为 Δ_1 和 Δ_2 ，且 $\Delta_1 < \Delta_2$ 。考虑 $\widetilde{\mathcal{M}}_2$ 中的一个马尔可夫策略 $\tilde{\pi}_2$ （即相对于其增广状态 $\mathcal{X}_2 = \mathcal{S} \times \mathcal{A}^{\Delta_2}$ ），具有 σ -有限占据测度。则 $\widetilde{\mathcal{M}}_1$ 中存在一个马尔可夫策略（相对于其增广状态 $\mathcal{X}_1 = \mathcal{S} \times \mathcal{A}^{\Delta_1}$ ），其在 $\mathcal{X}_1$ 上诱导的状态-动作分布与最优策略 $\tilde{\pi}_2$ 相同。

Proof. 设 $\tilde{\pi}_2$ 为 $\widetilde{\mathcal{M}}_2$ 中具有 σ -有限占据测度的策略。根据 ?? 的证明，可以在 $\widetilde{\mathcal{M}}_1$ 中构建一个基于历史的策略 $\tilde{\pi}_1$ ，其在 $\mathcal{X}_2$ 上具有相同的状态-动作分布。然后，根据 [?, Theorem 3]， $\widetilde{\mathcal{M}}_1$ 中存在一个马尔可夫策略 $\tilde{\pi}$ ，其在 $\mathcal{X}_1$ 上的状态分布与该 $\tilde{\pi}_1$ 相同。证明完毕。□




Figure 4.2: 相对于智能体可用信息量的问题维度。这些量之间的权衡由黑色虚线表示。无延迟MDP (U) 具有完全信息和低维度，而增广状态方法 (A) 是MDP $[?, ?]$ ，具有更高维度。无记忆方法 (Me) 维度低，但如??所示属于POMDPs。基于模型的方法 (Mo) 同样产生POMDPs ??。后一种方法允许在维度和可观性之间进行权衡。

4.3.2 常值延迟的复杂度

以下命题直接源自 [?, ?]，该文献指出具有状态观测延迟和/或动作执行延迟的 Δ MDP可以通过增广状态转化为MDP。

Proposition 4.3.2. 基于模型和无记忆方法将状态观测延迟或动作执行延迟的问题从 Δ MDP转化为POMDP。特别地，使用信念表征作为策略输入的框架可以归约为 POMDP。

Proof. 从 [?, ?] 可知，通过使用增广状态， Δ MDP转化为MDP。由于基于模型方法仅使用从增广状态计算的当前状态的某些统计量，而无记忆方法仅使用后者的部分信息，智能体策略所使用的观测可视为对真实增广状态的部分观测。这正是POMDP的框架。 $\square$

这是一个负面结果，因为尽管 Δ MDP 可以通过状态增广转化为 MDP，但我们现在只处理其部分观测，而已知 POMDP 比 MDP 难解得多 [?, Theorem 6]。[?, Theorem 2] 证实了这一点，他们指出使用增广状态在 Δ MDP 中进行规划已经是 NP-Hard 问题。

4.3.3 基于模型方法的反例

尽管上一节揭示了负面结果，但人们可能期望 Δ MDP 的特殊结构允许基于模型的方法实现最优性能。遗憾的是，以下命题证明基于模型策略集合上的最优回报相对于最优基于增广状态策略可能是次优的。

Proposition 4.3.3. 设 J_b^* 为同一 Δ MDP 上基于信念的策略空间的最优回报， J_a^* 为基于增广状态的策略空间的最优回报。则存在 Δ MDPs 使得

$$J_b^* < J_a^*.$$

Proof. 通过给出这样一个 Δ MDP 的实例来证明。该实例在??中展示。在该实例中，延迟设为两步。智能体从最下方状态开始，为初始化过程，前两个动作均匀随机选择。在任何状态下，有两个可用动作 a 和 b 。注意，除最上方状态外，没有任何转移产生奖励。前者作为吸收态，提供节点上方标注的折扣回报或平均奖励。因此，智能体收集的奖励仅取决于其到达的最上方状态。除虚线标示的转移外，所有转移都是确定性的。在后一种情况下，沿任一路径前进的概率均为 $1/2$ 。该 MDP 的特殊之处如下。由于两步延迟，初始化后智能体要么处于状态 s ，要么处于状态 s' 。这意味着，给定 MDP 的结构，智能体对其当前状态的信




Figure 4.3: Δ MDP实例，其中对于两步延迟，基于信念的策略相对于最优基于增广状态的策略是次优的。在任何状态下，智能体可以选择两个动作 a 和 b 之一。除最上方转移外，没有任何转移提供奖励。对于后者，一个循环状态提供节点上方标注的折扣回报或平均奖励。除虚线所示转移外，所有转移都是确定性的，其中选择给定动作的智能体各有 $1/2$ 的概率沿任一边前进。智能体从最下方状态开始。底层MDP设计为具有两条路径，它们在状态 s 和 s' 上产生相同的信念。

念在 s 和 s' 上各为 $1/2$ 。值得注意的是，基于信念的策略无法区分智能体到达 s 或 s' 所经过的路径。第一条路径（红色）从初始状态确定性直接上移到下一个状态，然后转移到 s 或 s' 。第二条路径（蓝色）在第一步向左或向右，然后确定性转移到 s 或 s' 。蓝色路径的有趣特性在于，从第二步起，智能体将知道它会到达 s 还是 s' 。然而，在红色路径上，智能体需要多等待一步才能知道它实际处于 s 还是 s' 。基于信念的智能体无论沿哪条路径都看到相同的状态，而基于增广状态的智能体从增广状态中包含的第一个动作就能知道它将沿蓝色还是红色路径前进。因此，基于信念的智能体必须选择一条不考虑路径而优化回报的动作，而基于增广状态的策略可以利用这一额外信息更精细地选择动作。

智能体需要选择后续两个动作才能获得最终奖励。对于红色路径，智能体在选择两个动作时不知道它将沿左分支还是右分支前进。智能体在各动作组合下获得的奖励见??。相反，对于蓝色路径，智能体可以根据其所沿MDP分支调整第二个动作。类似地，??给出了给定第一个动作和观测状态的奖励。注意，给定该状态和动作，下一步的最优动作是确定的。

初始化设计使得智能体沿任一路径的概率相同。对于红色路径，智能体应先执行 b 再执行 a ，获得 12.5 的奖励。对于蓝色路径，则应先选择动作 a ，然后根据观测调整第二个动作，获得 15 的平均奖励，而若先执行 b 则仅获得 12.5 的平均奖励。

因此，基于增广状态的策略将遵循上述推理，平均获得 $J_a^* = 13.75$ 的奖励。基于信念的策略则被迫对两条路径首先选择相同的动作，因为它不知道将沿哪条路径前进。若先选择 a ，智能体在红色路径情况下获得 10，在蓝色路径情况下获得 15。若先选择 b ，则在红色路径情况下获得 6.25，在另一条路径上获得 12.5。这意味着，无论第一个动作如何选择，期望奖励总是更小。其最优回报通过先执行 a 获得，为 $J_b^* = 12.5$ 。证明完毕。□

	a	b
a	5	10
b	12.5	0

Table 4.1: 初始沿红色路径时，所有第一个（行）和第二个（列）动作组合的奖励。

	s	s'
a	$a \rightarrow 10$	$b \rightarrow 20$
b	$a \rightarrow 15$	$a \rightarrow 10$

Table 4.2: 初始沿蓝色路径时，所有第一个动作（行）与下一步观测状态（列）组合的奖励。第二个动作最优选择并在表中标出。

尽管这个反例令人沮丧，但本文在??中对一种特殊类型的基于信念的策略进行了分析，并证明在光滑性条件下，该策略的回报与最优延迟策略的回报相差不超过一个常数。

4.4 实验评估

本节评估信念表征网络在不同任务中的实证表现，包括确定性和随机环境。在??中描述每个任务、基线方法和 D-TRPO 的设置。在??中提供并讨论实验结果。

4.4.1 设定

注意，所有基线、本文方法和所有任务的结果均在 10 个随机种子下取平均。

任务

Pendulum. 在该任务中，智能体必须学习将钟摆向上旋转。该任务是延迟RL中的经典任务，因为传统RL算法的性能随延迟增大而迅速下降。部分原因在于上方位置的不稳定平衡点，在延迟情况下难以维持。在实现中，使用 gym 库 [?] 的版本。该环境是确定性的。鉴于在 Pendulum 上运行实验的计算成本相对较低，我们对集合 $\{3, 5, 10, 15, 20\}$ 中的常值延迟重复分析。对该任务，执行 500 轮 (epoch)，每轮 5,000 步，总计 250 万步。

随机 Pendulum. 该任务与前一个任务相同，但人为地向过程添加随机性。具体而言，向智能体选择的动作添加形式为 $\epsilon = \text{scale}(\eta + \text{shift})$ 的独立同分布噪声，其中 η 为某个概率分布。??给出了考虑的六种噪声。还考虑一种额外噪声：环境以 0.9 的概率遵循智能体指示的动作，否则均匀随机采样一个动作。将此过程称为均匀 (uniform) 噪声。对这些任务，仅考虑延迟为 5，执行 1,000 轮，每轮 5,000 步，总计 500 万步。

Mujoco. 这是一个连续机器人运动控制任务，使用 mujoco [?] 库提供的高级物理模拟器。这些任务的复杂性在于其复杂的动力学以及大状态和动作空间。从所有 Mujoco 环境中，考虑 Walker2d、HalfCheetah、Reacher 和 Swimmer，这些环境在早期测试后证明受延迟影响最大。与 Pendulum 类似，这可以用某些情况下存在不稳定平衡点来解释。这些环境是确定性的。对这些任务，仅考虑延迟为 5，执行 1,000 轮，每轮 5,000 步，总计 500 万步。

Noise	Distribution η	Shift	Scale	Group
<i>Beta (8,2)</i>	$\beta(8, 2)$	0.5	2	1
<i>Beta (2,2)</i>	$\beta(2, 2)$	0.5	2	1
<i>U-Shaped</i>	$\beta(0.5, 0.5)$	0.5	2	1
<i>Triangular</i>	Triangular($-2, 1, 2$)	0	1	2
<i>Lognormal (1)</i>	Lognormal(0, 1)	-1	1	3
<i>Lognormal (0.1)</i>	Lognormal(0, 0.1)	-1	1	3

Table 4.3: 随机 *Pendulum* 中动作添加噪声的分布。

基线方法

作为基线, 包括基于增广状态的 TRPO (A-TRPO) 和无记忆 TRPO (M-TRPO), 以覆盖基于 TRPO 的方法谱系。此外, 考虑 SAC, 因其在延迟应用中取得了优异的实证结果 [?, ?]。还在基线中包括基于增广状态的 SAC (A-SAC) 和无记忆 SAC (M-SAC)。SAC 的一个超参数是其更新频率。尽管将该参数设置为每一步都重新训练可提高样本效率, 但会显著增加计算时间和内存占用。因此, 仅在 *Pendulum* 上每一步都训练 SAC, 而在 *Mujoco* 上限制为每 50 步训练一次以加速过程。曾考虑加入 DCAC [?], 但其实现计算开销较大, 决定不纳入。早期实验结果表明其运行时间超过其他算法的 10 倍以上。此外, 考虑 SARSA 和 $\lambda = 0.9$ 的 dSARSA, 但仅用于 *Pendulum* 环境。由于 SARSA 是一种批量 RL 算法, 需要对状态和动作空间进行仔细离散化, 这直接影响最终性能。因此, 需要额外的离散化验证步骤。对 *Pendulum*, 使用经过调优的 15×15 状态空间网格和总共五个离散动作。最后, 在测试中将 L2-TRPO 作为基线, 该方法采用与 [?] 类似的方法学习状态的期望值。

D-TRPO 的设置

在呈现的实验中, 测试 D-TRPO, 即信念表征网络接入 TRPO [?] 后的结果。一个重要说明是, 经过 D-TRPO 的早期实验, 我们注意到信念模块优化过程中信念表征可能发生显著变化。这反过来导致 TRPO 策略优化不稳定, 因为其输入分布不断变化。为缓解此问题, 在 200 轮后提前停止信念表征模块的训练。

4.4.2 结果

Pendulum. 不同方法和不同延迟值下的回报见??。水平虚线表示无延迟版本 SAC 获得的回报。对于不超过五的延迟, D-TRPO 和 L2-TRPO 的回报与无延迟 SAC 相当。同时注意 A-SAC 在此情况下的优异表现。然而, 随着延迟增加, D-TRPO 和 L2-TRPO 的性能下降比 A-SAC 更显著。在??中, 聚焦延迟为 5 时 D-TRPO 和基线方法在学习阶段的表现。图中还报告了无延迟 TRPO 的结果。自然, 后者比任何基于 TRPO 的延迟方法更快, 但有趣的是, 它比 A-SAC 慢。这表明 SAC 在解决此问题时特别有效, 即便存在延迟。除 A-SAC 外, D-TRPO 和 L2-TRPO 具有最快的收敛速度, 与无延迟 TRPO 相比, 需要额外约 100 万步才能达到类似策略。

Mujoco. 在??中, 报告 *Mujoco* 环境的结果。此处同样, A-SAC 特别高效, 仅在 *Swimmer* 环境中未获第一。令人惊讶的是, 在 500 万步后, M-TRPO 在该环境中表现最佳。D-TRPO 和 L2-TRPO 在所有环境中表现良好, 仅在 *Walker2d* 上出现明显性能不足。




Figure 4.4: *Pendulum* 环境中 *D-TRPO* 和基线方法在不同延迟值下的平均回报。水平虚线表示无延迟 *SAC* 的性能。阴影区域表示一个标准差，结果基于 10 个随机种子获得。

随机 Pendulum. 在该任务上，仅比较 *D-TRPO* 与 *L2-TRPO*，以评估学习未来状态信念表征相对于其均值的优势。结果报告在??中。为便于阅读结果，将噪声分为三组。可以观察到 *D-TRPO* 从未被 *L2-TRPO* 超越。对于某些噪声类型，如 Uniform 和 Triangular 噪声，两者获得相似的性能。然而，对于其他类型的噪声，如 Quadratic 和 LogNormal (0.1) 情况，性能差异更为明显。这表明信念表征在最坏情况下并非必要，但在最佳情况下可提供更高性能。

同时学习多个延迟. 在该实验中，测试??中提出的思路，即 *D-TRPO* 和 *L2-TRPO* 在某个延迟 $\Delta > 0$ 下学习的策略应用于另一个延迟 $0 < \Delta' < \Delta$ 。在??中，提供 *Pendulum* 任务上 *D-TRPO* 和 *L2-TRPO* 以 $\Delta = 5$ 训练的结果。在??和??中，提供 Mujoco 任务上 *D-TRPO* 和 *L2-TRPO* 以 $\Delta = 5$ 训练的结果。显然且符合预期，较小延迟下获得的性能与原始性能相当。

4.5 结论

本章针对常值延迟问题提出了一种基于模型的方法。核心思想是学习信念的向量表征，将无限维量转化为有限维。这得益于对 NN 的精心选择。该信念表征可作为状态的预处理模块接入任何 RL 算法，正如本文将其接入 TRPO 构建 *D-TRPO* 一样。通过一个简单技巧，展示了如何利用 *D-TRPO* 在较大延迟下学习的策略，直接应用于更小延迟。该技巧显著降低了适应延迟的学习成本，因为可以同时学习多个延迟。实验评估证实了这一可预见的结果，策略在任何更小延迟下均取得相似的性能。

随后对常值延迟问题进行了分析。延迟越长、最优性能越低这一事实已得到形式化证明，该证明可为未来分析提供有用工具。此外，揭示了基于模型方法的复杂度结果，展示了该方法的局限性。基于相同思路，给出了一个反例，证明与最优延迟策略相比，基于模型的策略在某些 MDPs 中可能产生次优的期望回报或平均奖励。

最后，通过实验分析评估了 *D-TRPO* 的能力。实验表明，尽管 *A-SAC* 是整体最有效的方法，但 *D-TRPO* 能够适应广泛场景，特别是随机 MDPs，甚至也包括确定性环境。因此，信念表征网络是一种通用方法，可作为任何 RL 算法




Figure 4.5: *D-TRPO* 和 *L2-TRPO* 与延迟为 5 的 *Pendulum* 任务中其他基线方法的回报比较。包含无延迟 *TRPO* 的性能（记为“*TRPO*”）作为对照。阴影区域表示一个标准差，结果基于 10 个随机种子获得。

的即插即用预处理模块。值得注意的是，它允许控制信念表征的大小，从而控制RL算法输入的维度。

一个有价值的未来方向是利用模型的知识将其融入RL算法内部，例如增强演员-评论家方法中的评论家更新。




Figure 4.6: *D-TRPO* 和 *L2-TRPO* 与基线方法在各种 *Mujoco* 环境中的回报比较。阴影区域表示一个标准差，结果基于 10 个随机种子获得。




Figure 4.7: *D-TRPO* 和 *L2-TRPO* 与基线方法在添加不同噪声（如??所述）的 *Pendulum* 环境中的回报比较。颜色表示噪声类型，标记表示算法。阴影区域表示一个标准差，结果基于 10 个随机种子获得。




Figure 4.8: 延迟 10 训练的 *D-TRPO* 在 *Pendulum* 上以更小延迟测试的回报。




Figure 4.9: 延迟 5 训练的 $D\text{-TRPO}$ 在 *Mujoco* 环境中以更小延迟测试的回报。




Figure 4.10: 延迟 5 训练的 $L2\text{-TRPO}$ 在 *Mujoco* 环境中以更小延迟测试的回报。

无延迟策略的模仿

5.1 引言

本章首先考虑常值状态观测或动作执行延迟。如??所述，常值延迟相关文献主要集中于三个方向：增广方法、无记忆方法和基于模型的方法。前一章探索了基于模型的方法。本章探索一条新方向，源自一种简单而高效的方法（后文将展示其高效性）。核心理念是通过模仿无延迟策略的行为学习延迟策略。遵循模仿学习（imitation learning）文献的惯例，本章将执行模仿的策略称为学习器（learner），将被模仿的策略称为专家（expert）。显然，延迟策略（学习器）可能无法精确模仿无延迟策略（专家），因为前者仅能访问增广状态，而无延迟策略可访问当前状态。但期望在于，模仿所得策略与专家策略足够相似，从而其性能仍接近专家水平。

本文提出一种算法——基于数据集聚合的延迟模仿（Delayed Imitation with Dataset Aggregation, DIDA），该算法建立在模仿学习算法 DAGGER [?] 基础之上（另见??）。由于延迟加剧了学习器与专家之间状态分布的偏移，DAGGER 尤为适用，因其在自身分布下表达模仿损失 [?]

在更详细地介绍该方法后，本文将证明 DIDA 在理论和实验上均取得优异结果。在理论上，本文为 DIDA 所学策略相对于无延迟专家提供了紧致的性能保证 (??)。在实验上，本文在广泛任务中测试 DIDA，与众多基线方法对比，并展示了其在最终性能和样本效率方面的优越性 (??)。

最后，除常值整数延迟之外，本文提出 DIDA 的三种扩展。通过对原始实现进行微小修改，将 DIDA 应用于非整数延迟并扩展了理论保证 (??)。接着，为 DIDA 所学策略在随机延迟任务中测试的情形提供理论界，这是匿名状态观测或动作执行延迟的首个界 (??)。随后，详细阐述如何将 DIDA 针对给定延迟所学策略应用于更小延迟 (??)。所有扩展均经实验验证，结果令人满意。




Figure 5.1: 无延迟策略 π (专家) 被延迟策略 $\tilde{\pi}$ (学习器) 模仿的示意图。学习器仅能看到增广状态，对当前状态 s_t 不可见。

5.2 无延迟策略的模仿学习

核心理念如??所示，即模仿无延迟专家在当前未观测状态上会执行的策略。由于当前状态未知，只能根据增广状态计算其信念。因此，延迟策略学习在信念分布下复制无延迟策略的动作。使用 DAGGER [?] 作为模仿学习算法，因其能够考虑专家与学习器策略之间的分布偏移，如??所述。这是一项重要性质，因为延迟加剧了状态分布的偏移。该偏移将在??中详细讨论。

5.2.1 轨迹的对偶性

应用 DAGGER 的重要前提是专家和学习器均能从环境中采样。对于常值延迟 Δ MDP，这得益于所谓轨迹的对偶性 (duality of trajectories)。一方面，在 MDP 中，可通过忽略最新状态信息、向智能体提供过去状态及此后执行的动作序列来构造合成增广状态。通过此方式，可在无延迟环境中从延迟策略采样。另一方面，延迟环境中的智能体最终将观测到其当前状态¹。得益于这一性质，延迟策略采样所得任意轨迹的概率均可按无延迟策略计算。综上所述，一旦完成采样，轨迹既可自延迟策略视角分析，亦可自无延迟策略视角分析，无论该轨迹是如何采样的。因此，常值延迟 Δ MDP 满足将 DAGGER 应用于模仿问题的前提。

5.2.2 基于数据集聚合的延迟模仿 (DIDA)

通用算法

遵循 DAGGER 框架 (见??)，提出基于数据集聚合的延迟模仿 (Delayed Imitation with Dataset Aggregation, DIDA)。与 DAGGER 类似，DIDA 通过跟随专家策略或学习器策略从环境中采样。若选择专家，则在环境的当前状态上查询无延迟策略 π 。若选择学习器策略，则从轨迹历史中合成构造增广状态，并将其输入延迟策略 $\tilde{\pi}$ 。实践中，这意味着需要维护一个近期历史缓冲区。对于模仿步骤，DIDA 构建一个数据集 $\mathcal{D} = (x^{(i)}, a_E^{(i)})_{0 \leq i \leq N}$ ，其中包含增广状态 $x^{(i)}$ 与无延迟策

¹这在部分可观测马尔可夫决策过程 (POMDP) 中通常不成立。

略在当前未观测状态上所选动作 $a_E^{(i)}$ 的元组。随后，延迟策略在 $\mathcal{D}$ 上训练，以在给定增广状态时复制专家的动作。实际实现中，增广状态的存储可以高效完成。事实上，两个连续增广状态中的大部分动作是相同的。因此，只需存储状态-动作历史，并在训练时才构造增广状态即可。DIDA 的算法如??所示。

无延迟环境时的 DIDA

若无法访问可直接应用 DIDA 的无延迟环境，对该算法稍作修改即可使用。当本应在未观测当前状态上查询无延迟策略时，可改为在最后观测到的状态上以无记忆方式查询无延迟策略（见??）。当 DAGGER 的 β -routine 满足 $\beta_1 = 1, \beta_{i \geq 2} = 0$ （见??）时，这一点更为重要。即仅第一次迭代使用无延迟策略（此时延迟策略尚未训练），后续迭代仅查询延迟策略。需对??做两处修改。首先，在第 5 行，将 $a_E \sim \pi(\cdot | s_{\Delta+1})$ 替换为 $a_E \sim \pi(\cdot | s_1)$ 。其次，数据集 $\mathcal{D}$ 的填充方式应更改。因为不需要专家以无记忆方式选择的动作。相反，存储在 $\mathcal{D}$ 中的专家动作应对应于专家在未观测当前状态下选择的动作。这意味着，在实践中，观察到增广状态 x 后，智能体需等待 Δ 步才能观察到当前未观测状态。只有在那时，无记忆专家才能提供动作 a_E ，与 x 一同添加到数据集 $\mathcal{D}$ 中。因此，?? 的第 10 行必须相应延迟。将 DIDA 的这一变体称为 memoryless-DIDA (M-DIDA)。

DIDA 学习得到的策略

在随机 MDPs 中，未观测当前状态的信念支撑可能扩展到多个状态。DIDA 将学习在该分布下复制专家的动作。形式上，完全模仿下 DIDA 的输出策略如下：

$$\tilde{\pi}(a|x) = \int_S b_{\Delta}(s|x) \pi(a|s) ds. \quad (5.1)$$

值得注意的是，该策略可视为基于模型的策略，?? 适用于它。因此，存在某些 MDPs 使得 DIDA 相比最优无延迟策略是次优的。后续??的理论分析将表明，该策略在平滑 MDPs 中仍然是高效的。

?? 中的策略是在完全模仿下获得的，然而实践中，取决于损失函数，该策略可能有所不同。下面给出两个例子。

均方误差损失 (Mean squared error loss)。 对于从 $\mathcal{D}$ 中采样的 x ，若 DIDA 的模仿步骤满足，

$$\arg \min_{\theta \in \Theta} \int_S \int_{\mathcal{A}} (a - \tilde{\pi}_{\theta}(x))^2 \pi(a|s) b_{\Delta}(s|x) da ds,$$

则输出策略为，

$$\tilde{\pi}_{\theta^*}(x) = \mathbb{E}_{s \sim b_{\Delta}(\cdot|x)} \left[\mathbb{E}_{a \sim \pi(\cdot|s)} [a] \right].$$

即，该策略返回专家策略在信念上的均值。

Kullback-Leibler 损失 (Kullback-Leibler loss)。 对于从 $\mathcal{D}$ 中采样的 x ，

Algorithm 2 基于 DAGGER 的延迟模仿算法 (DIDA)

Inputs (un)delayed MDP $\mathcal{M}$, undelayed expert π , β -routine, number of steps N , empty dataset $\mathcal{D}$.

Outputs: delayed policy $\tilde{\pi}$

```

1: for  $\beta_i$  in  $\beta$ -routine do
2:   for  $j$  in  $\{1, \dots, N\}$  do
3:     if New episode then
4:       Initialize state buffer  $(s_1, s_2, \dots, s_{\Delta+1})$  and action buffer  $(a_1, a_2, \dots, a_{\Delta})$ 
5:     end if
6:     Sample  $a_E \sim \pi(\cdot | s_{\Delta+1})$ , set  $a = a_E$ 
7:     if Random  $u \sim U([0, 1]) \geq \beta_i$  then
8:       Overwrite  $a \sim \pi_I(\cdot | [s_1, a_1, \dots, a_{\Delta}])$ 
9:     end if
10:    Aggregate dataset:
                                 $\mathcal{D} \leftarrow \mathcal{D} \cup ([s_1, a_1, \dots, a_{\Delta}], a_E)$ 
11:    Apply  $a$  in  $\mathcal{M}$  and get new state  $s$ 
12:    Update buffers:
                                 $(s_1, \dots, s_{\Delta+1}) \leftarrow (s_2, \dots, s_{\Delta+1}, s)$ 
                                 $(a_1, \dots, a_{\Delta}) \leftarrow (a_2, \dots, a_{\Delta}, a)$ 
13:  end for
14:  Train  $\tilde{\pi}$  on  $\mathcal{D}$ 
15: end for
    
```

DIDA 学习到的策略满足:

$$\begin{aligned} & \arg \min_{\theta \in \Theta} \int_{\mathcal{S}} D_{\text{KL}}(\pi(\cdot | s) \| \tilde{\pi}_{\theta}(\cdot | x)) b_{\Delta}(s | x) ds \\ &= \arg \min_{\theta \in \Theta} - \int_{\mathcal{S}} \int_{\mathcal{A}} \pi(a | s) \log \tilde{\pi}_{\theta}(a | x) b_{\Delta}(s | x) da ds \end{aligned} \quad (5.2)$$

$$= \arg \min_{\theta \in \Theta} - \int_{\mathcal{A}} \int_{\mathcal{S}} \pi(a | s) \log \tilde{\pi}_{\theta}(a | x) b_{\Delta}(s | x) ds da \quad (5.3)$$

$$\begin{aligned} &= \arg \min_{\theta \in \Theta} \int_{\mathcal{A}} \int_{\mathcal{S}} \pi(a | s) b_{\Delta}(s | x) \log (b_{\Delta}(s | x) \pi(a | x)) ds da \\ &\quad - \int_{\mathcal{A}} \int_{\mathcal{S}} \pi(a | s) \log \tilde{\pi}_{\theta}(a | x) b_{\Delta}(s | x) ds da \quad (5.4) \\ &= \arg \min_{\theta \in \Theta} D_{\text{KL}} \left(\int_{\mathcal{S}} \pi(\cdot | s) b(s | x) ds \middle\| \tilde{\pi}_{\theta}(\cdot | x) \right), \end{aligned}$$

其中?? 通过展开 KL 散度并注意到其中一项不依赖于 θ 得到; ?? 由 Fubini 定理成立, 因积分内的函数始终为负; ?? 通过添加一项不依赖于 θ 的项得到。

5.2.3 非整数延迟

下面将前述算法扩展到非整数延迟情形。然而, 首先需要推导一些理论结果, 以便扩展该框架。

非整数延迟的理论

注意到，即使延迟小于一个步长 $\Delta \in (0, 1)$ ，也需要增广状态 $x_t = (s_t, a_{t-1}) \in \mathcal{S} \times \mathcal{A} =: \mathcal{X}$ 。这是因为在某个时刻 $t + \epsilon$ （其中 $\epsilon \leq \Delta$ ）施加的动作仍然是上一时刻选择的动作 a_{t-1} 。在后续章节中，使用记号“ $\lfloor \cdot \rfloor$ ”表示实数的整数部分，“ $\{ \cdot \}$ ”表示其小数部分，“ $\lceil \cdot \rceil$ ”表示大于它的最小整数。关于如何通过两个交错 MDPs 构造非整数延迟环境，参见??。当 $\Delta \in (0, 1)$ 时，这些交错 MDPs 为 $\mathcal{M}$ 和 $\mathcal{M}_\Delta$ 。当 $\Delta > 1$ 时，只需将第二个 MDP 平移延迟的小数部分。因此，这两个 MDPs 为 $\mathcal{M}$ 和 $\mathcal{M}_{\{\Delta\}}$ 。第一个结果是，非整数延迟问题可以重新归结为 MDP。

Proposition 5.2.1. 设 $\Delta \in \mathbb{R}_{\geq 0}$ 为一个（非）整数延迟，考虑一个在动作执行或状态观测上具有常值延迟 Δ 的 Δ MDP $\widetilde{\mathcal{M}}$ 。则可通过用最近的 $\lfloor \Delta \rfloor$ 个动作增广状态，将该问题重新归结为 MDP。

Proof. 针对动作执行延迟证明此结果，状态观测延迟的证明可类似推导。构造一个 MDP $\mathcal{M}$ ，使用增广状态空间 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^{\lfloor \Delta \rfloor}$ 作为其状态空间，使得对任意延迟策略，其在 $\mathcal{M}$ 中的回报等于在 $\widetilde{\mathcal{M}}$ 中的回报。对于增广状态 $x = (s, a_1, \dots, a_{\lfloor \Delta \rfloor})$ 和 $x' = (s', a'_1, \dots, a'_{\lfloor \Delta \rfloor})$ in $\mathcal{X}$ ，新的转移分布为：

$$\tilde{p}(x'|x, a) := p(s'|s, a_1) \delta_a(a'_{\lfloor \Delta \rfloor}) \prod_{i=1}^{\lfloor \Delta \rfloor - 1} \delta_{a_{i+1}}(a'_i).$$

注意，当 $\Delta \notin \mathbb{N}$ 时， p 的定义如??所示：

$$p(s'|s, a) = \int_{\mathcal{S}} b_{1-\{\Delta\}}(s'|z, a) b_{\{\Delta\}}(z|s, a) dz. \quad (5.5)$$

现在，对于 $x = (s, a_1, \dots, a_{\lfloor \Delta \rfloor})$ ，期望奖励定义为，

$$\tilde{r}(x, a) = \mathbb{E}_{z \sim b_\Delta(z|x)} [r(z, a)].$$

为完成证明，设 $\tilde{\pi}$ 为 $\widetilde{\mathcal{M}}$ 的任意历史依赖策略。假设在时刻 t ， $\widetilde{\mathcal{M}}$ 和 $\mathcal{M}$ 中观测到的状态与动作历史 $(s_0, a_0, \dots, s_t, a_t, \dots, a_{t+\lfloor \Delta \rfloor - 1}) \in \mathcal{S}^t \times \mathcal{A}^{t+\lfloor \Delta \rfloor}$ 相同。任何基于历史的策略智能体随后在 $\mathcal{M}$ 和 $\widetilde{\mathcal{M}}$ 中以相同概率选择下一个动作 $a_{t+\lfloor \Delta \rfloor}$ 。在 $\widetilde{\mathcal{M}}$ 中，给定当前观测状态 s_t 和其效果尚未显现的动作 a_t ，智能体以概率 $p(s_{t+1}|s_t, a_t)$ 观测到新状态 s_{t+1} 。在 $\mathcal{M}$ 中，新增广状态中包含的状态 s_{t+1} 同样根据设计从 $p(s_{t+1}|s_t, a_t)$ 采样。因此， $t+1$ 时刻的历史也匹配。通过归纳，这对任意 $t' > t$ 均成立。只需以相同方式初始化这两个过程，即可使它们在 $\mathcal{S}$ 上具有相同的状态分布。由于历史相同， $\widetilde{\mathcal{M}}$ 和 $\mathcal{M}$ 中收集的奖励也由设计保证相等。这意味着任意延迟策略在两个过程中达到相同的回报。□

注意，为证明状态观测延迟的前述命题，需交换 $\mathcal{M}$ 和 $\mathcal{M}_{\{\Delta\}}$ 这两个 MDPs。事实上，考虑 $\Delta \in (0, 1)$ ；对于动作执行延迟，智能体看到当前状态 s_t ，但其动作 a_t 在 $t + \Delta$ 时刻执行于状态 $s_{t+\Delta}$ 。对于状态观测延迟，若智能体的当前未观测状态也是 s_t ，则最近观测到的状态将是 $s_{t-\Delta}$ ，若 $\Delta \neq \frac{1}{2}$ ，该状态不属于 $\mathcal{M}_\Delta$ 。相反，如果将当前未观测状态置于 $s_{t+\Delta}$ ，则延迟状态总是属于 $\mathcal{M}$ 。总之，两个

² $\mathcal{X}^t \times \mathcal{A}^t$ 上的历史显然定义了 $\mathcal{S}^t \times \mathcal{A}^{t+\lfloor \Delta \rfloor}$ 上的一个历史。

过程之间的区别在于智能体何时选择动作。对于动作执行延迟，智能体在其当前状态属于 $\mathcal{M}$ 时选择动作；而对于状态观测延迟，智能体在其当前状态属于 $\mathcal{M}_\Delta$ 时选择动作。这种控制步长的偏移可通过??形象理解。

下面给出一个结果，表明与整数情形类似，动作执行延迟和状态观测延迟在非整数情形下也是等价的。

Proposition 5.2.2. 设 $\Delta \in \mathbb{R}_{\geq 0}$ 为一个（非）整数延迟。设 $\mathcal{M}$ 和 $\mathcal{M}_{\{\Delta\}}$ 是两个交错的 MDPs，在此基础上定义两个常值延迟 Δ MDPs: $\tilde{\mathcal{M}}$ 在动作执行上延迟 Δ ， $\tilde{\mathcal{M}}'$ 在状态观测上延迟 Δ^3 。则 $\tilde{\mathcal{M}}$ 和 $\tilde{\mathcal{M}}'$ 等价。

Proof. 通过观察??中构造的等价 MDPs 相同，即可得证。 $\square$

面向非整数延迟的 DIDA

现在将 DIDA 扩展到非整数情形。使用??中的记法，以两个交错 MDPs $\mathcal{M}$ 和 $\mathcal{M}_\Delta$ 定义非整数延迟。与 DIDA 类似，第一步是学习一个无延迟策略。此处，无延迟策略在 $\mathcal{M}_\Delta$ 中学习。而延迟智能体观测到的状态将是 $\mathcal{M}$ 中的状态。修改后的算法如??所示。与??的主要区别在于，DIDA 必须记住最近的 $\lceil \Delta \rceil$ 个动作。此外，DIDA 还必须同时维护来自 $\mathcal{M}$ 和 $\mathcal{M}_\Delta$ 的状态缓冲区，因为前者用于构造增广状态，后者用于计算无延迟专家的动作。注意，DIDA 针对非整数延迟学习的策略仍然满足??。

Remark 5.2.1. 类似思路也可用于上一节提出的算法。 $D\text{-}TRPO$ 可以调整，使其在观测 $\mathcal{M}$ 中状态的同时，学习 $\mathcal{M}_\Delta$ 中的信念表示。

非整数延迟的时间 Lipschitz 性质

为将下一节的理论扩展到非整数延迟，现将非整数延迟纳入 $L_T\text{-}TLC$ 的定义中（见??）。给定 $\Delta \in (0, 1)$ ，若 $\forall s, a \in \mathcal{S} \times \mathcal{A}$,

$$\mathcal{W}_1(b_\Delta(\cdot|s, a), \delta_s) \leq \Delta L_T. \quad (5.6)$$

则称 Δ MDP 是 $L_T\text{-}TLC$ 的。

5.2.4 同时学习多重延迟的 DIDA

与??中相同的思想可应用于 DIDA。针对延迟 $\Delta > 0$ 学习的策略，可通过模拟 Δ 的延迟，在具有较小延迟 $0 < \Delta' < \Delta$ 的环境中执行。??中的实验将展示该思路的有效性。

5.3 DIDA 理论分析

本节理论分析旨在实现两个目标。首先，为延迟策略与无延迟策略之间的性能差异提供界。这些界将依赖于环境平滑性假设（见??）。其次，研究这些界有助于理解哪些无延迟专家更适于在延迟环境中被模仿。

³首先固定 $\mathcal{M}$ 和 $\mathcal{M}_{\{\Delta\}}$ 确保两个 Δ MDPs 中观测到的状态与执行动作时所处的状态相对应。否则，可以构造出动作延迟智能体观测 s_t 并作用于 $s_{t+\Delta}$ ，而状态延迟智能体观测 $s_{t-\Delta}$ 并作用于 s_t 的情形，此时会出现不匹配。

Algorithm 3 面向非整数延迟的 DIDA ($\Delta \in \mathbb{R}_{\geq 0}$)

Inputs: $\{\Delta\} := \Delta - \lfloor \Delta \rfloor$, MDPs $\mathcal{M}$ and $\mathcal{M}_{\{\Delta\}}$ obtained from continuous-time MDP, undelayed expert π trained on $\mathcal{M}_\Delta$, β -routine, number of steps N , empty dataset $\mathcal{D}$.

Outputs: delayed policy π_I

```

1: for  $\beta_i$  in  $\beta$ -routine do
2:   for  $j$  in  $\{1, \dots, N\}$  do
3:     if New episode then
4:       Initialize state buffer  $(s_1, s_{1+\{\Delta\}}, \dots, s_{\lfloor \Delta \rfloor}, s_{\Delta+1})$  and action buffer  $(a_0, a_1, \dots, a_{\lfloor \Delta \rfloor})$ 
5:     end if
6:     Sample  $a_E \sim \pi(\cdot | s_{\Delta+1})$ , set  $a = a_E$ 
7:     if Random  $u \sim U([0, 1]) \geq \beta_i$  then
8:       Overwrite  $a \sim \tilde{\pi}(\cdot | [s_1, a_0, \dots, a_{\lfloor \Delta \rfloor}])$ 
9:     end if
10:    Aggregate dataset:
                                 $\mathcal{D} \leftarrow \mathcal{D} \cup ([s_1, a_0, a_2, \dots, a_{\lfloor \Delta \rfloor}], a_E)$ 
11:    Apply  $a$  at  $s_{\Delta+1}$  and get new states  $(s_{\lfloor \Delta \rfloor+1}, s_{\Delta+2})$ 
12:    Update buffers:
                                 $(s_1, s_{1+\{\Delta\}}, \dots, s_{\lfloor \Delta \rfloor}, s_{\Delta+1}) \leftarrow (s_2, s_{2+\{\Delta\}}, \dots, s_{\lfloor \Delta \rfloor+1}, s_{\Delta+2})$ 
                                 $(a_0, \dots, a_{\lfloor \Delta \rfloor}) \leftarrow (a_1, \dots, a_{\lfloor \Delta \rfloor}, a)$ 
13:   end for
14:   Train  $\tilde{\pi}$  on  $\mathcal{D}$ 
15: end for

```

5.3.1 延迟与无延迟性能的比较

在直接给出理论结果之前，有必要澄清一点。需要比较延迟策略和无延迟策略的价值函数，然而它们的输入空间不同。具体而言，延迟策略 $\tilde{\pi}$ 的输入空间为 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^\Delta$ ，而无延迟策略的输入空间为 $\mathcal{S}$ 。下文详述文献中提出的两种比较方式。

弱随机马尔可夫决策过程中的比较

比较延迟策略与无延迟策略的一种可能方式由 [?] 提出。其思想源于以下观察：若 Δ MDP 源自确定性 MDP，则它们有相同的最优性能（直到??中提到的延迟初始化偏移）。这易于理解：利用环境的确定性模型计算当前状态后，智能体可选择无延迟策略在该状态下推荐的动作。显然，困难在于学习 MDP 的模型。为扩展这一比较，[?] 考虑了所谓的弱随机 (mildly stochastic) MDP，即满足如下条件的 MDP：

$$\exists \epsilon \text{ s.t. } \forall (s, a) \in \mathcal{S} \times \mathcal{A}, \exists s', p(s' | s, a) \geq 1 - \epsilon.$$

由于这些 MDPs 仅是弱随机的，可按上述方式针对 MDP 的确定性近似学习最优延迟策略。记 $\hat{V}^\pi$ 为无延迟策略在 MDP 确定性近似中的价值函数，则有 [?, Theorem 3]：

$$\|\hat{V}^\pi - V^\pi\|_\infty \leq \frac{\gamma \epsilon R_{\max}}{(1 - \gamma)^2},$$

其中 V^π 是同一策略 π 在无延迟 MDP 中的价值函数。注意这两个价值函数的输入空间均为 $\mathcal{S}$ 。另一个值得注意的观察是，结果对有效时域 $\frac{1}{1-\gamma}$ 呈二次依赖关系。弱随机性假设相当强，本文将为更弱的假设提供结果。

基于信念分布的比较

另一种方法的优势在于可适用于任意 MDP，由 [?] 提出。对于给定增广状态 $x \in \mathcal{X}$ ，作者比较了延迟策略的价值函数 $V^{\tilde{\pi}}(x)$ 与无延迟策略在给定 x 下信念的期望价值函数 $\mathbb{E}_{s \sim b_\Delta(\cdot|x)}[V^\pi(s)]$ 。作者提出学习一种延迟策略，该策略选择的动作最大化无延迟策略 Q 函数在信念分布下的期望。假设动作空间基数有限 $|\mathcal{A}|$ ，延迟策略 $\tilde{\pi}$ 相对于最优策略 π^* 具有如下保证 [?, Theorem 1]:

$$V^{\tilde{\pi}}(x) \geq \mathbb{E}_{s \sim b_\Delta(\cdot|x)}[V^{\pi^*}(s)] - \frac{R_{\max}}{(1-\gamma)^2} \left(1 - \frac{1}{|\mathcal{A}|}\right)$$

再次注意对有效时域的二次依赖关系。在本文的分析中，将比较相同量，同时增加对底层 MDP 平滑性的假设。

5.3.2 常值延迟性能损失的上界

在理论部分的余下内容中，假设底层 MDP 是平滑的。具体而言，需要 MDP 是 (L_P, L_r) -LC 的 (见??)，且专家的无延迟策略是 L_π -LC 的 (见??)。此外，还需要其 Q 函数是 L_Q -LC 的⁴。这些平滑性保证的优点在于排除了诸如?? 中的病态例子。然而，该设定仍然是现实的，因为许多物理系统是 Lipschitz 的。

为给出上界的主要结果，首先推导延迟情形下性能差异引理 [?, Lemma 6.1] 的改编版本。该结果本身可能对延迟文献有用。该结果曾在 [?, Equation 32] 中针对整数延迟独立推导，但本文给出一个更通用的版本，适用于延迟 $\Delta \in \mathbb{R}_{\geq 0}$ 。下文中，记 $d_x^{\tilde{\pi}}$ 为延迟策略 $\tilde{\pi}$ 从增广状态 x 出发在增广状态空间 $\mathcal{X}$ 上的折扣状态占据分布。

Lemma 5.3.1 (延迟性能差异引理 (Delayed Performance Difference Lemma)). 对于某些 $\Delta \in \mathbb{R}_{\geq 0}$ ，设 π 为无延迟策略， $\tilde{\pi}$ 为同一底层 MDP $\mathcal{M}$ 上的 Δ -延迟策略。则 $\forall x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_\Delta(\cdot|x)}[V^\pi(s)] - V^{\tilde{\pi}}(x) = \frac{1}{1-\gamma} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\mathbb{E}_{s \sim b_\Delta(\cdot|x')} [V^\pi(s)] - \mathbb{E}_{\substack{s \sim b_\Delta(\cdot|x') \\ a \sim \tilde{\pi}(\cdot|x')}} [Q^\pi(s, a)] \right].$$

Proof. 首先证明整数延迟下的结果。

整数延迟。 考虑 $\Delta \in \mathbb{N}$ ， $x \in \mathcal{X}$ ，设

$$I(x) = \mathbb{E}_{s \sim b_\Delta(\cdot|x)}[V^\pi(s)] - V^{\tilde{\pi}}(x).$$

⁴在某些情形下，这可由前两个假设推出，见??。

通过对 I 加上并减去同一量, 得到:

$$\begin{aligned}
 I(x) &= \underbrace{\mathbb{E}_{s \sim b_{\Delta}(\cdot|x)}[V^{\pi}(s)] - \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x) \\ a \sim \tilde{\pi}(\cdot|x)}} \left[r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot|s, a)}[V^{\pi}(s')] \right]}_{=A} \\
 &\quad + \underbrace{\mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x) \\ a \sim \tilde{\pi}(\cdot|x)}} \left[r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot|s, a)}[V^{\pi}(s')] \right]}_{=B} - V^{\tilde{\pi}}(x).
 \end{aligned}$$

然后分析上式中的每一项。首先,

$$A = \mathbb{E}_{s \sim b_{\Delta}(\cdot|x)}[V^{\pi}(s)] - \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x) \\ a \sim \tilde{\pi}(\cdot|x)}}[Q^{\pi}(s, a)].$$

其次, 由于 $V^{\tilde{\pi}}(x) = \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x) \\ a \sim \tilde{\pi}(\cdot|x)}}[r(s, a)] + \gamma \mathbb{E}_{\substack{x' \sim \tilde{p}(\cdot|x, a) \\ a \sim \tilde{\pi}(\cdot|x)}}[V^{\tilde{\pi}}(x')]$, 则,

$$B = \gamma \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x) \\ a \sim \tilde{\pi}(\cdot|x)}} \left[\mathbb{E}_{s' \sim p(\cdot|s, a)}[V^{\pi}(s')] \right] - \gamma \mathbb{E}_{\substack{x' \sim \tilde{p}(\cdot|x, a) \\ a \sim \tilde{\pi}(\cdot|x)}}[V^{\tilde{\pi}}(x')].$$

注意,

$$\int_{\mathcal{S}} b_{\Delta}(s|x)p(s'|s, a)ds = \int_{\mathcal{X}} \tilde{p}(x'|x, a)b_{\Delta}(s'|x')dx'. \quad (5.7)$$

这意味着, 给定当前增广状态 x 和某动作 a , 下一个未观测当前状态为 s' 的概率可通过两种方式获得: 要么先以当前未观测状态 s 为条件, 要么以下一个增广状态 x' 为条件。由此得到,

$$\begin{aligned}
 B &= \gamma \mathbb{E}_{\substack{x' \sim \tilde{p}(\cdot|x, a) \\ a \sim \tilde{\pi}(\cdot|x)}} \left[\mathbb{E}_{s \sim b_{\Delta}(\cdot|x')}[V^{\pi}(s')] - V^{\tilde{\pi}}(x') \right] \\
 &= \gamma \mathbb{E}_{\substack{x' \sim \tilde{p}(\cdot|x, a) \\ a \sim \tilde{\pi}(\cdot|x)}}[I(x')],
 \end{aligned}$$

通过识别量 I 。现在, 如同原始引理, 迭代此结果:

$$\begin{aligned}
 I(x) &= \sum_{t=0}^{\infty} \gamma^t \mathbb{E}_{\substack{x_{t+1} \sim \tilde{p}(\cdot|x_t, a_t) \\ a_t \sim \tilde{\pi}(\cdot|x_t)}} \left[\mathbb{E}_{s \sim b_{\Delta}(\cdot|x_t)}[V^{\pi}(s)] - \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x_t) \\ a \sim \tilde{\pi}(\cdot|x_t)}}[Q^{\pi}(s, a)] \middle| x_0 = x \right] \\
 &= \frac{1}{1 - \gamma} \mathbb{E}_{x' \sim d_{\tilde{\pi}}^x} \left[\mathbb{E}_{s \sim b_{\Delta}(\cdot|x')}[V^{\pi}(s)] - \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x') \\ a \sim \tilde{\pi}(\cdot|x')}}[Q^{\pi}(s, a)] \right], \quad (5.8)
 \end{aligned}$$

其中?? 由策略 $\tilde{\pi}$ 的折扣增广状态占据分布定义得到 (见??)。因此, 证明了 $\Delta \in \mathbb{N}$ 下的结果。

非整数延迟。 为证明清晰起见, 假设 $\Delta \in (0, 1)$, 但 $\Delta \in \mathbb{R}_{\geq 0}$ 的一般结果可由此轻松导出。注意此时信念的定义如?? 所示。前述整数延迟的证明可顺利应用于非整数延迟。唯一可能不易直接推导的步骤是??。因此, 下面详述该步骤。对于 $x_t = (s_t, a_{t-1}), x_{t+1} = (s_{t+1}, a_t) \in \mathcal{X}$,

$$\begin{aligned}
 & \int_{\mathcal{S}} b_{\Delta}(s_{t+\Delta}|x_t) p(s_{t+1+\Delta}|s_{t+\Delta}, a) ds_{t+\Delta} \\
 &= \int_{\mathcal{S}} b_{\Delta}(s_{t+\Delta}|x_t) \int_{\mathcal{S}} b_{\Delta}(s_{t+1+\Delta}|s_{t+1}, a) b_{1-\Delta}(s_{t+1}|s_{t+\Delta}, a) ds_{t+1} ds_{t+\Delta} \quad (5.9) \\
 &= \int_{\mathcal{S}} b_{\Delta}(s_{t+1+\Delta}|s_{t+1}, a) \int_{\mathcal{S}} b_{\Delta}(s_{t+\Delta}|x_t) b_{1-\Delta}(s_{t+1}|s_{t+\Delta}, a) ds_{t+\Delta} ds_{t+1} \\
 &= \int_{\mathcal{S}} b_{\Delta}(s_{t+1+\Delta}|s_{t+1}, a) \int_{\mathcal{S}} b_{\Delta}(s_{t+\Delta}|s_t, a_{t-1}) b_{1-\Delta}(s_{t+1}|s_{t+\Delta}, a) ds_{t+\Delta} ds_{t+1} \\
 &= \int_{\mathcal{A}} \int_{\mathcal{S}} b_{\Delta}(s_{t+1+\Delta}|s_{t+1}, a_t) \delta_a(a_t) \\
 & \quad \int_{\mathcal{S}} b_{\Delta}(s_{t+\Delta}|s_t, a_{t-1}) b_{1-\Delta}(s_{t+1}|s_{t+\Delta}, a) ds_{t+\Delta} ds_{t+1} da_t \\
 &= \int_{\mathcal{X}} b_{\Delta}(s_{t+1+\Delta}|x_{t+1}) \tilde{p}(x_{t+1}|x_t, a) dx_{t+1}. \quad (5.10)
 \end{aligned}$$

?? 由?? 中 p 的定义得到, ?? 通过识别增广 MDP 中的转移得到。 $\square$

下面陈述本章的主要结果。该结果不仅对 DIDA 有价值, 对任何满足?? 的策略均有价值。 Δ MDPs 的平滑性是证明的关键要素。

Theorem 5.3.1. 设 $\mathcal{M}$ 是 (L_P, L_r) -LC 的 MDP, π 是 L_{π} -LC 的无延迟策略。进一步假设 Q^{π} 是 L_Q -LC 的⁵。设 $\Delta \in \mathbb{R}_{\geq 0}$, 并考虑满足?? 的 Δ -延迟策略 $\tilde{\pi}$ 。则 $\forall x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_{\Delta}(\cdot|x)} [V^{\pi}(s)] - V^{\tilde{\pi}}(x) \leq \frac{L_Q L_{\pi}}{1 - \gamma} \sigma_b^x,$$

其中

$$\sigma_b^x = \mathbb{E}_{\substack{x' \sim d_x^{\tilde{\pi}} \\ s, s' \sim b_{\Delta}(\cdot|x')}} [\mathbf{d}_{\mathcal{S}}(s, s')].$$

Proof. 本证明无需区分整数和非整数延迟。设 $\Delta \in \mathbb{R}_{\geq 0}$ 。由??, 对于某些 $x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_{\Delta}(\cdot|x)} [V^{\pi}(s)] - V^{\tilde{\pi}}(x) = \frac{1}{1 - \gamma} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\underbrace{\mathbb{E}_{s \sim b_{\Delta}(\cdot|x')} [V^{\pi}(s)] - \mathbb{E}_{\substack{s \sim b_{\Delta}(\cdot|x') \\ a \sim \tilde{\pi}(\cdot|x')}} [Q^{\pi}(s, a)]}_{A(x')} \right].$$

⁵证明仅需 Q^{π} 在第二个参数上的 Lipschitz 性质。

关注项 $A(x')$ 。有,

$$\begin{aligned} A(x') &= \mathbb{E}_{s \sim b_{\Delta}(\cdot|x')} \left[\mathbb{E}_{\substack{a_1 \sim \pi(\cdot|s) \\ a_2 \sim \tilde{\pi}(\cdot|x')}} [Q^{\pi}(s, a_1) - Q^{\pi}(s, a_2)] \right] \\ &\leq L_Q \mathbb{E}_{s \sim b_{\Delta}(\cdot|x')} [\mathcal{W}_1(\pi(\cdot|s) \|\tilde{\pi}(\cdot|x'))], \end{aligned} \quad (5.11)$$

其中结果由应用?? 得到。最后一步是使用 σ_b^x 对 $\mathbb{E}_{s \sim b_{\Delta}(\cdot|x')} [\mathcal{W}_1(\pi(\cdot|s) \|\tilde{\pi}(\cdot|x'))]$ 进行上界估计。因此,

$$\begin{aligned} \mathcal{W}_1(\pi(\cdot|s) \|\tilde{\pi}(\cdot|x')) &= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} f(a)(\pi(a|s) - \tilde{\pi}(a|x')) da \right| \\ &= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} f(a)(\pi(a|s) - \int_{\mathcal{S}} \pi(a|s') b_{\Delta}(s'|x') ds') da \right| \end{aligned} \quad (5.12)$$

$$\leq \int_{\mathcal{S}} b_{\Delta}(s'|x') \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} f(a)(\pi(a|s) - \pi(a|s')) da \right| ds' \quad (5.13)$$

$$\begin{aligned} &\leq \int_{\mathcal{S}} b_{\Delta}(s'|x') \mathcal{W}_1(\pi(\cdot|s) \|\pi(\cdot|s')) ds' \\ &\leq L_{\pi} \int_{\mathcal{S}} b_{\Delta}(s'|x') d_{\mathcal{S}}(s, s') ds', \end{aligned} \quad (5.14)$$

其中?? 由?? 得到, ?? 由 Fubini-Tonelli 定理得到, ?? 由 π 的 Lipschitz 性质得到。将此结果代入?? 即得结论。 $\square$

为使该结果更具实际解释性, 提供两种方式进一步约束非常见项 σ_b^x , 每种方式引入一个新的假设。第一个结果假设 MDP 具有时间 Lipschitz 性质 (见??)。

Corollary 5.3.1. 若?? 的假设成立, 且此外 MDP 是 L_T -TLC 的, 则 $\forall x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_{\Delta}(\cdot|x)} [V^{\pi}(s)] - V^{\tilde{\pi}}(x) \leq \frac{2\Delta L_T L_Q L_{\pi}}{1 - \gamma}.$$

Proof. 将?? 应用于?? 即得结果。 $\square$

该结果清晰表明, 性能差异的界与延迟呈线性关系。该界的一个关键局限性在于, 当 MDP 变为确定性时, 它不会趋于 0。事实上, 如?? 所述, 在这种情况下, 最优延迟回报应与无延迟回报匹配。下面给出的 ?? 的第二个推论则没有这一局限性。

Corollary 5.3.2. 若?? 的假设成立, 且此外 $\mathcal{S} \subseteq \mathbb{R}^n$ 配备欧几里得范数, 则 $\forall x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_{\Delta}(\cdot|x)} [V^{\pi}(s)] - V^{\tilde{\pi}}(x) \leq \frac{\sqrt{2} L_Q L_{\pi}}{1 - \gamma} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\sqrt{\text{Var}_{s \sim b_{\Delta}(\cdot|x')} (s|x')} \right].$$

Proof. 将?? 应用于?? 即得结果。 $\square$

为评估这些界的质量, 下面给出性能差异的下界结果。

5.3.3 常值延迟性能损失的下界

本小节通过展示在相同平滑性假设下，当专家的无延迟策略为最优时，?? 与一个下界在常数项内匹配，从而增加其意义。

Theorem 5.3.2. 设 $L_\pi > 0$, $L_Q > 0$, $\Delta \in \mathbb{R}_{\geq 0}$ 。则存在一个 MDP，其最优 L_π -LC 策略 π^* 的价值函数在第二个参数上是 L_Q -LC 的，但对任意 Δ -延迟策略 $\tilde{\pi}$ 和 $x \in \mathcal{X}$,

$$\mathbb{E}_{s \sim b_\Delta(\cdot|x)} [V^*(s)] - V^{\tilde{\pi}}(x) \geq \frac{\sqrt{2} L_Q L_\pi}{\sqrt{\pi} 1 - \gamma} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\sqrt{\text{Var}_{s \sim b_\Delta(\cdot|x')} (s|x')} \right],$$

其中 V^* 为最优无延迟策略的价值函数。

Proof. 对于给定的 $L_\pi > 0$, $L_Q > 0$ 和 $\Delta \in \mathbb{R}_{\geq 0}$, 设计一个 MDP $\mathcal{M} = (\mathcal{S}, \mathcal{A}, p, R, d_0)$ 使得: $\mathcal{S} = \mathbb{R}$; $\mathcal{A} = \mathbb{R}$; 其转移函数为

$$p(s'|s, a) = \mathcal{N}\left(s'; s + \frac{a}{L_\pi}, \sigma^2\right),$$

即 $s' = s + \frac{a}{L_\pi} + \varepsilon$, 其中 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$; 其奖励函数为

$$r(s, a) = \mathbb{E}[R(s, a)] = -L_r \left| s + \frac{a}{L_\pi} \right|,$$

其中 $L_r := L_Q L_\pi$ 。在 r 的定义中使用 L_Q , 因为后文将证明这正是 Q^* 的 Lipschitz 常数。注意 $\forall (s, a) \in \mathcal{S} \times \mathcal{A}$, $r(s, a) \leq 0$, 但策略 $\pi^*(a|s) = \delta_{-L_\pi s}(a)$ 对任意状态-动作对 (s, a) 获得奖励 0。这意味着 $V^* = 0$ 处处成立。

现在证明 Q 函数是 Lipschitz 的,

$$\begin{aligned} Q^*(s, a) &= -L_r \left| s + \frac{a}{L_\pi} \right| + \gamma \int_{\mathbb{R}} V^*(s') p(s'|s, a) ds' \\ &= -L_r \left| s + \frac{a}{L_\pi} \right| \\ &= -L_Q |L_\pi s + a|. \end{aligned}$$

因此, Q^* 在第二个参数上是 L_Q -LC 的。

现在研究 Δ -延迟策略 $\tilde{\pi}$ 的情形。对于给定时间步 t , 未观测当前状态为

$$s_t = \underbrace{s_{t-\Delta} + \sum_{\tau=t-\Delta}^{t-1} \frac{a_\tau}{L_\pi}}_{=: \phi(x_t)} + \underbrace{\sum_{\tau=t-\Delta}^{t-1} \varepsilon_\tau}_{=: \epsilon}.$$

上面定义了两个量。第一个 $\phi(x_t)$ 是增广状态 $x_t \in \mathcal{X}$ 的确定性函数。第二个 ϵ 是服从分布 $\mathcal{N}(0, \Delta \sigma^2)$ 的随机变量。利用这些量, 可以定义增广奖励为,

$$\begin{aligned} \tilde{r}(x_t, a) &= -L_r \mathbb{E} \left[\left| s_t + \frac{a}{L_\pi} \right| \right] \\ &= -L_r \mathbb{E} \left[\left| \phi(x_t) + \frac{a}{L_\pi} + \epsilon \right| \right]. \end{aligned}$$

因此奖励正比于函数 $f : a \mapsto \mathbb{E} [\|\mathcal{N}(g(a), \Delta\sigma)\|]$, 其中 $g(a) = \phi(x_t) + \frac{a}{L_\pi}$ 。 f 的最小值在 $g(a) = 0$ 处取得, 对应于半正态分布的均值, 即 $\min_{a \in \mathbb{R}} f(a) = \frac{\sigma\sqrt{2\Delta}}{\sqrt{\pi}}$, 因此,

$$\tilde{r}(x_t, a) \leq -L_r \frac{\sqrt{2\Delta}}{\sqrt{\pi}} \sigma.$$

于是,

$$\begin{aligned} V^{\tilde{\pi}}(x) &= \mathbb{E}_{\substack{x_{t+1} \sim \tilde{p}(\cdot|x_t, a_t) \\ a_t \sim \tilde{\pi}(\cdot|x_t)}} \left[\sum_{t=0}^{\infty} \gamma^t \tilde{r}(x_t, a_t) \mid x_0 = x \right] \\ &\leq -\frac{L_r}{1-\gamma} \frac{\sqrt{2\Delta}}{\sqrt{\pi}} \sigma \\ &= -\frac{L_Q L_\pi}{1-\gamma} \frac{\sqrt{2}}{\sqrt{\pi}} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\sqrt{\text{Var}_{s \sim b_\Delta(\cdot|x')}(s|x')} \right], \end{aligned}$$

其中, 第一个不等式中注意到, 根据 $\mathcal{M}$ 的定义, 任何未观测当前状态的方差相同。最后一个不等式中, 将 L_r 替换为 $L_Q L_\pi$, 将 $\Delta\sigma^2$ 替换为信念上的方差 $\text{Var}_{s \sim b_\Delta(\cdot|x)}(s|x)$ 。该不等式与 $V^* = 0$ 在任意状态成立的事实共同完成了证明。 $\square$

该结果凸显出专家的策略越粗糙, 保证越弱。

5.3.4 常值延迟的启示

下面讨论前述理论结果的含义。这些界在策略 $\tilde{\pi}$ 完美模仿了无延迟策略且满足?? 时成立。实践中可能并非如此, 这是性能损失的第一来源。性能损失的第二个来源是无延迟策略本身可能并非最优, 虽然这不影响界, 但会降低智能体的最终性能。

特别指出两个关键权衡。首先, 更平滑的专家在无延迟环境中可能是次优的, 但根据??, 这为延迟策略提供了更简单的模仿问题。其次, 更嘈杂的策略在无延迟环境中也可能次优, 但通过提供错误决策及如何从中恢复的示例, 可以简化模仿任务 [?].

5.3.5 随机延迟性能损失的界

本小节研究将 DIDA 应用于随机整数延迟时的保证。动作执行延迟和状态观测延迟在此情形下可能不等价, 具体取决于延迟的随机性。等价性仅在特殊类型的随机延迟 [?, Result 2] 及 [?] 中得到证明。后者的结果中, 随机延迟的定义与下文引入的定义类似。

考虑延迟状态观测, 其延迟序列 $(\Delta_t)_{t \geq 0}$ 独立同分布, 具有离散分布 ζ , 支撑集为 $[0, \Delta_{\max}]$ 。例如, $\mathbb{P}(\Delta_t = k) = \zeta(k)$ 表示状态 s_t 在时刻 s_{t+k} 被观测到的概率。记 $\zeta(k|i)$ 为在已知 $\Delta_t > i$ 的条件下 $\Delta_t = k$ 的概率。同时假设延迟是非匿名的 (non-anonymous), 即每当智能体收集到新观测时, 该观测的原始时间步是已知的。这避免了信用分配问题。

在该框架下, 可以考虑如下增广状态 $x \in \tilde{\mathcal{X}} := \mathcal{S} \times \mathcal{A}^{\Delta_{\max}} \times \mathbb{N}$:

$$x = (s, a_1, \dots, a_{\Delta_{\max}}, n),$$




Figure 5.2: 随机延迟示例：在时刻 t ，延迟为 n ；在时刻 $t+1$ ，延迟变为 $n' = n-1$ 。这意味着智能体观测到了 2 个新状态。步数之间的观测数量随机变量 O 的概率定义为如?? 所示概率的乘积。注意，索引 $t-n+1$ 的状态是否被观测到无关紧要，因为已观测到更近期的状态。

其中 $(a_1, \dots, a_{\Delta_{\max}})$ 是通常的动作缓冲区， s 是最近观测到的状态， n 表示 s 被观测的时刻与当前时刻之间的时间差。换言之， n 是当前有效延迟。假设增广状态对智能体可用，因此延迟包含在智能体的信息结构中（见??）。后文将看到，延迟的非匿名性是该问题定义的关键。显然，当 $n < \Delta_{\max}$ 时，增广状态中的某些动作是无用的，因为已经观测到更近期的状态。该框架与 [?] 的随机延迟框架相似。

接下来，定义此新过程的转移概率，记为 $\tilde{p}_o$ 。对于两个增广状态 $x = (s, a_1, \dots, a_{\Delta_{\max}}, n)$ 和 $x' = (s', a'_1, \dots, a'_{\Delta_{\max}}, n')$ ，

$$\tilde{p}(x'|x, a) = \mathbb{P}(O = n + 1 - n') p^{n+1-n'}(s'|x, a) \delta_a(a'_{\Delta_{\max}}) \prod_{i=1}^{\Delta_{\max}-1} \delta_{a_{i+1}}(a'_i). \quad (5.15)$$

该方程引入了一些新项。首先，随机变量 O 。它表示前一个最近观测状态 s 与新的最近观测状态 s' 之间的步数差。其概率可计算为：

$$\begin{aligned} \mathbb{P}(O = k) &= \zeta(n - k + 1 | n - k) \\ &\quad \cdot (1 - \zeta(0)) \prod_{i=1}^{n-k} (1 - \zeta(n - k + 1 - i | n - k - i)), \end{aligned} \quad (5.16)$$

其中 $\zeta(n - k + 1 | n - k)$ 是 s 之后 k 步的状态被观测到的概率，后续的 $(1 - \zeta(\cdot))$ 项确保更近期的状态未被观测到。注意 $n' = n - k + 1$ 。另外注意 s 和 s' 之间的中间状态观测与否对转移概率无关紧要。基于这一观察， O 可视为给定步数内的观测数量。?? 给出了如何解释随机变量 O 的直观表示。其次，?? 中的项 $p^{n+1-n'}(s'|x, a)$ 是底层 MDP 中从 s 出发、遵循 x 中的动作序列再跟随 a 的 $n+1-n'$ 步转移。

该过程的奖励可定义如下，

$$\tilde{r}(x, a) = \sum_{k=0}^n \mathbb{P}(O = k) \sum_{i=0}^{k-1} \gamma^i \mathbb{E}_{s_i \sim p^i(s_i|x, a)} [r(s_i, a_i)].$$

该奖励基本上将新观测到的所有步数的奖励求和。该定义假设，每当某个状态被观测到时，所有尚未观测到的中间状态将被同时观测到。

显然，涉及增广状态的过程定义了一个 MDP，并证明了以下命题。

Proposition 5.3.1. 具有独立同分布延迟 $(\Delta_t)_{t \geq 0}$ （离散分布 ζ ，如上定义）的 Δ MDP 可通过用最近的 $\Delta_{\max}$ 个动作和当前有效延迟增广状态来归结为 MDP。

该命题也在 [?] 中针对更一般的状态观测和动作执行延迟设定中被发现。需要注意的是，包含动作执行延迟会带来一个问题：在给定时间步可能没有动作被执行，或者多个动作在同一时间步被执行。在这些情况下，必须定义环境的行为。

现在考虑在此框架中应用 DIDA 学习的策略 $\tilde{\pi}$ ，以研究当真实环境具有随机延迟但错误假设为常值延迟时的影响。注意，DIDA 训练的常值 Δ -延迟 Δ MDP 可视为上述过程的一个实例，其中 ζ 分布的全部权重放置在 Δ 处。在这种情况下，对于 $x = (s, a_1, \dots, a_{\Delta_{\max}}, n)$ ，认为 $\tilde{\pi}(\cdot|x) = \tilde{\pi}(\cdot|s, a_{\Delta_{\max}-\Delta+1}, \dots, a_{\Delta_{\max}})$ 。实际上，DIDA 将状态 s 视为延迟了 Δ ，并且对 n 不可见。将 DIDA 与如下定义的策略 $\tilde{\pi}$ 进行比较：

$$\tilde{\pi}(a|x) = \int_S b_n(s|x) \pi(a|s) ds. \quad (5.17)$$

该策略的构造与 DIDA 相似，但适应 n 的值。下文中，记 $\bar{\Delta}$ 为随机延迟过程的平均延迟，定义如下：

$$\bar{\Delta} = \mathbb{E}[n] = \sum_{k=0}^{\Delta_{\max}} k \prod_{i=0}^{k-1} \mathbb{P}(\Delta_i > i) \mathbb{P}(\Delta_k = k)$$

Theorem 5.3.3. 考虑如上定义的具有随机延迟的 Δ MDP，假设底层 MDP 是 L_T -TLC 的。考虑由 DIDA 针对常值延迟学习的策略 $\tilde{\pi}$ (??) 和策略 $\tilde{\pi}$ (??)。假设 $\tilde{\pi}$ 的 Q 函数 $Q^{\tilde{\pi}}$ 在第二个参数上是 $L_{\tilde{Q}}$ -LC 的⁶。则 $\tilde{\pi}$ 和 $\tilde{\pi}$ 之间的性能差异可界为：

$$|V^{\tilde{\pi}}(x) - V^{\tilde{\pi}}(x)| \leq \frac{L_{\tilde{Q}} L_{\pi} L_T}{1 - \gamma} (\bar{\Delta} + \Delta).$$

Proof. 由??，随机延迟 Δ MDP 是一个 MDP。因此，可应用常规性能差异引理，对于 $x \in \tilde{\mathcal{X}}$ ⁷，

$$V^{\tilde{\pi}}(x) - V^{\tilde{\pi}}(x) = \frac{1}{1 - \gamma} \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} \left[\underbrace{V^{\tilde{\pi}}(x) - \mathbb{E}_{a \sim \tilde{\pi}(\cdot|x')} [Q^{\tilde{\pi}}(x, a)]}_{A(x')} \right].$$

⁶例如，当 $\gamma \max(L_P, 1) \cdot (1 + 2L_{\pi} L_P) < 1$ 时成立。该结果通过将 [?, Theorem 1] 应用于常值延迟 MDP (??) 和 DIDA 策略 (??) 的 Lipschitz 常数得到。

⁷注意，本证明中，重载了原先定义于常值延迟 Δ MDP 空间 $\mathcal{X}$ 上的符号 $d_x^{\tilde{\pi}}$ ，改用空间 $\tilde{\mathcal{X}}$ 作为其定义域。

如?? 中, 可通过应用?? 推导以下界, 其中记 $x' = (s', a'_1, \dots, a'_{\Delta_{\max}}, n')$,

$$\begin{aligned}
 A(x') &\leq L_{\tilde{Q}} \mathcal{W}_1(\tilde{\pi}(\cdot|x') \| \tilde{\pi}(\cdot|x')) \\
 &= L_{\tilde{Q}} \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} f(a) (\tilde{\pi}(a|x') - \tilde{\pi}(a|x')) da \right| \\
 &= L_{\tilde{Q}} \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} \int_{\mathcal{S}} f(a) \pi(a|s) (b_{n'}(s|x') - b_{\Delta}(s|x')) ds da \right| \\
 &\leq L_{\tilde{Q}} L_{\pi} \mathcal{W}_1(b_{n'}(\cdot|x') \| b_{\Delta}(\cdot|x')) \\
 &\leq L_{\tilde{Q}} L_{\pi} L_T (n' + \Delta),
 \end{aligned} \tag{5.18}$$

其中设定 $b_{\Delta}(s|x') = b_{\Delta}(s|s', a'_1, \dots, a'_{\Delta_{\max}})$ 。这里使用了无延迟策略 π 是 L_{π} -LC 的事实, ?? 通过复现?? 的证明得到。因此,

$$\begin{aligned}
 V^{\tilde{\pi}}(x) - V^{\pi}(x) &\leq \frac{L_Q L_{\pi} L_T}{1 - \gamma} \left(\Delta + \mathbb{E}_{x' \sim d_x^{\tilde{\pi}}} [n'] \right) \\
 &= \frac{L_Q L_{\pi} L_T}{1 - \gamma} (\Delta + \bar{\Delta}),
 \end{aligned}$$

其中最后等式通过对增广状态中除 n' 外的项积分得到。 $\square$

注意时间 Lipschitz 性质在证明中的重要性。没有这一假设, $\mathcal{W}_1(b_{n'}(\cdot|x') \| b_{\Delta}(\cdot|x'))$ 对 x' 的依赖关系仍然存在, 其在 $d_x^{\tilde{\pi}}$ 下的期望也不明确。 n 与增广状态中其他元素之间确实存在非平凡依赖关系。例如, 当延迟较小时, $\mathcal{S}$ 中的某些状态可能被更频繁地访问。另外注意, ?? 中 $\mathcal{S} \subseteq \mathbb{R}^n$ 配备欧几里得范数的假设在此帮助不大, 因为 $\mathcal{W}_1(b_{n'}(\cdot|x') \| b_{\Delta}(\cdot|x'))$ 可能比较不同长度的轨迹 ($n' \neq \Delta$)。DIDA 在该框架中对真实延迟不可见, 构成了匿名延迟 (anonymous delay) 的情形 (见??)。据本文所知, 这是 RL 中匿名状态观测延迟的首个结果。

5.4 实验评估

本节提供实验以评估 DIDA 在广泛任务中的表现。首先在?? 中描述实验设置, 然后在?? 中展示并讨论结果。

5.4.1 实验设置

除 Trading 任务外, 对所有任务运行 DIDA 和基线方法, 取 10 个种子的结果进行平均。Trading 任务的详细说明如下。

任务

Pendulum. 与前一章相同, 采用 Pendulum 环境, 因其对延迟敏感。考虑 $\{3, 5, 10, 15, 20\}$ 中的常值延迟。对该任务, 执行 500 个 epoch, 每个 epoch 5,000 步, 总计 250 万步。

随机 Pendulum. 引入前一章定义的 Pendulum 随机版本, 以评估 DIDA 在随机环境中的表现。考虑常值延迟 5, 执行 500 个 epoch, 每个 epoch 5,000 步, 总计 250 万步。

非整数延迟 Pendulum。 为测试 DIDA 在非整数延迟上的表现，提出以下设置。首先，学习一个持久度 (persistence) 为 2 的无延迟专家，其中持久度表示智能体在选择新动作之前重复执行同一动作的次数 [?]。本质上，持久度为 2 时，智能体的控制频率减半。DIDA 将在时间步集合 $(2t)_{t \in \mathbb{N}}$ (与专家相同) 中的状态下执行，而 DIDA 观测到的状态的时间步在 $(2t + 1)_{t \in \mathbb{N}}$ 中。

Mujoco。 类似地，引入四个 mujoco 环境：Walker2d、HalfCheetah、Reacher 和 Swimmer。对这些任务，考虑常值延迟 5，执行 1,000 个 epoch，每个 epoch 5,000 步，总计 500 万步。

Trading。 在该任务中，智能体以 10 分钟的控制频率交易 EUR-USD (€/€) 货币对，涵盖 2016-2019 年期间。遵循 [?] 和 [?] 的框架，智能体相对于固定金额的 USD 可以选择买入 (buy)、卖出 (sell) 或持平 (flat)。不考虑交易费用；但考虑买卖价差，其对奖励的影响在实践中等同于交易费用。在该框架中，考虑 50 秒的常值动作执行延迟。这导致非整数延迟。在该任务中，使用 2016-2017 年数据训练不同方法，2018 年数据验证超参数，2019 年数据测试。需要验证集是因为数据集由历史数据构成；该任务是批量强化学习 (batch RL) 或离线强化学习 (offline RL) 任务，方法可能对训练集过拟合。

同时学习多重延迟。 对于 Pendulum 和 mujoco 环境，同时评估 DIDA 在较大延迟上训练、在较小延迟上测试时的表现。考虑在延迟 10 上训练 DIDA，然后在 $[1, 9]$ 的较小延迟上测试 Pendulum；类似地，在 mujoco 任务中，训练延迟为 5。

基线方法

考虑??中使用的基线方法，采用相同超参数。这些基线方法包括：无记忆 TRPO (M-TRPO)、增广状态 TRPO (A-TRPO)、增广状态 SAC (A-SAC)、无记忆 SAC (M-SAC)、SARSA 和 dSARSA ($\lambda = 0.9$)。同时包含之前的方法 L2-TRPO 和 D-TRPO。

同时考虑 M-DIDA (见??) 作为基线，以评估是否需要访问无延迟环境。

对于 Trading 任务，用于训练 DIDA 的无延迟专家通过 2018 年的超参数验证选出。也可以在延迟数据集上对 2018 年的超参数进行验证，以选择一个在延迟上泛化能力更强的专家 (尽管是在无延迟数据上训练的)。在实验中将此基线称为“延迟专家” (delayed expert)。

对于 Pendulum，还包含 BC-DIDA，对应于 DIDA 但使用行为克隆 (behavioral cloning) [?] 替代 DAGGER 作为模仿算法。该基线用于研究模仿算法选择的影响。

DIDA 设置

在所有实验中，为与其他基线进行公平的样本效率比较，将训练无延迟专家所需的步数纳入考虑，并相应平移 DIDA 的起始样本数。在图中以垂直虚线表示。关于无延迟专家本身，从前述理论可见，更平滑的专家对模仿延迟策略的性能界有利 (??)。因此，除 Trading 任务外，所有实验均采用 SAC 作为专家。关于平滑策略的研究 [?] 表明，SAC 的熵正则化框架在实践中具有学习更平滑策略的效果，而无需显式优化策略的平滑性。对于 DIDA 自身的策略，使用简单的前馈神经网络。

对于 Trading 环境，利用通过 Fitted Q-Iteration (FQI) [?] 在 2016-2017 年数据上训练的专家知识，使用 XGBoost [?] 作为 Q 函数的回归器，与 [?] 中的方法相同。在该任务中，为更好地匹配专家的基于树的方法，使用 Extra Trees [?]




Figure 5.3: DIDA 和基线方法在 *Pendulum* 环境中不同延迟值下的平均回报。水平虚线对应无延迟专家 (SAC) 的性能。阴影区域表示一个标准差，结果基于 10 个种子获得。

作为 DIDA 的策略。该环境高度随机，使用不同种子训练的专家可能具有非常不同的性能。因此，考虑 4 个使用不同种子但相同配置训练的专家。对每个专家，使用 5 个种子重复 DIDA 的训练。总计 20 次 DIDA 试验，对其结果计算均值和标准差。

对于 β -routine，如 [?] 建议，设置 $\beta_1 = 1, \beta_{i \geq 2} = 0$ 。这意味着无延迟专家仅在 DIDA 的第一次迭代中用于从环境采样。

如?? 所示，每次迭代中，DIDA 训练的示例缓冲区会加入最新样本。为防止无限增长，使用最大缓冲区大小为 10 次迭代。这意味着当缓冲区满时，较新的样本会以先进先出的方式覆盖最旧的样本。

5.4.2 实验结果

Pendulum. 不同延迟值下各方法的回报如?? 所示。对于小延迟，DIDA、BC-DIDA 和 M-DIDA 取得的回报与 A-SAC 相当，略优于 D-TRPO 和 L2-TRPO。当延迟增加时观察到有趣的现象。显然，DIDA 和 M-DIDA 对所有其他基线以及 BC-DIDA 对延迟增加更为鲁棒，BC-DIDA 的性能急剧下降。值得注意的是 DIDA 和 M-DIDA 性能相似，这表明从无延迟环境采样并非算法的关键要素。?? 中聚焦延迟 5 的结果证实了这一点，该图展示了性能随样本数的变化。DIDA 和 M-DIDA 在所需样本数方面具有非常相似的学习速度，而 BC-DIDA 稍慢，A-SAC 也稍慢。专家策略与 DIDA 之间的性能差异源于?? 中提及的延迟初始化偏移问题。在初始步骤中，为在实践中初始化延迟环境，动作从环境中均匀随机采样，这可能迫使智能体在与真实初始状态相比不利的状态下开始动作。

随机 Pendulum. 这些任务的结果如?? 所示。与前一章相同，噪声按照?? 分为几组。在左上图中，所有噪声均基于 beta 分布。在该任务中，DIDA 不仅取得了远优于基线的最终性能，而且收敛到这些性能的速度也远快于基线。在右上图的第二组中，基线性能接近 DIDA，但 DIDA 仍然显著领先。最后，在左下图的第三组中，DIDA 再次取得最佳性能。对于 $\text{LogNormal}(1.0)$ 噪声，即使 DIDA 的性能也显著下降，这在意料之中，因为该噪声高度不对称，使信念分布对算法更具挑战性。




Figure 5.4: DIDA 和基准方法在 *Pendulum* 环境中延迟为 5 时获得的回报。水平虚线对应专家家的回报，垂直虚线表示训练专家所用的步数。阴影区域表示一个标准差，结果基于 10 个种子获得。

非整数延迟 Pendulum。 结果如?? 所示。在该任务中，DIDA 的性能略低于其在整数延迟上的性能（报告于??）。有两个原因。首先，专家以持久度 2 训练，回报略低。其次，此处 DIDA 将其动作持续执行 2 步，因此延迟值也翻倍。?? 中的延迟 1 对应于?? 中的延迟 2。无论如何，DIDA 的性能仍然令人满意，表明其能够有效适应非整数延迟。

Mujoco。 结果如?? 所示。此处再次，DIDA 和 M-DIDA 取得了相似性能，同时优于所有基线。部分由于延迟的初始化偏移，在 *HalfCheetah* 和 *Reacher* 中，DIDA 的表现远差于无延迟专家。更令人惊讶的是，在 *Swimmer* 中，DIDA 的表现略好于专家。这是延迟初始化偏移的一个意外后果。事实上，在某些环境中，初始随机动作序列可能将智能体置于有利状态。在 *HalfCheetah* 中，随机动作有时使智能体头朝下，因此必须先站起来才能移动。而在 *Swimmer* 中，随机动作为智能体提供了初始速度。

Trading。 对于该任务，报告训练集（2019）上获得的结果，如?? 所示。鉴于买卖价差的存在对回报具有决定性影响，仅获得正回报便已是不小的成就。DIDA 不仅取得了正回报，而且明显优于延迟专家。令人惊讶的一点是，DIDA 初始时获得了比专家本身更好的回报。策略实际上略有不同。在?? 中，通过表示 DIDA 学习到的策略与专家策略的动作模式对比，分析 DIDA 学习到的策略。具体来说，该图说明了批量 RL 设定的困难。DIDA 在第 10 次迭代学习到的策略与训练集上的专家非常相似，但开始偏离测试集上的专家。

同时学习多重延迟。 此处探索?? 中提出的思路，即将 DIDA 针对某个延迟 $\Delta > 0$ 学习的策略应用于更小的延迟 $0 < \Delta' < \Delta$ 。在?? 中，给出 *Pendulum* 任务的结果，其中 DIDA 策略在延迟 $\Delta = 10$ 上训练。在?? 中，给出 *mujoco* 任务的结果，其中 DIDA 策略在延迟 $\Delta = 5$ 上训练。显然且符合预期，在较小延迟上获得的性能与 DIDA 在训练所用延迟上达到的性能相似。




Figure 5.5: 添加不同噪声（如?? 所述）的 *Pendulum* 环境中 *DIDA* 和基线方法获得的回报。颜色表示噪声类型，标记表示算法。水平虚线表示每种噪声下专家的回报，垂直虚线表示训练专家所用的步数。在右上图中，专家性能汇聚在一起。阴影区域表示一个标准差，结果基于 10 个种子获得。

5.5 结论

本章针对状态观测或动作执行中的常值延迟问题，设计了一种简单而高效的解决方案。该方案首先在无延迟环境中学习一个策略，然后在延迟环境中模仿该策略。本文证明了在环境具有平滑性时，此类模仿策略相对于无延迟专家的性能界。利用这些理论洞见，设计了 *DIDA* 算法，该算法遵循上述原则，采用 *DAGGER* 作为模仿算法。实验结果展示了 *DIDA* 相对于众多基线方法的有效性。*DIDA* 几乎总能取得更优的回报，同时需要更少的样本。有趣的是，本文展示了该算法如何经过修改适用于另外三种场景。首先，当延迟为常值但非整数时，对 *DIDA* 进行简单调整即表现出良好的实验结果。其次，虽然 *DIDA* 是在常值延迟上训练的，但本文为其在随机延迟上测试时提供了理论保证。第三，将?? 中的简单”技巧”应用于 *DIDA*，可利用针对某一延迟学习的策略高效地应用于更小延迟。作为未来研究方向，可修改当前算法使其在随机延迟上训练，并学习?? 中的策略。这样将获得比?? 提供更好的理论保证。另一个方向是解决 *DIDA* 的主要缺点——对无延迟专家的依赖。一种可能的思路是从延迟策略收集的数据集中离线




Figure 5.6: *DIDA* 在 *Pendulum* 环境中不同非整数延迟值下的平均回报。水平虚线表示无延迟专家 (*SAC*) 的性能。阴影区域表示一个标准差，结果基于 10 个种子获得。

学习一个无延迟专家。这意味着不再需要从无延迟环境中采样任何样本。




Figure 5.7: *DIDA* 和基准方法在各种 *Mujoco* 环境中获得的回报。水平虚线对应专家的回，垂直虚线表示训练专家所用的步数。阴影区域表示一个标准差，结果基于 10 个种子获得。




Figure 5.8: 2019 年 EUR-USD 货币对交易的累计回报 (占投资金额的百分比)。DIDA 与其训练的专家以及一个超参数在延迟数据集上选择的无延迟专家 (称为“延迟专家”) 进行比较。




Figure 5.9: 表示 *Trading* 任务中专家的动作模式和 *DIDA* 的动作模式的热力图。将专家的动作模式（左）与 *DIDA* 在第 10 次迭代的动作模式进行比较，分别在训练集（2016-2017，中）和测试集（2019，右）上。热力图显示给定天（行）的给定分钟（列）所选的动作（颜色）。




Figure 5.10: 在 *Pendulum* 上，以延迟 10 训练的 *DIDA* 在较小延迟上测试获得的回报。




Figure 5.11: 在多种 *Mujoco* 环境中，以延迟 5 训练的 *DIDA* 在较小延迟上测试获得的回报。

面向延迟的非平稳强化学习

6.1 引言

本章探索一种无记忆方法来解决状态观测或动作执行中的常值延迟问题。与增广方法相比，在无记忆方法中，过程失去了马尔可夫性质；动态依赖于一个未观测变量，即动作序列。这类似于从智能体视角看由于部分可观测性而呈现非平稳性的过程，而底层过程本身是平稳的 [?, Section 2.1]。因此，我们朝这个方向迈出一步，设计一种非平稳策略，能够解释状态的未观测部分并在整个回合中调整其行为。这一方法还受到如下事实的推动：存在某些 Δ MDPs，其中最优的平稳无记忆策略相对于最优无记忆策略是次优的 [?, Proposition 5.2]。此外，最优无记忆策略保证存在于仅使用最后观测状态而非其先前历史作为输入的非平稳策略集合中 [?, Theorem 5.1]。这类策略在 [?] 中被称为“Markovian”，尽管它们不知道当前未观测状态，而仅使用最后观测状态。

关于非平稳性本身，随时间变化的动态在许多 RL 设定中很常见，例如终身 RL、持续 RL、非平稳 RL 和迁移学习。事实上，这些设定常常被混淆在一起。为了更好地理解它们的差异，我们将按照 [?] 的分类法简要介绍它们。

非平稳 RL [?]. 它可以被视为许多子问题的统称，因为从该术语本身并不清楚考虑的是何种具体类型的非平稳性。以下框架可以被视为非平稳 RL 的子领域。

迁移学习 [?]. 在迁移学习中，智能体在一组任务上训练，然后被置于一组新任务中，应尽可能快地学习，利用先前知识。非平稳性通常出现在回合之间，因为任务从一个回合变为下一个。

终身学习 [?]. 与持续学习互换使用，它考虑智能体与其环境在永不结束的轨迹中的交互。智能体无法重启环境，也无法确定会再次经历环境的某些部分。这些特殊性带来了许多问题。首先，智能体必须以在线方式学习，利用迄今收集的信息来优化未来某种性能度量。其次，由于智能体正在学习且其策略发生变化，

访问状态的分布将是非平稳的。除此之外，环境本身也可能变化。因此，存在两个非平稳性来源。第三，智能体应智能地利用其过去记忆。为了计算和存储目的丢弃无用信息，但记住有用的策略以备类似情况再次发生。这种现象称为灾难性遗忘 [?, ?]。

最后，[?] 还提到了其他相关领域，如领域自适应、多任务 RL 或元学习，但它们严格来说并非非平稳过程，因此不在本章讨论范围内。我们在 ?? 中更深入地回顾了非平稳性的类型，并在 ?? 中回顾了相关工作。

在延迟的情况下，非平稳性出现在回合内部，且相同的非平稳性在不同回合间重复出现。此外，由于未观测动作序列在每个步骤缓慢演化，非平稳性可能是平滑的。因此，我们将专注于具有平滑非平稳性的终身学习设定。这些假设并不局限，因为这种设定非常常见。考虑金融交易，其中非平稳性显而易见，且智能体当然无法重启环境。此外，正如我们已经提到的，延迟在金融中无处不在，并且如我们将在实验中看到的，交易是一个有趣的延迟基准测试。

为了解决终身学习问题，我们采用基于参数的方法 (??)；一个超策略选择在时间 t 查询的策略。这使我们能够将问题分解为：首先在超策略层面学习非平稳性的动态，其次在策略层面学习动作选择的规则。这一方案对于延迟的应用很有意义，因为策略仅依赖于最后观测状态，因此属于马尔可夫策略集合 (如 [?, Theorem 5.1] 所定义的)，其中可以找到最优策略。我们训练该超策略以优化未来回报，该回报通过基于过去数据的 multiple importance sampling (MIS) 估计 (??)。在 ?? 中提供了该估计器偏差的分析。正如我们后面将看到的，直接优化该目标可能是有害的。因此，它增加了两个额外项。首先，增加了过去性能的估计。虽然优化过去性能显然不是最终目的，但这一项确保超策略记住在先前样本上学习到的行为，从而缓解灾难性遗忘。最后，为了防止过拟合，增加了对超策略过度非平稳性的惩罚。高度非平稳的超策略很可能无法在未来很好地泛化。因此，由于更非平稳的超策略会增加 MIS 估计器的方差，我们添加了对方差的惩罚。为了避免估计方差（这将给目标函数增加更多不确定性），我们推导了其可微上界 (??)。该上界涉及过去和未来超策略之间的散度。我们提出该目标的策略梯度优化方法，命名为 POLIS，即通过重要性采样进行终身学习中的策略优化 (??)。

在一般终身学习情况下推导出 POLIS 之后，我们聚焦延迟问题并在 ?? 中解释其如何应用于 Δ MDP。

为总结本章，我们在 ?? 中提供了 POLIS 在无延迟和延迟任务上的实验评估。这些实验展示了 POLIS 学习底层非平稳过程的能力，并利用该能力在未来获得更高回报，包括当非平稳性由延迟引起时的情况。

6.2 非平稳强化学习

本节中，我们形式化非平稳性的概念。然后介绍处理非平稳性的相关方法，特别是在终身学习的背景下。

6.2.1 强化学习中的非平稳性

非平稳性的性质

在 RL 中，定义过程的五个 MDP 元素中有四个可能引发非平稳性。显然，奖励函数和转移函数可能依赖于时间。更偶尔地，状态空间或动作空间本身也可能随时间变化。另一个区别在于非平稳性存在于回合之间还是可能发生在回合内部。

我们将前者称为 **回合间非平稳性**。它可以被视为一组任务，每个回合从中选择一个任务。我们将第二种类型称为 **回合内非平稳性**。在这种情况下，任务的概念不太清晰，因为 MDP 的动态可能在每个决策步骤发生变化。因此，对过去数据的估计和分析必须更加谨慎。最后，通常认为非平稳性可以是 **平滑的**（当动态随时间具有一定规律性演化时），也可以是 **突变的**（当动态通常变化较少但行为转变更明显时）。

关于延迟引发的非平稳性这一特殊情况，由于上述无记忆方法导致的部分可观测性，转移动态和奖励将成为非平稳性的来源。当然，状态空间和动作空间将保持平稳。非平稳性本质上是回合内的，因为动态将依赖于增广状态内部未观测的动作缓冲区。最后，非平稳性将是平滑的，因为增广状态的动作缓冲区与后续增广状态共享许多动作。注意，由于过程被划分为离散时间步，即使平滑的非平稳性在时间步之间也可以被视为突变的。我们将在 ?? 中更形式化地定义离散过程的平滑性。

非平稳性的驱动因素

上一节中提到的非平稳性可能有不同原因。我们按照 [?] 的分类法介绍其中三种。

多任务设定. 可以说是非平稳 RL 文献中最常见的设定，该设定考虑一组 $(\mathcal{M}_i)_{i \in \mathbb{N}}$ 的平稳 MDPs（或任务），其中环境可能在学习和测试阶段定期从一个任务切换到另一个任务。

被动非平稳性. 该设定考虑一种与智能体动作无关的非平稳性。

主动非平稳性. 与上一设定不同，在此智能体可能影响环境的非平稳性。

延迟引发主动非平稳性，因为正是智能体选择了重放缓冲区中的动作，而忽略这些动作所导致的局部知识引起了非平稳性。

终身学习的形式化

在本小节中，我们形式化我们将关注的终身 RL 框架。它基于一个非平稳 MDP $\mathcal{M}$ ，具有转移函数 $(p_t)_{t \in \mathbb{N}}$ 和奖励函数 $(R_t)_{t \in \mathbb{N}}$ ，期望值为 $(r_t)_{t \in \mathbb{N}}$ 。这些函数定义了每个决策步骤 $t \in \mathbb{N}$ 的转移和奖励。我们假设对任意 $t \in \mathbb{N}$ 有 $\|r_t\|_\infty \leq R_{\max} < \infty$ ，并考虑折扣因子 $\gamma \in [0, 1]$ 。然后定义一个非平稳策略 $\pi = (\pi_t)_{t \in \mathbb{N}}$ ，它定义了智能体在每个决策步骤 $t \in \mathbb{N}$ 遵循的策略。

终身 RL 的目标与传统 RL 不同，因为底层过程无法重新初始化。环境一次性初始化，智能体无法收集超过一条轨迹的经验。例如，考虑交易问题，显然完全相同的市场条件永远不会重复出现两次。没有准确的市场模拟器，智能体无法回到过去尝试另一种策略。相反，传统 RL 的一个例子是国际象棋。智能体可以多次对弈，总是从相同的初始状态分布开始，因此可以收集关于相似环境条件的更多信息。在终身 RL 中，期望未来回报因此依赖于智能体的当前状态。这引出了以下称为 β 步前视期望回报的目标。令 $T \in \mathbb{N}$ 为当前时间， $\beta \in \mathbb{N}$ ， β 步前视期望回报 定义为：

$$J_{T,\beta}(\pi) = \sum_{t=T+1}^{T+\beta} \hat{\gamma}_t^\pi \mathbb{E}_t^\pi[r_t(s_t, a_t)], \quad (6.1)$$

其中 $\hat{\gamma}_t^\pi = \gamma^{t-T-1}$ ， $\mathbb{E}_t^\pi$ 是在非平稳策略 π 诱导的状态-动作分布下经过 t 步后的期望。为简化符号，后续我们将从符号中移除奖励对 (s_t, a_t) 的依赖。

最后，如同经典 MDPs，我们说策略 π^* 在时间 T 是 β 步前视最优的，如果

$$\pi^* \in \arg \max_{\pi \in \Pi^{\text{HR}}} J_{T,\beta}(\pi),$$

其中 Π^{HR} 是如 ?? 中定义的非平稳策略集合。

我们可以进行类比，说经典 RL 的目标是最大化 $J_{0,H}$ ，其中 H 是（可能无限的）视界。然而，在这种情况下，智能体可以多次重启过程以收集同一过程的不同回合。相反，终身学习智能体关注的是在经历了单条轨迹的恰好 T 次转移后最大化 $J_{T,\infty}$ 。

6.2.2 非平稳强化学习中的相关工作

将 RL 适应非平稳 MDPs 已在文献中得到广泛研究 [?, ?, ?]。为了适应新任务，智能体必须学习整个问题的结构。例如，智能体可以使用函数组合将问题分解为更小的子问题 [?]，或学习环境的低维抽象表示 [?, ?]。另一种相关方法是关注问题中与任务无关的底层动态，而非特定于任务的动态，以学习高效的通用策略。这可以通过构建辅助任务（如奖励预测 [?]) 或逆动态预测 [?] 来实现。

虽然本质上是平稳的，但元 RL 可以适应非平稳过程。元 RL 的解决方案可能很有趣，因为它们利用先前经验高效学习新技能。基本上，将这些算法适应非平稳过程包括将问题重新转化为平稳问题。例如，任务序列可以建模为马尔可夫链 [?]，可以使用任务的经验回放缓冲区使过程“更平稳” [?]（如通常 RL 中所做的 [?]），或者可以学习任务序列的隐变量模型 [?]

先前的工作通常适用于回合间非平稳性。我们现在研究回合内非平稳性问题，其中动态可以在回合内部发生变化，例如在终身 RL 中。在有限视界设定中，经过一些修改，理论 RL 解决方案即使在环境变化时也能提供保证 [?, ?]。在无限视界设定中，即终身学习，可以使用来自随机过程和时间序列文献的不同统计工具。在动态突变变化的假设下，可以使用变化检测 [?, ?]。当假设环境可能在已知数量的平稳动态之间切换时，可以使用隐状态模型来描述任务序列 [?]。如果平稳动态的数量未知，一种解决方案是学习策略的因子化表示 [?]。在提出的解决方案中，策略的第一个因子在所有任务上共享，因此被训练为在迄今观测到的任务分布上表现良好。第二个因子是任务特定的，将策略适应当前任务。凭借这种结构，算法 LPG-FTW 可以快速适应新任务，同时避免灾难性遗忘。更深入的综述可以在 [?]（关于 RL 中的非平稳性）和 [?]（关于终身/持续 RL）中找到。

我们通过更深入地研究一种与我们的 POLIS 算法更相似的方法来结束本综述，突出它们之间的相似性和差异。[?] 采用了相当直接但高效的方法，直接优化未来预测性能。对于给定的策略参数集 $\theta \in \Theta$ ，策略 π_θ 的过去性能通过重要性采样估计。这些过去性能随后被用于回归算法内部，可用于预测未来性能。如果所有这些步骤都是可微的，那么通过梯度上升优化 Θ 上的未来预测性能是可行的。作者提出了两种实用算法，Pro-OLS 和 Pro-WLS，它们分别使用普通最小二乘回归和加权最小二乘来预测性能。后者建立在加权最小二乘回归与加权重要性采样之间的联系之上 [?, ?]，以减少由于重要性采样导致的估计方差，但代价是增加一些偏差。我们现在深入探讨与我们的方法的差异。

设定. 一个主要区别是 [?] 为具有回合间非平稳性的回合制 RL 设计了解决方案。我们考虑的是一个真正的终身学习框架，具有回合内非平稳性。

目标. 我们也使用重要性采样来估计未来性能，尽管我们的目标有很大不同。我们增加了一个新的折扣参数来控制由于非平稳性导致的偏差，并且我们在目标中增加了另外两项：过去性能的估计量和方差正则化项。

6.3. 面向延迟的基于参数非平稳策略优化




Figure 6.1: 表示将参数 PO 应用于环境非平稳性的两种框架的图形模型。左图：在策略参数层面处理非平稳性；右图：在动作层面处理非平稳性。

随时性. 我们的方法可以在终身回合中的任何时间重新训练。如果检测到动态的重大变化，我们的策略优化可以立即应用以适应该新动态。当非平稳性从过去高度可预测时，算法也可以减少更新频率。这使得我们的算法成为一种随时算法。相比之下，[?] 的方法可以在回合之间训练策略，但在回合内部保持策略不变。

基于参数. 与 [?] 的基于动作的策略优化设定相比，我们考虑基于参数的策略优化设定。

6.3 面向延迟的基于参数非平稳策略优化

6.3.1 终身基于参数策略优化

本节中，我们基于参数 PO，考虑 $\mathcal{V}_{\rho} = \{\nu_{\rho} : \rho \in \mathcal{P} \subseteq \mathbb{R}^{n_{\rho}}\}$ 中的超策略和 $\Pi_{\theta} = \{\pi_{\theta} : \theta \in \Theta \subseteq \mathbb{R}^{n_{\theta}}\}$ 中的策略。为了优化 ?? 中的 β 步前视期望回报，策略必须是非平稳的。这可以通过两种方式利用参数 PO 框架实现。第一种方式，状态 s 增广当前时间 t ，得到策略 $a_t \sim \pi_{\theta}(\cdot|(s, t))$ 。这一表述清晰展示了动作对时间的依赖。第二种方式，对时间的依赖转移到超策略层面，因此策略的参数依赖于时间 $\theta_t \sim \nu_{\rho}(\cdot|t)$ 。这可以说提供了对智能体如何适应非平稳性的更好理解。两种框架的图形表示见 ??。我们将此设定称为 终身基于参数 PO。

β 步前视期望回报可以针对参数 PO 重新表述为：

$$\rho_{T,\beta}^* \in \arg \max_{\rho \in \mathcal{P}} J_{T,\beta}(\rho) = \sum_{t=T+1}^{T+\beta} \hat{\gamma}_t^{\rho} \mathbb{E}_t^{\rho}[r_t], \quad (6.2)$$

其中 $\mathbb{E}_t^{\rho} := \mathbb{E}_{\theta \sim \nu_{\rho}(\cdot|t)}[\mathbb{E}_t^{\pi_{\theta}}[\cdot]]$ 。

6.3.2 通过多重重要性采样的终身基于参数 PO

现在我们提出一种优化 β 步前视期望回报的方法。在 ?? 中，我们推导该量的估计量。在 ?? 中，我们分析估计量的偏差，在 ?? 中分析其方差。最后，在 ?? 中，我们提出一个替代目标，考虑估计的不确定性，以优化 $J_{T,\beta}(\rho)$ 的下界。

β 步前视期望回报估计量

显然，这里的挑战在于估计一个依赖于未来未知动态的量，而我们只能访问过去（动态可能不同）的样本。然而，假设非平稳性是平滑的（我们在此做出这一假设），使得利用过去动态预测未来动态变得合理。更形式化地，令

$\mathcal{H}_{T,\alpha} = (\boldsymbol{\theta}_t, r_t)_{t \in [T-\alpha+1, T]}$ 为与环境的终身交互中最后 α 个样本。利用这些样本和 MIS，可以构建对 $s \in [T+1, T+\beta]$ 的 s 步前视期望奖励 $\mathbb{E}_s^\rho[r_s]$ 的（有偏）估计量：

$$\hat{r}_s = \sum_{t=T-\alpha+1}^T \omega^{T-t} \frac{\nu_\rho(\boldsymbol{\theta}_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_\rho(\boldsymbol{\theta}_k|k)} r_t,$$

其中 $\omega \in [0, 1]$ 是指数折扣参数。注意，此处重要性采样权重 $\frac{\nu_\rho(\boldsymbol{\theta}_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_\rho(\boldsymbol{\theta}_k|k)}$ 解释了未来目标超策略 $\nu_\rho(\cdot|s)$ 与过去行为超策略 $\nu_\rho(\cdot|k)$ 之间的差异。由于 ω 折扣，MIS 估计量并未精确使用 BH 建议的系数（见 ??）。相反，它通过给近期样本更高权重来体现我们对环境平滑变化的认识。BH 则会对每个过去样本赋予相同权重。在非平稳环境中，对较旧样本进行指数折扣并非新方法 [?]。

现在可以利用估计量 $\hat{r}_s$ 来估计 β 步前视期望回报，

$$\begin{aligned} \hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) &= \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \hat{r}_s \\ &= \sum_{t=T-\alpha+1}^T \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\boldsymbol{\theta}_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_\rho(\boldsymbol{\theta}_k|k)} r_t. \end{aligned}$$

该量可以直接最大化；然而，这会受到 IS 估计量的一个常见缺点的影响，我们将在下文解释。要增加 $\hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho})$ ，可以增加未来选择好策略的概率 $\nu_\rho(\boldsymbol{\theta}_t|s)$ ($\hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho})$ 的分子)，或者降低过去选择同样好策略的概率 $\nu_\rho(\boldsymbol{\theta}_t|k)$ ($\hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho})$ 的分母)。虽然第一个效果是期望的，第二个显然不是，并且相当于灾难性遗忘。然而，可以通过简单调整来防止这种现象。通过将最后 α 个奖励添加到目标函数中，智能体将避免降低过去好策略的概率。这个添加的量，我们称为 α 步后视期望回报，表示为：

$$\check{J}_{T,\alpha}(\boldsymbol{\rho}) = \frac{1}{C_\omega(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} \check{\gamma}^t r_t,$$

其中 $\check{\gamma}^t = \check{\gamma}^{t-T+\alpha-1}$ ，并且我们定义了对于 $\xi \geq 1$ 和 $\tau \in [0, 1]$

$$C_\tau(\xi) = \begin{cases} \frac{1-\tau^\xi}{1-\tau} & \text{if } \tau < 1 \\ \xi & \text{otherwise.} \end{cases} \quad (6.3)$$

新目标因此变为，

$$\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) = \hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) + \check{J}_{T,\alpha}(\boldsymbol{\rho}). \quad (6.4)$$

偏差分析

由于非平稳性，估计量 $\hat{J}_{T,\alpha,\beta}(\boldsymbol{\rho})$ 很可能有偏。然而，我们设计它适用于平滑演化的动态。下文我们形式化“平滑”的含义，并分析这些条件下估计量的偏差。

Assumption 6.3.1 (平滑非平稳环境). 对于任意 $t, t' \in \mathbb{N}$ ，以及任意策略 π ，存在 Lipschitz 常数 $0 \leq L_{\mathcal{M}} < \infty$ 使得：

$$|(\mathbb{E}_t^\pi - \mathbb{E}_{t'}^\pi)[r]| \leq L_{\mathcal{M}}|t - t'|.$$

6.3. 面向延迟的基于参数非平稳策略优化

Assumption 6.3.2 (平滑非平稳超策略). 对于任意 $t, t' \in \mathbb{N}$, 以及任意时间相关超策略 $\rho \in \mathcal{P}$, 存在 Lipschitz 常数 $0 \leq L_\nu < \infty$ 使得:

$$\|\nu_\rho(\cdot|t) - \nu_\rho(\cdot|t')\|_1 \leq L_\nu |t - t'|.$$

?? 确保在两种不同时间执行相同策略所收集的期望奖励的差异受时间差的比例约束。类似地, ?? 确保两种不同时间超策略的概率分布在总变差距离上受时间差的比例约束。关于平滑非平稳动态的假设以简化最坏情况分析在文献中并不新鲜 [?]. 利用这些假设, 可以推导出偏差的以下界。为简洁起见, 我们用 $\mathbb{E}_{T,\alpha}^\rho$ 表示由时间 $T - \alpha + 1$ 到 T 的超策略诱导的联合概率分布下的期望, 即,

$$\prod_{t=T-\alpha+1}^T \nu_\rho(\cdot|t). \quad (6.5)$$

Lemma 6.3.1. 在 ?? 和 ?? 以及 $\omega < 1$ 条件下, 估计量 $\hat{J}_{T,\alpha,\beta}(\rho)$ 的偏差可以界为:

$$\left| J_{T,\beta}(\rho) - \mathbb{E}_{T,\alpha}^\rho[\hat{J}_{T,\alpha,\beta}] \right| \leq (L_{\mathcal{M}} + 2R_{\max}L_\nu)C_\gamma(\beta) \left(\frac{\omega}{1-\omega} + \frac{1}{1-\gamma} \right),$$

其中 $C_\gamma(\beta)$ 定义如 ??。

Proof. ?? 提供了一个更紧的偏差界, 在 $\omega = 1$ 情况下也成立, 但更复杂。由此引理, 我们知道,

$$\begin{aligned} & \left| J_{T,\beta}(\rho) - \mathbb{E}_{T,\alpha}^\rho[\hat{J}_{T,\alpha,\beta}] \right| \\ & \leq (L_{\mathcal{M}} + 2R_{\max}L_\nu) C_\gamma(\beta) \left(\omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^\alpha}{(1-\omega)(1-\omega^\alpha)} + \frac{1}{1-\gamma} \right). \end{aligned}$$

利用此界, 结果由以下观察得到:

$$\frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^\alpha}{(1-\omega)(1-\omega^\alpha)} \leq \frac{1}{1-\omega}.$$

□

关于这一结果可以观察到两点。首先, 可以看到 ω 如何控制偏差: 更小的 ω 产生更小的偏差。其次, 当 Lipschitz 常数趋近于零时, 该界收缩为零。这意味着当环境和超策略都是平稳的 (即 $L_{\mathcal{M}} = L_\nu = 0$) 时, 估计量是无偏的。

方差分析

我们不想直接使用 ?? 作为目标, 而是考虑该量的统计下界。其背后的思想是防止使用高度非平稳的超策略过拟合过去的动态。因此, 带着这一思想, 我们推导 $\bar{J}_{T,\alpha,\beta}(\rho)$ 方差的一个界。我们用 $\text{Var}_{T,\alpha}^\rho$ 表示在 ?? 给出的时间 $T - \alpha + 1$ 到 T 超策略诱导的联合概率分布下的方差。

Lemma 6.3.2. $\bar{J}_{T,\alpha,\beta}$ 的方差可以界为：

$$\begin{aligned} \mathbb{V}\text{ar}_{T,\alpha}^{\rho} [\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})] &\leq 2R_{\max}^2 \left(C_{\gamma}(\alpha)^2 \right. \\ &\quad \left. + C_{\gamma}(\beta)^2 D_R^{\exp} \left(\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{C_{\gamma}(\beta)} \nu_{\boldsymbol{\rho}}(\cdot|s) \left\| \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \nu_{\boldsymbol{\rho}}(\cdot|t) \right\| \right) \right). \end{aligned}$$

Proof. 回忆符号 $\hat{\gamma}^t = \gamma^{t-T-1}$, $\check{\gamma}^t = \gamma^{t-T+\alpha-1}$ 。首先，利用任意随机变量 X 和 Y 有 $\mathbb{V}\text{ar}[X + Y] \leq 2\mathbb{V}\text{ar}[X] + 2\mathbb{V}\text{ar}[Y]$ 的事实，得到，

$$\mathbb{V}\text{ar}_{T,\alpha}^{\rho} [\bar{J}_{T,\alpha,\beta}] \leq \underbrace{2\mathbb{V}\text{ar}_{T,\alpha}^{\rho} [\check{J}_{T,\alpha}]}_A + \underbrace{2\mathbb{V}\text{ar}_{T,\alpha}^{\rho} [\hat{J}_{T,\alpha,\beta}]}_B,$$

然后，我们上界项 A ：

$$\begin{aligned} A &= \mathbb{V}\text{ar}_{T,\alpha}^{\rho} \left[\frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} \check{\gamma}^t r_t \right] \\ &\leq \mathbb{E}_{T,\alpha}^{\rho} \left[\left(\frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} \check{\gamma}^t r_t \right)^2 \right] \\ &\leq R_{\max} \left(\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \check{\gamma}^t \right)^2 \\ &\leq R_{\max} \left(\sum_{t=T-\alpha+1}^T \check{\gamma}^t \right)^2 \\ &= R_{\max} \left(\underbrace{\frac{1 - \gamma^{\alpha}}{1 - \gamma}}_{C_{\gamma}(\alpha)} \right)^2, \end{aligned}$$

其中我们利用了 $\frac{\omega^{T-t}}{C_\omega(\alpha)} \leq 1$ 。转到第二项 B ,

$$\begin{aligned}
 B &= \mathbb{V}\text{ar}_{T,\alpha}^\rho \left[\sum_{t=T-\alpha+1}^T \omega^{T-t} r_t \frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\boldsymbol{\theta}_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\boldsymbol{\theta}_t|k)} \right] \\
 &\leq R_{\max} \mathbb{E}_{T,\alpha}^\rho \left[\left(\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_\omega(\alpha)} \frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\boldsymbol{\theta}_t|s)}{\frac{1}{C_\omega(\alpha)} \sum_{k=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\boldsymbol{\theta}_t|k)} \right)^2 \right] \\
 &\leq R_{\max} \mathbb{E}_{T,\alpha}^\rho \left[\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_\omega(\alpha)} \left(\frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\boldsymbol{\theta}_t|s)}{\frac{1}{C_\omega(\alpha)} \sum_{k=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\boldsymbol{\theta}_t|k)} \right)^2 \right] \quad (6.6) \\
 &= C_\gamma(\beta)^2 R_{\max} \\
 &\quad \cdot \mathbb{E}_{T,\alpha}^\rho \left[\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_\omega(\alpha)} \left(\underbrace{\frac{\frac{1}{C_\gamma(\beta)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\boldsymbol{\theta}_t|s)}{\frac{1}{C_\omega(\alpha)} \sum_{k=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\boldsymbol{\theta}_t|k)}}_{\ell(\boldsymbol{\theta}_t)} \right)^2 \right],
 \end{aligned}$$

其中在行 (??) 中我们对求和应用了 Cauchy-Schwarz 不等式。上述期望 $\mathbb{E}_{T,\alpha}^\rho$ 在以下分布下计算：

$$D_0(s_0) \prod_{l=1}^T P_t(s_{l+1}|s_l, \pi_{\boldsymbol{\theta}_l}(s_l)) \nu_\rho(\boldsymbol{\theta}_l|l).$$

因此,

$$\begin{aligned}
 \mathbb{E}_{T,\alpha}^\rho [\ell(\boldsymbol{\theta}_t)^2] &= \int_{s_0} \int_{\boldsymbol{\theta}_0} \dots \int_{s_T} \int_{\boldsymbol{\theta}_T} D_0(s_0) \\
 &\quad \cdot \prod_{l=1}^T P_t(s_{l+1}|s_l, \pi_{\boldsymbol{\theta}_l}(s_l)) \nu_\rho(\boldsymbol{\theta}_l|l) \ell(\boldsymbol{\theta}_t)^2 ds_0 d\boldsymbol{\theta}_0 \dots ds_T d\boldsymbol{\theta}_T \\
 &= \int_{\boldsymbol{\theta}_t} \nu_\rho(\boldsymbol{\theta}_t|t) \ell(\boldsymbol{\theta}_t)^2 d\boldsymbol{\theta}_t,
 \end{aligned}$$

因为 θ_t 独立于其他参数 $(\theta_l)_{0 \leq l < t}$ 。因此，有：

$$\begin{aligned} \mathbb{E}_{T,\alpha}^{\rho} \left[\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \ell(\theta_t)^2 \right] &= \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \int_{\theta_t} \nu_{\rho}(\theta_t|t) \ell(\theta_t)^2 d\theta_t \\ &= \int_{\theta} \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \nu_{\rho}(\theta|t) \ell(\theta)^2 d\theta \end{aligned} \quad (6.7)$$

$$\begin{aligned} &= \int_{\theta} \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \nu_{\rho}(\theta|t) \\ &\quad \cdot \left(\frac{\frac{1}{C_{\gamma}(\beta)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_{\rho}(\theta|s)}{\frac{1}{C_{\omega}(\alpha)} \sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} \right)^2 d\theta, \end{aligned} \quad (6.8)$$

其中 ?? 利用了 θ_t 是哑变量的事实。结果通过观察到最后一个表达式对应于指数 2-Rényi 散度并合并项 A 和 B 得到。□

该界让人联想到离策略估计和学习中方差界的文献 [?, ?, ?]。与括号内和的第一项相关的量对应 $\hat{J}_{T,\alpha}(\rho)$ 的方差。和的第二项是 $\hat{J}_{T,\alpha,\beta}(\rho)$ 方差的一个界。由于该估计量涉及重要性采样，指数 2-Rényi 散度自然出现。该界的缺点是，即使对于超策略的便捷分布（如正态分布），这些分布的混合之间的 Rényi 散度也没有闭式解 [?]。然而，我们在 ?? 中讨论了分布混合之间的 Rényi 散度的几个上界。我们在以下结果中利用其中一个上界。

Lemma 6.3.3. ?? 中混合之间的散度可以界为：

$$\begin{aligned} D_R^{\exp} \left(\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{C_{\gamma}(\beta)} \nu_{\rho}(\cdot|s) \parallel \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_{\omega}(\alpha)} \nu_{\rho}(\cdot|t) \right) \\ \leq \frac{C_{\omega}(\alpha)}{C_{\gamma}(\beta)^2} \underbrace{\left(\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{\left(\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{D_R^{\exp}(\nu_{\rho}(\cdot|s) \parallel \nu_{\rho}(\cdot|t))} \right)^{\frac{1}{2}}} \right)^2}_{B_{T,\alpha,\beta}(\rho)}. \end{aligned}$$

Proof. 在 ?? 中，我们展示了对于两个分布混合 $\Psi = \sum_{i=1}^L \zeta_i P_i$ 和 $\Phi = \sum_{j=1}^K \mu_j Q_j$ ，其中 $\forall i \in [1, L], j \in [1, K], 0 < \zeta_i, \mu_j < 1, \sum_{i=1}^L \zeta_i = \sum_{j=1}^K \mu_j = 1$ 且 $\alpha \geq 1$,

$$\begin{aligned} D_{R,\alpha}^{\exp}(\Psi \parallel \Phi) &\leq \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \parallel \Psi)^{\frac{\alpha-1}{\alpha}} \right)^{\frac{\alpha}{\alpha-1}} \\ &\leq \left(\sum_{i=1}^L \zeta_i \frac{1}{\left(\sum_{j=1}^K \frac{\mu_j}{D_{R,\alpha}^{\exp}(P_i \parallel Q_j)} \right)^{\frac{\alpha-1}{\alpha}}} \right)^{\frac{\alpha}{\alpha-1}}. \end{aligned}$$

6.3. 面向延迟的基于参数非平稳策略优化

因此, 当前结果通过将 ?? 应用于我们的界, 其中 $\zeta_i = \frac{\hat{\gamma}^i}{C_\gamma(\beta)}$, $\mu_j = \frac{\omega^{T-j}}{C_\omega(\alpha)}$, $\alpha = 2$, 并将求和从 $i \in [1, \dots, L]$ 改为 $i \in [T+1, \dots, T+\beta]$, 从 $j \in [1, \dots, K]$ 改为 $j \in [T-\alpha+1, \dots, T]$ 直接得到。□

为方便起见, 我们在前述引理中定义了量 $B_{T,\alpha,\beta}(\boldsymbol{\rho})$ 。这个上界在实践中是可微的, 为我们提供了一种有效控制估计量方差同时避免估计方差的方法。我们现在准备推导替代目标。

替代目标

我们使用 Cantelli 不等式和 ?? 来得到关注量的以下概率下界。该下界随后将成为我们的替代目标, 遵循 [?] 的不确定性规避方法。

Theorem 6.3.1. 对于 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 有:

$$\mathbb{E}_{T,\alpha}^\rho [\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})] \geq \bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) - \sqrt{\frac{1-\delta}{\delta} 2R_{\max}^2 (C_\gamma(\alpha)^2 + C_\omega(\alpha)B_{T,\alpha,\beta}(\boldsymbol{\rho}))}.$$

Proof. 与 [?] 类似, 我们将 Cantelli 不等式应用于随机变量 $\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})$,

$$\mathbb{P}(\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) - \mathbb{E}[\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})] \geq \lambda) \leq \frac{1}{1 + \frac{\lambda^2}{\text{Var}[\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})]}}.$$

令 $\delta := \frac{1}{1 + \frac{\lambda^2}{\text{Var}[\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})]}}$ 并考虑补事件, 得到以至少 $1 - \delta$ 的概率,

$$\mathbb{E}[\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})] \geq \bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) - \sqrt{\frac{1-\delta}{\delta} \text{Var}_T^\rho [\bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho})]}.$$

接下来, 我们将方差替换为 ?? 中的上界, 并将后者界中的混合之间的 Rényi 散度替换为 ?? 中的变分上界。由此得到结果。□

基于前述结果, 我们定义替代目标, 其中将 $\lambda = \sqrt{\frac{1-\delta}{\delta} 2R_{\max}^2}$ 设置为新的超参数:

$$\mathcal{L}_\lambda(\boldsymbol{\rho}) = \bar{J}_{T,\alpha,\beta}(\boldsymbol{\rho}) - \lambda \sqrt{C_\gamma(\alpha)^2 + C_\omega(\alpha)B_{T,\alpha,\beta}(\boldsymbol{\rho})}. \quad (6.9)$$

该目标可以通过策略梯度方法优化, 得到我们命名为 POLIS 的算法, 即通过重要性采样进行终身学习中的策略优化 (Policy Optimisation in Lifelong learning through Importance Sampling)。我们在 ?? 中提供其伪代码。为完整起见, 我们

Algorithm 4 使用 POLIS 的终身学习

输入: 后视步数 α , 前视步数 β , 正则化 λ , 折扣因子 ω , 训练周期 T_{train} , 训练轮数 N ,

```

1: 初始化  $\nu_\rho$ ,  $t \leftarrow 0$ 
2: while True do
3:   从  $\nu_\rho(t)$  采样  $\theta_t$ 
4:   使用  $\pi_{\theta_t}$  收集新状态  $s_t$  和奖励  $r_t$ 
5:   if  $t \bmod h = 0$  且  $t > 1$  then
6:     for  $i \in \{1, \dots, N\}$  do
7:       计算  $\hat{J}_{t,\alpha}(\rho)$ ,  $\bar{J}_{t,\alpha,\beta}(\rho)$  和  $B_{t,\alpha,\beta}(\rho)$ 
8:        $\rho \leftarrow \arg \max_{\rho} \mathcal{L}_\lambda(\rho)$ 
9:     end for
10:  end if
11:   $t \leftarrow t + 1$ 
12: end while
    
```

使用类似于 PGT [?] 的推导, 推导 β 步前视期望回报的梯度 (另见 ??):

$$\begin{aligned}
 \nabla_{\rho} \hat{J}_{T,\alpha,\beta}(\nu_{\rho}) &= \nabla_{\rho} \mathbb{E}_{T,\alpha}^{\rho} \left[\sum_{t=T-\alpha+1}^T r_t \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} \right] \\
 &= \sum_{t=T-\alpha+1}^T \nabla_{\rho} \int_{\Theta} \mathbb{E}_t^{\pi_{\theta}}[r] \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} \nu_{\rho}(\theta|t) d\theta \\
 &= \sum_{t=T-\alpha+1}^T \int_{\Theta} \mathbb{E}_t^{\pi_{\theta}}[r] \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta|s)}{\sum_{k=T-\alpha+1}^T \nu_{\rho}(\theta|k)} \nu_{\rho}(\theta|t) \\
 &\quad \nabla_{\rho} \log \left(\frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} \nu_{\rho}(\theta|t) \right) d\theta \\
 &= \mathbb{E}_{T,\alpha}^{\rho} \left[\sum_{t=T-\alpha+1}^T r_t \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta_t|k)} \right. \\
 &\quad \left. \nabla_{\rho} \log \left(\frac{\sum_{s=T+1}^{T+\beta} \nu_{\rho}(\theta_t|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta_t|k)} \nu_{\rho}(\theta_t|t) \right) \right]
 \end{aligned}$$

6.3.3 对延迟的适应

当环境在状态观测或动作执行上延迟 Δ 步时, POLIS 可以稍作调整以考虑其引起的偏移。在原始设定中, 由 ν_{ρ} 在时间 t 采样的策略将选择一个动作 a_t , 该动作将影响状态 $s_{t+\Delta}$ 。因此, 我们提议修改估计量, 将奖励回移至实际产生该奖励的策略参数。这与 dSARSA 的思想类似 [?]。实现这一偏移后, β 步前视期望回报变为:

$$\hat{J}_{T,\alpha,\beta}(\rho) = \sum_{t=T-\alpha+1+\Delta}^T \omega^{T-t} \frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_{\rho}(\theta_{t-\Delta}|s)}{\sum_{k=T-\alpha+1+\Delta}^T \omega^{T-k} \nu_{\rho}(\theta_{t-\Delta}|k)} r_t.$$

如我们所见，对于固定的 α ，延迟减少了可用于 MIS 估计量的数据量。 α 步后视期望回报也可以相应调整：

$$\check{J}_{T,\alpha}(\rho) = \frac{1}{C_\omega(\alpha - \Delta)} \sum_{t=T-\alpha+1-\Delta}^T \omega^{T-t} \check{\gamma}^t r_t.$$

使用这些定义并将替代目标中的 α 替换为 $\alpha - \Delta$ ，得到了适用于 Δ 延迟 Δ MDP 的目标。

6.4 实验评估

本节中，我们将在一组终身 RL 任务中测试 POLIS 与不同基线方法的性能。第一组实验将考虑无延迟的非平稳环境，以评估算法面对动态变化的能力。然后，第二组实验将考虑在先前任务中添加延迟，以评估 POLIS 对延迟的鲁棒性。在本节中，我们将对我们关注的终身 RL 中 MDPs 的特定情况做一个假设。该假设是智能体无法通过其动作影响状态的一部分，且只有这部分状态可以是非平稳的。例如，这在金融数学中是简化分析的常见假设。通常假设仅交易小规模投资头寸不会影响市场动态。这大大简化了实验设置，并允许更清晰地评估我们的算法面对可观测非平稳性的能力。该假设正式表述如下。

Assumption 6.4.1. 转移模型 $P = (P_t)_{t \in \mathbb{N}}$ 分解如下，对于任意 $x = (x^c, x^u) \in \mathcal{S}$ ， $a \in \mathcal{A}$ ，和 $t \in \mathbb{N}$ ：

$$P_t(x'|x, a) = P^c(x'^c|x^c, x^u, a)P_t^u(x'^u|x^u). \quad (6.10)$$

除该假设外，在下面考虑的任务中， P^c 是确定性的。这使得我们可以通过使用新策略采样状态的可控部分来获得 α 步后视期望回报的值，同时状态的非平稳部分 x^u 保持不变。因此，我们可以获得 α 步后视期望回报梯度的精确值，而不需要重要性采样。

接下来，我们在 ?? 中描述实验设置，然后在 ?? 中提供结果。

6.4.1 设置

任务

首先，我们描述终身学习的一般背景。与环境的终身交互时间表可以分为两个阶段。在第一个阶段，我们称为 行为阶段，行为超策略从环境中采样数据。这是收集足够数据以计算替代目标中使用的第一个 α 步后视期望回报所必需的。然后，在第二个阶段，智能体从行为超策略停止的位置继续与环境交互。然而，它现在可以定期重新训练其超策略。在实践中，我们在所有测试环境中每 50 步重新训练一次。每次进行 100 步梯度更新。我们将此阶段称为 目标阶段。对于所有任务，我们设置 $\gamma = \omega = 1$ 。

无延迟 EUR-USD 交易. 第一个任务类似于 ?? 中的交易任务。它也考虑在外汇市场上交易 EUR-USD (€/ \$) 货币对，但这次是基于日数据。智能体可以选择 $[-1, 1]$ 中的连续动作；1 和 -1 对应以最大订单规模 10 万美元买入或卖出，而动作 0 对应保持空仓。在 ?? 下，我们假设最大订单规模相对于可用市场流动性很小，因此对市场动态没有影响。智能体观测到的状态由其当前投资组合 (x_t^c) 组成，即其先前动作的价值和当前货币汇率 (x_t^u) 。我们将历史数据分为三个数据集：2009-2012、2013-2016 和 2017-2020；每个时期有略多于 1000 个数据

点。各时期的历史利率见 ??。奖励定义为 $r_t = a_t(x_{t+1}^u - x_t^u) - f|a_t - x_t^c|$ ，其中 f 是费用，相当于投资规模的 $1e-3\%$ 。我们设置 α 为 500，同时考虑 500 步的目标阶段。需要注意的是，由于终身学习框架中训练和测试之间没有明确区分，选择超参数（指 POLIS 参数，而非超策略）可能很复杂。通过在目标阶段评估性能来选择最佳超参数是危险的，因为如果目标阶段被延长，显然会过拟合并泛化不良。为了研究这个问题，我们对此任务比较两种超参数选择方案。对于第一种方案，我们在 2009-2012 数据集的目标阶段选择超参数，并在其他两个数据集上评估。在第二种方案中，我们在最后两个数据集的目标阶段同时选择超参数和评估。

无延迟 Vasicek 交易。 由于 EUR-USD 货币对是一种高度复杂的资产，我们考虑交易一种具有更平滑非平稳性的合成利率，以为智能体提供更好的信噪比。我们保留整体交易框架，仅修改汇率 $(x_t^c)_{t \geq 0}$ ，将历史 EUR-USD 利率替换为 Vasicek 过程。框架的其他部分保持不变。所考虑的 Vasicek 过程为 $x_{t+1}^c = 0.9x_t^c + u_t$ ，其中 $u_t \sim \mathcal{N}(0, 1)$ 。

无延迟水坝。 第三个任务考虑水资源管理问题，其中水坝用于控制湖泊水位。湖泊从某些入流（如雨水）获得水，而水坝控制其出流。目标是利用出水满足一定需求（如城镇供水），即使在干旱时期也是如此。这涉及在预期降雨时储水，同时避免洪水。我们使用来自 [?, ?] 的环境模型。考虑三种不同的随机年入流量¹。智能体对它们没有影响，满足 ??。作为状态，智能体观测当前日期的湖泊水位。对 [?, ?] 原始设定的唯一修改是智能体不观测年份中的日期，以确保非平稳性。否则，智能体可以学习将年份中的日期映射到其期望入流，这将使问题回到平稳设定。动作空间是连续的。我们考虑洪水水位 $F = 300$ 和每日需水量 $D = 10$ 。对于某个湖泊水位 x 和某个选择的出流（或动作） a ，未满足需求的惩罚为 $c_D = (\max(a - D, 0))^2$ ，洪水的额外惩罚为 $c_F = (\max(x - F, 0))^2$ 。总成本根据入流情况通过加权这两种成本来组合这些惩罚，详见 ??。为了更好地理解过程动态，我们将 α 设置为 1000，以便估计器使用足够多的过去数据。我们将目标阶段的长度设置为 500 步。关于超参数，在该环境中结果对超参数选择似乎不太敏感，因此我们仅基于第一个入流情况选择超参数。

延迟 Vasicek 交易。 该任务与之前的 Vasicek 交易任务相同，但增加了延迟。我们考虑 Δ 在 $[1, 10]$ 范围内的延迟，以研究延迟增加对回报的影响。如本章所述，在此智能体是无记忆的。看到历史汇率 $x_{t-\Delta}$ 及其在时间 $t - \Delta$ 的投资组合后，智能体选择一笔交易，该交易将以汇率 x_t 执行，并考虑其在时间 t 的当前投资组合。因此，POLIS 学习的策略必须跟踪其投资组合以及过程的非平稳性，以选择其下一笔交易。

延迟水坝。 在该环境中，我们考虑上述水资源管理任务。与延迟 Vasicek 交易一样，我们测试 POLIS 在递增延迟下的表现，以评估其在该环境中的鲁棒性。

基线方法

第一个明显的基线是平稳策略。它可以视为 POLIS 的特例，其中超策略随时间恒定 $\nu_\rho(\cdot|t) = \nu_\rho(\cdot)$ 。为了突出 POLIS 方法的效果，我们考虑这样一个平稳超策略 ν_ρ ，其结构和优化与 POLIS 完全相同，只是去除了方差惩罚和对时间的依赖。但需要注意的是，尽管在重新训练步骤之间是平稳的，但平稳策略的参数也每 50 步重新训练一次，与 POLIS 和其他基线方法相同。在此基线之上，我们还考虑了文献中的几种方法，包括 Pro-OLS 和 Pro-WLS [?]; +、LPG-FTW [?] 和 ONPG（[?] 在其实验中提到的作为 [?] 思想复制的基线方法）。

¹ 其均值在 ?? 中给出




Figure 6.2: 超策略在时间 t 被查询时的图形表示。首先，由于时间卷积具有长度为 b 的感受野，我们将最后 b 个时间追加到 t ，作为馈入位置编码的输入。后者为每个时间输出一个向量 $f(t)$ 。这些向量随后被馈入时间卷积，该卷积返回每个策略参数 θ_k 在时间 k 的均值 μ_k 。其中最后一个就是当前策略参数 θ_t 。

POLIS 的设置

在本小节中，我们更精确地描述 POLIS 内部使用的策略和超策略。我们的超策略由两个模块组成。第一个模块是 [?] 中引入的 位置编码（见 ??）。在这里使用它有两个原因。首先，其输出维度是一个超参数，因此可用于控制下一模块的输入维度。其次，虽然时间索引可以无限增长，但位置编码的输出是有界的。这在将该值馈入 neural network (NN) 时尤其有用。第二个模块 时间卷积 [?] 用于随时间扫描其输入。卷积的一个主要优点是它们通常擅长在序列中发现模式 [?]。另一个优点是它们的通用性，它们接受不同长度的输入，并且可以有效并行化。由于它们的感受野（即卷积支撑集的大小），位置编码层应提供比最后一个时间 t 更多的输入。这可以通过将较旧的时间步与 t 一起作为输入序列来实现。这一修改并不否定超策略仅依赖当前时间 t 的观点。感受野的长度为 $b = 2^{l-1}(k-1)$ ，其中 l 和 k 分别是时间卷积的层数和卷积核大小。作为时间 t 的输出，时间卷积返回正态分布的均值 μ_t ，策略参数 θ_t 从中采样。我们选择将这些正态分布的标准差限制为不依赖于时间，但可以在终身交互过程中每 50 步重新训练或固定不变。超策略的图形表示见 ??。如上所述，时间卷积的一个巨大优势是可以并行采样未来 N 个策略参数 $(\theta_i)_{i \in [t, t+N]}$ ，对于任意 $N > 0$ 。只需将时间 $[t-b, t+N]$ 馈入超策略即可获得这些参数。

最后，在策略层面，我们考虑一个具有有界输出的简单仿射策略。平稳基线方法也是如此。

6.4.2 结果

无延迟 EUR-USD 交易. 我们在 ?? 中报告了随时间累积回报的结果。在上图中，超参数在训练集（2009-2012）上选择。有趣的是，对于 2013-2016 时期，平稳策略取得了最佳性能，而 POLIS 具有非常相似的性能。然而，回顾一下，平稳策略仅是在重新训练步骤之间是平稳的。2017-2020 时期似乎更为复杂，因为没有方法获得正回报。POLIS 的表现低于大多数基线方法，但优于平稳策略。在下图中，超参数在测试集（2013-2016 和 2017-2020 合并）上选择。在这些测试中，POLIS 的性能与其他基线方法更为相似，没有方法明显优于其他方法。

无延迟 Vasicek 交易. 在此任务上，我们测试了为 EUR-USD 交易选择的一组超参数。Vasicek 交易问题的累积回报在 ?? 中报告。POLIS 似乎比基线方法更有效地利用了合成资产提供的更清晰信号。它实现了比基线方法更高的最终回报和更小的方差。特别是，它明显优于平稳策略，后者由于费用而获得了负回




Figure 6.3: 两个测试数据集 2013-2016 (左) 和 2017-2020 (右) 上 EUR-USD 货币对终身交易的累积回报百分比。注意每个数据集仅显示目标阶段。超参数在 2009-2012 期间 (上) 或 2013-2020 期间 (下) 选择。均值和一倍标准差阴影区域基于 3 个随机种子计算。标记对应重新训练步骤的时间。

报。

作为此环境中的额外实验，我们研究了 POLIS 超参数 λ (用于方差惩罚的替代正则化项) 和 β (优化中考虑的前视步数) 的效果。我们考虑 $\lambda \in [1, 100]$ 和 $\beta \in [2, 100]^2$ 。我们感兴趣的是研究 λ 和 β 如何在回报和奖励标准差之间进行权衡。结果报告在 ?? 中，表明较小的 β 通常产生更高的回报，但代价是更高的标准差。 λ 对此权衡的影响不太明显。然而，按照设计，该参数允许控制奖励的标准差。

无延迟水坝。 我们在 ?? 中报告了实验结果。令人惊讶的是，在所有基线方法中，平稳超策略在 3 种入流情况下获得了最佳性能。除平稳策略外，其他基线方法具有较低的回报，并表现出更高标准差的趋势。POLIS 取得了比这些基线方法好得多的回报，包括方差方面，并与平稳策略持平。这表明我们的方法能够在不需要额外非平稳性的任务中避免引入多余的非平稳性。

延迟 Vasicek 交易。 结果在 ?? 中给出。正如预期，随着延迟增长，POLIS 的性能下降。然而，POLIS 对延迟相当鲁棒，即使对于 10 步的较大延迟，也获得了与 ?? 中最佳无延迟基线方法相似的性能。

延迟水坝。 水坝延迟测试的结果在 ?? 中报告。延迟对性能有明确的负面影响。

²对于 $\beta = 1$ ，?? 中 Rényi 散度内的左侧项不再涉及分布的混合，可以按照 [?] 的方式处理。




Figure 6.4: *Vasicek* 过程上终身交易的累积回报百分比。均值和一倍标准差阴影区域基于 10 个随机种子计算。标记对应重新训练步骤的时间。




Figure 6.6: *POLIS* 在 *Vasicek* 过程中的回报 (左) 和奖励标准差 (右) 随 λ 和 β 的变化。

令人惊讶的是，从延迟 1 步到延迟 10 步，性能似乎没有进一步下降。我们还注意到，延迟对方差似乎没有太大影响，除了第二个入流情况。*POLIS* 的性能，即使对于较大的延迟，也与无延迟专家方法的性能相当。

6.5 结论

本章中，我们探索了使用非平稳无记忆策略解决状态观测或动作执行中常值延迟的可能性。确实，无记忆策略由于对增广状态的部分观测，自然会导致动态的非平稳性。值得注意的是，在非平稳和马尔可夫策略空间中存在最优无记忆策略 [?, Theorem 5.1]。

基于这一结果，我们设计了一种能够适应过程回合内非平稳性的方法。受考虑此类场景的终身学习文献启发，我们提出学习一个超策略，它以时间为输入，采样在该时间被查询的策略的参数。为了优化未来性能，我们为其设计了一个估计量，其基础依赖于平滑非平稳性的假设。具体来说，该估计量重用过去样本来估计未来，并随着样本变旧对其进行指数折扣。在平滑条件下，我们证明了

	入流 1	入流 2	入流 3
Pro-OLS	-2.6 ± 0.4	-5.2 ± 5.1	-3.8 ± 0.7
Pro-WLS	-5.5 ± 4.3	-8.5 ± 9.7	-8.4 ± 4.2
ONPG	-5.1 ± 3.2	-1.4 ± 0.2	-4.1 ± 0.5
LPG-FTW	-2.3 ± 0.3	-11.9 ± 8.6	-4.7 ± 1.9
Stationary	-2.2 ± 0.1	-1.5 ± 0.0	-3.2 ± 0.2
POLIS	-2.2 ± 0.2	-1.5 ± 0.0	-3.2 ± 0.2

Table 6.1: 3 种入流情况下水坝环境中的终身学习。目标阶段的平均回报和基于 3 个随机种子的标准差。为美观起见，报告的结果除以 $1e3$ 量级。




Figure 6.7: 在 *Vasicek* 交易环境中以递增延迟运行 *POLIS* 获得的回报。

估计量的偏差是有界的，并且指数折扣可以在一定程度上控制它。值得注意的是，当环境和超策略都是平稳的时，偏差消失。在未来性能估计量之上，目标函数增加了两项。第一，添加了新超参数集下过去性能的估计。这一项通过迫使超策略在过去样本上表现良好来对抗灾难性遗忘。第二，增加对方差的惩罚。它禁止超策略的过度非平稳性，这种非平稳性将是过拟合环境过去非平稳性和未来泛化不良的症状。通过梯度优化来优化这一目标得到了我们的算法 *POLIS*。

利用该算法，我们提出了一个简单修改以考虑延迟。与 *dSARSA* 类似 [?]，我们在性能估计期间将奖励在时间上向后偏移，以重新对齐所选策略与其结果。

随后，我们展示了 *POLIS* 在不同终身场景（有延迟和无延迟）中的实证评估。该算法展示了其能够有效学习非平稳性的结构以适应未来。*POLIS* 还避免了不需要的额外非平稳性，这主要得益于目标函数中的惩罚项。在延迟任务上测试时，*POLIS* 随着延迟增加表现出鲁棒的行为。然而，与水坝环境中的平稳超策略相比，*POLIS* 的回报有时具有较高的方差。

未来研究可以考虑随机延迟。在这种情况下，无记忆策略的最大优势在于其输入是 S 中的一个状态，并且不像增广方法那样依赖于延迟。因此，无记忆策略具有小而固定的输入维度 $|S|$ 。

POLIS	无延迟	延迟 1 步	延迟 5 步	延迟 10 步
入流 1	-2.2 ± 0.2	-3.1 ± 0.3	-3.2 ± 0.2	-3.2 ± 0.2
入流 2	-1.5 ± 0.0	-1.4 ± 0.2	-1.5 ± 0.2	-1.5 ± 0.3
入流 3	-3.2 ± 0.2	-4.1 ± 0.3	-4.1 ± 0.2	-4.1 ± 0.2

Table 6.2: *POLIS* 在延迟水坝环境上获得的回报。目标阶段的平均回报和基于 3 个随机种子的标准差。为美观起见，报告的结果除以 $1e3$ 量级。

多动作延迟 (Multiple Action Delays)

7.1 引言

本章探索一种不同的延迟范式，该范式具有实用的现实应用价值。我们希望对动作的效果分散在多个时间步上的可能性进行建模。在时刻 t 选定的单个动作会影响未来多个转移的奖励和转移。这种性质类似于单个动作具有多个延迟。我们将这种新的延迟设定命名为多动作延迟 (*multiple action delay*)。

为引出该设定，回顾在 ?? 的相关工作讨论中，我们看到 [?] 通过在增广状态中包含额外量获得了更好的理论结果。该量定义为“待执行向量 (vector-to-go)”，即仍需作用于环境的动作量。这一概念与我们的多动作延迟存在相似之处，其中动作可能以不同概率分布到未来的时间步。多个过去动作影响当前动态的可能性也在控制理论中以分布式延迟 (distributed delay) 或多延迟 (multiple delays) 的名义被研究 [?, ?]。

该设定反过来意味着多个过去的动作可能影响当前的转移和奖励。这使人联想到高阶马尔可夫链。然而，如 ?? 所述，这些模型通常需要大量参数，代价高昂。这促使我们选择使用 MTD 模型对多动作延迟进行建模 (见 ??)。我们将这种环境模型称为 mixture transition distribution of Markov decision process (MTD-MDP)。在 ?? 中，我们正式定义了将 MTD 模型应用于 MDPs 以得到 MTD-MDPs 的四种不同方式。随后，在 ?? 中，我们从理论上分析这一新框架。首先证明 MTD-MDP 与本文前面讨论的常值延迟存在相似性。值得注意的是，它们可以通过状态增广 (augmentation of the state) 还原回 MDPs。在 ?? 中，我们表明在平均奖励准则下的最优策略在四种 MTD-MDPs 模型中的两种中也是最优的。因此它们不受延迟的影响。最后，在 ?? 中，我们更详细地分析一种更有趣的 MTD-MDP。后者特别值得关注，因为它将常值动作执行延迟 (constant action execution delays) 作为一种特例包含在内。我们将重点研究当延迟分布变化时，智能体的回报或平均奖励如何演变。还将研究该过程的结构，以发现哪些

理论 RL 算法可以直接应用于它。

理论结果的洞见随后通过实验探究，研究一些 RL 算法在面对多动作延迟时的行为。

7.2 问题形式化

7.2.1 定义

在预备知识中，我们介绍了两种转移概率混合模型：?? 的 MTD 和 ?? 的 MTD_g。基于这些模型，我们将构建延迟过程，其中转移被定义为转移概率的混合。定义此类模型有多种方式，下面将探索其中四种。我们用术语 MTD-MDP 统称这些过程。现在介绍第一个模型。

Definition 7.2.1 (Instantaneous Single-matrix Mixture Transition Markov Decision Process (ISM-MDP)). 给定一个转移为 p 的 MDP $\mathcal{M}$ 和延迟 Δ ，ISM-MDP 转移过程定义如下，

$$\begin{aligned} \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_t, \dots, A_{t-\Delta_{\max}} = a_{t-\Delta_{\max}}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_{t-g}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g p(s_{t+1} | s_t, a_{t-g}). \end{aligned}$$

其奖励为，

$$R(s_t, a_t, \dots, a_{t-\Delta_{\max}}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s_t, a_{t-g}).$$

Remark 7.2.1. 经典的常值 Δ -延迟 Δ MDP 属于此类，只需令 $\lambda_0 = \dots = \lambda_{\Delta-1} = 0$ 且 $\lambda_{\Delta} = 1$ 。

第一个定义基于如下假设：无论延迟动作是哪个，它都将应用于当前状态。因此，动作作用于瞬时 (*instantaneous*) 状态而非过去 (*past*) 状态。这对应了名称中的字母“I”。第二个重要的字母是“S”，因为该模型基于常规的 MTD 模型构建，该模型考虑单个 (*single*) 转移矩阵。现在考虑基于 MTD 的另一个模型，但使用过去状态来应用动作，因此名称中含“P”。

Definition 7.2.2 (Past Single-matrix Mixture Transition Markov Decision Process (PSM-MDP)). 给定一个转移为 p 的 MDP $\mathcal{M}$ 和延迟 Δ ，PSM-MDP 转移过程定义如下，

$$\begin{aligned} \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_t, \dots, S_{t-\Delta_{\max}} = s_{t-\Delta_{\max}}, A_{t-\Delta} = a_{t-\Delta_{\max}}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_{t-g}, A_t = a_{t-g}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g p(s_{t+1} | s_{t-g}, a_{t-g}). \end{aligned}$$

其奖励为，

$$R(s_t, a_t, \dots, s_{t-\Delta_{\max}}, a_{t-\Delta_{\max}}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s_{t-g}, a_{t-g}).$$

注意转移和奖励如何依赖于过去状态 s_{t-g} 。现在定义最后两个模型，它们使用 MTDg 模型，增加了更多自由度。由于它们依赖于多个 (*multiple*) 转移矩阵，我们在名称中使用字母“M”。

Definition 7.2.3 (Instantaneous Multi-matrix Mixture Transition Markov Decision Process (IMM-MDP)). 对于延迟 $\Delta_{\max}$ 以及各自转移为 $(p_g)_{g \in [1, \Delta_{\max}]}$ 的 MDPs $(\mathcal{M}_g)_{g \in [1, \Delta_{\max}]}$ ，IMM-MDP 转移过程定义如下，

$$\begin{aligned} \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_t, \dots, A_{t-\Delta_{\max}} = a_{t-\Delta_{\max}}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g \mathbb{P}(S_t = s_t | S_t = s_t, A_{t-g} = a_{t-g}) \\ &= \sum_{g=0}^{\Delta_{\max}} \lambda_g p_g(s_{t+1} | s_t, a_{t-g}). \end{aligned}$$

其奖励为，

$$R(s_t, a_t, \dots, a_{t-\Delta_{\max}}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s_t, a_{t-g}).$$

		转移使用的状态	
		过去	瞬时
转移矩阵	单一	PSM-MDP	ISM-MDP
	多个	PMM-MDP	IMM-MDP

Table 7.1: 从 MTD 和 MTD_g 模型应用于 MDPs 导出的四种过程的主要性质。

Definition 7.2.4 (Past Multi-matrix Mixture Transition Markov Decision Process (PMM-MDP)). 对于延迟 $\Delta_{\max}$ 以及各自转移为 $(p_g)_{g \in [1, \Delta_{\max}]}$ 的 MDPs $(\mathcal{M}_g)_{g \in [1, \Delta_{\max}]}$, PMM-MDP 转移过程定义如下,

$$\begin{aligned}
 & \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_t, \dots, S_{t-\Delta_{\max}} = s_{t-\Delta_{\max}}, A_{t-\Delta} = a_{t-\Delta_{\max}}) \\
 &= \sum_{g=0}^{\Delta_{\max}} \lambda_g \mathbb{P}(S_{t+1} = s_{t+1} | S_{t-g} = s_{t-g}, A_{t-g} = a_{t-g}) \\
 &= \sum_{g=0}^{\Delta_{\max}} \lambda_g p_g(s_{t+1} | s_{t-g}, a_{t-g}).
 \end{aligned}$$

其奖励为,

$$R(s_t, a_t, \dots, s_{t-\Delta_{\max}}, a_{t-\Delta_{\max}}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s_{t-g}, a_{t-g}).$$

注意初始状态分布尚未定义。一种可能性——本章采用的方式——是将过程初始化为常值 $\Delta_{\max}$ -延迟 Δ MDP: 前 $\Delta_{\max}$ 个动作从动作空间中均匀随机采样。?? 总结了每个过程的性质。

7.2.2 目标与假设

注意我们并不假设智能体知道每步哪个动作已被应用于环境, 即我们处于匿名框架中。关于 MTD-MDP 框架下的目标, 我们将研究无限时域下的期望折扣回报或平均奖励准则。特别地, 我们将关注延迟向量 $\lambda = (\lambda_0, \dots, \lambda_{\Delta_{\max}})$ 的选择对智能体性能的影响。关于信息结构 (见 ??), 与经典常值延迟 Δ 类似, 我们假设智能体在时刻 t 可以访问历史 $h_t = (h_t^s, h_t^r, h_t^a)$, 其中 $h_t^s = (s_i)_{0 \leq i \leq t-\Delta}$ 为状态历史, $h_t^r = (r_i)_{0 \leq i \leq t-\Delta}$ 为奖励历史, $h_t^a = (a_i)_{0 \leq i \leq t}$ 为动作历史。

在理论分析中, 我们假设状态空间和动作空间有限, 以简化问题并利用理论 RL 的结果。

7.2.3 记号

我们将采用 ?? 中定义的面向期望折扣回报和平均奖励目标的状态分布。由于某些结果可通过类似计算同时适用于两者, 为简洁起见, 我们可能在这些情况下省略下标“AVG”或“ γ ”。此外, 我们使用记号 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^{\Delta_{\max}}$ 表示 ISM-MDP 和 IMM-MDP 的增广状态空间, 类似于常值延迟 Δ MDP。对于 PSM-MDP 和 PMM-MDP, 我们将增广状态空间定义为 $\tilde{\mathcal{X}} = \mathcal{S}^{\Delta_{\max}} \times \mathcal{A}^{\Delta_{\max}}$ 。由于与常值延迟 Δ MDP 的相似性, 容易证明 ISM-MDP 和 IMM-MDP 中的策略属于集合 $\tilde{\Pi}$ (参见 ??)。PSM-MDP 和 PMM-MDP 在其转移模型中考虑过去状态, 因此它们不会向增广状态添加比 ISM-MDP 和 IMM-MDP 的增广状态中已有的更多最新信

息。这意味着前者的策略从后者的角度来看是历史依赖的，也属于 $\tilde{\Pi}$ 。我们将它们的策略集记为 $\bar{\Pi} \subset \tilde{\Pi}$ 。为避免混淆，我们将 PSM-MDP 和 PMM-MDP 的策略记作 $\bar{\pi}$ 。

最后，定义 MTD-MDP 中状态和动作分布的记号。考虑 $s \in \mathcal{S}$ 、 $a \in \mathcal{A}$ 、 $x \in \mathcal{X}$ 、 $\bar{x} \in \bar{\mathcal{X}}$ 、 $\pi \in \Pi$ 以及 $\tilde{\pi}, \bar{\pi} \in \tilde{\Pi}$ 。那么，无延迟策略 π 的分布写作，

1. $d^\pi(s)$ 为 MDP 中策略 π 下的状态分布；
2. $d^\pi(s, a)$ 为 MDP 中策略 π 下的状态-动作分布；

对于 ISM-MDP 和 IMM-MDP，分布为，¹

3. $d^{\tilde{\pi}}(x)$ 为 ISM-MDP 和 IMM-MDP 中策略 $\tilde{\pi}$ 下在 $\mathcal{X}$ 上的分布；
4. $d^{\tilde{\pi}}(x, a)$ 为 ISM-MDP 和 IMM-MDP 中策略 $\tilde{\pi}$ 下在 $\mathcal{X} \times \mathcal{A}$ 上的分布。
5. $d^{\tilde{\pi}}(s)$ 为 ISM-MDP 和 IMM-MDP 中策略 $\tilde{\pi}$ 下在 $\mathcal{S}$ 上的分布；
6. $d^{\tilde{\pi}}(s, a)$ 为 ISM-MDP 和 IMM-MDP 中策略 $\tilde{\pi}$ 下在 $\mathcal{S} \times \mathcal{A}$ 上的分布。

类似地，对于 PSM-MDP 和 PMM-MDP，分布为，

7. $d^{\bar{\pi}}(\bar{x})$ 为 PSM-MDP 和 PMM-MDP 中策略 $\bar{\pi}$ 下在 $\bar{\mathcal{X}}$ 上的分布；
8. $d^{\bar{\pi}}(\bar{x}, a)$ 为 PSM-MDP 和 PMM-MDP 中策略 $\bar{\pi}$ 下在 $\bar{\mathcal{X}} \times \mathcal{A}$ 上的分布。
9. $d^{\bar{\pi}}(s)$ 为 PSM-MDP 和 PMM-MDP 中策略 $\bar{\pi}$ 下在 $\mathcal{S}$ 上的分布；
10. $d^{\bar{\pi}}(s, a)$ 为 PSM-MDP 和 PMM-MDP 中策略 $\bar{\pi}$ 下在 $\mathcal{S} \times \mathcal{A}$ 上的分布。

7.3 理论分析

本节分析不同模型的性质。首先在 ?? 中分析 MTD-MDPs 与 MDPs 的关系。然后，在 ?? 中，针对平均奖励准则，证明在 PSM-MDP 或 PMM-MDP 中学习的问题等价于在底层无延迟 MDP 中学习。最后，在 ?? 中，考虑在 ISM-MDP 中学习策略的任务——这更为复杂。先说明其一些特殊性，再总结能或不能应用于此情况的 RL 算法。读者可能注意到我们将 IMM-MDP 搁置了。它们确实是一种更复杂的设定，需要未来单独分析。

7.3.1 从 MTD-MDP 回到 MDP

第一个结果展示了给定固定延迟策略时，上述分布之间的不同关系。首先给出 ISM-MDP 和 IMM-MDP 的结果。

Proposition 7.3.1 ($\mathcal{S}$ 、 $\mathcal{X}$ 、 $\mathcal{S} \times \mathcal{A}$ 与 $\mathcal{X} \times \mathcal{A}$ 上分布之间的关系). 设 $\tilde{\pi}$ 为 ISM-MDP 或 IMM-MDP 上的策略，其在增广状态空间上诱导分布 $d^{\tilde{\pi}}$ 。则前述分布 3 至 6 与 $d^{\tilde{\pi}}$ 的关系如下。设 $s \in \mathcal{S}$ 、 $x \in \mathcal{X}$ 、 $a \in \mathcal{A}$ ，

$$d^{\tilde{\pi}}(x, a) = d^{\tilde{\pi}}(x) \tilde{\pi}(a|x), \quad (7.1)$$

$$d^{\tilde{\pi}}(s) = \int_{\mathcal{X}} \delta_s(e_0^\top x) d^{\tilde{\pi}}(x) dx \quad (7.2)$$

$$d^{\tilde{\pi}}(s, a) = \int_{\mathcal{X}} \delta_s(e_1^\top x) \delta_a(e_1^\top x) d^{\tilde{\pi}}(x) dx, \quad (7.3)$$

¹可以看出，我们选择不在记号中显式指明输入空间，以保持可读性。输入空间由分布所评估的量即可明确。

其中使用 $(e_i)_{[0, \Delta_{\max}]}$ 作为 $\mathcal{X} \times \mathcal{A}$ 上的基。对于 $x = (s, a_1, \dots, a_{\Delta_{\max}})$ ，设 $e_0^\top x = s$ 且 $e_i^\top x = a_i$ 。

Proof. ?? 是 RL 领域的已知结果。?? 使用了与 [?, Lemma 3.1] 类似的思想，即对 x 中包含的状态求边际分布。?? 由类似推理得到。□

显然，对于 PSM-MDP 和 PMM-MDP 可证相同结果。

Proposition 7.3.2 ($\mathcal{S}$ 、 $\bar{\mathcal{X}}$ 、 $\mathcal{S} \times \mathcal{A}$ 与 $\bar{\mathcal{X}} \times \mathcal{A}$ 上分布之间的关系). 设 $\bar{\pi}$ 为 PSM-MDP 或 PMM-MDP 上的策略，其在增广状态空间上诱导分布 $d^{\bar{\pi}}$ 。则前述分布 7 至 10 与 $d^{\bar{\pi}}$ 的关系如下。设 $s \in \mathcal{S}$ 、 $\bar{x} \in \bar{\mathcal{X}}$ 、 $a \in \mathcal{A}$ ，

$$d^{\bar{\pi}}(\bar{x}, a) = d^{\bar{\pi}}(\bar{x})\bar{\pi}(a|\bar{x}), \quad (7.4)$$

$$d^{\bar{\pi}}(s) = \int_{\bar{\mathcal{X}}} \delta_s(e_0^\top \bar{x}) d^{\bar{\pi}}(\bar{x}) d\bar{x} \quad (7.5)$$

$$d^{\bar{\pi}}(s, a) = \int_{\bar{\mathcal{X}}} \delta_s(e_1^\top \bar{x}) \delta_a(e_1^\top \bar{x}) d^{\bar{\pi}}(\bar{x}) d\bar{x}, \quad (7.6)$$

其中将前述记号扩展到 $\bar{\mathcal{X}} \times \mathcal{A}$ 上的基 $(e_i)_{[-\Delta_{\max}+1, \Delta_{\max}]}$ 。对于 $\bar{x} = (s_{-\Delta_{\max}+1}, \dots, s_{-1}, s, a_1, \dots, a_{\Delta_{\max}})$ 设 $e_0^\top \bar{x} = s$ 、 $e_i^\top \bar{x} = a_i$ 、 $e_{-i}^\top \bar{x} = s_{-i}$ 。

延迟文献中一个反复出现的著名结果是 Δ MDP 与具有增广状态的 MDP 之间的等价性。我们证明类似结果对 MTD-MDPs 也成立。首先推导 ISM-MDP 和 IMM-MDP 的结果。

Proposition 7.3.3 (IMM-MDP 的等价 MDP). 对于 IMM-MDP，可以通过将状态空间增广到 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^{\Delta_{\max}}$ 将问题还原回 MDP。

Proof. 设 $\tilde{\mathcal{M}}_\lambda$ 为一个 IMM-MDP。为证明该性质，定义一个状态空间为 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^{\Delta_{\max}}$ 、动作空间为 $\mathcal{A}$ 的 MDP $\mathcal{M}$ ，使得为 $\tilde{\mathcal{M}}_\lambda$ 定义的任何历史依赖策略 $\tilde{\pi} \in \tilde{\Pi}$ 在 $\mathcal{M}$ 上实现相同的回报。

对于增广状态 $x \in \mathcal{X}$ （其中 $x = (s, a_1, \dots, a_{\Delta_{\max}})$ ）和某个动作 $a_{\Delta_{\max}+1} \in \mathcal{A}$ ，定义 $\mathcal{M}$ 中的奖励为，

$$\tilde{R}(x, a_{\Delta_{\max}+1}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s, a_{\Delta_{\max}+1-g}).$$

现在定义 $\mathcal{M}$ 上两个增广状态 $x = (s, a_1, \dots, a_{\Delta_{\max}})$ 与 $x' = (s', a'_1, \dots, a'_{\Delta_{\max}})$ 之间在动作 $a_{\Delta_{\max}+1} \in \mathcal{A}$ 下的转移函数 $\tilde{p}$ ：

$$\tilde{p}(x'|x, a_{\Delta_{\max}+1}) = \left(\sum_{g=0}^{\Delta_{\max}} \lambda_g p_g(s'|s, a_{\Delta_{\max}+1-g}) \right) \prod_{i=1}^{\Delta_{\max}} \delta_{a_{i+1}}(a'_i).$$

显然 $\mathcal{M}$ 是一个 MDP。现在，设 $\tilde{\pi}$ 是 $\tilde{\mathcal{M}}_\lambda$ 上的历史依赖策略。假设历史 $(s_0, a_0, \dots, s_{t-1}, a_{t-1}, s_t) \in (\mathcal{S} \times \mathcal{A})^{t+1}$ 对 $\mathcal{M}$ 和 $\tilde{\mathcal{M}}_\lambda$ 相同。那么， $\tilde{\pi}$ 选择的动作 a_t 显然具有相同分布。 $\tilde{\mathcal{M}}_\lambda$ 中的下一状态 s_{t+1} 从 $\sum_{g=0}^{\Delta_{\max}} \lambda_g p_g(\cdot | s_t, a_{t-g})$ 中采样，而根据构造，下一个增广状态 x_{t+1} 中包含的状态也是如此，因为当前增广状态

²回顾 $\mathcal{X} \times \mathcal{A}$ 上的分布定义了 $\mathcal{S} \times \mathcal{A}$ 上的分布。

x_t 是 $(s_t, a_{t-\Delta}, \dots, a_{t-1})$ 。通过递推，对于 $t' > t$ ，历史具有相同概率。只需以相同方式初始化两个过程，即初始增广状态中包含的动作应与 $\widetilde{\mathcal{M}}_\lambda$ 中前 $\Delta_{\max}$ 个动作具有相同概率。根据构造，这些轨迹上的奖励相同，因此回报也相同。证毕。 $\square$

Proposition 7.3.4 (ISM-MDP 的等价 MDP). 对于 ISM-MDP，可以通过将状态空间增广到 $\mathcal{X} = \mathcal{S} \times \mathcal{A}^{\Delta_{\max}}$ 将问题还原回 MDP。

Proof. 只需移除转移概率对 g 的依赖，即可应用相同的证明。 $\square$

类似地，对于 PMM-MDP 和 PSM-MDP 有以下结果。

Proposition 7.3.5 (PMM-MDP 的等价 MDP). 对于 PMM-MDP，可以通过将状态空间增广到 $\bar{\mathcal{X}} = \mathcal{S}^{\Delta_{\max}} \times \mathcal{A}^{\Delta_{\max}}$ 将问题还原回 MDP。

Proof. 设 $\widetilde{\mathcal{M}}_\lambda$ 为一个 PMM-MDP。如上所述，对于状态空间为 $\bar{\mathcal{X}} = \mathcal{S}^{\Delta_{\max}} \times \mathcal{A}^{\Delta_{\max}}$ 、动作空间为 $\mathcal{A}$ 的 MDP $\mathcal{M}$ ，对于增广状态 $x \in \bar{\mathcal{X}}$ (其中 $x = (s_{-\Delta_{\max}+1}, \dots, s_{-1}, s, a_1, \dots, a_{\Delta_{\max}})$) 和某个动作 $a_{\Delta_{\max}+1} \in \mathcal{A}$ ， $\mathcal{M}$ 中的奖励定义为，

$$\bar{R}(x, a_{\Delta_{\max}+1}) = \sum_{g=0}^{\Delta_{\max}} \lambda_g R(s_{\Delta_{\max}-g}, a_{\Delta_{\max}+1-g}).$$

考虑另一个增广状态 $x' = (s'_{-\Delta_{\max}+1}, \dots, s'_{-1}, s', a'_1, \dots, a'_{\Delta_{\max}}) \in \bar{\pi}$ ，则转移概率为，

$$\bar{p}(x'|x, a_{\Delta_{\max}+1}) = \left(\sum_{g=0}^{\Delta_{\max}} \lambda_g p_g(s'|s_{\Delta_{\max}-g}, a_{\Delta_{\max}+1-g}) \right) \prod_{i=1}^{\Delta} \delta_{a_i+1}(a'_i).$$

显然 $\mathcal{M}$ 是一个 MDP，可以应用与之前相同的推理证明等价性。 $\square$

Proposition 7.3.6 (PSM-MDP 的等价 MDP). 对于 PSM-MDP，可以通过将状态空间增广到 $\bar{\mathcal{X}} = \mathcal{S}^{\Delta_{\max}} \times \mathcal{A}^{\Delta_{\max}}$ 将问题还原回 MDP。

Proof. 只需移除转移概率对 g 的依赖，即可应用与 PMM-MDP 相同的证明。 $\square$

7.3.2 PSM-MDP 和 PMM-MDP 的分析

在本小节中，我们特别分析平均奖励情况下的 PSM-MDP 和 PMM-MDP。我们证明这些情况本质上等同于求解底层 MDP。实际上，正如将看到的，在延迟过程的当前状态上应用无延迟策略将产生相同的平均状态-动作分布，因此获得相同的奖励。记 $(p^\pi)^{(k)}(s', a'|s, a)$ 为从状态 s 出发、执行动作 a 后遵循策略 π ，在 k 步内到达状态-动作 (s', a') 的概率。首先给出 PSM-MDP 的结果。

Lemma 7.3.1. 设 π 为 MDP $\mathcal{M}$ 中的策略，满足 $\lim_{k \rightarrow \infty} (p^\pi)^{(k)}(s, a|s', a') = d_{AVG}^\pi(s, a)$ 。则对于基于 $\mathcal{M}$ 构建的 PSM-MDP $\widetilde{\mathcal{M}}$ ，将 π 应用于其当前状态在 $\mathcal{S} \times \mathcal{A}$ 上产生与 $\mathcal{M}$ 中相同的平均状态-动作占用分布 d_{AVG}^π 。

Proof. 固定策略 π 后，底层 MDP 变为 MC。将此结果 [?, Theorem 2.1] 应用于该马尔可夫链，可得对于 $(s', a') \in \mathcal{S} \times \mathcal{A}$,

$$\lim_{k \rightarrow \infty} (\bar{p}^\pi)^{(k)}(s', a'|x) = d_{AVG}^\pi(s, a),$$

其中 $x = (s, a_1, \dots, a_\Delta) \in \mathcal{X}$, 且

$$(\bar{p}^\pi)^{(1)}(s', a'|x) = \left(\sum_{g=1}^{\Delta_{\max}} \lambda_g p(s_t|s, a_{\Delta_{\max}+1-g}) + \lambda_g p(s|s, a') \right) \pi(a'|s).$$

上式中括号内的项正是 PSM-MDP 转移函数的定义。证毕。 $\square$

由上述结果显然可得以下定理。

Theorem 7.3.1. 设 π 为 MDP $\mathcal{M}$ 中的策略, 满足 $\lim_{k \rightarrow \infty} (p^\pi)^{(k)}(s, a|s', a') = d^\pi(s, a)$, 且 $\tilde{\mathcal{M}}_\lambda$ 为基于 $\mathcal{M}$ 构建的 PSM-MDP。则将该策略 π 应用于 PSM-MDP 的当前状态所获得的平均奖励与其在 $\mathcal{M}$ 中相同。

Proof. 根据 ??, π 在 $\tilde{\mathcal{M}}_\lambda$ 和 $\mathcal{M}$ 中的 $\mathcal{S} \times \mathcal{A}$ 上具有相同分布。根据 PSM-MDP 中延迟的定义, π 在两个过程中也具有相同的平均奖励。 $\square$

现在将注意力转向 PMM-MDP。假设 MTD-MDP 模型的转移函数是齐次的, 即对于 $s, s' \in \mathcal{S}$ 和 $a \in \mathcal{A}$:

$$p_g(s'|s, a) = p^{(g+1)}(s'|s, a).$$

这样, ?? 中定义的 PMM-MDP 转移变为,

$$\begin{aligned} \mathbb{P}(S_{t+1} = s_{t+1} | S_t = s_t, A_t = a_t, \dots, S_{t-\Delta_{\max}} = s_{t-\Delta_{\max}}, A_{t-\Delta} = a_{t-\Delta_{\max}}) \\ = \sum_{g=0}^{\Delta_{\max}} \lambda_g p^{(g+1)}(s_{t+1} | s_{t-g}, a_{t-g}). \end{aligned}$$

在此假设下, 可以证明以下结果。

Lemma 7.3.2. 设 π 为 MDP $\mathcal{M}$ 中的策略, 满足 $\lim_{k \rightarrow \infty} (p^\pi)^{(k)}(s, a|s', a') = d_{AVG}^\pi(s, a)$ 。则对于基于 $\mathcal{M}$ 构建的齐次 PMM-MDP $\tilde{\mathcal{M}}$, 将 π 应用于其当前状态在 $\mathcal{S} \times \mathcal{A}$ 上产生与 $\mathcal{M}$ 中相同的平均状态-动作占用分布 d_{AVG}^π 。

Proof. 如前所述, 固定策略 π 后, 底层 MDP 变为 MC。将此结果 [?, Proposition 4] 应用于该马尔可夫链, 可得对于 $(s', a') \in \mathcal{S} \times \mathcal{A}$,

$$\lim_{k \rightarrow \infty} (\bar{p}^\pi)^{(k)}(s', a'|x) = d_{AVG}^\pi(s, a),$$

其中 $x = (s, a_1, \dots, a_\Delta) \in \mathcal{X}$, 且

$$(\bar{p}^\pi)^{(1)}(s', a'|x) = \left(\sum_{g=1}^{\Delta_{\max}} \lambda_g p^{(g)}(s_t|s, a_{\Delta_{\max}+1-g}) + \lambda_g p(s|s, a') \right) \pi(a'|s).$$

上式中括号内的项正是齐次 PMM-MDP 转移函数的定义。证毕。 $\square$

然后, 采用与 PSM-MDP 相同的证明, 得到以下结果。

Theorem 7.3.2. 设 π 为 MDP $\mathcal{M}$ 中的策略, 满足 $\lim_{k \rightarrow \infty} (p^\pi)^{(k)}(s, a|s', a') = d^\pi(s, a)$, 且 $\tilde{\mathcal{M}}_\lambda$ 为基于 $\mathcal{M}$ 构建的齐次 PMM-MDP。则将该策略 π 应用于 PMM-MDP 的当前状态所获得的平均奖励与其在 $\mathcal{M}$ 中相同。




Figure 7.1: 针对“平均延迟越高则性能越低”这一推测的反例。智能体在两个状态中各有两个动作 a 和 b 。无论采取什么动作、处于什么状态，智能体都有 $1/2$ 的概率转移到另一个状态， $1/2$ 的概率保持在当前状态。奖励为 $r(s_1, b) = r(s_0, a) = 1$ 和 $r(s_0, b) = r(s_1, a) = 0$ 。奖励和转移函数经过特殊定义，使得两个智能体中，期望延迟较小但无延迟权重 λ_0 上质量较小的那个表现更差。

7.3.3 ISM-MDP 的分析

现在将更详细地分析 ISM-MDP 的情况，从延迟 RL 的角度看，这或许更有趣。诚然，如前所述，ISM-MDPs 将前几章研究的常值延迟作为特例包含在内。由于希望研究延迟向量 λ 的影响，记 $J_{\gamma}^{\tilde{\pi}}(\lambda)$ 为延迟策略 $\tilde{\pi}$ 在 λ -延迟 ISM-MDP 中的期望 γ 折扣回报， $J_{\text{AVG}}^{\tilde{\pi}}(\lambda)$ 为其平均奖励。

如 ?? 所示，较高延迟分配的权重越多，性能越低，这似乎是合理的。回顾由于 ISM-MDPs 将常值 Δ MDPs 作为特例包含，?? 可应用于权重全部集中在单个索引上的延迟向量。现在感兴趣的是研究更一般的结果，其中延迟向量 λ 的权重分布在不同的值上。首先展示一个可能反直觉的结果。

推测延迟均值越高则性能越低似乎是合理的。然而，我们通过 ?? 的反例证明这是错误的。在此 MDP 中考虑两个智能体。第一个智能体（智能体 1）的延迟权重为 $\lambda_0 = \epsilon, \lambda_1 = 0, \lambda_2 = 1 - \epsilon$ ，而第二个智能体（智能体 2）的所有权重在 λ_1 上，即 $\lambda_0 = \lambda_2 = 0$ 。对于 $\epsilon < 0.5$ ，智能体 1 承受的延迟比智能体 2 更大。然而，在此 MDP 中，智能体的动作对转移没有影响，因此智能体 1 可以优化其一步奖励，而智能体 2 不能。智能体 1 的最优策略是 $\pi(s_1) = b$ 和 $\pi(s_0) = a$ ，产生的一步期望奖励为 $1 \cdot \epsilon + 0.5 \cdot (1 - \epsilon) = 0.5(1 + \epsilon)$ 。相反地，智能体 2 的一步期望奖励为 0.5 。

因此，需要找到另一种比较两个延迟向量的方法。将 λ 的分布作为整体来考虑的一种方式考虑其累积分布。这是以下猜想的内容。

Conjecture 7.3.1. 设 λ 和 λ' 为两个延迟向量。记 F_{λ} 和 $F_{\lambda'}$ 分别为其累积分布，如 ?? 所示。如果对于任意 $i \in \mathbb{N}$ ：

$$F_{\lambda}(i) \geq F_{\lambda'}(i),$$

则它们的最优期望折扣回报和平均奖励满足，

$$\begin{aligned} J_{\gamma}^{\star}(\lambda) &\geq J_{\gamma}^{\star}(\lambda') \\ J_{\text{AVG}}^{\star}(\lambda) &\geq J_{\text{AVG}}^{\star}(\lambda'). \end{aligned}$$

作为该猜想的论据，我们提供以下思路。设 $\tilde{\mathcal{M}}$ 和 $\tilde{\mathcal{M}}'$ 是两个 ISM-MDPs，其延迟向量分别为 λ 和 λ' 。假设 $\forall i \in \mathbb{N}, F_{\lambda}(i) \geq F_{\lambda'}(i)$ 且 λ 的所有权重集中在 λ_{Δ} （其中 $\Delta \in \llbracket 0, \Delta_{\max} \rrbracket$ ）。对于策略 $\tilde{\pi}'$ 、增广状态 $x_t = (s_t, a_{t-\Delta_{\max}}, \dots, a_{t-1})$ 和动作 $a_t \sim \tilde{\pi}'$ ，在 $\tilde{\mathcal{M}}'$ 中底层 MDP 的新状态按以下分布采样：

$$s_{t+1} \sim p(\cdot | x_t, a_t) = \sum_{g=\Delta}^{\Delta_{\max}'} \lambda'_g p(\cdot | s_t, a_{t-g}). \quad (7.7)$$




Figure 7.2: 延迟向量 λ 示例及其累积分布函数。权重 λ_i 对应于延迟 i 。

注意求和从 Δ 开始，因为 $\forall i \in \mathbb{N}, F_\lambda(i) \geq F'_\lambda(i)$ 且 λ 的所有权重在 λ_Δ 上。在 $\widetilde{\mathcal{M}}$ 中，智能体在时刻 t 选择的动作将在时刻 $t + \Delta$ 精确执行。因此可以在 $\widetilde{\mathcal{M}}$ 中构建策略 $\tilde{\pi}$ ，使其在时刻 $t - \Delta$ 选择的动作精确复现 ?? 的概率。形式上，这种情况发生在：

$$\tilde{\pi}(a|x_{t-\Delta}) = \sum_{g=\Delta}^{\Delta_{\max}'} \lambda'_g \delta_{a_{t-g}}(a).$$

因此，该智能体将以不同于 $\tilde{\pi}'$ 的分布来为其增广状态填充动作。然而，如果 $\tilde{\pi}$ 是基于历史的，它可以保留 $\tilde{\pi}'$ 缓冲区中应有的动作记忆。但技术复杂性在于过程的初始化。如果 $\widetilde{\mathcal{M}}$ 和 $\widetilde{\mathcal{M}}'$ 以其缓冲区中相同的动作序列开始，由于延迟向量不同， $\mathcal{S}$ 中的第一个状态将从不同的分布中采样，而智能体对此无法控制。

接下来，通过评估延迟对方差的影响来继续研究延迟的影响。我们证明不仅性能随延迟增加而下降，而且期望回报或平均奖励的方差也在缩小。该结果适用于常值延迟 Δ MDP。

Proposition 7.3.7. 设 $\widetilde{\mathcal{M}}_1$ 和 $\widetilde{\mathcal{M}}_2$ 为两个一致的 Δ MDPs，其常值延迟分别为 Δ_1 和 Δ_2 ，增广状态空间分别为 $\mathcal{X}_1$ 和 $\mathcal{X}_2$ 。假设 $\Delta_1 < \Delta_2$ 。考虑 $\tilde{\pi}_2$ 为 $\widetilde{\mathcal{M}}_2$ 上具有 σ -有限占用测度的策略。则存在 $\widetilde{\mathcal{M}}_1$ 上的策略 $\tilde{\pi}_1$ ，使得 $\forall x_1 \in \mathcal{X}_1$ 有 $\mathbb{E}^{\tilde{\pi}_1}[Y|x_1] = \mathbb{E}^{\tilde{\pi}_2}[Y|x_1]$ ，且

$$\text{Var}^{\tilde{\pi}_2} [\mathbb{E}^{\tilde{\pi}_2}[Y|a, x_2]] \leq \text{Var}^{\tilde{\pi}_1} [\mathbb{E}^{\tilde{\pi}_1}[Y|a, x_1]],$$

其中 $x_2 \in \mathcal{X}_2$ 是从 x_1 构建的增广状态， Y 表示无限时域期望折扣回报或平均奖励的随机变量。项 $\mathbb{E}^\pi[Y|a, x]$ 为策略 π 下从增广状态 x 出发并首先选择动作 a 时 Y 的条件期望，而 Var^π 表示策略 π 诱导的状态-动作分布下的方差。

Proof. 回顾全方差公式；对于随机变量 X 和 Y (Y 具有有限方差)，有

$$\text{Var}[Y] = \mathbb{E} [\text{Var}[Y|X]] + \text{Var} [\mathbb{E}[Y|X]].$$

将此结果应用于期望回报情况下的 $Y = \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)$ 或平均奖励情况下的 $Y = \frac{1}{H} \sum_{t=0}^{\infty} r(s_t, a_t)$ ³。注意，根据奖励有界的假设 ($0 \leq r(s, a) \leq R_{\max}$)， Y 具有有限方差。现在，设 $\tilde{\pi}_2$ 为 $\tilde{\mathcal{M}}_2$ 中具有 σ -有限占用测度的策略。根据 ??， $\tilde{\mathcal{M}}_1$ 中存在一个马尔可夫策略，其在 $\mathcal{X}_1 \times \mathcal{A}$ 上的状态占用测度与 $\tilde{\pi}_2$ 相同。根据 [?, Lemma 1]，它们具有相同的期望回报或平均奖励。这表明 $\mathbb{E}^{\tilde{\pi}_1}[Y] = \mathbb{E}^{\tilde{\pi}_2}[Y]$ ，特别地，对于动作 $a \in \mathcal{A}$ 和增广状态 $x_2 \in \mathcal{X}_2$ ，有 $\mathbb{E}^{\tilde{\pi}_1}[Y|a, x_2] = \mathbb{E}^{\tilde{\pi}_2}[Y|a, x_2]$ 。现在回顾，给定两个随机变量 X_1 和 X_2 ，有

$$\text{Var}[\mathbb{E}[Y|X_1]] \leq \text{Var}[\mathbb{E}[Y|X_1, X_2]].$$

因此，如果也将 $x_1 \in \mathcal{X}_1$ 记为 $\tilde{\mathcal{M}}_1$ 中的当前增广状态，则有

$$\begin{aligned} \text{Var}^{\tilde{\pi}_2}[\mathbb{E}^{\tilde{\pi}_2}[Y|a, x_2]] &\leq \text{Var}^{\tilde{\pi}_2}[\mathbb{E}^{\tilde{\pi}_2}[Y|a, x_2, x_1]] \\ &= \text{Var}^{\tilde{\pi}_2}[\mathbb{E}^{\tilde{\pi}_2}[Y|a, x_1]], \end{aligned}$$

其中注意 Y 仅依赖于未来奖励，且 x_1 包含比 x_2 更新的信息，因为 $\Delta_1 < \Delta_2$ 。最后一个等式基于底层过程的马尔可夫性成立。接下来，将上述方程的最后一项在 $\tilde{\pi}_1$ 诱导的分布下表达：

$$\text{Var}^{\tilde{\pi}_2}[\mathbb{E}^{\tilde{\pi}_2}[Y|a, x_1]] = \text{Var}^{\tilde{\pi}_2}[\mathbb{E}^{\tilde{\pi}_1}[Y|a, x_1]] \quad (7.8)$$

$$= \text{Var}^{\tilde{\pi}_1}[\mathbb{E}^{\tilde{\pi}_1}[Y|a, x_1]], \quad (7.9)$$

其中 ?? 成立是因为策略具有相同回报，?? 成立是因为策略在 $\mathcal{X}_1 \times \mathcal{A}$ 上具有相同的状态占用测度。合并这两个方程即得结果。□

该结果表明，延迟越高，智能体的控制越弱，其回报的方差越小。延迟策略可获得回报的范围随延迟增加而缩小。在极限情况下，当延迟趋于无穷时，智能体不再控制动作序列，期望回报或平均奖励仅遵循 MDP 的随机性。

还可以轻松扩展 ?? 以证明最差延迟策略优于最差无延迟策略。

Corollary 7.3.1 (?? 的推论). 设 $\tilde{\mathcal{M}}_1$ 和 $\tilde{\mathcal{M}}_2$ 为两个一致的 Δ MDPs，其常值延迟分别为 Δ_1 和 Δ_2 。考虑 J_1^W 和 J_2^W ，即延迟策略集上可获得的最差期望折扣回报（无限时域）或平均奖励。若 $\Delta_1 < \Delta_2$ ，则有：

$$J_1^W \leq J_2^W.$$

Proof. 只需将 ?? 应用于奖励函数替换为其加法逆元的过程。□

因此，延迟策略集可达到的回报范围随延迟增加而缩小。在极限情况下，当延迟趋于无穷时，所有策略产生相同的期望回报或平均奖励。

最后两个结果结合起来让我们对延迟 RL 问题有了更深入的理解。延迟越长，环境的可控性越低，可能回报的范围越小。?? 展示了这一现象。

7.3.4 在 ISM-MDP 中学习

ISM-MDPs 在通过状态增广被视为 MDPs 时，具有特定的结构，本节将研究该结构，以理解哪些文献中的算法可能适用于它们。

³由于两种情况的证明类似，我们在记号上不做区分。




Figure 7.3: 延迟策略性能的理论洞察示意图。 x 轴表示给定策略所达到状态分布的抽象量， y 轴表示该策略的性能。外层椭圆表示所有随机历史依赖和无延迟策略的集合。最优无延迟策略将是该椭圆的最上端点。随着延迟 Δ 增加，可达到的回报和状态分布集合收缩，直至延迟变为无穷，此时智能体失去所有控制。

首先，一个有问题的结果是 ISM-MDPs 通常不是单链 (*unichain*) 的，即使底层 MDP 是单链的。当任何平稳确定性策略的转移矩阵是单链时，MDP 是单链的 [?, Section 8.3.1] (也见 ??)。在本节中，提及 ISM-MDPs 时，我们指的是按照 ?? 可转化为的 MDP。

Proposition 7.3.8. 存在这样的 ISM-MDPs，即使底层 MDP 是单链的，它们也不是单链的。

Proof. 在基于单链 MDP 构建的 ISM-MDP 中，考虑确定性平稳策略 π ，给定增广状态 $x = (s, a_1, \dots, a_\Delta)$ 时：

$$\pi(x) = a_\Delta.$$

则该策略在 $\mathcal{X}$ 上恰好诱导出 $|\mathcal{A}|$ 条链。 $\square$

Remark 7.3.1. 前一个证明中定义的策略访问所有状态 $s \in \mathcal{S}$ ，因为底层 MDP 是单链的，且策略 $\pi(s) = a$ 是确定性平稳的。然而，它并不访问 $\mathcal{X}$ 中的所有增广状态。

上述结果意味着某些算法，如 UCRL [?], 不能直接应用于具有增广状态的 ISM-MDPs。更有希望的方向是 UCRL2 [?], 它适用于连通 (*communicating*) MDPs [?, Section 8.3.1] (也见 ??)。

Proposition 7.3.9 (连通的 ISM-MDP). 考虑一个连通的 MDP $\mathcal{M}$ 和建立在其上的 ISM-MDP $\tilde{\mathcal{M}}_\lambda$ 。那么该 ISM-MDP 也是连通的。

Proof. 首先证明常值延迟 Δ MDP 的结果，再证明推广到 ISM-MDP。

对于延迟策略 $\tilde{\pi}$ ，记 $(p^{\tilde{\pi}})^{(k)}(s'|x)$ 为从 x 中的状态 s 出发，应用增广状态中最旧的 k 个动作后，环境状态为 s' 的概率。如果 $k > \Delta_{\max}$ ，则后续动作由 $\tilde{\pi}$ 采样。类似地，对于无延迟策略 π ，记 $(p^\pi)^{(k)}(s'|s)$ 为从 s 出发遵循策略 π 执行 k 步后，环境状态为 s' 的概率。

设 $x = (s, a_1, \dots, a_\Delta)$ 和 $x' = (s', a'_1, \dots, a'_\Delta)$ 为 $\tilde{\mathcal{M}}_\lambda$ 的两个增广状态。设 $s'' \in \mathcal{S}$ 使得 $(p^{\tilde{\pi}})^{(\Delta_{\max})}(s'' \cdot x) > 0$ 。由于底层 MDP 是连通的，存在无延迟策略

$\pi \in \Pi^{\text{SD}}$ 和 $k \in \mathbb{N}$ 使得 $(p^\pi)^{(k)}(s'|s'') > 0$ 。设 k 为最小的这样的数。现在记 τ 为无延迟 MDP 中的一条轨迹，它先从 s 到 s'' ($\Delta_{\max}$ 步)，然后从 s'' 到 s' (k 步)，且概率 $p^\pi(\tau) > 0$ 。上述性质保证这样的轨迹存在。具体地，记

$$\tau = (s, a_0^*, s_1^*, a_1^*, \dots, a_{\Delta_{\max}-1}^*, s'', a_{\Delta_{\max}}^*, \dots, s_{k+\Delta_{\max}-1}^*, a_{k+\Delta_{\max}-1}^*, s').$$

可以将 s 重写为 s_0^* , s'' 重写为 $s_{\Delta_{\max}}^*$ ；对于 x' 中包含的动作，记 a_i' 为 $a_{k+\Delta_{\max}+i-1}^*$ 。现在准备定义一个候选的平稳确定性延迟策略 $\tilde{\pi}$ ，以非零概率将我们从 s 带到 s' 。定义 $x_i^* = (s_i^*, a_i^*, \dots, a_{i+\Delta_{\max}-1}^*)$ ，策略定义如下：

$$\tilde{\pi}(x_i^*) = a_{i+\Delta_{\max}}^*.$$

其他增广状态的定义无关紧要，可以自由指定。该策略有非零概率从 x 到达 x' ，但不清楚它是否真正定义了一个策略。实际上，智能体可能两次面对相同的增广状态，而上述策略会指示两个不同的动作。换句话说， $\tilde{\pi}$ 可能不是正确定义的函数。下面证明这不是问题，或者当它发生时，可以应用简单的修改。

设 $i, j \in \mathbb{N}$ 使得 $\Delta_{\max} < i < j$ 且 $x_i^* = x_j^*$ ，但 $\tilde{\pi}(x_i^*) \neq \tilde{\pi}(x_j^*)$ 。则从 s_j^* 到 s 的轨迹长度为 $\Delta_{\max} + k - j < \Delta_{\max} + k - i$ ，但 $s_j^* = s_i^*$ ，因此时刻 j 之后定义的无延迟策略可以在时刻 i 应用，以严格正概率产生更短的轨迹。这与 τ 的假设矛盾。还有一个小的复杂性；正如读者注意到的，我们假设了 $\Delta_{\max} < i < j$ 。确实，由于我们无法控制前 $\Delta_{\max}$ 个动作，在第 $\Delta_{\max}$ 步之后出现的增广状态可能已经在最初的 $\Delta_{\max}$ 步中出现过。然而，这相当于智能体已经处于轨迹 τ 的更高级部分，因此可以将较高索引对应的增广状态的动作保留为 $\tilde{\pi}$ 的值。这确保了 $\tilde{\pi}$ 是正确定义的平稳确定性策略，且满足 $(p^{\tilde{\pi}})^{(\Delta_{\max}+k)}(x'|x) > 0$ 。因此 ΔMDP 是连通的。

ISM-MDP 的结果如下获得。在任何步骤中， $\Delta_{\max}$ 位置上的动作被执行的概率非零；因此，整个过程如同 $\Delta_{\max}$ -常值延迟 ΔMDP 那样采样轨迹的概率非零。根据上述结论，由于后者是连通的，因此在原始 ISM-MDP 中从 x 出发到达 x' 的概率非零。□

Remark 7.3.2. 如证明所示，且因为 ISM-MDP_S 将常值延迟 ΔMDP_S 作为特例包含，该结果也表明：若底层 MDP 是连通的，则常值延迟 ΔMDP 也是连通的。

有了这一性质，就可以应用 UCRL2 [?] 在 ISM-MDP 中学习策略。如 ?? 所述，UCRL2 的遗憾依赖于 MDP 直径的概念，定义见 ??。ISM-MDP 中的直径显然以底层 MDP 的直径为下界。通过将 [?] 的结果应用于这一特殊情况，可以给出直径的更好下界。

Proposition 7.3.10. 设 $\tilde{\mathcal{M}}_\lambda$ 为最大延迟为 $\Delta_{\max}$ 的 ISM-MDP，且其动作空间包含两个或以上动作，则

$$D(\tilde{\mathcal{M}}_\lambda) \geq \Delta_{\max} - 3 + \log_{|\mathcal{A}|} |\mathcal{S}|$$

Proof. 从 [?, Corollary 15] 可知，对于状态空间为 $\mathcal{S}$ 、动作空间为 $\mathcal{A}$ 的某个 MDP $\mathcal{M}$,

$$D(\mathcal{M}) \geq \log_{|\mathcal{A}|} |\mathcal{S}| - 3.$$

将此结果应用于从 ISM-MDP 获得的状态空间为 $\mathcal{S} \times \mathcal{A}^{\Delta_{\max}}$ 的增广 MDP，即完成证明。□

这里看到延迟对直径的加性影响。注意，即使项 $-3 + \log_{|A|}|S|$ 可能为负，直径也永远不会小于 $\Delta_{\max}$ 。为证明这一点，只需考虑两个增广状态其动作不匹配的情况，显然需要超过 $\Delta_{\max}$ 个动作才能从一个到达另一个。

7.4 实验评估

本节对 ISM-MDP 和 IMM-MDP 进行分析。首先在 ?? 中描述实验设置，然后在 ?? 中展示和讨论结果。

7.4.1 设置

对于本节讨论的所有任务，我们运行 10 个随机种子并对结果取平均。

任务

IMM-MDP 的 Pendulum 任务。 在此实验中，考虑本文已广泛研究的 Pendulum 任务。希望通过实验观察 ?? 的结果。因此，研究在无延迟 MDP 中使用 SAC 训练、在 IMM-MDP 中测试的同一策略 π 的状态分布。这些状态分布将与无延迟环境中随机策略的状态分布进行比较。

ISM-MDP 的 Pendulum 任务。 然后，将实验重点放在 ISM-MDP 上。在此第一个任务中，探索 Pendulum 环境中折扣期望回报的设置。研究延迟向量 λ 定义的延迟分布变化对智能体回报的影响。智能体的策略将使用 A-SAC 在从环境采样的 50,000 步中学习。

迷宫 (Maze)。 作为平均奖励设置的测试基准，考虑一个 3x3 网格世界⁴，智能体必须学习从左上角的起始状态到达右下角的目标状态。网格内的墙壁使任务略有难度。智能体可以朝四个基本方向移动。当智能体撞到墙壁或环境边界时，它停留在同一单元格中。在此环境中，比较延迟向量 λ 的若干取值。具体地，对于 $\lambda = (\lambda_0, \lambda_1)$ ，考虑 λ_0, λ_1 在集合 $\{0, 0.1, \dots, 0.9\}$ 中的取值。特殊情况 $\lambda = (1, 0)$ 是无延迟情况， $\lambda = (0, 1)$ 对应常值 1 步延迟。由于目标是平均奖励，将考虑 UCRL2 算法并研究智能体的遗憾（见 ??）。注意，即使在简单环境中，ISM-MDP 情况下最优策略的计算也更加复杂。首先，即使底层 MDP 是确定性的，过程的初始化也会在初始状态中引入随机性。其次，当延迟向量的权重不集中在单个元素上时，转移本身会进一步注入随机性。

7.4.2 结果

IMM-MDP 的 Pendulum 任务。 我们在 ?? 中报告三个过程的状态分布。这些分布通过运行 Pendulum 环境的多个回合获得。显然，无延迟 SAC 策略在无延迟 MDP 和 PSM-MDP 上产生相似的状态分布。该分布与随机策略的状态分布差异很大。可以观察到一条最内层抛物线，其中仅出现来自无延迟过程的状态。低速度和小幅度的状态典型地出现在过程的初始步骤中，延迟过程未观察到此类状态可能归因于延迟初始化偏移（见 ??）。环境中首个随机采样的动作赋予了初始速度或角度，使智能体从不同位置开始。这并不否定我们的理论，因为这些初始状态对于接近最优策略的 SAC 来说是瞬态的。

ISM-MDP 的 Pendulum 任务。 ?? 展示了不同延迟向量取值获得的回报。随着延迟分布开始向较长延迟偏移，回报开始下降，这与 ?? 的预期一致。更仔

⁴该环境可访问：[链接](#)。




Figure 7.4: 使用 SAC 获得的策略在无延迟 *Pendulum* 环境及其延迟 *PSM-MDP* 对应环境中测试的状态分布比较。状态由两个元素组成：速度和摆杆角度。添加无延迟环境中随机策略的状态分布作为比较。

细地观察结果，当延迟向量分布在两个连续的 λ 值上时 ($(\lambda_i = 0.5, \lambda_{i+1} = 0.5)$)，性能通常低于 ($\lambda_{i+1} = 1$)，尽管差异不显著。这可能与 ?? 相悖，但可能仅由学习问题导致。实际上，用于训练 A-SAC 的样本数对所有延迟都是固定的，但 ($\lambda_i = 0.5, \lambda_{i+1} = 0.5$) 类型的延迟在转移概率中注入了更多随机性，可能使最优策略的学习更加困难。

迷宫。 ?? 报告了结果。这里同样可以更清楚地观察到延迟分布偏移的影响。随着延迟分布在较长延迟上分配更多权重，遗憾增加。有趣的是，常值延迟情况 ($\lambda_0 = 1$ 和 $\lambda_1 = 1$) 与其他延迟向量之间似乎存在差距。尽管按累积分布排列，随机延迟的遗憾是聚集的，且显著偏离常值延迟的遗憾。

7.5 结论

本章提出将动作执行的常值延迟框架进行扩展。具体而言，考虑了动作效果可能分散在多个未来步骤中的可能性。利用高阶 MC 的既有文献，提出了将 MTD 和 MTD_g 模型适配到 MDPs 以获得 MTD-MDPs。选择此方法是因为 MTDs 具有强大的建模能力和低参数维度。这种高阶 MDPs 的新模型恰好提供了观察一个动作在多个未来时间步上效果的可能性。根据是基于 MTD 还是 MTD_g，以及动作应用于哪个状态，提出了四种过程变体。这些过程分别是 ISM-MDPs、IMM-MDPs、PSM-MDPs 和 PMM-MDPs。

随后对其性质进行了理论分析。首先，证明了 MTD-MDPs 可以通过状态增广还原回 MDPs，与常值延迟情况类似。然后重点研究了这些模型的最优策略学习问题。针对 PSM-MDPs 和 PMM-MDPs，证明了无延迟策略在这些过程中产生的平均奖励与底层无延迟 MDP 中相同。接着，研究了更有趣的 ISM-MDP 模型，它将常值延迟作为特例包含在内。首先研究了该模型的特殊性，突出了延迟向量 λ 的选择如何影响智能体的平均奖励和状态分布。针对 λ 对上述准则的影响提出了一个猜想并给出支持性论据。然后，针对常值延迟 Δ MDP 研究了延迟对这些量的方差的影响。最后，研究了底层 MDP 的性质如何传递给 ISM-MDP。这些结果有助于排除理论 RL 文献中不能直接应用于 ISM-MDP 的算法。对于




Figure 7.5: A-SAC 在 *Pendulum* 环境中针对不同延迟向量 λ 取值测试的回报演变。注意无延迟 ($\lambda_0 = 1$) 和常值 Δ -延迟环境 ($\lambda_\Delta = 1$) 的特殊取值。

可以应用的算法 UCRL2，提供了不同 λ 取值的实验以展示其对平均奖励的影响。基于相同思路，还提供了以期望折扣回报为目标函数的另一实验，以凸显 λ 在此情况下的影响。

最后，IMM-MDP 留待未来工作处理。考虑其他未来方向，一种可能性是利用 MTD 模型参数估计的特殊性来改进应用于 MTD-MDP 的理论 RL 算法 [?]. 此外，我们的设定让人联想到 [?], 该研究考虑了时间划分奖励 (temporally-partitioned rewards)，可视为多奖励延迟的一种形式。研究这些设定之间的联系可能为理论方法带来更好的保证。




Figure 7.6: UCRL2 在迷宫环境中针对不同延迟向量 λ 取值测试的遗憾演变。注意无延迟 ($\lambda = (1, 0)$) 和常值 1 步延迟 ($\lambda = (0, 1)$) 过程的特殊情况。

本章为本文的总结。我们系统审视了强化学习中的延迟问题。本文的结果特别凸显了 Δ MDPs 与 MDPs、POMDPs、高阶 MDPs 或高阶 MCs 之间的关系。我们的主要贡献围绕四个方向展开，在接下来的章节中加以总结。为便于读者理解，这些贡献将关联到其来源章节。最后讨论潜在的未来研究方向。

8.1 讨论与关键结果

延迟的统一框架

本文的第一个贡献是为延迟问题提供了统一框架。基于这一目标，在 ?? 中，我们提出了一个通用的数学框架，将文献中遇到的不同延迟过程统一起来。该框架称为 Δ MDP，它基于一个底层 MDP，并在其上添加定义延迟的过程。该定义将常值延迟、非整数延迟、随机延迟或马尔可夫延迟作为特例包含在内。随后，介绍了文献和实践中遇到的主要延迟类型 (??)，并根据它们影响的变量——状态、动作或奖励——以及它们遵循的过程——常值、随机、状态依赖过程等——加以组织。最后，在 ?? 中，深入讨论了强化学习及相关领域（如实时强化学习和老虎机）中的延迟问题，特别关注状态观测延迟和动作执行延迟。针对后者，将文献中的算法归纳为三类：增广状态方法、无记忆方法和基于模型的方法。

延迟的理论理解

关于延迟状态观测或延迟动作执行对 MDP 影响的首个理论结果，是证明了常值延迟 Δ MDP 的一个核心性质：延迟越长，性能越低 (??)。此外，还证明了较长的常值延迟意味着回报或平均奖励的方差更小 (??)。这两个结果的结合在 ?? 中得到了很好的说明。

在 ?? 中，探索了一个更通用的框架，称为多动作延迟 (multiple action delay)。该框架利用 MC 文献中的 MTD 和 MTDg 模型，将其应用于 MDPs 以获得所

谓的 MTD-MDPs。定义了四种这样的 MTD-MDPs: ISM-MDPs、IMM-MDPs、PSM-MDPs 和 PMM-MDPs, 它们在应用 MTD 和 MTD_g 模型的方式上有所不同。首先证明了状态增广可以将这些问题还原回 MDP (?? 及其后的命题)。然后, 专注于学习策略以优化这些模型中的期望折扣回报和平均奖励。对于 PSM-MDPs 和 PMM-MDPs, 证明延迟基本上无效 (?? 和 ??)。事实上, 无论将无延迟策略应用于这些过程还是底层无延迟 MDP, 它都产生相同的平均奖励。因此, 我们研究了更有趣的 ISM-MDPs, 因为它们将常值延迟 Δ MDP 作为特例包含在内。分析了延迟向量 λ 对这些模型的影响, 推测累积延迟分布是排列潜在最优回报或平均奖励的关键 (??)。为这一主张提供了论据, 并证明了均值奖励不能替代猜想中的累积延迟分布。在结束理论分析时, 考察了底层 MDP 的某些性质如何传递给建立在其上的 ISM-MDP。证明单链 MDP 并不蕴含单链 ISM-MDP (??), 而连通 MDP 蕴含连通的 ISM-MDP (??)。利用这些结果, 得出结论: UCRL 不能直接应用于 ISM-MDP, 而 UCRL2 可以。实验分析结束本章, 强调了理论的启示并研究了 λ 对期望折扣回报和平均奖励的影响。

将焦点转向延迟强化学习算法, 我们证明了基于模型的方法可能产生次优策略 (??)。尽管如此, 在 ?? 中, 为平滑 MDPs 中的基于模型方法提供了性能下界保证, 包括非整数延迟情况。值得注意的是, 这些界与理论上界匹配至一个乘法因子 (??)。这些结果表明延迟对性能损失的影响至多是加性的, 这与老虎机文献的结果一致。最后, 将保证扩展到基于模型策略在常值延迟上训练但在随机延迟上测试的情况, 为匿名动作执行延迟产生了强化学习中的首个性能界 (??)。

延迟强化学习算法

在 ?? 中, 引入了新的基于模型的方法——信念表示网络 (belief representation network)。其核心思想分两步学习信念的向量表示。首先, Transformer 网络处理增广状态, 为直到无延迟状态的每个未来状态生成信念的向量表示。其次, 掩码自回归流网络利用该表示拟合未来状态的分布, 以确保该表示确实编码了信念。与学习当前未观测状态某些统计量的先前基于模型方法相比, 信念知识包含更多信息, 使更复杂的策略成为可能。该信念表示可以作为状态的替代直接插入任何强化学习算法, 正如我们将 D-TRPO 方法与 TRPO 结合所做的那样。实验证明该思想是有效的, 并展示了多个延迟可以在单次训练中学习, 从而降低了考虑延迟的成本 (??)。进一步的实验突显了 D-TRPO 适应广泛问题的能力, 特别是随机 Δ MDPs。有趣的是, 实验表明 A-SAC 基线——一种增广方法——在处理延迟方面非常高效 (??)。最后, 展示了 D-TRPO 针对某个延迟学习的策略可以轻松应用于更小的延迟 (??)。

在 ?? 中, 设计了一种简单而有效的算法 DIDA, 该算法在给定增广状态知识的情况下模仿无延迟专家。利用模仿学习文献, 证明了 DAGGER 是执行模仿步骤的合适算法。尽管 DIDA 无法访问当前状态且不能总是完美模仿专家, 但 ?? 为 DIDA 在具有常值延迟的平滑 MDPs 中提供了性能下界保证。该结果也适用于非整数延迟, 而 ?? 为 DIDA 在随机延迟上提供了保证。这意味着 DIDA 适用于广泛的应用场景。这种通用性得到了广泛实验研究的确认。在多种任务中, DIDA 在包括 A-SAC 在内的大量基线中取得了最先进的性能。值得注意的是, DIDA 比这些基线更具样本效率, 且计算成本不高。然而, DIDA 需要知道或训练一个无延迟专家, 这在某些问题中可能是一个限制。

在 ?? 中, 探索了无记忆策略的解决方案。由于智能体对部分状态不可见, 对其而言, 动态本质上是而非平稳的。基于这一观察, 设计了一种能够适应非平稳动态的算法。具体地, 非平稳性出现在回合内部, 使问题更类似于终身学习

(lifelong) 设定。该算法名为 POLIS，其核心思想是在超策略 (hyper-policy) 层面处理非平稳性。超策略以时间为输入，输出在该时间点待查询策略的参数。这样，策略保持平稳，而非平稳性在超策略内部被考虑。为优化其超策略，POLIS 通过多重重要性采样利用过去数据构建未来的估计器，如 ?? 所述。在平滑环境中，估计器偏差有界且可通过参数 ω 控制 (??)。除估计的未来回报外，目标函数中还包含两项。首先，为防止灾难性遗忘，将超策略的过去表现加入目标函数。这样，智能体被激励保持对过去高效行为的记忆。其次，为避免通过学习过度非平稳的超策略而过拟合过去，使用估计器方差的概率上界对目标函数进行正则化 (??)。最后，在 ?? 中，详细说明了如何通过对估计器进行简单修改将 POLIS 应用于延迟过程。实验结果表明，POLIS 能够适应非平稳动态，并在不需要时避免过度的非平稳性。应用于延迟环境时，POLIS 展现出稳健的性能，且随着延迟增加性能自然下降。

广泛的实验评估

我们在广泛的任务和延迟上进行了实验评估，为延迟强化学习算法的特性和能力提供了有用的信息。这些任务包括 Pendulum 环境中的经典控制、迷宫中的路径规划、Mujoco 中的机器人运动等确定性环境 (??、??、??)。还包括 Pendulum 的不同变体，涉及随机延迟 (??、??)、非整数延迟 (??) 或多动作延迟 (??)。还考虑了更现实的环境，如外汇交易 (??、??) 和水资源管理 (??)。

在这些任务上，我们研究了自己的算法以及文献中的许多基线，包括增广状态 TRPO (A-TRPO)、无记忆 TRPO (M-TRPO)、增广状态 SAC (A-SAC)、无记忆 SAC (M-SAC)、SARSA、dSARSA、FQL、Pro-WLS、LPG-FTW 和 UCRL2。

8.2 未来研究方向

在结束本文之前，回顾前面各章提出的一些未来方向。对于基于模型的方法 (如 D-TRPO)，一个有价值的未来方向可能是利用环境模型进行更长期规划的优化。例如，这可用于增强 actor-critic 方法中的值函数估计。对于 DIDA，最大的限制是需要无延迟专家。未来的工作可以考虑从延迟策略收集的数据集中离线学习无延迟专家。这样，与环境的交互将始终在延迟情况下进行。对于 POLIS，可以考虑随机延迟以引入更多的非平稳性来源。在这种情况下，无记忆策略的优势在于其输入是常值的，且维度 $|S|$ “小”。最后，对于 MTD-MDPs，未来的方向可以是利用 MTD 模型参数估计技术 [?] 或奖励结构 [?] 来增强理论强化学习的保证。

希望本文在提供状态观测和动作执行延迟的全局概览以及加深对其理解方面有所助益。我期待强化学习的未来发展——无论在理论上还是应用中——当然，我将特别关注这些发展中延迟问题的处理方式。

8.3 结语

鉴于延迟对性能具有重要的实际影响，以及存在处理延迟的直接机制，我强烈建议读者将延迟考量纳入其强化学习应用中。

补充结果与证明

A.1 ?? 的补充结果

A.1.1 涉及 Wasserstein 距离的界

Proposition A.1.1. 考虑两个实值随机变量 X, Y ，其分布分别为 η, ν 。则有：

$$|\mathbb{E}[X] - \mathbb{E}[Y]| \leq \mathcal{W}_1(\eta \| \nu).$$

Proof. 有,

$$\begin{aligned} \mathbb{E}[X] - \mathbb{E}[Y] &= \int_{\mathbb{R}} x(\eta(x) - \nu(x)) \, dx \\ &\leq \sup_{\|f\|_L \leq 1} \left| \int_{\mathbb{R}} f(x)(\eta(x) - \nu(x)) \, dx \right| \end{aligned} \tag{A.1}$$

$$\leq \mathcal{W}_1(\eta \| \nu), \tag{A.2}$$

其中 ?? 基于恒等函数是 1-LC 的事实，?? 由识别 Wasserstein 距离得到。对 $\mathbb{E}[Y] - \mathbb{E}[X]$ 可进行相同的推理，Wasserstein 距离的对称性即完成证明。 $\square$

下一个结果断言，若将 L -LC 函数应用于两个随机变量，所得两个随机变量的分布之间的 Wasserstein 距离受原始 Wasserstein 距离乘以因子 L 的约束。

Proposition A.1.2. 考虑度量空间 Ω 上的两个概率测度 η 和 ν ，以及 L_f -LC 函数 $f: \Omega \rightarrow \mathbb{R}$ 。对于服从分布 η 的某个随机变量 X ，记 f_η 为 $f(X)$ 的分布。类似定义 f_ν 。则有，

$$\mathcal{W}_1(f_\eta \| f_\nu) \leq L_f \mathcal{W}_1(\eta \| \nu).$$

Proof. 直接证明结果:

$$\mathcal{W}_1(f_\eta \| f_\nu) = \sup_{\|g\|_L \leq 1} \left| \int_{\mathbb{R}} g(x)(f_\eta(x) - f_\nu(x)) dx \right| \quad (\text{A.3})$$

$$\begin{aligned} &= \sup_{\|g\|_L \leq 1} \left| \int_{\mathbb{R}} g(x)f_\eta(x) dx - \int_{\mathbb{R}} g(x)f_\nu(x) dx \right|, \\ &= \sup_{\|g\|_L \leq 1} \left| \int_{\mathbb{R}} g(f(x))\eta(x) dx - \int_{\mathbb{R}} g(f(x))\nu(x) dx \right| \quad (\text{A.4}) \\ &= \sup_{\|g\|_L \leq 1} \left| \int_{\mathbb{R}} g(f(x))(\eta(x) - \nu(x)) dx \right|, \end{aligned}$$

其中 ?? 由 Wasserstein 距离的定义成立, ?? 由 f_η 和 f_ν 的定义成立。结论由观察到 $g(f(x))$ 是 L_f -LC 函数 (因为 1-LC 函数与 L_f -LC 函数的复合) 得到。□

Proposition A.1.3. 设 $\mathcal{M}$ 为一个 MDP, π 为一个策略, 其 Q 函数在第二个参数上是 L_Q -LC 的。则对于 $\mathcal{A}$ 上的任意两个概率分布 η, ν ,

$$\left| \mathbb{E}_{\substack{X \sim \eta \\ Y \sim \nu}} [Q^\pi(s, X) - Q^\pi(s, Y)] \right| \leq L_Q \mathcal{W}_1(\eta(\cdot) \| \nu(\cdot)).$$

Proof. 对于某个 $s \in \mathcal{S}$, 设 $f_\eta(X)$ 和 $f_\nu(X)$ 分别为 $Q^\pi(s, X)$ 和 $Q^\pi(s, Y)$ 的分布。首先, 应用 ?? 得到,

$$\left| \mathbb{E}_{\substack{X \sim \eta \\ Y \sim \nu}} [Q^\pi(s, X) - Q^\pi(s, Y)] \right| \leq \mathcal{W}_1(g_\eta \| g_\nu).$$

然后, 应用 ?? 得到,

$$\mathcal{W}_1(f_\eta \| f_\nu) \leq L_Q \mathcal{W}_1(\eta \| \nu).$$

□

Proposition A.1.4. 设 $\mathcal{M}$ 是一个 (L_P, L_r) -LC MDP。设 $\widetilde{\mathcal{M}}$ 为基于 $\mathcal{M}$ 构建的常值 Δ -延迟 Δ MDP, 其转移函数为 $\tilde{p}$, 奖励函数为 $\tilde{r}$ 。则 $\widetilde{\mathcal{M}}$ 是 $(\max(1, L_P), L_r)$ -LC 的。

Proof. 首先分析奖励函数。设 $x = (s, a_1, \dots, a_\Delta)$ 和 $x' = (s', a'_1, \dots, a'_\Delta)$ 属于 $\mathcal{X}$, $a, a' \in \mathcal{A}$, 有,

$$\begin{aligned} |\tilde{r}(x, a) - \tilde{r}(x', a')| &= |r(s, a_1) - r(s', a'_1)| \\ &\leq L_r (d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a_1, a'_1)) \\ &\leq L_r (d_{\mathcal{X}}(x, x') + d_{\mathcal{A}}(a, a')), \end{aligned}$$

其中使用了 ??。对于转移函数, 为方便起见记 $a_{\Delta+1} = a$ 和 $a'_{\Delta+1} = a'$ 。有,

$$\begin{aligned}
 & \mathcal{W}_1(\tilde{p}(\cdot|x, a_{\Delta+1}) \| \tilde{p}(\cdot|x', a'_{\Delta+1})) \\
 &= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{X}} f(x'') (\tilde{p}(x''|x, a_{\Delta+1}) - \tilde{p}(x''|x', a'_{\Delta+1})) (dx'') \right| \\
 &= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{X}} f(x'') \left[p(s''|s, a_1) \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) - p(s''|s', a'_1) \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) \right] (dx'') \right| \\
 &\leq \sup_{\|f\|_L \leq 1} \left| \underbrace{\int_{\mathcal{X}} f(x'') \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) [p(s''|s, a_1) - p(s''|s', a'_1)] (dx'')}_A \right| \\
 &\quad + \sup_{\|f\|_L \leq 1} \left| \underbrace{\int_{\mathcal{X}} f(x'') p(s''|s', a'_1) \left[\prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) - \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) \right] (dx'')}_B \right|,
 \end{aligned}$$

其中在最后一个不等式中加减了相同量, 并使用记号 $x'' = (s'', a''_1, \dots, a''_{\Delta})$ 。考虑第一项,

$$\begin{aligned}
 A &= \int_{\mathcal{A}^{\Delta}} \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) \int_{\mathcal{S}} f(x'') [p(s''|s, a_1) - p(s''|s', a'_1)] (ds'' da''_1 \dots da''_{\Delta}) \\
 &\leq L_P(d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a_1, a'_1)) \int_{\mathcal{A}^{\Delta}} \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) (da''_1 \dots da''_{\Delta}) \\
 &= L_P(d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a_1, a'_1)),
 \end{aligned}$$

其中利用了 f 在 $\mathcal{X}$ 上是 1-LC 的, 因此 f 在 $\mathcal{S}$ 上也是 1-LC 的。对于另一项, 类似地,

$$\begin{aligned}
 B &= \int_{\mathcal{S}} p(s''|s', a'_1) \int_{\mathcal{A}^{\Delta}} f(x'') \left[\prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) - \prod_{i=1}^{\Delta} \delta_{a_{i+1}}(a''_i) \right] (da''_1 \dots da''_{\Delta} ds'') \\
 &\leq \sum_{i=2}^{\Delta+1} d_{\mathcal{A}}(a_i, a'_i).
 \end{aligned}$$

合并各项, 有,

$$\begin{aligned}
 \mathcal{W}_1(\tilde{p}(\cdot|x, a_{\Delta+1}) \| \tilde{p}(\cdot|x', a'_{\Delta+1})) &\leq L_P(d_{\mathcal{S}}(s, s') + d_{\mathcal{A}}(a_1, a'_1)) + \sum_{i=2}^{\Delta+1} d_{\mathcal{A}}(a_i, a'_i) \\
 &\leq \max(1, L_P)(d_{\mathcal{S}}(x, x') + d_{\mathcal{A}}(a_{\Delta+1}, a'_{\Delta+1}))
 \end{aligned}$$

□

Proposition A.1.5. 设 $\mathcal{M}$ 是一个 (L_T) -TLC MDP。设 $\tilde{\mathcal{M}}$ 为基于 $\mathcal{M}$ 构建的常值 Δ -延迟 Δ MDP。假设 $\tilde{\mathcal{M}}$ 的策略 $\tilde{\pi}$ 满足 ??，其中 π 是 $\mathcal{M}$ 中的 L_π -LC 策略。则 $\tilde{\pi}$ 是 $2\Delta L_\pi L_T$ -LC 的。

Proof. 设 $x = (s, a_1, \dots, a_\Delta)$ 和 $x' = (s', a_1, \dots, a'_\Delta)$ 属于 $\mathcal{X}$ 。

$$\begin{aligned} \mathcal{W}_1(\tilde{\pi}(\cdot|x) \parallel \tilde{\pi}(\cdot|x')) &= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{A}} f(a) \pi(a|s) (b_\Delta(s|x) - b_\Delta(s|x')) (da) \right| \\ &\leq L_\pi \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{S}} f(s) (b_\Delta(s|x) - b_\Delta(s|x')) (ds) \right| \end{aligned} \quad (\text{A.5})$$

$$\leq 2L_\pi L_T, \quad (\text{A.6})$$

其中在 ?? 中使用了 $s \mapsto f(a)\pi(a|s)$ 是 L_π -LC 的，在 ?? 中使用了 ??。 $\square$

A.1.2 对 σ_b^ρ

的界定在本小节中, 提供两种方式来界定来自 ?? 的项 $\sigma_b^\rho = \mathbb{E}_{\substack{x' \sim d_x^{\tilde{\pi}} \\ s, s' \sim b_\Delta(\cdot|x')}} [\text{d}_\mathcal{S}(s, s')]$, 其中 ρ 是 $\mathcal{X}$ 上的分布。对于第一种方式, 假设 $\mathcal{S} \subset \mathbb{R}^n$ 配备了欧几里得范数。

Lemma A.1.1 (欧几里得界). 设 $\mathcal{M}$ 为一个 MDP, 其中 $\mathcal{S} \subset \mathbb{R}^n$ 配备了欧几里得范数。则有,

$$\sigma_b^\rho \leq \sqrt{2} \mathbb{E}_{x' \sim d_\rho^{\tilde{\pi}}(\cdot)} \left[\sqrt{\mathbb{Var}_{s \sim b_\Delta(\cdot|x')} (s|x')} \right],$$

其中 ρ 是 $\mathcal{X}$ 上的分布。

Proof. 证明基于以下步骤,

$$\begin{aligned} \sigma_b^\rho &= \mathbb{E}_{\substack{x' \sim d_\rho^{\tilde{\pi}} \\ s, s' \sim b_\Delta(\cdot|x')}} [\text{d}_\mathcal{S}(s, s')] \\ &= \mathbb{E}_{\substack{x' \sim d_\rho^{\tilde{\pi}} \\ s, s' \sim b_\Delta(\cdot|x')}} \left[\sqrt{(s' - s)^2} \right] \end{aligned} \quad (\text{A.7})$$

$$= \mathbb{E}_{x' \sim d_\rho^{\tilde{\pi}}} \sqrt{\mathbb{E}_{s, s' \sim b_\Delta(\cdot|x')} [(s' - s)^2]} \quad (\text{A.8})$$

$$= \mathbb{E}_{x' \sim d_\rho^{\tilde{\pi}}} \left[\sqrt{\mathbb{Var}_{s \sim b_\Delta(\cdot|x')} (s|x')} \right], \quad (\text{A.9})$$

其中 ?? 显式写出了欧几里得范数, ?? 应用了 Jensen 不等式, ?? 基于如下事实: 若 s' 和 s 是独立同分布的, 则 $\mathbb{E}_{s, s' \sim b_\Delta(\cdot|x')} [(s' - s)^2] = 2 \mathbb{Var}_{s \sim b_\Delta(\cdot|x')} [s]$ 。 $\square$

现在提供第二个结果, 它假设 MDP 是时间-Lipschitz 的 (见 ?? 和 ??)。在提供结果之前, 先证明以下中间结果。

Proposition A.1.6. 设 $\mathcal{M}$ 为一个 L_T -TLC MDP¹。设 $x = (s_1, a_1, \dots, a_\Delta) \in \mathcal{S} \times \mathcal{A}^\Delta$ 为延迟 $\Delta \in \mathbb{R}_{\geq 0}$ 下的增广状态。则有:

$$\mathcal{W}_1(b_\Delta(\cdot|x) \parallel \delta_{s_1}) \leq \Delta L_T$$

¹注意, 由于考虑非整数延迟, 我们在 ?? 中扩展了 TLC 假设。

Proof. 首先证明整数延迟的结果，再证明非整数延迟的结果。

整数延迟。 设 $\Delta \in \mathbb{N}$ 。采用归纳法证明。初始化时，当 $\Delta = 0$ ，结果显然成立，因为当前状态对智能体是已知的。注意 $\Delta = 1$ 由 L_T -TLC 假设成立。对于递推步骤，假设该断言对某个 $\Delta \in \mathbb{N}$ 成立。设 $x = (s_1, a_1, \dots, a_{\Delta+1}) \in \mathcal{S} \times \mathcal{A}^{\Delta+1}$ 。则，

$$\mathcal{W}_1(b_{\Delta+1}(\cdot|x)\|\delta_{s_1}) \quad (\text{A.10})$$

$$= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{S}} f(s') (b_{\Delta+1}(s'|x) - \delta_{s_1}(s')) ds' \right|$$

$$= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{S}} p(s_2|s_1, a_1) \int_{\mathcal{S}} f(s') (b_{\Delta}(s'|s_2, a_2, \dots, a_{\Delta}) - \delta_{s_1}(s')) ds' \right| \quad (\text{A.11})$$

$$= \sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{S}} p(s_2|s_1, a_1) \int_{\mathcal{S}} f(s') (b_{\Delta}(s'|s_2, a_2, \dots, a_{\Delta}) - \delta_{s_2}(s')) ds' \right.$$

$$\left. + \int_{\mathcal{S}} p(s_2|s_1, a_1) \int_{\mathcal{S}} f(s') (\delta_{s_2}(s) - \delta_{s_1}(s')) ds' \right| \quad (\text{A.12})$$

$$\leq \underbrace{\sup_{\|f\|_L \leq 1} \left| \int_{\mathcal{S}} p(s_2|s_1, a_1) \int_{\mathcal{S}} f(s') (b_{\Delta}(s'|s_2, a_2, \dots, a_{\Delta}) - \delta_{s_2}(s')) ds' \right|}_A$$

$$+ \underbrace{\mathcal{W}_1(P(|s_1, a_1)\|\delta_{s_1})}_B,$$

其中 (??) 通过对下一个观测状态 s_2 取条件得到，?? 通过加减相同量 δ_{s_2} 得到。

项 A 可使用 Δ 处的断言进行界定，而 B 直接由 TLC 假设得到。因此有，

$$\mathcal{W}_1(b_{\Delta+1}(\cdot|x)\|\delta_{s_1}) \leq (\Delta + 1)L_T.$$

通过归纳法，证明了该结果对任意 $\Delta \in \mathbb{N}$ 成立。

非整数延迟。 为证明结果在更一般的 $\Delta \in \mathbb{R}_{\geq 0}$ 情况下成立，可以将延迟分解为小数部分 ($\{\Delta\}$) 和整数部分 ($\lfloor \Delta \rfloor$)。应用与之前类似的推理，会得到类似的项 A 和 B ，其中 A 涉及延迟的整数部分 (该断言对其成立)， B 涉及 Δ 的小数部分 (该断言在 ?? 下对其成立)。 $\square$

Lemma A.1.2 (时间-Lipschitz 界). 设 $\mathcal{M}$ 为一个 L_T -TLC MDP。考虑从 $\mathcal{M}$ 获得的 Δ -延迟 Δ MDP $\widetilde{\mathcal{M}}$ ，其中 $\Delta \in \mathbb{R}_{\geq 0}$ 。则，

$$\sigma_b^\rho \leq 2\Delta L_T,$$

其中 ρ 是 $\mathcal{X}$ 上的分布。

Proof. 对于增广状态 x , 设 s_x 为其包含的最近观测状态。则可以写出以下内容,

$$\begin{aligned}\sigma_b^\rho &= \mathbb{E}_{\substack{x \sim d_{\tilde{\rho}} \\ s, s' \sim b_\Delta(\cdot|x)}} [d_S(s, s')] \\ &\leq \mathbb{E}_{\substack{x \sim d_{\tilde{\rho}} \\ s \sim b_\Delta(\cdot|x')}} [d_S(s, s_x)] + \mathbb{E}_{\substack{x \sim d_{\tilde{\rho}} \\ s' \sim b_\Delta(\cdot|x)}} [d_S(s_x, s')] \quad (\text{A.13})\end{aligned}$$

$$\begin{aligned}&= 2 \mathbb{E}_{x \sim d_{\tilde{\rho}}} \left[\int_{\mathcal{S}} d_S(s, s_x) b_\Delta(s|x) ds \right] \\ &= 2 \mathbb{E}_{x \sim d_{\tilde{\rho}}} \left[\int_{\mathcal{S}} d_S(s, s_x) (b_\Delta(s|x) - \delta_{s_x}(s)) ds \right] \quad (\text{A.14})\end{aligned}$$

$$\leq 2 \mathbb{E}_{x \sim d_{\tilde{\rho}}} [\mathcal{W}_1(b_\Delta(\cdot|x) \| \delta_{s_x})], \quad (\text{A.15})$$

其中 ?? 由三角不等式成立; 在 ?? 中添加了 $\int_{\mathcal{S}} d_S(s, s_x) \delta_{s_x}(s) ds = 0$ 项; 在 ?? 中使用了 Wasserstein 距离的定义。为完成证明, 在期望内应用 ??。 $\square$

A.2 ?? 的补充结果

A.2.1 偏差分析

在本小节中, 推导一个比 ?? 中提供的界更紧但表达式更复杂的界。值得注意的是, 该界对 $\omega = 1$ 也成立。

Lemma A.2.1. 在 ?? 和 ?? 下, 对于 $0 < \omega \leq 1$, 估计器 $\hat{J}_{T,\alpha,\beta}(\rho)$ 的偏差可界定为:

$$\begin{aligned}&\left| J_{T,\beta}(\rho) - \mathbb{E}_{T,\alpha}^\rho [\hat{J}_{T,\alpha,\beta}] \right| \\ &\leq (L_{\mathcal{M}} + 2R_{\max}L_\nu) C_\gamma(\beta) \left(\omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^\alpha}{(1-\omega)(1-\omega^\alpha)} + \frac{1}{1-\gamma} \right),\end{aligned}$$

其中 $C_\gamma(\beta)$ 定义如 ??。特别地, 对于 $\omega = 1$, 该界是前式在 $\omega \rightarrow 1$ 时的极限, 为:

$$\left| J_{T,\beta}(\rho) - \mathbb{E}_{T,\alpha}^\rho [\hat{J}_{T,\alpha,\beta}] \right| \leq (L_{\mathcal{M}} + 2R_{\max}L_\nu) C_\gamma(\beta) \left(\frac{\alpha-1}{2} + \frac{1}{1-\gamma} \right).$$

Proof. 回顾 $\hat{J}_{T,\alpha,\beta}(\rho)$ 的定义:

$$\begin{aligned}\mathbb{E}_{T,\alpha}^\rho [\hat{J}_{T,\alpha,\beta}(\rho)] &= \sum_{t=T-\alpha+1}^T \omega^{T-t} \int_{\Theta} \nu_\rho(\theta|t) \frac{\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \nu_\rho(\theta|s)}{\sum_{k=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\theta|k)} \mathbb{E}_t^{\pi_\theta}[r] d\theta \\ &= \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_\rho(\theta|s) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_\rho(\theta|t) \mathbb{E}_t^{\pi_\theta}[r]}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_\rho(\theta|k)} d\theta.\end{aligned}$$

注意到 $J_{T,\beta}(\rho) = \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_{\rho}(\theta|s) \mathbb{E}_s^{\pi_{\theta}}[r] d\theta$ 。因此,

$$\begin{aligned} & \left| \mathbb{E}_{T,\alpha}^{\rho} \left[\hat{J}_{T,\alpha,\beta}(\rho) \right] - J_{T,\beta}(\rho) \right| \\ &= \left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_{\rho}(\theta|s) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) \mathbb{E}_t^{\pi_{\theta}}[r]}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} d\theta \right. \\ & \quad \left. - \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_{\rho}(\theta|s) \mathbb{E}_s^{\pi_{\theta}}[r] d\theta \right| \\ &= \left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_{\rho}(\theta|s) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r])}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} d\theta \right|. \end{aligned}$$

接下来, 在上式最后一项中加入并移除量 $\bar{\nu}(\theta) := \frac{1}{C_{\omega}(\alpha)} \sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)$, 得到:

$$\begin{aligned} & \left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \nu_{\rho}(\theta|s) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r])}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \nu_{\rho}(\theta|k)} d\theta \right| \\ &= \left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} (\nu_{\rho}(\theta|s) \pm \bar{\nu}_{\rho}(\theta)) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r])}{C_{\omega}(\alpha) \bar{\nu}(\rho)} d\theta \right| \\ &\leq \underbrace{\left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \bar{\nu}_{\rho}(\theta) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r])}{C_{\omega}(\alpha) \bar{\nu}(\rho)} d\theta \right|}_{(a)} \\ & \quad + \underbrace{\left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} (\nu_{\rho}(\theta|s) - \bar{\nu}_{\rho}(\theta)) \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r])}{C_{\omega}(\alpha) \bar{\nu}(\rho)} d\theta \right|}_{(b)}. \end{aligned}$$

可以对 (a) 进行如下界定,

$$\begin{aligned} (a) &= \frac{1}{C_{\omega}(\alpha)} \left| \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) (\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r]) d\theta \right| \\ &\leq \frac{1}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} \sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\theta|t) |\mathbb{E}_t^{\pi_{\theta}}[r] - \mathbb{E}_s^{\pi_{\theta}}[r]| d\theta \\ &\leq \frac{L_{\mathcal{M}}}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \sum_{t=T-\alpha+1}^T \omega^{T-t} \int_{\Theta} \nu_{\rho}(\theta|t) |t-s| d\theta \end{aligned} \tag{A.16}$$

$$\leq \frac{L_{\mathcal{M}}}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \sum_{t=T-\alpha+1}^T \omega^{T-t} |t-s|, \tag{A.17}$$

其中在 ?? 中使用了 $\int_{\Theta} \nu_{\rho}(\boldsymbol{\theta}|t) d\boldsymbol{\theta} = 1$ 的事实, 在 ?? 中使用了 ??。接下来处理 (b),

$$\begin{aligned}
 (b) &\leq 2R_{\max} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} |\nu_{\rho}(\boldsymbol{\theta}|s) - \bar{\nu}_{\rho}(\boldsymbol{\theta})| \frac{\sum_{t=T-\alpha+1}^T \omega^{T-t} \nu_{\rho}(\boldsymbol{\theta}|t)}{C_{\omega}(\alpha) \bar{\nu}(\boldsymbol{\rho})} d\boldsymbol{\theta} \\
 &= 2R_{\max} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \int_{\Theta} |\nu_{\rho}(\boldsymbol{\theta}|s) - \bar{\nu}_{\rho}(\boldsymbol{\theta})| d\boldsymbol{\theta} \\
 &\leq 2R_{\max} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} \int_{\Theta} |\nu_{\rho}(\boldsymbol{\theta}|s) - \nu_{\rho}(\boldsymbol{\theta}|t)| d\boldsymbol{\theta} \\
 &\leq \frac{2R_{\max} L_{\nu}}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \sum_{t=T-\alpha+1}^T \omega^{T-t} |t-s|, \tag{A.18}
 \end{aligned}$$

其中在 ?? 中使用了 ??。合并 (a) 和 (b) 得到:

$$\left| J_{T,\beta}(\boldsymbol{\rho}) - \mathbb{E}_{T,\alpha}^{\boldsymbol{\rho}}[\hat{J}_{T,\alpha,\beta}] \right| \leq \frac{L_{\mathcal{M}} + 2R_{\max} L_{\nu}}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \sum_{t=T-\alpha+1}^T \hat{\gamma}^s \omega^{T-t} (s-t).$$

以下推导使用与 [?, Lemma 3.4] 类似的结构。首先, 令 $m = s - T$ 和 $n = T - t$, 得到,

$$\begin{aligned}
 \frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} (s-t) &= \frac{1}{C_{\omega}(\alpha)} \sum_{n=0}^{\alpha-1} \omega^n (m+n) \\
 &= m + \frac{1}{C_{\omega}(\alpha)} \sum_{n=1}^{\alpha-1} \omega^n n. \tag{A.19}
 \end{aligned}$$

现在研究以下两种情况。

- 情况 $\omega < 1$ 。 有,

$$\begin{aligned}
 \frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t} (s-t) &= m + \frac{1}{C_{\omega}(\alpha)} \omega \frac{d}{d\omega} \sum_{n=1}^{\alpha-1} \omega^n \\
 &= m + \frac{1}{C_{\omega}(\alpha)} \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)^2} \\
 &= m + \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})},
 \end{aligned}$$

这给出,

$$\begin{aligned}
 & \left| J_{T,\beta}(\boldsymbol{\rho}) - \mathbb{E}_{T,\alpha}^{\boldsymbol{\rho}} \left[\hat{J}_{T,\alpha,\beta} \right] \right| \\
 & \leq \frac{L_{\mathcal{M}} + 2R_{\max}L_{\nu}}{C_{\omega}(\alpha)} \sum_{s=T+1}^{T+\beta} \sum_{t=T-\alpha+1}^T \hat{\gamma}^s \omega^{T-t}(s-t) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \left(m + \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})} \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \left((s-T) + \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})} \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \left(\frac{1 - \gamma^{\beta}}{1 - \gamma} \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})} + \sum_{k=0}^{\beta-1} \gamma^k(k+1) \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \left(\frac{1 - \gamma^{\beta}}{1 - \gamma} \omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})} + \frac{1 - \gamma^{\beta}}{(1 - \gamma)^2} \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \frac{1 - \gamma^{\beta}}{1 - \gamma} \left(\omega \frac{1 - \alpha\omega^{\alpha-1} + (\alpha-1)\omega^{\alpha}}{(1-\omega)(1-\omega^{\alpha})} + \frac{1}{1 - \gamma} \right).
 \end{aligned}$$

• 情况 $\omega = 1$ 。 此时, ?? 变为:

$$\frac{1}{C_{\omega}(\alpha)} \sum_{t=T-\alpha+1}^T \omega^{T-t}(s-t) = m + \frac{1}{\alpha} \sum_{n=1}^{\alpha-1} n = m + \frac{\alpha-1}{2}.$$

因此, 界变为:

$$\begin{aligned}
 & \left| J_{T,\beta}(\boldsymbol{\rho}) - \mathbb{E}_{T,\alpha}^{\boldsymbol{\rho}} \left[\hat{J}_{T,\alpha,\beta} \right] \right| \leq (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \sum_{s=T+1}^{T+\beta} \hat{\gamma}^s \left(m + \frac{\alpha-1}{2} \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) \left(C_{\gamma}(\beta) \frac{\alpha-1}{2} + \sum_{k=0}^{\beta-1} \gamma^k(k+1) \right) \\
 & = (L_{\mathcal{M}} + 2R_{\max}L_{\nu}) C_{\gamma}(\beta) \left(\frac{\alpha-1}{2} + \frac{1}{1-\gamma} \right).
 \end{aligned}$$

□

A.2.2 关于混合分布之间 Rényi 散度的变分界

在本附录中, 讨论混合分布 $\Psi = \sum_{i=1}^L \zeta_i P_i$ 和 $\Phi = \sum_{j=1}^K \mu_j Q_j$ 之间的 Rényi 散度 $D_{R,\alpha}^{\exp}(\Psi \parallel \Phi)$ 的若干上界, 其中 $\forall i \in \llbracket 1, L \rrbracket, j \in \llbracket 1, K \rrbracket, 0 < \zeta_i, \mu_j < 1$ 且 $\sum_{i=1}^L \zeta_i = \sum_{j=1}^K \mu_j = 1$ 。我们限制在 $\alpha \geq 1$ 的情况。首先, 报告 [?] 中的一个基本结果。

Lemma A.2.2 (Lemma 4, [?]). 考虑变分参数集 $\{\psi_{ij}\}_{(i,j) \in \llbracket 1, L \rrbracket \times \llbracket 1, K \rrbracket}$ 和 $\{\phi_{ij}\}_{(i,j) \in \llbracket 1, L \rrbracket \times \llbracket 1, K \rrbracket}$, 满足 $\phi_{ij}, \psi_{ij} \geq 0$, $\sum_{i=1}^L \psi_{ij} = \mu_j$ 且 $\sum_{j=1}^K \phi_{ij} = \zeta_i$ 。则对于任何 $\alpha \geq 1$ 以及上述

定义的混合分布，有：

$$D_{R,\alpha}^{exp}(\Psi \parallel \Phi) \leq \sum_{i=1}^L \sum_{j=1}^K \phi_{ij}^\alpha \psi_{ij}^{1-\alpha} D_{R,\alpha}^{exp}(P_i \parallel Q_j)^{\alpha-1}. \quad (\text{A.20})$$

寻找最紧的上界相当于找到使 ?? 最小化的 $\{\psi_{ij}\}$ 和 $\{\phi_{ij}\}$ 的值。一个直接但不成功的选择是均匀值。下面，我们推导六种替代方法用于选择 $\{\psi_{ij}\}$ 和 $\{\phi_{ij}\}$ ，以获得更紧的界。最后，在一个玩具问题上比较这些可能的界，以选择最佳的一个。

直接凸优化

在各自的约束下，最小化 ?? (其中 $\phi_{ij} \geq 0$ 和 $\psi_{ij} \geq 0$) 的问题是凸的。因此，可以采用相当直接的方法，使用梯度下降法来优化这些变分参数。

带重置。第一种方法是先从变分参数的均匀分布开始，然后连续多步沿着梯度方向更新。每当 POLIS 需要对 Rényi 散度进行界定时，都需要应用相同的过程。我们将此方法称为带重置的直接优化。

无重置。第二个想法也是连续多步沿着梯度方向更新，但从先前变分参数的值而非均匀分布开始。更具体地说，每次 POLIS 需要对 Rényi 散度进行界定时，前一次界的变分参数被用作新优化问题的起点。我们将此方法称为无重置的直接优化。

两步最小化

每次需要上界时都必须求解优化问题，这并不令人满意。在本节中，提出基于以下定理的替代推导。

Theorem A.2.1 (Theorem 5, [?]). 考虑概率分布 P 和之前的混合分布 Φ ，则对于任何 $\alpha \geq 1$ ，有：

$$D_{R,\alpha}^{exp}(P \parallel \Phi) \leq \frac{1}{\sum_{j=1}^K \frac{\mu_j}{D_{R,\alpha}^{exp}(P \parallel Q_j)}}.$$

注意该界涉及 P 与混合分量之间 Rényi 散度的调和均值。类似地，为 $D_{R,\alpha}^{exp}(\Psi \parallel Q)$ 推导一个界，其中 Ψ 是混合分布。

Proposition A.2.1. 设 Q 为一个概率测度，考虑之前的混合分布 Ψ ，则对于任何 $\alpha \geq 1$ ，有：

$$D_{R,\alpha}^{exp}(\Psi \parallel Q) \leq \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{exp}(P_i \parallel Q)^{\frac{\alpha-1}{\alpha}} \right)^{\frac{\alpha}{\alpha-1}}.$$

Proof. 根据 [?]，由于 ?? 关于 $\{\psi_i\}$ 是凸的，可以使用拉格朗日乘子法找到 $\{\psi_i\}$ 的最优值，

$$\psi_i = \frac{\zeta_i D_{R,\alpha}^{exp}(P_i \parallel Q)^{\frac{\alpha-1}{\alpha}}}{\sum_{i=1}^L \zeta_i D_{R,\alpha}^{exp}(P_i \parallel Q)^{\frac{\alpha-1}{\alpha}}}.$$

将该值代入原问题得到,

$$\begin{aligned}
 D_{R,\alpha}^{\exp}(\Psi \| Q)^{\alpha-1} &\leq \sum_{i=1}^L \zeta_i^\alpha \left(\frac{\zeta_i D_{R,\alpha}^{\exp}(P_i \| Q)^{\frac{\alpha-1}{\alpha}}}{\sum_{l=1}^L \zeta_l D_{R,\alpha}^{\exp}(P_l \| Q)^{\frac{\alpha-1}{\alpha}}} \right)^{1-\alpha} D_{R,\alpha}^{\exp}(P_i \| Q)^{\alpha-1} \\
 &= \sum_{i=1}^L \zeta_i \frac{D_{R,\alpha}^{\exp}(P_i \| Q)^{(1-\alpha)\frac{\alpha-1}{\alpha} + \alpha-1}}{\left(\sum_{l=1}^L \zeta_l D_{R,\alpha}^{\exp}(P_l \| Q)^{\frac{\alpha-1}{\alpha}} \right)^{1-\alpha}} \\
 &= \frac{\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \| Q)^{\frac{\alpha-1}{\alpha}}}{\left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \| Q)^{\frac{\alpha-1}{\alpha}} \right)^{1-\alpha}} \\
 &= \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \| Q)^{\frac{\alpha-1}{\alpha}} \right)^\alpha.
 \end{aligned}$$

□

特别地, 与 ?? 相比, 该界现在涉及 Q 与混合元素之间 Rényi 散度的指数 $\frac{\alpha-1}{\alpha}$ 的加权幂均值。现在, 可以组合 ?? 和 ?? 来寻找 $D_{R,\alpha}^{\exp}(\Psi \| \Phi)$ 的界。根据先应用哪个结果, 得到不同的界。

两步 ψ 优先。 先应用 ?? 再应用 ?? 得到以下界, 我们称之为两步 ψ 优先。

Proposition A.2.2. 在 ?? 的假设下, 有:

$$\begin{aligned}
 D_{R,\alpha}^{\exp}(\Psi \| \Phi) &\leq \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \| \Psi)^{\frac{\alpha-1}{\alpha}} \right)^{\frac{\alpha}{\alpha-1}} \\
 &\leq \left(\sum_{i=1}^L \zeta_i \frac{1}{\left(\sum_{j=1}^K \frac{\mu_j}{D_{R,\alpha}^{\exp}(P_i \| Q_j)} \right)^{\frac{\alpha-1}{\alpha}}} \right)^{\frac{\alpha}{\alpha-1}}.
 \end{aligned}$$

Lemma ??. ?? 中混合之间的散度可以界为:

$$\begin{aligned}
 D_R^{\exp} \left(\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{C_\gamma(\beta)} \nu_\rho(\cdot|s) \right) &\left\| \sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_\omega(\alpha)} \nu_\rho(\cdot|t) \right\| \\
 &\leq \frac{C_\omega(\alpha)}{C_\gamma(\beta)^2} \underbrace{\left(\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{\left(\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{D_R^{\exp}(\nu_\rho(\cdot|s) \| \nu_\rho(\cdot|t))} \right)^{\frac{1}{2}}} \right)^2}_{B_{T,\alpha,\beta}(\rho)}.
 \end{aligned}$$

Proof. 结果通过将 $\alpha = 2$ 的 ?? 应用于混合分布 $\sum_{s=T+1}^{T+\beta} \frac{\hat{\gamma}^s}{C_\gamma(\beta)} \nu_\rho(\cdot|s)$ 和 $\sum_{t=T-\alpha+1}^T \frac{\omega^{T-t}}{C_\omega(\alpha)} \nu_\rho(\cdot|t)$ 得到。□

两步 ϕ 优先。 另一种方式, 先应用 ?? 再应用 ?? 得到以下界, 称之为两步 ϕ 优先。

Proposition A.2.3. 在 ?? 的假设下，

$$\begin{aligned} D_{R,\alpha}^{\exp}(\Psi \parallel \Phi) &\leq \frac{1}{\sum_{j=1}^K \frac{\mu_j}{D_{R,\alpha}^{\exp}(\Psi \parallel Q_j)}} \\ &\leq \frac{1}{\sum_{j=1}^K \mu_j \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i \parallel Q_j)^{\frac{\alpha-1}{\alpha}} \right)^{-\frac{\alpha}{\alpha-1}}}. \end{aligned}$$

将此结果应用于 ?? 得到以下结果。

Proposition A.2.4 (使用两步 ϕ 优先的下界). 对于 $\delta > 0$ ，以至少 $1 - \delta$ 的概率，有

$$\begin{aligned} \mathbb{E} [\bar{J}_{T,\alpha,\beta}] &\geq \bar{J}_{T,\alpha,\beta} - \sqrt{\frac{1-\delta}{\delta} 2R_{\max}} \\ &\cdot \sqrt{C_\gamma(\alpha)^2 + \frac{C_\omega(\alpha)}{\sum_{k=T-\alpha+1}^T \omega^{T-k} \left(\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s d_2(\nu_\rho(\cdot|s) \parallel \nu_\rho(\cdot|k))^{\frac{1}{2}} \right)^{-2}}}. \end{aligned}$$

一步后均匀化

在本节中，探索将一组变分参数表示为另一组的函数，然后再将其值代入 ?? 的可能性。在下一个命题中，给出 $\{\psi_{ij}\}_{(i,j) \in [1,L] \times [1,K]}$ 关于 $\{\phi_{ij}\}_{(i,j) \in [1,L] \times [1,K]}$ 的表达式，反之亦然。

Proposition A.2.5. 在与 ?? 相同的假设下， ψ_{ij} 的最优值为

$$\psi_{ij} = \mu_j \frac{\phi_{ij} D_{R,\alpha}^{\exp}(P_i \parallel Q_j)^{\frac{\alpha-1}{\alpha}}}{\sum_{l=1}^L \phi_{lj} D_{R,\alpha}^{\exp}(P_l \parallel Q_j)^{\frac{\alpha-1}{\alpha}}}; \quad (\text{A.21})$$

ϕ_{ij} 的最优值为

$$\phi_{ij} = \frac{\zeta_i \psi_{ij}}{D_{R,\alpha}^{\exp}(P_i \parallel Q_j)} \left(\sum_{k=1}^K \frac{\psi_{ik}}{D_{R,\alpha}^{\exp}(P_i \parallel Q_k)} \right)^{-1}. \quad (\text{A.22})$$

Proof. 由 ?? 可知，

$$D_{R,\alpha}^{\exp}(\Psi \parallel \Phi)^{\alpha-1} \leq \sum_{i=1}^L \sum_{j=1}^K \phi_{ij}^\alpha \psi_{ij}^{1-\alpha} D_{R,\alpha}^{\exp}(P_i \parallel Q_j)^{\alpha-1}.$$

该问题的拉格朗日函数为：

$$\mathcal{L}(\phi_{ij}, \psi_{ij}, \lambda_i^\zeta, \lambda_j^\mu) = \sum_{i=1}^L \sum_{j=1}^K \phi_{ij}^\alpha \psi_{ij}^{1-\alpha} D_{R,\alpha}^{\exp}(P_i \parallel Q_j)^{\alpha-1} - \sum_{i=1}^L \lambda_i^\zeta \left(\sum_{j=1}^K \phi_{ij} - \zeta_i \right) - \sum_{j=1}^K \lambda_j^\mu \left(\sum_{i=1}^L \psi_{ij} - \mu_j \right).$$

对变分变量求导并令其为零得到，

$$\frac{\partial \mathcal{L}}{\partial \phi_{ij}} = \alpha \phi_{ij}^{\alpha-1} \psi_{ij}^{1-\alpha} D_{R,\alpha}^{\exp}(P_i \parallel Q_j)^{\alpha-1} - \lambda_i^\zeta = 0.$$

这意味着：

$$\phi_{ij} = \frac{\lambda_i^{\zeta \frac{1}{\alpha-1}} \psi_{ij}}{\alpha^{\frac{1}{\alpha-1}} D_{R,\alpha}^{\exp}(P_i \| Q_j)}.$$

回顾 $\sum_j \phi_{ij} = \zeta_i$ ，所以：

$$\left(\frac{\lambda_i^{\zeta}}{\alpha} \right)^{\frac{1}{\alpha-1}} \sum_{k=1}^K \frac{\psi_{ik}}{D_{R,\alpha}^{\exp}(P_i \| Q_k)} = \zeta_i.$$

这给出了 λ_i^{ζ} 的值：

$$\lambda_i^{\zeta} = \frac{\alpha \zeta_i^{\alpha-1}}{\left(\sum_{k=1}^K \frac{\psi_{ik}}{D_{R,\alpha}^{\exp}(P_i \| Q_k)} \right)^{\alpha-1}}.$$

最后，代入得到，

$$\phi_{ij} = \frac{\zeta_i \psi_{ij}}{D_{R,\alpha}^{\exp}(P_i \| Q_j)} \left(\sum_{k=1}^K \frac{\psi_{ik}}{D_{R,\alpha}^{\exp}(P_i \| Q_k)} \right)^{-1}.$$

对 ψ_{ij} 做相同处理：

$$\frac{\partial \mathcal{L}}{\partial \psi_{ij}} = (1 - \alpha) \psi_{ij}^{\alpha} \psi_{ij}^{-\alpha} D_{R,\alpha}^{\exp}(P_i \| Q_j)^{\alpha-1} - \lambda_j^{\mu} = 0.$$

这意味着

$$\psi_{ij} = \left(\frac{1 - \alpha}{\lambda_j^{\mu}} \right)^{\frac{1}{\alpha}} \phi_{ij} D_{R,\alpha}^{\exp}(P_i \| Q_j)^{\frac{\alpha-1}{\alpha}}.$$

回顾 $\sum_i \psi_{ij} = \beta_j$ ，所以：

$$\left(\frac{1 - \alpha}{\lambda_j^{\mu}} \right)^{\frac{1}{\alpha}} \sum_{l=1}^L \phi_{lj} D_{R,\alpha}^{\exp}(P_l \| Q_j)^{\frac{\alpha-1}{\alpha}} = \mu_j.$$

这给出了 λ_j^{β} 的值：

$$\lambda_j^{\beta} = \frac{1 - \alpha}{\mu_j^{\alpha}} \left(\sum_{l=1}^L \phi_{lj} D_{R,\alpha}^{\exp}(P_l \| Q_j)^{\frac{\alpha-1}{\alpha}} \right)^{\alpha}.$$

最后，代入得到，

$$\psi_{ij} = \mu_j \frac{\phi_{ij} D_{R,\alpha}^{\exp}(P_i \| Q_j)^{\frac{\alpha-1}{\alpha}}}{\sum_{l=1}^L \phi_{lj} D_{R,\alpha}^{\exp}(P_l \| Q_j)^{\frac{\alpha-1}{\alpha}}}.$$

□

均匀 ψ . 在本节中, 通过利用 ?? 中 ϕ_{ij} 的最优值并将其代入 ??, 提出 ?? 的一个上界。然后将参数 ψ_{ij} 设置为均匀值。该界如下所示, 称为均匀 ψ 。

Proposition A.2.6. 在 ?? 的假设下, 有

$$D_{R,\alpha}^{\exp}(\Psi|\Phi) \leq \sum_{i=1}^L \frac{\zeta_i^\alpha}{L^{1-\alpha}} \left(\sum_{j=1}^K \frac{\mu_j}{D_{R,\alpha}^{\exp}(P_i\|Q_j)} \right)^{1-\alpha}.$$

Proof. 将 ?? 代入 ?? 得到,

$$\begin{aligned} D_{R,\alpha}^{\exp}(\Psi|\Phi) &\leq \sum_{i=1}^L \sum_{j=1}^K \zeta_i^\alpha \frac{\psi_{ij}}{D_{R,\alpha}^{\exp}(P_i\|Q_j)} \left(\sum_{k=1}^K \frac{\psi_{ik}}{D_{R,\alpha}^{\exp}(P_i\|Q_k)} \right)^{-\alpha} \\ &= \sum_{i=1}^L \zeta_i^\alpha \left(\sum_{j=1}^K \frac{\psi_{ij}}{D_{R,\alpha}^{\exp}(P_i\|Q_j)} \right)^{1-\alpha}. \end{aligned}$$

然后, 回顾约束 $\psi_{ij} \geq 0$ 和 $\sum_{i=1}^L \psi_{ij} = \mu_j$, 设置 $\psi_{ij} = \frac{\mu_j}{L}$ 满足这些约束并得到结果。 $\square$

与之前的界一样, 将此结果应用于 ?? 得到以下结果。

Proposition A.2.7 (使用均匀 ψ 的下界). 对于 $\delta > 0$, 以至少 $1 - \delta$ 的概率, 有

$$\begin{aligned} \mathbb{E} [\bar{J}_{T,\alpha,\beta}] &\geq \bar{J}_{T,\alpha,\beta} - \sqrt{\frac{1-\delta}{\delta} 2R_{\max}} \\ &\quad \sqrt{C_\gamma(\alpha)^2 + \beta C_\omega(\alpha) \sum_{s=T+1}^{T+\beta} \hat{\gamma}^{2s} \left(\sum_{k=T-\alpha+1}^T \frac{\omega^{T-k}}{d_2(\nu_\rho(\cdot|s)\|\nu_\rho(\cdot|k))} \right)^{-1}}. \end{aligned}$$

均匀 ϕ .

与之前的界类似, 利用 ?? 中 ψ_{ij} 的最优值并将其代入 ??。然后将参数 ϕ_{ij} 设置为均匀值。该界如下所示, 称为均匀 ϕ 。

Proposition A.2.8. 在 ?? 的假设下, 有

$$D_{R,\alpha}^{\exp}(\Psi|\Phi) \leq \sum_{j=1}^K \frac{\mu_j^{1-\alpha}}{K^\alpha} \left(\sum_{i=1}^L \zeta_i D_{R,\alpha}^{\exp}(P_i\|Q_j)^{\frac{\alpha-1}{\alpha}} \right)^\alpha.$$

Proof. 将 ?? 代入 ?? 得到,

$$\begin{aligned} D_{R,\alpha}^{\exp}(\Psi|\Phi) &\leq \sum_{i=1}^L \sum_{j=1}^K \mu_j^{1-\alpha} \frac{\phi_{ij} D_{R,\alpha}^{\exp}(P_i\|Q_j)^{\frac{\alpha-1}{\alpha}}}{\left(\sum_{l=1}^L \phi_{lj} D_{R,\alpha}^{\exp}(P_l\|Q_j)^{\frac{\alpha-1}{\alpha}} \right)^{1-\alpha}} \\ &= \sum_{j=1}^K \mu_j^{1-\alpha} \left(\sum_{i=1}^L \phi_{ij} D_{R,\alpha}^{\exp}(P_i\|Q_j)^{\frac{\alpha-1}{\alpha}} \right)^\alpha. \end{aligned}$$

然后，回顾约束 $\phi_{ij} \geq 0$ 和 $\sum_{j=1}^K \phi_{ij} = \zeta_i$ ，设置 $\phi_{ij} = \frac{\zeta_i}{K}$ 满足这些约束并得到结果。□

与之前的界一样，将此结果应用于 ?? 得到以下结果。

Proposition A.2.9 (使用均匀 ϕ 的下界). 对于 $\delta > 0$ ，以至少 $1 - \delta$ 的概率，有

$$\mathbb{E} [\bar{J}_{T,\alpha,\beta}] \geq \bar{J}_{T,\alpha,\beta} - \sqrt{\frac{1-\delta}{\delta} 2R_{\max}} \sqrt{C_\gamma(\alpha)^2 + \frac{C_\omega(\alpha)}{\alpha^2} \sum_{k=T-\alpha+1}^T \frac{1}{\omega^{T-k}} \left(\sum_{s=T+1}^{T+\beta} \hat{\gamma}^s d_2(\nu_\rho(\cdot|s) \|\nu_\rho(\cdot|k))^{\frac{1}{2}} \right)^2}.$$

界的比较

我们使用不同方法推导了 $\bar{J}_{T,\alpha,\beta}(\rho)$ 的 6 种界。在本节中，探索哪个结果提供最紧的界，从而将在实践中使用。回顾该界的目标是对策略进行正则化，以避免额外的非平稳性。因此，期望候选界的优化能产生平稳分布。

基于此，设计以下测试。考虑以下正弦超策略：

$$\nu(t) = \theta_t = A \sin(\phi t + \psi) + B.$$

这个简单的超策略具有通过尺度参数 A 清晰衡量非平稳性的优势。因此，如前所述，优化候选下界应该将 A 推向 0。在此测试中，仅对方差界进行优化，环境不相关。但为了完整性，报告环境是一个上下文老虎机，其中上下文也遵循正弦函数。

从 ?? 可以看出，使超策略平稳（从而将 A 推向 0）的最有效方法是均匀 Ψ 、两步 Ψ 优先、两步 Φ 优先和带重置的直接优化。

从 ?? 报告的结果可以看出，基于凸优化的方法的上界（右图）更粗糙。第二个观察结果是均匀 Ψ 和两步 Ψ 优先的上界更紧，并且参数 A 向 0 收敛也更快。这些界有相似之处，但需要做出选择以提供替代目标。我们选择两步 Ψ 优先，因为相信它可能更通用。实际上，如均匀 Ψ 那样使用均匀分布来设置某些变分参数似乎在某些场景下不够鲁棒。

A.2.3 实验细节

数据集

此处提供交易 (Trading) 和大坝 (Dam) 任务中涉及过程的更多细节。对于大坝任务，三种平均入流如 ?? 所示。还提供了该环境中计算总成本的权重。对于洪水和未满足需求，第一个入流分布的成本分别为 0.3 和 0.7；第二个入流分布为 0.8 和 0.2；第三个入流分布为 0.35 和 0.65。对于交易任务，EUR-USD 货币对的历史值见 ??。

Appendix A. 补充结果与证明




Figure A.1: 左图：方差上界的几种方法的尺度参数演变。注意 两步 Ψ 优先 和 均匀 Ψ 的 A 值是混叠的。
右图：方差的变分上界在几种方法下的演变。这里同样，两步 Ψ 优先 和 均匀 Ψ 的对数上界是混叠的。

“CO” 表示凸优化 (convex optimisation)。





Figure A.2: 大坝实验考虑的三种入流分布。



数据集 2009-2012。

数据集 2013-2016。

数据集 2017-2020。

Figure A.4: 2009-2020 年间 EUR-USD 货币对的历史汇率，分为三个数据集。

List of Figures

List of Tables

Bibliography

- [AA21] Mridul Agarwal and Vaneet Aggarwal. Blind decision making: Reinforcement learning with delayed observations. *Pattern Recognition Letters*, 150:176–182, 2021.
- [ABS99] Eitan Altman, Tamer Başar, and R Srikant. Congestion control as a stochastic control problem with action delays. *Automatica*, 35(12):1937–1950, 1999.
- [ACBF02] Peter Auer, Nicolo Cesa-Bianchi, and Paul Fischer. Finite-time analysis of the multiarmed bandit problem. *Machine learning*, 47(2):235–256, 2002.
- [AD88] SR Adke and SR Deshmukh. Limit distribution of a high order markov chain. *Journal of the Royal Statistical Society: Series B (Methodological)*, 50(1):105–108, 1988.
- [AHA03] Omar Ait-Hellal and Eitan Altman. Stability of abr congestion control using the theory of delayed differential equations. *International Journal of Systems Science*, 34(10-11):575–584, 2003.
- [AJO08] Peter Auer, Thomas Jaksch, and Ronald Ortner. Near-optimal regret bounds for reinforcement learning. *Advances in neural information processing systems*, 21, 2008.
- [AKS09] Eitan Altman, Vijay Kambly, and Alonso Silva. Stochastic games with one step delay sharing information pattern with application to power control. In *2009 International Conference on Game Theory for Networks*, pages 124–129. IEEE, 2009.
- [AMGW⁺19] Jose A Arjona-Medina, Michael Gillhofer, Michael Widrich, Thomas Unterthiner, Johannes Brandstetter, and Sepp Hochreiter. Rudder: Return decomposition for delayed rewards. *Advances in Neural Information Processing Systems*, 32, 2019.
- [AN92] Eitan Altman and Philippe Nain. Closed-loop control with delayed information. *ACM sigmetrics performance evaluation review*, 20(1):193–204, 1992.
- [AO06] Peter Auer and Ronald Ortner. Logarithmic online regret bounds for undiscounted reinforcement learning. *Advances in neural information processing systems*, 19, 2006.
- [AS73] G Alevisakis and DE Seborg. An extension of the smith predictor method to multivariable linear systems containing time delays. *International Journal of Control*, 17(3):541–551, 1973.
- [ASBB⁺18] Maruan Al-Shedivat, Trapit Bansal, Yura Burda, Ilya Sutskever, Igor Mordatch, and Pieter Abbeel. Continuous adaptation via meta-learning in nonstationary and competitive environments. In *International Conference on Learning Representations (ICLR)*, 2018.
- [BCB14] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014.
- [BCDS10] Fawzi P Bayan, Anthony D Cornetto, Ashley Dunn, and Eric Sauer. Brake timing measurements for a tractor-semitrailer under emergency braking. *SAE International Journal of Commercial Vehicles*, 2(2):245–255, 2010.
- [BCP⁺16] Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. Openai gym, 2016.

Bibliography

- [Bel54] Richard Bellman. The theory of dynamic programming. *Bulletin of the American Mathematical Society*, 60(6):503–515, 1954.
- [Bel66] Richard Bellman. Dynamic programming. *Science*, 153(3731):34–37, 1966.
- [Ber87] Dimitri P Bertsekas. *Dynamic Programming: Determinist. and Stochast. Models*. Prentice-Hall, 1987.
- [Ber96] André Berchtold. Modélisation autorégressive des chaînes de markov: Utilisation d’une matrice différente pour chaque retard. *Revue de statistique appliquée*, 44(3):5–25, 1996.
- [BL72] DM Brooks and Cornelius T Leondes. Markov decision processes with state-information lag. *Operations Research*, 20(4):904–907, 1972.
- [BLS⁺20] Lorenzo Bisi, Pierre Liotet, Luca Sabbioni, Gianmarco Reho, Nico Montali, Marcello Restelli, and Cristiana Corno. Foreign exchange trading: A risk-averse batch reinforcement learning approach. In *Proceedings of the First ACM International Conference on AI in Finance*, pages 1–8, 2020.
- [Bow74] Bruce Bowerman. *Nonstationary Markov decision processes and related topics in nonstationary Markov chains*. PhD thesis, Iowa State University, 1974.
- [BR02] André Berchtold and Adrian Raftery. The mixture transition distribution model for high-order markov chains and non-gaussian time series. *Statistical Science*, 17(3):328–356, 2002.
- [BRB⁺20] Yann Bouteiller, Simon Ramstedt, Giovanni Beltrame, Christopher Pal, and Jonathan Binas. Reinforcement learning with random delays. In *International Conference on Learning Representations (ICLR)*, 2020.
- [BS95] Michael Bain and Claude Sammut. A framework for behavioural cloning. In *Machine Intelligence 15*, pages 103–129, 1995.
- [CBL06] Nicolo Cesa-Bianchi and Gábor Lugosi. *Prediction, learning, and games*. Cambridge university press, 2006.
- [CCML18] Kurtland Chua, Roberto Calandra, Rowan McAllister, and Sergey Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *Advances in neural information processing systems*, 31, 2018.
- [CG16] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794, 2016.
- [CGRSS10] A Castelletti, Stefano Galelli, Marcello Restelli, and Rodolfo Soncini-Sessa. Tree-based reinforcement learning for optimal water reservoir operation. *Water Resources Research*, 46(9), 2010.
- [CGS16] Jeffrey S Campbell, Sidney N Givigi, and Howard M Schwartz. Multiple model q-learning for stochastic asynchronous rewards. *Journal of Intelligent & Robotic Systems*, 81(3):407–422, 2016.
- [CL18] Zhiyuan Chen and Bing Liu. Lifelong machine learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning*, 12(3):1–207, 2018.
- [CLL95] LL Chung, CC Lin, and KH Lu. Time-delay control of structures. *Earthquake Engineering & Structural Dynamics*, 24(5):687–701, 1995.
- [CS15] Wouter Caarls and Erik Schuitema. Parallel online temporal difference learning for motor control. *IEEE transactions on neural networks and learning systems*, 27(7):1457–1468, 2015.
- [CT91] Thomas M Cover and Joy A Thomas. Information theory and statistics. *Elements of information theory*, 1(1):279–335, 1991.
- [CTS⁺20] Yash Chandak, Georgios Theodorou, Shiv Shankar, Sridhar Mahadevan, Martha White, and Philip S Thomas. Optimizing for the future in non-stationary mdps. *ICML 2020*, 2020.
- [CXLZ21] Baiming Chen, Mengdi Xu, Liang Li, and Ding Zhao. Delay-aware model-based reinforcement learning for continuous control. *Neurocomputing*, 450:119–128, 2021.

- [CYZ00] Samuel PM Choi, Dit-Yan Yeung, and Nevin L Zhang. Hidden-mode markov decision processes for nonstationary sequential decision making. In *Sequence Learning*, pages 264–287. Springer, 2000.
- [DCLT18] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- [DDM21] Esther Derman, Gal Dalal, and Shie Mannor. Acting in delayed environments with non-stationary markov policies. *arXiv preprint arXiv:2101.11992*, 2021.
- [DFB⁺22] Jonas Degraeve, Federico Felici, Jonas Buchli, Michael Neunert, Brendan Tracey, Francesco Carpanese, Timo Ewalds, Roland Hafner, Abbas Abdolmaleki, Diego de Las Casas, et al. Magnetic control of tokamak plasmas through deep reinforcement learning. *Nature*, 602(7897):414–419, 2022.
- [DNP13] Marc Peter Deisenroth, Gerhard Neumann, and Jan Peters. A survey on policy search for robotics. *Foundations and Trends in Robotics*, 2(1-2), 2013.
- [dSBBE06] Bruno C. da Silva, Eduardo W. Basso, Ana L. C. Bazzan, and Paulo M. Engel. Dealing with non-stationary environments using context detection. In *ICML 2006*, 2006.
- [DV98] Luc Dugard and Erik I Verriest. *Stability and control of time-delay systems*, volume 228. Springer, 1998.
- [DVDV91] Russell L De Valois and Karen K De Valois. Vernier acuity with stationary moving gabors. *Vision research*, 31(9):1619–1626, 1991.
- [EGW05] Damien Ernst, Pierre Geurts, and Louis Wehenkel. Tree-based batch mode reinforcement learning. *Journal of Machine Learning Research*, 6(Apr):503–556, 2005.
- [ESM⁺18] Lasse Espeholt, Hubert Soyer, Remi Munos, Karen Simonyan, Vlad Mnih, Tom Ward, Yotam Doron, Vlad Firoiu, Tim Harley, Iain Dunning, et al. Impala: Scalable distributed deep-rl with importance weighted actor-learner architectures. In *International conference on machine learning*, pages 1407–1416. PMLR, 2018.
- [FJT18] Vlad Firoiu, Tina Ju, and Josh Tenenbaum. At human speed: Deep reinforcement learning with action delay. *arXiv preprint arXiv:1810.07286*, 2018.
- [FLBPP19] Vincent Francois-Lavet, Yoshua Bengio, Doina Precup, and Joelle Pineau. Combined reinforcement learning via abstract representations. In *AAAI 2019*, 2019.
- [Fre99] Robert M French. Catastrophic forgetting in connectionist networks. *Trends in cognitive sciences*, 3(4):128–135, 1999.
- [Fri14] Emilia Fridman. *Introduction to time-delay systems: Analysis and control*. Springer, 2014.
- [G⁺15] Mathieu Germain et al. Made: Masked autoencoder for distribution estimation. In *International Conference on Machine Learning*, pages 881–889, 2015.
- [GAACR19] Yaobang Gong, Mohamed Abdel-Aty, Qing Cai, and Md Sharikur Rahman. Decentralized network level adaptive signal control by multi-agent deep reinforcement learning. *Transportation Research Interdisciplinary Perspectives*, 1:100020, 2019.
- [GBC16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep learning*. MIT press, 2016.
- [GCC⁺19] Thomas L Griffiths, Frederick Callaway, Michael B Chang, Erin Grant, Paul M Krueger, and Falk Lieder. Doing more with less: meta-reasoning and meta-learning in humans and machines. *Current Opinion in Behavioral Sciences*, 29:24–30, 2019. Artificial Intelligence.
- [GEW06] Pierre Geurts, Damien Ernst, and Louis Wehenkel. Extremely randomized trees. *Machine learning*, 63(1):3–42, 2006.
- [GN03] Keqin Gu and Silviu-Iulian Niculescu. Survey on recent results in the stability and control of time-delay systems. *J. Dyn. Sys., Meas., Control*, 125(2):158–165, 2003.
- [GPAM⁺14] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. *Advances in neural information processing systems*, 27, 2014.
- [GS00] Alfredo Garcia and Robert L. Smith. Solving nonstationary infinite horizon stochastic production planning problems. *Oper. Res. Lett.*, 27(3), 2000.

Bibliography

- [GS13] Archis Ghate and Robert L. Smith. A linear programming approach to nonstationary infinite-horizon markov decision processes. *Oper. Res.*, 61(2):413–425, 2013.
- [Hau00] Milos Hauskrecht. Value-function approximations for partially observable markov decision processes. *Journal of artificial intelligence research*, 13:33–94, 2000.
- [HBW14] Emmanuel Hadoux, Aurélie Beynier, and Paul Weng. Sequential decision-making under non-stationary environments via sequential change-point detection. In *Learning over multiple contexts (LMCE)*, 2014.
- [HCS⁺22] Jonathan Ho, William Chan, Chitwan Saharia, Jay Whang, Ruiqi Gao, Alexey Gritsenko, Diederik P. Kingma, Ben Poole, Mohammad Norouzi, David J. Fleet, and Tim Salimans. Image video: High definition video generation with diffusion models, 2022.
- [HDCM15] Assaf Hallak, Dotan Di Castro, and Shie Mannor. Contextual markov decision processes. *arXiv preprint arXiv:1502.02259*, 2015.
- [HHZ⁺18] Tuomas Haarnoja, Sehoon Ha, Aurick Zhou, Jie Tan, George Tucker, and Sergey Levine. Learning to walk via deep reinforcement learning. *arXiv preprint arXiv:1812.11103*, 2018.
- [HM82] Kai Hsu and Steven Marcus. Decentralized control of finite state markov processes. *IEEE Transactions on Automatic Control*, 27(2):426–431, 1982.
- [How60] Ronald A. Howard. *Dynamic Programming and Markov Processes*. MIT Press, Cambridge, MA, 1960.
- [HPBF21] Benjamin Howson, Ciara Pike-Burke, and Sarah Filippi. Delayed feedback in episodic reinforcement learning. *arXiv preprint arXiv:2111.07615*, 2021.
- [HQS12] Todd Hester, Michael Quinlan, and Peter Stone. Rtmba: A real-time model-based reinforcement learning architecture for robot control. In *2012 IEEE International Conference on Robotics and Automation*, pages 85–90. IEEE, 2012.
- [HRW⁺22] Beining Han, Zhizhou Ren, Zuofan Wu, Yuan Zhou, and Jian Peng. Off-policy reinforcement learning with delayed rewards. In *International Conference on Machine Learning*, pages 8280–8303. PMLR, 2022.
- [HS13] Todd Hester and Peter Stone. Texplora: real-time sample-efficient reinforcement learning for robots. *Machine learning*, 90(3):385–429, 2013.
- [HSU12] Hirotaka Hachiya, Masashi Sugiyama, and Naonori Ueda. Importance-weighted least-squares probabilistic classifier for covariate shift adaptation with application to human activity recognition. *Neurocomputing*, 80:93–101, 2012.
- [HY18] Robert Hannah and Wotao Yin. On unbounded delays in asynchronous parallel fixed-point algorithms. *Journal of Scientific Computing*, 76(1):299–326, 2018.
- [HZAL18] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018.
- [Jac88] Van Jacobson. Congestion avoidance and control. *ACM SIGCOMM computer communication review*, 18(4):314–329, 1988.
- [JBKS15] Aditya Jain, Ramta Bansal, Avnish Kumar, and KD Singh. A comparative study of visual and auditory reaction times on the basis of gender and physical activity levels of medical first year students. *International Journal of Applied and Basic Medical Research*, 5(2):124, 2015.
- [JGS13] Pooria Joulani, Andras Gyorgy, and Csaba Szepesvári. Online learning under delayed feedback. In *International Conference on Machine Learning*, pages 1453–1461. PMLR, 2013.
- [JMC⁺17] Max Jaderberg, Volodymyr Mnih, Wojciech Marian Czarnecki, Tom Schaul, Joel Z. Leibo, David Silver, and Koray Kavukcuoglu. Reinforcement learning with unsupervised auxiliary tasks. In *International Conference on Learning Representations (ICLR)*, 2017.
- [JMdR19] Rolf Jagerman, Ilya Markov, and Maarten de Rijke. When people change their mind: Off-policy evaluation in non-stationary recommendation environments. In *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*, pages 447–455, 2019.

- [KD18] Durk P Kingma and Prafulla Dhariwal. Glow: Generative flow with invertible 1x1 convolutions. *Advances in neural information processing systems*, 31, 2018.
- [KE03] Konstantinos V Katsikopoulos and Sascha E Engelbrecht. Markov decision processes with delays and asynchronous cost collection. *IEEE transactions on automatic control*, 48(4):568–574, 2003.
- [KKLM03] Wook Hyun Kwon, Jin Won Kang, Young Sam Lee, and Young Soo Moon. A simple receding horizon control for state delayed systems and its stability criterion. *Journal of Process Control*, 13(6):539–551, 2003.
- [KL02] Sham Kakade and John Langford. Approximately optimal approximate reinforcement learning. In *In Proc. 19th International Conference on Machine Learning*. Citeseer, 2002.
- [KLC98] Leslie Pack Kaelbling, Michael L Littman, and Anthony R Cassandra. Planning and acting in partially observable stochastic domains. *Artificial intelligence*, 101(1-2):99–134, 1998.
- [KNG99] Vladimir B Kolmanovskii, S-I Niculescu, and Keqin Gu. Delay effects on stability: A survey. In *Proceedings of the 38th IEEE Conference on Decision and Control (Cat. No. 99CH36304)*, volume 2, pages 1993–1998. IEEE, 1999.
- [KRRP20] Khimya Khetarpal, Matthew Riemer, Irina Rish, and Doina Precup. Towards continual reinforcement learning: A review and perspectives. *arXiv preprint arXiv:2012.13490*, 2020.
- [KSH17] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6):84–90, 2017.
- [KST⁺21] B Ravi Kiran, Ibrahim Sobh, Victor Talpaert, Patrick Mannion, Ahmad A Al Sallab, Senthil Yogamani, and Patrick Pérez. Deep reinforcement learning for autonomous driving: A survey. *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [KV15] Panqanamala Ramana Kumar and Pravin Varaiya. *Stochastic systems: Estimation, identification, and adaptive control*. SIAM, 2015.
- [LAL⁺20] P Liotet, Patrice Abry, R Leonarduzzi, Marc Senneret, Laurent Jaffres, and Gerald Perrin. Deep learning abilities to classify intricate variations in temporal dynamics of multivariate time series. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 3857–3861. IEEE, 2020.
- [LB08] Sophie Lèbre and Pierre-Yves Bourguignon. An em algorithm for estimation in the mixture transition distribution model. *Journal of Statistical Computation and Simulation*, 78(8):713–729, 2008.
- [LCB22] Romain Laroche, Remi Tachet des Combes, and Jacob Buckman. Non-markovian policies occupancy measures. *arXiv preprint arXiv:2205.13950*, 2022.
- [Lew14] Michael Lewis. *Flash boys: a Wall Street revolt*. WW Norton & Company, 2014.
- [LHP⁺16] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. Continuous control with deep reinforcement learning. In Yoshua Bengio and Yann LeCun, editors, *International Conference on Learning Representations (ICLR)*, 2016.
- [LLF⁺17] Michael Laskey, Jonathan Lee, Roy Fox, Anca Dragan, and Ken Goldberg. Dart: Noise injection for robust imitation learning. In *Conference on robot learning*, pages 143–156. PMLR, 2017.
- [LMBR22] Pierre Liotet, Davide Maran, Lorenzo Bisi, and Marcello Restelli. Delayed reinforcement learning by imitation. In Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvari, Gang Niu, and Sivan Sabato, editors, *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pages 13528–13556. PMLR, 17–23 Jul 2022.
- [LP17] David A Levin and Yuval Peres. *Markov chains and mixing times*, volume 107. American Mathematical Soc., 2017.
- [LR19] Erwan Lecarpentier and Emmanuel Rachelson. Non-stationary markov decision processes, a worst-case approach using model-based reinforcement learning. *Advances in neural information processing systems*, 32, 2019.

Bibliography

- [LS98] John Loch and Satinder Singh. Using eligibility traces to find the best memoryless policy in partially observable markov decision processes. In *ICML*, volume 98, pages 323–331, 1998.
- [LS15] Boris Lesner and Bruno Scherrer. Non-stationary approximate modified policy iteration. In Francis R. Bach and David M. Blei, editors, *ICML 2015*, 2015.
- [LS20] Tor Lattimore and Csaba Szepesvári. *Bandit algorithms*. Cambridge University Press, 2020.
- [LSKM21] Tal Lancewicki, Shahar Segal, Tomer Koren, and Yishay Mansour. Stochastic multi-armed bandits with unrestricted delay distributions. In *International Conference on Machine Learning*, pages 5969–5978. PMLR, 2021.
- [LVMR22] Pierre Liotet, Francesco Vidaich, Alberto Maria Metelli, and Marcello Restelli. Lifelong hyper-policy optimization with multiple importance sampling regularization. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022.
- [LVR21] Pierre Liotet, Erick Venneri, and Marcello Restelli. Learning a belief representation for delayed reinforcement learning. In *2021 International Joint Conference on Neural Networks (IJCNN)*, pages 1–8. IEEE, 2021.
- [MBM⁺16] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International conference on machine learning*, pages 1928–1937. PMLR, 2016.
- [MC89] Michael McCloskey and Neal J Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, volume 24, pages 109–165. Elsevier, 1989.
- [MGY⁺21] Azalia Mirhoseini, Anna Goldie, Mustafa Yazgan, Joe Wenjie Jiang, Ebrahim Songhori, Shen Wang, Young-Joon Lee, Eric Johnson, Omkar Pathak, Azade Nazi, et al. A graph placement methodology for fast chip design. *Nature*, 594(7862):207–212, 2021.
- [MKKB18] A Rupam Mahmood, Dmytro Korenkevych, Brent J Komer, and James Bergstra. Setting up a reinforcement learning task with a real-world robot. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4635–4640. IEEE, 2018.
- [MKS⁺13] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning. *arXiv preprint arXiv:1312.5602*, 2013.
- [MMB⁺20] Alberto Maria Metelli, Flavio Mazzolini, Lorenzo Bisi, Luca Sabbioni, and Marcello Restelli. Control frequency adaptation via action persistence in batch reinforcement learning. In *International Conference on Machine Learning*, pages 6862–6873. PMLR, 2020.
- [MMMS21] Siddharth Mysore, Bassel Mabsout, Renato Mancuso, and Kate Saenko. Regularizing action policies for smooth control with reinforcement learning. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1810–1816. IEEE, 2021.
- [MPFR18] Alberto Maria Metelli, Matteo Papini, Francesco Faccio, and Marcello Restelli. Policy optimization via importance sampling. In *NeurIPS 2018*, 2018.
- [MPMR20] Alberto Maria Metelli, Matteo Papini, Nico Montali, and Marcello Restelli. Importance sampling techniques for policy optimization. *Journal of Machine Learning Research*, 21(141):1–75, 2020.
- [MVHS14] A Rupam Mahmood, Hado P Van Hasselt, and Richard S Sutton. Weighted importance sampling for off-policy learning with linear function approximation. *Advances in Neural Information Processing Systems*, 27, 2014.
- [MWE20] Jorge Mendez, Boyu Wang, and Eric Eaton. Lifelong policy gradient learning of factored policies for faster training without forgetting. *Advances in Neural Information Processing Systems*, 33:14398–14409, 2020.
- [MZY22] Yiqian Mao, Shan Zhong, and Hujun Yin. Active flow control using deep reinforcement learning with time delays in markov decision process and autoregressive policy. *Physics of Fluids*, 34(5):053602, 2022.
- [Nic01] Silviu-Iulian Niculescu. *Delay effects on stability: a robust control approach*, volume 269. Springer Science & Business Media, 2001.

- [Nij94] Romi Nijhawan. Motion extrapolation in catching. *Nature*, 1994.
- [NMT10] Ashutosh Nayyar, Aditya Mahajan, and Demosthenis Teneketzis. Optimal control strategies in delayed sharing information structures. *IEEE Transactions on Automatic Control*, 56(7):1606–1620, 2010.
- [NT20] Chris Nota and Philip S Thomas. Is the policy gradient a gradient? In *Proceedings of the 19th International Conference on Autonomous Agents and MultiAgent Systems*, pages 939–947, 2020.
- [ODZ⁺16] Aaron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, and Koray Kavukcuoglu. Wavenet: A generative model for raw audio. *arXiv preprint arXiv:1609.03499*, 2016.
- [OGA20] Ronald Ortner, Pratik Gajane, and Peter Auer. Variational regret bounds for reinforcement learning. In *UAI 2020*, 2020.
- [OPN18] Takayuki Osa, Joni Pajarinen, and Gerhard Neumann. *An Algorithmic Perspective on Imitation Learning*. Now Publishers Inc., Hanover, MA, USA, 2018.
- [Owe13] Art B. Owen. *Monte Carlo theory, methods and examples*. 2013.
- [Pad21] Sindhu Padakandla. A survey of reinforcement learning algorithms for dynamically varying environments. *ACM Computing Surveys (CSUR)*, 54(6):1–25, 2021.
- [PBASG18] Ciara Pike-Burke, Shipra Agrawal, Csaba Szepesvari, and Steffen Grunewalder. Bandits with delayed, aggregated anonymous feedback. In *International Conference on Machine Learning*, pages 4105–4113. PMLR, 2018.
- [PMLR19] Matteo Papini, Alberto Maria Metelli, Lorenzo Lupo, and Marcello Restelli. Optimistic policy optimization via multiple importance sampling. In *ICML 2019*, 2019.
- [PPM17] George Papamakarios, Theo Pavlakou, and Iain Murray. Masked autoregressive flow for density estimation. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [PS08] Jan Peters and Stefan Schaal. Reinforcement learning of motor skills with policy gradients. *Neural networks*, 21(4):682–697, 2008.
- [PT87] Christos H Papadimitriou and John N Tsitsiklis. The complexity of markov decision processes. *Mathematics of operations research*, 12(3):441–450, 1987.
- [PTR21] Riccardo Poiani, Andrea Tirinzoni, and Marcello Restelli. Meta-reinforcement learning by tracking task non-stationarity. In *IJCAI*, pages 2899–2905. ijcai.org, 2021.
- [Put94] Martin L Puterman. Markov decision processes: Discrete stochastic dynamic programming, 1994.
- [R⁺61] Alfréd Rényi et al. On measures of entropy and information. In *Proceedings of the fourth Berkeley symposium on mathematical statistics and probability*, volume 1, pages 547–561. Berkeley, California, USA, 1961.
- [Raf85a] Adrian E Raftery. A model for high-order markov chains. *Journal of the Royal Statistical Society: Series B (Methodological)*, 47(3):528–539, 1985.
- [Raf85b] AE Raftery. A new model for discrete-valued time series: autocorrelations and extensions. *Rassegna di Metodi Statistici ed Applicazioni*, 3(4):149–162, 1985.
- [RAT⁺22] Giulia Romano, Andrea Agostini, Francesco Trovò, Nicola Gatti, and Marcello Restelli. Multi-armed bandit problem with temporally-partitioned rewards: When partial feedback counts. In Lud De Raedt, editor, *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22*, pages 3401–3407. International Joint Conferences on Artificial Intelligence Organization, 7 2022. Main Track.
- [RB10] Stéphane Ross and Drew Bagnell. Efficient reductions for imitation learning. In *Proceedings of the thirteenth international conference on artificial intelligence and statistics*, pages 661–668. JMLR Workshop and Conference Proceedings, 2010.
- [RBL⁺21a] Antonio Riva, Lorenzo Bisi, Pierre Liotet, Luca Sabbioni, Edoardo Vittori, Marco Pinciroli, Michele Trapletti, and Marcello Restelli. Learning fx trading strategies with fqi and persistent actions. In *Proceedings of the Second ACM International Conference on AI in Finance*, pages 1–9, 2021.

Bibliography

- [RBL⁺21b] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models, 2021.
- [RBL⁺22] Antonio Riva, Lorenzo Bisi, Pierre Liotet, Luca Sabbioni, Edoardo Vittori, Marco Pinciroli, Michele Trapletti, and Marcello Restelli. Addressing non-stationarity in fx trading with online model selection of offline rl experts. 2022.
- [RCA⁺19] Matthew Riemer, Ignacio Cases, Robert Ajemian, Miao Liu, Irina Rish, Yuhai Tu, and Gerald Tesauro. Learning to learn without forgetting by maximizing transfer and minimizing interference. In *International Conference on Learning Representations (ICLR)*, 2019.
- [RDN⁺22] Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu, and Mark Chen. Hierarchical text-conditional image generation with clip latents. *arXiv preprint arXiv:2204.06125*, 2022.
- [RGB11] Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, pages 627–635. JMLR Workshop and Conference Proceedings, 2011.
- [Ric03] Jean-Pierre Richard. Time-delay systems: an overview of some recent advances and open problems. *automatica*, 39(10):1667–1694, 2003.
- [RL10] E. Rachelson and M. G. Lagoudakis. On the Locality of Action Domination in Sequential Decision Making. In *Tenth Intl. Symposium on AI and Math*, 2010.
- [RM15] Danilo Rezende and Shakir Mohamed. Variational inference with normalizing flows. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 1530–1538. PMLR, 2015.
- [RN94] Gavin A Rummery and Mahesan Niranjana. *On-line Q-learning using connectionist systems*, volume 37. Citeseer, 1994.
- [RP19] Simon Ramstedt and Chris Pal. Real-time reinforcement learning. *Advances in neural information processing systems*, 32, 2019.
- [RRT21] Feng Ren, Jean Rabault, and Hui Tang. Applying deep reinforcement learning to active flow control in weakly turbulent conditions. *Physics of Fluids*, 33(3):037121, 2021.
- [SB18] Richard S Sutton and Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- [SBBJ10] Erik Schuitema, Lucian Buşoniu, Robert Babuška, and Pieter Jonker. Control delay in reinforcement learning for real-time dynamic systems: a memoryless approach. In *2010 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 3226–3231. IEEE, 2010.
- [SCS⁺22] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S Sara Mahdavi, Rapha Gontijo Lopes, et al. Photorealistic text-to-image diffusion models with deep language understanding. *arXiv preprint arXiv:2205.11487*, 2022.
- [SHM⁺16] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *nature*, 529(7587):484–489, 2016.
- [SLA⁺15] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *International conference on machine learning*, pages 1889–1897. PMLR, 2015.
- [SMAD17] Evan Shelhamer, Parsa Mahmoudieh, Max Argus, and Trevor Darrell. Loss is its own reward: Self-supervision for reinforcement learning. In *International Conference on Learning Representations (ICLR)*, 2017.
- [Smi57] Otto JM Smith. Closer control of loops with dead time. *Chemical engineering progress*, 53:217–219, 1957.
- [SMSM99] Richard S Sutton, David McAllester, Satinder Singh, and Yishay Mansour. Policy gradient methods for reinforcement learning with function approximation. *Advances in neural information processing systems*, 12, 1999.

- [SOR⁺08] Frank Sehnke, Christian Osendorfer, Thomas Rückstieß, Alex Graves, Jan Peters, and Jürgen Schmidhuber. Policy gradients with parameter-based exploration for control. In Vera Kurková, Roman Neruda, and Jan Koutník, editors, *ICANN 2008*, 2008.
- [Spa12] Matthijs TJ Spaan. Partially observable markov decision processes. In *Reinforcement Learning*, pages 387–414. Springer, 2012.
- [SPH⁺22] Uriel Singer, Adam Polyak, Thomas Hayes, Xi Yin, Jie An, Songyang Zhang, Qiyuan Hu, Harry Yang, Oron Ashual, Oran Gafni, et al. Make-a-video: Text-to-video generation without text-video data. *arXiv preprint arXiv:2209.14792*, 2022.
- [SPS99] Richard S Sutton, Doina Precup, and Satinder Singh. Between mdps and semi-mdps: A framework for temporal abstraction in reinforcement learning. *Artificial intelligence*, 112(1-2):181–211, 1999.
- [SWD⁺17] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *CoRR*, abs/1707.06347, 2017.
- [TET12] Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033. IEEE, 2012.
- [TMSP18] Jaden B Travník, Kory W Mathewson, Richard S Sutton, and Patrick M Pilarski. Reactive reinforcement learning in asynchronous environments. *Frontiers in Robotics and AI*, 5:79, 2018.
- [TS09] Matthew E Taylor and Peter Stone. Transfer learning for reinforcement learning domains: A survey. *Journal of Machine Learning Research*, 10(7), 2009.
- [TSPR18] Andrea Tirinzoni, Andrea Sessa, Matteo Pirotta, and Marcello Restelli. Importance weighted transfer of samples in reinforcement learning. In *ICML 2018*, 2018.
- [U⁺16] Benigno Uria et al. Neural autoregressive distribution estimation. *The Journal of Machine Learning Research*, 17(1):7184–7220, 2016.
- [VBC⁺19] Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [VEH14] Tim Van Erven and Peter Harremos. Rényi divergence and kullback-leibler divergence. *IEEE Transactions on Information Theory*, 60(7):3797–3820, 2014.
- [VG95] Eric Veach and Leonidas J. Guibas. Optimally combining sampling techniques for monte carlo rendering. In Susan G. Mair and Robert Cook, editors, *SIGGRAPH 1995*, 1995.
- [Vil09] Cédric Villani. *Optimal transport: old and new*, volume 338. Springer, 2009.
- [VSP⁺17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [VW78] Pravin Varaiya and Jean Walrand. On delayed sharing patterns. *IEEE Transactions on Automatic Control*, 23(3):443–445, 1978.
- [W⁺09] Thomas J Walsh et al. Learning and planning in environments with delayed feedback. *Autonomous Agents and Multi-Agent Systems*, 18(1):83, 2009.
- [Wat89] C. J. C. H. Watkins. *Learning from Delayed Rewards*. PhD thesis, King’s College, Oxford, 1989.
- [WC17] Sheng-Jhih Wu and Moody T Chu. Markov chains with memory, tensor formulation, and the dynamics of power iteration. *Applied Mathematics and Computation*, 303:226–239, 2017.
- [WD92] Christopher JCH Watkins and Peter Dayan. Q-learning. *Machine learning*, 8:279–292, 1992.
- [Wil92] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Mach Learn*, 8(3):229–256, 1992.
- [Wil93] Jarrod W Wilcox. The effect of transaction costs and delay on performance drag. *Financial Analysts Journal*, 49(2):45–54, 1993.

Bibliography

- [Wit71] Hans S Witsenhausen. Separation of estimation and control for discrete time systems. *Proceedings of the IEEE*, 59(11):1557–1566, 1971.
- [XJK⁺20] Ted Xiao, Eric Jang, Dmitry Kalashnikov, Sergey Levine, Julian Ibarz, Karol Hausman, and Alexander Herzog. Thinking While Moving: Deep Reinforcement Learning with Concurrent Control. *International Conference on Learning Representations (ICLR)*, 2020.
- [XLY20] Tian Xu, Ziniu Li, and Yang Yu. Error bounds of imitating policies and environments. *Advances in Neural Information Processing Systems*, 33, 2020.
- [ZSP18] Amy Zhang, Harsh Satija, and Joelle Pineau. Decoupling dynamics and reward for transfer learning. In *ICLR (workshop) 2018*, 2018.