

Transformer 注意力的贝叶斯几何

贝叶斯注意力三部曲之第一篇

NAMAN AGARWAL^{*}, Dream Sports, USA

SIDDHARTHA R. DALAL, Columbia University, USA

VISHAL MISRA, Columbia University, USA

现代序列模型常常表现出贝叶斯学习者的行为，但尚不清楚这反映的是真正的概率推理还是任务特定的启发式方法。本文引入贝叶斯风洞（*Bayesian wind tunnels*）——其中真实后验已知闭式解且记忆被证明不可行的受控环境——来实证回答这一问题。在这些设置中，小型 Transformer 以 10^{-3} – 10^{-4} 比特精度再现了滤波和假设消除的精确贝叶斯后验，而容量匹配的 MLP 则差了几个数量级。

为理解哪些架构要素能实现精确推理，我们将贝叶斯计算分解为三种推理原语（*inference primitives*）：(i) **信念累积（belief accumulation）**——将证据整合到运行后验中；(ii) **信念传输（belief transport）**——通过随机动力学向前传播信念；(iii) **随机访问绑定（random-access binding）**——通过内容而非位置检索存储的假设。不同任务需要这些原语的不同子集，不同架构能实现不同的子集。

通过比较双射学习、隐马尔可夫模型（Hidden Markov Model, HMM）滤波和联想回忆任务中的 Transformer、Mamba、LSTM 和 MLP，我们发现 Transformer 实现了全部三种原语；Mamba 实现了累积和传输但在随机访问绑定上表现困难；LSTM 仅实现累积（静态充分统计量）；而 MLP 则一种也未能实现。几何诊断揭示了正交的 Key 基、由后验熵参数化的低维值流形（value manifold），以及——在 Mamba 中——对应 HMM 隐藏状态的五个离散聚类。

这些结果表明贝叶斯计算并非单一整体：其可实现性取决于任务所需的推理原语以及可用于实现这些原语的架构机制。贝叶斯风洞为将可验证的小型系统与大型语言模型中观察到的推理现象进行机制性连接提供了基础。

1 引言

Transformer 能否执行精确的贝叶斯推理——滤波和假设消除——还是仅通过模式匹配近似实现？自然语言无法提供可验证预测的真实后验，而现代大语言模型规模过大且与训练数据纠缠过深，难以将真正的概率计算与记忆区分开来。即使模型表现出贝叶斯行为，也没有直接方法确认其内部计算是否匹配贝叶斯法则。

本文方法。我们以贝叶斯风洞（*Bayesian wind tunnels*）替代不可验证的自然数据：这类受控预测任务满足

- (1) 解析后验（*analytic posterior*）在每一步精确已知，
- (2) 假设空间（*hypothesis space*）足够大以至于记忆计算不可行，
- (3) 上下文内预测需要真正的概率推理。

这将一个定性问题（“它是否在做贝叶斯？”）转化为定量检验：模型的预测熵是否逐位置匹配解析后验？

四种风洞。本文研究四种设置：

- **双射学习（Bijection learning）**：一个离散假设消除问题，具有闭式后验。
- **隐马尔可夫模型（Hidden Markov Models, HMMs）**：一个需要递归更新的序贯随机推理问题。
- **贝叶斯回归（Bayesian regression）**：一个连续推理问题，在线性权重上具有闭式高斯后验。
- **联想回忆（Associative recall）**：一个基于内容的检索任务，测试绑定原语。

^{*}Currently at Google DeepMind. Work performed while at Dream Sports.

Authors' emails: naman33k@gmail.com, sd2803@columbia.edu, vishal.misra@columbia.edu. Authors are listed in alphabetical order.




Fig. 1. 推理原语分类。每行为一种原语，每列为一个架构。Transformer 实现了全部三种原语。Mamba 实现了累积和传输但在随机访问绑定上表现困难。LSTM 仅实现静态充分统计量的累积。MLP 则一种也未能实现。

为理解哪些架构要素能实现贝叶斯推理，我们将其分解为三种推理原语（*inference primitives*）：

- (1) **信念累积 (Belief accumulation)**：将证据整合到运行后验中（例如，随着观测到达更新 $P(\theta | x_{1:t})$ ）。
- (2) **信念传输 (Belief transport)**：通过随机动力学向前传播信念（例如，隐藏状态演化的 HMM 滤波）。
- (3) **随机访问绑定 (Random-access binding)**：通过内容而非位置检索存储的假设（例如，给定探针线索回忆目标）。

不同任务需要这些原语的不同子集，不同架构能实现不同的子集。我们测试四种架构：Transformer、Mamba（一种选择性状态空间模型）、LSTM 和 MLP。图 1 总结了哪些架构实现了哪些原语。

研究发现。 Transformer 实现了全部三种原语并在所有任务上取得成功。Mamba 实现了累积和传输——在 HMM 滤波上达到最先进水平——但在联想回忆中难以实现随机访问绑定。LSTM 仅实现静态充分统计量的累积：它们在信念修正（其中统计量是固定维度的）上成功，但当充分统计量本身在动力学下演化或需要按内容索引时则失败。MLP 未实现任何原语且全面失败。

几何诊断揭示了正交的 Key 轴、渐进对齐和由熵参数化的低维值流形。在 HMM 跟踪中，Mamba 的最后一层组织成五个聚类——每个隐藏状态一个——表明模型发现了信念单纯形的角点几何。

贡献。 本文首次实证证明神经序列模型能够实现精确贝叶斯后验，引入贝叶斯风洞作为在可验证环境中探测算法推理的工具，并建立了推理原语分类体系来解释哪些架构在哪些任

务上成功。原语框架统一了先前的观察：基于内容的路由支持累积和传输；注意力的随机访问能力额外支持了绑定。

关于“贝叶斯推理”的说明。我们不声称对网络权重存在贝叶斯后验；而是表明学习到的预测器实现了关于潜在任务变量的贝叶斯后验预测——HMM 中隐藏状态的滤波后验，或双射的消除后验。这是关于 Transformer 计算的输入-输出函数，而非权重空间的不确定性。具体而言，我们展示了在后验在输入上顺序分解的任务中实现精确贝叶斯推理——滤波和消除，而非一般的贝叶斯模型选择。

路线图：本文作为引理 1。本文建立了在可验证条件下 Transformer 中精确贝叶斯推理的存在性与内部几何。它是构成统一论证的三篇论文中的第一篇：第二篇论文表明这种几何结构从交叉熵训练下的梯度动力中自然产生，解释了为什么 Transformer 学习到贝叶斯结构。第三篇论文展示这些原语如何在更接近自然语言的部分可观测设置中组合。三部曲共同刻画了神经序列模型何时、为何以及如何实现概率推理。

结构定理（推理原语与架构可实现性）。序贯预测中的贝叶斯推理分解为三种原语：

- (1) 关于固定潜在假设的信念累积，
- (2) 潜在状态动力学下的信念传输，以及
- (3) 信念与过去观测之间的随机访问绑定。

神经序列架构的差异不在于能否近似贝叶斯推理，而在于能实现哪些原语：

- 循环架构（LSTM）实现静态充分统计量的累积，但当推理需要在非平凡动力学下传输概率质量时失败。
- 状态空间模型（Mamba）实现累积和传输，但当推理需要对任意过去观测进行随机访问绑定时失败。
- 基于注意力的 Transformer 通过将信念外部化为一种几何的、可寻址的表示而非压缩为固定大小状态，实现了全部三种原语。

Transformer 在推理任务中的主导地位不仅来自规模，更来自原语完备性：它们是实现完整推理原语集合的最简架构。

2 理论框架：交叉熵与贝叶斯推理

上下文预测任务上的交叉熵训练具有一个众所周知的人群最优解：即贝叶斯后验预测分布。本节将该联系形式化。理论部分阐明了在无限数据、无限容量的极限下学习到的函数应该是什么；实证部分则评估在有限设置中哪些架构能近似该函数。

2.1 设置

考虑一族由潜在参数 $\theta \sim \pi(\theta)$ 索引的任务。对每个任务：

- 输入 x 从某个分布（可能由实验者选择或对抗性设定）中抽取，
- 标签按 $y \sim p(y | x, \theta)$ 抽取，
- 模型观测到上下文 $c = \{(x_i, y_i)\}_{i=1}^k$ 并对新的查询输入预测 y 。

我们通过最小化人群交叉熵来训练模型 $q(y | x, c)$ ：

$$\mathcal{L}(q) = \mathbb{E}_{\theta \sim \pi} \mathbb{E}_{c, (x, y) \sim p(\cdot | \theta)} [-\log q(y | x, c)] . \quad (1)$$

2.2 交叉熵的最小化趋于贝叶斯后验预测

定理 1 (交叉熵的人群最优解). (1) 的最小化器为贝叶斯后验预测分布

$$q^*(y | x, c) = \int p(y | x, \theta) p(\theta | c) d\theta, \quad (2)$$

where

$$p(\theta | c) \propto \pi(\theta) \prod_{(x_i, y_i) \in c} p(y_i | x_i, \theta). \quad (3)$$

PROOF. 固定 (x, c) 并对 $y \sim p(\cdot | x, c)$ 取期望,

$$\arg \min_q \mathbb{E}[-\log q(y | x, c)] = p(y | x, c),$$

由贝叶斯法则和因子分解 $(y \perp c) | (x, \theta)$, 该式等于 $\int p(y | x, \theta) p(\theta | c) d\theta$. $\square$

备注 1. 该结果是架构无关的: 它定义了贝叶斯最优函数, 但并未说明特定架构能否表示或学习该函数。我们的实验直接回答了该可实现性问题。

2.3 双射风洞中的应用

在双射任务中, 每个 θ 是一个双射 $\pi: \{1, \dots, V\} \rightarrow \{1, \dots, V\}$ 。训练序列揭示 $k-1$ 个输入-输出对。令 $\mathcal{O}_{k-1}$ 为已观测到的输出集合。由于每个输入在序列中至多出现一次, 当前查询 x_k 此前从未出现过, 因此贝叶斯法则简化为:

$$p(\pi(x_k) = y | c) = \begin{cases} \frac{1}{V - k + 1}, & y \notin \mathcal{O}_{k-1}, \\ 0, & \text{otherwise.} \end{cases} \quad (4)$$

因此解析后验熵为

$$H_{\text{Bayes}}(k) = \log_2(V - k + 1), \quad (5)$$

每当一个映射被揭示时, 熵就减少一比特, 形成一个单调递减的阶梯。

这种闭式后验支持模型熵与贝叶斯熵之间直接的逐位置比较; 由于假设空间大小 $V!$ 极其巨大, 记忆在计算上不可行。

2.4 HMM 风洞中的应用

在 HMM 任务中, 每个 θ 包含:

- 转移矩阵 $T \in \mathbb{R}^{S \times S}$,
- 发射矩阵 $E \in \mathbb{R}^{S \times V}$,
- 初始状态分布 π_0 。

在观测到 $o_{1:t}$ 后, 隐藏状态上的真实贝叶斯后验由前向算法 (forward algorithm) 给出:

$$\alpha_t(s) = p(s_t = s | o_{1:t}) = \frac{E(o_t | s) \sum_{s'} T(s | s') \alpha_{t-1}(s')}{\sum_{s''} E(o_t | s'') \sum_{s'} T(s'' | s') \alpha_{t-1}(s')}. \quad (6)$$

由于模型预测的是下一观测 o_{t+1} 而非隐藏状态, 我们评估预测熵 (predictive entropy):

$$H_{\text{Bayes}}(t) = - \sum_o p(o_{t+1} | o_{1:t}) \log_2 p(o_{t+1} | o_{1:t}), \quad (7)$$

其中 $p(o_{t+1} | o_{1:t}) = \sum_{s, s'} \alpha_t(s) T(s' | s) E(o_{t+1} | s')$ 。

由于每个训练序列都来自新采样的 (T, E) , 假设空间巨大, 记忆在计算上不可行。模型必须学会 (i) 解析编码 T 和 E 的头部, 以及 (ii) 实现递归贝叶斯更新。

2.5 回归风洞中的应用

在回归任务中, 每个 θ 是一个权重向量 $w \in \mathbb{R}^d$, 先验为 $w \sim \mathcal{N}(0, I)$ 。给定上下文观测 (x_i, y_i) , 其中 $y_i = w^\top x_i + \epsilon_i$ 且 $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$, w 上的后验为高斯分布, 具有闭式均值和协方差。任意查询点 x 处的后验预测也是高斯分布, 从而可精确计算贝叶斯预测分布以进行比较。

2.6 联想回忆风洞中的应用

在联想回忆任务中，每个序列包含 N 个线索-目标对 (c_i, t_i) ，后跟探针线索。与其他测试信念累积或信念传输的任务不同，联想回忆测试绑定原语：模型必须存储所有配对并在探针到达时通过内容进行检索。成功需要基于内容的路由——识别哪个存储的配对与探针匹配——而非顺序贝叶斯更新。

2.7 模型评估的意义

上述理论结果蕴含一种实用诊断方法：在每个位置上实现正确后验熵的模型在功能上是贝叶斯的——其产生的预测具有与精确后验相同的不确定性轮廓。结合交叉熵训练目标（其唯一的人群最小化器是贝叶斯后验预测分布），低的熵校准误差为贝叶斯计算提供了有力证据。

超越熵：完整分布验证。一般而言，熵匹配是分布收敛的必要但不充分条件，因为不同分布可以共享相同的熵值。然而，在我们的风洞中，熵充当一种诊断性充分统计量（*diagnostic sufficient statistic*）：任务的结构化特性（双射中的离散消除、HMM 状态上的递归滤波）强烈约束了达到给定熵的分布空间。为确认完整的分布等价性，我们通过 KL 散度直接验证训练后的 Transformer 是否匹配完整的贝叶斯后验（表 1）。在本文中，我们以熵 MAE 作为主要度量指标，因为它提供了可解释的比特级度量，且可跨任务泛化。

表 1. 完整分布验证：Transformer 预测与精确贝叶斯后验之间的 KL 散度 (nats) 和总变差距离。双射结果按 Key 类型分层：“新”Key（首次出现）与“重复”Key（序列中已出现过的）。数值在 2,000 个保留序列上取平均。

Condition	KL(model Bayes)	TVD
<i>Bijection task</i>		
New keys	8.2×10^{-4}	0.027
Repeated keys	$< 10^{-6}$	$< 10^{-4}$
<i>HMM task ($K = 20$)</i>		
All positions	1.1×10^{-4}	0.018

评估熵校准误差 (entropy calibration error)

$$\text{MAE} = \frac{1}{L} \sum_k |H_{\text{model}}(k) - H_{\text{Bayes}}(k)| \quad (8)$$

因此提供了一种直接的比特级贝叶斯正确性度量，独立于准确率或困惑度。

在后续章节中，我们将展示 Transformer 达到了接近完美的校准，而匹配的 MLP 则未能做到。

3 实验设计

我们通过将小型 Transformer 置于四种受控的“贝叶斯风洞”中来评估它们能否实现精确贝叶斯推理——这些风洞中记忆在计算上不可行且解析后验已知闭式解。四个任务——双射学习、隐马尔可夫模型（Hidden Markov Model, HMM）状态跟踪、贝叶斯回归和联想回忆——探测不同的推理结构。双射需要离散假设消除；HMM 需要随机转移和发射似然的递归整合。

在这两种设置中，评估标准很简单：模型的预测熵 H_{model} 在每个位置上都匹配解析后验熵 H_{Bayes} 吗？

我们使用平均绝对熵误差 (Mean Absolute Entropy Error, MAE) 来衡量,

$$\text{MAE} = \frac{1}{L} \sum_{t=1}^L |H_{\text{model}}(t) - H_{\text{Bayes}}(t)|, \quad (9)$$

其中 L 是有监督预测位置的数量。由于每个训练实例使用新的双射或新的 HMM, 记忆不可行; 模型必须执行真正的上下文内推理。

3.1 任务 1: 双射学习

每个序列来自一个新的随机双射 $\pi : \{1, \dots, V\} \rightarrow \{1, \dots, V\}$, 其中 $V = 20$ 。在位置 k 处, 模型已观测到 $k-1$ 个不同的输入-输出对, 并需预测 $\pi(x_k)$ 。由于输入从不重复, $\pi(x_k)$ 上的贝叶斯最优后验在 $V - k + 1$ 个未见值上均匀分布。

贝叶斯真实值。令 $\mathcal{O}_{k-1}$ 为已观测到的输出。则

$$p(\pi(x_k) = y \mid \text{context}) = \begin{cases} \frac{1}{V-k+1}, & y \notin \mathcal{O}_{k-1}, \\ 0, & y \in \mathcal{O}_{k-1}, \end{cases}$$

熵为 $H_{\text{Bayes}}(k) = \log_2(V - k + 1)$ 。

评估。我们在 2,000 个保留双射上计算 MAE。由于存在 $20! \approx 2.4 \times 10^{18}$ 种可能的双射且训练仅使用 10^5 个样本, 没有双射被看到两次; 该任务强制执行真正的假设消除。

序列格式。每个训练示例被分词为

$$[x_1, y_1, \text{SEP}, x_2, y_2, \text{SEP}, \dots, x_{19}, \text{SEP}],$$

在每个 y_k 位置使用 Teacher Forcing。

3.2 任务 2: 隐马尔可夫模型状态跟踪

第二种风洞探测一种性质不同的推理结构: 递归信念更新。每个序列来自一个新的 HMM, 具有 $S = 5$ 个隐藏状态和 $V = 5$ 个观测符号。转移行和发射行独立地从对称 Dirichlet 分布中抽取, 所有浓度参数均为 1 (即 $\text{Dirichlet}(1, 1, 1, 1, 1)$), 确保多样且非退化的动力学。初始状态分布 π_0 也从 $\text{Dirichlet}(1, 1, 1, 1, 1)$ 中抽取。

序列格式。每个序列包含:

- 一个 10 个 Token 的头部 (**header**), 编码展平的 T 和 E , 以及
- K 个观测-预测对, 每对包括:
 - 观测到的符号 o_t ,
 - 在同一位置针对 $p(s_t \mid o_{1:t})$ 的有监督预测。

贝叶斯真实值: 前向算法。对每个 HMM 和每个时间步 t 我们计算

$$\alpha_t(s) \propto E(o_t \mid s) \sum_{s'} T(s \mid s') \alpha_{t-1}(s'), \quad (10)$$

归一化为 $\sum_s \alpha_t(s) = 1$ 。精确后验熵为

$$H_{\text{Bayes}}(t) = - \sum_{s=1}^S \alpha_t(s) \log_2 \alpha_t(s).$$

评估长度。模型在 $K = 20$ 个预测位置的序列上训练，并在以下情况下评估：

- $K = 20$ (验证：在训练范围内)，
- $K = 30$ ($1.5 \times$ 训练长度)，
- $K = 50$ ($2.5 \times$ 训练长度)。

这测试模型是学习到了位置无关的递归算法，还是仅仅记忆了有限时间范围的计算。

为什么记忆在计算上不可行。每个序列使用新的 T 、 E 矩阵和新的随机发射轨迹。即使在粗粒度离散化下，可能的 HMM 空间也超过 10^{40} ，确保学习到的行为不能依赖于对任何特定 HMM 的记忆。

3.3 任务 3：联想回忆

为隔离随机访问绑定 (*random-access binding*) 原语，我们使用标准的联想回忆任务：模型必须从上下文中呈现的一组线索-目标对中，根据探针线索检索目标。

任务格式。每个序列包含 N 个线索-目标对 (c_i, t_i) ，后跟 Q 个探针线索。线索和目标统一从两个不相交的大小为 256 的词表中抽取 (总词表 522，含特殊 Token)。模型必须为每个探针预测关联的目标。当 $N = 16$ 对、 $Q = 3$ 个探针时，序列长度为 137 个 Token。

实验设置。

- **训练**：50,000 个序列，30 个 Epoch
- **模型**：Transformer、Mamba、LSTM， $d_{\text{model}} = 128$ ，参数量可比 ($\sim 570\text{k} - 660\text{k}$)
- **度量**：探针预测上的精确匹配准确率

为什么这测试绑定。与双射 (假设空间可预测地缩小) 或 HMM (信念通过动力学演化) 不同，联想回忆需要延迟的、内容相关的检索：模型在探针到达之前无法知道哪些线索-目标对是相关的。这需要存储所有配对并通过内容检索——即绑定原语。

结果预览。当 $N = 16$ 对时：Transformer 达到 100% 准确率 (第 12 个 Epoch)；Mamba 达到 97.8% (第 30 个 Epoch)；LSTM 达到 0.5% (随机猜测)。Mamba 需要 $2.5 \times$ 更长的训练且准确率不完美，表明选择性 SSM 路由可以近似但无法完全实现随机访问绑定。完整结果见节 4.6。

3.4 任务 4：贝叶斯回归

为测试连续潜在变量，我们使用具有高斯先验的多元线性回归。

任务格式。每个序列来自一个新的线性回归，权重 $w \sim \mathcal{N}(0, I_d)$ ，其中 $d = 3$ 。观测遵循 $y_i = w^\top x_i + \epsilon_i$ ， $\epsilon_i \sim \mathcal{N}(0, 0.25)$ ，输入 $x_i \sim \mathcal{N}(0, I_d)$ 。模型观测 $k = 6$ 个上下文对，然后在来自同一输入分布的查询点上进行预测。输出被离散化为 41 个区间，均匀分布在 $[-5, 5]$ 上，覆盖给定先验和噪声尺度下 $> 99.9\%$ 的预测质量。

贝叶斯真实值。给定上下文后 w 上的后验为高斯分布，具有闭式均值和协方差，在任意查询点产生高斯预测分布。这使得可精确计算贝叶斯预测以进行比较。

为什么这测试连续推理。与双射 (离散假设) 或 HMM (离散状态) 不同，回归需要连续参数空间上的推理。高斯结构确保后验保持可处理性，同时测试 Transformer 能否在连续设置中校准不确定性。

3.5 架构

Transformer。我们使用小型但实用的 Transformer 堆叠：

- **双射 Transformer (2.67M 参数)**：6 层，6 头， $d_{\text{model}} = 192$ ， $d_{\text{ffn}} = 768$ 。
- **HMM Transformer (2.68M 参数)**：9 层，8 头， $d_{\text{model}} = 256$ ， $d_{\text{ffn}} = 1024$ 。

两者均使用学习到的 Token 嵌入、学习到的绝对位置嵌入、Pre-Norm 残差块和标准多头自注意力。

Mamba（选择性状态空间模型）。为测试是否特别需要注意力，或更一般化的基于内容的路由是否足够，我们训练 *Mamba* 模型 [9]：

- **双射 Mamba (3.77M 参数)**：9 层， $d_{\text{model}} = 256$ ，状态维度 16。
- **HMM Mamba (3.77M 参数)**：9 层， $d_{\text{model}} = 256$ ，状态维度 16。

Mamba 用选择性状态空间机制替代注意力：输入依赖的矩阵 (Δ, B, C) 门控循环状态更新。这提供了无需显式 Query-Key 匹配的基于内容的路由。

LSTM 基线。为测试循环结构是否足够，我们训练 *LSTM*：

- **双射 LSTM (4.77M 参数)**：9 层，隐藏维度 256。
- **HMM LSTM (4.77M 参数)**：9 层，隐藏维度 256。

LSTM 具有循环状态但使用固定门控——遗忘门、输入门和输出门不依赖于跨序列位置的内容关系。这测试了没有基于内容路由的循环结构能否实现贝叶斯推理。

容量匹配的 *MLP* 基线。为完全隔离序列结构的作用，我们训练 18–20 层、宽度 384–400、带有残差连接和层归一化的 *MLP*（参数量与 *Transformer* 匹配，差异在 1% 以内）。*MLP* 在每个预测位置接收完整上下文序列（所有先前 token 拼接而成）作为输入，但对此展平的输入进行处理时没有任何注意力或循环结构——测试拼接上下文上的前馈计算是否足以实现贝叶斯推理。我们选择这种设计以给 *MLP* 最大的上下文信息获取能力；更强的不带注意力的基线（例如 *Perceiver* 风格的池化、置换不变聚合）可能会缩小差距，但会重新引入某种形式的基于内容的路由。

3.6 训练协议

每个任务中不同架构的训练是相同的。

优化。AdamW， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ，权重衰减 0.01，梯度裁剪阈值为 1.0。所有任务批大小均为 64。

学习率和训练步数。

- 双射：恒定 10^{-3} ，150k 步。
- HMM： 3×10^{-4} ，1000 步预热和余弦衰减，100k 步。
- 回归： 5×10^{-4} ，50k 步。

数据采样。每个批次抽取新的双射或新的 HMM；序列从不重复。

Teacher Forcing。在每个有监督预测位置应用交叉熵损失。

消融稳定性。逐层和逐头消融报告为三个随机种子的平均值；HMM 长度泛化结果也在多个种子上评估以确保鲁棒性。

4 结果：Transformer 追踪贝叶斯后验

我们通过两种行为测试来评估 *Transformer* 是否处于解析贝叶斯流形上：（1）逐点校准—— $H_{\text{model}}(t)$ 在每个位置上都匹配 $H_{\text{Bayes}}(t)$ 吗？（2）泛化——学习到的计算能否推广到未见过的双射、未见过的 HMM 和更长的序列？

我们并行展示双射和 HMM 的结果，随后是 *MLP* 对照实验和多种子鲁棒性分析。

4.1 双射风洞：精确假设消除

一个 2.67M 参数的 Transformer 以接近机器精度的水平收敛到解析后验。图 3 显示了预测熵

$$H_{\text{model}}(k) = - \sum_y p_{\text{model}}(y | x_k, \text{context}) \log_2 p_{\text{model}}(y | x_k, \text{context})$$

与 $H_{\text{Bayes}}(k) = \log_2(V - k + 1)$ 的叠加。两条曲线在所有位置上重合，包括仅剩 2-4 个假设的后期步骤。

定量上，该 Transformer 达到

$$\text{MAE} = 3 \times 10^{-3} \text{ bits},$$

在 2,000 个保留双射上取平均。这一误差小于解析后验中的单精度数值噪声。所有解析贝叶斯计算均使用双精度算术，因此报告的误差是有意义的。我们通过 KL 和 TVD 验证了完整的分布一致性：在所有位置上， $\text{KL}(\text{model} \parallel \text{Bayes}) < 0.01 \text{ nats}$ 且 $\text{TVD} < 3\%$ ，逐位置分析证实了一致性在整个熵范围（高熵、中熵和低熵位置）内成立。

逐序列证据。聚合校准可能隐藏平均伪影。图 4 绘制了八条个体熵轨迹。每条都呈现特征性的阶梯模式：每当新的输入-输出对消除假设时熵离散下降，当输入重复且映射已知时熵骤降至接近零。该模型执行逐步贝叶斯消除，逐序列地再现曲线，而非仅在期望上匹配。

模型内部一致性。逐层消融（图 5）显示移除任何模块会使误差增加一个数量级以上，证实这是一种深度组合的计算。逐头消融（图 6）识别出单个第 0 层假设框架头（hypothesis-frame head），其移除具有独特的破坏性，这与节 5 中的几何分析一致。

4.2 HMM 风洞：递归贝叶斯状态跟踪

2.68M 参数的 Transformer 同样学会了 HMM 推理的前向算法。

训练范围内（ $K=20$ ）。在 $t \leq 20$ 时，模型熵追踪精确前向递归熵，达到

$$\text{MAE} = 7.5 \times 10^{-5} \text{ bits}.$$

两条曲线视觉上无法区分（图 7）。（注：表 2 中的架构比较使用了较小的参数匹配模型（2.7M）以实现公平的跨架构比较，MAE 为 0.049 bits；此处结果使用了任务优化的 2.68M Transformer。）

超出训练范围（ $K=30, K=50$ ）。为测试算法泛化能力，我们将模型展开到 $1.5\times$ 和 $2.5\times$ 训练长度。Transformer 仍接近解析后验：

$$\text{MAE}(K=30) = 1.25 \times 10^{-2}, \quad \text{MAE}(K=50) = 2.88 \times 10^{-2}.$$

误差随 t 平滑增加，在 $t=20$ （训练边界）处没有不连续性。这强烈表明是位置无关的递归算法，而非有限时间范围的记忆计算。

逐位置校准。图 8 显示了绝对误差 $|H_{\text{model}}(t) - H_{\text{Bayes}}(t)|$ 。三种模式显现：

- (1) 早期位置略为嘈杂（初始状态不确定）；
- (2) 序列中间位置在所有长度上均达到接近零的误差；
- (3) 后期位置随序列长度平滑退化，与累积的数值漂移一致。

逐序列动力学。图 9 展示了模型跟踪序列特定的波动：当发射强烈识别状态时熵下降，当观测模糊时熵上升。Transformer 精确捕捉了这些动力学。

隐藏状态重标号下的语义不变性。隐藏状态索引纯粹是符号性的：对标签进行置换对应于相同的潜在过程。我们采样 $\{1, \dots, S\}$ 的一个随机置换 σ ，通过置换 T 的行和列（即 $T'_{\sigma(i), \sigma(j)} = T_{i,j}$ ）和置换 E 的行（即 $E'_{\sigma(i), o} = E_{i,o}$ ）将其应用于 HMM 参数。然后我们在 (T', E') 下重新计算解析后验，并在从置换后的 HMM 生成的序列上评估模型。如果模型实现的是贝叶斯滤波而非将含义关联到特定状态 ID，其熵校准应保持不变，差异不超过数值噪声。图 10 显示置换前后的 MAE 位于对角线上， ΔMAE 集中在零附近。

4.3 长度泛化需要后层注意力

为识别哪些组件支持稳定展开，我们训练了一种变体 Transformer，其中顶部两层的注意力被禁用，但 FFN 和残差连接保持不变。

无后层注意力模型在训练范围内表现尚可（ 1.57×10^{-3} bits），但在展开时崩溃：

$$\text{MAE}(K = 30) = 5.55 \times 10^{-1}, \quad \text{MAE}(K = 50) = 1.79.$$

退化因子从 $21 \times$ （ $K = 20$ 时）增长到 $62 \times$ （ $K = 50$ 时），表明后层注意力对于拟合 $K = 20$ 并非必需，但对于稳定的长程贝叶斯更新至关重要（图 11）。

4.4 联想回忆：基于内容的检索

联想回忆任务测试架构能否通过内容检索存储的信息——即绑定原语。与双射或 HMM 任务中相关上下文由位置或动力学决定不同，此处模型必须基于仅在测试时到达的探针识别要检索哪个线索-目标对。

Transformer 在保留序列上达到 100% 准确率，展示了完美的基于内容检索。这需要注意力机制：探针线索必须与存储的线索匹配，以从相应目标路由信息。MLP 在我们的训练协议下未能成功完成此任务（准确率为随机猜测水平），因为它们独立处理每个位置，没有跨 Token 交互。

4.5 连续贝叶斯回归

为测试连续潜在变量，我们在具有高斯先验的多元线性回归上进行评估。Transformer（857k 参数，4 层）在 41 个区间上预测离散化输出，与闭式贝叶斯预测的 KL 散度为 0.034 nats；容量匹配的 MLP 的 KL 为 0.22——差 $6 \times$ 。差距小于离散任务，但 Transformer 在不确定性校准上仍显著优于 MLP，表明贝叶斯推理能力可扩展到连续参数空间。

4.6 架构比较：每种架构实现了哪些原语？

为理解哪些架构要素能实现贝叶斯推理，我们将其分解为三种推理原语（*inference primitives*）并测试每种架构实现了哪些：

- **信念累积（Belief accumulation）**：将证据整合到运行后验中（通过双射消除测试）
- **信念传输（Belief transport）**：通过随机动力学传播信念（通过 HMM 滤波测试）
- **随机访问绑定（Random-access binding）**：通过内容检索存储的假设（通过联想回忆测试）

表 2 总结了所有三个任务的结果。

Transformer 实现了全部三种原语。Transformer 在双射和 HMM 上达到接近精确的贝叶斯后验，并在具有 64 个线索-目标对的联想回忆上达到完美准确率。注意力提供了全部三种能力：通过残差流实现累积，通过基于内容路由实现传输，以及通过 Query-Key 匹配实现绑定。

Mamba 实现了累积和传输，但在绑定上存在困难。Mamba 在 HMM 跟踪上优于 Transformer（0.024 vs 0.049 bits MAE），表明其选择性状态空间机制擅长信念传输。然而，在联想回忆上，Mamba 仅达到 97.8% 准确率且需要 $2.5 \times$ 更多的训练 Epoch。这与 Jelassi et al. [11]

表 2. **推理原语上的架构比较**。双射/HMM：熵 MAE（比特，越低越好；Mamba/LSTM 为 5 个种子的均值 ± 标准差）。回忆：准确率（越高越好）。每个任务测试不同的原语。Transformer 实现了全部三种；Mamba 实现了累积和传输；LSTM 仅实现累积（静态充分统计量）；MLP 一种也未能实现。

Architecture	Bijection (accumulation)	HMM (transport)	Assoc. Recall (binding)	Primitives realized
Transformer	0.007	0.049	100%	All 3
Mamba	0.010±.001	0.024±.009	97.8% (slow)	2 of 3
LSTM	0.009±.000	0.411±.003 (fail)	0.5% (fail)	1 of 3
MLP	1.85	0.40	—	0 of 3

的发现一致——SSM 在检索任务上存在困难：Mamba 的选择机制在转移动力学上实现基于内容的路由，这支持了传输但不支持直接的随机访问检索。

LSTM 仅实现静态充分统计量的累积。LSTM 在双射上达到 0.009 bits——与 Transformer 和 Mamba 相当——但在 HMM（0.416 bits）和联想回忆（0.5%，随机猜测）上均失败。关键区别在于：双射消除允许静态充分统计量（已观测输出的集合，可在固定维度中表示），LSTM 可以用其循环状态跟踪。但 HMM 需要在动力学下演化的充分统计量——信念向量必须在每一步通过转移矩阵传输——而联想回忆需要统计量按内容索引。在我们的训练协议下，LSTM 的固定门控累积了证据，但未能学会实现传输或绑定所需的内容依赖操作。

MLP 未实现任何原语。没有序列结构，MLP 退化为边缘预测并全面失败。

原语分类体系预测性能。这种分解解释了全部结果模式：每种架构恰好在其所需原语能够实现的那些任务上成功。该分类体系还解决了文献中的表面矛盾——Mamba 在以传输为主的任务（HMM）上击败 Transformer，但在需要绑定的任务（回忆）上失败。




Fig. 2. **Mamba 发现了 HMM 信念空间的 5 角几何**。Mamba 在 HMM 任务（5 个隐藏状态）上的最终层表示。左图：按最可能隐藏状态着色的点揭示了五个不同的聚类——每个状态一个。右图：相同点按后验熵着色，显示每个聚类内的置信度变化（红色 = 低熵/高置信度，蓝色 = 高熵/不确定性）。Mamba 已学会信念单纯形有五个角点并相应组织了其表示。这种几何结构解释了其强大性能（MAE = 0.024 bits，5 种子平均）。

4.7 多种子一致性

为确保贝叶斯跟踪不是初始化或优化噪声的伪影，我们在五个独立随机种子上重复了 Transformer HMM 实验。所有种子的逐位置误差曲线（图 13）在 $K = 20$ 、 $K = 30$ 和 $K = 50$ 时几乎重叠。

种子间变异性与架构间差距相比可以忽略不计，证实学习到的贝叶斯算法对初始化和训练噪声具有鲁棒性。表 2 中 Mamba 和 LSTM 的 HMM 结果是 5 个种子的平均值，标准差分别为 0.009 和 0.003 bits——证实架构间的大性能差距（例如 LSTM 在 HMM 上的 0.411 vs Mamba 的 0.024 bits）反映了真正的架构差异，而非种子间变异。




Fig. 3. **双射风洞：Transformer 匹配贝叶斯后验；MLP 则不能。** 150k 训练步时的熵轨迹。Transformer 在所有位置上基本与解析贝叶斯曲线重合，而容量匹配的 MLP 几乎未能降低不确定性，未能实现假设消除。此比较在表 3 中定量总结，并在节 4.1 中讨论。




Fig. 4. **双射风洞：逐序列熵动力学。** 测试集中八个随机选择的双射。每个面板显示 Transformer 熵（实线）和解析贝叶斯熵（虚线）作为位置的函数。锯齿模式——当映射揭示时离散下降，当先前见过的输入再次出现时坍塌到（接近）零——证实 Transformer 在执行逐步假设消除，而不仅仅是在总体上匹配贝叶斯曲线。

5 机制：Transformer 如何实现贝叶斯推理

节 4 中的行为结果表明，小型 Transformer 在两种不同的风洞任务中以亚比特精度追踪了解析贝叶斯后验。现在我们研究这种计算在内部是如何实现的。来自消融实验、QK 几何、探针动力学和训练轨迹的证据揭示了一致的架构机制：Transformer 通过构建表示框架、在该框架内执行顺序消除，以及跨层次渐进精化后验精度来实现贝叶斯推理。




Fig. 5. **双射风洞：逐层消融**。依次消融每层（注意力 +FFN）时的平均绝对熵误差（比特），在种子上平均。移除任何单层会使校准误差增加一个数量级以上，表明贝叶斯计算是真正的层次化组合结构，而非浅层或冗余的。




Fig. 6. **逐头消融**。消融单个注意力头时平均绝对熵误差的变化。单个第 0 层“假设框架头”扮演了独特的重要角色，而许多后续头部则部分冗余。这支持了节 6 中的三阶段图景：基础绑定、渐进消除和值流形精化。




Fig. 7. HMM 风洞：跨序列长度的校准。Transformer 预测熵 $H_{\text{model}}(t)$ (实线) 与解析 $H_{\text{Bayes}}(t)$ (虚线) 在训练长度 $K = 20$ 以及 $K = 30$ 和 $K = 50$ 时的对比。在 $K = 20$ 时，轨迹几乎完美重叠；对于更长序列，误差随位置平滑增长，在训练边界处没有扭结，表明是位置无关的递归算法，而非有限时间范围的记忆。




Fig. 8. HMM 风洞：逐位置校准。绝对熵误差 $|H_{\text{model}}(t) - H_{\text{Bayes}}(t)|$ 作为 $K = 20$ 、 $K = 30$ 和 $K = 50$ 时位置的函数。在训练长度下误差极小，对于扩展长度随 t 逐渐增加，在 $t = 20$ 处再次没有不连续性。

表 3. HMM 风洞：Transformer 与 MLP 跨长度校准对比。模型熵与解析贝叶斯熵之间的平均绝对熵误差（比特）。Transformer 达到接近完美的校准，随长度优雅退化；容量匹配的 MLP 灾难性失败，在所有位置和长度上误差均为 ~ 0.4 比特。

Model	$K = 20$ (training)	$K = 50$ ($2.5\times$ length)
Transformer (2.68M)	7.5×10^{-5}	2.88×10^{-2}
MLP (2.70M)	4.09×10^{-1}	4.02×10^{-1}
Degradation factor	5,467 $\times$	14 $\times$

5.1 第 0 层创建假设框架

计算始于一个结构化操作：第 0 层注意力构建了所有后续推理发生的假设空间。该层的 Key 在输入 Token 上形成近似正交的基（图 16），提供了一个可以在其上表示和操作后验质量的坐标系。我们通过 Key 向量之间平均绝对非对角线余弦相似度来度量正交性。在 5 个种子




Fig. 9. **HMM 风洞: 逐序列熵动力学。**八个随机选择的 $K = 20$ 测试 HMM 的熵轨迹 $H_{\text{model}}(t)$ 和 $H_{\text{Bayes}}(t)$ 。Transformer 跟踪了序列特定的不确定性上升和下降，反映了转移和发射的随机相互作用。




Fig. 10. **隐藏状态重标号下的语义不变性。** HMM 中随机置换隐藏状态标签前后的平均绝对熵误差对比。点位于对角线上， ΔMAE 的分布紧密集中在零附近，证实 Transformer 的计算对隐藏状态空间的任意重标号具有不变性。

上，双射模型在 $d = 192$ 维度上达到 0.052 ± 0.004 ，而随机向量为 0.082 ± 0.003 ——降低了 37% ($p < 0.001$, 配对 t 检验)。HMM 模型显示类似结构: 0.061 ± 0.006 ，随机基线为 0.079 ± 0.002 。

逐头消融证实了这一步骤的不可或缺性。单个第 0 层”假设框架头”主导了该层的贡献 (图 6)，仅消融此头就严重破坏了校准。这里”假设框架头”是指其 Key 跨越假设 Token 上的




Fig. 11. **后层注意力与长度泛化。**完整 Transformer 和顶部两层注意力被禁用的变体在不同序列长度下的平均绝对熵误差。无后层注意力模型在训练长度下仅略差，但其误差在更长序列上爆炸式增长，退化因子从 $K = 20$ 时的 $\sim 21\times$ 增长到 $K = 50$ 时的超过 $60\times$ 。因此后层注意力对于训练范围之外的稳定展开至关重要。




Fig. 12. **HMM 风洞：Transformer 与 MLP 长度泛化对比。**Transformer（实线）和容量匹配的 MLP（虚线）在 $K = 20$ 和 $K = 50$ 时的逐位置平均绝对熵误差。垂直灰线标记 $t = 20$ 处的训练边界。Transformer 在训练长度上显示接近零的误差，超出后平滑退化；MLP 在所有位置上保持平坦的 ~ 0.4 比特误差，表明未能学会递归贝叶斯更新。

近似正交基、其 Value 在残差流中实例化相应逐假设槽位的注意力头。没有其他注意力头表现出类似的敏感性。这识别出一个结构性瓶颈：形成假设框架是任何后续贝叶斯计算的前提条件。




Fig. 13. **HMM 长度泛化的多种子鲁棒性。**五个随机种子在 $K = 20$ 、 $K = 30$ 和 $K = 50$ 时的 Transformer 逐位置 MAE 曲线叠加。种子间变异性相对于 Transformer-MLP 差距可忽略不计，表明学习到的贝叶斯算法对初始化和优化噪声具有鲁棒性。




Fig. 14. **代表性单种子轨迹。**一个代表性种子（2024）的逐位置 MAE 与图 13 中的多种子平均值紧密匹配，进一步证实长度泛化模式并非特定初始化的伪影。

一旦建立，该框架在整个训练过程中保持稳定。即使值流形和校准大幅改善，第 0 层的注意力图在各检查点之间变化很小。模型因此早期就学会推理问题的几何结构，随后在这个固定框架内精化数值精度。

5.2 跨深度的顺序贝叶斯消除

假设框架就位后，中间层执行逐层过程，镜像贝叶斯消除。

渐进式 QK 锐化。随着深度增加，Query 与观测证据一致的 Key 子集的对齐更强（图 17）。早期层广泛关注；更深层几乎将注意力完全集中于可行的假设上。这种几何聚焦与解析贝叶斯条件化类似——不一致的假设获得趋零的权重。




Fig. 15. **用于熵预测的逐块探针差值 (Probe Deltas)**。对每个 Transformer 块，我们在子层前残差流上训练一个线性探针以预测解析后熵，然后在子层后残差上评估同一探针。绘制的量是从子层前到子层后移动时均方误差 (MSE) 的变化，即 $\Delta \text{MSE} = \text{MSE}(\text{probe on post-residual}) - \text{MSE}(\text{probe on pre-residual})$ ，正值表示该块减少了探针误差。FFN 层贡献了 MSE 的最大降低，表明它们实现了大部分数值贝叶斯更新，而注意力主要提供路由而非执行繁重的概率计算。




Fig. 16. **第 0 层中的 Key 正交性**。双射模型在 150k 步时所有输入 Token 的 Key 向量余弦相似度矩阵。非对角元素集中在零附近，表明不同输入占据接近正交的方向，并形成显式的假设基。

层次化组合性。逐层消融（图 5）表明移除任何单层（注意力 + FFN，按实现方式）会使校准误差增加一个数量级以上。这表明计算不是浅层或冗余的。每层提供了独特且不可互换的精细化步骤，形成了贝叶斯更新的顺序组合实现。




Fig. 17. **Query-Key 随深度渐进对齐**。双射 Transformer 中早期层（左）和深层（右）的 Query 与 Key 之间的余弦相似度。对于水平轴上的每个序列位置 t ，我们沿垂直轴绘制位置 t 处的 Query 与所有 Key 向量 k_j 之间的余弦相似度 $\cos(q_t, k_j)$ 。此处 t 索引序列化输入序列中查询 Token 的位置（即模型必须预测的位置），而非 Token 身份；分隔符/头部 Token 仅以其占据序列位置的方式被包含。在第 0 层，注意力分散在许多 Key 上；到第 5 层，它急剧集中在剩余可行的假设 Key 上，使得顺序消除在 Q-K 空间中显现为几何聚焦。




Fig. 18. **训练过程中值流形的展开**。双射模型中注意力输出的 PCA 投影，按解析后验熵着色。在 100k 步时，低熵状态紧密聚集；到 150k 步时，它们沿一条由熵参数化的平滑一维曲线分布，实现了后验状态的细粒度编码。每个点是在有监督预测位置处的注意力输出（头部输出或块注意力输出——取决于使用哪种）；PCA 在汇总输出上拟合后绘制，按解析后验熵着色。

综合这些观察表明，Transformer 并非通过单一变换来实现贝叶斯消除，而是通过在第 0 层框架内进行深度方向的投影和精化序列。

5.3 注意力作为内容可寻址路由

在所有深度上，注意力扮演着一致的几何角色：它检索与下一次更新相关的信念状态分量。

三个观察支持这种路由解释：

- 正交 Key（图 16）为假设的内容可寻址查找提供了基。
- 跨深度的锐化 QK 对齐（图 17）将残差流信息路由到可行的假设子空间。




Fig. 19. **逐位置校准随值流形展开而改善**。双射任务中在 100k 和 150k 训练步时绝对熵误差作为位置的函数。主要改进发生在后期位置，与图 18 中低熵状态的几何展开相匹配。




Fig. 20. 贝叶斯推理的三阶段架构机制。第 0 层构建 Key-Value 假设框架，中间层在残差流中实现顺序贝叶斯更新，后期层在低维后验流形上精化表示。

- **后期精化中路由的稳定性**（图 18 and 19）表明，一旦框架正确，即使校准改善，注意力图也变化极小。

路由对于维持稳定的递归推理也至关重要。在 HMM 任务中，仅禁用顶部两层的注意力，训练范围内的性能基本保持完整，但长程推理崩溃（图 11）。因此，注意力既用于形成初始假设框架，也用于在扩展展开下维持稳定的信念更新。

5.4 值空间流形与精度精化

路由稳定后，最终层精化后验表示的精度。图 18 and 19 表明：

- 在中间检查点，低熵状态的 Value 表示几乎坍塌，无法可靠编码小剩余假设集之间的区分。
- 到最终检查点时，这些状态沿一条由后验熵参数化的平滑一维流形分布。

这种几何展开实现了后验置信度的细粒度编码，并解释了后期位置校准的改善。这种精化发生在注意力图几乎保持不变的同时，产生了清晰的框架-精度分离：注意力定义了信息流动的位置，而下游变换精化了信念编码的精确度。

5.5 综合：三阶段架构机制

在两种风洞中，证据汇聚成一个三阶段机制（图 20）：

- (1) **基础绑定（第 0 层）**。构建正交假设框架。（Key 几何；灾难性的第 0 层头部消融。）
- (2) **渐进消除（中间层）**。通过锐化 QK 对齐顺序抑制不一致的假设。（逐层组合性；几何聚焦。）
- (3) **精度精化（后期层）**。保持路由固定，在平滑的值流形上编码后验熵。（值流形展开；框架-精度分离。）

这种结构镜像了贝叶斯条件化的解析分解：定义假设空间，用证据更新信念，随着不确定性降低精化置信度。

5.6 Mamba 的机制：选择性状态空间动力学

虽然上述三阶段机制是 Transformer 注意力特有的，但 Mamba 通过性质不同的机制实现了可比的 HMM 性能（0.024 vs 0.049 bits MAE）。分析 Mamba 的内部表示揭示了选择性状态空间动力学如何在没有注意力的情况下实现信念传输。

五聚类几何从状态选择中涌现。Mamba 的最终层表示组织成对应五个 HMM 隐藏状态的五个离散聚类（图 2），聚类内变异编码后验熵。这是 Transformer 学习的相同信念单纯形角点几何，通过输入依赖的状态选择而非 Query-Key 匹配实现。

分布式表示实现信念传输。逐层分析（图 21）揭示了 Mamba 与 LSTM 之间的关键差异：

- **Mamba**：最终层表示在熵预测上达到 $R^2 = 0.40$ ，PC1 仅解释 21.9% 的方差——模型保持了分布式的多维信念表示。
- **LSTM**：最终层表示达到 $R^2 = 0.004$ （接近随机），PC1 解释 92.3% 的方差——模型坍缩为与真实后验熵无关的一维流形。

这解释了原语差异：在我们的训练协议下，LSTM 的固定门控未能维持信念传输所需的多维结构，而 Mamba 的选择机制保留了它。

逐层熵编码。与 Transformer 中熵相关性在后期层急剧增加不同，Mamba 在中间层显示中等相关性（ $|r| \approx 0.11$ ），线性可预测性（ R^2 ）从第 1 层的 0.025 逐步提升到第 9 层的 0.40。这表明 Mamba 通过其循环状态更渐进地累积信息，而非通过离散消除步骤。

收敛到贝叶斯几何。不同机制——注意力的 Query-Key 匹配和 Mamba 的选择性状态更新——收敛到相似的几何解（信念单纯形的角点几何），这表明贝叶斯几何可能是具有基于内容路由的架构的通用吸引子。这为两种架构尽管使用根本不同的计算原语却在信念传输上均能成功提供了几何解释。

5.7 与梯度动力学预测的关系

这些实证观察与最近梯度动力学分析的预测一致，该分析表明一旦正确的路由结构形成，注意力分数趋于稳定，而 Value 和残差表示继续精化精度。观察到的注意力图稳定性与值流形的展开为路由和精度的这种差异收敛提供了直接证据。

6 分析与讨论

风洞实验表明，经过标准优化且无架构修改的小型 Transformer 以惊人的保真度实现了贝叶斯推理。本节讨论这些结果对可解释性、架构必要性以及受控风洞与大语言模型行为之间联系的广泛意义。

6.1 为何层次化注意力能实现贝叶斯推理

在双射和 HMM 设置中，节 5 揭示的内部几何展现出一致的计算模式。Transformer 通过堆叠的几何操作序列实现贝叶斯条件化：




Fig. 21. **逐层分析：Mamba 与 LSTM 在 HMM 上的对比。** 对每层，我们测量 PC1 方差（维度）、熵相关性（与不确定性对齐程度）和线性 R^2 （熵的可预测性）。左图：LSTM 坍塌为一维流形（ $PC1 > 90\%$ ），熵相关性接近零。右图：Mamba 保持分布式表示（ $PC1 \approx 22\%$ ），熵可预测性随深度增加。这解释了为何 LSTM 在信念传输上失败而 Mamba 成功。

- (1) **Foundational binding (Layer 0).** Orthogonal keys create a hypothesis frame. The catastrophic effect of ablating the Layer 0 hypothesis-frame head (图 6) demonstrates that this frame is structurally indispensable.
- (2) **Progressive elimination (middle layers).** QK-alignment sharpens across depth (图 17), mirroring the multiplicative suppression of ruled-out hypotheses in analytic Bayesian updates. Layer-wise ablations (图 5) show that each layer contributes a non-interchangeable refinement step.
- (3) **Precision refinement (late layers).** Once routing stabilizes, value representations unfold into a low-dimensional manifold parameterized by posterior entropy (图 18), improving calibration particularly at late positions (图 19). This frame-precision dissociation reflects a division of labor: attention establishes where information flows, while subsequent transformations refine the numerical precision of the belief.

This hierarchy parallels Bayes' rule: define a hypothesis space, integrate evidence, and refine the posterior. The transformer implements these steps using attention geometry and residual-stream representations.

6.2 深度作为组合的必要条件

消融研究的一个核心结论是深度并非冗余。在两种风洞中，移除任何单层会使校准误差增加一个数量级以上（图 5）。这表明贝叶斯推理被表达为一系列组合投影，每层以无法坍塌为单一变换的方式精化信念状态。

这与宽而浅的架构形成对比：即使参数量相当且训练相同，MLP 也无法进行假设消除或状态跟踪（节 4.6）。贝叶斯推理需要层次化精化，而 Transformer 通过深度和残差组合提供了适当的归纳偏置。

6.3 从风洞到自然语言

尽管风洞被有意简化，它们捕捉了概率推理的本质结构：随时间整合证据以更新潜在信念。大语言模型在远更复杂的设置中运行，具有高维潜在空间和模糊的多模态证据。但本文观察到的几何要素——正交的假设轴、深度方向的精化和稳定的路由——是结构性的而非任务特定的。

因此，结果表明 LLM 表现出的概率行为可能不仅来自规模或数据丰富度，也来自架构几何。风洞提供了一个可验证的下界：它们表明 Transformer 在后验已知时能够精确实现贝叶斯推理。

6.4 原语分类体系解释架构差异

四种架构的比较（表 2）揭示了贝叶斯推理并非单一整体——不同任务需要不同的推理原语，不同架构实现不同的子集。

为何 *Mamba* 在 HMM 上击败 *Transformer* 但在回忆上失败。*Mamba* 的选择性状态空间机制在转移动力学上实现了基于内容的路由：输入依赖的矩阵 (Δ, B, C) 控制哪些信息通过循环向前传播。这是信念传输的理想选择——跟踪后验如何通过随机动力学演化——解释了 *Mamba* 在 HMM 上的优越性（0.024 vs 0.049 bits）。

但绑定需要不同的操作：给定查询，从记忆中检索关联的值。注意力通过 Query-Key 匹配直接提供此功能，具有对任意位置的 $O(1)$ 访问能力。*Mamba* 必须通过其循环状态模拟检索，这更慢且精度更低。这解释了联想回忆上 2.5× 更长的训练时间和 97.8% vs 100% 的准确率差距。

为何 *LSTM* 在双射上成功但在其他所有任务上失败。*LSTM* 的门控仅依赖于 (h_{t-1}, x_t) ——在我们的训练协议下，它们未能学会跨位置执行基于内容的匹配。这对累积静态充分统计量足够了（双射允许一个固定维度的统计量：已观测输出的集合），但在以下情况下失败：

- **统计量必须在动力学下演化（传输）**：LSTM 将 HMM 表示压缩为与真实 5D 信念状态无关的一维流形——它未能通过转移矩阵传输信念向量。
- **统计量必须按内容索引（绑定）**：LSTM 在回忆上达到 0.5%（随机猜测）——它未能通过内容检索。

启示。*原语框架* 为架构选择提供了原则性基础：将架构的能力与任务的原始需求相匹配。它还解释了为何注意力在需要灵活检索的任务中仍然至关重要，即使像 *Mamba* 这样的替代方案在序列建模上表现出色。

6.5 LLM 推理的下界

风洞为 *Transformer* 中的机制推理建立了原则性基线。如果一个模型在具有闭式后验且记忆不可能的设置中无法实现贝叶斯推理，那么它在自然语言中几乎没有真正推理能力的证据。相反，小型可验证 *Transformer* 在此处成功——具有可解释的几何机制——表明类似的结构可能支撑大型模型中的推理。

这提供了一个具体的研究方向：在前沿 LLM 中搜索相同的几何特征。本文使用的诊断方法——Key 正交性、QK 锐化、值流形结构和路由稳定性——为分析预训练语言模型提供了可检验的预测。

6.6 双熵测量框架

风洞提供了一个可以以比特级精度测量推理质量的设置。我们通过一个双熵框架形式化这一概念，该框架将实践中常被混淆的两个量分离开来。

定义 1 (双熵 (Dual Entropies)) . 对于上下文序列 s :

- **上下文惊喜度 (Context Surprisal)** $H_I(s) = -\log p_{\text{train}}(s)$ 度量 s 在训练分布中的独特性（高 H_I = 稀有、信息量大的上下文）。
- **预测熵 (Prediction Entropy)** $H_P(s) = -\sum_i p_{\text{model}}(t_i | s) \log p_{\text{model}}(t_i | s)$ 度量模型在给定 s 条件下的预测不确定性（低 H_P = 置信预测）。

比率 $\rho = H_P/H_I$ 是一个归一化的每信息置信度系数。高 H_I 下的低 ρ 表明模型利用了独特的上下文证据来集中其后验——组合推理。低 H_I 下的低 ρ 表明从频繁训练模式中检索——死记硬背。仅靠预测熵 H_P 无法区分这些模式。

为什么风洞至关重要。*对于自然语言*， H_I 需要知道训练分布，而这不可用。在风洞中，两个量都可以解析计算：贝叶斯后验熵扮演了 H_I 的角色——它度量给定假设类下观测序列

的信息量——而模型的预测熵是 H_P 。本文报告的熵 MAE 是 $|H_P - H_{\text{Bayes}}|$ ：模型置信度与证据所保证的置信度之间的差距。

在我们的双射风洞中，训练后的 Transformer 实现了 $\rho \rightarrow 0$ ：预测熵追踪贝叶斯后验熵达到 0.007 bits，意味着模型的置信度在每个位置上都被精确校准到信息内容。这定量验证了该框架：节 5 中描述的几何结构——正交假设框架、熵参数化的值流形和稳定路由——是产生低 ρ 的计算基础。论文 II-III 表明，产生这种几何结构的梯度动力学实现了一种类似 EM 的算法，其中驱动路由的优势信号恰好在 H_I 高而 H_P 低时较大 [1, 2]，并且相同的低 ρ 几何在生产语言模型中持续存在。

7 相关工作

7.1 深度学习的贝叶斯解释

一系列长期的研究通过贝叶斯视角解释神经网络，从预测不确定性的经典分析 [12, 14] 到后验推理的变分或随机近似 [4, 8]。最近的研究认为，在大数据极限下，最小化交叉熵隐式地以贝叶斯后验预测为目标 [19, 20]。这些结果关注训练在人群水平上应该产生什么。我们的贡献是互补的：一个受控设置，其中真实后验已知、记忆在计算上不可行，并且可以直接测试有限 Transformer 是否实际上实现了这种贝叶斯计算。

7.2 上下文学习与算法泛化

研究表明，Transformer 可以在上下文内执行算法任务，包括算术 [7]、合成归纳 [6]，以及更一般的模式外推 [3, 15]。在行为上，这些模型常常类似于贝叶斯学习器，这一观察已被最近的解释性理论形式化 [19, 20]。Panwar et al. [16] 提供了高容量 Transformer 在上下文学习中常常模仿贝叶斯预测器的证据，Reuter et al. [18] 则证明 Transformer 可以对包括广义线性模型和潜在因子模型在内的统计模型执行完整的贝叶斯推理，其结果可与昂贵的精确方法相媲美。

然而，先前的工作无法区分真正的贝叶斯计算与学习到的启发式方法或记忆模板，因为自然语言任务的真实后验是未知的。此外，这些研究关注 Transformer 是否能实现贝叶斯推理，而非为何它们能在其他架构失败时成功。

我们的风洞方法解决了这两个空白：通过构建具有闭式解析后验和组合大假设空间的任务，我们获得了模型预测与贝叶斯法则之间的直接逐点比较。通过比较多种架构，我们识别出解释成功与失败的推理原语。这将讨论从相关性推进到机制，从存在性推进到架构特征刻画。

7.3 机制可解释性与注意力几何

Transformer 的机制研究揭示了用于归纳、复制和检索的专门注意力头 [5, 13]。其他工作考察了 QKV 空间、电路分解以及训练中出现的稀疏结构 [15]。这些研究提供了对模型行为的定性和电路级洞察。

我们的贡献在于将这些几何结构直接关联到后验已知的设置中的贝叶斯推理。我们展示了 Key 形成接近正交的假设轴，Query 随深度锐化到可行假设上，而 Value 表示展开为一维熵流形。这以严谨的方式将机制可解释性与概率计算联系起来：贝叶斯推理所需的内部几何变得直接可见。

7.4 架构比较与复制问题

替代的序列模型——状态空间架构 [9, 10]、卷积变体 [17] 和循环网络——在自然文本的困惑度上常常与 Transformer 相当。但困惑度混淆了建模和推理能力。我们的结果提供了一个更精细的测试：架构能否在严格非记忆约束下再现解析贝叶斯后验。

最近的研究识别了状态空间模型的一个根本局限：Jelassi et al. [11] 表明 SSM 在复制和检索任务上存在困难，因为它们将输入压缩为固定大小的潜在状态。参数比 Mamba 少 $10\times$ 的

Transformer 在检索上优于 Mamba，而 Mamba 需要 $100\times$ 更多的训练数据来学习简单复制。这一局限源于循环结构本身——信息必须显式存储在状态中而非按需检索。

我们的原语框架为这些发现提供了统一解释。我们将贝叶斯推理分解为三种原语：信念累积（整合证据）、信念传输（通过动力学传播信念）和随机访问绑定（通过内容检索假设）。Jelassi et al. [11] 识别的复制/检索局限恰好对应我们的绑定原语。Mamba 的选择性状态空间机制 [9]——其中转移矩阵 Δ 、 B 、 C 变为输入依赖——在转移动力学上实现基于内容的路由，支持累积和传输。但这与注意力通过 Query-Key 匹配直接检索任意过去位置的能力根本不同。

这解释了我们的经验模式：Mamba 在以信念传输为主的任务 HMM 滤波上优于 Transformer (0.027 vs 0.049 bits MAE)，因为其选择机制针对控制哪些信息向前传播进行了优化。但 Mamba 在联想回忆上更慢 (97.8% vs 100%，需要 $2.5\times$ 更多 Epoch)，这是需要随机访问绑定的任务。LSTM 在两者上都失败，因为其门控仅依赖于 (h_{t-1}, x_t) ——在我们的训练协议下，它们未能学会跨位置基于内容匹配。因此，原语分类体系预测了哪个架构将在哪个任务上表现出色，解决了文献中的表面矛盾。

最近的研究表明 SSM 性能强烈依赖于优化：模仿初始化可以在 Mamba 中产生类似注意力的行为，改善复制和自回归任务。我们的原语结论刻画了每个架构在标准训练下实现了什么，而非绝对能力上限。通过专门的初始化或更广泛的超参数搜索，我们观察到的差距可能会缩小——尽管定性模式（Mamba 在传输上出色，在绑定上困难）在我们的实验中似乎是鲁棒的。

7.5 训练动力学

最后，并行工作分析了在训练中创建这些结构的梯度动力学 [2]。他们表明注意力和 Value 更新遵循耦合规律，产生稳定的路由框架和逐步精化的值流形。我们的实证发现与此图景一致：注意力早期稳定，而 Value 向量继续以更高分辨率编码后验。综合来看，这些视角将优化轨迹与实现贝叶斯推理的几何结构联系起来。

8 局限性与未来工作

我们的实验有意采用小规模设置：使用具有解析后验的受控贝叶斯风洞、适中的词表大小和 2–3M 参数的 Transformer。这种设置使得机制验证成为可能，但它自然抽象掉了自然语言推理的全部复杂性。因此仍存在若干局限性，它们直接指向未来的扩展方向。

推理任务的规模与丰富性。双射和 HMM 捕捉了贝叶斯计算的基本要素——离散消除和递归状态跟踪——但它们仅代表大语言模型遇到的推理问题的一小部分。未来的风洞可以纳入更丰富的潜在变量结构，包括卡尔曼滤波、层次贝叶斯模型或因果图模型，所有这些都具有闭式后验并允许精确验证。

假设空间的维度。尽管两个任务中的假设空间都大到足以防止记忆，其表示维度适中（例如 HMM 中的五个隐藏状态）。具有高维潜在变量的更大系统将测试我们观察到的几何机制——正交假设轴、渐进 Q-K 锐化和值流形精化——是否随维度平滑扩展。

与大型预训练模型的联系。我们的几何诊断（Key 正交性、分数梯度结构、值流形）是对前沿 LLM 的可检验预测。在自然文本上训练的大型模型中是否会出现类似的贝叶斯流形仍是一个开放问题。将这些工具直接应用于预训练 Transformer 层是自然的下一步，可能揭示近似贝叶斯结构如何在更复杂的环境中显现。

架构通用性。本文的实验使用标准 Transformer。尚不清楚替代架构——状态空间模型、具有更复杂门控的深度 MLP 或混合循环注意力系统——能否形成可比的贝叶斯流形。风洞评估可以提供原则性基准，从推理保真度而非仅困惑度角度比较架构。

训练动力学与相变。一个值得注意的经验现象是框架-精度分离：注意力图早期稳定，而值流形继续展开并精化后验精度。对这些阶段的系统研究——框架多早形成、精度提升多快，以及这些动力学如何依赖于深度、宽度和数据复杂度——可以导向更一般的 Transformer 表示形成理论。

迈向自然语言风洞。最终，我们旨在理解此处展示的精确贝叶斯推理与自然语言任务中观察到的近似推理之间的关系。风洞提供了一个下界：它们确立了 Transformer 在问题良好指定时能够实现贝叶斯更新。下一个挑战是设计嵌入自然语言数据中的受控任务，在保持解析结构的同时引入真实世界的模糊性。

9 结论

我们引入了贝叶斯风洞——具有解析后验和组合巨大假设空间的受控实验设置——以测试神经序列模型是真正实现贝叶斯推理还是仅模仿它。在多个推理问题上，小型 Transformer 以亚比特校准误差收敛到精确贝叶斯后验，即使在远超训练长度的序列上也是如此。

关键洞察在于贝叶斯推理并非单一整体。我们将其分解为三种推理原语——信念累积、信念传输和随机访问绑定——并展示了不同架构实现不同的子集：

- **Transformer** 实现了全部三种原语并全面成功。
- **Mamba** 实现了累积和传输，在 HMM 滤波上达到最先进水平，但在随机访问绑定上存在困难。
- **LSTM** 仅实现静态充分统计量的累积：它们在信念修正（其中统计量是固定维度的）上成功，但在统计量须在动力学下演化或按内容索引时失败。
- **MLP** 未实现任何原语并全面失败。

几何诊断揭示了这些原语如何实现。Key 在假设上形成接近正交的基；Query 渐进地与该基的可行区域对齐；Value 向量沿由后验熵参数化的低维流形组织。在 HMM 跟踪中，Mamba 的表示组织成五个离散聚类——每个隐藏状态一个——表明模型发现了信念单纯形的角点几何。训练雕琢了这一流形：注意力模式早期稳定，而 Value 表示继续精化后验精度——这是并行梯度动力学分析预测的框架-精度分离。

风洞设置被有意简化，但它确立了一个清晰的下界：如果一个模型在后验已知且记忆不可能的设置中无法实现贝叶斯推理，那么它在自然语言中也无法做到。相反，我们的结果表明，当任务仅要求该架构能实现的那些原语时，基于内容的路由足以实现精确贝叶斯推理。这为研究更大模型中的近似推理提供了原则性基础，并为分析预训练 LLM 提供了具体可检验的预测——正交假设轴、渐进 Q-K 锐化和值流形结构。

原语框架解释了为何 Transformer 成功：它们提供了所有三种推理原语的架构机制。注意力通过 Query-Key 匹配提供随机访问绑定；基于内容的路由实现信念传输；残差流跨位置累积证据。理解这些原语如何扩展到真实语言，以及新架构能否更高效地实现它们，仍然是未来工作的重要方向。

参考文献

- [1] Naman Agarwal, Siddhartha R. Dalal, and Vishal Misra. 2025. Geometric Scaling of Bayesian Inference in LLMs. arXiv:2512.23752 [cs.CL] <https://arxiv.org/abs/2512.23752> Paper III of the Bayesian Attention Trilogy.
- [2] Naman Agarwal, Siddhartha R. Dalal, and Vishal Misra. 2025. Gradient Dynamics of Attention: How Cross-Entropy Sculpt Bayes Manifolds. arXiv:2512.22473 [cs.LG] <https://arxiv.org/abs/2512.22473> Paper II of the Bayesian Attention Trilogy.
- [3] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. 2023. What Learning Algorithm is In-Context Learning? Investigations with Linear Models. In *International Conference on Learning Representations*.
- [4] Charles Blundell, Julien Cornebise, Koray Kavukcuoglu, and Daan Wierstra. 2015. Weight Uncertainty in Neural Networks. In *Proceedings of the 32nd International Conference on Machine Learning*. 1613–1622.
- [5] Nelson Elhage, Neel Nanda, Catherine Olsson, Tom Henighan, Nicholas Joseph, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Nova DasSarma, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez,

- Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Jack Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. 2021. A Mathematical Framework for Transformer Circuits. Transformer Circuits Thread, Anthropic. <https://transformer-circuits.pub/2021/framework/index.html>
- [6] Jeffrey L Elman. 1990. Finding structure in time. *Cognitive Science* 14, 2 (1990), 179–211.
- [7] Shivam Garg, Dimitris Tsipras, Percy S. Liang, and Gregory Valiant. 2022. What Can Transformers Learn In-Context? A Case Study of Simple Function Classes. In *Advances in Neural Information Processing Systems*, Vol. 35. 29881–29895.
- [8] Alex Graves. 2011. Practical Variational Inference for Neural Networks. In *Advances in Neural Information Processing Systems*, Vol. 24.
- [9] Albert Gu and Tri Dao. 2023. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. *arXiv preprint arXiv:2312.00752* (2023).
- [10] Albert Gu, Karan Goel, and Christopher Ré. 2022. Efficiently Modeling Long Sequences with Structured State Spaces. In *International Conference on Learning Representations*.
- [11] Samy Jelassi, David Brandfonbrener, Sham M. Kakade, and Eran Malach. 2024. Repeat After Me: Transformers are Better than State Space Models at Copying. *arXiv preprint arXiv:2402.01032* (2024). <https://arxiv.org/abs/2402.01032>
- [12] David J. C. MacKay. 1992. A Practical Bayesian Framework for Backpropagation Networks. *Neural Computation* 4, 3 (1992), 448–472.
- [13] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. 2023. Progress Measures for Grokking via Mechanistic Interpretability. *arXiv preprint arXiv:2301.05217* (2023).
- [14] Radford M. Neal. 2012. *Bayesian Learning for Neural Networks*. Lecture Notes in Statistics, Vol. 118. Springer.
- [15] Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, et al. 2022. In-Context Learning and Induction Heads. Transformer Circuits Thread, Anthropic. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/index.html>
- [16] Madhur Panwar, Kabir Ahuja, and Navin Goyal. 2024. In-Context Learning Through the Bayesian Prism. In *International Conference on Learning Representations*. <https://openreview.net/forum?id=HX5ujdsSon>
- [17] Michael Poli, Stefano Massaroli, et al. 2023. Hyena Hierarchy: Towards Larger Convolutional Language Models. In *International Conference on Machine Learning*.
- [18] Arik Reuter, Tim G. J. Rudner, Vincent Fortuin, and David Rügamer. 2025. Can Transformers Learn Full Bayesian Inference in Context?. In *International Conference on Machine Learning*. <https://arxiv.org/abs/2501.16825> arXiv:2501.16825.
- [19] Johannes von Oswald, Eyvind Niklasson, Ettore Randazzo, João Sacramento, Alexander Mordvintsev, Andrey Zhmoginov, and Max Vladymyrov. 2023. Transformers Learn In-Context by Gradient Descent. *arXiv preprint arXiv:2212.07677* (2023). Also appeared in ICML 2023.
- [20] Sang Michael Xie, Aditi Raghunathan, Percy Liang, and Tengyu Ma. 2022. An Explanation of In-Context Learning as Implicit Bayesian Inference. In *International Conference on Learning Representations*.