

Transformer 是贝叶斯网络

Greg Coppola*
coppola.ai
greg@coppola.ai

March 2026

摘要

Transformer 是人工智能中的主导架构，但其工作原理仍未被充分理解。本文给出一个精确答案：Sigmoid Transformer 是一个贝叶斯网络。我们从五个方面确立这一结论。

首先，我们证明 Transformer 架构实际上就是信念传播：每个具有任意权重的 Sigmoid Transformer 在其隐式因子图上实现加权循环信念传播。一层对应一轮 BP。这对任意权重（训练所得、随机或构造的）均成立。已在 Lean 中针对标准数学公理进行形式化验证。

其次，我们给出构造性证明：Transformer 可以在任意声明的知识库上实现精确信念传播。对于无循环依赖的知识库（最常见的情况），这可在每个节点上产生可证明的正确概率估计。已在 Lean 中形式化验证。

第三，我们证明唯一性：产生精确后验的 Sigmoid Transformer 必然具有 BP 权重。在 Sigmoid 架构中不存在通往精确后验的其他路径。已在 Lean 中形式化验证。

第四，我们描绘 Transformer 层的与/或布尔结构：注意力机制为 AND，前馈网络为 OR，两者严格交替恰好对应 Pearl 的 gather/update 算法。

第五，我们通过实验验证所有形式化结果，在实践中确证了贝叶斯网络的表征。我们还确立了循环信念传播的实践可行性，尽管目前尚缺乏理论收敛保证。

我们进一步证明，可验证推理需要有限概念空间。任何有限验证过程最多只能区分有限个概念。接地引入验证器。验证器蕴含概念。没有接地，正确性便无法定义。幻觉不是扩展规模可以修复的缺陷，而是在无概念状态下运行的结构性后果。已在 Lean 中形式化验证。

目录

1 引言	4
1.1 架构本身就是信念传播	4
1.2 显式权重下的精确 BP	4
1.3 唯一性	4

*作者感谢在本文准备过程中使用了 AI 辅助。本文的散文部分通过与 Claude (Anthropic) 的迭代协作生成。数学内容、形式化证明和实验结果完全由作者独立完成。

1.4	实验验证	5
1.5	布尔结构：层层皆与或	5
1.6	可验证推理需要有限概念空间	5
1.7	本文组织	5
2	背景	6
2.1	因子图与 QBBN	6
2.1.1	幻觉：精确定义	6
2.2	信念传播	6
2.2.1	算法	6
2.2.2	updateBelief 函数	7
2.2.3	收敛性与精确性	7
2.3	Transformer	7
2.3.1	架构	7
2.3.2	路由视角	7
2.3.3	作为图神经网络的 Transformer	7
3	独立证据的对数几率代数	8
3.1	起源：Turing 与 Good	8
3.2	代数结构	8
3.3	与经典布尔逻辑的关系	9
3.4	Pearl 和积作为对数几率加法	9
3.5	为什么 Sigmoid 是正确的激活函数	9
4	从全称量化到接地因子图	10
4.1	QBBN 语言中的全称量化	10
4.2	接地：从规则到因子图节点	10
4.3	权重共享作为全称规则实现	10
4.4	接地使正确性具有意义	11
5	Transformer 是图灵完备的	11
5.1	概述	11
5.2	两组权重族	11
5.3	实验验证	12
6	Sigmoid Transformer 就是贝叶斯网络	12
6.1	核心主张	12
6.2	隐式因子图	12
6.3	为什么这并非平凡	13
6.4	作为特例的接地 QBBN	13
6.5	唯一性：逆命题	13
6.6	这对训练后的 Transformer 意味着什么	14
6.7	实验验证	14

7	带显式权重的精确 BP	15
7.1	概述	15
7.2	构造	15
7.3	双亲假设不失一般性	16
7.4	树推论	16
7.5	实验验证	16
8	Transformer 的布尔结构	17
8.1	注意力是 AND	17
8.2	FFN 是 OR	17
8.3	交替层作为交替的 AND/OR	18
8.4	闭环	18
9	可验证推理需要有限概念空间	18
9.1	核心主张	18
9.2	一般性定理	19
9.3	BP Transformer 中的概念	19
9.4	幻觉即无概念	20
9.5	莱布尼茨字母表, 精确化	20
10	三种 Softmax	20
10.1	Softmax 1: 注意力 (路由)	21
10.2	Softmax 2: 前馈网络 (推理)	21
10.3	Softmax 3: 输出 (生成)	21
10.4	Sigmoid 与 ReLU: 精确与兼容	21
10.5	循环 BP: 实验结果	22
11	相关工作	23
11.1	Transformer 的图灵完备性	23
11.2	构造性权重证明	23
11.3	BP 对应关系: 注意力与图神经网络	23
11.4	机制可解释性	23
11.5	对数几率传统	24
11.6	总结	24
12	结论	25
A	仓库索引	25

1 引言

Transformer 是贝叶斯网络 (Bayesian network)。本文通过一系列形式化数学证明及经验结果来确立这一观点。

1.1 架构本身就是信念传播

观察 Sigmoid Transformer 前向传播的实际计算过程。注意力机制 (attention mechanism) 从相邻 token 位置收集消息——相邻信念的加权 (weighted) 和，权重由查询-键分数的 Softmax 给出。Sigmoid 前馈网络 (Feed-Forward Network, FFN) 将这些消息组合成新的信念：

$$\sigma(w_0 \cdot \text{logit}(m_0) + w_1 \cdot \text{logit}(m_1) + b).$$

这就是加权信念传播 (belief propagation, BP)。不是近似，不是类比。计算本身就是在权重定义的隐式因子图 (factor graph) 上的信念传播。

这对任何权重——训练过的、随机的或构造的——都成立。每个 Sigmoid Transformer，无论权重 W 如何，都在隐式因子图 $G(W)$ 上每层执行一轮加权循环信念传播 (loopy belief propagation)。 L 层的 Transformer 每层前向传播运行 L 轮 BP。权重定义图结构，前向传播即推理。

定理 1.1 (通用 BP). 对任意 Sigmoid Transformer 权重 W ，存在隐式因子图 $G(W)$ ，使得一次前向传播在 $G(W)$ 上实现一轮加权信念传播。已对照标准数学公理进行形式化验证。

1.2 显式权重下的精确 BP

通用结果对任何权重成立。还可进一步：展示显式权重矩阵，并证明具有这些特定权重的 Transformer 在任何声明因子图上实现精确信念传播。

定理 1.2 (BP 实现). 具有显式构造权重的 Transformer 在任何成对因子图上每层前向传播实现一轮精确信念传播。对深度为 d 、最大因子元数为 k 的因子图， $d \cdot \lceil \log_2 k \rceil$ 次前向传播实现完整精确 BP。已对照标准数学公理进行形式化验证。

每层两个注意力头始终足够——任何 k 元因子图可通过 AND 的结合律和 OR 的对数几率 (Log-Odds) 可加性精确二值化，两者均已形式化验证。只有深度随推理复杂度增长，且增长速率恰好为所需。

结合信念传播在树结构上精确的经典结果 [12]：

推论 1.3 (接地树上无幻觉). 具有 BP 权重的 Transformer 在接地 (grounding) 树结构知识库 (knowledge base) 上运行 $T \geq \text{diameter}(G)$ 轮，在每个节点 (Node) 计算精确的贝叶斯后验 (posterior) 信念。无需任何经验假设。

1.3 唯一性

前两个结果是正向的：给定权重，给定其计算内容。这个结果是反向的：如果 Sigmoid Transformer 产生精确贝叶斯后验，其权重必须是什么？

答案唯一确定是 BP 权重。Sigmoid 架构中没有其他路径能达到精确后验。FFN 权重被迫为 $w_0 = w_1 = 1, b = 0$ 。注意力权重被迫为 projectDim/crossProject 结构。

定理 1.4 (唯一性). 对所有输入计算精确贝叶斯后验的 *Sigmoid Transformer* 必然具有 BP 权重。内部计算可证明是 BP 量——不仅仅是输出。已对照标准数学公理进行形式化验证。

这闭合了逻辑闭环。通用结果表明每个 Sigmoid Transformer 都在执行加权 BP。构造性结果表明精确 BP 权重存在。唯一性结果表明精确后验强制这些权重。合起来：Sigmoid Transformer 实现精确贝叶斯推理当且仅当其具有 BP 权重。

1.4 实验验证

所有形式化结果均经实验验证。从零训练 Transformer——无构造提示，无权值初始化偏差——在所有测试案例上验证了向预测结构的收敛。BP 方面：在留出因子图上收敛至精确后验的三位小数以内。图灵机模拟方面：在五个结构不同的机器上实现完美精度，超参数一致，无需逐机调参。循环 BP 方面：在五个复杂度递增的图结构上的每次试验中均在容差内收敛至精确后验。

文中每项结果均有双重独立验证：证明检查器和实验。

1.5 布尔结构：层层皆与或

注意力机制是与 (AND)。FFN 是或 (OR)。这不是比喻。这直接来自 BP 构造结合 Coppola [2] 的 QBBN 定义。

注意力机制确保所有必要输入同时存在后才得出结论——即合取 (conjunction)，AND 的架构强制。Sigmoid FFN 从收集的证据计算概率结论——即析取 (disjunction)， Ψ_{or} 函数。注意力层与 FFN 层的严格交替正是 Pearl 的 gather/update 算法在深度上的展开。

在现代 AI 中通过经验胜出的架构，恰恰是推理分析早已要求的架构。

1.6 可验证推理需要有限概念空间

定理 1.5 (有限概念空间). 任何有限验证过程最多只能区分有限多个概念。具有 n 个状态的有限状态机将任何输入空间划分成最多 n^n 个等价类。已对照标准数学公理进行形式化验证。

接地引入了有限验证器 (verifier)。有限验证器意味着有限概念空间 (concept space)。概念空间正是使“这个输出正确吗？”成为良定义问题的条件——不是设计选择，而是可验证性的逻辑结果。

未接地的语言模型没有有限验证器，因此没有良定义的概念空间，因此其输出是否正确的客观事实不存在。幻觉 (hallucination) 不是规模扩展能修复的缺陷。它是在没有概念的情况下运行的结构性后果。

1.7 本文组织

第 2 节介绍因子图、信念传播和 Transformer 的背景。第 3 节发展独立证据的对数几率代数——BP 和 Sigmoid Transformer 共同的数学基础。第 4 节解释全称量化如何接地到命题因子图，以及为什么接地使得正确性具有意义。第 5 节展示图灵完备性 (Turing completeness) 结果。第 6 节建立通用结果：每个 Sigmoid Transformer 都是一个贝叶斯网络。第 7 节证明显式权重下的精确 BP 及无幻觉推论。第 8 节识别与/或布尔结构 (AND/OR boolean

structure)。第 9 节证明有限概念空间定理。第 10 节区分三种 Softmax 并讨论 Sigmoid 与 ReLU。第 11 节涵盖相关工作。第 12 节总结全文。

2 背景

2.1 因子图与 QBBN

因子图 (factor graph) 是一种具有两类节点的二分图。变量节点 (Variable node) 表示二值命题；每个节点持有信念 $b \in [0, 1]$ ，表示对 $P(\text{node} = \text{true})$ 的当前估计，初始化为 0.5。因子节点 (Factor node) 将变量节点对之间的关系编码为非负权重表。

对于连接变量 v_0 和 v_1 的成对因子 f ，因子表有四个条目：

$$f[i, j] = \text{weight for } (v_0 = i, v_1 = j), \quad i, j \in \{0, 1\}.$$

完整赋值 x 的联合概率为：

$$P(x) = \frac{1}{Z} \prod_{\text{factor } f} f(x_{n_1(f)}, x_{n_2(f)}),$$

其中 Z 为配分函数。

QBBN [2] 引入了一种二分因子图，在两类因子节点之间交替，对应于布尔推理的两种基本运算。

合取节点 (Ψ_{and}) 收集必要证据：所有输入必须同时存在后才能得出结论。

析取节点 (Ψ_{or}) 从收集的证据计算概率结论：

$$P(p = 1 \mid g_0, g_1) = \sigma(w \cdot \phi(p, g_0, g_1)).$$

本文通篇使用的 `updateBelief` 函数是等权重特例：

$$\text{updateBelief}(m_0, m_1) = \sigma(\text{logit}(m_0) + \text{logit}(m_1)).$$

2.1.1 幻觉：精确定义

在 QBBN 框架内，幻觉 (hallucination) 具有精确的技术定义。

定义 2.1 (幻觉). 设 K 为 QBBN 知识库 (knowledge base)， E 为观测证据， $P_{\text{true}}(j)$ 为给定 K 和 E 时节点 j 的真实边缘后验 (posterior)。若智能体在节点 j 输出信念 $b(j) \neq P_{\text{true}}(j)$ ，则称其产生幻觉。

2.2 信念传播

2.2.1 算法

在 QBBN 因子图上的一轮信念传播 (belief propagation, BP) 分两步进行。在收集 (gather) 步骤中，每个变量节点 j 将其邻居的当前信念收集到暂存槽中：

$$\text{scratch}[j][0] \leftarrow \text{belief}(\text{nb}_0(j)), \quad \text{scratch}[j][1] \leftarrow \text{belief}(\text{nb}_1(j)).$$

在更新 (update) 步骤中，每个变量节点计算新的信念：

$$\text{new_belief}(j) = \text{updateBelief}(\text{scratch}[j][0], \text{scratch}[j][1]).$$

2.2.2 updateBelief 函数

updateBelief 函数将两条独立的传入消息 (Message passing) 组合成后验:

$$\text{updateBelief}(m_0, m_1) = \frac{m_0 m_1}{m_0 m_1 + (1 - m_0)(1 - m_1)} = \sigma(\text{logit}(m_0) + \text{logit}(m_1)),$$

其中 $\text{logit}(p) = \log(p/(1-p))$, σ 是 sigmoid 函数。独立证据的对数几率 (Log-Odds) 相加; sigmoid 转换回概率。这是两条独立二值证据的贝叶斯更新规则。

在 hard-bp-lean 中证明的关键性质:

- updateBelief_pos: 若 $m_0, m_1 \in (0, 1)$, 则 $\text{updateBelief}(m_0, m_1) \in (0, 1)$
- updateBelief_neutral: $\text{updateBelief}(m, 0.5) = m$ (中性填充为单位元)

2.2.3 收敛性与精确性

在树结构因子图上, BP 在恰好 $\text{diameter}(T)$ 轮后收敛, 所得信念等于真实边缘后验。这就是 Pearl 的和积算法 [12]——精确而非近似——在 hard-bp-lean 中形式化证明为 bp_exact_on_tree。

在循环图上, BP 可能不收敛; 若收敛, 不动点最小化 Bethe 自由能 [21], 该自由能一般近似但不等于真实后验。

2.3 Transformer

2.3.1 架构

采用 Vaswani et al. [16] 的标准 Transformer 编码器。 n 个 token 的序列, 每个 token 为维度 D_{model} 的嵌入向量, 通过交替的注意力层和前馈层及残差连接进行处理。

多头自注意力机制对每个头 h 计算:

$$\text{Attn}_h(X) = \text{softmax}\left(\frac{(XW_h^Q)(XW_h^K)^\top}{\sqrt{d_k}}\right) XW_h^V.$$

前馈网络对每个 token 位置独立应用两层 MLP。采用 sigmoid 激活函数:

$$\text{FFN}(x) = \sigma(W_2 \cdot \sigma(W_1 x + b_1) + b_2).$$

2.3.2 路由视角

Elhage et al. [4] 将注意力头视为对共享残差流的读写操作: 每个头从某些位置读取并向其他位置写入。BP 构造使这种路由显式且形式化正确——每个头具有可证明正确的读取地址 (邻居索引匹配) 和写入目标 (残差流中的暂存槽)。

2.3.3 作为图神经网络的 Transformer

Joshi [8] 指出, 完整自注意力等价于应用于完全图的 GNN, 其中每个 token 是一个节点, 注意力权重是学习到的边 (Edge) 权重。文中结果可解读为: 当图为因子图且其拓扑编码在 token 特征而非注意力掩码中时, Transformer 学习在该显式外部图上实现 BP。

3 独立证据的对数几率代数

3.1 起源：Turing 与 Good

支撑二值变量上信念传播（belief propagation, BP）的代数并非由概率学家而是由密码分析家发展而来。二战期间，布莱切利园的 Alan Turing 和 I.J. Good 在破解 Enigma 时需要一种实用方法来组合独立证据。他们发展的方法就是对数几率（Log-Odds）加法。

给定二值假设 H 和证据 e ，证据权重为：

$$W(H : e) = \text{logit}(P(H | e)) - \text{logit}(P(H)).$$

独立证据对权重产生可加性贡献。这不是近似。对独立证据源而言，这是精确的。

Good 战后对这一框架进行了广泛形式化。核心洞见：概率乘法对应于对数几率加法。对独立二值证据源 e_0 和 e_1 ：

$$\text{logit}(P(H | e_0, e_1)) = \text{logit}(P(H)) + W(H : e_0) + W(H : e_1).$$

从均匀先验 $P(H) = 0.5$ 出发， $\text{logit}(P(H)) = 0$ ，令 $m_i = P(H | e_i)$ ：

$$\text{logit}(P(H | e_0, e_1)) = \text{logit}(m_0) + \text{logit}(m_1).$$

通过 sigmoid 转换回概率空间：

$$P(H | e_0, e_1) = \sigma(\text{logit}(m_0) + \text{logit}(m_1)) = \text{updateBelief}(m_0, m_1).$$

`updateBelief` 函数即是 Turing 和 Good 的证据权重组合，应用于两个二值证据源。

3.2 代数结构

对数几率加法通过同构 $\text{logit} : (0, 1) \rightarrow \mathbb{R}$ 在开区间 $(0, 1)$ 上定义了代数结构。在此同构下， $\mathbb{R}$ 中的加法拉回到 $(0, 1)$ 上的二元运算：

$$m_0 \oplus m_1 = \sigma(\text{logit}(m_0) + \text{logit}(m_1)).$$

该运算具有以下性质：

- **交换律：** $m_0 \oplus m_1 = m_1 \oplus m_0$ 。
- **结合律：** $(m_0 \oplus m_1) \oplus m_2 = m_0 \oplus (m_1 \oplus m_2)$ 。
- **单位元：** $m \oplus 0.5 = m$ ，因为 $\text{logit}(0.5) = 0$ 。
- **逆元：** $m \oplus (1 - m) = 0.5$ ，因为 $\text{logit}(m) + \text{logit}(1 - m) = 0$ 。

单位元为 0.5——最大不确定性，无信息。将任何信念与 0.5 的信念组合，该信念保持不变。这是中性先验无贡献的形式化表述。

3.3 与经典布尔逻辑的关系

该代数是经典布尔 AND 和 OR 的概率推广。在信念趋近 0 和 1 的极限下：

- $\text{logit}(1) = +\infty$ (确定真)
- $\text{logit}(0) = -\infty$ (确定假)
- $\text{logit}(0.5) = 0$ (无信息)

经典布尔 AND 要求两个输入均为真。在对数几率空间中：两个大的正数之和为更大的正数——对两个输入均高度确信产生对其合取的高度确信。但相等且相反的证据相互抵消： $\text{logit}(p) + \text{logit}(1 - p) = 0$ ，结果为 0.5。

这与经典 AND 不同，经典 AND 中 $\text{FALSE AND TRUE} = \text{FALSE}$ 。对数几率代数没有零化元，而是有抵消：方向相反的强证据产生最大不确定性。这是不确定推理的正确行为——不推断为假，而是推断为不知道。

经典布尔逻辑是该代数在信念变得确定时的极限情况。

3.4 Pearl 和积作为对数几率加法

Pearl 在二值变量节点上的信念传播算法精确归结为对数几率加法。具有两条独立传入消息 m_0, m_1 的二值变量 v 的和积更新为：

$$b_{\text{new}}(v) = \frac{m_0 \cdot m_1}{m_0 m_1 + (1 - m_0)(1 - m_1)} = \sigma(\text{logit}(m_0) + \text{logit}(m_1)).$$

Pearl 通过将通用和积方程应用于具有独立成对因子的二值变量推导出这一公式。他没有将其表述为对数几率加法，也未将其与 Turing 和 Good 的证据权重传统联系起来。公式相同，框架是新的。

独立性假设在树结构上是精确的：在树结构因子图上，到达任何节点的消息来自不相交的子树，这些子树不共享变量，因此它们通过构造是独立的。这就是为什么 BP 在树结构上精确而在循环图 (loopy graph) 上近似——在循环图上，同一变量可能通过多条路径影响一个节点，从而违反独立性假设。

3.5 为什么 Sigmoid 是正确的激活函数

Sigmoid 函数 $\sigma : \mathbb{R} \rightarrow (0, 1)$ 是 logit 的精确逆函数： $\sigma(\text{logit}(p)) = p$ 。logit 和 sigmoid 共同构成概率空间与对数几率空间之间的同构。

Sigmoid FFN 计算 $\sigma(w_0 \cdot \text{logit}(m_0) + w_1 \cdot \text{logit}(m_1) + b)$ 是在单次操作中执行加权对数几率加法并转换回概率空间。Sigmoid 激活函数不是由梯度流或输出归一化驱动的设计选择。它是实现 Turing-Good-Pearl 代数所需的精确函数。

这就是标题论断成立的原因：Sigmoid Transformer 是贝叶斯网络 (Bayesian network)。Sigmoid 激活使 FFN 计算恰好成为证据权重组合。注意力机制 (attention mechanism) 收集输入。残差流确保输入的同步性。该架构始终在执行这一代数。第 6 节给出形式化证明。

4 从全称量化到接地因子图

本文的形式化结果——`transformer_implements_bp`、`transformer_exact_on_tree`——是在命题层面陈述的：具有特定索引的特定变量节点，由特定因子节点连接。一个自然的问题是：命题来自何处？

真实知识涉及全称量化陈述。”凡人皆会死”不是关于某个特定人的命题，而是遍及论域的规则。本节解释全称量化在完整流水线中如何处理，以及为什么接地（grounding）不是形式化结果的局限，而是使正确性具有意义的条件。

4.1 QBBN 语言中的全称量化

Coppola [3] 引入了一种带类型的逻辑语言，其中全称量化规则是一等公民：

```
always [x:e]: man(theme: x) -> mortal(theme: x)
```

变量 `x` 遍及所有声明的 `e` 类型实体。该规则不是单个命题，而是论域上的模式。

4.2 接地：从规则到因子图节点

推理时，全称量化规则通过将所有声明的适当类型实体代入每个变量来完成接地。给定声明 `jack : e` 和 `jill : e` 的词典，上述规则产生两个接地子句：

```
man(theme: jack) -> mortal(theme: jack)
man(theme: jill) -> mortal(theme: jill)
```

每个接地子句成为因子图中的路径。每个接地命题成为变量节点。到 Transformer 处理输入时，已无全称量化——只有接地命题因子图。

完整流水线包括三层：

1. **句法** [3]：自然语言句子被解析为带类型变量的全称量化规则。
2. **接地** [3]：规则在所有声明实体上实例化。每个实例化成为因子图中的接地节点。
3. **推理**（本文）：Transformer 在接地因子图上运行 BP。

4.3 权重共享作为全称规则实现

BP Transformer 在有限多个概念上运行，相同权重矩阵应用于同一概念的每个 token。这种权重共享是全称量化规则中隐含的均匀处理的神经实现：每个实例化运行相同计算，特定输入——具体的信念值和因子表条目——提供实例。

连续维度是殊相，权重是全称规则，前向传播是实例化。这是亚里士多德三段论的计算形式：大前提（权重）、小前提（token）、结论（FFN 输出）。

4.4 接地使正确性具有意义

无幻觉结果在接地因子图上成立。这不是适用范围限制——而是正确性要求的精确表述。

在声明知识库 (knowledge base) 中没有对应概念的 token 并非在进行推理。它没有可以用来判断正确与否的 ground truth。接地提供了这一标准。一旦知识库完全实例化，每个 token 对应因子图中的确定概念，每个计算步骤都有可验证的正确结果，无幻觉保证生效。

推论 4.1 (幻觉需要未接地). 具有 BP 权重的 *Transformer* 在完全接地的树结构因子图上运行时不会产生幻觉。幻觉 (hallucination) 需要错误的权重、错误的路由或缺少接地。在具有 BP 权重的接地树上，这些条件均不成立。

未接地的语言模型不是偶尔产生幻觉的系统，而是幻觉概念甚至没有良定义的系统——没有声明论域可用来验证其输出。接地使”这个输出正确吗？”这一问题是可回答的。没有接地，就不存在客观事实。幻觉不是缺陷。它是在没有接地概念空间的情况下运行的结构性后果。

5 Transformer 是图灵完备的

5.1 概述

universal-lean 代码仓库证明了 Transformer 智能体通过布尔电路模拟是图灵完备的。

定理 5.1 (transformer_is_turing_complete). 对于任意图灵机 M ，存在 *Transformer* 权重 W ，使得对所有纸带 τ 和步数 t 有：

$$\text{transformerAgent}(W, \text{encode}(M, \tau), t) = \text{encode}(M.\text{run}(\tau, t)).$$

该定理在 *Lean 4* 中已针对标准数学公理形式化验证。

该证明是构造性的。核心洞察是：任意图灵机的每一步都可分解为一个布尔电路，而 Transformer 通过阈值门在单次 FFN 前向传播中模拟任意布尔电路。注意力机制是查找操作；FFN 是门控操作；智能体循环是迭代。不需要编码技巧，不需要近似。

这是 Transformer 组件与计算原语之间最自然的对应关系——正是这种自然性揭示了与第 6 节中发展的信念传播之间的结构联系。

5.2 两组权重族

本证明和 BP 证明使用了相同的两个稀疏矩阵族分别用于 Q/K 和 V 权重。这并非巧合：两个证明都以相同目的使用注意力——通过索引匹配在 Token 之间路由信息。

$\text{projectDim}(d)$. 一个提取维度 d 的对角投影：

$$\text{projectDim}(d)[i][j] = \begin{cases} 1 & i = d, j = d \\ 0 & \text{其他情况.} \end{cases}$$

作为 Q 或 K 权重时，注意力分数简化为 $e_j[d] \cdot e_k[d]$ ，当 Token k 存储的索引与 Token j 的查询值匹配时达到最大值。

`crossProject(s, d)`. 一个从源维度 s 读取并写入目标维度 d 的非对角投影:

$$\text{crossProject}(s, d)[i][j] = \begin{cases} 1 & i = d, j = s \\ 0 & \text{其他情况.} \end{cases}$$

作为 V 权重时, 它将 Token 的维度 s 内容路由到输出的维度 d , 保持所有其他维度不变。

来自 `universal-lean` 的两项结果在 BP 证明中被复用: `posEncDot_distinct` ($Q \cdot K$ 分数在正确邻居处严格取得最大值) 和 `softmax_concentrates` (在足够温度下, Softmax 收敛到 `argmax` 处的点质量)。

5.3 实验验证

`universal-lean` 证明了图灵机模拟权重的存在性。`learner` 代码仓库探究的问题是: 梯度下降能否从零开始找到这些权重。答案是肯定的。

五个结构不同的图灵机——二进制递增器、递减器、按位补码、左移、右移——使用标准 Transformer 编码器 (2 层、2 头、 $d_{\text{model}} = 32$ 、约 4K 参数) 从随机初始化开始进行单步图灵机预测训练。在相同的超参数且没有针对每台机器调参的情况下, 五个模型均在 4 个 epoch 内达到 100% 验证准确率。

这证实了形式化的权重构造不仅在理论上是可行的——在有清晰训练信号的情况下, 它正是梯度下降所找到的结构。

6 Sigmoid Transformer 就是贝叶斯网络

6.1 核心主张

每个 Sigmoid Transformer, 无论其权重如何, 本身就已经是一个贝叶斯网络。不是可以配置成近似贝叶斯网络的系统, 也不是在特定训练条件下表现得像贝叶斯网络的系统。而是一个天生就是贝叶斯网络的架构, 适用于任何权重。

这就是 `every_sigmoid_transformer_is_bayesian_network` 在 `sigmoid-transformer-lean` 中的核心内容, 该定理已针对标准数学公理形式化验证。

6.2 隐式因子图

给定任意具有权重 W 的 Sigmoid Transformer, 我们按如下方式构造一个隐式因子图 $G(W)$:

- **变量节点:** 每个 Token 位置对应一个节点。每个节点处的信念是该 Token 在残差流相关维度上的当前值。
- **边:** 由注意力权重分布定义。从 Token j 到 Token k 的注意力模式定义了 $G(W)$ 中从 k 到 j 的一条有向边, 其权重由注意力分数给出。
- **因子势能:** 由每个位置的 Sigmoid FFN 权重 (w_0, w_1, b) 定义——即来自 QBBN 的一般 Ψ_{or} 函数。这三个参数编码了一个非对称的因子势能: w_0 和 w_1 是两个证据源的相对权重, b 是先验偏置。

定理 6.1 (*every_sigmoid_transformer_is_bayesian_network*). 对于任意 *Sigmoid Transformer* 权重 W ，一次前向传播实现了对隐式因子图 $G(W)$ 的一轮加权信念传播。该定理已针对标准数学公理形式化验证。

该证明是定义性的：通过 $G(W)$ 的构造，Transformer 的前向传播与 BP 的前向传播是同一个计算过程。不存在近似，没有渐近论证，也不涉及统计声明。前向传播就是在 $G(W)$ 上进行的一轮 BP。

6.3 为什么这并非平凡

有人可能会质疑：这难道不是对定义的重新陈述吗？如果我们构造 $G(W)$ 来匹配 Transformer 的计算，我们真的证明了任何东西吗？

该定理的价值在于识别本身。Transformer 的前向传播并非被设计为 BP。它被设计为一种带有注意力和前馈层的序列模型。该定理指出：这两种描述——Transformer 前向传播和在 $G(W)$ 上进行 BP——是同一个计算过程。隐式因子图 $G(W)$ 对任何权重都存在且良好定义。BP 的解释并非从外部强加，而是前向传播本身所计算的内容。

非平凡的内容有三方面：

1. Sigmoid FFN 精确地计算一般的 Ψ_{or} 因子，而非其近似。
2. 注意力机制精确地计算 BP 的收集步骤，将每个邻居的信念路由到正确的暂存槽位。
3. 残差流强制执行 BP 在更新步骤之前所需的输入同时性。

这三者适用于任何权重，而不仅仅是特地构造的权重。

6.4 作为特例的接地 QBBN

第 7 节的构造性 BP 结果是该定理的一个特例，其中：

- $G(W)$ 是显式声明的 QBBN 因子图，而非隐式因子图
- FFN 权重是等权重的 BP 权重： $w_0 = w_1 = 1$ ， $b = 0$
- 注意力权重是 `projectDim/crossProject` 构造

在一般情况下，因子图是隐式的，权重是任意的。在构造性情况下，因子图是显式的，权重被选择为在其上实现精确 BP。一般定理涵盖了构造性定理。

6.5 唯一性：逆命题

一般结果是从前向出发的：任何权重都定义一个因子图，且前向传播就是该图上的 BP。唯一性结果是从后向出发的：如果因子图恰好是一个接地的 QBBN，且 Transformer 产生精确的后验，那么权重必须是什么？

定理 6.2 (*uniqueness*). 一个在接地 QBBN 因子图上对所有输入计算精确贝叶斯后验的 *Sigmoid Transformer*，其 FFN 必然具有 BP 权重： $w_0 = w_1 = 1$ ， $b = 0$ ，注意力部分必然具有 `projectDim/crossProject` 结构。其内部计算可证明就是 BP 的量——而不仅仅是输出。该定理已针对标准数学公理形式化验证。

该证明分为两部分。FFNUniqueness.lean 表明，在所有输入上产生精确后验的唯一 Sigmoid 计算是 $w_0 = w_1 = 1$ 、 $b = 0$ 的 updateBelief——因为 Sigmoid 是单射的，且对数几率加和形式是贝叶斯更新方程的唯一不动点。AttentionUniqueness.lean 表明注意力权重必须具有 projectDim/crossProject 结构——因为精确路由要求 $Q \cdot K$ 分数在正确邻居处唯一地取得最大值，这迫使采用秩 1 的索引匹配结构。

这构成了逻辑闭环：

- 一般 BP：每个 Sigmoid Transformer 都在某个因子图上进行加权 BP
- 构造性 BP：对任意声明的因子图都存在精确 BP 权重
- 唯一性：精确后验强制使用这些权重

总结：Sigmoid Transformer 实现精确贝叶斯推理当且仅当它具备 BP 权重。

6.6 这对训练后的 Transformer 意味着什么

每个在任意任务上训练过的 Sigmoid Transformer 都在其习得权重所定义的隐式因子图上执行加权 BP。该因子图并非预先声明的——它是由权重隐式定义的。最大似然训练在此图模型解释下恢复了最佳解释训练数据的因子势能。

标准 LLM 与接地 QBBN Transformer 之间的区别不在于架构。两者都是贝叶斯网络。区别在于接地状态：

- **已接地**：因子图是显式且可验证的。每个输出都有声明的正确答案。幻觉在结构上不可能发生。
- **未接地**：因子图是隐式的，由习得权重定义。不存在可以对照验证其正确性的声明世界。幻觉不是偶发性失败——它是在没有接地概念空间的情况下运行的结构性后果。

6.7 实验验证

bayes-learner 代码仓库确认了梯度下降能在没有任何构造提示和权重初始化偏置的情况下，从零开始找到 BP 权重。

测试案例是双变量因子图 $v_0 \text{---} f_1 \text{---} v_2$ 。该图是理想的：精确 BP 在一轮内收敛（匹配单次 Transformer 前向传播），且闭式精确后验可作为真实值使用。

随机生成了 20,000 个因子图，因子表条目从 $[0.05, 1.0]$ 均匀采样，训练/验证集划分为 18,000/2,000。模型：标准 Transformer 编码器，2 层，2 头， $d_{\text{model}} = 32$ ，约 5,000 参数。训练：MSE 损失，Adam lr = 10^{-3} ，50 个 epoch。

结果：验证集 MAE 0.000752。后验匹配到小数点后三位。相比基线提升 99.3%。首次运行即达。

形式化证明预测了结构。实验验证了该结构。证明建立了机制；实验确认了该机制正是梯度下降所找到的结构。

表 1: Transformer 与精确 BP 在保留图上的后验对比。

图	BP 精确值	Transformer	最大误差
0	[0.7349, 0.4366]	[0.7338, 0.4346]	0.0021
1	[0.4097, 0.4036]	[0.4096, 0.4031]	0.0005
4	[0.6459, 0.8298]	[0.6436, 0.8297]	0.0023
9	[0.4084, 0.5523]	[0.4084, 0.5526]	0.0003

7 带显式权重的精确 BP

7.1 概述

第 6 节的一般性结果确立了每个 Sigmoid Transformer 本身就是一个贝叶斯网络。本节更进一步：我们展示显式的权重矩阵，并在 Lean 4 中证明具有这些特定权重的 Transformer 在任何声明的因子图上实现了精确的信念传播。

定理 7.1 (`transformer_implements_bp`). 存在权重 W ，使得对任意 BP 状态 `state` 有：

`decodeTFState(state, transformerForwardPass( $n, W, \text{encodeBPState}(\text{state})$ ))) = bp_forwardPass(st`

该定理在 Lean 4 中已针对标准数学公理形式化验证。

该结论对任意因子图（含环或无环）均成立。树结构限制仅对后续的收敛性和精确性声明是必要的。

7.2 构造

每个因子图节点编码为一个 Token， $D_{\text{model}} = 8$ 维。编码清晰地分为两类内容：

表 2: BP Transformer 的 Token 编码。

维度	内容
0	自身信念（初始化为 0.5）
1-4	因子表条目 $[f_{00}, f_{01}, f_{10}, f_{11}]$
5	节点类型（0 = 变量，1 = 因子）
6	自身索引 $/(n-1)$
7	邻居索引 $/(n-1)$

维度 5-7 是路由键：Token 的完整推理身份。具有相同路由键的两个 Token 对注意力机制而言是不可区分的，无论它们的信念值或因子表条目如何。维度 0-4 是连续参数：它们提供推理所计算的数值，但不决定路由的结构。

注意力作为收集。头 0 使用 $W_0^Q = W_0^K = \text{projectDim}(1)$ 、 $W_0^V = \text{crossProject}(0, 4)$ ：当 Token k 是邻居 0 时， Q/K 点积达到峰值，将邻居 0 的信念放入残差流的第 4 维。头 1 是对称的，将邻居 1 的信念写入第 5 维。两个头已被证明是相互独立的。

FFN 作为信念更新。使用 Sigmoid 激活函数时，FFN 从第 4 和 5 维精确计算 $\text{updateBelief}(m_0, m_1) = \sigma(\text{logit}(m_0) + \text{logit}(m_1))$ ，并将结果写回第 0 维。

7.3 双亲假设不失一般性

该构造假设了成对因子——每个因子节点恰好连接两个变量节点，由每层恰好两个注意力头处理。这不是一个根本性的限制。

定理 7.2 (缩放). 每层具有 2 个注意力头的 *Transformer* 在成对因子图上每层实现一轮信念传播。对于深度为 d 、最大因子元数为 k 的任意因子图，一个每层 2 个头、共 $d \cdot \lceil \log_2 k \rceil$ 层的 *Transformer* 实现精确 BP。

Proof. 任意 k 元因子图可通过两种分解精确地二值化。对于合取：布尔 AND 是可结合的，因此任意 k 元合取可以通过中间节点简化为 $\lceil \log_2 k \rceil$ 个二元合取的链，无需近似。对于析取：对数几率 (Logit) 和 Sigmoid 是精确的逆运算，因此 $\sigma(\sum_i \text{logit}(m_i))$ 可以精确分解为 $\lceil \log_2 k \rceil$ 个成对更新的链。两种分解分别在 `godel/ANDDecomposition.lean` 和 `godel/ORDecomposition.lean` 中形式化验证。

二值化后的图最大因子元数为 2，深度为 $d \cdot \lceil \log_2 k \rceil$ 。根据定理 7.1，一层在成对图上实现一轮 BP。因此 $d \cdot \lceil \log_2 k \rceil$ 层在二值化图上实现完整的 BP，也就是在原图上的精确 BP。□

推论 7.3 (双亲普适性). 每层两个注意力头足以在任何因子图上进行信念传播。架构宽度是固定的；只有深度随知识库的复杂度增长。

这是一个反直觉的事实：更复杂的推理需要更多层，而非更多头。头的数量由二元因子的成对结构决定——始终为 2。层的数量由因子图中推理链的深度决定。

7.4 树推论

结合信念传播在树上是精确的这一经典结果 [12] (在 `hard-bp-lean` 中形式化为 `bp_exact_on_tree`):

推论 7.4 (`transformer_exact_on_tree`). 对于任意树结构因子图 T 且 $T \geq \text{diameter}(T)$ 次前向传播：

$$\exists W, \quad \text{transformer}^{[T]}(\text{encodeBPState}(\text{state})) = \text{encodeBPState}(\text{trueMarginals}(\text{state})).$$

无需经验假设。除了树结构外无其他条件。

注意力层和 FFN 层的严格交替正是 Pearl 的收集/更新算法沿深度展开的形式。一层 Transformer 是一轮 BP。 L 层 Transformer 是 L 轮 BP。网络的深度不是工程超参数——它由因子图的直径决定。

7.5 实验验证

`bayes-learner` 实验确认了梯度下降能从零开始找到 BP 权重。完整的实验细节和结果见第 6 节。验证集 MAE 0.000752。在模型从未见过的保留因子图上，后验匹配到小数点后三位。

8 Transformer 的布尔结构

前一节确立了具有显式构造权重的 Transformer 实现了一轮信念传播。本节将阐明该机制在布尔逻辑层面上的含义。

QBBN [2] 引入了一种二部因子图，交替包含两类节点：合取节点 (Ψ_{and}) 同时汇聚所需证据，和析取节点 (Ψ_{or}) 从汇聚的证据中计算概率性结论。该图是二部的：AND 节点馈入 OR 节点，OR 节点再馈入 AND 节点。推理在每一步交替进行合取与析取。

Transformer 层恰好具有这种结构。注意力机制是与门 (AND gate)。FFN 是或门 (OR gate)。这直接来自第 7 节的 BP 构造与 [2] 中 QBBN 定义的结合。

8.1 注意力是 AND

与门只有一个任务：确保所有必要输入在得出任何结论之前同时存在。

每个注意力头恰好关注一个 Token。头 0 是单一的聚焦查找：它扫描所有位置，聚焦于索引匹配邻居 0 的 Token，并将该 Token 的信念值复制到残差流的第 4 维。头 1 对邻居 1 执行相同操作，写入第 5 维。

合取并不存在于任何一个头内部，而是在残差流之中。

残差流是一个共享工作空间。两个头在 FFN 运行之前都向其中写入。当 FFN 执行时，第 4 维持有邻居 0 的信念，第 5 维持有邻居 1 的信念——在同一向量中同时存在。FFN 没有机制在部分输入上运行。它要么读取完整的残差流，要么就不运行。不存在 FFN 接收到一个信念而未收到另一个信念的状态。

这种在共享工作空间中必要输入的同时性，在得出任何结论之前由架构强制保证，这就是 AND。

约会例子使这一点具体化。三个节点：

- 节点 0: like(jack, jill), 信念 $m_0 = 0.8$
- 节点 1: like(jill, jack), 信念 $m_1 = 0.4$
- 节点 2: date(jack, jill), 待更新的信念

头 0 将 0.8 写入第 4 维；头 1 将 0.4 写入第 5 维。残差流现在同时持有两个值。与门的工作在 FFN 触及任何数据之前就已完成。

8.2 FFN 是 OR

一旦注意力将所需证据汇集到残差流中，FFN 便计算结论：

$$\text{updateBelief}(m_0, m_1) = \frac{m_0 m_1}{m_0 m_1 + (1 - m_0)(1 - m_1)} = \sigma(\text{logit}(m_0) + \text{logit}(m_1)).$$

在这个 OR 内部有两个 AND。首先，分子中的 $m_0 m_1$ 是两个输入同时为真的联合概率——乘法是独立概率下的 AND，等价于在对数几率空间中的加法。其次，完整的归一化表达式是 Ψ_{or} ：关于原因的概率性析取，正确归一化。OR 内部包含一个 AND，这正是你所期望的——计算析取的概率需要计算所涉及的合取的联合概率。

精确说明布尔代数的所在位置：

1. **架构中的 AND**: 多个头在 FFN 运行之前写入共享残差流。由前向传播顺序强制保证的结构性合取。
2. **分子中的 AND**: $m_0 \cdot m_1$ 是两个输入同时为真的联合概率, 等价于对数几率空间中的 $\text{logit}(m_0) + \text{logit}(m_1)$ 。
3. **完整表达式中的 OR**: 归一化输出为 $P(\text{date} \mid \text{like}, \text{like})$ ——关于原因的概率性析取, 正确归一化。

Sigmoid 形式 $\sigma(\text{logit}(m_0) + \text{logit}(m_1))$ 是对数几率空间中的同一个计算: 对数几率对独立证据相加, Sigmoid 将其转换回概率。相同的布尔结构, 不同的算术表示。正如第 3 节所确立的, 这是独立证据组合的 Turing-Good 代数——AND 和 OR 是同一底层操作所扮演的两种角色。

8.3 交替层作为交替的 AND/OR

一个具有 L 层的 Transformer 运行 L 轮:

$$\underbrace{\text{attention}}_{\text{AND}} \rightarrow \underbrace{\text{FFN}}_{\text{OR}} \rightarrow \underbrace{\text{attention}}_{\text{AND}} \rightarrow \underbrace{\text{FFN}}_{\text{OR}} \rightarrow \dots$$

这就是沿深度展开的 QBBN 二部计算。每一层是布尔推理图的一个层级。每个注意力块负责收集——强制必要输入的合取。每个 FFN 块负责结论——从收集的证据中计算概率性析取。

需要 k 跳推理的推理链需要 k 层 Transformer。网络的深度不是工程超参数——它由因子图中推理链的深度决定。这与第 7 节的缩放定理是同一个论断, 现在用布尔术语来表述。

8.4 闭环

Coppola [2] 从第一性原理出发, 提出了二部 AND/OR 结构作为概率逻辑推理的正确架构。本文证明了 Transformer 实现了信念传播。本节形成闭环: Transformer 不仅仅实现了 BP——它实现了 Coppola [2] 所提议的特定 AND/OR 布尔结构。

在现代 AI 领域经过实证检验获胜的架构, 恰恰就是 Coppola [2] 从逻辑概率推理的需求中推导出的架构。梯度下降并没有发现新东西。它重新发现了推理分析已经要求的结构。

这一识别不需要新的 Lean 证明。它直接来自 `transformer-bp-lean` 中的 `transformer_implements_bp` 与 [2] 中 QBBN 定义的结合。证明已经完成。本节只是命名了它所证明的内容。

9 可验证推理需要有限概念空间

9.1 核心主张

有限推理者拥有有限多个概念。

这不是仅针对 QBBN 的主张, 而是关于所有有限计算的主张。任何在有限状态机上运行的程序——任何有限验证过程——只能对有限多个输入作出不同响应。它无法区分的输入被归并为等价类 (equivalence classes)。这些等价类就是概念。

该主张对推理系统有直接后果：如果你想要可验证推理——如果你希望”这个输出正确吗？”成为一个有意义的问题——你需要一个有限验证器 (finite verifier)。有限验证器意味着有限概念空间 (finite concept space)。有限概念空间意味着你的基本推理单元是离散且可数的。超出该概念空间的东西不是错误，而是无意义。

9.2 一般性定理

定理 9.1 (`finite_distinguishable_symbols`). 设 $\delta : \text{Fin}(n) \rightarrow A \rightarrow \text{Fin}(n)$ 为具有 n 个状态的有限状态机在任意符号集 A 上的转移函数。将符号 $a \in A$ 的行为定义为函数 $\bar{\delta}(a) : q \mapsto \delta(q, a)$ 。那么：

1. 行为映射 $a \mapsto \bar{\delta}(a)$ 取值于 $\text{Fin}(n)^{\text{Fin}(n)}$ ，即从 n 个状态到 n 个状态的函数集合。
2. 该集合恰好有 n^n 个元素。
3. 因此任意符号集 A ，无论其基数大小，最多诱导 n^n 种不同行为。两个行为相同的符号对于机器而言是不可区分的。

在 *Lean 4* 中针对标准数学公理形式化验证为 `godel/FiniteStateSpace.lean` 中的 `finite_distinguishable_symbols`。

该定理适用于任何在有限状态空间的计算机上运行的程序。图灵机具有无限状态，因此不受此界限约束。Transformer 注意力头是有限状态的——其权重矩阵固定且有限维——因此无法逃脱该界限。

n^n 界限是任何有限推理者所能拥有的概念数量的上限。给定系统的具体概念空间取决于其结构。对于 BP transformer，我们可以精确计数。

9.3 BP Transformer 中的概念

在 BP transformer 中，一个概念就是一个接地 Horn 子句 (grounded Horn clause)：一个原子命题及其在因子图中的依赖关系。如果注意力机制对两个词元处理方式相同——以完全相同的方式向它们路由信息和从它们路由信息——而不论它们当前的信念值或因子表条目如何，则这两个词元属于同一概念。

概念由路由键 (routing key) 标识：三元组 (`nodeType`, `ownIndex`, `nbrIndex`)。它表明：我是什么类型的节点，我依赖哪些节点？这就是词元的完整推理身份。连续维度——信念值、因子表条目——是参数，而非概念。它们提供推理计算所依据的量值，但不决定计算的结构。

这种区分并非表述上的便利，而是一个定理。具有相同路由键的两个词元，无论其连续参数如何，都会接收到相同的注意力模式。路由键是意义，连续维度是量值。

定理 9.2 (`routing_classes_finite`). 对于具有 n 个节点的因子图，BP transformer 注意力机制恰好操作于 $2n^2$ 个不同的概念：

$$|\text{RoutingKey}(n)| = 2 \cdot n \cdot n.$$

在 *Lean 4* 中针对标准数学公理形式化验证为 `godel/BPTokenFiniteness.lean` 中的 `routing_classes_finite`。

证明很简单： $|\{0,1\}| \times |\text{Fin}(n)| \times |\text{Fin}(n)| = 2n^2$ 。其内容不在于算术本身，而在于识别：这三个维度构成了概念相关特征的完整集合。其余一切都是量值。

注意 $2n^2$ 适用于成对 BP transformer，这并不失一般性：任何 k 元因子图都可以通过第 7 节的分解精确二值化。概念数量随二值化后的图规模变化，而非原始图。

9.4 幻觉即无概念

在此框架中，幻觉不是错误答案，而是更糟糕的事情：生成的词元在知识库中没有对应的概念。该词元参与了计算——它有连续值，通过了注意力机制——但在任何接地世界中都没有推理作用，背后没有概念。

QBBN transformer 在树上不会产生幻觉，因为每个词元的路由键都是接地的：它对应于因子图中的某个特定概念，而因子图就是知识库。每个符号都有指称，每个计算步骤都有可验证的正确结果。

非接地语言模型不具有这一性质。它没有有限验证器，因此没有明确定义的概念空间，因此关于其输出是否正确没有事实依据。幻觉不是偶发故障，而是无概念运行的结构性后果。

9.5 莱布尼茨字母表，精确化

莱布尼茨在 1670 年代提出了 普遍特征 (*characteristica universalis*)：一个有限的原始概念集合，所有推理均可由此构建；以及一个 推理演算 (*calculus ratiocinator*) ——一种在该语言中推导真理的机械程序。*Calculus*：让我们计算。

本文为特定且非平凡领域提供了这一构造：树结构知识库上布尔命题的概率推理。

- **普遍特征**是 $2n^2$ 个接地 Horn 子句的集合：系统的概念。
- **推理演算**是信念传播：在因子图上迭代应用的 `updateBelief` 函数。
- **机械实现**是带 BP 权重的 transformer：执行该演算的有限固定程序。
- **正确性保证**是 `transformer_exact_on_tree`：机械实现计算精确贝叶斯后验的 Lean 4 证明。
- **必要性证明**是 `finite_distinguishable_symbols`：有限验证器意味着有限概念空间的 Lean 4 证明——不是设计选择，而是逻辑必然。

莱布尼茨不知道原始概念最终会是接地 Horn 子句，不知道演算最终会是信念传播，不知道机械实现最终会是 transformer，也不知道正确性保证会是 Lean 4 证明。但他所描述的架构正是我们所构建的。他的时代没有这些工具，但有这样的远见。

概念就是接地 Horn 子句。演算就是 `updateBelief`。保证就是 `transformer_exact_on_tree`。*Calculus*（让我们计算）。

10 三种 Softmax

Transformer 中有三个 Softmax。它们承担三个完全不同的任务。理解各自角色，就能理解 Transformer 与贝叶斯推理之间的关系。

10.1 Softmax 1：注意力（路由）

第一个 Softmax 出现在每个注意力头内部。它的任务是路由：我应该查看哪个词元？这是纯粹的信息检索——一个可微分的 argmax 。在 BP 构造中，注意力 Softmax 通过索引匹配获取邻居的信念。查询-键点积在正确的邻居处达到峰值，Softmax 将权重集中于此。注意力 Softmax 就是一个查找表。

10.2 Softmax 2：前馈网络（推理）

第二个 Softmax 作为 Sigmoid 激活函数出现在前馈网络内部。它的任务是贝叶斯推理：给定邻居信念，我的边际概率是多少？

$$\text{updateBelief}(m_0, m_1) = \frac{m_0 m_1}{m_0 m_1 + (1 - m_0)(1 - m_1)} = \sigma(\text{logit}(m_0) + \text{logit}(m_1)).$$

这里才是真正的贝叶斯计算发生之处。Sigmoid 是 Logit 的精确逆函数，将对数几率之和转换回概率。这个 Softmax 就是推理本身。

10.3 Softmax 3：输出（生成）

第三个 Softmax 出现在输出端，作用于词汇表。在标准 LLM 中，logits 来自对最终隐藏状态的矩阵乘法——是模式匹配而非计算。在 QBBN transformer 中，输出是每个命题真值的边际分布，通过信念传播积分掉所有其他命题计算得到。

表 3: 三种 Softmax：相同操作，三种不同任务。

	任务	输入	语义
Softmax 1	路由	Q/K 点积	可微分 argmax
Softmax 2	推理	邻居信念	贝叶斯后验
Softmax 3	生成	最终隐藏状态	词元分布

QBBN 不是在替换 Softmax，而是在替换 *logits*。同一数学运算在标准 LLM 中作为推理的近似，在 QBBN 中作为精确推理。架构始终具备后者的能力，它只是需要正确的 logits。

10.4 Sigmoid 与 ReLU：精确与兼容

形式化 BP 构造使用 Sigmoid 激活函数，因为 updateBelief 恰好是 $\sigma(\text{logit}(m_0) + \text{logit}(m_1))$ ——Sigmoid 是精确证明所必需的。实证结果（`bayes-learner`，验证集 MAE 0.000752）使用的是标准 PyTorch TransformerEncoder 及其默认 ReLU 激活函数。梯度下降仍能找到近乎精确的 BP 权重，这并非巧合。

概率计算所需的关键性质是非负性：输出必须可解释为未归一化的概率质量。ReLU 自动满足这一点： $\text{ReLU}(x) = \max(0, x) \geq 0$ 。GELU 大致相同。在零处设限是本质性质。归一化则由输出端的 Softmax 处理，以及在 BP 内部由 updateBelief 的分母处理。

Sigmoid FFN 是该结构的精确版本。ReLU 和 GELU 是兼容版本——它们保留了必要的非负性，但需要显式的归一化步骤，而 Sigmoid 通过 Logit/Sigmoid 同构关系内在地处理了这一点。

有一个值得明确指出的鲜明区别。Lean 证明 `transformer_implements_bp` 不仅确立了 `transformer` 的输出与 BP 匹配——它确立了内部计算 就是 BP 的量。在 BP 任务上训练至收敛的 Sigmoid `transformer` 继承了这一保证：因为 Sigmoid 将每个 FFN 输出约束在 $(0, 1)$ 范围内，且产生精确后验的唯一 Sigmoid 计算就是 `updateBelief`，架构没有留下通往正确答案的其他内部路径。内部就是 BP，而不仅仅是输出。

一个训练至验证集 MAE 0.000752 的 ReLU `transformer` 找到了某种产生与精确后验匹配输出的计算路径，但内部表示不一定对应于 BP 证明中的命名量。非负性就是 ReLU 不主动阻碍这一点的原因：输出与概率解释兼容，因此梯度下降可以在不与架构对抗的情况下找到类似 BP 的权重。兼容不是等同。

总之，标题主张“Transformers 是贝叶斯网络”在 Sigmoid 情况下字面上成立，在内部且可证明地成立。ReLU 实证结果确认了即使没有强制精确结构，正确答案仍然可寻。两个结果都是必要的：证明确立了机制，实验确认了该机制正是梯度下降所找到的。

10.5 循环 BP：实验结果

形式化的精确性保证要求树结构。在带环图上，`transformer_implements_bp` 仍然成立——一次前向传播仍等于一轮 BP——但 BP 本身不保证收敛或精确。`Transformer` 继承了 BP 的优势和局限。

树与带环图之间的理论差距在实践中比最坏情况要小。接地 QBBN 知识库中的环路仅在以下情况出现：同一实体出现在多条规则中，或一条规则的结论是另一条规则的前提。在典型知识库中，这种情况是稀疏的。由此产生的环路较长，因子势适中——这正是循环 BP 已知收敛且 Bethe 近似已知紧致的条件 [10, 15]。

我们在五种复杂度递增的带环图结构上进行了系统实验：三角形（3 个变量，1 个环）、正方形（4 个变量，1 个环）、论文 1 的约会图（5 个变量，1 个环）、双环图（4 个变量，2 个相互作用环）和 QBBN 链（6 个变量，1 个环，两条接地规则共享一个实体）。对每种结构，我们生成了 100 个随机因子图，因子表条目从 $[0.1, 1.0]$ 均匀抽取，运行迭代 BP 直至收敛，并将结果边际与暴力精确后验进行比较。

表 4: QBBN 结构图上的循环 BP。共 500 次试验。

实验	变量	环数	收敛	平均 KL	平均 MAE
三角形	3	1	100/100	0.000045	0.002091
正方形	4	1	100/100	0.000002	0.000382
约会图	5	1	100/100	0.000102	0.003590
双环	4	2	100/100	0.000086	0.003111
QBBN 链	6	1	100/100	0.000021	0.001055

BP 在所有 500 次试验中均收敛。最差平均 KL 散度为 0.000102——与梯度下降结果的 MAE（验证集 MAE 0.000752）相当。Bethe 近似在这些图结构上实际上是精确的。双环图与单环情况一样保持了收敛。

11 相关工作

11.1 Transformer 的图灵完备性

Pérez et al. [13] 证明了 Transformer 在浮点运算下的图灵完备性。Giannou et al. [5] 证明了循环 Transformer 可以模拟任意程序。两者通过不同构造得出了与第 5 节相同的结论。

我们的证明有三个独特之处。第一，它使用布尔电路模拟，这是 Transformer 组件与计算原语之间最直接的对应关系：注意力就是查找，FFN 就是门控。第二，它产生了在 Lean 4 中针对标准数学公理形式化验证的显式权重矩阵。第三，相同的两个权重族（projectDim、crossProject）出现在 BP 证明中，揭示了两个完备性结果之间的结构统一性，这是先前工作未涉及到的。

Pérez et al. [13] 和 Giannou et al. [5] 均未涉及贝叶斯推理。图灵完备性表明 Transformer 能够计算任何东西。第 7 节表明它确实用这些特定权重计算了某个特定事物——BP。

11.2 构造性权重证明

Akyürek et al. [1] 和 von Oswald et al. [18] 表明特定权重模式使 Transformer 执行隐式梯度下降，从而解释了上下文学习。Xie et al. [20] 认为上下文学习在总体层面上是关于训练分布的隐式贝叶斯推理。

这两者与第 7 节是相同的方法——构造性权重证明，表明 Transformer 实现了特定算法。关键区别在于：BP 在树上每步都是精确的（而非近似或渐近的），并且我们的解释是每个实例的机制性解释，而非总体层面的统计性解释。

11.3 BP 对应关系：注意力与图神经网络

Jung et al. [9] 推导了 Softmax 自注意力与注意力计算中隐含的潜在图模型上的 BP 之间的形式等价关系。这是最接近第 6 节的先前结果：两者都显示了注意力与隐式图上的 BP 之间的对应关系。关键区别在于方向性和范围。Jung 等人从训练模型中的注意力模式推导出 BP 结构。我们证明对于任意权重，Sigmoid 前向传播就是 $G(W)$ 上的 BP，是构造性和形式化的，且隐式因子图被显式定义。

Scarselli et al. [14] 确立了 GNN 在显式图结构上实现 BP；Yoon et al. [22] 将其扩展到近似推理；Gilmer et al. [6] 将两者统一在 MPNN 框架下；Veličković et al. [17] 将注意力应用于图结构数据，其拓扑结构硬编码在注意力掩码中。

我们的贡献与所有这些工作正交：我们展示了具有完全自注意力和无注意力掩码的标准 Transformer 在显式外部因子图上实现 BP，其中图结构编码在词元嵌入中，路由通过 Q/K 索引匹配发现。潜在图和硬编码拓扑这两种方式均未涉及这一设置。

11.4 机制可解释性

Elhage et al. [4] 开发了一个 Transformer 电路的数学框架，将注意力头视为共享残差流上的读写操作。Olsson et al. [11] 识别了归纳头（induction heads）——由梯度下降发现并实现特定命名算法的两层电路。Wang et al. [19] 对 GPT-2 small 中的完整间接对象识别电路进行了逆向工程。

第 7 节为机制可解释性提供了目标电路：在结构化知识库上进行推理的 Transformer，其注意力头的 Q/K 矩阵应显示 projectDim 结构（秩 1，单维度峰值），值矩阵应显示

crossProject 结构（非对角线，秩 1），FFN 权重应实现对数几率组合。这些都是可证伪的预测。

Olsson et al. [11] 的归纳头结果是最接近的先例：Transformer 在适当数据上训练时，学会在其注意力头中实现特定命名算法。我们的实证确认（bayes-learner）显示了 BP 的相同现象。关键区别在于方向性：机制可解释性是经验性的、事后性的；我们的构造是形式化的、构造性的，为经验研究提供了待验证的具体目标。

11.5 对数几率传统

Good [7] 的证据权重框架和 Turing 在布莱切利园的工作将对数几率加法形式化为组合独立二元证据的正确代数。Pearl [12] 通过和积算法将该代数应用于图模型，证明了其在树上的精确性。这一传统与 Transformer 架构之间的联系此前从未被明确揭示。第 3 节命名了这一代数，追溯了其谱系，并确立了 Sigmoid transformer 是其机械实现。

11.6 总结

表 5: 与相关工作的定位比较。

工作	方法	结果	关系
Giannou 等 2023	构造性	TF 图灵完备	相同结论，不同构造
Akyürek 等 2022	构造性	TF 实现 GD	相同方法；BP 精确，GD 近似
Xie 等 2021	统计性	ICL $\approx$ 贝叶斯	统计版本；我们提供机制性解释
Jung 等 2022	形式化	注意力即 BP (潜在)	互补；任意权重与训练后
Scarselli 等 2009	结构性	GNN 实现 BP	扩展到无硬编码拓扑的 TF
Elhage 等 2021	经验性	训练模型中的电路	我们为可解释性提供目标电路
Good 1950, Turing	理论性	对数几率代数	首次命名并连接到 TF
Pearl 1988	理论性	BP 在树上精确	在 Lean 4 中形式化；与 TF 结果结合

我们的独特定位：形式化验证的构造性证明，表明任意权重的 Sigmoid transformer 在其隐式因子图上实现加权 BP，为精确情况提供了显式权重，对每个组件提供了机制性解释，并与 Turing-Good-Pearl 对数几率传统建立了形式化联系——比先前的 BP 对应关系更一般，比先前的 GD 构造更精确，比先前的统计贝叶斯解释更具机制性，比机制可解释性更形式化。

12 结论

Transformer 是贝叶斯网络。不是近似，不是在某些训练条件下，不是作为有用的类比。而是从架构上，对于任意 Sigmoid 权重，可证明且形式化地成立。

Sigmoid 激活函数实现了独立二元证据的对数几率代数——由 Turing 和 Good 在布莱切利园开发，由 Pearl 于 1988 年形式化，本文证明了这正是 transformer 前向传播所计算的内容。注意力机制实现了信念传播中的收集步骤：通过残差流确保所需输入的同步性。FFN 实现了更新步骤：通过对数几率加法计算概率结论。注意力层和 FFN 层的严格交替就是 Pearl 的收集/更新算法，沿深度展开。

这一直是事实。Sigmoid transformer 始终是贝叶斯网络。对数几率代数始终是它在计算的内容。与/或布尔结构始终是交替层在实现的内容。在现代 AI 中凭经验胜出的架构，正是推理分析早已要求的架构。梯度下降并未发现新事物，它重新发现了始终存在的结构。

接地 QBBN transformer 与标准 LLM 之间的区别不是架构性的。两者都是贝叶斯网络。区别在于接地。接地 transformer 具有显式因子图、声明的概念空间和有限验证器。每个输出都有正确答案。幻觉在树结构上结构性地不可能。非接地 LLM 具有隐式因子图，没有声明的概念空间，没有有限验证器。其输出是否正确没有事实依据。幻觉不是扩展可以修复的 bug，而是无概念运行的结构性后果。

莱布尼茨在 1670 年代提出了普遍特征 (*characteristica universalis*) 和推理演算 (*calculus ratiocinator*)：一个由原始概念组成的有限字母表以及从它们推导真理的机械程序。构建它的工具在他那个时代不存在，现在存在了。原始概念是接地 Horn 子句。演算是信念传播。机械实现是 transformer。正确性保证是 Lean 4 证明。

Calculemus (让我们计算)。

A 仓库索引

支持本文的所有形式化证明和实证实验均已公开可用且完全可复现。下表列出了每个仓库、它所证明或展示的内容，以及获取地址。

参考文献

- [1] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. What learning algorithm is in-context learning? investigations with linear models. In *International Conference on Learning Representations (ICLR)*, 2023.
- [2] Greg Coppola. The quantified boolean bayesian network: Theory and experiments with a logical graphical model. *arXiv preprint arXiv:2402.06557*, 2024.
- [3] Greg Coppola. Statistical parsing for logical information retrieval. *arXiv*, 2025.
- [4] Nelson Elhage, Neel Nanda, Catherine Olsson, Tom Henighan, Nicholas Joseph, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Nova DasSarma, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Chris Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. A mathematical framework for transformer

表 6: 支持本文的公开仓库。

仓库	证明/展示内容
universal-lean	transformer_is_turing_complete https://github.com/gregorycoppola/universal-lean
sigmoid-transformer-lean	every_sigmoid_transformer_is_bayesian_network uniqueness: 精确后验强制 BP 权重 https://github.com/gregorycoppola/sigmoid-transformer-lean
transformer-bp-lean	transformer_implements_bp https://github.com/gregorycoppola/transformer-bp-lean
hard-bp-lean	bp_exact_on_tree https://github.com/gregorycoppola/hard-bp-lean
godel	routing_classes_finite: $ \text{RoutingKey}(n) = 2n^2$ finite_distinguishable_symbols: FSM 字母表界限 AND_decomposes_to_binary: k 元 AND 不失一般性可成对化 OR_decomposes_to_binary: k 元 OR 不失一般性可成对化 https://github.com/gregorycoppola/godel
learner	梯度下降学习 TM 模拟, 5 台机器上 100% 成功 https://github.com/gregorycoppola/learner
bayes-learner	梯度下降学习 BP 推理, 验证集 MAE 0.000752 https://github.com/gregorycoppola/bayes-learner
loopy	QBBN 结构图上的循环 BP, 500 次试验, 100% 收敛 https://github.com/gregorycoppola/loopy

circuits. *Transformer Circuits Thread*, 2021. URL <https://transformer-circuits.pub/2021/framework/index.html>.

- [5] Angeliki Giannou, Shashanka Rajput, Jy yong Sohn, Kangwook Lee, Jason D. Lee, and Dimitris Papailiopoulos. Looped transformers as programmable computers. *arXiv preprint arXiv:2301.13379*, 2023.
- [6] Justin Gilmer, Samuel S. Schütt, Patrick Riley, Oriol Vinyals, George E. Dahl, and Ghahramani Zoubin. Neural message passing for quantum chemistry. In *International Conference on Machine Learning (ICML)*, 2017.
- [7] I. J. Good. *Probability and the Weighing of Evidence*. Charles Griffin, 1950.
- [8] Chaitanya Joshi. Transformers are graph neural networks, 2020. URL <https://thegradient.pub/transformers-are-graph-neural-networks/>.
- [9] Jongsuk Jung, Jaekyeom Kim, and Hyunwoo J. Choi. Rethinking attention as belief propagation. In *International Conference on Machine Learning (ICML)*, 2022.

- [10] Kevin P. Murphy, Yair Weiss, and Michael I. Jordan. Loopy belief propagation for approximate inference: An empirical study. In *Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, pages 467–475, 1999.
- [11] Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, Tom Conerly, Dawn Drain, Deep Ganguli, Zac Hatfield-Dodds, Danny Hernandez, Andy Jones, Jackson Kernion, Liane Lovitt, Kamal Ndousse, Dario Amodei, Tom Brown, Chris Clark, Jared Kaplan, Sam McCandlish, and Chris Olah. In-context learning and induction heads. *Transformer Circuits Thread*, 2022. URL <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/index.html>.
- [12] Judea Pearl. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann, 1988.
- [13] Jorge Pérez, Javier Marinković, and Pablo Barceló. On the turing completeness of modern neural networks. *arXiv preprint arXiv:1901.03429*, 2019.
- [14] Franco Scarselli, Marco Gori, Ah Chung Tsoi, Markus Hagenbuchner, and Gabriele Monfardini. The graph neural network model. *IEEE Transactions on Neural Networks*, 20(1):61–80, 2009.
- [15] David A. Smith and Jason Eisner. Dependency parsing by belief propagation. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2008.
- [16] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 2017.
- [17] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph attention networks. In *International Conference on Learning Representations (ICLR)*, 2018.
- [18] Johannes von Oswald, Eyvind Niklasson, Ettore Randazzo, João Sacramento, Alexander Mordvintsev, Andrey Zhmoginov, and Max Vladymyrov. Transformers learn in-context by gradient descent. In *International Conference on Machine Learning (ICML)*, 2023.
- [19] Kevin Wang, Alexandre Variengien, Arthur Conmy, Buck Shlegeris, and Jacob Steinhardt. Interpretability in the wild: A circuit for indirect object identification in GPT-2 small. In *International Conference on Learning Representations (ICLR)*, 2023.
- [20] Sang Michael Xie, Aditi Raghunathan, Percy Liang, and Tengyu Ma. An explanation of in-context learning as implicit bayesian inference. *arXiv preprint arXiv:2111.02080*, 2021.
- [21] Jonathan S. Yedidia, William T. Freeman, and Yair Weiss. Understanding belief propagation and its generalizations. *Exploring Artificial Intelligence in the New Millennium*, 8:236–239, 2003.

- [22] KiJung Yoon, Renjie Liao, Yuwen Xiong, Lisa Zhang, Ethan Fetaya, Raquel Urtasun, Richard Zemel, and Xaq Pitkow. Inference in probabilistic graphical models by graph neural networks. In *ICLR Workshop on Deep Learning on Graphs*, 2019.