

BEVFormer: 通过时空 Transformer 从多相机图像学习鸟瞰视图表示 (Learning Bird's-Eye-View Representation from Multi-Camera Images via Spatiotemporal Transformers)

Zhiqi Li^{1,2*}, Wenhai Wang^{2*}, Hongyang Li^{2*}, Enze Xie³, Chonghao Sima², Tong Lu¹, Yu Qiao², Jifeng Dai²✉

¹Nanjing University ²Shanghai AI Laboratory ³The University of Hong Kong




图 1: 本文提出 **BEVFormer**——一种用于自动驾驶的范式, 该范式同时利用 Transformer 和时序结构从多相机输入生成鸟瞰视图 (BEV) 特征。BEVFormer 利用查询 (Query) 在空间/时序空间中查找并相应地聚合时空信息, 从而为感知任务提供 stronger 的特征表示。

摘要

3D 视觉感知任务 (包括基于多相机图像的 3D 目标检测和地图分割) 对于自动驾驶系统至关重要。本文提出一种名为 BEVFormer 的新框架, 该框架通过时空 Transformer 学习统一的 BEV 表示, 以支持多种自动驾驶感知任务。简而言之, BEVFormer 通过预定义的网格状 BEV 查询与空间和时序空间交互, 从而利用空间和时序信息。为聚合空间信息, 本文设计了空间交叉注意力 (Spatial Cross-Attention), 使每个 BEV 查询从跨相机视图的感兴趣区域中提取空间特征。对于时序信息, 本文提出了时序自注意力 (Temporal Self-Attention), 以循环方式融合历史 BEV 信息。本文方法在 nuScenes test 集上的 NDS 指标达到 56.9% 的当前最优 (SOTA) 性能, 比此前最佳方法高出 9.0 个百分点, 与基于 LiDAR 的基线方法性能相当。本文进一步表明, BEVFormer 显著提升了速度估计精度和低能见度条件下的目标召回率。代码开源在<https://github.com/zhiqi-li/BEVFormer>。

*: 同等贡献 (Equal contribution)。本工作完成于 Zhiqi Li 在上海人工智能实验室实习期间。
✉: 通讯作者 (Corresponding author)。

1 引言

3D 空间感知对于自动驾驶、机器人等各种应用至关重要。尽管基于 LiDAR 的方法 [43, 20, 54, 50, 8] 取得了显著进展，基于相机的方法 [45, 32, 47, 30] 近年来受到广泛关注。与基于 LiDAR 的方法相比，相机除了部署成本低之外，还具有检测远距离物体和识别基于视觉的道路元素（如交通灯、停止线）的显著优势。

自动驾驶中周围场景的视觉感知需要从多相机提供的 2D 线索中预测 3D 边界框或语义地图。最直接的解决方案基于单目框架 [45, 44, 31, 35, 3] 和跨相机后处理。该框架的缺点在于分别处理不同视角的图像，无法捕捉跨相机的信息，导致性能和效率低下 [32, 47]。

作为单目框架的替代方案，一种更统一的框架是从多相机图像中提取整体表示。鸟瞰视图 (BEV) 是周围场景的常用表示形式，因为它能清晰呈现物体的位置和尺度，适用于多种自动驾驶任务（如感知和规划）[29]。尽管先前的地图分割方法已经证明了 BEV 的有效性 [32, 18, 29]，但基于 BEV 的方法在 3D 目标检测中并未展现出相对于其他范式的显著优势 [47, 31, 34]。根本原因在于 3D 目标检测任务需要强大的 BEV 特征来支持精确的 3D 边界框预测，但从 2D 平面生成 BEV 是一个不适定问题。一种流行的基于 BEV 的框架利用深度信息生成 BEV 特征 [46, 32, 34]，但该范式对深度值的精度或深度分布敏感。基于 BEV 的方法的检测性能因此受到复合误差的影响 [47]，不精确的 BEV 特征会严重损害最终性能。因此，本文致力于设计一种不依赖深度信息、能够自适应学习 BEV 特征而非严格依赖 3D 先验的 BEV 生成方法。Transformer 利用注意力机制动态聚合有价值的特征，在概念上满足本文的需求。

使用 BEV 特征执行感知任务的另一个动机在于，BEV 是连接时序空间和空间域的理想桥梁。对于人类视觉感知系统，时序信息在推断物体运动状态和识别遮挡物体方面起着至关重要的作用，许多视觉领域的工作已经证明了利用视频数据的有效性 [2, 27, 26, 33, 19]。然而，现有的当前最优多相机 3D 检测方法很少利用时序信息。主要挑战在于自动驾驶对时间高度敏感且场景中物体变化迅速，因此简单地堆叠跨时间戳的 BEV 特征会带来额外的计算成本和干扰信息，并非理想方案。受循环神经网络 (Recurrent Neural Networks, RNN) [17, 10] 启发，本文利用 BEV 特征以循环方式将时序信息从过去传递到现在，这与 RNN 模型中隐藏状态的精神一致。

为此，本文提出一种基于 Transformer 的鸟瞰视图编码器，称为 **BEVFormer**，它能够有效聚合来自多视角相机和历史 BEV 特征的时空特征。BEVFormer 生成的 BEV 特征可同时支持多种 3D 感知任务（如 3D 目标检测和地图分割），这对自动驾驶系统非常有价值。如图1所示，BEVFormer 包含三个关键设计：(1) 网格状 BEV 查询，通过注意力机制灵活融合空间和时序特征；(2) 空间交叉注意力模块，用于聚合多相机图像的空间特征；(3) 时序自注意力模块，用于从历史 BEV 特征中提取时序信息，有助于运动物体的速度估计和严重遮挡物体的检测，且仅带来可忽略的计算开销。借助 BEVFormer 生成的统一特征，模型可与不同的任务特定头（如 Deformable DETR [56] 和掩码解码器 [22]）协同工作，实现端到端的 3D 目标检测和地图分割。

本文主要贡献如下：

- 提出 BEVFormer——一种时空 Transformer 编码器，将多相机和/或多时间戳输入投影到 BEV 表示中。借助统一的 BEV 特征，模型可同时支持多种自动驾驶感知任务，包括 3D 目标检测和地图分割。
- 设计了可学习的 BEV 查询，与空间交叉注意力层和时序自注意力层配合，分别从跨相机视图和历史 BEV 中查找空间特征和时序特征，然后聚合到统一的 BEV 特征中。
- 在多个具有挑战性的基准测试（包括 nuScenes [4] 和 Waymo [40]）上评估了 BEVFormer 性能。BEVFormer 相比于先前方法持续取得改进。例如，在可比的参数数量和计算开销下，BEVFormer 在 nuScenes test 集上达到 56.9% 的 NDS，比此前最佳检测方法 DETR3D [47] 高出 9.0 个百分点 (56.9% vs. 47.9%)。在地图分割任务中，本文方法同样达到当前最优性能，在最具有挑战性的车道分割任务上比 Lift-Splat [32] 高出 5.0 个百分点以上。希望这种简洁而强大的框架能为后续 3D 感知任务提供新的基线。

2 相关工作

2.1 基于 Transformer 的 2D 感知

近来, 使用 Transformer 重构检测和分割任务已成为一种新趋势 [7, 56, 22]。

DETR [7] 通过交叉注意力解码器直接使用一组目标查询 (Object Queries) 生成检测结果。然而, DETR 的主要缺点是训练时间较长。Deformable DETR [56] 通过提出可变形注意力 (Deformable Attention) 解决了这一问题。与 DETR 中的标准全局注意力不同, 可变形注意力与局部感兴趣区域交互, 仅在每个参考点附近采样 K 个点并计算注意力结果, 从而实现了高效率并显著缩短了训练时间。可变形注意力机制的计算公式如下:

$$\text{DeformAttn}(q, p, x) = \sum_{i=1}^{N_{\text{head}}} \mathcal{W}_i \sum_{j=1}^{N_{\text{key}}} \mathcal{A}_{ij} \cdot \mathcal{W}'_i x(p + \Delta p_{ij}), \quad (1)$$

其中 q, p, x 分别表示查询、参考点和输入特征。 i 索引注意力头, N_{head} 表示注意力头的总数。 j 索引采样键, N_{key} 是每个头的总采样键数量。 $\mathcal{W}_i \in \mathbb{R}^{C \times (C/H_{\text{head}})}$ 和 $\mathcal{W}'_i \in \mathbb{R}^{(C/H_{\text{head}}) \times C}$ 是可学习权重, C 为特征维度。 $\mathcal{A}_{ij} \in [0, 1]$ 是预测的注意力权重, 通过 $\sum_{j=1}^{N_{\text{key}}} \mathcal{A}_{ij} = 1$ 归一化。 $\Delta p_{ij} \in \mathbb{R}^2$ 是相对于参考点 p 的预测偏移量。 $x(p + \Delta p_{ij})$ 表示位置 $p + \Delta p_{ij}$ 处的特征, 通过双线性插值提取 (如 Dai *et al.* [12] 所述)。本文将可变形注意力扩展到 3D 感知任务, 以高效聚合空间和时序信息。

2.2 基于相机的 3D 感知

先前的 3D 感知方法通常独立执行 3D 目标检测或地图分割任务。在 3D 目标检测任务中, 早期方法与 2D 检测方法相似 [1, 28, 49, 39, 53], 通常基于 2D 边界框预测 3D 边界框。Wang *et al.* [45] 借鉴先进的 2D 检测器 FCOS [41], 直接预测每个物体的 3D 边界框。DETR3D [47] 将可学习的 3D 查询投影到 2D 图像上, 然后采样相应特征进行端到端的 3D 边界框预测, 无需 NMS 后处理。另一种方案是将图像特征转换为 BEV 特征, 从俯视图预测 3D 边界框。这类方法通过深度估计 [46] 或类别深度分布 [34] 提供的深度信息将图像特征转换到 BEV 特征。OFT [36] 和 ImVoxelNet [37] 将预定义体素投影到图像特征上, 生成场景的体素表示。最近, M²BEV [48] 进一步探索了基于 BEV 特征同时执行多种感知任务的可行性。

事实上, 从多相机特征生成 BEV 特征在地图分割任务中得到了更广泛的研究 [32, 30]。一种直接的方法是通过逆透视映射 (Inverse Perspective Mapping, IPM) [35, 5] 将透视图转换为 BEV。此外, Lift-Splat [32] 基于深度分布生成 BEV 特征。方法 [30, 16, 9] 利用多层感知机学习从透视图到 BEV 的转换。PYVA [51] 提出了跨视角 Transformer, 将前视单目图像转换为 BEV, 但由于全局注意力机制 [42] 的计算开销, 该范式不适合融合多相机特征。除空间信息外, 先前的工作 [18, 38, 6] 也通过堆叠多个时间戳的 BEV 特征来考虑时序信息。堆叠 BEV 特征将可用时序信息限制在固定时间窗口内, 并带来额外计算开销。本文提出的时空 Transformer 通过同时考虑空间和时序线索生成当前时刻的 BEV 特征, 时序信息以 RNN 方式从前一时刻的 BEV 特征中获得, 仅带来很小的计算成本。

3 BEVFormer

将多相机图像特征转换为鸟瞰视图 (BEV) 特征可以为各种自动驾驶感知任务提供统一的环境表示。本文提出一种新的基于 Transformer 的 BEV 生成框架, 通过注意力机制有效聚合多视角相机和历史 BEV 特征的时空信息。

3.1 整体架构

如图2所示, BEVFormer 包含 6 个编码器层, 每层遵循 Transformer 的传统结构 [42], 但包含三个特殊设计: BEV 查询、空间交叉注意力和时序自注意力。具体而言, BEV 查询是网格状可学习参数, 旨在通过注意力机制从多相机视角中查询 BEV 空间中的特征。空间交叉注意力和时序自注意力是与 BEV 查询配合工作的注意力层, 用于根据 BEV 查询查找并聚合来自多相机图像的空间特征以及来自历史 BEV 的时序特征。




图 2: **BEVFormer** 整体架构。(a) BEVFormer 的编码器层包含网格状 BEV 查询、时序自注意力和空间交叉注意力。(b) 在空间交叉注意力中, 每个 BEV 查询仅与感兴趣区域内的图像特征交互。(c) 在时序自注意力中, 每个 BEV 查询与两类特征交互: 当前时间戳的 BEV 查询和前一时刻的 BEV 特征。

在推理过程中, 在时间戳 t 处, 将多相机图像输入骨干网络 (如 ResNet-101 [15]), 获得不同相机视角的特征 $F_t = \{F_t^i\}_{i=1}^{N_{\text{view}}}$, 其中 F_t^i 是第 i 个视角的特征, N_{view} 是相机视角总数。同时, 保留前一时刻 $t-1$ 的 BEV 特征 B_{t-1} 。在每个编码器层中, 首先使用 BEV 查询 Q 通过时序自注意力从前一 BEV 特征 B_{t-1} 中查询时序信息。然后使用 BEV 查询 Q 通过空间交叉注意力从多相机特征 F_t 中查询空间信息。经过前馈网络 [42] 后, 编码器层输出精炼后的 BEV 特征, 作为下一编码器层的输入。经过 6 个堆叠的编码器层后, 生成当前时间戳 t 的统一 BEV 特征 B_t 。以 BEV 特征 B_t 为输入, 3D 检测头和地图分割头预测 3D 边界框和语义图等感知结果。

3.2 BEV 查询

本文预定义一组网格状可学习参数 $Q \in \mathbb{R}^{H \times W \times C}$ 作为 BEVFormer 的查询, 其中 H, W 是 BEV 平面的空间形状。具体来说, 位于 Q 中 $p = (x, y)$ 处的查询 $Q_p \in \mathbb{R}^{1 \times C}$ 负责 BEV 平面中对应的网格单元区域。BEV 平面中的每个网格单元对应实际空间中的 s 米。默认情况下, BEV 特征中心对应自行车位置。遵循常见做法 [14], 在将 BEV 查询 Q 输入 BEVFormer 之前, 加入可学习位置编码。

3.3 空间交叉注意力

由于多相机 3D 感知的输入规模较大 (包含 N_{view} 个相机视角), 标准多头注意力 [42] 的计算开销极高。因此, 本文基于可变形注意力 [56] 开发了空间交叉注意力, 这是一种资源高效的注意力层, 其中每个 BEV 查询 Q_p 仅与跨相机视图的感兴趣区域交互。然而, 可变形注意力最初为 2D 感知设计, 因此需要针对 3D 场景进行一些调整。

如图 2 (b) 所示, 首先将 BEV 平面上的每个查询提升为柱状查询 (Pillar-like Query) [20], 从柱体中采样 N_{ref} 个 3D 参考点, 然后将这些点投影到 2D 视图上。对于一个 BEV 查询, 投影后的 2D 点只会落在部分视图上, 其他视图不会被命中。将命中的视图记为 $\mathcal{V}_{\text{hit}}$ 。之后, 将这些 2D 点视为查询 Q_p 的参考点, 从命中视图 $\mathcal{V}_{\text{hit}}$ 的这些参考点周围采样特征。最后, 对采样特征进行加权求和, 作为空间交叉注意力的输出。空间交叉注意力 (Spatial Cross-Attention, SCA) 的过程可以表示为:

$$\text{SCA}(Q_p, F_t) = \frac{1}{|\mathcal{V}_{\text{hit}}|} \sum_{i \in \mathcal{V}_{\text{hit}}} \sum_{j=1}^{N_{\text{ref}}} \text{DeformAttn}(Q_p, \mathcal{P}(p, i, j), F_t^i), \quad (2)$$

其中 i 索引相机视图, j 索引参考点, N_{ref} 是每个 BEV 查询的总参考点数。 F_t^i 是第 i 个相机视图的特征。对于每个 BEV 查询 Q_p , 使用投影函数 $\mathcal{P}(p, i, j)$ 获取第 i 个视图图像上的第 j 个参考点。

接下来介绍如何通过投影函数 $\mathcal{P}$ 获得视图图像上的参考点。首先计算 Q 中位于 $p = (x, y)$ 处的查询 Q_p 对应的真实世界位置 (x', y') ，如公式3所示。

$$x' = (x - \frac{W}{2}) \times s; \quad y' = (y - \frac{H}{2}) \times s, \quad (3)$$

其中 H, W 是 BEV 查询的空间形状， s 是 BEV 网格的分辨率大小， (x', y') 是以自车位置为原点的坐标。在 3D 空间中，位于 (x', y') 的物体会在 z 轴上的高度 z' 处出现。因此预定义一组锚点高度 $\{z'_j\}_{j=1}^{N_{\text{ref}}}$ ，确保能捕捉到出现在不同高度的线索。这样，对于每个查询 Q_p ，得到一个 3D 参考点柱体 $(x', y', z'_j)_{j=1}^{N_{\text{ref}}}$ 。最后，通过相机的投影矩阵将 3D 参考点投影到不同图像视图上，表达为：

$$\begin{aligned} \mathcal{P}(p, i, j) &= (x_{ij}, y_{ij}) \\ \text{where } z_{ij} \cdot [x_{ij} \quad y_{ij} \quad 1]^T &= T_i \cdot [x' \quad y' \quad z'_j \quad 1]^T. \end{aligned} \quad (4)$$

这里， $\mathcal{P}(p, i, j)$ 是从第 j 个 3D 点 (x', y', z'_j) 投影到第 i 个视图上的 2D 点， $T_i \in \mathbb{R}^{3 \times 4}$ 是第 i 个相机的已知投影矩阵。

3.4 时序自注意力

除空间信息外，时序信息对于视觉系统理解周围环境也至关重要 [27]。例如，在没有时序线索的情况下，从静态图像中推断运动物体的速度或检测高度遮挡的物体具有挑战性。为解决这一问题，本文设计了时序自注意力，通过融合历史 BEV 特征来表示当前环境。

给定当前时间戳 t 的 BEV 查询 Q 和历史 BEV 特征 B_{t-1} ，首先根据自车运动将 B_{t-1} 与 Q 对齐，使同一网格的特征对应相同的真实世界位置。将对齐后的历史 BEV 特征 B_{t-1} 记为 B'_{t-1} 。然而，从 $t-1$ 时刻到 t 时刻，可移动物体在真实世界中以不同的偏移量移动。在不同时间的 BEV 特征之间构建同一物体的精确关联具有挑战性。因此，通过时序自注意力 (Temporal Self-Attention, TSA) 层建模特征之间的时序连接，表达如下：

$$\text{TSA}(Q_p, \{Q, B'_{t-1}\}) = \sum_{V \in \{Q, B'_{t-1}\}} \text{DeformAttn}(Q_p, p, V), \quad (5)$$

其中 Q_p 表示位于 $p = (x, y)$ 的 BEV 查询。此外，与标准可变形注意力不同，时序自注意力中的偏移量 Δp 由 Q 和 B'_{t-1} 的拼接结果预测。特别地，对于每个序列的第一个样本，时序自注意力将退化为无时序信息的自注意力，此时将 BEV 特征 $\{Q, B'_{t-1}\}$ 替换为重复的 BEV 查询 $\{Q, Q\}$ 。

与 [18, 38, 6] 中简单堆叠 BEV 的方法相比，时序自注意力能更有效地建模长时序依赖。BEVFormer 从前一时刻的 BEV 特征而非多个堆叠的 BEV 特征中提取时序信息，因此计算成本更低，受干扰信息的影响更小。

3.5 BEV 特征的应用

由于 BEV 特征 $B_t \in \mathbb{R}^{H \times W \times C}$ 是一种通用的 2D 特征图，可用于多种自动驾驶感知任务，因此 3D 目标检测和地图分割任务头可以基于 2D 感知方法 [56, 22] 进行少量修改即可开发。

3D 目标检测：基于 2D 检测器 Deformable DETR [56] 设计了端到端 3D 检测头。修改包括：使用单尺度 BEV 特征 B_t 作为解码器的输入，预测 3D 边界框和速度而非 2D 边界框，仅使用 L_1 损失来监督 3D 边界框回归。借助该检测头，模型无需 NMS 后处理即可端到端预测 3D 边界框和速度。

地图分割：基于 2D 分割方法 Panoptic SegFormer [22] 设计了地图分割头。由于基于 BEV 的地图分割与常规语义分割基本相同，使用 [22] 的掩码解码器和类别固定查询来针对每个语义类别，包括轿车、车辆、道路（可行驶区域）和车道。

3.6 实现细节

训练阶段。对于时间戳 t 处的每个样本，从过去 2 秒的连续序列中随机采样另外 3 个样本，该随机采样策略可增强自车运动的多样性 [57]。将这 4 个样本的时间戳记为 $t-3$ 、 $t-2$ 、 $t-1$

和 t 。前三个时间戳的样本负责循环生成 BEV 特征 $\{B_{t-3}, B_{t-2}, B_{t-1}\}$ ，该阶段不需要梯度。对于时间戳 $t-3$ 处的第一个样本，没有前一时刻的 BEV 特征，时序自注意力退化为自注意力。在时间 t 处，模型基于多相机输入和前一 BEV 特征 B_{t-1} 生成 BEV 特征 B_t ，因此 B_t 包含跨越四个样本的时序和空间线索。最后，将 BEV 特征 B_t 输入检测和分割头，计算相应的损失函数。

推理阶段。在推理阶段，按时间顺序评估视频序列的每一帧。保存前一时刻的 BEV 特征并用于下一时刻，这种在线推理策略时间效率高，与实际应用场景一致。尽管利用了时序信息，推理速度仍与其他方法相当 [45, 47]。

4 实验

4.1 数据集

本文在两个具有挑战性的公开自动驾驶数据集上进行实验，即 nuScenes 数据集 [4] 和 Waymo 开放数据集 [40]。

nuScenes 数据集 [4] 包含 1000 个场景，每个场景时长约 20 秒，关键样本以 2Hz 的频率进行标注。每个样本包含来自 6 个相机的 RGB 图像，水平视场角为 360° 。检测任务包含来自 10 个类别的 140 万个标注 3D 边界框。按照 [32] 中的设置执行 BEV 分割任务。该数据集还提供了检测任务的官方评估指标。nuScenes 的平均精度 (mAP) 使用地面上的中心距离而非 3D 交并比 (IoU) 来计算，用于匹配预测结果和真实值。nuScenes 指标还包含 5 种真阳性指标 (TP Metrics)，包括 ATE、ASE、AOE、AVE 和 AAE，分别衡量平移、尺度、朝向、速度和属性误差。nuScenes 还定义了 nuScenes 检测分数 (NDS)：
$$\text{NDS} = \frac{1}{10} [5\text{mAP} + \sum_{\text{mTP} \in \text{TP}} (1 - \min(1, \text{mTP}))]$$
，以捕获 nuScenes 检测任务的各个方面。

Waymo 开放数据集 [40] 是一个大规模自动驾驶数据集，包含 798 个训练序列和 202 个验证序列。需要注意的是，Waymo 提供的每帧五张图像仅具有约 252° 的水平视场角，但提供的标注标签是自行车周围 360° 的。在训练和验证集中，移除在任何图像上不可见的边界框。由于 Waymo 开放数据集规模大、帧率高 [34]，通过从训练序列中每 5 帧采样一次的方式使用训练集子集，且仅检测车辆类别。在 Waymo 数据集上，使用 0.5 和 0.7 的 3D IoU 阈值计算 mAP。

4.2 实验设置

参照先前方法 [45, 47, 31]，采用两种骨干网络：从 FCOS3D [45] 检查点初始化的 ResNet101-DCN [15, 12]，以及从 DD3D [31] 检查点初始化的 VoVnet-99 [21]。默认使用 FPN [23] 输出的多尺度特征，尺寸为 $1/16$ 、 $1/32$ 、 $1/64$ ，特征维度 $C=256$ 。在 nuScenes 实验上，BEV 查询的默认大小为 200×200 ，感知范围为 X 和 Y 轴的 $[-51.2\text{m}, 51.2\text{m}]$ ，BEV 网格的分辨率 s 为 0.512m 。对 BEV 查询采用可学习位置编码。BEV 编码器包含 6 个编码器层，每层不断精炼 BEV 查询。每个编码器层输入的 BEV 特征 B_{t-1} 相同且不需要梯度。对于每个局部查询，在由可变形注意力机制实现的空间交叉注意力模块中，对应 $N_{\text{ref}}=4$ 个不同高度的 3D 目标点，预定义的高度锚点从 -5 米到 3 米均匀采样。对于 2D 视图特征上的每个参考点，每个头在该参考点周围使用 4 个采样点。默认情况下，模型训练 24 个轮次，学习率为 2×10^{-4} 。

在 Waymo 实验上更改了一些设置。由于 Waymo 的相机系统无法捕获自行车周围的完整场景 [40]，BEV 查询的默认空间形状为 300×220 ， X 轴感知范围为 $[-35.0\text{m}, 75.0\text{m}]$ ， Y 轴感知范围为 $[-75.0\text{m}, 75.0\text{m}]$ 。每个网格的分辨率 s 为 0.5m 。自行车位于 BEV 的 $(70, 150)$ 处。

基线方法。为消除任务头的影响并公平比较其他 BEV 生成方法，使用 VPN [30] 和 Lift-Splat [32] 替换 BEVFormer，保持任务头和其他设置不变。还将 BEVFormer 调整为静态模型 **BEVFormer-S**，将时序自注意力改为不使用历史 BEV 特征的标准自注意力。

4.3 3D 目标检测结果

仅在检测任务上使用检测头训练模型，以便与先前的当前最优 3D 目标检测方法进行公平比较。在表1和表2中报告了在 nuScenes test 和 val 划分上的主要结果。在公平的训练策略和可比的模型规模下，本文方法在 val 集上以 9.2 个百分点的优势超越此前最佳方法 DETR3D [47] ($51.7\% \text{ NDS vs. } 42.5\% \text{ NDS}$)。在 test 集上，模型在无复杂技巧的情况下

表 1: nuScenes test 集上的 3D 检测结果。* 表示 VoVNet-99 (V2-99) [21] 在深度估计任务上使用额外数据 [31] 进行了预训练。“BEVFormer-S”表示在 BEV 编码器中不利用时序信息。“L”和“C”分别表示 LiDAR 和 Camera。

方法	模态	骨干网络	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
SSN [55]	L	-	0.569	0.463	-	-	-	-	-
CenterPoint-Voxel [52]	L	-	0.655	0.580	-	-	-	-	-
PointPainting [43]	L&C	-	0.581	0.464	0.388	0.271	0.496	0.247	0.111
FCOS3D [45]	C	R101	0.428	0.358	0.690	0.249	0.452	1.434	0.124
PGD [44]	C	R101	0.448	0.386	0.626	0.245	0.451	1.509	0.127
BEVFormer-S	C	R101	0.462	0.409	0.650	0.261	0.439	0.925	0.147
BEVFormer	C	R101	0.535	0.445	0.631	0.257	0.405	0.435	0.143
DD3D [31]	C	V2-99*	0.477	0.418	0.572	0.249	0.368	1.014	0.124
DETR3D [47]	C	V2-99*	0.479	0.412	0.641	0.255	0.394	0.845	0.133
BEVFormer-S	C	V2-99*	0.495	0.435	0.589	0.254	0.402	0.842	0.131
BEVFormer	C	V2-99*	0.569	0.481	0.582	0.256	0.375	0.378	0.126

表 2: nuScenes val 集上的 3D 检测结果。“C”表示 Camera。

方法	模态	骨干网络	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
FCOS3D [45]	C	R101	0.415	0.343	0.725	0.263	0.422	1.292	0.153
PGD [44]	C	R101	0.428	0.369	0.683	0.260	0.439	1.268	0.185
DETR3D [47]	C	R101	0.425	0.346	0.773	0.268	0.383	0.842	0.216
BEVFormer-S	C	R101	0.448	0.375	0.725	0.272	0.391	0.802	0.200
BEVFormer	C	R101	0.517	0.416	0.673	0.274	0.372	0.394	0.198

达到 56.9% 的 NDS，比 DETR3D (47.9% NDS) 高出 9.0 个百分点。本文方法甚至可以与一些基于 LiDAR 的基线方法（如 SSN (56.9% NDS) [55] 和 PointPainting (58.1% NDS) [43]）性能相当。

此前基于相机的方法 [47, 31, 45] 几乎无法估计速度，本文方法证明了时序信息在多相机检测的速度估计中起着至关重要的作用。BEVFormer 在 test 集上的平均速度误差 (mAVE) 为 0.378 m/s，大幅超越其他基于相机的方法，接近基于 LiDAR 的方法 [43] 的性能。

还在 Waymo 上进行了实验，如表3所示。参照 [34]，使用 0.7 和 0.5 的 IoU 阈值评估车辆类别。此外，还采用 nuScenes 指标评估结果，因为基于 IoU 的指标对基于相机的方法过于苛刻。由于只有少数基于相机的工作报告了 Waymo 上的结果，因此使用 DETR3D 的官方代码在 Waymo 上进行实验以便对比。可以观察到，在 IoU 阈值为 0.5 的条件下，BEVFormer 在 LEVEL_1 和 LEVEL_2 难度上分别以 6.0% 和 2.5% 的带航向信息平均精度 (APH) [40] 超越 DETR3D。在 nuScenes 指标上，BEVFormer 以 3.2% NDS 和 5.2% AP 的优势超越 DETR3D。还在前置相机上进行了实验，将 BEVFormer 与 CaDNN [34]（一种在 Waymo 数据集上报告了结果的单目 3D 检测方法）进行比较。在 IoU 阈值为 0.5 的条件下，BEVFormer 在 LEVEL_1 和 LEVEL_2 难度上分别以 13.3% 和 11.2% 的 APH 超越 CaDNN。

4.4 多任务感知结果

同时使用检测和分割头训练模型，以验证模型对多任务的学习能力，结果如表4所示。在相同设置下比较不同 BEV 编码器时，BEVFormer 在所有任务上取得了更高性能，仅道路分割结果与 BEVFormer-S 相当。例如，在联合训练下，BEVFormer 在检测任务上以 11.0 个百分点的优势超越 Lift-Splat* [32] (52.0% NDS *v.s.* 41.0% NDS)，在车道分割上的 IoU 高出 5.6 个百分点 (23.9% *v.s.* 18.3%)。与单独训练任务相比，多任务学习通过共享更多模块（包括骨干网络和 BEV 编码器）节省了计算成本并减少了推理时间。本文表明，BEV 编码器生成的 BEV 特征能够很好地适应不同任务，使用多任务头训练的模型在检测任务和车辆

表 3: 在 Waymo val 集上分别使用 Waymo 评估指标和 nuScenes 评估指标的 3D 检测结果。“L1”和“L2”指 Waymo 的“LEVEL_1”和“LEVEL_2”难度 [40]。*: 仅使用前置相机, 且仅考虑前置相机视场角 (50.4°) 内的物体标签。†: 将 ATE 和 AAE 设为 1 来计算 NDS 分数。“L”和“C”分别表示 LiDAR 和 Camera。

方法	模态	Waymo 指标				NuScenes 指标				
		IoU=0.5		IoU=0.7		NDS†↑	AP↑	ATE↓	ASE↓	AOE↓
		L1/APH	L2/APH	L1/APH	L2/APH					
PointPillars [20]	L	0.866	0.801	0.638	0.557	0.685	0.838	0.143	0.132	0.070
DETR3D [47]	C	0.220	0.216	0.055	0.051	0.394	0.388	0.741	0.156	0.108
BEVFormer	C	0.280	0.241	0.061	0.052	0.426	0.440	0.679	0.157	0.101
CaDNN* [34]	C	0.175	0.165	0.050	0.045	-	-	-	-	-
BEVFormer*	C	0.308	0.277	0.077	0.069	-	-	-	-	-

表 4: nuScenes val 集上的 3D 检测和地图分割结果。联合训练与单独训练分割和检测任务的对比。*: 使用 VPN [30] 和 Lift-Splat [32] 替换 BEV 编码器进行对比, 任务头相同。†: 来自原论文的结果。

方法	任务头		3D 检测		BEV 分割 (IoU)			
	检测	分割	NDS↑	mAP↑	轿车	各类车辆	道路	车道
Lift-Splat† [32]	✗	✓	-	-	32.1	32.1	72.9	20.0
FIERY† [18]	✗	✓	-	-	-	38.2	-	-
VPN* [30]	✓	✗	0.333	0.253	-	-	-	-
VPN*	✗	✓	-	-	31.0	31.8	76.9	19.4
VPN*	✓	✓	0.334	0.257	36.6	37.3	76.0	18.0
Lift-Splat*	✓	✗	0.397	0.348	-	-	-	-
Lift-Splat*	✗	✓	-	-	42.1	41.7	77.7	20.0
Lift-Splat*	✓	✓	0.410	0.344	43.0	42.8	73.9	18.3
BEVFormer-S	✓	✗	0.448	0.375	-	-	-	-
BEVFormer-S	✗	✓	-	-	43.1	43.2	80.7	21.3
BEVFormer-S	✓	✓	0.453	0.380	44.3	44.4	77.6	19.8
BEVFormer	✓	✗	0.517	0.416	-	-	-	-
BEVFormer	✗	✓	-	-	44.8	44.8	80.1	25.7
BEVFormer	✓	✓	0.520	0.412	46.8	46.7	77.5	23.9

分割上表现更优。然而, 联合训练模型在道路和车道分割上不如单独训练模型, 这是多任务学习中一种常见的现象, 称为负迁移 [11, 13]。

4.5 消融实验

为深入探究不同模块的效果, 在 nuScenes val 集上使用检测头进行消融实验。更多消融实验见附录。

空间交叉注意力的有效性。为验证空间交叉注意力的效果, 使用 BEVFormer-S 进行消融实验以排除时序信息的干扰, 结果如表5所示。默认的空间交叉注意力基于可变形注意力。为进行对比, 还构建了另外两种使用不同注意力机制的基线: (1) 使用全局注意力替换可变形注意力; (2) 使每个查询仅与其参考点交互而非周围局部区域, 这类似于先前的方法 [36, 37]。为进行更广泛的对比, 还将 BEVFormer 替换为 VPN [30] 和 Lift-Splat [32] 提出的 BEV 生成方法。可以观察到, 在可比的模型规模下, 可变形注意力显著优于其他注意力机制。全局注意力消耗过多 GPU 显存, 而仅点交互的感知范围有限。稀疏注意力通过与先验确定的感兴趣区域交互, 平衡了感受野和 GPU 消耗, 取得了更好的性能。

时序自注意力的有效性。从表1和表4可以观察到, 在相同设置下 BEVFormer 以显著改进超越 BEVFormer-S, 尤其在具有挑战性的检测任务上。时序信息的效果主要体现在以下方

表 5: 不同方法在 nuScenes val 集上使用不同 BEV 编码器的检测结果。“Memory”表示训练期间消耗的 GPU 显存。*: 使用 VPN [30] 和 Lift-Splat [32] 替换 BEV 编码器进行对比。†: 在空间交叉注意力中使用全局注意力训练 BEVFormer-S, 模型使用 fp16 权重训练。此外, 仅采用骨干网络的单尺度特征, 并将 BEV 查询的空间形状设为 100×100 以节省显存。‡: 通过移除预测的偏移量和权重, 将可变形注意力的交互目标从局部区域退化为仅参考点。

方法	注意力机制	NDS↑	mAP↑	mATE↓	mAOE↓	参数量	FLOPs	显存
VPN* [30]	-	0.334	0.252	0.926	0.598	111.2M	924.5G	~20G
List-Splat* [32]	-	0.397	0.348	0.784	0.537	74.0M	1087.7G	~20G
BEVFormer-S†	Global	0.404	0.325	0.837	0.442	62.1M	1245.1G	~36G
BEVFormer-S‡	Points	0.423	0.351	0.753	0.442	68.1M	1264.3G	~20G
BEVFormer-S	Local	0.448	0.375	0.725	0.391	68.7M	1303.5G	~20G




图 3: 不同可见度子集的检测结果。根据物体可见度将 nuScenes val 集划分为四个子集: {0-40%, 40-60%, 60-80%, 80-100%} 的物体可见。(a): 借助时序信息增强了 BEVFormer 在所有子集上的召回率, 尤其在可见度最低的子集 (0-40%) 上提升显著。(b)、(d) 和 (e): 时序信息有助于提高平移、朝向和速度精度。(c) 和 (f): 不同方法之间的尺度和属性误差差异较小。时序信息对物体尺度预测帮助有限。

面: (1) 时序信息的引入极大提升了速度估计的精度; (2) 使用时序信息后, 物体位置和朝向的预测更加精确; (3) 由于时序信息包含过去的物体线索, 在严重遮挡的物体上获得了更高的召回率, 如图3所示。为评估 BEVFormer 在不同遮挡程度物体上的性能, 根据 nuScenes 提供的官方可见度标签将验证集划分为四个子集。在每个子集中, 还计算了匹配时中心距离阈值为 2 米的所有类别的平均召回率。所有方法的最大预测框数量均为 300, 以公平比较召回率。在仅有 0-40% 物体可见的子集上, BEVFormer 的平均召回率以超过 6.0 个百分点的优势超越 BEVFormer-S 和 DETR3D。

模型规模与延迟。在表6中比较了不同配置的性能和延迟。从三个方面消融 BEVFormer 的规模, 包括是否使用多尺度视图特征、BEV 查询的形状和层数, 以验证性能和推理延迟之间的权衡。可以观察到, 配置 C 在 BEVFormer 中仅使用一个编码器层, 达到了 50.1% 的 NDS, 并将 BEVFormer 的延迟从原来的 130ms 降低到 25ms。配置 D 采用单尺度视图特征、较小的 BEV 尺寸和仅有 1 个编码器层, 推理时仅消耗 7ms, 尽管与默认配置相比损失了 3.9 个百分点。然而, 由于多视角图像输入, 限制效率的瓶颈在于骨干网络, 适用于自动驾驶的高效骨干网络值得深入研究。总体而言, 架构可以适应多种模型规模, 并灵活地权衡性能和效率。

表 6: 不同模型配置在 nuScenes val 集上的延迟和性能。延迟在 V100 GPU 上测量, 骨干网络为 R101-DCN。输入图像尺寸为 900×1600 。“MS”表示多尺度视图特征。

方法	BEVFormer 规模			延迟 (ms)			FPS	NDS $\uparrow$	mAP $\uparrow$
	多尺度	BEV 尺寸	层数	骨干网络	BEVFormer	检测头			
BEVFormer	✓	200×200	6	391	130	19	1.7	0.517	0.416
A	✗	200×200	6	387	87	19	1.9	0.511	0.406
B	✓	100×100	6	391	53	18	2.0	0.504	0.402
C	✓	200×200	1	391	25	19	2.1	0.501	0.396
D	✗	100×100	1	387	7	18	2.3	0.478	0.374




图 4: BEVFormer 在 nuScenes val 集上的可视化结果。展示了多相机图像和鸟瞰视图中的 3D 边界框预测结果。

4.6 可视化结果

在图4中展示了一个复杂场景的检测结果。BEVFormer 产生了令人印象深刻的结果, 仅在少数小物体和远处物体上存在错误。更多定性结果见附录。

5 讨论与结论

本文提出了 BEVFormer, 用于从多相机输入生成鸟瞰视图特征。BEVFormer 能够高效聚合空间和时序信息, 生成强大的 BEV 特征, 同时支持 3D 目标检测和地图分割任务。

局限性。目前, 基于相机的方法在效果和效率上与基于 LiDAR 的方法仍存在一定差距。从 2D 信息精确推理 3D 位置仍然是基于相机的方法长期面临的挑战。

更广泛的影响。BEVFormer 证明了利用多相机输入的时空信息可以显著提升视觉感知模型的性能。BEVFormer 展示的优势, 如更精确的速度估计和更高的低可见度物体召回率, 对于构建更好、更安全的自动驾驶系统及其相关应用至关重要。相信 BEVFormer 只是后续更强大的视觉感知方法的一个基线, 基于视觉的感知系统仍有巨大潜力有待挖掘。

参考文献

- [1] Brazil, G., Liu, X.: M3d-rpn: Monocular 3d region proposal network for object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 9287–9296 (2019)
- [2] Brazil, G., Pons-Moll, G., Liu, X., Schiele, B.: Kinematic 3d object detection in monocular video. In: European Conference on Computer Vision. pp. 135–152. Springer (2020)
- [3] Bruls, T., Porav, H., Kunze, L., Newman, P.: The right (angled) perspective: Improving the understanding of road scenes using boosted inverse perspective mapping. In: 2019 IEEE Intelligent Vehicles Symposium (IV). pp. 302–309. IEEE (2019)
- [4] Caesar, H., Bankiti, V., Lang, A.H., Vora, S., Liong, V.E., Xu, Q., Krishnan, A., Pan, Y., Baldan, G., Beijbom, O.: nuscenes: A multimodal dataset for autonomous

- driving. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 11621–11631 (2020)
- [5] Can, Y.B., Liniger, A., Paudel, D.P., Van Gool, L.: Structured bird’s-eye-view traffic scene understanding from onboard images. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 15661–15670 (2021)
 - [6] Can, Y.B., Liniger, A., Unal, O., Paudel, D., Van Gool, L.: Understanding bird’s-eye view semantic hd-maps using an onboard monocular camera. arXiv preprint arXiv:2012.03040 (2020)
 - [7] Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S.: End-to-end object detection with transformers. In: European conference on computer vision. pp. 213–229. Springer (2020)
 - [8] Chen, X., Ma, H., Wan, J., Li, B., Xia, T.: Multi-view 3d object detection network for autonomous driving. In: Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. pp. 1907–1915 (2017)
 - [9] Chitta, K., Prakash, A., Geiger, A.: Neat: Neural attention fields for end-to-end autonomous driving. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 15793–15803 (2021)
 - [10] Cho, K., Van Merriënboer, B., Bahdanau, D., Bengio, Y.: On the properties of neural machine translation: Encoder-decoder approaches. arXiv preprint arXiv:1409.1259 (2014)
 - [11] Crawshaw, M.: Multi-task learning with deep neural networks: A survey. arXiv preprint arXiv:2009.09796 (2020)
 - [12] Dai, J., Qi, H., Xiong, Y., Li, Y., Zhang, G., Hu, H., Wei, Y.: Deformable convolutional networks. In: Proceedings of the IEEE international conference on computer vision. pp. 764–773 (2017)
 - [13] Fifty, C., Amid, E., Zhao, Z., Yu, T., Anil, R., Finn, C.: Efficiently identifying task groupings for multi-task learning. *Advances in Neural Information Processing Systems* **34** (2021)
 - [14] Gehring, J., Auli, M., Grangier, D., Yarats, D., Dauphin, Y.N.: Convolutional sequence to sequence learning. In: International Conference on Machine Learning. pp. 1243–1252. PMLR (2017)
 - [15] He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 770–778 (2016)
 - [16] Hendy, N., Sloan, C., Tian, F., Duan, P., Charchut, N., Xie, Y., Wang, C., Philbin, J.: Fishing net: Future inference of semantic heatmaps in grids. arXiv preprint arXiv:2006.09917 (2020)
 - [17] Hochreiter, S., Schmidhuber, J.: Long short-term memory. *Neural computation* **9**(8), 1735–1780 (1997)
 - [18] Hu, A., Murez, Z., Mohan, N., Dudas, S., Hawke, J., Badrinarayanan, V., Cipolla, R., Kendall, A.: Fiery: Future instance prediction in bird’s-eye view from surround monocular cameras. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 15273–15282 (2021)
 - [19] Kang, K., Ouyang, W., Li, H., Wang, X.: Object detection from video tubelets with convolutional neural networks. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 817–825 (2016)
 - [20] Lang, A.H., Vora, S., Caesar, H., Zhou, L., Yang, J., Beijbom, O.: Pointpillars: Fast encoders for object detection from point clouds. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 12697–12705 (2019)
 - [21] Lee, Y., Hwang, J.w., Lee, S., Bae, Y., Park, J.: An energy and gpu-computation efficient backbone network for real-time object detection. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. pp. 0–0 (2019)

- [22] Li, Z., Wang, W., Xie, E., Yu, Z., Anandkumar, A., Alvarez, J.M., Lu, T., Luo, P.: Panoptic segformer: Delving deeper into panoptic segmentation with transformers. arXiv preprint arXiv:2109.03814 (2021)
- [23] Lin, T.Y., Dollár, P., Girshick, R.B., He, K., Hariharan, B., Belongie, S.J.: Feature pyramid networks for object detection. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) pp. 936–944 (2017)
- [24] Loshchilov, I., Hutter, F.: Sgdr: Stochastic gradient descent with warm restarts. arXiv: Learning (2017)
- [25] Loshchilov, I., Hutter, F.: Decoupled weight decay regularization. In: ICLR (2019)
- [26] Luo, W., Yang, B., Urtasun, R.: Fast and furious: Real time end-to-end 3d detection, tracking and motion forecasting with a single convolutional net. In: Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. pp. 3569–3577 (2018)
- [27] Ma, X., Ouyang, W., Simonelli, A., Ricci, E.: 3d object detection from images for autonomous driving: A survey. arXiv preprint arXiv:2202.02980 (2022)
- [28] Mousavian, A., Anguelov, D., Flynn, J., Kosecka, J.: 3d bounding box estimation using deep learning and geometry. In: Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. pp. 7074–7082 (2017)
- [29] Ng, M.H., Radia, K., Chen, J., Wang, D., Gog, I., Gonzalez, J.E.: Bev-seg: Bird’s eye view semantic segmentation using geometry and semantic point cloud. arXiv preprint arXiv:2006.11436 (2020)
- [30] Pan, B., Sun, J., Leung, H.Y.T., Andonian, A., Zhou, B.: Cross-view semantic segmentation for sensing surroundings. IEEE Robotics and Automation Letters **5**(3), 4867–4873 (2020)
- [31] Park, D., Ambrus, R., Guizilini, V., Li, J., Gaidon, A.: Is pseudo-lidar needed for monocular 3d object detection? In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 3142–3152 (2021)
- [32] Philion, J., Fidler, S.: Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d. In: European Conference on Computer Vision. pp. 194–210. Springer (2020)
- [33] Qi, C.R., Zhou, Y., Najibi, M., Sun, P., Vo, K., Deng, B., Anguelov, D.: Offboard 3d object detection from point cloud sequences. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 6134–6144 (2021)
- [34] Reading, C., Harakeh, A., Chae, J., Waslander, S.L.: Categorical depth distribution network for monocular 3d object detection. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 8555–8564 (2021)
- [35] Reiher, L., Lampe, B., Eckstein, L.: A sim2real deep learning approach for the transformation of images from multiple vehicle-mounted cameras to a semantically segmented image in bird’s eye view. In: 2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC). pp. 1–7. IEEE (2020)
- [36] Roddick, T., Kendall, A., Cipolla, R.: Orthographic feature transform for monocular 3d object detection. In: BMVC (2019)
- [37] Rukhovich, D., Vorontsova, A., Konushin, A.: Imvoxelnet: Image to voxels projection for monocular and multi-view general-purpose 3d object detection. In: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. pp. 2397–2406 (2022)
- [38] Saha, A., Maldonado, O.M., Russell, C., Bowden, R.: Translating images into maps. arXiv preprint arXiv:2110.00966 (2021)
- [39] Simonelli, A., Bulò, S.R., Porzi, L., Lopez-Antequera, M., Kotschieder, P.: Disentangling monocular 3d object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (October 2019)
- [40] Sun, P., Kretschmar, H., Dotiwalla, X., Chouard, A., Patnaik, V., Tsui, P., Guo, J., Zhou, Y., Chai, Y., Caine, B., et al.: Scalability in perception for autonomous driving: Waymo open dataset. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 2446–2454 (2020)

- [41] Tian, Z., Shen, C., Chen, H., He, T.: Fcos: Fully convolutional one-stage object detection. In: Proceedings of the IEEE/CVF international conference on computer vision. pp. 9627–9636 (2019)
- [42] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. *Advances in neural information processing systems* **30** (2017)
- [43] Vora, S., Lang, A.H., Helou, B., Beijbom, O.: Pointpainting: Sequential fusion for 3d object detection. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 4604–4612 (2020)
- [44] Wang, T., Xinge, Z., Pang, J., Lin, D.: Probabilistic and geometric depth: Detecting objects in perspective. In: Conference on Robot Learning. pp. 1475–1485. PMLR (2022)
- [45] Wang, T., Zhu, X., Pang, J., Lin, D.: Fcos3d: Fully convolutional one-stage monocular 3d object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 913–922 (2021)
- [46] Wang, Y., Chao, W.L., Garg, D., Hariharan, B., Campbell, M., Weinberger, K.Q.: Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 8445–8453 (2019)
- [47] Wang, Y., Guizilini, V.C., Zhang, T., Wang, Y., Zhao, H., Solomon, J.: Detr3d: 3d object detection from multi-view images via 3d-to-2d queries. In: Conference on Robot Learning. pp. 180–191. PMLR (2022)
- [48] Xie, E., Yu, Z., Zhou, D., Philion, J., Anandkumar, A., Fidler, S., Luo, P., Alvarez, J.M.: M² 2bev: Multi-camera joint 3d detection and segmentation with unified birds-eye view representation. *arXiv preprint arXiv:2204.05088* (2022)
- [49] Xu, B., Chen, Z.: Multi-level fusion based 3d object detection from monocular images. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 2345–2353 (2018)
- [50] Yan, Y., Mao, Y., Li, B.: Second: Sparsely embedded convolutional detection. *Sensors* **18**(10), 3337 (2018)
- [51] Yang, W., Li, Q., Liu, W., Yu, Y., Ma, Y., He, S., Pan, J.: Projecting your view attentively: Monocular road scene layout estimation via cross-view transformation. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 15536–15545 (2021)
- [52] Yin, T., Zhou, X., Krahenbuhl, P.: Center-based 3d object detection and tracking. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 11784–11793 (2021)
- [53] Zhou, X., Wang, D., Krähenbühl, P.: Objects as points. *arXiv preprint arXiv:1904.07850* (2019)
- [54] Zhou, Y., Tuzel, O.: Voxelnet: End-to-end learning for point cloud based 3d object detection. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 4490–4499 (2018)
- [55] Zhu, X., Ma, Y., Wang, T., Xu, Y., Shi, J., Lin, D.: Ssn: Shape signature networks for multi-class object detection from point clouds. In: European Conference on Computer Vision. pp. 581–597. Springer (2020)
- [56] Zhu, X., Su, W., Lu, L., Li, B., Wang, X., Dai, J.: Deformable detr: Deformable transformers for end-to-end object detection. In: International Conference on Learning Representations (2020)
- [57] Zhu, X., Xiong, Y., Dai, J., Yuan, L., Wei, Y.: Deep feature flow for video recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 2349–2358 (2017)

附录

A 实现细节

本节提供所提方法和实验的更多实现细节。

A.1 训练策略

参照先前方法 [47, 56], 所有模型训练 24 个轮次, 每个 GPU 的批大小为 1 (包含 6 张视图图像), 学习率为 2×10^{-4} , 骨干网络的学习率乘数为 0.1, 使用余弦退火 [24] 衰减学习率。采用 AdamW [25] 优化模型, 权重衰减为 1×10^{-2} 。

A.2 VPN 与 Lift-Splat

本文使用 VPN [30] 和 Lift-Splat [32] 作为两个基线方法。为公平比较, 骨干网络和任务头与 BEVFormer 相同。

VPN. 使用官方代码¹。受限于 MLP 的巨大参数量, VPN 难以生成高分辨率 BEV (如 200×200)。为与 VPN 进行比较, 本文通过两个视图转换层将单尺度视图特征转换为低分辨率 (50×50) 的 BEV。

Lift-Splat. 为与 BEVFormer 在可比参数量下进行公平比较, 对 Lift-Splat²的相机编码器增加了两个额外的卷积层。其他设置保持不变。

A.3 任务头

检测头. 为每个 3D 边界框预测 10 个参数, 包括框尺度的 3 个参数 (l, w, h), 中心位置的 3 个参数 (x_o, y_o, z_o), 物体偏航角 θ 的 2 个参数 ($\cos(\theta), \sin(\theta)$), 以及速度的 2 个参数 (v_x, v_y)。训练阶段仅使用 L_1 损失和 L_1 代价。参照 [47], 使用 900 个目标查询, 推理时保留置信度最高的 300 个预测框。

分割头. 如图5所示, 对于语义图的每个类别, 借鉴 [22] 中的掩码解码器, 使用一个可学习查询表示该类别, 基于标准多头注意力的注意力图生成最终分割掩码。

A.4 空间交叉注意力

全局注意力. 除了可变形注意力 [56], 空间交叉注意力也可以通过全局注意力 (即标准多头注意力) [42] 实现。使用全局注意力最直接的方式是让每个 BEV 查询与所有多相机特征交互, 这种概念实现不需要相机标定。然而, 这种直接方式的计算成本不可承受。因此, 仍然利用相机内参和外参来决定每个 BEV 查询应当交互的命中视图。该策略使得一个 BEV 查询通常仅与一个或两个视图交互而非全部视图, 从而使在空间交叉注意力中使用全局注意力成为可能。值得注意的是, 与其他依赖精确相机内参和外参的注意力机制相比, 全局注意力对相机标定更加鲁棒。




图 5: BEVFormer 的分割头 (掩码解码器)。

B 相机外参鲁棒性

BEVFormer 依赖相机内参和外参获取 2D 视图上的参考点。在自动驾驶系统部署阶段, 由于标定误差、相机偏移等各种原因, 外参可能存在偏差。如图6所示, 展示了模型在不同相机外参噪声水平下的结果。与 BEVFormer-S (point) 相比, BEVFormer-S 使用基于可变形注意力 [56] 的空间交叉注意力, 在参考点周围采样特征, 而非仅与参考点交互。借助可变形注意力, BEVFormer-S 的鲁棒性强于 BEVFormer-S (point)。例如, 在噪声水平为 4 时, BEVFormer-S 的 NDS 下降了 15.2% (计算方式为 $1 - \frac{0.380}{0.448}$), 而 BEVFormer-S (point)

¹<https://github.com/pbw-Berwin/View-Parsing-Network>

²<https://github.com/nv-tlabs/lift-splat-shoot>




图 6: 不同相机外参噪声水平下各方法在 nuScenes val 集上的 NDS。对于第 i 级噪声, 旋转噪声从均值为 0、方差为 i 的正态分布中采样 (旋转噪声单位为度, 各轴噪声独立), 平移噪声从均值为 0、方差为 $5i$ 的正态分布中采样 (平移噪声单位为厘米, 各方向噪声独立)。“BEVFormer” 是默认版本。“BEVFormer (noise)” 使用含噪声外参 (噪声水平 =1) 训练。“BEVFormer-S” 是 BEVFormer 的静态版本, 空间交叉注意力由可变形注意力 [56] 实现。“BEVFormer-S (global)” 是 BEVFormer-S 的空间交叉注意力由全局注意力 (即标准多头注意力) [42] 实现。“BEVFormer-S (point)” 是 BEVFormer-S 使用点空间交叉注意力, 通过移除预测的偏移量和权重将可变形注意力的交互目标从局部区域退化为仅参考点。

的 NDS 下降了 17.3%。与 BEVFormer-S 相比, BEVFormer 仅下降 14.3% 的 NDS, 表明时序信息也能提升对相机外参的鲁棒性。参照 [32], 结果表明当使用含噪声的外参训练 BEVFormer 时, BEVFormer (noise) 具有更强的鲁棒性 (仅下降 8.9% NDS)。使用基于全局注意力的空间交叉注意力时, 即使在相机外参噪声水平 4 下, BEVFormer (global) 也具备很强的抗干扰能力 (NDS 下降 4.0%)。原因在于不需要利用相机外参为 BEV 查询选择感兴趣区域。

值得注意的是, 在最严苛的噪声条件下, BEVFormer-S (global) 甚至优于 BEVFormer-S (38.8% NDS *vs.* 38.0% NDS)。

C 消融实验

训练中帧数量的影响。表7展示了训练中帧数量的影响。可以看到, nuScenes val 集上的 NDS 随帧数增加持续上升, 并在帧数 ≥ 4 时趋于平稳。因此, 实验默认将训练帧数设为 4。

部分设计的影响。表8展示了多项消融实验的结果。比较 #1 和 #4, 将历史 BEV 特征与自车运动对齐对于表示与当前 BEV 查询相同的几何场景至关重要 (51.0% NDS *vs.* 51.7% NDS)。比较 #2 和 #4, 从 5 帧中随机采样 4 帧是一种有效的数据增强策略, 可提升性能 (51.3% NDS *vs.* 51.7% NDS)。与仅使用 BEV 查询预测时序自注意力模块中的偏移量和权重 (见 #3) 相比, 同时使用 BEV 查询和历史 BEV 特征 (见 #4) 包含更多关于过去 BEV 特征的线索, 有利于位置预测 (51.3% NDS *vs.* 51.7% NDS)。

D 可视化

如图7所示, 比较了 BEVFormer 与 BEVFormer-S。借助时序信息, BEVFormer 成功检测到两辆被遮挡的公交车。还在图8中展示了目标检测和地图分割结果, 可以看到检测结果和分割结果高度一致。在图9中提供了更多地图分割结果, 可以看出借助 BEVFormer 生成的强大 BEV 特征, 通过简单的掩码解码器即可很好地预测语义图。

表 7: 不同训练帧数下模型在 nuScenes val 集上的 NDS。“#Frame”表示训练帧数。

#Frame	NDS↑	mAP↑	mAVE↓
1	0.448	0.375	0.802
2	0.490	0.388	0.467
3	0.510	0.410	0.423
4	0.517	0.416	0.394
5	0.517	0.412	0.387

表 8: nuScenes val 集上的消融实验。“A.”表示将历史 BEV 特征与自车运动对齐。“R.”表示从 5 个连续帧中随机采样 4 帧。“B.”表示同时使用 BEV 查询和历史 BEV 特征预测偏移量和权重。

#	A.	R.	B.	NDS↑	mAP↑
1	✗	✓	✓	0.510	0.410
2	✓	✗	✓	0.513	0.410
3	✓	✓	✗	0.513	0.404
4	✓	✓	✓	0.517	0.416




图 7: BEVFormer 与 BEVFormer-S 在 nuScenes val 集上的对比。可以观察到 BEVFormer 能够检测到严重遮挡的物体，而这些物体在 BEVFormer-S 的预测结果中被遗漏 (红色圆圈标注)。




图 8: 目标检测和地图分割任务的可视化结果。车辆、道路和车道分割分别用蓝色、橙色和绿色表示。




图 9: 地图分割任务的可视化结果。车辆、道路、人行横道和车道分割分别用蓝色、橙色、青色和绿色表示。