

Depth Anything 3: 从任意视角恢复视觉空间

Haotong Lin*, Sili Chen*, Jun Hao Liew*, Donny Y. Chen*, Zhenyu Li, Guang Shi, Jiashi Feng, Bingyi Kang*,†

ByteDance Seed


† 项目负责人, * 同等贡献

摘要

本文提出 Depth Anything 3 (DA3), 一个能够从任意数量的视觉输入中预测空间一致几何信息的模型, 可在已知或未知相机位姿的条件下运行。在追求极简建模的过程中, DA3 带来了两项关键洞察: 一个普通的 Transformer (如原始 DINO 编码器) 无需架构特化即可胜任骨干网络, 且单一的深度-射线预测目标足以替代复杂的多任务学习。通过教师-学生训练范式, 该模型达到了与 Depth Anything 2 (DA2) 相当的细节水平和泛化能力。我们建立了一个新的视觉几何基准, 涵盖相机位姿估计、任意视角几何和视觉渲染。在该基准上, DA3 在所有任务上均创下新的最优水平, 在相机位姿精度上平均超越此前最优方法 VGGT 35.7%, 在几何精度上平均超越 23.6%。此外, 在单目深度估计方面也优于 DA2。所有模型均仅使用公开学术数据集训练。

通讯作者: Bingyi Kang

Project Page: [depth-anything-3.github.io](https://github.com/bingkang01/depth-anything-3)



¹“Depth Anything 3” 标志着该系列的新一代演进, 从单目输入扩展到任意视角输入, 这一发展基于我们坚信深度是理解物理世界的基石。

Contents

1	引言	3
2	相关工作	4
3	Depth Anything 3	5
3.1	问题形式化	5
3.2	网络架构	6
3.3	训练	7
3.4	实现细节	7
4	教师-学生学习	7
4.1	构建教师模型	8
4.2	教导 Depth Anything 3	9
4.3	教导单目模型	9
4.4	教导度量深度模型	9
5	应用：前馈式 3D 高斯泼溅	10
5.1	位姿条件化的前馈式 3DGS	10
5.2	位姿自适应的前馈式 3DGS	10
5.3	实现细节	10
6	视觉几何基准	11
6.1	基准流程	11
6.2	指标	11
6.3	数据集	11
7	实验	13
7.1	与现有最优方法的比较	13
7.2	Depth Anything 3 分析	15
7.2.1	深度-射线表示的充分性	15
7.2.2	单个普通 Transformer 的充分性	15
7.2.3	消融与分析	16
7.3	Depth Anything 3 单目模型分析	17
7.3.1	教师模型	17
7.3.2	学生模型	18
7.4	Depth Anything 3 度量深度模型分析	19
7.5	前馈 3DGS 分析	19
8	结论与讨论	20
A	数据处理	30




Figure 1 Given any number of images and optional camera poses, **Depth Anything 3** reconstructs the visual space, producing consistent depth and ray maps that can be fused into accurate point clouds, resulting in high-fidelity 3D Gaussians and geometry. It significantly outperforms VGGT in multi-view geometry and pose accuracy; with monocular inputs, it also surpasses Depth Anything 2 while matching its detail and robustness.

1 引言

从视觉输入中感知和理解三维空间信息是人类空间智能的基石 [4]，也是机器人技术和混合现实等应用的关键需求。这一基本能力催生了广泛的 3D 视觉任务，包括单目深度估计 [23]、运动恢复结构 [80]、多视图立体视觉 [73] 和同步定位与建图 [58]。尽管这些任务在概念上具有很强的重叠性——通常仅相差单一因素，例如输入视图的数量——但主流范式一直是为每个任务开发高度专门化的模型。虽然近期的努力 [91, 97] 已探索通过统一模型来同时处理多个任务，但它们通常存在关键局限性：往往依赖复杂、特制的架构，从头开始通过任务联合优化进行训练，因而无法有效利用大规模预训练模型。

在本工作中，我们跳出既有的 3D 任务定义，回归到受人类空间智能启发的更基本目标：从任意视觉输入中恢复 3D 结构，无论是单张图像、场景的多个视图还是视频流。我们摒弃复杂的架构工程，以两个核心问题为导向，追求一种极简的建模策略。第一，是否存在**最小的预测目标集合**，还是需要对众多 3D 任务进行联合建模？第二，**单一的朴素 Transformer** 是否足以实现这一目标？我们的工作对这两个问题都给出了肯定答案。我们提出 **Depth Anything 3**，这是一个单一 Transformer 模型，通过一种特殊选择的射线表示，专门针对**任意视角深度与位姿估计**进行训练。我们证明，这种极简方法足以从任意数量的图像中重建视觉空间，无论相机位姿是否已知。

Depth Anything 3 将上述几何重建目标表述为一个密集预测任务。对于给定的 N 张输入图像，模型经过训练输出 N 张对应的深度图和射线图，每张图与其各自输入像素对齐。实现这一目标的架构始于一个标准的预训练视觉 Transformer（例如，Oquab et al. 61）作为骨干网络，利用其强大的特征提取能力。为了处理任意数量的视图，我们引入了一个关键改进：一种输入自适应的跨视角自注意力机制。该模块在选定层的前向传播过程中动态重排标记，从而实现所有视图间的高效信息交换。对于最终预测，我们提出了一个新的双 DPT 头，通过以不同的融合参数处理同一组特征，同时输出深度值和射线值。为了增强灵活性，模型可以通过一个简单的相机编码器可选地融入已知的相机位姿，使其能够适应各种实际场景。这一整体设计产生了一个简洁且可扩展的架构，直接继承了其预训练骨干网络的缩放特性。

我们通过教师-学生训练范式来训练 Depth Anything 3，以统一多样化的训练数据，这对于通用模型是必要的。我们的数据来源包括多种格式，如真实世界的深度相机采集数据（例如，Baruch et al. 5）、3D 重建数据（例如，Reizenstein et al. 68）以及合成数据，其中真实世界的深度可能质量较差（图 4）。为了解决这个问题，我们采用了受先前工作 [112, 113] 启发的伪标签策略。具体来说，我们在合成数据上训练一个强大的教师单目深度模型，为所有真实世界数据生成密集、高质量的伪深度。至关重要的是，为了保持几何完整性，我们将这些密集的伪深度图与原始的稀疏或噪声深度进行对齐。这种方法被证明非常有效，在保证几何精度的同时，显著增强了标签的细节和完整性。

为了更好地评估我们的模型并跟踪该领域的进展，我们建立了一个全面的基准，用于评估几何和位姿精度。该基准包含 5 个不同的数据集，总计超过 89 个场景，涵盖从物体级别到室内和室外环境。通过跨场景直接评估位姿精度，并将预测的位姿和深度融合成 3D 点云进行精度评估，该基准忠实地衡量了视觉几何估计器的位姿和深度精度。实验表明，我们的模型在 20 个设置中有 18 个达到了最先进水平的性能。此外，在标准的单目基准上，我们的模型优于 Depth Anything 2 [113]。

为了进一步展示 3D 视觉任务方面的基本能力，我们引入了一个具有挑战性的前馈新视角合成（FF-NVS）基准，包含超过 160 个场景。我们遵循极简建模策略，用额外的 DPT 头微调我们的模型，以预测像素对齐的 3D 高斯参数。大量实验产生了两个关键发现：1) 将几何基础模型微调用于 NVS，显著优于高度专门化的任务特定模型 [108]；2) 增强的几何重建能力与改进的 FF-NVS 性能直接相关，确立了。

2 相关工作

多视角视觉几何估计。 传统系统 [70, 71] 将重建分解为特征检测与匹配、鲁棒相对位姿估计、带光束法平差的增量式或全局式 SfM，以及用于逐视图深度和融合点云的密集多视图立体视觉。这些方法在纹理良好的场景中仍然表现强劲，但其模块化和脆弱的对应关系在低纹理、高光或大视角变化条件下难以保证鲁棒性。早期的学习方法在组件层面注入了鲁棒性：学习型检测器 [20]、用于匹配的描述子 [22]，以及可微优化层，将位姿/深度更新暴露给梯度流 [31, 33, 62]。在密集重建方面，用于 MVs 的代价体网络 [106, 114] 用 3D CNN 取代了手工设计的正则化方法，与经典的 PatchMatch 相比，在大基线和薄结构上提高了深度精度。早期的端到端方法 [86, 90] 超越了模块化的 SfM/MVs 流水线，直接从图像对回归相机位姿和每幅图像的深度。这些方法降低了工程复杂度，并证明了学习型联合深度位姿估计的可行性，但它们往往在可扩展性、泛化性和处理任意输入基数方面存在困难。

一个转折点出现在 DUST3R [96]，它利用 Transformer 直接在两个视图之间预测点图，并以纯前馈方式计算深度和相对位姿。这项工作作为后续旨在大规模统一多视图几何估计的基于 Transformer 的方法奠定了基础。后续模型将这一范式扩展到多视图输入 [10, 85, 94, 110]、视频输入 [19, 59, 94, 121]、鲁棒对应关系建模 [48]、相机参数注入 [39, 43]、大规模 SfM [18]、SLAM 应用 [54]，以及使用 3D 高斯的视图合成 [11, 13, 41, 79, 108, 122]。其中，[91] 通过大规模训练、多阶段架构和冗余设计将精度提升到了新水平。相比之下，我们专注于围绕单一、简单的 Transformer 构建的极简建模策略。

单目深度估计。 早期的单目深度估计方法依赖于在单领域数据集上的全监督学习，这通常产生专门针对室内房间 [75] 或室外驾驶场景 [26] 的模型。这些早期的深度模型在训练领域内取得了良好的精度，但难以泛化到新环境，凸显了跨域深度预测的挑战。现代的通用方法 [6, 42, 95, 112, 113, 118] 通过利用大规模多数据集训练和先进的架构（如视觉 Transformer [67] 或 DiT [64]）体现了这一趋势。在数百万张图像上训练后，它们学习了广泛的视觉线索，并结合了仿射不变深度归一化等技术。相比之下，我们的方法主要设计用于统一的视觉几何估计任务，但仍然展示了具有竞争力的单目深度性能。




Figure 2 Pipeline of Depth Anything 3. Depth Anything 3 employs a single transformer (vanilla DINOv2 model) without any architectural modifications. To enable cross-view reasoning, an input-adaptive cross-view self-attention mechanism is introduced. A dual-DPT head is used to predict depth and ray maps from visual tokens. Camera parameters, if available, are encoded as camera tokens and concatenated with patch tokens, participating in all attention operations.

前馈新视角合成 新视角合成 (NVS) 长期以来一直是计算机视觉和图形学的核心问题 [8, 34, 49], 并且随着神经渲染的兴起而受到更多关注 [28, 44, 57, 77, 78]。一个特别有前景的方向是前馈 NVS, 它通过图像到 3D 的网络单次前向传播生成 3D 表示, 避免了繁琐的逐场景优化。早期方法采用 NeRF 作为底层 3D 表示 [12, 14, 35, 52, 107, 119], 但近期工作已大幅转向 3DGS, 因其显式的结构和实时渲染能力。代表性方法通过几何先验改进图像到 3D 网络, 例如, 极线注意力 [11]、代价体 [13] 和深度先验 [107]。最近, 多视图几何基础模型 [85, 91, 96, 110] 被集成进来以提高建模能力, 特别是在无位姿设定下, 然而基于此类模型构建的方法通常依赖单一选定的基础模型进行评估 [41, 79, 116]。在此, 我们系统地评估了不同几何基础模型对 NVS 的贡献, 并提出了更好地利用它们的策略, 使前馈 3DGS 能够处理有位姿和无位姿输入、可变数量的视图以及任意分辨率。

3 Depth Anything 3

我们致力于从多样的视觉输入——单张图像、多视图集合或视频——中恢复一致的 3D 几何结构, 并在已知相机位姿可用时可选地融入这些信息。

3.1 问题形式化

我们将输入记为 $\mathcal{I} = \{\mathbf{I}_i\}_{i=1}^{N_v}$, 其中每个 $\mathbf{I}_i \in \mathbb{R}^{H \times W \times 3}$ 。当 $N_v = 1$ 时为单目图像, 当 $N_v > 1$ 时则代表视频或多视图集合。每幅图像对应深度 $\mathbf{D}_i \in \mathbb{R}^{H \times W}$ 、相机外参 $[\mathbf{R}_i | \mathbf{t}_i]$ 和内参 $\mathbf{K}_i$ 。相机也可表示为 $\mathbf{v}_i \in \mathbb{R}^9$, 包含平移 $\mathbf{t}_i \in \mathbb{R}^3$ 、旋转四元数 $\mathbf{q}_i \in \mathbb{R}^4$ 和视场角参数 $\mathbf{f}_i \in \mathbb{R}^2$ 。像素 $\mathbf{p} = (u, v, 1)^\top$ 投影到 3D 点 $\mathbf{P} = (X, Y, Z, 1)^\top$ 的过程为:

$$\mathbf{P} = \mathbf{R}_i(\mathbf{D}_i(u, v) \mathbf{K}_i^{-1} \mathbf{p}) + \mathbf{t}_i,$$

通过该投影, 底层的 3D 视觉空间可以被忠实地恢复。

深度-射线表示。 预测有效的旋转矩阵 $\mathbf{R}_i$ 因正交约束而具有挑战性。为规避这一问题, 我们使用逐像素的射线图隐式表示相机位姿, 该射线图与输入图像和深度图对齐。对于每个像素 $\mathbf{p}$, 相机射线 $\mathbf{r} \in \mathbb{R}^6$ 由其原点 $\mathbf{t} \in \mathbb{R}^3$ 和方向 $\mathbf{d} \in \mathbb{R}^3$ 定义: $\mathbf{r} = (\mathbf{t}, \mathbf{d})$ 。方向通过将 $\mathbf{p}$ 反投影到相机坐标系并旋转至世界坐标系得到: $\mathbf{d} = \mathbf{R} \mathbf{K}^{-1} \mathbf{p}$ 。稠密射线图 $\mathbf{M} \in \mathbb{R}^{H \times W \times 6}$ 存储所有像素的这些参数。我们不对 $\mathbf{d}$ 进行归一化, 因此其幅度保留了投影尺度。由此, 世界坐标系中的 3D 点可简单地表示为: $\mathbf{P} = \mathbf{t} + \mathbf{D}(u, v) \cdot \mathbf{d}$ 。该形式化通过将预测的深度图和射线图进行逐元素操作, 能够生成一致的点云。

从射线图推导相机参数。 给定输入图像 $\mathbf{I} \in \mathbb{R}^{H \times W \times 3}$, 对应的射线图记为 $\mathbf{M} \in \mathbb{R}^{H \times W \times 6}$ 。该图包含逐像素的射线原点 (存储在前三个通道 $\mathbf{M}(:, :, 3)$) 和射线方向 (存储在后三个通道 $\mathbf{M}(:, :, 3:5)$)。

首先，相机中心 $\mathbf{t}_c$ 通过对逐像素射线原点向量取平均来估计：

$$\mathbf{t}_c = \frac{1}{H \times W} \sum_{h=1}^H \sum_{w=1}^W \mathbf{M}(h, w, : 3). \quad (1)$$

为了估计旋转 $\mathbf{R}$ 和内参 $\mathbf{K}$ ，我们将问题形式化为求解一个单应矩阵 $\mathbf{H}$ 。我们首先定义一个具有单位内参矩阵的“单位”相机， $\mathbf{K}_I = \mathbf{I}$ 。对于给定像素 $\mathbf{p}$ ，其在该标准相机坐标系中的对应射线方向即为 $\mathbf{d}_I = \mathbf{K}_I^{-1} \mathbf{p} = \mathbf{p}$ 。从该标准射线 $\mathbf{d}_I$ 到目标相机坐标系中射线方向 $\mathbf{d}_{\text{cam}}$ 的变换为 $\mathbf{d}_{\text{cam}} = \mathbf{K} \mathbf{R} \mathbf{d}_I$ 。这就在两组射线之间建立了一个直接的单应关系 $\mathbf{H} = \mathbf{K} \mathbf{R}$ 。然后，我们通过最小化变换后的标准射线与预计算的目标射线 $\mathbf{M}(h, w, 3 :)$ 之间的几何误差来求解该单应矩阵。这引出以下优化问题：

$$\mathbf{H}^* = \arg \min_{\|\mathbf{H}\|=1} \sum_{h=1}^H \sum_{w=1}^W \|\mathbf{H} \mathbf{p}_{h,w} \times \mathbf{M}(h, w, 3 :)\|. \quad (2)$$

这是一个标准的最小二乘问题，可以使用直接线性变换（DLT）算法 [2] 高效求解。一旦找到最优单应矩阵 $\mathbf{H}^*$ ，我们便可恢复相机参数。由于内参矩阵 $\mathbf{K}$ 是上三角矩阵而旋转矩阵 $\mathbf{R}$ 是正交矩阵，我们可以对 $\mathbf{H}^*$ 进行 RQ 分解来唯一地分解出 $\mathbf{K}$ 和 $\mathbf{R}$ 。

最小预测目标集。 近期工作致力于构建统一的 3D 任务模型，通常采用多任务学习并使用不同的预测目标——例如，单独的点图 [96]，或位姿、局部/全局点图和深度的冗余组合 [91, 94, 110]。点图不足以确保一致性，而冗余目标虽能提升位姿精度，但常引入耦合而损害位姿估计。相比之下，我们的实验（表 6）表明，深度-射线表示构成了同时捕捉场景结构和相机运动的最小且充分的目标集，其表现优于点图或更复杂输出等替代方案。然而，在推理时从射线图恢复相机位姿计算成本较高。为此，我们增加了一个轻量级的相机头 $\mathcal{D}_C$ 。该 Transformer 在相机令牌上操作，用于预测视场角 ($\mathbf{f} \in \mathbb{R}^2$)、旋转四元数 ($\mathbf{q} \in \mathbb{R}^4$) 和平移 ($\mathbf{t} \in \mathbb{R}^3$)。由于每视图仅处理一个令牌，增加的计算开销可忽略不计。


3.2 网络架构

下面我们详细介绍 Depth Anything 3 的网络架构，如 图 2 所示。该网络由三个主要组件构成：一个作为骨干网络的单一 Transformer 模型、一个用于位姿条件化的可选相机编码器，以及一个用于生成预测结果的双 DPT 预测头。

单一 Transformer 骨干网络。 我们使用具有 L 个块的视觉 Transformer，并在大规模单目图像语料库（如 DINOv2 [61]）上进行预训练。通过一种输入自适应的自注意力机制，对输入令牌进行重新排列，可以在不改变网络架构的情况下实现跨视角推理。我们将 Transformer 分为两组，大小分别为 L_s 和 L_g 。前 L_s 层在每幅图像内部应用自注意力，而后面的 L_g 层在跨视角和视角内注意力之间交替切换，通过张量重排序在所有令牌上联合操作。实际中，我们设置 $L_s : L_g = 2 : 1$ ，其中 $L = L_s + L_g$ 。如 表 7 中的消融研究所示，与其他配置相比，这一设置在性能和效率之间提供了最优权衡。该设计是输入自适应的：当输入为单张图像时，模型自然地退化为单目深度估计，无需额外开销。

相机条件注入。 为了无缝处理既有位姿和无位姿的输入，我们为每个视图预置一个相机令牌 $\mathbf{c}_i$ 。如果相机参数 ($\mathbf{K}_i, \mathbf{R}_i, \mathbf{t}_i$) 可用，则通过一个轻量级 MLP $\mathcal{E}_c$ 获得该令牌： $\mathbf{c}_i = \mathcal{E}_c(\mathbf{f}_i, \mathbf{q}_i, \mathbf{t}_i)$ 。否则，使用一个共享的可学习令牌 $\mathbf{c}_l$ 。这些相机令牌与图像块令牌拼接在一起，参与所有注意力操作，提供显式的几何上下文或一致的可学习占位信息。

双 DPT 预测头。 在最终预测阶段，我们提出了一种新颖的双 DPT 预测头，联合生成稠密的深度值和射线值。如 表 6 所示，该设计既强大又高效。给定来自骨干网络的一组特征，双 DPT 预测头首先通过一组共享的重组模块对它们进行处理。随后，处理后的特征通过两组不同的融合层进行融合：一组用于深度分支，一组用于射线分支。最后，两个独立的输出层生成最终的深度图和射线图预测。该架构确保两个分支在相同的处理特征集上操



作，仅在最后的融合阶段有所不同。这种设计促进了两个预测任务之间的强交互，同时避免了冗余的中间表示。

3.3 训练

教师-学生学习范式。我们的训练数据来自多种来源，包括真实世界的深度采集数据、3D 重建数据和合成数据集。真实世界的深度数据通常带有噪声且不完整（图 4），这限制了其监督价值。为解决这一问题，我们训练了一个仅使用合成数据的单目相对深度估计“教师”模型，用于生成高质量的伪标签。这些伪深度图通过 RANSAC 最小二乘法与原始的稀疏或带噪声的标注真值对齐，在保持几何精度的同时增强了标签的细节和完整性。我们将该模型称为 Depth-Anything-3-Teacher，它在涵盖室内、室外、以物体为中心以及多种野外场景的大规模合成语料库上训练，以捕获精细几何结构。我们在 章节 4.1 中详细介绍了教师模型的设计。

训练目标。遵循 章节 3.1 中的形式化，我们的模型 $\mathcal{F}_\theta$ 将输入 $\mathcal{I}$ 映射到一组输出，包括深度图 $\hat{\mathbf{D}}$ 、射线图 $\hat{\mathbf{R}}$ 以及可选的相机位姿 $\hat{\mathbf{c}}$: $\mathcal{F}_\theta: \mathcal{I} \mapsto \{\hat{\mathbf{D}}, \hat{\mathbf{R}}, \hat{\mathbf{c}}\}$ 。灰色表示 $\hat{\mathbf{c}}$ 是可选输出，主要出于实际便利而包含。在计算损失之前，所有标注真值信号均通过一个公共尺度因子进行归一化。该尺度定义为有效的重投影点图 $\mathbf{P}$ 的平均 ℓ_2 范数，这一步骤确保了不同模态之间的量级一致，并稳定了训练过程。总体训练目标定义为若干项的加权和：

$$\mathcal{L} = \mathcal{L}_D(\hat{\mathbf{D}}, \mathbf{D}) + \mathcal{L}_M(\hat{\mathbf{R}}, \mathbf{M}) + \mathcal{L}_P(\hat{\mathbf{D}} \odot \mathbf{d} + \mathbf{t}, \mathbf{P}) + \beta \mathcal{L}_C(\hat{\mathbf{c}}, \mathbf{v}) + \alpha \mathcal{L}_{\text{grad}}(\hat{\mathbf{D}}, \mathbf{D}),$$

$$\mathcal{L}_D(\hat{\mathbf{D}}, \mathbf{D}; D_c) = \frac{1}{Z_\Omega} \sum_{p \in \Omega} m_p \left(D_{c,p} |\hat{\mathbf{D}}_p - \mathbf{D}_p| - \lambda_c \log D_{c,p} \right),$$

其中 $D_{c,p}$ 表示深度 D_p 的置信度。所有损失项均基于 ℓ_1 范数，权重设置为 $\alpha = 1$ 和 $\beta = 1$ 。梯度损失 $\mathcal{L}_{\text{grad}}$ 对深度梯度进行惩罚：

$$\mathcal{L}_{\text{grad}}(\hat{\mathbf{D}}, \mathbf{D}) = \|\nabla_x \hat{\mathbf{D}} - \nabla_x \mathbf{D}\|_1 + \|\nabla_y \hat{\mathbf{D}} - \nabla_y \mathbf{D}\|_1, \quad (3)$$

其中 ∇_x 和 ∇_y 分别是水平和垂直方向的有限差分算子。该损失在保持锐利边缘的同时确保平坦区域的平滑性。实际中，我们设置 $\alpha = 1$ 和 $\beta = 1$ 。

3.4 实现细节

训练数据集。我们在表 1 中提供了训练数据集。需要注意的是，对于训练集和测试集之间可能存在重叠的数据集（如 ScanNet++），我们在场景级别确保严格的分离，即训练和测试中的场景互斥。使用 ScanNet++ 进行训练对其他方法是公平的，因为它在 [91, 96] 中被广泛用于训练。

训练细节。我们在 128 块 H100 GPU 上训练模型共 20 万步，使用 8 千步的预热阶段和峰值学习率 2×10^{-4} 。基础分辨率为 504×504 ，该数值能被 2、3、4、6、9 和 14 整除，使其与常见的照片宽高比（如 2:3、3:4 和 9:16）更加兼容。训练图像分辨率从以下值中随机采样： 504×504 、 504×378 、 504×336 、 504×280 、 336×504 、 896×504 、 756×504 、 672×504 。对于 504×504 分辨率，视图数量从 [2, 18] 中均匀采样。批量大小动态调整，以保持每步的令牌数量大致恒定。在 12 万步时，监督信号从标注真值深度切换为教师模型标签。位姿条件化在训练期间以 0.2 的概率随机激活。

4 教师-学生学习

如图 4 所示，真实世界数据集的质量较差，因此我们仅在合成数据上训练教师模型，为真实世界数据提供监督。我们的教师模型作为单目相对深度预测器进行训练。在推理或提供监督时，带噪声的标注真值深度可用于提供尺度和偏移参数，从而将预测的相对深度与绝对深度测量值对齐。




Table 1 Depth Anything 3 使用的数据集，包括场景数量和数据类型。

Usage	Dataset	#Scenes	Data Type
Pose-geometry benchmark	HiRoom (ours)	29	Synthetic
	ETH3D [72]	11	LiDAR
	DTU [1]	22	LiDAR
	7Scenes [74]	7	LiDAR
	ScanNet++ [117]	20	LiDAR
Pose-geometry Training	AriaDigitalTwin [63]	237	Synthetic
	AriaSyntheticENV [63]	99950	Synthetic
	ArkitScenes [5]	4388	LiDAR
	BlendedMVS [115]	503	3D Recon
	Co3dv2 [68]	30616	Colmap
	DL3DV [53]	6379	Colmap
	HyperSim [69]	344	Synthetic
	MapFree [3]	921	Colmap
	MegaDepth [51]	268	Colmap
	MegaSynth [40]	6049	Synthetic
	MvsSynth [38]	121	Synthetic
	Objaverse [17]	505557	Synthetic
	Omniobject [102]	5885	Synthetic
	OmniWorld [128]	1039	Synthetic
	PointOdyssey [127]	44	Synthetic
	ReplicaVMAP [83]	17	Synthetic
	ScanNet++ [117]	230	LiDAR
	ScenenetRGBD [55]	16866	Synthetic
	TartanAir [98]	355	Synthetic
	Trellis [104]	557408	Synthetic
	vKitti2 [9]	50	Synthetic
	WildRGBD [103]	23050	LiDAR

4.1 构建教师模型

在 Depth Anything 2 [112] 的基础上，我们在包括数据和表示在内的多个关键方面进行了扩展。我们观察到，扩大训练语料库能显著提升深度估计性能，验证了数据规模化的益处。此外，虽然我们改进的深度表示在标准的 2D 评估指标上可能没有显著提升，但它能产生质量更优的 3D 点云，展现出更多的几何畸变和更真实的场景结构。需要注意的是，我们的教师网络骨干结构与上述 DA3 框架直接对齐，仅由 DINOv2 视觉 Transformer 和 DPT 解码器组成——没有引入专门的架构修改。我们在以下各节中详细阐述完整的设计和实现细节。

数据规模化。我们仅在合成数据上训练教师模型，以获得更精细的几何细节。DA2 中使用的合成数据集相对有限。在 DA3 中，我们大幅扩展了训练语料库，包括：Hypersim [69]、TartanAir [98]、IRS [93]、vKITTI2 [9]、BlendedMVS [115]、SPRING [56]、MVSSynth [38]、UnrealStereo4K [123]、GTA-SfM [92]、TauAgent [27]、KenBurns [60]、MatrixCity [50]、EDEN [47]、ReplicaGSO [82]、UrbanSyn [32]、PointOdyssey [127]、Structured3D [125]、Objaverse [17]、Trellis [104] 和 OmniObject [102]。这一集合涵盖了室内、室外、以物体为中心以及多种野外场景，提升了教师模型的泛化能力。

深度表示。与 DA2 预测尺度-偏移不变的视差不同，我们的教师模型输出的是尺度-偏移不变的深度。深度更有利于下游任务，如度量深度估计和多视图几何，这些任务直接在深度空间而非视差空间中进行操作。为解决深度相对于视差在近相机区域灵敏度较低的问题，我们预测指数深度而非线性深度，从而增强对小距离的

分辨能力。

训练目标。在几何监督方面，除了标准的深度-梯度损失外，我们还采用 [95] 中引入的全局-局部损失进行 ROE 对齐。为进一步优化局部几何结构，我们引入了距离加权的表面法向损失。对于每个中心像素，我们采样四个相邻点并计算未归一化的法向量 n_i 。然后按以下方式对这些法向量加权：

$$w_i = \sum_{j=0}^4 \|n_j\| - \|n_i\|, \quad (4)$$

该加权方式降低了远离中心的相邻点的贡献，使得平均法向量更接近真实的局部表面法向量：

$$n_m = \sum_{i=0}^4 w_i \frac{n_i}{\|n_i\|}, \quad (5)$$

最终的法向损失为：

$$\mathcal{L}_N = \mathcal{E}(\hat{n}_m, n_m) + \sum_{i=0}^4 \mathcal{E}(\hat{n}_i, n_i) \quad (6)$$

其中 $\mathcal{E}$ 表示法向量之间的角度误差。在天空区域以及仅含物体的数据集的背景区域中，标注真值是未定义的。为防止这些区域降低深度预测质量并便于下游使用，我们联合预测一个与深度输出对齐的天空掩码和一个物体掩码，使用 MSE 损失进行监督。总体训练目标为：

$$\mathcal{L}_T = \alpha \mathcal{L}_{\text{grad}} + \mathcal{L}_{\text{gl}} + \mathcal{L}_N + \mathcal{L}_{\text{sky}} + \mathcal{L}_{\text{obj}} \quad (7)$$

其中 $\alpha = 0.5$ 。这里， $\mathcal{L}_{\text{grad}}$ 、 $\mathcal{L}_{\text{gl}}$ 、 $\mathcal{L}_{\text{sky}}$ 和 $\mathcal{L}_{\text{obj}}$ 分别表示梯度损失、全局-局部损失、天空掩码损失和物体掩码损失。

4.2 教导 Depth Anything 3

真实世界数据集对于泛化相机位姿估计至关重要，但它们很少提供干净的深度数据；监督信号通常带有噪声或是稀疏的（图 4）。Depth Anything 3 Teacher 提供高质量的相对深度，我们通过鲁棒的 RANSAC 尺度-偏移过程将其与带噪声的度量深度（例如来自 COLMAP 或主动传感器的数据）对齐。设 $\tilde{\mathbf{D}}$ 为教师模型的相对深度， $\mathbf{D}$ 为可用的稀疏深度，并在区域 Ω 上有有效性掩码 m_p 。我们通过 RANSAC 最小二乘法估计尺度 s 和偏移 t ，内点阈值设置为残差中位数的平均绝对偏差：

$$(\hat{s}, \hat{t}) = \arg \min_{s>0, t} \sum_{p \in \Omega} m_p (s \tilde{\mathbf{D}}_p + t - \mathbf{D}_p)^2, \quad \mathbf{D}^{T \rightarrow M} = \hat{s} \tilde{\mathbf{D}} + \hat{t}. \quad (8)$$

对齐后的 $\mathbf{D}^{T \rightarrow M}$ 为 Depth Anything 3 提供了尺度一致且位姿-深度协调的监督，补充了我们的联合深度-射线训练目标，并提升了真实世界的泛化能力，如图 8 所示。

4.3 教导单目模型

我们还以教师-学生范式额外训练了一个单目深度模型。我们遵循 DA2 框架，在无标注图像上使用教师模型生成的伪标签来训练单目学生模型。与 DA2 的主要区别在于预测目标：我们的学生模型预测深度图，而 DA2 预测视差。我们进一步使用与教师模型相同的损失函数对学生模型进行监督，该损失应用于伪深度标签。该单目模型也预测相对深度。仅使用无标注数据并在教师模型的监督下训练，该模型在标准单目深度基准上取得了最先进的性能，如表 10 所示。

4.4 教导度量深度模型

接下来，我们展示教师模型可用于训练具有锐利边界的度量深度估计模型。遵循 Metric3Dv2 [37]，我们应用标准相机空间变换来解决由焦距变化引起的深度歧义。具体而言，我们使用比率 f^c/f 对标注真值深度进行重新缩放，其中 f^c 和 f 分别表示标准焦距和相机焦距。为确保锐利细节，我们使用教师模型的预测作为训练标签。我们将教师模型预测深度的尺度和偏移与标注真值的度量深度标签对齐，以进行监督。

训练数据集。 我们在 14 个数据集上训练度量深度模型，包括 Taskonomy [120]、DIML (Outdoor) [15]、DDAD [30]、Argoverse [101]、Lyft []、PandaSet [105]、Waymo [84]、ScanNet++ [117]、ARKitScenes [5]、Map-free [3]、DSEC [24]、Driving Stereo [109] 和 Cityscapes [16]。对于立体数据集，我们利用 FoundationStereo [100] 的预测作为训练标签。

实现细节。 训练过程大致遵循单目教师模型的训练方式。所有图像在基础分辨率 504 下训练，具有多种宽高比 (1:1、1:2、16:9、9:16、3:4、1:1.5、1.5:1、1:1.8)。我们使用 AdamW 优化器，编码器和解码器的学习率分别设置为 $5e-6$ 和 $5e-5$ 。我们应用随机旋转数据增强，训练图像以 5% 的概率旋转 90 度或 270 度。标准焦距 f^c 设置为 300。我们使用教师模型的对齐预测作为监督。以 20% 的概率，我们使用原始标注真值标签进行训练。批量大小为 64，训练 16 万次迭代。训练目标是深度损失 $\mathcal{L}_{depth}$ 、 $\mathcal{L}_{grad}$ 和天空掩码损失 $\mathcal{L}_{sky}$ 的加权和。

5 应用：前馈式 3D 高斯泼溅

5.1 位姿条件化的前馈式 3DGS

受人类空间智能的启发，我们相信一致的深度估计可以极大地促进下游 3D 视觉任务。我们选择前馈式新视角合成 (FF-NVS) 作为演示任务，因为它在神经 3D 表示 (即我们选择 3DGS) 的推动下日益受到关注，并且与众多应用场景相关。遵循最小化建模策略，我们通过微调一个添加的 DPT 头 (GS-DPT) 来推断逐像素对齐的 3D 高斯 [11, 13]，从而实现 FF-NVS。

GS-DPT 头。 给定通过我们的单一 Transformer 骨干网络 (章节 3.2) 提取的每个视图的视觉令牌，GS-DPT 预测相机空间中的 3D 高斯参数 $\{\sigma_i, \mathbf{q}_i, \mathbf{s}_i, \mathbf{c}_i\}_{i=1}^{H \times W}$ ，其中 σ_i 、 $\mathbf{q}_i \in \mathbb{H}$ 、 $\mathbf{s}_i \in \mathbb{R}^3$ 、 $\mathbf{c}_i \in \mathbb{R}^3$ 分别表示第 i 个 3D 高斯的透明度、旋转四元数、尺度和 RGB 颜色。其中， σ_i 由置信度头预测，其他参数由主 GS-DPT 头预测。估计的深度通过反投影到世界坐标以获得 3D 高斯的全局位置 $\mathbf{P}_i \in \mathbb{R}^3$ 。然后这些图元被光栅化，以从给定的相机位姿合成新视角。

训练目标。 NVS 模型通过两个训练目标进行微调，即新视角渲染的光度损失 (即 $\mathcal{L}_{MSE}$ 和 $\mathcal{L}_{LPIPS}$) 以及观测视角估计深度的尺度-偏移不变深度损失 $\mathcal{L}_D$ ，遵循教师-学生学习范式 (章节 3.3)。

5.2 位姿自适应的前馈式 3DGS

与上述旨在将 DA3 作为强前馈式 3DGS 骨干网络进行基准测试的位姿条件化版本不同，我们还提出了一个更适合野外评估的替代方案。该版本设计为使用与 DA3 完全相同的预训练权重无缝集成，从而能够在使用或不使用相机位姿的情况下，以及在多种分辨率和输入视图数量下进行新视角合成。

位姿自适应形式化。 我们不假设所有输入图像均为无标定状态 [41, 79, 116, 122]，而是采用一种位姿自适应设计，同时接受有位姿和无位姿的输入，形成一个在有位姿或无位姿条件下均可工作的灵活框架。实现这一目标需要两个设计选择：1) 所有 3DGS 参数均在局部相机空间中预测；2) 骨干网络必须能够无缝处理有标定和无标定的图像。我们的 DA3 骨干网络满足这两个要求 (章节 3.2)。具体而言，当位姿可用时，我们 (通过 [87]) 对预测的深度和相机空间 3DGS 进行缩放并反投影到世界空间以与其对齐。当位姿不可用时，我们直接使用预测的位姿进行反投影到世界空间。

为减少精确表面几何与渲染质量之间的权衡 [29]，我们在 GS-DPT 头中额外预测一个深度偏移。为增强野外鲁棒性，我们将每个 3D 高斯的颜色替换为球谐系数，以通过建模视角相关的表面来减少与几何的冲突。

增强的训练策略。 为避免不稳定的训练，我们从预训练权重初始化 DA3 骨干网络并在训练时冻结它，仅微调 GS-DPT 头。为提升野外性能，我们使用变化的图像分辨率和变化的上下文视图数量进行训练。具体而言，较高分辨率的输入配以较少的上下文视图，较低分辨率的输入配以更多的视图，这稳定了训练过程，同时支持多样化的评估场景。

5.3 实现细节

训练数据集。 对于 NVS 模型的训练，我们利用大规模 DL3DV 数据集 [53]，该数据集提供了多样的真实场景及其由 COLMAP 估计的相机位姿。我们使用 DL3DV 中的 10,015 个场景来训练前馈式 3DGS 模型。为确保公平评估，我们严格保持训练集和测试集之间的排他性：用于基准测试的 140 个 DL3DV 场景与训练集完全不相交，防止任何数据泄露。

6 视觉几何基准

我们进一步引入一个视觉几何基准来评估几何预测模型。它直接评估位姿精度、通过重建评估深度精度以及视觉渲染质量。

6.1 基准流程

位姿估计. 对于每个场景，我们选择所有可用的图像；如果总数超过限制，我们使用固定随机种子随机采样 100 张图像。选定的图像随后通过前馈模型处理，以生成一致的位姿和深度估计，然后计算位姿精度。

几何估计. 对于相同的图像集，我们使用预测的位姿和预测的深度进行重建。为了将重建的点云与真值对齐，我们使用 `evo` [87] 将预测位姿与真值位姿对齐，得到一个将重建映射到真值坐标系的变换。为了提高稳健性，我们采用基于 RANSAC 的对齐流程。具体来说，我们在随机采样的位姿子集上重复应用 `evo`，并通过统计内点位姿的数量来评估每个候选变换，其中内点定义为平移误差低于整体位姿偏差中位数的位姿。然后选择具有最大内点集的变换，并通过 TSDF 融合将对齐后的预测点云与预测深度图进行融合。最后，通过使用第 6.2 节描述的指标，将对齐后的重建与真值点云进行比较来评估重建质量。

视觉渲染. 对于每个测试场景，图像数量在所有基准数据集中通常为 300 到 400 张。我们每隔 8 张图像采样一张作为目标新视角进行评估。从剩余的视角中，我们使用每个数据集提供的 COLMAP 相机位姿，并应用最远点采样（同时考虑相机平移和旋转距离），选择 12 张图像作为输入上下文视角。对于 DL3DV，我们使用官方的 Benchmark 集进行测试。对于 Tanks and Temples，除 Courthouse 外，所有训练数据场景均被包含。对于 MegaDepth，我们选择编号从 5000 到 5018 的场景，因为这些场景最适合 NVS。

6.2 指标

位姿指标. 为了评估位姿估计，我们遵循 [89, 91] 中引入的评估协议，并使用 AUC 报告结果。该指标由两个分项推导得出：相对旋转精度 (RRA) 和相对平移精度 (RTA)。RRA 和 RTA 分别量化了两张图像之间旋转和平移的角偏差。将每个误差与一组阈值进行比较以获得精度值。AUC 则计算为精度-阈值曲线的积分，其中曲线由每个阈值下 RRA 和 RTA 中较小的一个决定。为了展示在不同容差水平下的性能，我们主要报告阈值 3 和 30 下的结果。

重建指标. 设 $\mathcal{G}$ 表示真值点集， $\mathcal{R}$ 表示待评估的重建点集。我们使用 $\text{dist}(\mathcal{R} \rightarrow \mathcal{G})$ 衡量精度，使用 $\text{dist}(\mathcal{G} \rightarrow \mathcal{R})$ 衡量完整度，遵循 [1]。然后，倒角距离 (CD) 定义为这两项的平均值。基于这些距离，我们定义重建 $\mathcal{R}$ 相对于距离阈值 d 的精确率和召回率。精确率由 $\frac{1}{|\mathcal{R}|} \sum [\text{dist}(\mathcal{R}_i \rightarrow \mathcal{G}) < d]$ 给出，召回率由 $\frac{1}{|\mathcal{G}|} \sum [\text{dist}(\mathcal{G}_i \rightarrow \mathcal{R}) < d]$ 给出，其中 $[\cdot]$ 表示艾弗森括号 [46]。为了联合捕捉这两个度量，我们报告 F1 分数，计算为 $F1 = \frac{2 \times \text{精确率} \times \text{召回率}}{\text{精确率} + \text{召回率}}$ 。

6.3 数据集

我们的基准建立在五个数据集上：HiRoom [129]、ETH3D [72]、DTU [1]、7Scenes [74] 和 ScanNet++ [117]。它们共同涵盖了从以物体为中心的采集到复杂室内外环境的多样化场景，并在先前的研究中被广泛采用。下面，我们提供关于数据集准备过程的更多细节。

HiRoom 是一个使用 Blender 渲染的合成数据集，包含由专业艺术家创建的 30 个室内生活场景。我们在 F1 重建指标计算中使用阈值 d 为 0.05m。对于 TSDF 融合，我们将体素大小参数设置为 0.007m。

ETH3D 提供高分辨率室内外图像，以及来自激光传感器的真值深度。我们通过 TSDF 融合聚合真值深度图以获取真值 3D 形状。我们选择了 11 个场景：courtyard、electro、kicker、pipes、relief、delivery area、facade、office、playground、relief 2、terrains 用于基准测试。所有帧均用于评估。我们在 F1 重建指标计算中使用阈值 d 为 0.25。对于 TSDF 融合，我们将体素大小参数设置为 0.039m。

DTU 是一个室内数据集，包含 124 个不同的物体，每个场景从 49 个视角记录。它提供了在良好受控条件下收集的真值点云。我们按照 [114] 的方法，在 DTU 数据集的 22 个评估扫描上评估模型。我们采用 RGB 2.0 [126] 去除无意义的背景像素，并使用 [124] 中提出的默认深度融合策略。所有帧均用于评估。

7Scenes 是一个具有挑战性的真实世界数据集，包含低分辨率图像，具有严重的运动模糊，用于室内场景。我们遵循 [130] 的实现，使用 TSDF 融合融合 RGBD 图像并准备真值 3D 形状。我们将每个场景的帧数按 11

倍下采样以方便评估。我们在 F1 重建指标计算中使用阈值 d 为 0.05m。对于 TSDF 融合，我们将体素大小参数设置为 0.007m。

ScanNet++ 是一个大规模的室内数据集，提供高分辨率图像、来自 iPhone LiDAR 的深度图以及从激光扫描重建中采样的高分辨率深度图。我们选择了 20 个场景用于基准测试。由于来自 iPhone LiDAR 的深度图缺乏无效真值指示符，我们默认使用从激光扫描重建中采样的深度图作为真值深度。我们通过 TSDF 融合聚合真值深度图以获取真值 3D 形状。我们将每个场景的帧数按 5 倍下采样以方便评估。我们在 F1 重建指标计算中使用阈值 d 为 0.05m。对于 TSDF 融合，我们将体素大小参数设置为 0.02m。

视觉渲染质量. 我们在多样化的大规模场景上评估视觉渲染质量。我们引入了一个新的 NVS 基准, 由三个数据集构建, 包括 140 个场景的 DL3DV [53]、6 个场景的 Tanks and Temples [45] 和 19 个场景的 MegaDepth [51], 每个场景约 300 个采样帧。直接使用通过 COLMAP 估计的真值相机位姿, 以确保在不同模型间进行准确和公平的比较。我们报告在给定相机位姿下渲染的新视角上的 PSNR、SSIM 和 LPIPS 指标。

Table 2 与 SOTA 方法在位姿精度上的对比。报告 Auc3 $\uparrow$ 和 Auc30 $\uparrow$ 指标。前三名结果高亮为 第一、第二和 第三。

Methods	Params	HiRoom		ETH3D		DTU		7Scenes		ScanNet++	
		Auc3	Auc30	Auc3	Auc30	Auc3	Auc30	Auc3	Auc30	Auc3	Auc30
DUST3R	0.57B	17.6	54.3	4.30	27.3	4.00	74.3	6.90	61.6	8.10	33.9
Fast3R	0.65B	25.9	77.0	8.10	44.4	9.50	79.1	19.0	78.6	17.9	72.5
MapAnything	0.56B	17.9	82.8	19.2	77.4	6.50	72.7	12.6	79.7	20.2	84.1
Pi3	0.96B	67.0	94.8	35.2	87.3	62.5	94.9	25.5	86.3	50.7	92.1
VGGT	1.19B	49.1	88.0	26.3	80.8	79.2	99.8	23.9	85.0	62.6	95.1
DA3-Giant	1.10B	80.3	95.9	48.4	91.2	94.1	99.4	28.5	86.8	85.0	98.1
DA3-Large	0.36B	58.7	94.2	32.2	86.9	70.2	96.7	29.2	86.6	60.2	94.7
DA3-Base	0.11B	19.0	83.2	15.1	74.6	60.1	95.9	20.1	82.9	25.1	83.4
DA3-Small	0.03B	9.49	75.2	8.59	62.1	30.6	91.2	14.0	78.7	10.9	71.9




Figure 5 Comparisons of pose estimation quality. Camera trajectories for two videos are shown. Ground-truth trajectories are derived using COLMAP on images with dynamic objects masked.

7 实验

7.1 与现有最优方法的比较

基线方法. VGGT [91] 是一个端到端 Transformer，能够从单个或多个视角联合预测相机参数、深度和 3D 点。Pi3 [99] 进一步采用置换等变设计，从无序图像中恢复仿射不变相机和尺度不变点图。MapAnything [43] 提供了一个前馈框架，也可以将相机位姿作为输入来进行密集几何预测。Fast3R [111] 将点图回归扩展到单次前向传播中处理数百甚至数千张图像。最后，DUST3R [97] 通过回归点图并进行全局对齐来处理无标定图像对。我们的方法与 VGGT [91] 类似，但采用了新的架构和不同的相机表示，并且与 Pi3 [99] 是正交的。

位姿估计. 如表 2 和图 5 所示，与五种基线方法 [43, 91, 96, 99, 110] 相比，我们的 DA3-Giant 模型在几乎所有指标上都取得了最佳性能，唯一的例外是 DTU 数据集上的 Auc30。值得注意的是，在 Auc3 指标上，我们的模型相较于所有竞争方法至少实现了 8% 的相对改进，在 ScanNet++ 上相较于第二优模型实现了 33% 的相对提升。

几何估计. 如表 3 所示，我们的 DA3-Gaint 在几乎所有场景中建立了新的最优水平，在所有五个无位姿设定下均优于所有竞争对手。平均而言，DA3-Gaint 相较于 VGGT 实现了 25.1% 的相对改进，相较于 Pi3 实现了 21.5% 的相对改进。图 7 和图 6 可视化了我们预测的深度和恢复的点云。结果不仅干净、准确、完整，而且保留了精细的几何细节，明显优于其他方法。更值得注意的是，我们更小的 DA3-Large (0.30B 参数) 展现出显著的效率。尽管规模小 3 $\times$ ，它在十个设定中的五个超越了之前的最优方法 VGGT (1.19B 参数)，

Table 3 与 SOTA 方法在重建精度上的对比。除 DTU 外所有数据集报告 F-Score (F1 ↑)。DTU 报告倒角距离 (CD ↓, 单位: mm)。w/o p. 和 w/ p. 分别表示不提供和提供真值相机位姿用于重建。前三名结果高亮为 第一、第二和 第三。

Methods	Params	HiRoom		ETH3D		DTU		7Scenes		ScanNet++	
		w/o p.	w/ p.	w/o p.	w/ p.	w/o p.	w/ p.	w/o p.	w/ p.	w/o p.	w/ p.
DUST3R	0.57B	30.1	39.5	19.7	18.8	7.60	7.97	26.6	39.8	18.9	27.3
Fast3R	0.65B	40.7	48.2	38.5	50.3	6.88	8.20	41.0	49.8	37.1	53.7
MapAnything	0.56B	32.4	69.2	54.8	71.9	7.91	3.97	44.8	55.2	39.4	71.3
Pi3	0.96B	75.8	85.0	72.7	80.6	3.28	1.72	44.2	57.5	63.1	73.3
VGGT	1.19B	56.7	70.2	57.2	66.7	2.05	1.44	47.9	51.4	66.4	70.7
DA3-Giant	1.10B	85.1	95.6	79.0	87.1	1.85	1.85	53.5	56.5	77.0	79.3
DA3-Large	0.36B	69.5	87.1	65.8	75.2	2.08	1.23	56.3	49.2	67.9	75.7
DA3-Base	0.11B	25.9	71.4	49.5	66.7	2.87	2.36	49.9	50.6	47.2	67.8
DA3-Small	0.03B	18.3	52.2	41.6	63.4	5.83	2.49	41.0	46.8	32.3	53.8




Figure 6 Comparisons of point cloud quality. Our model produces point clouds that are more geometrically regular and substantially less noisy than those generated by other methods.

在 ETH3D 上表现尤为出色。

当相机位姿可用时，我们的方法和 MapAnything 都可以利用它们来改进结果，其他方法也能从真值位姿融合中受益。除 7Scenes 外，我们的模型在大多数数据集上展现出明显的增益——在 7Scenes 上，有限的视频设定已经使性能饱和，降低了位姿条件的益处。值得注意的是，在位姿条件下，模型规模扩展带来的性能提升小于无位姿模型，**这表明位姿估计比深度估计具有更强的规模扩展性，需要更大的模型才能充分实现改进。**

单目深度精度也反映了几何质量。如 表 4 所示，在 [113] 报告的标准单目深度基准上，我们的模型优于 VGGT 和 Depth Anything 2。作为参考，我们还列出了教师模型的结果。

视觉渲染。 为了公平评估前馈新视角合成 (FF-NVS)，我们比较了三个最新的 3DGS 模型——pixelSplat [11]、MVSplat [13] 和 DepthSplat [108]——并进一步通过将我们的几何骨干网络替换为 Fast3R [111]、MV-DUST3R [85] 和 VGGT [91] 来测试替代框架。所有模型在统一的协议下使用 DL3DV-10K 训练集进行训练，并在我们的基准 (章节 6.3) 上进行评估。

如 表 5 所报告，所有模型在 DL3DV 上的表现显著优于其他数据集，这表明基于 3DGS 的 NVS 对 DL3DV 标准化的轨迹和位姿分布敏感，而非场景内容。比较两组模型，基于几何模型的框架始终优于专门的前馈模型，这表明简单的骨干网络加 DPT 预测头可以超越复杂的任务特定设计。这一优势源于大规模预训练，它

Table 4 单目深度比较. $\delta_1 \uparrow$

Method	KITTI	NYU	SINTEL	ETH3D	DIODE	Rank
DA2	94.6	97.9	77.2	86.5	95.2	2.60
VGGT	91.7	97.9	67.9	97.5	95.3	3.75
DA3	95.3	97.4	75.5	98.6	95.4	2.20
Teacher	97.2	97.9	81.4	99.8	96.6	1.00




Figure 7 Comparisons of depth quality. Compared with other methods, our depth maps exhibit finer structural detail and higher semantic correctness across diverse scenes.

比依赖极线 Transformer、代价体或级联模块的方法具有更好的泛化性和可扩展性。在这一组中，NVS 性能与几何估计能力相关，使 DA3 成为最强的骨干网络。展望未来，我们期望 FF-NVS 可以通过利用预训练几何骨干网络的简单架构得到有效解决，并且 DA3 强大的空间理解能力将使其他 3D 视觉任务受益。

7.2 Depth Anything 3 分析

训练我们的 DA3-Giant 模型需要 $128 \times H100$ GPU 约 10 天。为了减少碳足迹和计算成本，本节报告的所有消融实验均使用 ViT-L 骨干网络，最多 10 个视角，在 $32 \times H100$ GPU 上约需 4 天。

7.2.1 深度-射线表示的充分性

为了验证我们的深度-射线表示，我们比较了表 6 中总结的不同预测组合。所有模型均使用 ViT-L 骨干网络，相同的训练设置（视角数：10，批大小：128，步数：120k）。我们评估了四种预测头：1) **depth** 用于密集深度图；2) **pcd** 用于直接 3D 点云；3) **cam** 用于 9 自由度相机位姿 $\mathbf{c} = (\mathbf{t}, \mathbf{q}, \mathbf{f})$ ；以及 4) 我们提出的 **ray**，预测逐像素射线图（章节 3.1）。**ray** 预测头使用 Dual-DPT 架构，而 **pcd** 使用单独的 DPT 预测头。对于没有 **pcd** 的模型，点云通过将 **depth** 与来自 **ray** 或 **cam** 的相机参数结合得到。如表 6 所示，最小的 **depth + ray** 配置在所有数据集和指标上始终优于 **depth + pcd + cam** 和 **depth + cam**，在 AUC3 上相对于 **depth + cam** 实现了近 100% 的相对增益。添加辅助 **cam** 预测头（**depth + ray + cam**）没有带来进一步的好处，证实了深度-射线表示的充分性。我们采用 **depth + ray + cam** 作为最终表示，因为相机预测头的计算开销可以忽略不计，大约占主骨干网络计算成本的 0.1%。

7.2.2 单个普通 Transformer 的充分性

我们将标准 ViT-L 骨干网络与 VGGT 风格的架构进行比较，后者堆叠了两个不同的 Transformer，块数是三倍。为了公平比较容量，VGGT 风格的模型使用较小的 ViT-B 骨干网络，其参数量与我们的 ViT-L 相当。我们的骨干网络支持两种注意力策略：**Full Alt.**，在所有层中交替使用跨视角/视角内注意力（ $L = L_g$ ），以及我们的默认部分交替策略。如表 7 所示，VGGT 风格的模型性能下降到我们基线方法的 79.8%，证实了在相似规模下单 Transformer 设计的优越性。我们将这一差距归因于我们骨干网络的完全预训练与 VGGT 中有三分之二的块未经过训练。此外，**Full Alt.** 变体在几乎所有指标上都有所下降——除了 7Scenes 上的 F1——表明部分交替是更有效且更稳健的策略。

Table 5 与 SOTA 方法在 NVS 任务上的对比。报告与前馈 3DGS 模型及使用其他骨干网络的对应方法的 NVS 比较。每个场景使用 12 张输入上下文视图，并在超过 300 张视图中每隔 8 张采样的目标视图上测试。图像分辨率为 270×480 。

Methods	In-domain Dataset			Out-of-domain Datasets					
	DL3DV-Benchmarks (140)			Tanks and Temples (6)			MegaDepth (19)		
	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
pixelSplat	16.55	0.456	0.480	13.81	0.347	0.558	13.87	0.367	0.561
MVSplat	18.13	0.559	0.393	14.81	0.391	0.508	14.67	0.398	0.533
DepthSplat	19.24	0.620	0.322	15.80	0.474	0.418	15.90	0.471	0.450
Fast3R	19.30	0.604	0.320	16.24	0.478	0.409	16.43	0.493	0.421
MV-DUST3R	20.01	0.645	0.294	17.04	0.529	0.370	16.20	0.484	0.437
VGGT	20.96	0.697	0.253	17.18	0.550	0.347	16.45	0.500	0.417
DAv3 (Ours)	21.33	0.711	0.241	18.10	0.578	0.311	17.89	0.561	0.351

Table 6 预测目标组合的消融实验。注意本表中所有实验均不含相机条件令牌。**最优**和**次优**结果已突出显示。

Methods	HiRoom		ETH3D		DTU		7Scenes		ScanNet++	
	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	CD $\downarrow$	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	F1 $\uparrow$
depth + pcd + cam	9.1	12.8	19.0	<u>60.4</u>	42.3	4.918	20.8	43.4	22.0	43.0
depth + cam	10.8	16.5	9.9	48.0	23.3	5.316	13.0	38.5	13.3	41.0
depth + ray	48.7	60.3	25.5	65.4	<u>46.5</u>	<u>3.919</u>	<u>24.0</u>	46.5	35.5	<u>53.4</u>
depth + ray + cam	<u>37.2</u>	<u>45.4</u>	<u>22.3</u>	59.4	56.3	3.066	25.7	<u>45.6</u>	<u>34.1</u>	56.5

7.2.3 消融与分析

双 DPT 预测头。我们通过消融实验评估了双 DPT 预测头的有效性，其中两个独立的 DPT 预测头分别预测深度图和射线图。结果报告在表 7 的 (d) 项中。与配备双 DPT 预测头的模型相比，无此设计的变体在各个指标上均出现一致下降，证实了我们双 DPT 设计的有效性。

教师模型监督。我们消融了使用教师模型标签作为监督的做法，定量结果报告在表 7 的 (e) 项中。没有教师标签的训练在 DTU 上略有改进，但在 7Scenes 和 ScanNet++ 上导致性能下降。值得注意的是，在 HiRoom 上退化尤为明显。我们将其归因于 HiRoom 的合成性质及其真值包含大量精细结构；来自教师的监督帮助学生更准确地捕捉这些细节。图 8 中的定性比较证实了这一趋势：使用教师标签监督训练的模型产生的深度图具有更丰富的细节和更精细的结构。

Table 7 消融实验。评估三种具有可比模型规模的架构设计 (a-c)，双 DPT 头 (d)、教师标签监督 (e) 和位姿条件模块 (f-g) 的效果。**最优**和**次优**结果已突出显示。标记“*”的方法使用真值位姿融合进行评估。

Methods	HiRoom		ETH3D		DTU		7Scenes		ScanNet++	
	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	CD $\downarrow$	Auc3 $\uparrow$	F1 $\uparrow$	Auc3 $\uparrow$	F1 $\uparrow$
a. Proposed Arch.	39.2	47.0	21.0	55.4	45.8	3.82	26.2	<u>47.6</u>	30.3	51.1
b. VGGT Style	3.72	14.5	2.31	27.4	1.38	6.93	0.97	21.4	2.03	12.2
c. Full Alt.	<u>24.7</u>	<u>29.3</u>	<u>13.1</u>	<u>51.9</u>	<u>44.6</u>	<u>4.23</u>	<u>21.1</u>	48.6	<u>27.7</u>	<u>47.5</u>
d. w/o Dual DPT	5.59	11.5	13.6	33.4	21.7	5.14	14.2	49.4	26.5	46.6
e. w/o Teacher	11.2	16.0	16.2	57.6	52.5	3.29	23.3	40.3	26.2	47.7
f. w/o Pose Cond.*		65.8		63.2		3.65		58.4		62.8
g. w/ Pose Cond.*		73.8		70.9		2.14		46.0		65.7

Table 8 模型参数与运行速度对比。最大图像数量在 80 GB A100 GPU 上测试。若将部分中间令牌存储于 CPU 内存，则可处理更多图像。运行速度在 A100 GPU 上以 32 张图像的场景测量，报告每张图像的平均速度。图像分辨率为 504×336 。

Model	Max # of Images	Parameters			Running Speed
		Backbone	DualDPT	CameraHead	
VGGT(Reference)	400-500	0.91B	0.064B	0.22B	34.1 FPS
DA3-Giant	900-1000	1.130B	0.050B	0.018B	37.6 FPS
DA3-Large	1500-1600	0.300B	0.047B	0.008B	78.37 FPS
DA3-Base	2100-2200	0.086B	0.015B	0.004B	126.5 FPS
DA3-Small	4000-4100	0.022B	0.003B	0.001B	160.5 FPS

位姿条件。 为了评估位姿条件模块，我们在 ViT-L 骨干网络上对其进行消融，结果报告在 表 7 的 (f) 和 (g) 项中。与表中其他条目不同，这两项是在真值位姿融合下评估的（标有”*”），而其余条目使用预测位姿融合。在各个指标上，带位姿条件的配置始终优于不带位姿条件的配置，证实了位姿条件模块的有效性。

运行时间。 我们在 表 8 中给出了关于参数量、最大图像数量和运行速度的分析。



Figure 8 Comparison of teacher-label supervision. Supervision with teacher-generated labels yields depth maps with substantially richer detail and finer structures.

更多可视化。 我们在 图 9 中提供了野外场景中相机位姿和深度估计的更多可视化，展示了我们的模型在多样化真实场景中的稳健性和质量。

7.3 Depth Anything 3 单目模型分析

7.3.1 教师模型

教师模型的指标报告在 表 4 中。我们的新教师模型在所有数据集上始终优于 DA2，唯一的例外是 NYU，其性能与 DA2 持平。对于教师消融实验，我们使用 ViT-L 骨干网络和批大小 64。评估遵循 DA2 基准协议，我们还额外报告了平方相对误差 (SqRel)，定义为预测值与真值之间的均方误差除以真值。如 表 9 所示，在各种几何目标中，深度相对于视差和点图成为最有效的目标。在训练目标方面，本文提出的完整教师损失优于 DA2 损失和没有所提出的法向损失项的变体。最后，数据规模扩展对性能有显著贡献：从 V2 到 V3 的数据集升级以及采用多分辨率训练策略，使教师模型的最终指标得到一致改进。

Table 9 教师模型的消融实验。使用 V3 数据集和多分辨率策略训练取得最佳性能。基于深度的几何取得最佳 AbsRel 和 SqRel。完整的教师损失优于其他变体。(AbsRel: ↓, SqRel: ↓, δ_1 : ↑). The results are averaged over KITTI, NYU, ETH3D, SUN-RGBD and DIODE.

Data				Geometry				Loss			
Data	δ_1	AbsRel	SqRel	Geometry	δ_1	AbsRel	SqRel	Loss	δ_1	AbsRel	SqRel
V2	0.919	0.087	0.596	Disparity	0.919	0.095	1.033	MAE-Loss	0.918	0.089	0.637
V3	<u>0.929</u>	<u>0.079</u>	<u>0.508</u>	Pointmap	0.912	0.096	<u>0.693</u>	w/o Dist. Nor.	0.918	0.087	<u>0.600</u>
V3 + mr.	0.938	0.072	0.452	Depth	<u>0.918</u>	0.089	0.637	Full loss	0.919	0.087	0.596




Figure 9 Visualizations of camera pose and depth estimation on in-the-wild scenes.

7.3.2 学生模型

如 表 10 所示，我们使用 ViT-L 骨干网络的单目学生模型在所有评估数据集上均优于 DA2 学生模型。值得注意的是，在 ETH3D [72] 基准上，新的单目学生模型相比 DA2 实现了超过 10% 的改进。性能提升归因于具有更好几何监督的增强教师模型以及扩展的训练数据 (V3)。在像 SINTEL 这样具有挑战性的数据集上，我们的学生模型也展示了显著的增益 (+5.1%)，验证了我们的教师-学生蒸馏框架的有效性。

Table 10 单目学生深度比较. δ_1 ↑

Method	KITTI	NYU	SINTEL	ETH3D	DIODE
DA2	94.6	97.9	77.2	86.5	95.2
mono-student	97.1	98.0	82.3	98.8	96.5

Table 11 与 SOTA 方法在度量深度估计上的对比。最优和次优 结果已突出显示。底部行显示有无教师监督的消融结果。注意消融设置与最终模型在训练分辨率上略有不同，导致性能有微小差异。

Methods	NYUv2		KITTI		ETH3D		SUN-RGBD		DIODE	
	$\delta_1 \uparrow$	AbsRel $\downarrow$	$\delta_1 \uparrow$	AbsRel $\downarrow$	$\delta_1 \uparrow$	AbsRel $\downarrow$	$\delta_1 \uparrow$	AbsRel $\downarrow$	$\delta_1 \uparrow$	AbsRel $\downarrow$
DepthPro [7]	0.932	0.093	0.843	0.121	0.386	0.349	0.950	0.126	0.734	0.173
Metric3D v2 [36]	<u>0.971</u>	0.067	<u>0.976</u>	0.051	0.830	<u>0.138</u>	0.954	0.132	0.018	0.154
UniDepthv1 [65]	0.980	0.061	0.978	0.051	0.234	0.464	<u>0.971</u>	0.113	0.570	0.266
UniDepthv2 [66]	0.968	<u>0.064</u>	0.968	0.076	<u>0.863</u>	0.152	0.977	<u>0.111</u>	0.856	0.123
DA3-metric	0.963	0.070	0.953	0.086	0.917	0.104	<u>0.973</u>	0.105	<u>0.838</u>	<u>0.128</u>
w/ teacher	0.966	0.073	0.947	0.086	0.906	0.105	0.973	0.104	0.824	0.132
w/o teacher	0.969	0.066	0.965	0.067	0.907	0.105	0.975	0.099	0.816	0.134

7.4 Depth Anything 3 度量深度模型分析

我们与最先进的度量深度估计方法(包括 DepthPro [7]、Metric3D v2 [37]、UniDepthv1 [65] 和 UniDepthv2 [66]) 在 5 个基准上进行比较: NYUv2 [76]、KITTI [25]、ETH3D [72]、SUN-RGBD [81] 和 DIODE (室内) [88]。

如 表 11 所示, DA3-metric 在 **ETH3D 上取得了最优性能** ($\delta_1 = 0.917$, AbsRel = 0.104), 大幅超过了第二优方法 UniDepthv2 ($\delta_1 = 0.863$)。DA3-metric 还在 **SUN-RGBD 上取得了最佳 AbsRel** (0.105), 并在 **DIODE 上取得了第二优** ($\delta_1 = 0.838$, AbsRel = 0.128)。虽然 UniDepthv1 和 UniDepthv2 在 NYUv2 和 KITTI 上取得了最佳结果, 但 DA3-metric 在所有基准上展示了强大的泛化能力和有竞争力的性能, 尤其是在像 ETH3D 这样多样化的室外场景中表现出色。

我们在 表 11 中对教师监督进行了消融。结果显示了有趣的权衡: 移除教师监督在 NYUv2 和 KITTI 上略微提升了指标, 而在其他数据集上保持可比的性能。如图 10 所示, 教师监督显著改善了清晰度和细节质量, 表明教师模型提供了超出标准指标之外的补充知识。




Figure 10 教师模型用于监督度量深度估计的有效性。引入教师模型进行监督显著提升了度量深度的清晰度。

7.5 前馈 3DGS 分析

我们重新训练了所有比较的前馈 3DGS 模型, 通过使用最远点采样选择 12 个输入上下文视角来确保训练配置与测试设置匹配。我们采用了工程优化, 如 flash attention 和完全共享的数据并行, 使所有模型能够高效处理 12 个输入视角。所有基线均加入深度训练损失以确保稳定训练和收敛。所有模型在 8 个 A100

GPU 上训练，步数 200K，批大小为 1，但 pixelSplat 由于极线注意力较慢而训练了 100K 步。所有结果均在 $H \times W = 270 \times 480$ 下报告。

视觉质量分析. 我们在图 11 中展示了在新视角合成设置下与其他模型的视觉比较。如图所示，仅通过在我们的 DA3 模型上添加一个 3D 高斯 DPT 预测头，就能在现有最优方法的基础上显著提升渲染质量。我们的模型在具有挑战性的区域展现出特别强的能力，例如细薄结构（如第一个和第三个场景中的柱子）以及具有宽基线输入视图的大规模室外环境（最后两个场景），如图 11 所示。这些结果强调了稳健的几何骨干网络对于高质量视觉渲染的重要性，这与我们在表 5 中的定量结果一致。我们预期 DA3 强大的几何理解能力也将使其他 3D 视觉任务受益。

8 结论与讨论

Depth Anything 3 表明，一个简单的 Transformer，在深度与射线目标的教师-学生监督下进行训练，无需复杂的架构即可统一任意视角的几何信息。尺度感知的深度、逐像素射线以及自适应跨视角注意力使模型能够继承强大的预训练特征，同时保持轻量且易于扩展。在所提出的视觉几何基准上，该方法创下了新的位姿估计与重建记录，其大型和紧凑变体均超越了先前的模型，同时同一骨干网络还支撑了高效的前馈式新视角合成模型。

我们将 Depth Anything 3 视为迈向通用 3D 基础模型的一步。未来的工作可以将其推理能力扩展到动态场景，整合语言与交互线索，并探索更大规模的预训练，以打通几何理解与可操作世界模型之间的闭环。我们希望本文提供的模型与数据集发布、基准测试以及简洁的建模原则能够推动通用 3D 感知的更广泛研究。

致谢

我们感谢周晓伟、彭思达和郭恒凯在本项目开发过程中提供的宝贵讨论。我们也感谢赵杨在工程上的支持。预告演示中的输入图像提取自一个公开的 YouTube 视频 [21]，鸣谢原作者。




Figure 11 Qualitative comparisons with state-of-the-art methods for visual rendering. The first column shows the selected input views, while the remaining columns display novel views rendered by comparison models and ground truth. For each scene, two rendered novel viewpoints are presented in consecutive rows. The first three scenes are from DL3DV, the following two are from Tanks and Temples, and the last three are from MegaDepth. Compared to other methods, our model consistently achieves superior rendering quality across diverse and challenging scenes.

参考文献

- [1] Henrik Aanaes, Rasmus Ramsbøl Jensen, George Vogiatzis, Engin Tola, and Anders Bjorholm Dahl. Large-scale data for multiple-view stereopsis. *Int. J. Comput. Vis.*, 120(2):153–168, 2016.
- [2] Yousset I Abdel-Aziz, Hauck Michael Karara, and Michael Hauck. Direct linear transformation from comparator coordinates into object space coordinates in close-range photogrammetry. *Photogrammetric engineering & remote sensing*, 81(2):103–107, 2015.
- [3] Eduardo Arnold, Jamie Wynn, Sara Vicente, Guillermo Garcia-Hernando, Aron Monszpart, Victor Prisacariu, Daniyar Turmukhambetov, and Eric Brachmann. Map-free visual relocalization: Metric pose relative to a single image. In *European Conference on Computer Vision*, pages 690–708. Springer, 2022.
- [4] Martha E Arterberry and Albert Yonas. Perception of three-dimensional shape specified by optic flow by 8-week-old infants. *Perception & Psychophysics*, 62(3):550–556, 2000.
- [5] Gilad Baruch, Zhuoyuan Chen, Afshin Dehghan, Tal Dimry, Yuri Feigin, Peter Fu, Thomas Gebauer, Brandon Joffe, Daniel Kurz, Arik Schwartz, et al. Arkitscenes: A diverse real-world dataset for 3d indoor scene understanding using mobile rgb-d data. *Adv. Neural Inform. Process. Syst.*, 2021.
- [6] Aleksei Bochkovskii, Amaël Delaunoy, Hugo Germain, Marcel Santos, Yichao Zhou, Stephan R Richter, and Vladlen Koltun. Depth pro: Sharp monocular metric depth in less than a second. *arXiv preprint arXiv:2410.02073*, 2024.
- [7] Alexey Bochkovskiy, Amaël Delaunoy, Hugo Germain, Marcel Santos, Yichao Zhou, Stephan Richter, and Vladlen Koltun. Depth pro: Sharp monocular metric depth in less than a second. In *Int. Conf. Learn. Represent.*, 2025.
- [8] Chris Buehler, Michael Bosse, Leonard McMillan, Steven Gortler, and Michael Cohen. Unstructured lumigraph rendering. In *Proceedings of the 28th annual conference on Computer graphics and interactive techniques*, pages 425–432, 2001.
- [9] Yann Cabon, Naila Murray, and Martin Humenberger. Virtual kitti 2, 2020.
- [10] Yann Cabon, Lucas Stof, Leonid Antsfeld, Gabriela Csurka, Boris Chidlovskii, Jerome Revaud, and Vincent Leroy. Must3r: Multi-view network for stereo 3d reconstruction. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1050–1060, 2025.
- [11] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi, and Vincent Sitzmann. pixelsplat: 3d gaussian splats from image pairs for scalable generalizable 3d reconstruction. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 19457–19467, 2024.
- [12] Anpei Chen, Zexiang Xu, Fuqiang Zhao, Xiaoshuai Zhang, Fanbo Xiang, Jingyi Yu, and Hao Su. Mvsnerf: Fast generalizable radiance field reconstruction from multi-view stereo. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 14124–14133, 2021.
- [13] Yuedong Chen, Haoqi Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham, and Jianfei Cai. Mvsplat: Efficient 3d gaussian splatting from sparse multi-view images. In *Eur. Conf. Comput. Vis.*, pages 370–386. Springer, 2024.
- [14] Yuedong Chen, Haoqi Xu, Qianyi Wu, Chuanxia Zheng, Tat-Jen Cham, and Jianfei Cai. Explicit correspondence matching for generalizable neural radiance fields. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2025.
- [15] Jaehoon Cho, Dongbo Min, Youngjung Kim, and Kwanghoon Sohn. Diml/cvl rgb-d dataset: 2m rgb-d images of natural indoor and outdoor scenes. *arXiv preprint arXiv:2110.11590*, 2021.
- [16] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3213–3223, 2016.
- [17] Matt Deitke, Dustin Schwenk, Jordi Salvador, Luca Weihs, Oscar Michel, Eli VanderBilt, Ludwig Schmidt, Kiana Ehsani, Aniruddha Kembhavi, and Ali Farhadi. Objaverse: A universe of annotated 3d objects. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 13142–13153, 2023.

- [18] Junyuan Deng, Heng Li, Tao Xie, Weiqiang Ren, Qian Zhang, Ping Tan, and Xiaoyang Guo. Sail-recon: Large sfm by augmenting scene regression with localization. *arXiv preprint arXiv:2508.17972*, 2025.
- [19] Kai Deng, Zexin Ti, Jiawei Xu, Jian Yang, and Jin Xie. Vggt-long: Chunk it, loop it, align it – pushing vggt’s limits on kilometer-scale long rgb sequences. *arXiv preprint arXiv:2507.11539*, 2025.
- [20] Daniel DeTone, Tomasz Malisiewicz, and Andrew Rabinovich. Superpoint: Self-supervised interest point detection and description. In *CVPR workshops*, pages 224–236, 2018.
- [21] MTS Drones. Drone australia gliding ep025: Sydney views | opera house, harbour bridge & hyde park | dji mavic 4k. <https://www.youtube.com/watch?v=qbgKDaGraTA>, 2024. Accessed: Sep. 25, 2025. Used under YouTube Standard License.
- [22] Mihai Dusmanu, Ignacio Rocco, Tomas Pajdla, Marc Pollefeys, Josef Sivic, Akihiko Torii, and Torsten Sattler. D2-net: A trainable cnn for joint description and detection of local features. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 8092–8101, 2019.
- [23] David Eigen, Christian Puhersch, and Rob Fergus. Depth map prediction from a single image using a multi-scale deep network. In *Adv. Neural Inform. Process. Syst.*, 2014.
- [24] Mathias Gehrig, Willem Aarents, Daniel Gehrig, and Davide Scaramuzza. Dsec: A stereo event camera dataset for driving scenarios. *IEEE Robotics and Automation Letters*, 6(3):4947–4954, 2021.
- [25] Andreas Geiger, Philip Lenz, Christoph Stiller, and Raquel Urtasun. Vision meets robotics: The kitti dataset. *The international journal of robotics research*, 32(11):1231–1237, 2013.
- [26] Andreas Geiger, Philip Lenz, Christoph Stiller, and Raquel Urtasun. Vision meets robotics: The kitti dataset. *The international journal of robotics research*, 32(11):1231–1237, 2013.
- [27] Yotam Gil, Shay Elmaleh, Harel Haim, Emanuel Marom, and Raja Giryes. Online training of stereo self-calibration using monocular depth estimation. *IEEE Transactions on Computational Imaging*, 7:812–823, 2021.
- [28] Shrisudhan Govindarajan, Daniel Rebain, Kwang Moo Yi, and Andrea Tagliasacchi. Radiant foam: Real-time differentiable ray tracing. In *Int. Conf. Comput. Vis.*, 2025.
- [29] Antoine Guédon and Vincent Lepetit. Sugar: Surface-aligned gaussian splatting for efficient 3d mesh reconstruction and high-quality mesh rendering. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5354–5363, 2024.
- [30] Vitor Guizilini, Rares Ambrus, Sudeep Pillai, Allan Raventos, and Adrien Gaidon. 3d packing for self-supervised monocular depth estimation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2020.
- [31] Haoyu Guo, He Zhu, Sida Peng, Haotong Lin, Yunzhi Yan, Tao Xie, Wenguan Wang, Xiaowei Zhou, and Hujun Bao. Multi-view reconstruction via sfm-guided monocular depth estimation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5272–5282, 2025.
- [32] Jose L. Gómez, Manuel Silva, Antonio Seoane, Agnès Borràs, Mario Noriega, German Ros, Jose A. Iglesias-Guitian, and Antonio M. López. All for one, and one for all: Urbansyn dataset, the third musketeer of synthetic driving scenes. *Neurocomputing*, 637:130038, 2025. ISSN 0925-2312. doi: <https://doi.org/10.1016/j.neucom.2025.130038>. URL <https://www.sciencedirect.com/science/article/pii/S0925231225007106>.
- [33] Xingyi He, Jiaming Sun, Yifan Wang, Sida Peng, Qixing Huang, Hujun Bao, and Xiaowei Zhou. Detector-free structure from motion. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 21594–21603, 2024.
- [34] Benno Heigl, Reinhard Koch, Marc Pollefeys, Joachim Denzler, and Luc Van Gool. Plenoptic modeling and rendering from image sequences taken by a hand-held camera. In *Mustererkennung 1999: 21. DAGM-Symposium Bonn, 15.–17. September 1999*, pages 94–101. Springer, 1999.
- [35] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui, and Hao Tan. Lrm: Large reconstruction model for single image to 3d. In *Int. Conf. Learn. Represent.*, 2024.
- [36] Mu Hu, Wei Yin, Chi Zhang, Zhipeng Cai, Xiaoxiao Long, Hao Chen, Kaixuan Wang, Gang Yu, Chunhua Shen, and Shaojie Shen. Metric3d v2: A versatile monocular geometric foundation model for zero-shot metric depth and surface normal estimation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.

- [37] Mu Hu, Wei Yin, Chi Zhang, Zhipeng Cai, Xiaoxiao Long, Hao Chen, Kaixuan Wang, Gang Yu, Chunhua Shen, and Shaojie Shen. Metric3d v2: A versatile monocular geometric foundation model for zero-shot metric depth and surface normal estimation. TPAMI, 2024.
- [38] Po-Han Huang, Kevin Matzen, Johannes Kopf, Narendra Ahuja, and Jia-Bin Huang. Deepmvs: Learning multi-view stereopsis. In IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018.
- [39] Wonbong Jang, Philippe Weinzaepfel, Vincent Leroy, Lourdes Agapito, and Jerome Revaud. Pow3r: Empowering unconstrained 3d reconstruction with camera and scene priors. In IEEE Conf. Comput. Vis. Pattern Recog., pages 1071–1081, 2025.
- [40] Hanwen Jiang, Zexiang Xu, Desai Xie, Ziwen Chen, Haian Jin, Fujun Luan, Zhixin Shu, Kai Zhang, Sai Bi, Xin Sun, et al. Megasynt: Scaling up 3d scene reconstruction with synthesized data. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 16441–16452, 2025.
- [41] Lihan Jiang, Yucheng Mao, Linning Xu, Tao Lu, Kerui Ren, Yichen Jin, Xudong Xu, Mulin Yu, Jiangmiao Pang, Feng Zhao, et al. Anysplat: Feed-forward 3d gaussian splatting from unconstrained views. ACM Trans. Graph., 2025.
- [42] Bingxin Ke, Anton Obukhov, Shengyu Huang, Nando Metzger, Rodrigo Caye Daudt, and Konrad Schindler. Repurposing diffusion-based image generators for monocular depth estimation. In CVPR, pages 9492–9502, 2024.
- [43] Nikhil Keetha, Norman Müller, Johannes Schönberger, Lorenzo Porzi, Yuchen Zhang, Tobias Fischer, Arno Knapitsch, Duncan Zauss, Ethan Weber, Nelson Antunes, Jonathon Luiten, Manuel Lopez-Antequera, Samuel Rota Bulò, Christian Richardt, Deva Ramanan, Sebastian Scherer, and Peter Kotschieder. MapAnything: Universal feed-forward metric 3D reconstruction, 2025. arXiv preprint arXiv:2509.13414.
- [44] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. ACM Trans. Graph., 42(4):139–1, 2023.
- [45] Arno Knapitsch, Jaesik Park, Qian-Yi Zhou, and Vladlen Koltun. Tanks and temples: Benchmarking large-scale scene reconstruction. ACM Trans. Graph., 36(4):1–13, 2017.
- [46] Arno Knapitsch, Jaesik Park, Qian-Yi Zhou, and Vladlen Koltun. Tanks and temples: Benchmarking large-scale scene reconstruction. ACM Trans. Graph., 36(4):1–13, 2017.
- [47] Hoang-An Le, Thomas Mensink, Partha Das, Sezer Karaoglu, and Theo Gevers. Eden: Multimodal synthetic dataset of enclosed garden scenes. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, pages 1579–1589, 2021.
- [48] Vincent Leroy, Yohann Cabon, and Jérôme Revaud. Grounding image matching in 3d with mast3r. In Eur. Conf. Comput. Vis., pages 71–91. Springer, 2024.
- [49] Marc Levoy and Pat Hanrahan. Light field rendering. ACM Trans. Graph., 1996.
- [50] Yixuan Li, Lihan Jiang, Linning Xu, Yuanbo Xiangli, Zhenzhi Wang, Dahua Lin, and Bo Dai. Matrixcity: A large-scale city dataset for city-scale neural rendering and beyond. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 3205–3215, 2023.
- [51] Zhengqi Li and Noah Snavely. Megadepth: Learning single-view depth prediction from internet photos. In IEEE Conf. Comput. Vis. Pattern Recog., pages 2041–2050, 2018.
- [52] Haotong Lin, Sida Peng, Zhen Xu, Yunzhi Yan, Qing Shuai, Hujun Bao, and Xiaowei Zhou. Efficient neural radiance fields for interactive free-viewpoint video. In SIGGRAPH Asia 2022 Conference Papers, pages 1–9, 2022.
- [53] Lu Ling, Yichen Sheng, Zhi Tu, Wentian Zhao, Cheng Xin, Kun Wan, Lantao Yu, Qianyu Guo, Zixun Yu, Yawen Lu, et al. D13dv-10k: A large-scale scene dataset for deep learning-based 3d vision. In IEEE Conf. Comput. Vis. Pattern Recog., pages 22160–22169, 2024.
- [54] Dominic Maggio, Hyungtae Lim, and Luca Carlone. Vggt-slam: Dense rgb slam optimized on the $sl(4)$ manifold. arXiv preprint arXiv:2505.12549, 2025.

- [55] John McCormac, Ankur Handa, Stefan Leutenegger, and Andrew J Davison. Scenenet rgb-d: Can 5m synthetic images beat generic imagenet pre-training on indoor segmentation? In Proceedings of the IEEE International Conference on Computer Vision, pages 2678–2687, 2017.
- [56] Lukas Mehl, Jenny Schmalfluss, Azin Jahedi, Yaroslava Nalivayko, and Andrés Bruhn. Spring: A high-resolution high-detail dataset and benchmark for scene flow, optical flow and stereo. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 4981–4991, 2023.
- [57] Ben Mildenhall, Pratul P Srinivasan, Matthew Tancik, Jonathan T Barron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis. In Eur. Conf. Comput. Vis., 2020.
- [58] Raul Mur-Artal, Jose Maria Martinez Montiel, and Juan D Tardos. Orb-slam: A versatile and accurate monocular slam system. IEEE transactions on robotics, 31(5):1147–1163, 2015.
- [59] Riku Murai, Eric Dexheimer, and Andrew J Davison. Mast3r-slam: Real-time dense slam with 3d reconstruction priors. In IEEE Conf. Comput. Vis. Pattern Recog., pages 16695–16705, 2025.
- [60] Simon Niklaus, Long Mai, Jimei Yang, and Feng Liu. 3d ken burns effect from a single image. ACM Transactions on Graphics (ToG), 38(6):1–15, 2019.
- [61] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023.
- [62] Linfei Pan, Dániel Baráth, Marc Pollefeys, and Johannes L Schönberger. Global structure-from-motion revisited. In Eur. Conf. Comput. Vis., pages 58–77. Springer, 2024.
- [63] Xiaqing Pan, Nicholas Charron, Yongqian Yang, Scott Peters, Thomas Whelan, Chen Kong, Omkar Parkhi, Richard Newcombe, and Yuheng Carl Ren. Aria digital twin: A new benchmark dataset for egocentric 3d machine perception. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 20133–20143, 2023.
- [64] William Peebles and Saining Xie. Scalable diffusion models with transformers. In Proceedings of the IEEE/CVF international conference on computer vision, pages 4195–4205, 2023.
- [65] Luigi Piccinelli, Yung-Hsu Yang, Christos Sakaridis, Mattia Segu, Siyuan Li, Luc Van Gool, and Fisher Yu. Unidepth: Universal monocular metric depth estimation. In IEEE Conf. Comput. Vis. Pattern Recog., pages 10106–10116, 2024.
- [66] Luigi Piccinelli, Christos Sakaridis, Yung-Hsu Yang, Mattia Segu, Siyuan Li, Wim Abbeloos, and Luc Van Gool. Unidepthv2: Universal monocular metric depth estimation made simpler. arXiv preprint arXiv:2502.20110, 2025.
- [67] René Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In Int. Conf. Comput. Vis., pages 12179–12188, 2021.
- [68] Jeremy Reizenstein, Roman Shapovalov, Philipp Henzler, Luca Sbordone, Patrick Labatut, and David Novotny. Common objects in 3d: Large-scale learning and evaluation of real-life 3d category reconstruction. In Int. Conf. Comput. Vis., pages 10901–10911, 2021.
- [69] Mike Roberts, Jason Ramapuram, Anurag Ranjan, Atulit Kumar, Miguel Angel Bautista, Nathan Paczan, Russ Webb, and Joshua M Susskind. Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding. In Proceedings of the IEEE/CVF international conference on computer vision, pages 10912–10922, 2021.
- [70] Johannes Lutz Schönberger and Jan-Michael Frahm. Structure-from-motion revisited. In IEEE Conf. Comput. Vis. Pattern Recog., 2016.
- [71] Johannes Lutz Schönberger, Enliang Zheng, Marc Pollefeys, and Jan-Michael Frahm. Pixelwise view selection for unstructured multi-view stereo. In Eur. Conf. Comput. Vis., 2016.
- [72] Thomas Schops, Johannes L Schonberger, Silvano Galliani, Torsten Sattler, Konrad Schindler, Marc Pollefeys, and Andreas Geiger. A multi-view stereo benchmark with high-resolution images and multi-camera videos. In IEEE Conf. Comput. Vis. Pattern Recog., pages 3260–3269, 2017.

- [73] Steven M Seitz, Brian Curless, James Diebel, Daniel Scharstein, and Richard Szeliski. A comparison and evaluation of multi-view stereo reconstruction algorithms. In *IEEE Conf. Comput. Vis. Pattern Recog.*, volume 1, pages 519–528. IEEE, 2006.
- [74] Jamie Shotton, Ben Glocker, Christopher Zach, Shahram Izadi, Antonio Criminisi, and Andrew Fitzgibbon. Scene coordinate regression forests for camera relocalization in rgb-d images. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 2930–2937, 2013.
- [75] Nathan Silberman, Derek Hoiem, Pushmeet Kohli, and Rob Fergus. Indoor segmentation and support inference from rgb-d images. In *Eur. Conf. Comput. Vis.*, pages 746–760. Springer, 2012.
- [76] Nathan Silberman, Derek Hoiem, Pushmeet Kohli, and Rob Fergus. Indoor segmentation and support inference from rgb-d images. In *Eur. Conf. Comput. Vis.*, pages 746–760. Springer, 2012.
- [77] Vincent Sitzmann, Michael Zollhöfer, and Gordon Wetzstein. Scene representation networks: Continuous 3d-structure-aware neural scene representations. *Adv. Neural Inform. Process. Syst.*, 32, 2019.
- [78] Vincent Sitzmann, Semon Rezchikov, Bill Freeman, Josh Tenenbaum, and Fredo Durand. Light field networks: Neural scene representations with single-evaluation rendering. *Adv. Neural Inform. Process. Syst.*, 34:19313–19325, 2021.
- [79] Brandon Smart, Chuanxia Zheng, Iro Laina, and Victor Adrian Prisacariu. Splatt3r: Zero-shot gaussian splatting from uncalibrated image pairs. *arXiv preprint arXiv:2408.13912*, 2024.
- [80] Noah Snavely, Steven M Seitz, and Richard Szeliski. Photo tourism: exploring photo collections in 3d. *ACM Trans. Graph.*, pages 835–846, 2006.
- [81] Shuran Song, Samuel P Lichtenberg, and Jianxiong Xiao. Sun rgb-d: A rgb-d scene understanding benchmark suite. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 567–576, 2015.
- [82] Julian Straub, Thomas Whelan, Lingni Ma, Yufan Chen, Erik Wijmans, Simon Green, Jakob J. Engel, Raul Mur-Artal, Carl Ren, Shobhit Verma, Anton Clarkson, Mingfei Yan, Brian Budge, Yajie Yan, Xiaqing Pan, June Yon, Yuyang Zou, Kimberly Leon, Nigel Carter, Jesus Briales, Tyler Gillingham, Elias Mueggler, Luis Pesqueira, Manolis Savva, Dhruv Batra, Hauke M. Strasdat, Renzo De Nardi, Michael Goesele, Steven Lovegrove, and Richard Newcombe. The Replica dataset: A digital replica of indoor spaces. *arXiv preprint arXiv:1906.05797*, 2019.
- [83] Julian Straub, Thomas Whelan, Lingni Ma, Yufan Chen, Erik Wijmans, Simon Green, Jakob J Engel, Raul Mur-Artal, Carl Ren, Shobhit Verma, et al. The replica dataset: A digital replica of indoor spaces. *arXiv preprint arXiv:1906.05797*, 2019.
- [84] Pei Sun, Henrik Kretschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, Vijay Vasudevan, Wei Han, Jiquan Ngiam, Hang Zhao, Aleksei Timofeev, Scott Ettinger, Maxim Krivokon, Amy Gao, Aditya Joshi, Yu Zhang, Jonathon Shlens, Zhifeng Chen, and Dragomir Anguelov. Scalability in perception for autonomous driving: Waymo open dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [85] Zhenggang Tang, Yuchen Fan, Dilin Wang, Hongyu Xu, Rakesh Ranjan, Alexander Schwing, and Zhicheng Yan. Mv-dust3r+: Single-stage scene reconstruction from sparse views in 2 seconds. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5283–5293, 2025.
- [86] Zachary Teed and Jia Deng. Deepv2d: Video to depth with differentiable structure from motion. *arXiv preprint arXiv:1812.04605*, 2018.
- [87] Shinji Umeyama. Least-squares estimation of transformation parameters between two point patterns. *IEEE Trans. Pattern Anal. Mach. Intell.*, 13(4):376–380, 2002.
- [88] Igor Vasiljevic, Nick Kolkin, Shanyi Zhang, Ruotian Luo, Haochen Wang, Falcon Z Dai, Andrea F Daniele, Mohammadreza Mostajabi, Steven Basart, Matthew R Walter, et al. Diode: A dense indoor and outdoor depth dataset. *arXiv preprint arXiv:1908.00463*, 2019.
- [89] Jianyuan Wang, Christian Rupprecht, and David Novotny. Posediffusion: Solving pose estimation via diffusion-aided bundle adjustment. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 9773–9783, 2023.
- [90] Jianyuan Wang, Nikita Karaev, Christian Rupprecht, and David Novotny. Vggsfm: Visual geometry grounded deep structure from motion. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 21686–21697, 2024.

- [91] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. Vggt: Visual geometry grounded transformer. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5294–5306, 2025.
- [92] Kaixuan Wang and Shaojie Shen. Flow-motion and depth network for monocular stereo and beyond. *IEEE Robotics and Automation Letters*, 5(2):3307–3314, 2020.
- [93] Qiang Wang, Shizhen Zheng, Qingsong Yan, Fei Deng, Kaiyong Zhao, and Xiaowen Chu. Irs: A large naturalistic indoor robotics stereo dataset to train deep models for disparity and surface normal estimation. *arXiv preprint arXiv:1912.09678*, 2019.
- [94] Qianqian Wang, Yifei Zhang, Aleksander Holynski, Alexei A Efros, and Angjoo Kanazawa. Continuous 3d perception model with persistent state. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 10510–10522, 2025.
- [95] Ruicheng Wang, Sicheng Xu, Cassie Dai, Jianfeng Xiang, Yu Deng, Xin Tong, and Jiaolong Yang. Moge: Unlocking accurate monocular geometry estimation for open-domain images with optimal training supervision. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5261–5271, 2025.
- [96] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. Dust3r: Geometric 3d vision made easy. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 20697–20709, 2024.
- [97] Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jerome Revaud. Dust3r: Geometric 3d vision made easy. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 20697–20709, 2024.
- [98] Wenshan Wang, DeLong Zhu, Xiangwei Wang, Yaoyu Hu, Yuheng Qiu, Chen Wang, Yafei Hu, Ashish Kapoor, and Sebastian Scherer. Tartanair: A dataset to push the limits of visual slam. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4909–4916. IEEE, 2020.
- [99] Yifan Wang, Jianjun Zhou, Haoyi Zhu, Wenzheng Chang, Yang Zhou, Zizun Li, Junyi Chen, Jiangmiao Pang, Chunhua Shen, and Tong He. π^3 : Scalable permutation-equivariant visual geometry learning, 2025. URL <https://arxiv.org/abs/2507.13347>.
- [100] Bowen Wen, Matthew Trepte, Joseph Aribido, Jan Kautz, Orazio Gallo, and Stan Birchfield. Foundationstereo: Zero-shot stereo matching. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5249–5260, 2025.
- [101] Benjamin Wilson, William Qi, Tanmay Agarwal, John Lambert, Jagjeet Singh, Siddhesh Khandelwal, Bowen Pan, Ratnesh Kumar, Andrew Hartnett, Jhony Kaesemodel Pontes, et al. Argoverse 2: Next generation datasets for self-driving perception and forecasting. In *Adv. Neural Inform. Process. Syst.*, 2021.
- [102] Tong Wu, Jiarui Zhang, Xiao Fu, Yuxin Wang, Liang Pan Jiawei Ren, Wayne Wu, Lei Yang, Jiaqi Wang, Chen Qian, Dahua Lin, and Ziwei Liu. Omniobject3d: Large-vocabulary 3d object dataset for realistic perception, reconstruction and generation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [103] Hongchi Xia, Yang Fu, Sifei Liu, and Xiaolong Wang. Rgb-d objects in the wild: Scaling real-world 3d object learning from rgb-d videos, 2024.
- [104] Jianfeng Xiang, Zelong Lv, Sicheng Xu, Yu Deng, Ruicheng Wang, Bowen Zhang, Dong Chen, Xin Tong, and Jiaolong Yang. Structured 3d latents for scalable and versatile 3d generation. *arXiv preprint arXiv:2412.01506*, 2024.
- [105] Pengchuan Xiao, Zhenlei Shao, Steven Hao, Zishuo Zhang, Xiaolin Chai, Judy Jiao, Zesong Li, Jian Wu, Kai Sun, Kun Jiang, et al. Pandaset: Advanced sensor suite dataset for autonomous driving. In *2021 IEEE international intelligent transportation systems conference (ITSC)*, pages 3095–3101. IEEE, 2021.
- [106] Gangwei Xu, Xianqi Wang, Xiaohuan Ding, and Xin Yang. Iterative geometry encoding volume for stereo matching. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 21919–21928, 2023.
- [107] Haofei Xu, Anpei Chen, Yuedong Chen, Christos Sakaridis, Yulun Zhang, Marc Pollefeys, Andreas Geiger, and Fisher Yu. Murf: multi-baseline radiance fields. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 20041–20050, 2024.
- [108] Haofei Xu, Songyou Peng, Fangjinhua Wang, Hermann Blum, Daniel Barath, Andreas Geiger, and Marc Pollefeys. Depthspat: Connecting gaussian splatting and depth. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 16453–16463, 2025.

- [109] Guorun Yang, Xiao Song, Chaoqin Huang, Zhidong Deng, Jianping Shi, and Bolei Zhou. Drivingstereo: A large-scale dataset for stereo matching in autonomous driving scenarios. In IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2019.
- [110] Jianing Yang, Alexander Sax, Kevin J Liang, Mikael Henaff, Hao Tang, Ang Cao, Joyce Chai, Franziska Meier, and Matt Feiszli. Fast3r: Towards 3d reconstruction of 1000+ images in one forward pass. In IEEE Conf. Comput. Vis. Pattern Recog., pages 21924–21935, 2025.
- [111] Jianing Yang, Alexander Sax, Kevin J Liang, Mikael Henaff, Hao Tang, Ang Cao, Joyce Chai, Franziska Meier, and Matt Feiszli. Fast3r: Towards 3d reconstruction of 1000+ images in one forward pass. In IEEE Conf. Comput. Vis. Pattern Recog., pages 21924–21935, 2025.
- [112] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything v2. Adv. Neural Inform. Process. Syst., 37:21875–21911, 2024.
- [113] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything v2. In Adv. Neural Inform. Process. Syst., 2024.
- [114] Yao Yao, Zixin Luo, Shiwei Li, Tian Fang, and Long Quan. Mvsnet: Depth inference for unstructured multi-view stereo. In Eur. Conf. Comput. Vis., pages 767–783, 2018.
- [115] Yao Yao, Zixin Luo, Shiwei Li, Jingyang Zhang, Yufan Ren, Lei Zhou, Tian Fang, and Long Quan. Blendedmvs: A large-scale dataset for generalized multi-view stereo networks. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pages 1790–1799, 2020.
- [116] Botao Ye, Sifei Liu, Haofei Xu, Xueting Li, Marc Pollefeys, Ming-Hsuan Yang, and Songyou Peng. No pose, no problem: Surprisingly simple 3d gaussian splats from sparse unposed images. In Int. Conf. Learn. Represent., 2024.
- [117] Chandan Yeshwanth, Yueh-Cheng Liu, Matthias Nießner, and Angela Dai. Scannet++: A high-fidelity dataset of 3d indoor scenes. In Int. Conf. Comput. Vis., pages 12–22, 2023.
- [118] Wei Yin, Chi Zhang, Hao Chen, Zhipeng Cai, Gang Yu, Kaixuan Wang, Xiaozhi Chen, and Chunhua Shen. Metric3d: Towards zero-shot metric 3d prediction from a single image. In CVPR, pages 9043–9053, 2023.
- [119] Alex Yu, Vickie Ye, Matthew Tancik, and Angjoo Kanazawa. pixelnerf: Neural radiance fields from one or few images. In IEEE Conf. Comput. Vis. Pattern Recog., pages 4578–4587, 2021.
- [120] Amir R Zamir, Alexander Sax, , William B Shen, Leonidas Guibas, Jitendra Malik, and Silvio Savarese. Taskonomy: Disentangling task transfer learning. In IEEE Conf. Comput. Vis. Pattern Recog. IEEE, 2018.
- [121] Junyi Zhang, Charles Herrmann, Junhwa Hur, Varun Jampani, Trevor Darrell, Forrester Cole, Deqing Sun, and Ming-Hsuan Yang. Monst3r: A simple approach for estimating geometry in the presence of motion. In Int. Conf. Learn. Represent., 2025.
- [122] Shangzhan Zhang, Jianyuan Wang, Yinghao Xu, Nan Xue, Christian Rupprecht, Xiaowei Zhou, Yujun Shen, and Gordon Wetzstein. Flare: Feed-forward geometry, appearance and camera estimation from uncalibrated sparse views. In IEEE Conf. Comput. Vis. Pattern Recog., pages 21936–21947, 2025.
- [123] Yi Zhang, Weichao Qiu, Qi Chen, Xiaolin Hu, and Alan Yuille. Unrealstereo: Controlling hazardous factors to analyze stereo vision. In 2018 International Conference on 3D Vision (3DV), pages 228–237. IEEE, 2018.
- [124] Zhe Zhang, Rui Peng, Yuxi Hu, and Ronggang Wang. Geomvsnet: Learning multi-view stereo with geometry perception. In IEEE Conf. Comput. Vis. Pattern Recog., pages 21508–21518, 2023.
- [125] Jia Zheng, Junfei Zhang, Jing Li, Rui Tang, Shenghua Gao, and Zihan Zhou. Structured3d: A large photo-realistic dataset for structured 3d modeling. In European Conference on Computer Vision, pages 519–535. Springer, 2020.
- [126] Peng Zheng, Dehong Gao, Deng-Ping Fan, Li Liu, Jorma Laaksonen, Wanli Ouyang, and Nicu Sebe. Bilateral reference for high-resolution dichotomous image segmentation. CAAI Artificial Intelligence Research, 2024.
- [127] Yang Zheng, Adam W Harley, Bokui Shen, Gordon Wetzstein, and Leonidas J Guibas. Pointodyssey: A large-scale synthetic dataset for long-term point tracking. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 19855–19865, 2023.

- [128] Yang Zhou, Yifan Wang, Jianjun Zhou, Wenzheng Chang, Haoyu Guo, Zizun Li, Kaijing Ma, Xinyue Li, Yating Wang, Haoyi Zhu, Mingyu Liu, Dingning Liu, Jiange Yang, Zhoujie Fu, Junyi Chen, Chunhua Shen, Jiangmiao Pang, Kaipeng Zhang, and Tong He. Omniworld: A multi-domain and multi-modal dataset for 4d world modeling, 2025. URL <https://arxiv.org/abs/2509.12201>.
- [129] Rui Zhu, Second Author, and Third Author. Svlightverse: Large-scale photorealistic indoor dataset with spatially-varying hdri lighting. <https://jerryiglet.github.io/SVLightVerse/>, 2025. Project page. Affiliations: University of California San Diego; PICO (ByteDance); KooLab (Manycore); Rembrand. Accessed: 2025-11-11.
- [130] Zihan Zhu, Songyou Peng, Viktor Larsson, Zhaopeng Cui, Martin R Oswald, Andreas Geiger, and Marc Pollefeys. Nicer-slam: Neural implicit scene encoding for rgb slam. In 3DV, pages 42–52. IEEE, 2024.

附录

尽管合成数据集能够提供带有真实深度标注的大规模训练数据，但许多数据集存在质量问题，例如无效背景、空间错位、裁剪伪影以及错误的深度值，这些问题可能影响模型训练。因此，我们进行了仔细的预处理，以过滤有问题的样本并裁剪不切实际的深度范围，确保为我们的教师模型提供高质量的监督。

A 数据处理

为了训练教师模型，我们对以下原始训练数据集进行了如下预处理。

TartanAir. 我们在训练中移除了 `amusement` 场景，因为该场景存在无效背景（天空盒）（图 12）。我们将 `carwelding`、`hospital`、`ocean`、`office` 和 `office2` 场景的最大深度值分别裁剪为 80、30、1000、30 和 30。




Figure 12 TartanAir 数据集中 amusement 场景的无效背景。

IRS. 我们注意到 IRS 中的部分场景在图像与深度图之间存在空间错位（图 13）。为过滤这些图像-深度错位的样本，我们首先在图像（转换为灰度图）和深度图上运行 Canny 边缘检测器以提取边界。接着，我们将边界膨胀 1 个像素，并计算图像边界与深度边界之间的交集百分比。然后，我们再将边界膨胀 3 个像素，并计算图像边界与深度边界之间的交集。最后，计算两个交集之间的比率，并移除比率低于某一阈值的样本。



Figure 13 IRS 数据集中的图像-深度空间错位。

UnrealStereo4K. 我们移除了包含大面积错误区域的 00003 场景。我们还移除了存在裁剪问题的 00004 场景。对于 00008 场景，我们移除了海洋区域没有深度值的样本（图像编号 9-13、23-29、80-82、86-88、96、103-111、126-136、144-145、148-154、173-176、178-179、186-187、191-192、198-199）（图 14）。

GTA-SfM. 我们将最大深度值裁剪为 1000。

Kenburns. 根据 GitHub 问题¹，我们将深度值裁剪为 50,000。

PointOdyssey. 我们移除了 `animal2_s` 和 `dancingroom3_3rd` 两个场景，这些场景的地面深度不正确²。

TRELLIS. 我们移除了所有后缀为 `stl`、`abc`、`STL`、`PLY`、`ply` 的样本，因为我们注意到这些样本不包含纹理。

OmniObject3D. 我们将最大深度值裁剪为 10。

¹<https://github.com/sniklaus/3d-ken-burns/issues/40>

²https://github.com/y-zheng18/point_odyssey/issues/6




Figure 14 UnrealStereo4K 数据集中的错误样本。 00003 场景中的窗户是透明的；00004 场景存在裁剪问题；00008 场景中海洋区域没有深度值。