

DETR3D: 通过 3D 到 2D 查询实现多视角图像 3D 目标检测 (3D Object Detection from Multi-view Images via 3D-to-2D Queries)

Yue Wang
Massachusetts Institute of Technology
yuewang@csail.mit.edu

Vitor Guizilini*
Toyota Research Institute
vitor.guizilini@tri.global

Tianyuan Zhang*
Carnegie Mellon University
tianyuaz@andrew.cmu.edu

Yilun Wang
Li Auto
yilunw@cs.stanford.edu

Hang Zhao ¶
Tsinghua University
hangzhao@mail.tsinghua.edu.cn

Justin Solomon ¶
Massachusetts Institute of Technology
jsolomon@mit.edu

Abstract: 本文提出了一种多相机 3D 目标检测 (Multi-Camera 3D Object Detection) 框架。与直接从单目图像估计 3D 边界框或使用深度预测网络从 2D 信息生成 3D 目标检测输入的现有方法不同, 本文方法直接在 3D 空间中进行预测。本文架构从多个相机图像中提取 2D 特征, 然后使用稀疏的 3D 目标查询集合索引这些 2D 特征, 通过相机变换矩阵将 3D 位置与多视角图像关联起来。最终, 本文模型对每个目标查询进行边界框预测, 并使用集合到集合 (Set-to-Set) 损失来衡量预测与真值之间的差异。本文研究了连接 2D 观测与 3D 预测的两种方案: 一种是依赖于密集深度预测和 3D 场景结构恢复的自底向上 (Bottom-Up) 方法; 另一种是从稀疏目标先验出发, 通过反向投影 (Backward Projection) 查询 2D 图像特征的自顶向下 (Top-Down) 方法。这种自顶向下方法优于自底向上方法 (后者在逐像素深度估计后进行目标边界框预测), 因为它不受深度预测模型引入的累积误差影响。此外, 本文方法不需要非极大值抑制 (Non-Maximum Suppression, NMS) 等后处理, 显著提升了推理速度。本文在 nuScenes 自动驾驶基准上取得了当前最优 (State-of-the-Art, SOTA) 的性能。

1 引言

从视觉信息中进行 3D 目标检测 (3D Object Detection) 一直是低成本自动驾驶系统面临的长期挑战。虽然利用激光雷达 (LiDAR) 等传感器采集的点云进行目标检测得益于可见物体 3D 结构信息, 但基于相机的设置更为不适定, 因为必须仅从 RGB 图像中包含的 2D 信息生成 3D 边界框预测。

现有方法 [1, 2] 通常完全基于 2D 计算构建检测流程。它们使用为 2D 任务设计的检测流程 (如 CenterNet [1]、FCOS [3]) 来预测物体姿态和速度等 3D 信息, 而未考虑 3D 场景结构或传感器配置。这些方法需要多个后处理步骤来融合不同相机的预测并去除冗余边界框, 导致效率和效果之间存在严重权衡。

作为这些基于 2D 方法的替代方案, 一些方法通过应用 3D 重建方法 [4, 5, 6], 从相机图像创建场景的伪激光雷达 (Pseudo-LiDAR) 或距离输入, 从而将更多 3D 计算引入检测流程。然后, 可对这些数据应用 3D 目标检测方法, 就像直接来自 3D 传感器一样。然而, 这种策

*: 同等贡献 (Equal contribution)。¶: 项目共同指导 (Co-advise)。

略会受到累积误差的影响 [7]：估计不准确的深度值会对 3D 目标检测性能产生强烈的负面影响，而 3D 目标检测本身也可能产生误差。

本文提出了一种更优雅的 2D 观测与 3D 预测之间的转换方案，该方案不依赖密集深度预测模块。本文框架称为 DETR3D（多视角 3D 检测），以自顶向下的方式解决该问题。通过几何反向投影（Geometric Back-Projection）和相机变换矩阵，将 2D 特征提取与 3D 目标预测相连接。

本文方法从一组稀疏的目标先验开始，这些先验在数据集上共享并以端到端方式学习。为获取场景特定信息，将从这些目标先验解码得到的一组参考点反向投影到每个相机，并获取由 ResNet 骨干网络 [8] 提取的相应图像特征。参考点的图像特征随后通过多头自注意力层 [9] 进行交互。经过一系列自注意力层后，从每一层读取边界框参数，并使用受 DETR [10] 启发的集合到集合损失来评估性能。

本文架构不进行点云重建或从图像显式预测深度，因此对深度估计误差具有鲁棒性。此外，本文方法不需要任何后处理（如非极大值抑制），提高了效率并减少了对人工设计的输出清洗方法的依赖。在 nuScenes 数据集上，本文方法（无 NMS）与先前方法（有 NMS）性能相当。在相机重叠区域，本文方法显著优于其他方法。

贡献。本文的主要贡献总结如下：

- 提出了一种基于 RGB 图像的简洁 3D 目标检测模型。与现有在最后阶段才融合不同相机视图目标预测的方法不同，本文方法在每一层计算中都融合了所有相机视图的信息。据本文所知，这是首次将多相机检测视为 3D 集合到集合预测的尝试。
- 引入了一个通过几何反向投影连接 2D 特征提取和 3D 边界框预测的模块。该模块不受辅助网络不准确深度预测的影响，并通过将 3D 信息反向投影到所有可用帧上无缝利用多相机信息。
- 与 Object DGCNN [11] 类似，本文方法不需要逐图像或全局 NMS 等后处理，性能与现有基于 NMS 的方法相当。在相机重叠区域，本文方法以显著优势优于其他方法。
- 公开代码以促进可重复性和未来研究。

2 相关工作

2D 目标检测 (2D Object Detection)。RCNN [12] 开创了使用深度学习进行目标检测的先河。它将一组预选的目标候选框输入卷积神经网络 (CNN)，并据此预测边界框参数。尽管该方法表现出令人惊讶的性能，但由于需要对每个目标候选框执行一次卷积网络前向传播，其速度比其他方法慢一个数量级。为解决此问题，Fast RCNN [13] 引入了一个共享的可学习 CNN，在单次前向传播中处理整张图像。为进一步提升性能和速度，Faster RCNN [13] 包含了一个区域提议网络 (Region Proposal Network, RPN)，该网络与检测网络共享全图卷积特征，从而几乎零成本地生成区域提议。Mask RCNN [14] 引入了一个掩码预测分支，以实现并行实例分割。这些方法通常涉及多阶段优化，在实践中可能速度较慢。与这些多阶段方法不同，SSD [15] 和 YOLO [16] 以单次方式执行密集预测。虽然它们显著快于上述替代方案，但仍依赖 NMS 去除冗余框预测。这些方法相对于预定义的锚框 (Anchors) 预测边界框。CenterNet [1] 和 FCOS [3] 改变了范式，从逐锚框预测转向逐像素预测，大大简化了常见的目标检测流程。

基于集合的目标检测 (Set-based Object Detection)。DETR [10] 将目标检测视为一个集合到集合问题。它使用 Transformer [9] 捕获特征和目标交互。DETR 学习将预测结果分配给一组真值框，因此不需要后处理来过滤冗余框。然而，DETR 的一个关键缺点是需要大量的训练时间。Deformable DETR [17] 分析了 DETR 收敛缓慢的原因，并提出了一种可变形自注意力模块来定位特征并加速训练。与此同时，[18] 将 DETR 收敛缓慢归因于集合损失和 Transformer 交叉注意力机制，提出了 TSP-FCOS 和 TSP-RCNN 两种变体来克服这些问题。SparseRCNN [19] 将集合预测融入 RCNN 风格的流程，性能优于多阶段目标检测且无需 NMS。OneNet [20] 研究了一个有趣的现象：密集目标检测器配备最小代价集合损失后，可实现无 NMS 检测。在 3D 领域，Object DGCNN [11] 研究了从点云进行 3D 目

<https://github.com/WangYueFt/detr3d>




图 1: 本文方法概述。模型输入为一组多视角图像，经 ResNet 和 FPN 编码后，模型在一组稀疏的目标查询上操作，每个查询解码为一个 3D 参考点。通过将 3D 参考点投影到图像空间，提取 2D 特征以优化目标查询。模型对每个查询进行预测，并使用集合到集合损失。目标检测。它将 3D 目标检测建模为动态图上的消息传递，将 DGCNN 框架推广到预测一组目标。与 DETR 类似，Object DGCNN 也是无 NMS 的。

单目 3D 目标检测 (Monocular 3D Object Detection)。从 RGB 图像进行 3D 检测的早期方法是 Mono3D [21]，它利用语义和形状线索，在训练时使用场景约束和额外先验从一组 3D 候选框中进行选择。[22] 使用鸟瞰视图 (Bird’s-Eye View, BEV) 进行单目 3D 检测，而 [23] 利用 2D 检测结果，通过最小化 2D-3D 投影误差进行 3D 边界框回归。使用 2D 检测器作为 3D 计算的起点最近已成为一种标准方法 [24, 25]。其他工作还探索了可微渲染 [26] 或 3D 关键点检测 [27, 28, 1] 等方面的进展，以实现当前最优的 3D 目标检测性能。所有这些方法都是在单目设置下运行的，扩展到多相机的方式是独立处理每个视角的图像，然后在后处理阶段合并输出。

3 多视角 3D 目标检测

3.1 概述

本文架构以一组相机（其投影矩阵已知）采集的 RGB 图像作为输入，输出场景中目标的 3D 边界框参数集合。与以往方法不同，本文基于以下几个高层次需求构建架构：

- 在架构的中间计算中融入 3D 信息，而非仅在图像平面上执行纯 2D 计算。
- 不估计密集的 3D 场景几何结构，避免引入相关的重建误差。
- 避免 NMS 等后处理步骤。

本文通过一个新的集合预测模块满足这些需求，该模块在 2D 和 3D 计算之间交替，连接 2D 特征提取与 3D 框预测。模型包含三个关键组件，如图 1 所示。首先，遵循 2D 视觉中的常见做法，使用共享的 ResNet [8] 骨干网络从相机图像中提取特征，并可选地使用特征金字塔网络 (Feature Pyramid Network, FPN) [29] 增强这些特征 (§3.2)。其次，检测头 (§3.3) ——本文的主要贡献——以几何感知的方式将计算得到的 2D 特征与一组 3D 边界框预测连接起来 (§3.3)。检测头的每一层从一组稀疏的目标查询开始，这些查询从数据中学习得到。每个目标查询编码一个 3D 位置，该位置被投影到相机平面并通过双线性插值收集图像特征。与 DETR [10] 类似，使用多头注意力 [9] 通过融入目标交互来优化目标查询。该层重复多次，在特征采样和目标查询优化之间交替。最后，使用集合到集合损失 [30, 10] 训练网络 (§3.4)。

3.2 特征学习

模型以一组图像 $\mathcal{I} = \{\mathbf{im}_1, \dots, \mathbf{im}_K\} \subset \mathbb{R}^{H_{\text{im}} \times W_{\text{im}} \times 3}$ （由环视相机拍摄）、相机矩阵 $\mathcal{T} = \{T_1, \dots, T_K\} \subset \mathbb{R}^{3 \times 4}$ 、真值边界框 $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_j, \dots, \mathbf{b}_M\} \subset \mathbb{R}^9$ 和类别标签 $\mathcal{C} = \{c_1, \dots, c_j, \dots, c_M\} \subset \mathbb{Z}$ 为输入。每个 $\mathbf{b}_j$ 包含在鸟瞰视图 (Bird’s-Eye View, BEV) 中的位置、尺寸、朝向角和速度；本文旨在从图像中预测这些边界框及其标签。本文不使用通常由高端激光雷达捕获的点云。

这些图像经 ResNet [8] 和 FPN [29] 编码为四组特征 $\mathcal{F}_1, \mathcal{F}_2, \mathcal{F}_3, \mathcal{F}_4$ 。每组特征 $\mathcal{F}_k = \{\mathbf{f}_{k1}, \dots, \mathbf{f}_{k6}\} \subset \mathbb{R}^{H \times W \times C}$ 对应 6 张图像的一个特征层级。这些多尺度特征提供了丰富的信息，以识别不同大小的目标。下面详细阐述如何通过新颖的集合预测模块将这些 2D 特征转换为 3D 特征。

3.3 检测头

现有的从相机输入进行目标检测的方法通常采用自底向上的方式，即对每张图像预测一组密集的边界框，在图像间过滤冗余框，并在后处理步骤中聚合所有相机的预测。该范式有两个关键缺陷：密集边界框预测需要准确的深度感知（这本身就是一个具有挑战性的问题）；基于 NMS 的冗余去除和聚合是不可并行化的操作，会引入显著的推理开销。本文通过下面描述的自顶向下检测头来解决这些问题。

与 [11, 17] 类似，DETR3D 是迭代式的；使用 L 层基于集合的计算从 2D 特征图中生成边界框估计。每一层包括以下步骤：

1. 预测与目标查询关联的一组边界框中心；
2. 使用相机变换矩阵将这些中心投影到所有特征图中；
3. 通过双线性插值采样特征并将其融入目标查询；
4. 使用多头注意力描述目标交互。

受 DETR [10] 启发，每一层 $\ell \in \{0, \dots, L-1\}$ 对一组目标查询 $\mathcal{Q}_\ell = \{\mathbf{q}_{\ell 1}, \dots, \mathbf{q}_{\ell M^*}\} \subset \mathbb{R}^C$ 进行操作，生成新集合 $\mathcal{Q}_{\ell+1}$ 。从目标查询 $\mathbf{q}_{\ell i}$ 解码出参考点 $\mathbf{c}_{\ell i} \in \mathbb{R}^3$ ：

$$\mathbf{c}_{\ell i} = \Phi^{\text{ref}}(\mathbf{q}_{\ell i}), \quad (1)$$

其中 Φ^{ref} 是一个神经网络。 $\mathbf{c}_{\ell i}$ 可视作第 i 个框中心的一个假设。接下来，获取与 $\mathbf{c}_{\ell i}$ 对应的图像特征，以优化并预测最终的边界框。然后，使用相机变换矩阵将 $\mathbf{c}_{\ell i}$ （更准确地说，其齐次坐标 $\mathbf{c}_{\ell i}^*$ ）投影到每张图像中：

$$\mathbf{c}_{\ell i}^* = \mathbf{c}_{\ell i} \oplus 1 \quad \mathbf{c}_{\ell m i} = T_m \mathbf{c}_{\ell i}^*, \quad (2)$$

其中 $\oplus$ 表示拼接操作， $\mathbf{c}_{\ell m i}$ 是参考点在第 m 个相机上的投影。为消除特征图大小的影响并收集不同层级的特征，将 $\mathbf{c}_{\ell m i}$ 归一化到 $[-1, 1]$ 。接下来，通过以下方式收集图像特征：

$$\mathbf{f}_{\ell k m i} = f^{\text{bilinear}}(\mathcal{F}_{km}, \mathbf{c}_{\ell m i}), \quad (3)$$

其中 $\mathbf{f}_{\ell k m i}$ 是第 ℓ 层中第 i 个点在第 m 个相机第 k 个特征层级上的特征。

给定参考点不一定在所有相机图像中都可见，因此需要使用启发式方法过滤无效点。为此，定义二值变量 $\sigma_{\ell k m i}$ ，其取值基于参考点是否投影到图像平面之外。最终特征 $\mathbf{f}_{\ell i}$ 和下一层的目标查询 $\mathbf{q}_{(\ell+1)i}$ 由下式给出：

$$\mathbf{f}_{\ell i} = \frac{1}{\sum_k \sum_m \sigma_{\ell k m i} + \epsilon} \sum_k \sum_m \mathbf{f}_{\ell k m i} \sigma_{\ell k m i} \quad \text{and} \quad \mathbf{q}_{(\ell+1)i} = \mathbf{f}_{\ell i} + \mathbf{q}_{\ell i}, \quad (4)$$

其中 ϵ 是一个微小数值，用于避免除零。最后，对每个目标查询 $\mathbf{q}_{\ell i}$ ，使用两个神经网络 Φ_ℓ^{reg} 和 Φ_ℓ^{cls} 预测边界框 $\hat{\mathbf{b}}_{\ell i}$ 及其类别标签 $\hat{c}_{\ell i}$ ：

$$\hat{\mathbf{b}}_{\ell i} = \Phi_\ell^{\text{reg}}(\mathbf{q}_{\ell i}) \quad \text{and} \quad \hat{c}_{\ell i} = \Phi_\ell^{\text{cls}}(\mathbf{q}_{\ell i}). \quad (5)$$

在训练期间，对每一层的预测 $\hat{\mathcal{B}}_\ell = \{\hat{\mathbf{b}}_{\ell 1}, \dots, \hat{\mathbf{b}}_{\ell j}, \dots, \hat{\mathbf{b}}_{\ell M^*}\} \subset \mathbb{R}^9$ 和 $\hat{\mathcal{C}}_\ell = \{\hat{c}_{\ell 1}, \dots, \hat{c}_{\ell j}, \dots, \hat{c}_{\ell M}\} \subset \mathbb{Z}$ 计算损失。推理时，只使用最后一层的输出。

3.4 损失函数

参考 [30, 10]，使用集合到集合损失来衡量预测集合 $(\hat{\mathcal{B}}_\ell, \hat{\mathcal{C}}_\ell)$ 与真值集合 $(\mathcal{B}, \mathcal{C})$ 之间的差异。该损失由两部分组成：类别标签的焦点损失 (Focal Loss) [31] 和边界框参数的 L^1 损失。为书写方便，省略 $\hat{\mathcal{B}}_\ell$ 和 $\hat{\mathcal{C}}_\ell$ 中的下标 ℓ 。真值框的数量 M 通常小于预测数量 M^* ，因此将真值框集

合用 $\emptyset$ (无目标) 填充到 M^* 以便于计算。通过二分匹配 (Bipartite Matching) 问题建立真值与预测之间的对应关系: $\sigma^* = \arg \min_{\sigma \in \mathcal{P}} \sum_{j=1}^M -1_{\{c_j \neq \emptyset\}} \hat{p}_{\sigma(j)}(c_j) + 1_{\{c_j = \emptyset\}} \mathcal{L}_{\text{box}}(\mathbf{b}_j, \hat{\mathbf{b}}_{\sigma(j)})$,

其中 $\mathcal{P}$ 表示所有排列的集合, $\hat{p}_{\sigma(j)}(c_j)$ 是索引 $\sigma(j)$ 的预测属于类别 c_j 的概率, $\mathcal{L}_{\text{box}}$ 是边界框参数的 L_1 损失。与 [30, 10] 一样, 使用匈牙利算法 [32] 求解该分配问题, 得到集合到集合损失 $\mathcal{L}_{\text{sup}} = \sum_{j=1}^N -\log \hat{p}_{\sigma^*(j)}(c_j) + 1_{\{c_j = \emptyset\}} \mathcal{L}_{\text{box}}(\mathbf{b}_j, \hat{\mathbf{b}}_{\sigma^*(j)})$ 。

4 实验

实验结果按以下方式呈现: 首先在 §4.1 中详细说明数据集、评估指标和实现细节; 然后在 §4.2 中将本文方法与现有工作进行对比; 在 §4.3 中评估不同模型在相机重叠区域的性能; 在 §4.4 中与前向预测模型进行比较; 最后在 §4.5 中提供额外的分析和消融实验。

4.1 实现细节

数据集 (Dataset)。在 nuScenes 数据集 [33] 上进行测试。nuScenes 包含 1,000 个序列, 每个序列长约 20 秒, 采样率为 20 帧/秒。每个样本包含 6 个相机图像 [front_left, front, front_right, back_left, back, back_right]。提供了包括内参和外参在内的相机参数。nuScenes 每 0.5 秒提供一次标注, 训练集、验证集和测试集分别有 28k、6k 和 6k 个标注样本。从全部 23 个类别中选取 10 个类别用于计算评估指标。

评估指标 (Metrics)。遵循 nuScenes 提供的官方评估协议。评估平均平移误差 (Average Translation Error, ATE)、平均尺度误差 (Average Scale Error, ASE)、平均朝向误差 (Average Orientation Error, AOE)、平均速度误差 (Average Velocity Error, AVE) 和平均属性误差 (Average Attribute Error, AAE)。这些指标是真正例指标 (True Positive Metrics, TP Metrics), 以物理单位计算。此外, 还测量平均精度 (mean Average Precision, mAP)。为全面捕获检测任务的所有方面, 定义了一个综合标量指标——nuScenes 检测得分 (nuScenes Detection Score, NDS) [33]: $\text{NDS} = \frac{1}{10} [5\text{mAP} + \sum_{\text{mTP} \in \mathbb{TP}} (1 - \min(1, \text{mTP}))]$ 。

模型 (Model)。本文模型由 ResNet [8] 特征提取器、FPN 和 DETR3D 检测头组成。使用在第 3 和第 4 阶段具有可变形卷积 [34] 的 ResNet101。FPN [29] 接收 ResNet 输出的特征, 生成 4 张尺寸分别为输入图像大小 $1/8$ 、 $1/16$ 、 $1/32$ 和 $1/64$ 的特征图。DETR3D 检测头包含 6 层, 每层由一个特征优化步骤和一个多头注意力层组成。DETR3D 检测头的隐藏维度为 256。最后, 两个子网络分别预测每个目标查询的边界框参数和类别标签; 每个子网络由两个隐藏维度为 256 的全连接层组成。在检测头中使用层归一化 (LayerNorm) [35]。

训练与推理 (Training & Inference)。使用 AdamW [36] 训练整个流程。权重衰减为 10^{-4} 。初始学习率为 10^{-4} , 在第 8 和第 11 个 epoch 分别降至 10^{-5} 和 10^{-6} 。模型总共训练 12 个 epoch, 使用 8 张 RTX 3090 GPU, 每 GPU 批大小为 1。训练过程大约需要 18 小时。推理时不使用 NMS 等后处理。评估使用 nuScenes 评估工具包。

4.2 与现有工作对比

与之前的当前最优方法 CenterNet [1] 和 FCOS3D [2] 进行比较。CenterNet 是一种无锚框 2D 检测方法, 在高分辨率特征图上进行密集预测。FCOS3D 采用 FCOS [3] 流程进行逐像素预测。这两种方法都将 3D 目标检测转化为 2D 问题, 因此忽略了场景几何和传感器配置。为执行多视角目标检测, 这些方法必须独立处理每张图像, 并分别使用逐图像和全局 NMS 来去除各视角和重叠区域中的冗余框。如表 1 所示, 本文方法即使不使用任何后处理, 也优于这些方法。本文方法在 mATE 指标上略逊于 FCOS3D, 推测是因为 FCOS3D 直接预测边界框深度, 从而对目标平移提供了强监督。此外, FCOS3D 为不同的边界框参数使用了解耦检测头, 这有助于提升性能。

在测试集上 (表 2), 截至 2021 年 10 月 13 日, 本文方法优于所有现有方法; 为公平比较, 本文方法与 DD3D [37] 使用相同的骨干网络。

表 1: 在验证集上与近期工作的对比。本文方法对 NMS 的使用具有鲁棒性。*: CenterNet 使用自定义骨干网络 DLA [38]。‡: 该模型使用深度权重 1.0 训练, 并从 FCOS3D 检查点初始化; 该检查点在同一数据集上使用深度权重 0.2 训练。§: 使用测试时数据增强。¶: 使用测试时数据增强、更多 epoch 和模型集成。详见 [2]。†: 本文方法同样从 FCOS3D 骨干网络初始化; 检测头随机初始化。#: 使用 CBGS [39] 训练。

方法	NDS ↑	mAP ↑	mATE ↓	mASE ↓	mAOE ↓	mAVE ↓	mAAE ↓	NMS
CenterNet *	0.328	0.306	0.716	0.264	0.609	1.426	0.658	✓
FCOS3D	0.373	0.299	0.785	0.268	0.557	1.396	0.154	✓
FCOS3D ‡	0.393	0.321	0.746	0.265	0.503	1.351	0.160	✓
FCOS3D §	0.402	0.326	0.743	0.259	0.441	1.341	0.163	✓
FCOS3D ¶	0.415	0.343	0.725	0.263	0.422	1.292	0.153	✓
DETR3D (Ours)	0.374	0.303	0.860	0.278	0.437	0.967	0.235	-
DETR3D (Ours) †	0.425	0.346	0.773	0.268	0.383	0.842	0.216	-
DETR3D (Ours) #	0.434	0.349	0.716	0.268	0.379	0.842	0.200	-

表 2: 在测试集上与排行榜上最优方法的对比。#: 从 DD3D 检查点初始化。†: 从额外数据预训练的骨干网络初始化。

方法	NDS ↑	mAP ↑	mATE ↓	mASE ↓	mAOE ↓	mAVE ↓	mAAE ↓	NMS
Mono3D	0.429	0.366	0.642	0.252	0.523	1.591	0.119	N/A
DHNet	0.437	0.363	0.667	0.259	0.402	1.589	0.120	N/A
PGD [40]	0.448	0.386	0.626	0.245	0.451	1.509	0.127	✓
DD3D [37] †	0.477	0.418	0.572	0.249	0.368	1.014	0.124	✓
DETR3D (Ours) #	0.479	0.412	0.641	0.255	0.394	0.845	0.133	-

4.3 重叠区域对比

重叠区域是一个巨大挑战, 因为目标更容易被截断。本文方法同时考虑所有相机, 而 FCOS3D 则逐相机独立预测边界框。为进一步展示融合推理的优势, 计算落入相机重叠区域的边界框的评估指标。具体而言, 选择 3D 中心被多个相机可见的框。在验证集上, 共有 18,147 个这样的框, 占总数的 9.7

4.4 与伪激光雷达方法对比

另一种执行 3D 目标检测的方式是使用深度预测模型从多视角图像生成伪激光雷达点云。在 nuScenes 数据集上, 没有公开可用的伪激光雷达工作可供直接比较。因此, 自行实现一个基线方法以验证本文方法优于显式深度预测。使用预训练的 PackNet [6] 网络从所有六个相机预测密集深度图, 然后使用相机变换将这些深度图转换为点云。还尝试了带有速度监督的自监督 PackNet 模型 (如原始论文所述), 但发现真值深度监督能生成更真实的点云, 因此使用有监督模型作为基线。对于 3D 检测, 采用最近提出的 CenterPoint 架构 [41]。从概念上讲, 该流程是伪激光雷达 (Pseudo-LiDAR) [42] 的一个变体。表 4 展示了结果; 即使深度估计由当前最优模型生成, 该伪激光雷达方法仍显著不如本文方法。一个可能的解释是, 伪激光雷达目标检测器受到不准确深度预测引入的累积误差的影响, 而深度预测本身容易过拟合训练数据且对其他数据分布泛化能力差 [7]。

4.5 消融实验与分析

图 2 可视化了目标查询的优化过程。可视化了每一层从目标查询解码出的边界框。随着模型层数加深, 预测边界框逐渐逼近真值。左侧子图展示了从所有数据中学习到的共享目标查询先验。表 5 提供了定量结果, 表明迭代优化确实显著提升了性能。这表明迭代优化对于充分利用本文提出的架构既有益又必要。此外, 表 6 提供了目标查询数量的消融实验; 增加查询数量持续提升性能, 直到在 900 个查询时饱和。最后, 表 7 展示了不同骨干网络的结果。

图 3 还提供了定性结果, 以便直观理解模型性能。将预测的边界框投影到 6 个相机视图以及 BEV 视角中。总体而言, 本文方法生成了合理的结果, 甚至能检测到相对较小的目标。然

表 3: 重叠区域对比。‡: 该模型使用深度权重 1.0 训练, 并从 FCOS3D 检查点初始化; 该检查点在同一数据集上使用深度权重 0.2 训练。详见 [2]。†: 本文方法同样从 FCOS3D 骨干网络初始化; 检测头随机初始化。

方法	NDS ↑	mAP ↑	mATE ↓	mASE ↓	mAOE ↓	mAVE ↓	mAAE ↓	NMS
FCOS3D	0.317	0.213	0.841	0.276	0.604	1.122	0.173	✓
FCOS3D‡	0.329	0.229	0.816	0.272	0.571	1.084	0.195	✓
DETR3D (Ours)	0.356	0.231	0.825	0.280	0.400	0.863	0.223	-
DETR3D (Ours) †	0.384	0.268	0.807	0.273	0.453	0.788	0.184	-

表 4: 与伪激光雷达方法对比。

方法	NDS ↑	mAP ↑	mATE ↓	mASE ↓	mAOE ↓	mAVE ↓	mAAE ↓	NMS
pseudo-LiDAR	0.160	0.048	-	-	-	-	-	✓
DETR3D (Ours)	0.374	0.303	0.860	0.278	0.437	0.967	0.235	-




图 2: DETR3D 头中第 1 层到第 5 层的检测结果。在 BEV 中可视化边界框, 并叠加来自 lidar_top 的点云。随着层数加深, 预测逐渐接近真值。

而, 本文方法仍然存在显著的平移误差 (与表 4.2 的结果一致): 尽管模型避免了显式深度预测, 深度估计仍然是该问题的核心挑战。

5 结论

本文提出了一种解决从 2D 图像恢复 3D 信息这一不适定逆问题的新范式。在该设定下, 输入信号缺乏必要信息, 模型必须借助从数据中学习到的先验才能做出有效预测。其他方法要么仅在 2D 空间中进行计算, 要么使用额外的深度网络重建场景, 而本文方法在 3D 空间中操作, 并通过反向投影按需获取图像特征。本文方法有两个优势: (1) 消除了中间层表示 (如预测的深度图或点云), 这些表示可能成为累积误差的来源; (2) 通过将同一 3D 点投影到所有可用帧, 利用多相机信息。

表 5: 不同层检测结果的评估。

层数 $\uparrow$	NDS $\uparrow$	mAP $\uparrow$	mATE $\downarrow$	mASE $\downarrow$	mAOE $\downarrow$	mAVE $\downarrow$	mAAE $\downarrow$
0	0.380	0.302	0.855	0.280	0.435	0.910	0.231
1	0.410	0.335	0.791	0.275	0.408	0.887	0.217
2	0.420	0.343	0.782	0.271	0.395	0.851	0.214
3	0.420	0.346	0.778	0.268	0.390	0.874	0.218
4	0.424	0.346	0.777	0.268	0.389	0.855	0.217
5	0.425	0.346	0.773	0.268	0.383	0.842	0.216

表 6: 不同查询数量的结果。

查询数量	30	100	300	600	900	1200	1500
mAP $\uparrow$	0.201	0.313	0.338	0.347	0.346	0.340	0.346
NDS $\uparrow$	0.331	0.408	0.415	0.420	0.425	0.415	0.420




图 3: DETR3D 预测结果的可视化，包括 BEV 和图像视图。本文模型能够检测相当小的目标，甚至包括未标注为真值的目标（CAM_BACK_LEFT 中的车辆）。一些失败案例包括 CAM_FRONT 中远处的车辆未被检测到。

除了直接应用于自动驾驶 3D 目标检测外，本文工作还有几个值得未来探索的方向。例如，单点投影在检索到的图像特征图中产生有限的感受野，为每个目标查询采样多个点将为目标优化融入更多信息。此外，新检测头与输入模态无关，引入激光雷达（LiDAR）/雷达（RADAR）等其他模态将增强性能和鲁棒性。最后，将本文流程推广到室内导航和物体操作等其他领域，将扩大其应用范围并揭示更多改进方向。

表 7: 不同骨干网络的结果。

骨干网络 $\uparrow$	NDS $\uparrow$	mAP $\uparrow$	mATE $\downarrow$	mASE $\downarrow$	mAOE $\downarrow$	mAVE $\downarrow$	mAAE $\downarrow$
ResNet50	0.373	0.302	0.811	0.282	0.493	0.979	0.212
ResNet101	0.425	0.346	0.773	0.268	0.383	0.842	0.216
DLA34	0.394	0.312	0.829	0.276	0.450	0.844	0.221

参考文献

- [1] X. Zhou, D. Wang, and P. Krähenbühl. Objects as points. *ArXiv*, abs/1904.07850, 2019.
- [2] T. Wang, X. Zhu, J. Pang, and D. Lin. FCOS3D: Fully convolutional one-stage monocular 3d object detection. *arXiv:2104.10956*, 2021.
- [3] Z. Tian, C. Shen, H. Chen, and T. He. FCOS: Fully convolutional one-stage object detection. In *Proc. Int. Conf. Computer Vision (ICCV)*, 2019.
- [4] C. Godard, O. Mac Aodha, M. Firman, and G. J. Brostow. Digging into self-supervised monocular depth prediction. In *ICCV*, 2019.
- [5] J. H. Lee, M.-K. Han, D. W. Ko, and I. H. Suh. From big to small: Multi-scale local planar guidance for monocular depth estimation. *arXiv:1907.10326*, 2019.
- [6] V. Guizilini, R. Ambrus, S. Pillai, A. Raventos, and A. Gaidon. 3d packing for self-supervised monocular depth estimation. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [7] A. Simonelli, S. Rota Bulò, L. Porzi, P. Kotschieder, and E. Ricci. Demystifying pseudo-lidar for monocular 3d object detection, 12 2020.
- [8] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *The IEEE Conference on Computer Vision and Pattern Recognition Recognition (CVPR)*, 2016.
- [9] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [10] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko. End-to-end object detection with transformers. In *ECCV*, 2020.
- [11] Anonymous. Object dgcnn: 3d object detection using dynamic graphs. 2021.
- [12] R. Girshick, J. Donahue, T. Darrell, and J. Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2014.
- [13] S. Ren, K. He, R. Girshick, and J. Sun. Faster R-CNN: Towards real-time object detection with region proposal networks. In *Neural Information Processing Systems (NeurIPS)*, 2015.
- [14] K. He, G. Gkioxari, P. Dollár, and R. Girshick. Mask R-CNN. In *The International Conference on Computer Vision (ICCV)*, 2017.
- [15] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg. SSD: Single shot multibox detector. In *The European Conference on Computer Vision (ECCV)*, 2016.
- [16] J. Redmon, S. K. Divvala, R. B. Girshick, and A. Farhadi. You only look once: Unified, real-time object detection. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [17] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai. Deformable {detr}: Deformable transformers for end-to-end object detection. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=gZ9hCDWe6ke>.

- [18] Z. Sun, S. Cao, Y. Yang, and K. Kitani. Rethinking transformer-based set prediction for object detection. *ArXiv*, abs/2011.10881, 2020.
- [19] P. Sun, R. Zhang, Y. Jiang, T. Kong, C. Xu, W. Zhan, M. Tomizuka, L. Li, Z. Yuan, C. Wang, and P. Luo. SparseR-CNN: End-to-end object detection with learnable proposals. *arXiv:2011.12450*, 2020.
- [20] P. Sun, Y. Jiang, E. Xie, Z. Yuan, C. Wang, and P. Luo. OneNet: Towards end-to-end one-stage object detection. *arXiv: 2012.05780*, 2020.
- [21] X. Chen, K. Kundu, Z. Zhang, H. Ma, S. Fidler, and R. Urtasun. Monocular 3d object detection for autonomous driving. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2147–2156, 2016.
- [22] T. Roddick, A. Kendall, and R. Cipolla. Orthographic feature transform for monocular 3d object detection. *arXiv:1811.08188*, 2018.
- [23] A. Mousavian, D. Anguelov, J. Flynn, and J. Kosecka. 3d bounding box estimation using deep learning and geometry. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7074–7082, 2017.
- [24] W. Kehl, F. Manhardt, F. Tombari, S. Ilic, and N. Navab. Ssd-6d: Making rgb-based 3d detection and 6d pose estimation great again. In *Proceedings of the IEEE international conference on computer vision*, pages 1521–1529, 2017.
- [25] J. Ku, A. D. Pon, and S. L. Waslander. Monocular 3d object detection leveraging accurate proposals and shape reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11867–11876, 2019.
- [26] D. Beker, H. Kato, M. A. Morariu, T. Ando, T. Matsuoka, W. Kehl, and A. Gaidon. Monocular differentiable rendering for self-supervised 3d object detection. *arXiv:2009.14524*, 2020.
- [27] I. Barabanau, A. Artemov, E. Burnaev, and V. Murashkin. Monocular 3d object detection via geometric reasoning on keypoints. *arXiv:1905.05618*, 2019.
- [28] Z. Liu, Z. Wu, and R. Tóth. Smoke: single-stage monocular 3d object detection via keypoint estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 996–997, 2020.
- [29] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie. Feature pyramid networks for object detection. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [30] R. Stewart, M. Andriluka, and A. Y. Ng. End-to-end people detection in crowded scenes. In *2016 IEEE Conference on Computer Vision and Pattern Recognition CVPR*, pages 2325–2333. IEEE Computer Society, 2016. doi:10.1109/CVPR.2016.255. URL <https://doi.org/10.1109/CVPR.2016.255>.
- [31] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár. Focal Loss for Dense Object Detection. In *The International Conference on Computer Vision (ICCV)*, 2017.
- [32] H. W. Kuhn and B. Yaw. The hungarian method for the assignment problem. *Naval Res. Logist. Quart.*, pages 83–97, 1955.
- [33] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom. nuscenes: A multimodal dataset for autonomous driving. *arXiv:1903.11027*, 2019.

- [34] J. Dai, H. Qi, Y. Xiong, Y. Li, G. Zhang, H. Hu, and Y. Wei. Deformable convolutional networks. In *The International Conference on Computer Vision (ICCV)*, 2017.
- [35] L. J. Ba, J. R. Kiros, and G. E. Hinton. Layer normalization. *CoRR*, 2016.
- [36] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=Bkg6RiCqY7>.
- [37] D. Park, R. Ambrus, V. Guizilini, J. Li, and A. Gaidon. Is pseudo-lidar needed for monocular 3d object detection? In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [38] F. Yu, D. Wang, E. Shelhamer, and T. Darrell. Deep layer aggregation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018.
- [39] B. Zhu, Z. Jiang, X. Zhou, Z. Li, and G. Yu. Class-balanced Grouping and Sampling for Point Cloud 3D Object Detection. *arXiv e-prints*, art. arXiv:1908.09492, Aug 2019.
- [40] T. Wang, X. ZHU, J. Pang, and D. Lin. Probabilistic and geometric depth: Detecting objects in perspective. In *5th Annual Conference on Robot Learning*, 2021. URL <https://openreview.net/forum?id=bEito8UUUmf>.
- [41] T. Yin, X. Zhou, and P. Krähenbühl. Center-based 3d object detection and tracking. *CVPR*, 2021.
- [42] Y. Wang, W.-L. Chao, D. Garg, B. Hariharan, M. Campbell, and K. Weinberger. Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving. In *CVPR*, 2019.