

基于扩散的自动驾驶规划与灵活引导

Yinan Zheng^{1*}, Ruiming Liang^{2*†}, Kexin Zheng^{3*†}, Jinliang Zheng¹, Liyuan Mao^{4‡},
Jianxiong Li¹, Weihao Gu⁵, Rui Ai⁵, Shengbo Eben Li¹, Xianyu Zhan^{1,6†}, Jingjing Liu^{1†}

¹ Tsinghua University ² Institute of Automation, Chinese Academy of Sciences

³ The Chinese University of Hong Kong ⁴ Shanghai Jiao Tong University

⁵ HAOMO.AI ⁶ Shanghai Artificial Intelligence Laboratory

zhengyn23@mails.tsinghua.edu.cn, zhanxianyu@air.tsinghua.edu.cn

ABSTRACT

在复杂开放世界环境中实现拟人化驾驶行为是自动驾驶面临的关键挑战。现有基于学习的规划方法（如模仿学习方法）常难以权衡相互冲突的目标，缺乏安全保障：原因是适应性有限，难以学习人类规划中常见的复杂多模态行为，更不必说严重依赖带预定义规则的回退策略（Fallback Strategy）。本文提出基于 Transformer 的扩散规划器（*Diffusion Planner*），用于闭环规划（Closed-loop Planning），无需任何基于规则的精细化即可有效建模多模态驾驶行为并保证轨迹质量。模型在同一架构下联合建模预测与规划任务，实现车辆间的协作行为。此外，通过学习轨迹分数函数（Score Function）的梯度并采用灵活的分类器引导机制，扩散规划器有效实现安全且可自适应的规划行为。在大型真实自动驾驶规划基准 nuPlan 及新收集的 200 小时配送车辆（Delivery-vehicle）驾驶数据集上的评估表明，扩散规划器在多样驾驶风格下取得最优闭环性能，具备稳健的可迁移性（Transferability）。项目网站：<https://zhengynan-air.github.io/Diffusion-Planner/>。

1 引言

自动驾驶作为基石性技术，有望推动交通迈向更安全、更高效的出行时代 (Tampuu et al., 2020)。核心挑战在于复杂开放世界环境中实现拟人化驾驶 (Human-like Driving) 行为，同时保证安全、效率与舒适性 (Muhammad et al., 2020)。基于规则 (Rule-based) 的规划方法通过人工知识定义驾驶行为并划定边界，在工业应用中已取得初步成功 (Fan et al., 2018)，但对预定义规则的依赖限制了其应对新交通场景的适应性 (Hawke et al., 2020)，修改规则也需大量工程投入。相比之下，基于学习 (Learning-based) 的规划方法通过行为克隆 (Behavior Cloning) 从采集数据集中学习驾驶技能 (Caesar et al., 2021)，直接的模仿学习 (Imitation Learning) 损失使该过程更易实现。此外，扩大训练资源还可进一步提升模型能力 (Chen et al., 2023)。

尽管前景广阔，现有基于学习的规划方法仍面临若干局限。首先，人类驾驶员在规划场景中常表现出多模态 (Multi-modal) 行为 (Nayakanti et al., 2023)，而依赖行为克隆的现有方法即使采用大型 Transformer 架构或采样多条轨迹，也无法保证拟合此类复杂数据分布 (Cheng et al., 2023)。其次，遇到分布外 (Out-of-Distribution, OOD) 场景时，直接使用模型输出可能产生低质量规划结果，迫使许多方法退回基于规则的轨迹精细化或筛选 (Vitelli et al., 2022; Huang et al., 2023)，不可避免地遭遇与基于规则方法相同的固有局限。第三，仅靠模仿学习难以覆盖自动驾驶所需的多样化驾驶行为。例如，现有方法 (Bansal et al., 2018; Cheng et al., 2024) 通过辅助损失惩罚不安全规划，但缺乏教会智能体从错误中恢复的学习信号 (Zheng et al., 2024; Chen et al., 2021)，常导致多目标冲突与较差的安全表现。此外，训练良好的模型也难以调整行为以满足特定需求。

本文发现，扩散模型 (Diffusion Model) (Ho et al., 2020) 在解决上述问题上潜力巨大。其建模复杂数据分布的能力 (Chi et al., 2023) 可有效捕获多模态的人类驾驶行为；高质量生成能力也提供了通过合理结构设计提升输出轨迹质量、摆脱对基于规则精细化依赖的机会。扩散模型最突出的优点在于灵活的引导机制 (Guidance Mechanism) (Dhariwal & Nichol,

*同等贡献。

†通讯作者。

‡本工作在清华大学人工智能产业研究院 (AIR) 实习期间完成。

2021), 无需额外训练即可适应各种规划行为需求。受上述观察启发, 本文提出基于学习的扩散规划器 (*Diffusion Planner*), 开创性地将扩散模型 (Ho et al., 2020) 用于提升闭环规划性能, 且不依赖任何基于规则的精化。扩散规划器通过学习车辆轨迹分数函数的梯度 (Song & Ermon, 2019) 建模多模态数据分布, 并通过分类器引导机制实现个性化规划行为适配。具体而言, 本文在扩散 Transformer (Diffusion Transformer, DiT) (Peebles & Xie, 2023) 基础上提出新的网络架构, 采用扩散损失在同一架构内联合训练预测与规划任务, 无需额外损失函数即可实现车辆间的协作行为。此外, 分类器引导的通用性还体现在可修改训练模型的规划行为, 如增强安全性与舒适性、控制车速等; 可微 (Differentiable) 的分类器分数可并行计算、灵活组合, 且无需额外训练。在大型真实自动驾驶规划基准 nuPlan (Caesar et al., 2021) 上的评估表明, 扩散规划器直接使用模型输出 (无任何后处理 (Post-processing)) 即取得基于学习基线中的最优闭环性能, 可与基于规则方法相媲美甚至更优。在模型后附加现有后处理模块后, 进一步在所有基线中达到最优性能。此外, 本文收集了 200 小时覆盖多种城市场景的长期配送车辆驾驶数据, 进一步验证了模型在多样驾驶风格下的可迁移性与鲁棒性 (Robustness)。

综上, 本文贡献如下:

- 据我们所知, 本文首次以专门设计的架构充分发挥扩散模型在高效运动规划上的潜力, 且不过度依赖基于规则的精化。
- 在真实 nuPlan 数据集上取得最优性能, 生成相比基线更鲁棒、更平滑的轨迹。
- 通过灵活的引导机制, 模型可在运行时实现个性化驾驶行为, 这是实际应用所需的重要特性。
- 收集并评估了新的 200 小时配送车辆数据集, 兼容 nuPlan 框架, 并计划开源。

2 相关工作

基于规则规划器。基于规则方法依赖预定义规则决定自动驾驶车辆的驾驶行为, 提供高度可控、可解释的决策过程 (Treiber et al., 2000a; Fan et al., 2018; Dauner et al., 2023a)。尽管已在真实场景中得到广泛验证 (Leonard et al., 2008; Urmson et al., 2008), 此类框架应对超出预定义规则的新复杂情况的能力仍然有限。

基于学习规划器。基于学习规划侧重利用模仿学习中的行为克隆等方法直接建模人类驾驶行为, 已成为自动驾驶中的主流方案, 尤其在近期的端到端训练流程 (Hu et al., 2023; Tampuu et al., 2020; Chen et al., 2023) 中。行为克隆最初基于 CNN (Bojarski et al., 2016; Kendall et al., 2019; Hawke et al., 2020) 或 RNN (Bansal et al., 2018) 网络实现, 后因 Transformer 在拟合复杂数据分布上性能强、效率高, 已扩展至 Transformer 架构 (Scheel et al., 2021; Chitta et al., 2022)。然而, 这些方法缺乏建模多模态驾驶行为的理论保证, 可能在闭环规划中造成严重误差累积。因此, 大多数现有方法仍严重依赖规则来精化 (Vitelli et al., 2022; Huang et al., 2023) 或筛选 (Cheng et al., 2024) 生成轨迹, 这在一定程度上背离了用学习替代预定义规则的初衷。基于学习方法虽能提供更拟人的驾驶行为, 但输出不可控、缺乏安全保证, 且难以按用户需求调整。现有方法通过增加额外训练损失 (Bansal et al., 2018; Cheng et al., 2024) 改善, 却难以在相互竞争的学习目标间取得平衡。此外, 这些方法还缺乏灵活性, 难以在训练后调整行为。实际应用中, 期望训练好的规划模型在推理时灵活对齐各种安全与个性化驾驶偏好, 现有文献尚缺此类能力。针对上述局限, 本文开发新的扩散规划器, 无需基于规则精化即可生成高质量规划轨迹, 并通过扩散引导机制实现训练后对不同驾驶风格的灵活适配。

相关领域中的基于扩散方法。扩散模型近年已在决策领域得到探索 (Janner et al., 2022; Chi et al., 2023; Liu et al., 2025), 但在自动驾驶规划中的应用尚未充分研究。部分现有工作将扩散模型用于运动预测 (Jiang et al., 2023) 和交通仿真 (Zhong et al., 2023b;a), 但其关注点在于开环 (Open-loop) 性能或仿真多样性, 而非轨迹质量与可行驶性, 因为输出不直接用于控制。也有研究直接面向规划 (Hu et al., 2024; Yang et al., 2024; Sun et al., 2023), 但仅将扩散损失应用于现有框架或堆叠参数, 缺乏针对性设计, 合理性能高度依赖后处理。本文证明, 通过合理的结构设计可充分发挥扩散模型潜力, 提升自动驾驶中的闭环规划性能。

3 预备知识

3.1 自动驾驶与闭环规划

自动驾驶的首要目标是让车辆在最少人工干预下穿越复杂环境，其中关键挑战在于闭环规划 (Caesar et al., 2021)。与仅需适应静态条件决策的开环规划 (Caesar et al., 2019) 或运动预测 (Ngiam et al., 2021; Zhou et al., 2023) 不同，闭环规划要求实时感知 (Real-time Perception)、预测与控制的无缝集成：车辆须持续评估周围环境、预测其他邻居车辆的行为并执行精确操作。真实驾驶场景的动态特性，加上传感器数据与环境因素的不确定性，使闭环规划成为一项艰巨任务。

3.2 扩散模型与引导方案

扩散模型。扩散概率模型 (Diffusion Probabilistic Models) (Sohl-Dickstein et al., 2015; Ho et al., 2020) 是一类生成模型 (Generative Model)，通过逆转称为前向扩散过程 (Forward Diffusion Process) 的马尔可夫链 (Markov Chain) 过程生成输出。前向过程的转移分布满足：

$$q_{t0}(\mathbf{x}^{(t)}|\mathbf{x}^{(0)}) = \mathcal{N}(\mathbf{x}^{(t)} | \alpha_t \mathbf{x}^{(0)}, \sigma_t^2 \mathbf{I}), t \in [0, 1], \quad (1)$$

该过程逐步添加高斯噪声 (Gaussian Noise)，从 $\mathbf{x}^{(0)}$ 生成 $t \in [0, 1]$ 范围内的一系列带噪数据 $\mathbf{x}^{(t)}$ 。 $\sigma_t > 0$ 为控制所引入噪声的方差项， $\alpha_t > 0$ 通常定义为 $\alpha_t = \sqrt{1 - \sigma_t^2}$ ，确保当 $t \rightarrow 1$ 时 $\mathbf{x}^{(t)} \rightarrow \mathcal{N}(0, \mathbf{I})$ 。式 (1) 的逆向去噪过程 (Denoising Process) 可等价表示为扩散常微分方程 (ODE) (Song et al., 2021)：

$$(\text{Diffusion ODE}) \quad d\mathbf{x}^{(t)} = \left[f(t)\mathbf{x}^{(t)} - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}^{(t)}} \log q_t(\mathbf{x}^{(t)}) \right] dt, \quad (2)$$

其中 $f(t) = \frac{d \log \alpha_t}{dt}$, $g^2(t) = \frac{d\sigma_t^2}{dt} - 2 \frac{d \log \alpha_t}{dt} \sigma_t^2$ 由固定的噪声调度 (Noise Schedule) α_t, σ_t 决定， q_t 为 $\mathbf{x}^{(t)}$ 的边缘分布 (Marginal Distribution)。扩散模型利用神经网络 $s_\theta(\mathbf{x}^{(t)}, t)$ 拟合概率分数 $\nabla_{\mathbf{x}^{(t)}} \log q_t(\mathbf{x}^{(t)})$ 。通过学习分数函数，扩散模型具备建模任意复杂分布的强大表达能力 (Chi et al., 2023)，在自动驾驶等挑战性任务中展现出高度通用性与适应性。

分类器引导。分类器引导 (Dhariwal & Nichol, 2021) 是一种通过分类器 $\mathcal{E}_\phi(\mathbf{x}^{(t)}, t)$ 引导采样过程以生成偏好数据的技术，利用分类器分数的梯度修正原始扩散分数：

$$\tilde{s}_\theta(\mathbf{x}^{(t)}, t) = s_\theta(\mathbf{x}^{(t)}, t) - \nabla_{\mathbf{x}^{(t)}} \mathcal{E}_\phi(\mathbf{x}^{(t)}, t) \quad (3)$$

在自动驾驶中，该方法比基于规则的精化更灵活，因为它直接提升模型自身能力，而非过度依赖需要大量人工与针对性数据收集的次优后处理。

4 方法论

本节将规划任务重新定义为未来轨迹生成任务，联合生成自车规划与邻居车辆预测。随后介绍扩散规划器——一种利用扩散模型强表达力与灵活性增强自动驾驶规划的新方法。最后展示如何利用扩散模型中的引导机制，将规划行为对齐到安全或符合人类偏好的驾驶风格。

4.1 任务重定义

自动驾驶需要考虑自车与邻居车辆之间的紧密交互，使规划与运动预测任务之间形成协作关系 (Ngiam et al., 2021)。对邻居车辆未来轨迹的监督已证明有助于增强闭环规划模型处理复杂交互场景的能力 (Hu et al., 2023)。在实际部署中，运动预测还能提供更可控的手段以增强安全性，便于系统落地 (Fan et al., 2018)。因此，邻居车辆轨迹已成为模型训练中关键的特权信息 (Privileged Information)。然而，常见的做法——使用专门子模块 (Huang et al., 2023) 或额外损失设计 (Cheng et al., 2023; Huang et al., 2023) 来利用该特权信息——限制了训练时的建模能力，也使框架更加复杂。

针对上述问题，本文综合考虑驾驶场景中关键参与者的状态，将运动预测与闭环规划任务联合建模为未来轨迹生成任务。具体而言，给定包含当前车辆状态、历史数据、车道信息与导航信息的条件 C ，同时生成所有关键参与者的未来轨迹，以建模参与者之间的协作行为。




图 1: 扩散规划器的模型架构。

然而，这种复杂分布的联合建模难以用简单的行为克隆方法解决。借助扩散模型强大的表达能力，本文采用扩散模型完成该任务，优化目标表述为：

$$\mathbf{x}^{(0)} = \begin{bmatrix} x_{\text{ego}}^{(0)} \\ x_{\text{neighbor}_1}^{(0)} \\ \vdots \\ x_{\text{neighbor}_M}^{(0)} \end{bmatrix} = \begin{bmatrix} x_{\text{ego}}^1 & x_{\text{ego}}^2 & \dots & x_{\text{ego}}^\tau \\ x_{\text{neighbor}_1}^1 & x_{\text{neighbor}_1}^2 & \dots & x_{\text{neighbor}_1}^\tau \\ \vdots & \vdots & \ddots & \vdots \\ x_{\text{neighbor}_M}^1 & x_{\text{neighbor}_M}^2 & \dots & x_{\text{neighbor}_M}^\tau \end{bmatrix}, \quad (4)$$

其中括号上标表示扩散去噪的时间线，普通上标表示未来轨迹的时间线，轨迹含 τ 个时间步。对每个状态 x ，仅考虑坐标与航向角（Heading Angle）的正弦、余弦值，这对下游 LQR 控制器已足够。选取最近的 M 辆邻居车辆预测其可能的未来轨迹。用 θ 参数化扩散规划器后，训练目标表示为：

$$\mathcal{L}_\theta = \mathbb{E}_{\mathbf{x}^{(0)}, t \sim \mathcal{U}(0,1), \mathbf{x}^{(t)} \sim q_{t0}(\mathbf{x}^{(t)} | \mathbf{x}^{(0)})} \left[\|\mu_\theta(\mathbf{x}^{(t)}, t, \mathbf{C}) - \mathbf{x}^{(0)}\|^2 \right], \quad (5)$$

其目标是从带噪数据中恢复数据分布 (Ramesh et al., 2022)。分数函数可由 $\mathbf{s}_\theta = (\alpha_t \mu_\theta - \mathbf{x}^{(t)}) / \sigma_t^2$ 得到，并用于去噪过程。多车辆联合预测与运动预测 (Jiang et al., 2023)、交通仿真 (Zhong et al., 2023b;a) 任务类似，但本文更关注自车的闭环规划性能与实时部署。下面介绍具体设计。

4.2 扩散规划器

扩散规划器基于 DiT 架构 (Peebles & Xie, 2023) 构建，核心设计聚焦于带噪未来车辆轨迹 $\mathbf{x}$ 与条件信息 $\mathbf{C}$ 之间的融合机制。图 1 给出完整架构概览，下面详细介绍各交互与融合模块。

车辆信息集成。 第一步将未来车辆轨迹 $\mathbf{x}$ 与每辆车当前状态拼接，表示为 $\mathbf{x}^0 = [x_{\text{ego}}^0, x_{\text{neighbor}_1}^0, \dots, x_{\text{neighbor}_M}^0]^T$ 。拼接作为约束引导模型，提供明确起点以简化规划任务。值得注意的是，自车速度与加速度信息被排除在外，已有工作 (Cheng et al., 2023; Li et al., 2024) 表明这能提升闭环性能。模型运行中，不同车辆信息的集成通过多头自注意力 (Multi-head Self-attention) 机制完成。

历史状态与车道信息融合。 邻居车辆历史状态与车道信息用向量表示 (Gao et al., 2020)。具体而言，每辆邻居车辆表示为 $\mathbf{s}_{\text{neighbor}} \in \mathbb{R}^{L \times D_{\text{neighbor}}}$ ，车道表示为 $\mathbf{s}_{\text{lane}} \in \mathbb{R}^{P \times D_{\text{lane}}}$ ，其中 L 为历史时间戳数量， P 为每条折线 (Polyline) 的点数。 D_{neighbor} 包含车辆坐标、航向、速度、尺寸与类别等数据， D_{lane} 提供坐标、交通信号灯 (Traffic Light) 状态、限速 (Speed Limit) 等车道信息。这些向量信息稀疏，直接融合会使训练困难。为此，使用 MLP-Mixer 网络 (Tolstikhin et al., 2021) 提取信息密集的表达。相比采用复杂结构设计的

现有工作 (Huang et al., 2023; Cheng et al., 2023), 本文方案更统一、更简洁: 将向量反复经过同时在向量维与特征维上操作的 MLP 混合层。每层混合层的前向过程可表示为:

$$\mathbf{S} = \mathbf{S} + \text{MLP}(\mathbf{S}^T)^T, \mathbf{S} = \mathbf{S} + \text{MLP}(\mathbf{S}) \quad (6)$$

邻居车辆与车道各使用一个独立的 MLP-Mixer 网络。此处 $\mathbf{S}$ 表示每辆邻居车辆或每条车道的特征。经过多个混合层后, 沿向量维对最终输出进行池化 (Pooling)。同时考虑静态物体 (Static Object) 信息 $\mathbf{S}_{\text{static}} \in \mathbb{R}^{D_{\text{static}}}$, D_{static} 包含坐标、航向、尺寸与类别等数据, 用 MLP 提取其表示。最后拼接所有表示并输入普通 Transformer 编码器进一步聚合, 得到编码器表示 $\mathbf{Q}_f$ 。 $\mathbf{Q}_f$ 与 $\mathbf{x}$ 的融合过程如下:

$$\mathbf{x} = \mathbf{x} + \text{MHCA}(\mathbf{x}, \mathbf{Q}_f), \mathbf{x} = \mathbf{x} + \text{FFN}(\mathbf{x}), \quad (7)$$

其中 MHCA 表示多头交叉注意力 (Multi-head Cross-attention)。

导航信息融合。导航信息对自动驾驶规划至关重要, 提供预期路线的关键引导, 使车辆能做出明智决策。在 nuPlan 基准 (Caesar et al., 2021) 中, 导航信息表示为沿路线的一组车道 $\mathbf{S}_{\text{route}} \in \mathbb{R}^{(K \times P) \times D_{\text{route}}}$, 其中 K 为路线车道数, D_{route} 仅包含坐标信息。首先按式 6 使用 MLP-Mixer 网络提取关键引导表示 $\mathbf{Q}_n$ 。随后将 $\mathbf{Q}_n$ 与扩散时间步条件 $\mathbf{Q}_t$ 相加, 经自适应层归一化 (Adaptive Layer Norm) 块 (Peebles & Xie, 2023) 作用于所有词元, 引导轨迹生成。

4.3 通过分类器引导对齐规划行为

多样且可控的驾驶行为对真实世界自动驾驶至关重要。例如, 车辆须在调节速度以符合用户偏好的同时保证安全与舒适性。借助与基于能量的模型 (Energy-Based Models) (Lu et al., 2023) 的紧密联系, 扩散模型可通过分类器引导便捷地注入此类偏好。在推理期间通过梯度修正引导模型输出, 为定制化适配提供巨大潜力。

具体而言, 给定原始驾驶行为 $q_0(\mathbf{x}^{(0)})$, 目标是在现有行为 q_0 之上编码额外引导, 强化某些偏好行为。该操作可表述为生成目标行为: $p_0(\mathbf{x}^{(0)}) \propto q_0(\mathbf{x}^{(0)})e^{-\mathcal{E}(\mathbf{x}^{(0)})}$, 其中 $\mathcal{E}(\mathbf{x}^{(0)})$ 为编码安全性或偏好行为的某种能量函数 (Energy Function)。如第 3.2 节所述, 利用中间能量的梯度 (Lu et al., 2023) 修正原始概率分数, 促进生成落在目标分布内的轨迹。该过程通常需要额外训练的分类器提供精确近似。而扩散后验采样 (Diffusion Posterior Sampling, DPS) (Chung et al., 2022; Xu et al., 2025) 提供免训练 (Training-free) 方法, 仅使用式 (5) 中训练好的扩散模型 μ_θ 近似引导能量, 省去带来额外计算开销的分类器训练:

$$\begin{aligned} \nabla_{\mathbf{x}^{(t)}} \log p_t(\mathbf{x}^{(t)}) &\approx \nabla_{\mathbf{x}^{(t)}} \log q_t(\mathbf{x}^{(t)}) - \nabla_{\mathbf{x}^{(t)}} \mathcal{E} \left(\mathbb{E}_{q_{0:t}(\mathbf{x}^{(0)}|\mathbf{x}^{(t)})}[\mathbf{x}^{(0)}] \right) \\ &= \nabla_{\mathbf{x}^{(t)}} \log q_t(\mathbf{x}^{(t)}) - \nabla_{\mathbf{x}^{(t)}} \mathcal{E} \left(\mu_\theta(\mathbf{x}^{(t)}, t, \mathbf{C}) \right). \end{aligned} \quad (8)$$

该方法的一个限制是, 式 (8) 需使用预定义的可微能量函数 $\mathcal{E}(\cdot)$ 计算引导能量。幸运的是, 自动驾驶场景中的许多轨迹评估方案可定义为可微函数。下面简要介绍可用于定制模型规划行为的能量函数, 更多细节见附录 C.3。

- **目标速度维持 (Target Speed Maintenance):** 以速度差作为能量, 通过比较规划平均速度与设定的目标速度计算得到。
- **舒适性 (Comfort):** 通过衡量车辆状态超出预定义限制的程度计算能量函数。
- **碰撞避免 (Collision Avoidance):** 在每个时间戳计算自车与邻居车辆间的有符号距离 (Signed Distance)。
- **保持在可行驶区域内 (Staying within Drivable Area):** 计算每个时间步自车偏离车道的距离。

此外, 该免训练方法支持推理时灵活组合, 为复杂场景中的可控轨迹生成提供解决方案。例如, 如图 2 所示, 仅使用碰撞引导时, 自车为避让后方来车而驶离道路; 加入可行驶引导后, 车辆在保持安全的同时留在道路上。更多案例分析见第 5.1 节与附录 B.2。




图 2: 从相同起点出发、在不同引导设置下行驶的轨迹。

表 1: nuPlan 数据集上的闭环规划结果。■：各类基线中的最高分数。*：使用预搜索参考线作为模型输入提供先验知识，相比标准基于学习方法降低了规划难度。NR：非反应式模式。R：反应式模式。

类型	规划器	Val14		Test14-hard		Test14	
		NR	R	NR	R	NR	R
专家	日志回放	93.53	80.32	85.96	68.80	94.03	75.86
基于规则 & 混合	IDM	75.60	77.33	56.15	62.26	70.39	74.42
	PDM-Closed	92.84	92.12	65.08	75.19	90.05	91.63
	PDM-Hybrid	92.77	92.11	65.99	76.07	90.10	91.28
	GameFormer	79.94	79.78	68.70	67.05	83.88	82.05
	PLUTO	92.88	76.88	80.08	76.88	92.23	90.29
	Diffusion Planner w/ refine. (Ours)	94.26	92.90	78.87	82.00	94.80	91.75
基于学习	PDM-Open*	53.53	54.24	33.51	35.83	52.81	57.23
	UrbanDriver	68.57	64.11	50.40	49.95	51.83	67.15
	GameFormer w/o refine.	13.32	8.69	7.08	6.69	11.36	9.31
	PlanTF	84.27	76.95	69.70	61.61	85.62	79.58
	PLUTO w/o refine.*	88.89	78.11	70.03	59.74	89.90	78.62
	Diffusion Planner (Ours)	89.87	82.80	75.99	69.22	89.19	82.93

表 2: 配送车辆驾驶数据集上的闭环规划结果。

类型	规划器	分数	碰撞	碰撞时间 (TTC)	可行驶	舒适性	进度
基于规则	IDM	75.38	86.00	79.43	99.43	89.14	95.43
	PDM-Closed	80.95	86.51	80.00	100.0	97.21	97.47
混合	PDM-Hybrid	80.72	86.50	77.00	100.0	92.50	99.00
	GameFormer	51.35	82.50	72.50	65.00	98.00	90.00
	PLUTO	83.49	88.95	85.64	99.45	94.47	97.79
基于学习	PDM-Open*	64.84	75.75	70.50	93.50	98.50	95.00
	GameFormer w/o refine.	22.41	62.00	57.50	33.00	98.50	77.00
	PlanTF	90.89	95.00	90.50	99.50	96.00	99.50
	PLUTO w/o refine.	87.77	92.69	87.64	99.44	97.19	98.88
	Diffusion Planner (ours)	92.08	96.00	91.00	100.0	94.00	100.0




图 3: 未来轨迹生成可视化。闭环测试中一个具有挑战性的窄路转弯场景画面，包含自车的未来规划 (PlanTF 与 PLUTO w/o refine. 显示多条候选轨迹)、对邻居车辆的预测以及真值自行车轨迹。

4.4 闭环规划的实践实现

数据增强 (Data Augmentation) 有助于缓解分布外问题，在规划中广泛应用。训练前对当前状态添加随机扰动 (Perturbation) (Cheng et al., 2023)，再通过插值 (Interpolation) 生成物理可行的过渡轨迹，使模型能够抵抗扰动并回归真值轨迹 (Bansal et al., 2018)。随后通过坐标变换将数据从全局坐标系转换到以自行车为中心 (Ego-centric) 的表示。考虑到车辆纵向与横向行驶距离差异显著，采用 z-score 归一化使数据分布均值接近零，进一步稳定训练过程。推理时使用 DPM-Solver (Lu et al., 2022) 加速采样，低温采样 (Low-temperature Sampling) (Ajay et al., 2022) 增强规划过程的不确定性。模型可在 10 Hz 下完成未来 8 秒轨迹规划及邻居车辆预测，推理频率约 20 Hz。实现细节见附录 C。

5 实验

评估设置。本文在大型真实自动驾驶规划基准 nuPlan (Caesar et al., 2021) 上进行广泛评估，将扩散规划器与其他先进规划方法对比。使用 Val14 (Dauner et al., 2023b)、Test14 与 Test14-hard 基准 (Cheng et al., 2023)，所有实验均在闭环非反应式 (Non-reactive) 与反应式 (Reactive) 两种模式下测试。最终分数为所有场景的平均值，范围 0 到 100，分数越高表示算法性能越好。为在不同驾驶场景与驾驶行为下进一步验证算法性能，本文使用 Haomo.AI 的配送车辆收集了 200 小时真实数据。与 nuPlan 不同，配送车辆表现出更保守的规划行为，且在非机动车道行驶，涉及密集的人车交互与独特交通规则。收集的数据集成到 nuPlan 框架中，并采用相同评估指标进行闭环仿真，详见附录 D。

基线。基线分为三类 (Dauner et al., 2023b)：基于规则、基于学习和混合（对基于学习模型的输出附加精化）。为进行更全面的比较，本文使用现有精化模块 (Sun et al., 2024)，对模型输出施加偏移并给所有轨迹打分 (Dauner et al., 2023b)。在不做任何参数调整的情况下，将该模块作为扩散规划器 (*Diffusion Planner w/ refine.*) 的后处理集成。扩散规划器与以下基线进行比较，更多实现细节见附录 C.4。


- *IDM* (Treiber et al., 2000b)：由 nuPlan 实现的经典基于规则方法。
- *PDM* (Dauner et al., 2023b)：nuPlan 挑战赛冠军，提供沿中心线 (Centerline) 行驶的基于规则版本 (*PDM-Closed*)、以参考线 (Reference Line) 为条件的基于学习版本 (*PDM-Open*) 以及二者结合的混合方法 (*PDM-Hybrid*)。
- *UrbanDriver* (Scheel et al., 2021)：使用策略梯度 (Policy Gradient) 优化的基于学习方法，由 nuPlan 实现。
- *GameFormer* (Huang et al., 2023)：利用博弈论 (Game Theory) 建模自车与邻居车辆交互 (*GameFormer w/o refine.*)，随后进行基于规则精化。
- *PlanTF* (Cheng et al., 2023)：基于 Transformer 架构的先进基于学习方法，探索了适合闭环规划的各种设计。
- *PLUTO* (Cheng et al., 2024)：在 *PDM-Open* 基础上构建，通过对比学习 (Contrastive Learning) 增强环境理解的复杂模型 (*PLUTO w/o refine.*)，随后进行后处理。

主要结果。nuPlan 基准上的评估结果见表 1。相比所有基于学习基线，扩散规划器在更多基准上取得最优性能。加入后处理后，*Diffusion Planner w/ refine.* 超越混合与基于规则基线，分数甚至超过人类表现。这源于模型输出高质量轨迹的能力，后处理进一步放大了该优势。值得注意的是，与基于 Transformer 的 *PlanTF* 和 *PLUTO* 相比，扩散规划器借助扩散模型的力量取得了更优性能。*GameFormer* 用博弈论建模自车与邻居车辆的交互，但模型能力有限，过度依赖基于规则的精化。配送车辆驾驶数据集上的规划结果见表 2。*PDM*、*GameFormer* 和 *PLUTO* 包含针对 nuPlan 基准专门设计的结构，限制了向配送车辆驾驶任务的迁移能力，导致性能下降。相比之下，扩散规划器在不同驾驶行为下展现出强可迁移性。此外，本文还与利用扩散进行规划的工作进行了比较，见附录 B.1 的表 4。扩散规划器更充分地利用了扩散模型的强大能力，更具实用性。

定性结果。为进一步展示基于学习模型的能力，图 3 给出代表性基线（无精化）的轨迹生成结果。扩散规划器生成高质量轨迹：对邻居车辆的预测准确，自车规划轨迹平滑且合理考虑前车速度，体现联合建模预测与规划任务的优势。更多闭环规划结果见附录 A。相比之下，*GameFormer w/o refine* 生成的轨迹不够平滑，对邻居车辆的预测也不准确，这解释了其为何严重依赖精化。虽然 *PlanTF* 和 *PLUTO w/o refine.* 一次性采样多条轨迹，但其中大部分质量较低。

5.1 扩散规划器特性的实证研究

多模态规划行为。本文选取一个路口场景，从相同初始位置在无低温采样的条件下进行多次推理，获得不同可能输出，以评估模型拟合多模态驾驶行为的能力。如图 5 所示，无导航信息时，车辆可表现出左转、右转、直行三种差异明显的驾驶行为；提供导航信息后，模型准确遵循导航进行左转，展示了扩散模型拟合不同分布驾驶行为以及在行为间切换的能力。






图 4: 目标速度与舒适性引导: 目标速度引导部分可视化引导前后的速度变化; 舒适性引导部分对比在碰撞避免引导基础上叠加舒适性引导前后的纵向加加速度 (Jerk) 变化。

表 3: nuPlan Test14 基准上训练过程中各模块的消融。

类型	规划器	分数
基础	Diffusion Planner	89.19
数据	无 z-score 归一化	85.02
	无插值	83.78
	无数据增强	76.53
自车状态	带 SDE	82.90
	带自车状态	78.65
	无当前状态	81.11




图 6: 预测车辆数量 M 的消融。




图 7: 推理参数网格搜索。

灵活的引导机制。基于训练好的扩散规划器模型，在推理时加入第 4.3 节所述不同类型的分类器引导，无需额外训练。图 4 给出两个案例，展示引导的有效性与灵活组合能力。1) 目标速度设定：掩码所有车道限速信息，使其不影响模型规划，确保速度调整完全通过引导实现。结果显示，无引导时模型速度偏低；将目标速度设为 10m/s 到 14m/s 后，模型在保持平滑速度过渡的同时紧密贴合期望速度区间。2) 舒适性引导：有效缓解驾驶不适，甚至可与碰撞引导同时使用。附录 B.2 还给出碰撞与可行驶引导的更多案例分析，图 2 则展示碰撞与可行驶引导灵活组合的案例。

5.2 消融实验

训练设计选择。本文验证方法关键组件的有效性：数据处理方式、自车当前状态处理方式以及预测车辆数量。1) 对不使用 z-score 归一化 (*w/o z-score norm*)、不使用数据增强 (*w/o augmentation*) 以及仅扰动当前状态而不对未来轨迹插值 (*w/o interpolation*) 的变体进行消融，结果汇总于表 3。 *w/o z-score norm* 变体即使经过以自车为中心变换，数据范围仍然很大，模型难以拟合分布； *w/o augmentation* 变体面临分布外问题，性能较差。结果还表明，相比仅扰动当前状态，未来轨迹插值必不可少。2) 分析自车当前状态对模型的影响：保留速度、加速度与横摆角速度 (*w/ ego state*) 可能导致学习捷径，降低规划能力；状态丢弃编码器 (Cheng et al., 2023) (*w/ SDE*) 虽能缓解该问题，但直接丢弃信息更为有效。此外， *w/o current state* 表明向解码器加入当前状态信息可提升规划能力。3) 对 M 取值进行消融。图 6 显示，解码器纳入过多邻居车辆会引入噪声，影响自车性能；但大多数取值仍优于 PlanTF。

推理设计选择。如图 7 所示，对两个超参数进行扫描：去噪步数与低温采样强度。低温有助于提升输出轨迹的稳定性；模型借助 DPM-Solver 实现高效去噪，且在不同步数下保持鲁棒。详细参数选择见表 5。

6 结论

本文提出扩散规划器——一种充分利用扩散模型表达能力与灵活引导机制实现高质量自动驾驶规划的基于学习方法。通过扩散目标，基于 Transformer 的架构联合建模运动预测与规划任务中的多模态数据分布；分类器引导用于将规划行为对齐到安全或用户偏好的驾驶风格。在 nuPlan 基准与新收集的 200 小时配送车辆驾驶数据集上，扩散规划器不依赖任何基于规则精化即取得最优闭环性能，展现出对多样驾驶风格的强适应性。受篇幅限制，关于局限性与未来方向的更多讨论见附录 E。

致谢

本工作受国家重点研发计划（2022YFB2502904）与 Haomo.AI 资助。

参考文献

- Anurag Ajay, Yilun Du, Abhi Gupta, Joshua B Tenenbaum, Tommi S Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision making? In *The Eleventh International Conference on Learning Representations*, 2022.
- Mayank Bansal, Alex Krizhevsky, and Abhijit Ogale. Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst. *arXiv preprint arXiv:1812.03079*, 2018.
- Mariusz Bojarski, Davide Del Testa, Daniel Dworakowski, Bernhard Firner, Beat Flepp, Praseem Goyal, Lawrence D Jackel, Mathew Monfort, Urs Muller, Jiakai Zhang, et al. End to end learning for self-driving cars. *arXiv preprint arXiv:1604.07316*, 2016.
- Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multimodal dataset for autonomous driving. *arXiv preprint arXiv:1903.11027*, 2019.
- Holger Caesar, Juraj Kabzan, Kok Seang Tan, Whye Kit Fong, Eric Wolff, Alex Lang, Luke Fletcher, Oscar Beijbom, and Sammy Omari. nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. *arXiv preprint arXiv:2106.11810*, 2021.
- Dian Chen, Vladlen Koltun, and Philipp Krähenbühl. Learning to drive from a world on rails. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 15590–15599, 2021.
- Li Chen, Penghao Wu, Kashyap Chitta, Bernhard Jaeger, Andreas Geiger, and Hongyang Li. End-to-end autonomous driving: Challenges and frontiers. *arXiv preprint arXiv:2306.16927*, 2023.
- Jie Cheng, Yingbing Chen, Xiaodong Mei, Bowen Yang, Bo Li, and Ming Liu. Rethinking imitation-based planners for autonomous driving, 2023.
- Jie Cheng, Yingbing Chen, and Qifeng Chen. Pluto: Pushing the limit of imitation learning-based planning for autonomous driving. *arXiv preprint arXiv:2404.14327*, 2024.
- Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *arXiv preprint arXiv:2303.04137*, 2023.
- Kashyap Chitta, Aditya Prakash, Bernhard Jaeger, Zehao Yu, Katrin Renz, and Andreas Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(11):12878–12895, 2022.

- Hyungjin Chung, Jeongsol Kim, Michael T Mccann, Marc L Klasky, and Jong Chul Ye. Diffusion posterior sampling for general noisy inverse problems. *arXiv preprint arXiv:2209.14687*, 2022.
- Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *Conference on Robot Learning (CoRL)*, 2023a.
- Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *Conference on Robot Learning*, pp. 1268–1281. PMLR, 2023b.
- Prafulla Dhariwal and Alexander Nichol. Diffusion models beat gans on image synthesis. *Advances in neural information processing systems*, 34:8780–8794, 2021.
- Haoyang Fan, Fan Zhu, Changchun Liu, Liangliang Zhang, Li Zhuang, Dong Li, Weicheng Zhu, Jiangtao Hu, Hongye Li, and Qi Kong. Baidu apollo em motion planner, 2018.
- Jiyang Gao, Chen Sun, Hang Zhao, Yi Shen, Dragomir Anguelov, Congcong Li, and Cordelia Schmid. Vectornet: Encoding hd maps and agent dynamics from vectorized representation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 11525–11533, 2020.
- Jeffrey Hawke, Richard Shen, Corina Gurau, Siddharth Sharma, Daniele Reda, Nikolay Nikolov, Przemysław Mazur, Sean Micklethwaite, Nicolas Griffiths, Amar Shah, et al. Urban driving with conditional imitation learning. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 251–257. IEEE, 2020.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Planning-oriented autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 17853–17862, 2023.
- Yihan Hu, Siqi Chai, Zhenning Yang, Jingyu Qian, Kun Li, Wenxin Shao, Haichao Zhang, Wei Xu, and Qiang Liu. Solving motion planning tasks with a scalable generative model. *arXiv preprint arXiv:2407.02797*, 2024.
- Zhiyu Huang, Haochen Liu, and Chen Lv. Gameformer: Game-theoretic modeling and learning of transformer-based interactive prediction and planning for autonomous driving. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 3903–3913, 2023.
- Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, pp. 9902–9915. PMLR, 2022.
- Chiyu Jiang, Andre Cornman, Cheolho Park, Benjamin Sapp, Yin Zhou, Dragomir Anguelov, et al. Motiondiffuser: Controllable multi-agent motion prediction using diffusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9644–9653, 2023.
- Alex Kendall, Jeffrey Hawke, David Janz, Przemysław Mazur, Daniele Reda, John-Mark Allen, Vinh-Dieu Lam, Alex Bewley, and Amar Shah. Learning to drive in a day. In *2019 international conference on robotics and automation (ICRA)*, pp. 8248–8254. IEEE, 2019.
- John J. Leonard, Jonathan P. How, Seth J. Teller, Mitch Berger, Stefan Campbell, Gaston A. Fiore, Luke Fletcher, Emilio Frazzoli, Albert S. Huang, Sertac Karaman, Olivier Koch, Yoshiaki Kuwata, David C. Moore, Edwin Olson, Steven C. Peters, Justin Teo, Robert Truax, Matthew R. Walter, David Barrett, Alexander K Epstein, Keoni Maheloni, Katy Moyer, Troy Jones, Ryan Buckley, Matthew E. Antone, Robert Galejs, Siddhartha Krishnamurthy, and Jonathan Williams. A perception-driven autonomous urban

- vehicle. *Journal of Field Robotics*, 25, 2008. URL <https://api.semanticscholar.org/CorpusID:1906145>.
- Zhiqi Li, Zhiding Yu, Shiyi Lan, Jiahao Li, Jan Kautz, Tong Lu, and Jose M Alvarez. Is ego status all you need for open-loop end-to-end autonomous driving? In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 14864–14873, 2024.
- Tenglong Liu, Jianxiong Li, Yinan Zheng, Haoyi Niu, Yixing Lan, Xin Xu, and Xianyuan Zhan. Skill expansion and composition in parameter space. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=GLWf2fqObX>.
- Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps. *Advances in Neural Information Processing Systems*, 35:5775–5787, 2022.
- Cheng Lu, Huayu Chen, Jianfei Chen, Hang Su, Chongxuan Li, and Jun Zhu. Contrastive energy prediction for exact energy-guided diffusion sampling in offline reinforcement learning. *arXiv preprint arXiv:2304.12824*, 2023.
- Chenlin Meng, Robin Rombach, Ruiqi Gao, Diederik Kingma, Stefano Ermon, Jonathan Ho, and Tim Salimans. On distillation of guided diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 14297–14306, 2023.
- Khan Muhammad, Amin Ullah, Jaime Lloret, Javier Del Ser, and Victor Hugo C de Albuquerque. Deep learning for safe autonomous driving: Current challenges and future directions. *IEEE Transactions on Intelligent Transportation Systems*, 22(7):4316–4336, 2020.
- Nigamaa Nayakanti, Rami Al-Rfou, Aurick Zhou, Kratarth Goel, Khaled S Refaat, and Benjamin Sapp. Wayformer: Motion forecasting via simple & efficient attention networks. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 2980–2987. IEEE, 2023.
- Jiquan Ngiam, Benjamin Caine, Vijay Vasudevan, Zhengdong Zhang, Hao-Tien Lewis Chiang, Jeffrey Ling, Rebecca Roelofs, Alex Bewley, Chenxi Liu, Ashish Venugopal, et al. Scene transformer: A unified architecture for predicting multiple agent trajectories. *arXiv preprint arXiv:2106.08417*, 2021.
- William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4195–4205, 2023.
- Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu, and Mark Chen. Hierarchical text-conditional image generation with clip latents. *arXiv preprint arXiv:2204.06125*, 1(2):3, 2022.
- Oliver Scheel, Luca Bergamini, Maciej Wołczyk, Błażej Osiński, and Peter Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients, 2021.
- Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics, 2015.
- Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *Advances in neural information processing systems*, 32, 2019.
- Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations, 2021.
- Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. *arXiv preprint arXiv:2303.01469*, 2023.

- Qiao Sun, Shiduo Zhang, Danjiao Ma, Jingzhe Shi, Derun Li, Simian Luo, Yu Wang, Ningyi Xu, Guangzhi Cao, and Hang Zhao. Large trajectory models are scalable motion predictors and planners. *arXiv preprint arXiv:2310.19620*, 2023.
- Qiao Sun, Huimin Wang, Jiahao Zhan, Fan Nie, Xin Wen, Leimeng Xu, Kun Zhan, Peng Jia, Xianpeng Lang, and Hang Zhao. Generalizing motion planners with mixture of experts for autonomous driving. *arXiv preprint arXiv:2410.15774*, 2024.
- Ardi Tampuu, Tambet Matiisen, Maksym Semikin, Dmytro Fishman, and Naveed Muhammad. A survey of end-to-end driving: Architectures and training methods. *IEEE Transactions on Neural Networks and Learning Systems*, 33(4):1364–1384, 2020.
- Ilya O Tolstikhin, Neil Houlsby, Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Thomas Unterthiner, Jessica Yung, Andreas Steiner, Daniel Keysers, Jakob Uszkoreit, et al. Mlp-mixer: An all-mlp architecture for vision. *Advances in neural information processing systems*, 34:24261–24272, 2021.
- Martin Treiber, Ansgar Hennecke, and Dirk Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical Review E*, 62(2):1805–1824, August 2000a. ISSN 1095-3787. doi: 10.1103/physreve.62.1805. URL <http://dx.doi.org/10.1103/PhysRevE.62.1805>.
- Martin Treiber, Ansgar Hennecke, and Dirk Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 62(2):1805, 2000b.
- Chris Urmson, Joshua Anhalt, J. Andrew Bagnell, Christopher R. Baker, Robert Bitner, M. N. Clark, John M. Dolan, David Duggins, Tugrul Galatali, Christopher Geyer, Michele Gittleman, Sam Harbaugh, Martial Hebert, Thomas M. Howard, Sascha Kolski, Alonzo Kelly, Maxim Likhachev, Matthew McNaughton, Nick Miller, Kevin M. Peterson, Brian Pilnick, Ragunathan Raj Rajkumar, Paul E. Rybski, Bryan Salesky, Young-Woo Seo, Sanjiv Singh, Jarrod M. Snider, Anthony Stentz, William Whittaker, Ziv Wolkowicki, Jason Ziglar, Hong Bae, Thomas Brown, Daniel Demitrish, Bakhtiar Litkouhi, James N. Nickolaou, Varsha Sadekar, Wende Zhang, Joshua Struble, Michael Taylor, Michael Darms, and Dave Ferguson. Autonomous driving in urban environments: Boss and the urban challenge. *Journal of Field Robotics*, 25, 2008. URL <https://api.semanticscholar.org/CorpusID:11849332>.
- Matt Vitelli, Yan Chang, Yawei Ye, Ana Ferreira, Maciej Wolczyk, Błażej Osiński, Moritz Niendorf, Hugo Grimmett, Qiangui Huang, Ashesh Jain, et al. Safetynet: Safe planning for real-world self-driving vehicles using machine-learned policies. In *2022 International Conference on Robotics and Automation (ICRA)*, pp. 897–904. IEEE, 2022.
- Tongda Xu, Jian Li, Xinjie Zhang, Xingtong Ge, Dailan He, Xiyan Cai, Ming Sun, Yan Wang, Jingjing Liu, and Ya-Qin Zhang. Rethinking diffusion posterior sampling: From conditional score estimator to maximizing a posterior. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=GcvLoqQoXL>.
- Brian Yang, Huangyuan Su, Nikolaos Gkanatsios, Tsung-Wei Ke, Ayush Jain, Jeff Schneider, and Katerina Fragkiadaki. Diffusion-es: Gradient-free planning with diffusion for autonomous driving and zero-shot instruction following. *arXiv preprint arXiv:2402.06559*, 2024.
- Yinan Zheng, Jianxiong Li, Dongjie Yu, Yujie Yang, Shengbo Eben Li, Xianyuan Zhan, and Jingjing Liu. Safe offline reinforcement learning with feasibility-guided diffusion model. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=j5JvZCaDM0>.
- Ziyuan Zhong, Davis Rempe, Yuxiao Chen, Boris Ivanovic, Yulong Cao, Danfei Xu, Marco Pavone, and Baishakhi Ray. Language-guided traffic simulation via scene-level diffusion. In *Conference on Robot Learning*, pp. 144–177. PMLR, 2023a.

Ziyuan Zhong, Davis Rempe, Danfei Xu, Yuxiao Chen, Sushant Veer, Tong Che, Baishakhi Ray, and Marco Pavone. Guided conditional diffusion for controllable traffic simulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 3560–3566. IEEE, 2023b.

Zikang Zhou, Jianping Wang, Yung-Hui Li, and Yu-Kai Huang. Query-centric trajectory prediction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 17863–17873, 2023.

A 闭环规划结果可视化




图 8: 闭环规划结果: 每行表示一个场景在 0、5、10 和 15 秒时刻的画面。每帧包含自行车的**未来规划**、对邻居车辆的**预测**、**真值**自行车轨迹以及自行车的**行驶历史**。

B 附加结果

B.1 与基于扩散的规划方法比较

为进一步展示模型优势, 本文与近期两项使用扩散模型进行运动规划的工作进行比较。Diffusion-es (Yang et al., 2024) 引入大语言模型 (Large Language Model, LLM) 作为轨迹过滤器以增强扩散模型; STR-16M (Sun et al., 2023) 使用扩散模型作为解码器; STR2-CPKS-800M (Sun et al., 2024) 在其基础上有 800M 参数, 并包含类似 PDM 的精细化模块。在非反应式模式下比较模型性能并记录推理时间, 结果见表 4。观察发现, 现有基于扩散的方法在脱离 LLM 或基于规则精细化后同样出现显著性能下降。另一重要问题是, 这些方法依赖 LLM 或大量模型参数, 计算成本高, 难以在实际应用中部署。

表 4: 基于扩散的规划器在 nuPlan 数据集上的闭环非反应式规划结果。

规划器	Test14	Test14-hard	Val14	推理时间 (秒)
Diffusion-es w/o LLM	-	-	50	-
Diffusion-es w/ LLM	-	-	92	0.5
STR-16M	-	27.59	45.06	-
STR2-CPKS-800M w/o refine.	68.74	52.57	65.16	>11
Diffusion Planner (ours)	89.19	75.99	89.87	0.04




图 9: 碰撞与可行驶引导的案例研究。从相同起点出发, 可视化闭环测试结果: 虚线表示无引导的结果, 空心车辆标记表示发生安全事故的位置; 实线表示有引导的结果, 实心车辆标记表示最终位置。

B.2 引导机制的更多案例研究

C 实验细节

本节介绍复现本文主要结果所需的实验细节。

C.1 训练细节

数据集。使用 nuPlan 数据集的训练数据, 采样 1 百万个场景作为训练集, 各场景数量见图 11。对每个场景, 考虑当前时刻自车周围 100m 半径内的车道与导航信息, 以及邻居车辆过去两秒的历史数据。各类型数据填充到统一维度作为模型输入, 并使用注意力掩码有效去除无关信息。

数据增强。首先对自车当前状态进行轻微扰动, 涉及 x 、 y 坐标、朝向角 θ 、速度 v 、加速度 a 。

$$\Delta x^0 \sim \mathcal{U}([- \Delta x, - \Delta y, - \Delta \theta, - \Delta v, - \Delta a], [\Delta x, \Delta y, \Delta \theta, \Delta v, \Delta a]) .$$

<https://www.nuplan.org/>

对增强后的状态 $\tilde{x}_{ego}^0 = x_{ego}^0 + \Delta x^0$ ，确保速度 v 始终大于 0，避免车辆学到倒车行为。随后在当前状态 $\tilde{x}_{ego}^0$ 与 $x_{ego}^{\tau_{2s}}$ 之间进行五次多项式插值，生成符合动力学约束的新轨迹，替换真值轨迹。

归一化。沿用已有工作 (Huang et al., 2023; Cheng et al., 2023; 2024) 的做法，对原始数据集应用以自车为中心的变换：利用车辆航向与位置将全局坐标转换到自车局部坐标系。随后观察到自车纵向进度显著大于横向进度。为提升训练稳定性，对所有 x 轴坐标应用 z -score 归一化， y 轴缩放至相同量级以避免变形：

$$\tilde{x} = \frac{x - \mu}{\sigma}, \quad \tilde{y} = \frac{y}{\sigma},$$

其中 $\mu = 10$, $\sigma = 20$ 。其他场景输入采用相同处理。

训练使用 8 块 NVIDIA A100 80GB GPU，批大小 2048，共 500 轮，含 5 轮预热阶段。采用 AdamW 优化器，学习率 $5e^{-4}$ 。详细设置见表 5。

C.2 推理细节

使用 DPM-Solver++ 作为扩散逆过程求解器，采用方差保持 (Variance-preserving, VP) 噪声调度，噪声为 $\sigma_t = (1 - t)\beta_{\min} + t\beta_{\max}$ 。低温采样用于进一步增强去噪过程稳定性。实验发现，直接使用模型输出时，较高温度有利于生成高质量轨迹；反之，若在模型输出后接精化模块，较低温度有助于生成更稳定的轨迹，便于精化模块做出更准确的判断。模型在单块 A6000 GPU 上推理频率达 20 Hz。详细设置见表 5。

C.3 分类器引导细节

下面具体介绍第 4.3 节所述不同能量函数的数学形式。

碰撞避免。基于扩散时间戳 t 时解码器输出的自车规划与邻居车辆预测，计算每个时间戳 τ 下自车与各邻居车辆之间的有符号距离 $\mathbf{D}$ 。当车辆包围盒重叠时取最小分离距离，否则取最近点之间的距离。碰撞避免的能量函数定义为：

$$\begin{aligned} \mathcal{E}_{\text{collision}} = & \frac{1}{\omega_c} \cdot \frac{\sum_{M, \tau} \mathbb{1}_{\mathbf{D}_M^\tau > 0} \cdot \Psi\left(\omega_c \cdot \max\left(1 - \frac{\mathbf{D}_M^\tau}{r}, 0\right)\right)}{\sum_{M, \tau} \mathbb{1}_{\mathbf{D}_M^\tau > 0} + \text{eps}} \\ & + \frac{1}{\omega_c} \cdot \frac{\sum_{M, \tau} \mathbb{1}_{\mathbf{D}_M^\tau < 0} \cdot \Psi\left(\omega_c \cdot \max\left(1 - \frac{\mathbf{D}_M^\tau}{r}, 0\right)\right)}{\sum_{M, \tau} \mathbb{1}_{\mathbf{D}_M^\tau < 0} + \text{eps}}, \end{aligned} \quad (9)$$

其中 $\Psi(x) := e^x - x$, r 为碰撞敏感距离，控制产生梯度的最大距离，eps 用于保证数值稳定性 (Jiang et al., 2023)。

目标速度维持。基于生成轨迹的平均速度与目标速度区间的差值计算能量函数：

$$\mathcal{E}_{\text{target_speed}} = \max\left(\frac{\overline{dx_{\text{ego}}^\tau}}{d\tau} - v_{\text{low}}, 0\right)^2 + \max\left(v_{\text{high}} - \frac{\overline{dx_{\text{ego}}^\tau}}{d\tau}, 0\right)^2. \quad (10)$$

其中 v_{low} 为设定的速度下界， v_{high} 为设定的速度上界。

舒适性。以纵向加速度为例，计算每个点与舒适性阈值的差值，忽略满足舒适性要求的情况：

$$\mathcal{E}_{\text{comfort}} = \mathbb{E} \left[\max \left(\left(j_{\max} - \left| \frac{d^3 x_{\text{ego}}^\tau}{d\tau^3} \right| \right) \Delta\tau^3, 0 \right)^2 \right]. \quad (11)$$

其中 $j_{\max}$ 为最大纵向加速度限制。

保持在可行驶区域内。利用并行计算的欧氏有符号距离场 (Euclidean Signed Distance Field) (Cheng et al., 2024) 构造可微代价地图 $\mathbf{M}$ ，计算每个时间戳自车超出车道的距离。能量定义为：

$$\mathcal{E}_{\text{drivable}} = \frac{1}{\omega_d} \cdot \frac{\sum_{\tau} \Psi(\omega_d \cdot \mathbf{M}(x_{\text{ego}}^{\tau}))}{\sum_{\tau} \mathbb{1}_{\mathbf{M}(x_{\text{ego}}^{\tau}) > 0} + \text{eps}}. \quad (12)$$

鉴于能量函数设计有多种选择，本文的选择主要为了验证模型能否支持各类引导，未必是最优方案。通过大量实证实验，可以分享能量函数选择方面的一些见解与经验，以帮助未来工作探索更有效的方案：

- **平滑连续的梯度**：具有平滑连续梯度的引导函数有助于生成稳定轨迹。
- **梯度稀疏性**：引导函数最好仅在特定情形下产生梯度，如轨迹点接近潜在碰撞时。
- **高阶状态导数采用间接引导**：对速度、加速度、角速度等高阶状态导数，更适合通过位置与航向间接引导。例如，控制轨迹速度可改为引导轨迹长度。
- **梯度量级一致**：引导函数应保证不同条件下梯度量级大致一致，可通过在贡献代价的点数上对代价取平均实现。

表 5: 扩散规划器的超参数

类型	参数	符号	值
训练	邻居车辆数量	-	32
	历史时间戳数量	L	21
	邻居车辆维度	D_{neighbor}	11
	车道数量	-	70
	每条折线点数	P	20
	车道维度	D_{lane}	12
	导航车道数量	D	25
	预测邻居车辆数量	M	10
	编码器/解码器块数量	-	3
	隐藏层维度	-	192
	多头数量	-	6
	噪声调度	-	Linear
推理	噪声系数	$\beta_{\min}, \beta_{\max}$	0.1, 20.0
	温度	-	0.5
	温度（带精化）	-	0.1
	去噪步数	-	10

C.4 基线设置

nuPlan 数据集评估。对 *IDM* 和 *UrbanDriver*，使用官方 nuPlan 代码，其中 *UrbanDriver* 检查点来自 *PDM* 代码库，该代码库也提供 *PDM-Hybrid* 与 *PDM-Open* 的检查点。对 *PlanTF* 和 *PLUTO*，使用各自官方代码库的检查点。对 *PLUTO w/o refine*，跳过后期处理代码并在不重训练的情况下重新运行仿真。遵循官方代码库的指导，训练 *GameFormer* 并跳过精化步骤，得到 *GameFormer w/o refine*。

配送车辆数据集评估。采用与 nuPlan 相同的指标与模型，通过修改各类车辆相关参数使基线适应配送车辆训练，并据此按官方训练代码重训练和测试模型。

<https://github.com/motional/nuplan-devkit>
https://github.com/autonomousvision/tuplan_garage
<https://github.com/jchengai/planTF>
<https://github.com/jchengai/pluto>
<https://github.com/MCZhi/GameFormer-Planner>

D 配送车辆实验细节

本文使用 Haomo.AI 的自主物流配送车辆收集约 200 小时真实数据。配送车辆的任务与 nuPlan 中的 Robotaxi 类似，需自主沿指定路线行驶。运行中须遵守交通规则、保证安全，并尽可能高效完成配送。与 nuPlan 数据集中的车辆相比，配送车辆更小（见表 6）、速度更低，因此可在主干道与非机动车道上行驶。配送过程中与行人、骑行者的交互频繁，且行驶规则与机动车不同，如图 10 所示。该数据集作为 nuPlan 的补充，用于评估算法在多样驾驶场景下的性能。

表 6: 车辆参数详情

参数 (米)	配送车辆	nuPlan 车辆
宽度	1.03	2.30
长度	2.34	5.18
高度	1.65	1.78
轴距	1.20	3.09

具体而言，将原始数据转换为 nuPlan 数据结构，存储为兼容 nuPlan API 的 DB 文件，便于无缝集成使用。模型与基线均使用 nuPlan 基准的相同训练流程训练。对部分需要人行横道信息的基线，用停止线数据替代；车辆参数替换为配送车辆参数。模型性能使用 nuPlan 指标评估。




图 10: 配送车辆驾驶数据集中各类型场景数量及代表性可视化。

E 局限、讨论与未来工作

下面讨论本文的局限、潜在解决方案与有趣的未来工作。

- 场景输入。** 本文方法依赖矢量化地图信息与邻居车辆检测结果。与主流端到端流程相比，该方法存在一定信息损失，且需要数据处理模块。但与端到端方法不同，本文更关注规划阶段，尤其是闭环规划能力。
 解决方案与未来工作：本文展示了无基于规则精化时扩散模型在闭环规划中的性能。一个有趣的未来方向是修改编码器架构，以图像作为输入，实现端到端训练流程。
- 横向灵活性。** 研究发现基于学习方法在灵活性上存在不足，尤其当需要较大横向移动时；基于规则方法因提供参考轨迹而在该方面表现更好。与已有工作 (Li et al., 2024) 的发现一致，这主要是因为数据集以直线行驶场景为主，变道与避让操作实例很少，使基于学习方法难以泛化习得这些技能。此外，模型只输出规划轨迹而非刹车、油门等控制信号，规划轨迹与下游控制器结果之间存在差距 (Cheng et al., 2023)，这在需要更灵活动作的场景中同样可能导致性能不佳甚至分布外行为。

解决方案与未来工作：数据增强可在一定程度上缓解车辆不愿横向移动的问题，但在需要大幅变道的场景中仍表现不佳。可通过纳入更多大幅横向移动的数据、利用带奖励机制的强化学习，或设计更有效的扩散引导机制帮助模型学习变道行为来改进。本文认为这是一个有趣的发现，留待未来工作探索。

- **采样效率。**扩散模型的高性能以多次模型推理为代价，导致采样效率下降。

解决方案与未来工作：通过使用高阶 ODE 求解器，本文在很大程度上解决了该问题，可在 0.05 秒内完成 8 秒、10 Hz 的轨迹规划。考虑实际应用需求，可采用一致性模型 (Consistency Model) (Song et al., 2023) 或基于蒸馏的采样方法 (Meng et al., 2023) 进一步加速。

总体而言，尽管部分设计选择看似简单且存在一定局限，本文通过大量实验充分证明了扩散模型在自动驾驶闭环规划中的能力，并展示了扩散模型对齐安全或人类偏好驾驶行为的潜力，为自动驾驶系统提供了高性能、高适应性的规划器。




图 11: nuPlan 数据集中各类型场景数量。