

DriveLM : 基于图视觉问答的驾驶

Chonghao Sima^{4,1*} Katrin Renz^{2,3*} Kashyap Chitta^{2,3} Li Chen^{4,1}
Hanxue Zhang¹ Chengen Xie¹ Jens Beißwenger^{2,3} Ping Luo⁴
Andreas Geiger^{2,3†} Hongyang Li^{1†}

¹ OpenDriveLab, 上海人工智能实验室, 中国

² 蒂宾根大学, 德国

³ 蒂宾根人工智能中心, 德国

⁴ 香港大学, 中国

simachonghao@pjlab.org.cn katrin.renz@uni-tuebingen.de




图1: 本文提出 DriveLM: 一个面向端到端自动驾驶的新任务、数据集、评估指标和基线方法。受 [10] 启发, DriveLM 采用图视觉问答 (Graph Visual Question Answering, GVQA), 其中问答对通过逻辑依赖关系相互连接, 包括对象层面 (即对象对之间的交互) 和任务层面 (即 感知 → 预测 → 规划 → 行为 (以自然语言描述的离散动作) → 运动 (连续轨迹))。本文提出 DriveLM-Data 用于训练 GVQA 基线方法 DriveLM-Agent, 并在需要零样本泛化的挑战性场景下, 使用 DriveLM-Metrics 验证其有效性。

摘要 研究基于网络规模数据训练的视觉语言模型 (Vision-Language Model, VLM) 如何集成到端到端驾驶系统中, 以增强泛化能力并实现

* 同等贡献。† 项目负责人。

与人类用户的交互。现有方法通过单轮视觉问答 (Visual Question Answering, VQA) 将 VLM 适配到驾驶任务, 但人类驾驶员以多步骤方式推理决策——从关键目标定位开始, 在采取行动前评估目标间的交互。核心思路在于, 提出的图视觉问答 (Graph Visual Question Answering, GVQA) 任务通过感知、预测和规划的问答对来建模图结构推理, 从而获得模拟人类推理过程的合适代理任务。基于 nuScenes 和 CARLA 构建了数据集 (DriveLM-Data), 并提出基于 VLM 的基线方法 (DriveLM-Agent) 以联合执行 GVQA 与端到端驾驶。实验表明, GVQA 为驾驶场景推理提供了简洁、系统化的框架, DriveLM-Data 则为该任务提供了具有挑战性的基准。DriveLM-Agent 基线在端到端自动驾驶上取得了与当前最优驾驶专用架构相当的性能。值得注意的是, 在未见过的传感器配置上进行零样本评估时, 其优势更为显著。逐问题消融研究表明, 性能提升来源于图结构中预测和规划问答对的丰富标注。所有数据、模型及官方评估服务器均可在 <https://github.com/OpenDriveLab/DriveLM> 获取。

Keywords: 视觉语言模型 · 端到端自动驾驶

1 引言

当前自动驾驶 (Autonomous Driving, AD) 系统仍缺乏关键能力 [10, 15]。一个核心需求是泛化, 即处理未见场景或不熟悉传感器配置的能力。另一个需求涉及模型与人类的交互, 例如欧盟法规要求部署中的可解释性 [3]。此外, 与现有 AD 模型不同, 人类并非依赖几何精确的鸟瞰图 (Bird’s Eye View, BEV) 表征进行导航 [17, 32, 46], 而是隐式地执行以目标为中心的感知、预测和规划 (记为 P_{1-3}): 粗略识别和定位关键目标, 推理其可能的运动, 并将这些信息综合为驾驶行动 [60, 76]。

同时, 另一领域也在快速发展: 视觉语言模型 (VLM) [47, 54, 90, 106]。这类模型具有若干优势。首先, 通过网络规模数据获得对世界的基础理解, 有望促进 AD 中规划的泛化。事实上, VLM 已在较简单的机器人任务中实现了此类泛化 [23, 108]。其次, 使用语言表征作为输入和输出为与模型进行友好交互提供了平台, 而现有方法则更多使用边界框或轨迹 [19, 31, 49, 70]。最后, VLM 能够通过逻辑推理连接的多步骤进行决策 [5, 21, 93, 95, 103, 108]。重要的是, 尽管 VLM 以多个独立步骤进行推理, 但其架构是端到端可微的——这一特性对自动驾驶极为重要 [10]。

将 VLM 应用于 AD 系统的现有工作分为两类: 场景级和单目标级视觉问答 (Visual Question Answering, VQA)。场景级 VQA 指用一两个支撑理由描述驾驶行为的任务, *e.g.*, “自车正在并入右侧车道, 因为这样做是安全的。” [41, 42]。单目标级 VQA 通过 “什么-哪个-哪里-如何-为什么” 形式的问答链建模自车对单个目标的响应, *e.g.*, “自车停下, 因为前方路口有一名穿白衬衫的行人正在横穿马路, 自车不想撞到该行人。” [56, 67, 71]。然而, 这两种范式均未提供合适的代理任务来模拟人类 P_{1-3} 推理过程——人类考虑多个目标并对每个目标进行多步推理。因此, 本文提出新任务及其对应的数据集和基线模型架构 (Fig. 1)。

任务. 图视觉问答 (Graph Visual Question Answering, GVQA) 将 P_{1-3} 推理建模为有向图中的一系列问答对。与上述 AD 的 VQA 任务的关键区别在

于，问答对之间存在逻辑依赖关系，可用于指导回答过程。GVQA 还包含关于行为和运动规划的提问，并配有专用指标（详见 Section 2）。

数据集. DriveLM-nuScenes 和 DriveLM-CARLA 包含以图结构组织的带标注问答对，通过逻辑推理将图像与驾驶行为关联。与现有基准相比，每帧提供的文本标注显著更多（Table 1 和 Fig. 2）。此外，作为 DriveLM-CARLA 的组成部分，构建了 PDM-Lite [4]——首个适用于 CARLA Leaderboard 2.0 的基于规则的专家算法。这些训练数据集配套了挑战性测试数据，用于评估零样本泛化能力。

基线. DriveLM-Agent 采用可应用于任意通用 VLM [47, 54, 65, 106] 的轨迹分词器，并结合将逻辑依赖建模为 VLM 上下文输入的图提示方案。由此得到一种将 VLM 有效改造为端到端 AD 的简洁方法（Section 3）。

实验取得了令人鼓舞的结果。发现 DriveLM 上的 GVQA 是一项具有挑战性的任务，现有方法仅获得中等分数，可能需要更好地建模逻辑依赖关系才能实现强大的 QA 性能。尽管如此，DriveLM-Agent 虽采用任务无关架构，在开环规划设置下测试时，性能已与当前最优的驾驶专用模型 [32] 相当。此外，采用图结构提升了零样本泛化能力，使 DriveLM-Agent 在仅使用 nuScenes [6] 数据训练后，能够正确处理 Waymo 数据 [77] 上的未见部署场景。最后，通过逐问题分析发现，预测和规划阶段的问答对最有助于最终驾驶决策。基于这些结果，认为改进 GVQA 在构建具有强泛化能力的自动驾驶智能体方面具有巨大潜力。

2 DriveLM：任务、数据与评估指标

人类驾驶员通常将其决策过程分解为不同阶段，这些阶段遵循逻辑递进关系，涵盖关键目标的识别与定位、它们可能的未来行为与交互，以及基于所有这些信息的自车 (ego vehicle) 规划 [27, 55]。这启发我们提出将图视觉问答 (Graph Visual Question Answering, GVQA) 作为 DriveLM 的关键组成部分，作为模拟人类推理过程的合适代理任务。在本节中，我们将阐述 DriveLM 任务：GVQA 的构成 (Section 2.1)，介绍 DriveLM-数据 (Section 2.2) 以示例说明如何使用主流驾驶数据集实例化 GVQA，并概述用于评估的 DriveLM-评估指标 (Section 2.3)。为了鼓励在这一方向的进一步研究，将设立一个官方的评测服务器（含公开排行榜 (Leaderboard)），用于对不同方法进行基准测试，并发现关于将语言模型与自动驾驶相结合的更多见解。

2.1 DriveLM-GVQA 任务

我们将一个图像帧的所有问答对 (question-answer pairs, QA) 组织成一个图结构。我们使用术语“图结构” (graph-structured) 来指代有向无环图 (directed acyclic graph, DAG)，即当前问题可以从 (多个) 父节点和祖父节点获取上下文。图 $G = (V, E)$ 包含一组顶点 V ，其中每个顶点表示一个与该场景中一个或多个关键目标相关的问答对 $v = (q, a)$ 。图视觉问答与普通视觉问答 (Visual Question Answering, VQA) 的关键区别在于，图视觉问答中的问答对具有逻辑依赖关系，我们将其表述为顶点之间的边。 $E \subseteq V \times V$ 是一组有向边，其中每条边 $e = (v_p, v_c)$ 连接父问答对和子问答对。我们通过引入两个维度来构建边集 E ：目标级边和任务级边。在目标层面，我们构建逻辑边 $e \in E$ 来表示不同目标之间交互的影响。例如，在 Fig. 1 (中间) 的示例中，轿车的规划问答节点受到行人




图2: 标注流程 (Annotation Pipeline): 在 DriveLM-nuScenes 中, 我们采用半基于规则的问答 (QA) 标注流程, 既使用 nuScenes/OpenLane-V2 中的真值 (ground truth) 标注, 也使用人工标注员 (human annotator) 的反馈。我们流程的关键部分是多轮质量检查, 以合理的成本保证高质量数据。在 DriveLM-CARLA 中, 我们达到相同的标准, 但采用完全基于规则的问答标注流程, 使用一种名为 PDM-Lite 的新型专家算法。

感知问答节点的影响。在任务层面, 我们建立逻辑边 $e \in E$ 来捕获不同推理阶段的逻辑链:

- **感知 (Perception) (P_1)**: 当前场景中关键目标的识别、描述与定位。
- **预测 (Prediction) (P_2)**: 基于感知结果对关键目标可能行为/交互的估计。
- **规划 (Planning) (P_3)**: 自车的可能安全行为。
- **行为 (Behavior) (B)**: 驾驶决策的分类。
- **运动 (Motion) (M)**: 自车未来轨迹的路点。

感知、预测和规划 (P_{1-3}) 的概念与端到端 (end-to-end) 自动驾驶 (AD) [10] 中的概念类似, 而运动和行为的概念则基于自车的未来轨迹。具体来说, 我们将运动 M 定义为自车的未来轨迹, 这是一组在鸟瞰图 (Bird’s Eye View, BEV) 中具有坐标 (x, y) 的 N 个点, 表示为 $M = \{(x_0, y_0), (x_1, y_1), \dots, (x_N, y_N)\}$ 。每个点是未来位置与当前位置之间按固定时间间隔的偏移量。然后, 每个时间间隔上的 x, y 距离计算如下:

$$\{x, y\}_{\text{dist}} = \{(\delta_{x,1}, \delta_{y,1}), \dots, (\delta_{x,N}, \delta_{y,N})\}, \quad (1)$$

其中 $\delta_{x,i} = x_i - x_{i-1}$ 且 $\delta_{y,i} = y_i - y_{i-1}$, 对于 $i = 1, 2, \dots, N$. 行为表示的目标是充当从 P_{1-3} 到 M 的接口。为了获得行为表示, 我们将 x_{dist} 和 y_{dist} 的均值映射到预定义的区间之一, 其中每个区间对应速度或转向中的一个类别。分别记为 B_{sp} 和 B_{st} 。在本工作中, 我们考虑 5 个区间:

$$B_{sp} \in \{\text{fast}_2, \text{fast}_1, \text{moderate}, \text{slow}_1, \text{slow}_2\},$$

$$B_{st} \in \{\text{left}_2, \text{left}_1, \text{straight}, \text{right}_1, \text{right}_2\},$$

其中下标中的数字表示强度。轨迹的速度和转向类别的组合形成其行为类别 $B = (B_{sp}, B_{st})$ 。虽然我们使用 B 的简单定义作为视觉语言模型 (Vision-Language Model, VLM) 驾驶研究的起点, 但我们注意到我们的公式支持纳入更抽象的行为, 例如变道或超车。

表 1: DriveLM-nuScenes 和 DriveLM-CARLA 与现有数据集的比较。 DriveLM 数据在标注数量、全面性（覆盖感知、预测和规划）以及逻辑性（从链式到图）方面取得了显著进展。† 完整数据集, ‡ 关键帧数据集, * 半规则标注（有人工标注员）, ** 全规则标注（无人工标注员）。- 表示未公开。

数据集	源数据集	帧数	每帧平均问答数	感知	预测	规划	逻辑
nuScenes-QA [67]	nuScenes	34,149	13.5	460k**	✗	✗	无
nuPrompt [98]	nuScenes	34,149	1.0	35k*	✗	✗	无
HAD [41]	HDD	25,549	1.8	25k	✗	20k	无
BDD-X [42]	BDD	26,228	1	26k	✗	✗	无
LingoQA [59]	LingoQA	28,000	15.3	-	-	-	无
DRAMA [56]	DRAMA	17,785	5.8	85k	✗	17k	链式
Rank2Tell [71]	Rank2Tell	5,800	-	-	✗	-	链式
DriveLM-nuScenes	nuScenes	4,871	91.4	144k*	153k	146k	图
DriveLM-CARLA†	CARLA	64,285	24.4	697k**	311k**	558k**	图
DriveLM-CARLA‡	CARLA	5,721	24.8	63k**	28k**	51k**	图

2.2 DriveLM-数据

为了提供符合 Section 2.1 中定义的图结构的全面且准确的问答对，我们引入了 DriveLM-nuScenes 和 DriveLM-CARLA。由于 nuScenes 和 CARLA 之间存在显著差异，这些数据集的收集方法和统计特性也有所不同。

DriveLM-nuScenes. 我们将标注（annotation）过程分为三个步骤：从视频片段中选择关键帧（key frame），在这些关键帧中选择关键目标，然后为这些关键目标标注帧级别的 P_{1-3} 问答对。部分感知问答对是根据 nuScenes [6] 和 OpenLane-V2 [87] 的真值生成的，其余问答对则通过人工标注。用于人工标注的问题模板由 5 位领域专家设计，考虑了人类如何做出驾驶决策。标注人员会看到每帧的所有问题模板，鼓励回答所有问题，但提供跳过选项以应对可能存在的不兼容情况。由于我们在 DriveLM-nuScenes 中人工标注了绝大多数数据，质量对这一部分尤为关键。在标注过程中，我们进行多轮严格的质量检查。在每一轮中，我们将数据分为不同批次，并检查每批中百分之十的数据。如果这百分之十中人工标注数据的合格率未达到预期，我们要求标注人员重新标注该批次中的所有数据。在 Fig. 2 中，我们展示了一个问答标注流程的示例，其中所有问题都按照我们的标准进行质量检查。因此，DriveLM-nuScenes 以其更大的规模、更全面的覆盖范围和更复杂的结构从先前提出的数据集中脱颖而出（参见 Table 1）。这些问答对涵盖了驾驶过程的各个方面，从感知、预测到规划，提供了对自动驾驶场景的全面理解（详见补充材料）。

DriveLM-CARLA 专家 (Expert) . 我们使用 CARLA 0.9.14 在排行榜 2.0 (Leaderboard 2.0) 框架 [22] 中收集数据。与前一版本排行榜 1.0 (Leaderboard 1.0) 相比，排行榜 2.0 包含大量新的驾驶场景。然而，截至目前，尚无现有方法能够在排行榜 2.0 中大规模收集训练数据。例如，TransFuser++ [36]（排行榜 1.0 中的最先进方法）所使用的特权基于规则的专家，在排行榜 2.0 的 8 公里以上的官方验证路线上的驾驶得分 (Driving Score, DS) 仅为 2%。我们构建了一种新的专家算法 PDM-Lite，可以应对排行榜 2.0 中的新挑战。我们的方法类似

于 PDM-Closed [19], 后者是 nuPlan [7] 的基于规则规划器。PDM-Lite 使用智能驾驶员模型 (Intelligent Driver Model, IDM) [84] 根据前车、行人、停止标志或交通灯获取目标速度。与 PDM-Closed 中通过复杂代价函数从 16 个提案中选择一个不同, 我们仅使用两个提案和基于 TransFuser++ 专家 [36] 的更简单的代价函数, 从而得到一个适合可扩展问答生成的轻量级规划器。PDM-Lite 在官方 CARLA 验证路线上获得了改进的 44% 驾驶得分。更多详情见补充材料。

DriveLM-CARLA 问答生成 (QA Generation). 为了收集 DriveLM-CARLA 数据集, 我们在城市、住宅和乡村区域设置了一系列路线, 并在这些路线上执行 PDM-Lite。在此过程中, 我们收集必要的传感器数据, 采样关键帧, 基于关于目标和场景的特权信息生成相关的问答对, 并组织逻辑关系将这些问答对连接成图结构。我们以 4 FPS 生成数据和标签, 并基于专家决策的变化 (例如, 当专家从加速变为制动时) 提取关键帧。基于规则的标注流程如图 2 所示。在数据收集过程中, 我们从模拟器中提取关于场景中静态和动态目标状态以及专家触发规则的特权信息。我们使用除 InterurbanAdvancedActorFlow、MergerIntoSlowTraffic 和 VehicleTurningRoute 之外的所有 38 个场景, 基于从模拟器提取的信息, 使用手工制作的句子模板创建问答对。具体的问题及其图结构可在补充材料中找到。我们的标注过程具有直接可扩展性的优势, 因为我们只需要在 CARLA 中定义路线和场景设置, 后续步骤即可自动执行。包含 1.6M 问答对 (具有直接的扩展方案), 我们的 DriveLM-CARLA 在现有基准中以其总文本内容成为最大的驾驶语言基准, 如表 1 所示。

2.3 DriveLM-评估指标

为了评估图视觉问答, DriveLM-评估指标由三个部分组成, 分别用于评估运动 M 、行为 B 和 P_{1-3} 。为了衡量运动阶段的性能, 我们使用 nuScenes 和 Waymo 基准中的标准评估指标: 平均位移误差 (Average Displacement Error, **ADE**)、最终位移误差 (Final Displacement Error, **FDE**) 以及预测轨迹上的**碰撞率 (Collision Rate)**, 遵循 UniAD [32]。我们通过**分类准确率**评估行为预测, 并将整体准确率分解为转向和速度分量。最后, 我们使用两个评估指标来衡量 P_{1-3} 的性能。**SPICE** [2] 是视觉问答和图像描述中广泛使用的评估指标, 它计算预测文本与真值之间的结构相似性, 同时忽略语义含义。同时, 我们使用**GPT 评分 (GPT Score)**来衡量答案的语义对齐程度, 以补充 SPICE 评估指标。具体来说, 将问题、真值答案、预测答案以及要求对答案进行数值评分的提示一起发送给 ChatGPT-3.5 [61, 62]。我们解析返回的文本以获得评分, 其中更高的评分表示更好的语义准确性。

3 DriveLM-Agent : 一个图视觉问答 (GVQA) 基线方法

在本节中, 我们介绍 DriveLM-Agent, 这是在 Section 2 中详述的图视觉问答 (GVQA) 任务的一种基线方法。DriveLM-Agent 基于通用视觉语言模型构建, 因此可以利用预训练期间获得的基础知识。我们的总体目标是通过视觉问答的不同阶段 (P_1, P_2, P_3, B) 将图像转化为期望的自行车运动 (M)。为此, 我们选择 BLIP-2 [47] 作为基础视觉语言模型 (Vision-Language Model, VLM), 因其架构简洁且微调灵活, 但我们的方法也可无关地应用于其他 VLM。

如图 3 所示, DriveLM-Agent 可分解为若干阶段: (1) P_{1-3} , 即, 感知 (*perception*)、预测 (*prediction*)、规划 (*planning*), 作为理解场景和推理其结




图 3: DriveLM-Agent 管道 (Pipeline)。给定场景图像, 视觉语言模型 (VLM) 执行带上下文的提示, 以建模五个问答阶段间的逻辑依赖。上下文由先前问答构建, 可包含一个或多个来源。

构的基础层。(2) 行为 (*behavior*) 阶段将 P_{1-3} 的关键信息聚合成语言空间中期望驾驶动作的描述。(3) 最后, 运动 (*motion*) 阶段将行为转化为可执行的驾驶轨迹。为实现各链接问答之间的逻辑依赖, 我们提出在图视觉问答 (GVQA) 图的连接节点之间使用上下文。下文将详细阐述这一思想。

3.1 上下文提示 (Prompting with Context)

如图像到运动的直接转化 (如文献 [16, 66]) 极具挑战性。受人类进行多步推理过程的倾向启发, 我们提出对基于 VLM 的驾驶采用类似策略。通过此方式, 我们促进大语言模型 (Large Language Model, LLM) 中存储知识的检索, 并提升可解释性。

更精确地, 该模型设计为使用推理过程中先前步骤的答案作为后续问题的上下文。对于每条边 $e = (v_p, v_c) \in E$, 我们以“上下文:”为前缀, 将父节点 v_p 的问答附加到当前节点 v_c 的问题上。上下文也可包含来自多个前置节点的问答, 此时我们将所有问答拼接为一个上下文序列。值得注意的是, 上下文仅是图视觉问答 (GVQA) 中表述逻辑依赖的一种可能实现, 我们因其简洁性而选择此方案。通过这一方案, 我们基于图建立的逻辑依赖前向传递相关信息。

注意, 推理过程中图的大小和结构是算法的设计选择, 可根据任务或可用计算预算进行调整。我们利用此特性在所有可用问答上训练, 但在特定子图上推理, 其中问题通过启发式方法采样。更多细节请参见补充材料。

通过行为聚合上下文 (Context Aggregation through Behavior). 驾驶涵盖需要适当响应的广泛潜在情景。然而, 尽管这些情景多种多样, 值得注意的是几乎所有事件都涉及可离散化为一组行为的决策。例如, 适当刹车可以应对红灯信号、停车标志或车辆前方存在物体等多种情况。我们行为阶段的重点是生成这样的行为: 一种用自然语言表述车辆预期运动的陈述。如 Section 2.1 所述, 该描述实质上充当反思步骤, 模型在其中汇总图中所有关键信息。因此, 我们提出使用所有可能的上下文来源来预测行为, 即 P_{1-3} 中的所有问答。我们实证发现该设计对基于 VLM 的驾驶至关重要。

3.2 运动轨迹分词 (Trajectory Tokenization for Motion)

由于使用通用视觉语言模型 (VLM) 输出细粒度数值结果并非易事, RT-2 [108] 基于专门的轨迹分词模块处理机器人动作。我们采用此方法使 DriveLM-Agent 能够以图像和行为描述为输入, 输出轨迹。具体地, 我们根据训练集轨迹的统计信息, 将路径点的坐标经验性地划分为 256 个区间。我们重新定义 BLIP-2 语言分词器中的标记, 为每个区间建立标记, 并在重新定义的词汇表上微调视觉语言模型 (VLM)。为简洁起见, 我们使用相同的 VLM 架构 (BLIP-2) 执行此

任务，但采用独立的 LoRA 权重，并在仅包含该运动阶段问答的数据集上训练。因此，也可使用轻量级大语言模型（Large Language Model, LLM）[68] 或接受命令作为输入的驾驶专用架构 [31, 99] 实现此功能。

4 实验

在本节中，我们介绍旨在回答以下研究问题的实验结果：(1) 如何有效地将视觉语言模型（VLM）重新用于端到端自动驾驶？(2) 用于驾驶的 VLM 在评估未见过的传感器配置时能否泛化（generalization）？(3) 感知（perception）、预测（prediction）和规划（planning）中的每个问题对最终行为（behavior）决策有何影响？(4) VLM 通过图视觉问答（GVQA）执行感知、预测和规划的效果如何？关于更多 VLM 在 DriveLM-nuScenes 上的实验以及在 DriveLM-CARLA 上对未见物体的泛化实验详见补充材料。

实验设置. 我们简要概述实验中两种设置的关键实现细节（更多细节详见补充材料）。所有微调（fine-tuning）均通过 LoRA [30] 实现。在 DriveLM-nuScenes 上，我们在 `train` 分割上对 BLIP-2 进行微调，共 10 轮（epoch）。我们为每块 GPU 使用批次大小（batch size）为 2，整个训练过程在 8 块 V100 GPU 上耗时约 7 小时。我们在 DriveLM-CARLA 的 `train` 分割（关键帧）上训练 BLIP-2，共 6 轮（epoch），在 4 块 A100 GPU 上耗时 6 小时。

4.1 VLM 用于端到端驾驶

在第一个实验中，我们旨在评估 VLM 在 DriveLM-nuScenes 上执行开环（open-loop）规划的能力。特别地，我们研究提供给行为（behavior）和运动（motion）阶段的上下文（context）的影响。给定传感器数据（对于 VLM 方法，还包括文本输入），模型需要以路径点形式预测自车未来轨迹。尽管开环规划存在数据分布不匹配的问题 [50]，我们通过在 DriveLM-nuScenes 中仅对标注的关键帧进行评估来缓解这一问题。

基线方法. 作为任务难度的参考，我们提供一个简单的**指令均值基线**。nuScenes 中的每一帧都与三个指令之一相关联：‘左转’、‘右转’或‘直行’。我们输出训练集中指令与当前测试帧指令匹配的所有轨迹的均值。此外，我们将我们的方法与当前 nuScenes 上最先进的方法 UniAD [32] 进行比较。除其需要视频输入的原始设置外，我们还训练一个单帧版本（‘UniAD-Single’）以进行公平比较。最后，**BLIP-RT-2** 表示在 DriveLM-Data 上使用 Section 3.2 中描述的轨迹 token 化方案进行微调的 BLIP-2 [47]（仅用于运动任务）。这作为使用与 DriveLM-Agent 相同网络架构但没有上下文输入或视觉问答（VQA）训练数据时的性能指标。

DriveLM-Agent. 我们考虑逐步纳入所提出变更的 3 种 DriveLM-Agent 变体：(1) 两阶段版本，先预测行为再预测运动（如 Section 2.1 所述），但行为预测不使用任何 P_{1-3} 上下文（‘None’）；(2) ‘Chain’ 版本，构建 P_{1-3} 图，但仅将最终节点（ P_3 ）传递给行为阶段；(3) 完整模型（‘Graph’），使用 P_{1-3} 中的所有问答对作为 B 的上下文。

实验结果. 我们在 Table 4.1 中展示了上述方法的结果。在基线方法中，BLIP-RT-2 无法匹敌 UniAD-Single（尽管两者相对于指令均值均表现良好）。这表明没有任何推理的单阶段方法无法与 nuScenes 上先前最先进的方法竞争。然而，所提出

表 2: DriveLM-nuScenes 上的开环规划和 Waymo 上跨传感器配置的零样本泛化。在 nuScenes 上, 使用行为 (B) 作为运动 (M) 的上下文使得视觉语言模型 (VLM) 的端到端驾驶能力与最先进的专用驾驶架构 UniAD-Single 相当。在 Waymo 上, 我们在 DriveLM-nuScenes 上训练后, 从 Waymo val 集中随机采样了 1000 帧。DriveLM-Agent 优于 UniAD-Single, 并受益于图上下文。

方法	行为 (B) 上下文	运动 (M) 上下文	nuScenes					Waymo				
			行为 (B)		运动 (M)			行为 (B)		运动 (M)		
			准确率 $\uparrow$	速度 $\uparrow$	转向 $\uparrow$	ADE $\downarrow$	碰撞率 $\downarrow$	准确率 $\uparrow$	速度 $\uparrow$	转向 $\uparrow$	ADE $\downarrow$	碰撞率 $\downarrow$
指令均值	-	-	-	-	-	4.57	5.72	-	-	-	7.98	11.41
UniAD-Single	-	-	-	-	-	1.80	2.62	-	-	-	4.16	9.31
BLIP-RT-2	-	-	-	-	-	2.63	2.77	-	-	-	2.78	6.47
DriveLM-Agent	无	B	61.45	72.20	84.73	1.39	1.67	35.70	43.90	65.20	2.76	6.59
	链式	B	50.43	60.32	75.34	2.07	2.08	34.62	41.28	64.55	2.85	6.89
	图	B	57.49	69.89	80.63	1.74	1.89	39.73	54.29	70.35	2.63	6.17
UniAD [32]	-	-	-	-	-	0.80	0.17	-	-	-	-	-




图 4: DriveLM-Agent 的定性结果。(左) DriveLM-nuScenes val 帧, (右) Waymo val 帧。我们展示问题 (Q)、上下文 (C) 和预测答案 (A)。DriveLM-Agent 的输出易于人类用户理解。

的 DriveLM-Agent 将行为预测作为运动的中间步骤, 显著提升了性能, 超越了 UniAD-Single。这表明通过适当的提示方式, VLM 在端到端驾驶中可以具有出人意料的竞争力。有趣的是, 在不涉及泛化的实验设置中, DriveLM-Agent 的 Chain 和 Graph 版本相较于无上下文并未带来进一步提升。此外, 单帧 VLM 的表现逊于具有更丰富信息的基于视频的 UniAD 模型, 表明具有视频输入的 VLM 可能对此任务是必要的。我们在补充材料中提供了视频输入 VLM 的结果。

4.2 跨传感器配置的泛化

作为评估 Section 4.1 中模型的更具挑战性的设置, 我们现在将模型直接应用于新领域 Waymo 数据集 [77], 无需进一步训练。Waymo 不包含后视摄像头图像, 因此我们为 UniAD-Single 丢弃该输入。VLM 方法仅使用前视图, 不需要任何适配。

实验结果. 如 Table 4.1 所示, UniAD-Single 无法很好地适应新的传感器配置, 性能降至 BLIP-RT-2 之下。DriveLM-Agent 的多阶段方法带来了进一步提升。特

表 3: DriveLM-nuScenes 中的逐问题分析。 P_{x-y} 的问题列于 Section 4.3。使用预测和规划阶段的问答对作为行为问题的上下文相比仅使用感知能够提升性能。然而，同一阶段内不同问题的性能略有差异。

编号	感知			预测			规划			准确率 $\uparrow$	行为	
	P_{1-1}	P_{1-2}	P_{1-3}	P_{2-1}	P_{2-2}	P_{2-3}	P_{3-1}	P_{3-2}	P_{3-3}		速度 $\uparrow$	转向 $\uparrow$
1	✓	-	-	-	-	-	-	-	-	54.69	66.83	75.22
2	✓	✓	-	-	-	-	-	-	-	55.32	67.33	74.34
3	✓	✓	✓	-	-	-	-	-	-	53.94	65.33	75.72
4	✓	✓	✓	✓	-	-	-	-	-	58.82	71.83	80.98
5	✓	✓	✓	✓	✓	-	-	-	-	57.07	71.96	78.97
6	✓	✓	✓	✓	✓	✓	-	-	-	57.70	72.22	79.22
7	✓	✓	✓	✓	✓	✓	✓	-	-	58.95	72.59	80.23
8	✓	✓	✓	✓	✓	✓	✓	✓	-	57.95	72.97	79.97
9	✓	✓	✓	✓	✓	✓	✓	✓	✓	57.49	69.89	80.63

别地，速度预测的准确率从无上下文时的 43.90 提升到完整图时的 54.29。另一方面，链式方法未能提供足够的有用信息，速度准确率仅为 41.28。

我们在 Fig. 4 中展示了 DriveLM-Agent 在 nuScenes 和 Waymo 上的定性结果。该模型通常提供直观的答案，仅少数例外（*e.g.*，在 DriveLM-nuScenes 上的规划，在 Waymo 上的感知）。这表明图视觉问答（GVQA）在交互式驾驶系统中的实用性。此外，在 Waymo 上，尽管感知不完美，我们仍观察到有意义的预测和规划答案。更多可视化结果详见补充材料。

4.3 DriveLM-nuScenes 中的问题层面分析

接下来，我们通过将各类问答对添加为上下文来分析其对行为性能的影响。首先，在每个阶段选择一组代表性问答对。然后，我们在不同问答对组合上训练 BLIP-2，并将这些问答对作为行为问题的上下文添加（Table 3）。

各阶段的代表性问答对。 我们在各阶段选择不同的代表性问答对集合如下：

- P_{1-1} : 当前场景中的重要物体有哪些？
- P_{1-2} : 物体 X 的运动状态是什么？
- P_{1-3} : 物体 X 的视觉描述是什么？
- P_{2-1} : 物体 X 的未来状态是什么？
- P_{2-2} : 物体 X 是否在自行车行驶方向上？
- P_{2-3} : 当自行车到达下一个可能位置时，自行车应第一/第二/第三注意哪个物体？
- P_{3-1} : 基于对物体 X 的观察，自行车可以采取哪些行动？
- P_{3-2} : 自行车采取哪些行动可能导致与物体 X 发生碰撞？
- P_{3-3} : 在此场景中，自行车可以采取哪些安全行动？

选择理由如下：1) 从统计上看，这些问答对约占三个阶段总问答对的 60%。2) 从主观上看，它们代表了人类驾驶所需的大部分信息。补充材料中提供了更粗略的阶段级分析供进一步研究。

实验结果。 我们的结果如 Table 3 所示。我们观察到，使用预测和规划阶段的问答对（ID 4-9）进行训练相比仅使用感知阶段问答对（ID 1-3）性能有所提升。添加规划阶段的问答对（ID 7-9）相较于其前一阶段（ID 4-6）并未显著提升性能。原因可能是其他车辆的未来状态已包含做出行为决策所需的全部信息。

表 4: 基线 P_{1-3} 结果。DriveLM-Agent 和零样本 BLIP-2 都受益于我们的图结构提供的逐步推理过程。

上下文	DriveLM-nuScenes (P_{1-3})				DriveLM-CARLA (P_{1-3})			
	BLIP-2 [47]		DriveLM-Agent		BLIP-2 [47]		DriveLM-Agent	
	SPICE $\uparrow$	GPT 评分 $\uparrow$	SPICE $\uparrow$	GPT 评分 $\uparrow$	SPICE $\uparrow$	GPT 评分 $\uparrow$	SPICE $\uparrow$	GPT 评分 $\uparrow$
无图	4.34	42.97	42.56	71.39	10.46	46.37	72.71	79.67
	7.71	45.21	49.54	72.51	10.30	55.03	75.26	81.78
真值	8.19	41.10	50.29	72.94	16.18	57.98	79.07	83.13

4.4 基于 GVQA 的 P_{1-3} 性能

在最后一个实验中，我们建立了 GVQA 中 P_{1-3} 阶段的基线结果，研究了上下文的影响。我们使用两种 VLM：现成的 BLIP-2 [47]（未在 DriveLM 上微调）以及所提出的 DriveLM-Agent。

基线方法. 我们考虑无上下文的下界（‘None’），其训练和评估设置与标准 VQA 相同（输入图像和问题，输出答案）。作为每种架构的上界，我们执行 GVQA，但在测试时将真实上下文（‘GT’）而非模型自身的先前预测输入模型。

实验结果. 我们的结果总结在 Table 4 中。可以观察到，DriveLM-nuScenes 对两种模型都更具挑战性，在所有上下文设置中其在 DriveLM-nuScenes 上的得分均低于 DriveLM-CARLA。这很可能是因为 DriveLM-nuScenes 中人类答案的多样性较高，而 CARLA 中的答案为基于规则的生成。在两个数据集上，在 DriveLM 上微调的 DriveLM-Agent 显著优于以零样本（zero-shot）方式应用的 BLIP-2。在两个数据集和两种情况下（零样本和微调），我们看到了基于图的结构潜力。有关确切的评估设置和逐问题性能分析，请参见补充材料。

5 相关工作

自动驾驶中的泛化. 对”长尾（long tail）”极端情况（corner case）的泛化（generalization）不足，给自动驾驶（Autonomous Driving, AD）系统带来了重大安全隐患 [10, 79, 80]。为解决此问题，现有研究主要致力于数据驱动方法 [1, 9, 29, 78, 88]。例如，TrafficSim [78] 通过仿真收集更多安全关键场景下的数据。一个新兴方向是利用语义信息来监督对未见或异常物体的检测 [14, 24, 63, 89]。即便如此，自动驾驶（AD）系统的零样本（zero-shot）性能目前仍不尽人意。本文提出了一种实现更好泛化的新途径：利用图视觉问答（Graph VQA, GVQA）学习逻辑推理。

基于语言的驾驶. 多种同期方法尝试将多模态输入融入大语言模型（Large Language Model, LLM）以完成自动驾驶（AD）任务 [11, 14, 28, 39, 57–59, 63, 72, 73, 81, 89, 91, 94, 102, 104]。具体而言，GPT-Driver [57] 和 LLM-Driver [11] 将感知到的场景状态编码为提示（prompt），依靠大语言模型（LLM）制定合理规划。DriveGPT4 [102] 将原始传感器（sensor）数据投影为令牌，并利用大语言模型（LLM）进行控制信号的端到端（end-to-end）预测和解释。尽管已有这些初步尝试，但通过大语言模型（LLM）解决自动驾驶（AD）中的泛化问题仍有待挖掘的潜力。我们的工作将视觉语言模型（VLM）与来自 DriveLM 的图结构问答训练相结合。这使我们能够展示零样本（zero-shot）端到端规划的优越性，这是同期研究尚未证实的。

6 讨论

尽管 DriveLM 展现出令人期待的泛化 (generalization) 能力, 但本研究仍存在一些值得关注的局限性。

- **效率受限。** 继承了大语言模型 (Large Language Model, LLM) 的不足, 我们的基线模型推理时间较长, 特别是由于需要基于图结构进行多轮预测 (约比 UniAD 慢 $10\times$, 如 Table 5所示)。核心问题在于当前模型吞吐量较慢 (**8.5 tokens/s** in DriveLM-Agent), 这可能影响实际应用。然而, 大语言模型 (LLM) 近几个月来速度已提升数个数量级 [74, 100], 这是一个受到广泛关注的通用课题。我们相信, 正交研究的快速进展可以缓解这一问题。
- **驾驶专用输入。** DriveLM-Agent 直接应用视觉语言模型 (VLM) 的视觉模块, 以低分辨率前视图图像作为输入。LiDAR 等驾驶专用传感器 (sensor) 数据无法处理。这导致缺乏时序信息和 360 度场景理解。由于图结构允许不同节点使用多种输入帧, 将 DriveLM-Agent 扩展到多视图图像是直接的。我们将多模态和多帧输入方案留待未来探索。
- **闭环 (closed-loop) 规划。** 我们的方法目前仅在开环 (open-loop) 方案下进行评估。在此设置下, 加入自车状态作为输入可以显著提升指标, 但其效果可能无法很好地迁移到真实世界, 因此我们仅考虑不采用此类输入的方法。以可承受的训练时间和计算成本将工作扩展到闭环设置是一个值得探索的方向。通过使用 CARLA, 我们为视觉语言模型 (VLM) 在闭环规划方向上的更多研究提供了良好的基础。

结论。 我们展示了如何利用视觉语言模型 (VLM) 作为端到端 (end-to-end) 自动驾驶代理, 相比于特定任务驾驶栈具有更好的泛化 (generalization) 能力。为此, 我们提出了图视觉问答 (Graph VQA, GVQA) 任务以及新的数据集和评价指标。借助这些工具, 我们构建了一个架构简单的基线方法, 并取得了令人期待的结果。

致谢

OpenDriveLab 团队隶属于上海人工智能实验室, 并得到国家重点研发计划 (2022ZD0160104) 和国家自然科学基金 (62206172) 的资助。本文部分得到国家重点研发计划 No.2022ZD0161000 以及香港特别行政区研究资助局项目 No.17200622 和 17209324 的支持。本研究还得到 BMBF (图宾根人工智能中心, FKZ: 01IS18039A)、DFG (SFB 1233, TP 17, 项目编号: 276693517) 以及 EXC (编号 2064/1 – 项目编号 390727645) 的资助。我们感谢国际马克斯·普朗克智能系统研究院 (IMPRS-IS) 对 K. Renz 和 K. Chitta 的支持。感谢王泰 (Tai Wang) 的宝贵意见, 秦靖文 (Qingwen Bu) 对插图的完善, 以及杨嘉智 (Jiazhi Yang)、高深远 (Shenyuan Gao)、邱亦杭 (Yihang Qiu)、李添羽 (Tianyu Li)、周云松 (Yunsong Zhou)、杨泽通 (Zetong Yang)、Julian Zimmerlin 的富有成效的讨论。

表 5: 与 UniAD-Single 相比, DriveLM-Agent 具有更少的可训练参数但推理成本更高。

方法	参数量	可训练参数	FLOPs	FPS
UniAD-Single	131.9M	58.8M	1.7T	1.8
DriveLM-Agent	3.955B	12.9M	24.2T	0.16

参考文献

1. Akhauri, S., Zheng, L.Y., Lin, M.C.: Enhanced transfer learning for autonomous driving with systematic accident simulation. In: IROS (2020)
2. Anderson, P., Fernando, B., Johnson, M., Gould, S.: Spice: Semantic propositional image caption evaluation. In: ECCV (2016)
3. Atakishiyev, S., Salameh, M., Babiker, H., Goebel, R.: Explaining autonomous driving actions with visual question answering. arXiv preprint arXiv:2307.10408 (2023)
4. Beißwenger, J.: PDM-Lite: A rule-based planner for carla leaderboard 2.0. <https://github.com/OpenDriveLab/DriveLM/blob/DriveLM-CARLA/docs/report.pdf> (2024)
5. Besta, M., Blach, N., Kubicek, A., Gerstenberger, R., Gianinazzi, L., Gajda, J., Lehmann, T., Podstawski, M., Niewiadomski, H., et al.: Graph of Thoughts: Solving Elaborate Problems with Large Language Models. arXiv preprint arXiv:2308.09687 (2023)
6. Caesar, H., Bankiti, V., Lang, A.H., Vora, S., Liong, V.E., Xu, Q., Krishnan, A., Pan, Y., Baldan, G., Beijbom, O.: nuScenes: A multimodal dataset for autonomous driving. In: CVPR (2020)
7. Caesar, H., Kabzan, J., Tan, K.S., Fong, W.K., Wolff, E.M., Lang, A.H., Fletcher, L., Beijbom, O., Omari, S.: nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. In: CVPR Workshops (2021)
8. Chen, D., Koltun, V., Krähenbühl, P.: Learning to drive from a world on rails. In: ICCV (2021)
9. Chen, D., Krähenbühl, P.: Learning from all vehicles. In: CVPR (2022)
10. Chen, L., Wu, P., Chitta, K., Jaeger, B., Geiger, A., Li, H.: End-to-end autonomous driving: Challenges and frontiers. arXiv preprint arXiv:2306.16927 (2023)
11. Chen, L., Sinavski, O., Hünemann, J., Karnsund, A., Willmott, A.J., Birch, D., Maund, D., Shotton, J.: Driving with llms: Fusing object-level vector modality for explainable autonomous driving. arXiv preprint arXiv:2310.01957 (2023)
12. Chen, X., Jia, S., Xiang, Y.: A review: Knowledge reasoning over knowledge graph. Expert Syst. Appl (2020)
13. Chen, Y., Rohrbach, M., Yan, Z., Shuicheng, Y., Feng, J., Kalantidis, Y.: Graph-based global reasoning networks. In: CVPR (2019)
14. Chen, Y., Tonkens, S., Pavone, M.: Categorical traffic transformer: Interpretable and diverse behavior prediction with tokenized latent. arXiv preprint arXiv:2311.18307 (2023)
15. Chib, P.S., Singh, P.: Recent advancements in end-to-end autonomous driving using deep learning: A survey. IEEE T-IV (2023)
16. Chitta, K., Prakash, A., Geiger, A.: Neat: Neural attention fields for end-to-end autonomous driving. In: ICCV (2021)
17. Chitta, K., Prakash, A., Jaeger, B., Yu, Z., Renz, K., , Geiger, A.: Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. IEEE T-PAMI (2023)
18. Database, A.I.: Incident 293: Cruise’s self-driving car involved in a multiple-injury collision at an san francisco intersection. <https://incidentdatabase.ai/cite/293/> (2022)
19. Dauner, D., Hallgarten, M., Geiger, A., Chitta, K.: Parting with misconceptions about learning-based vehicle motion planning. In: CoRL (2023)

20. Dewangan, V., Choudhary, T., Chandhok, S., Priyadarshan, S., Jain, A., Singh, A., Srivastava, S., Jatavallabhula, K., Krishna, M.: Talk2BEV: Language-enhanced bird's-eye view maps for autonomous driving. *arXiv preprint arXiv:2310.02251* (2023)
21. Ding, R., Zhang, C., Wang, L., Xu, Y., Ma, M., Zhang, W., Qin, S., Rajmohan, S., Lin, Q., Zhang, D.: Everything of thoughts: Defying the law of penrose triangle for thought generation. *arXiv preprint arXiv:2311.04254* (2023)
22. Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A., Koltun, V.: CARLA: An open urban driving simulator. In: *CoRL* (2017)
23. Driess, D., Xia, F., Sajjadi, M.S.M., Lynch, C., Chowdhery, A., Ichter, B., Wahid, A., Tompson, J., Vuong, Q., et al.: PaLM-E: An embodied multimodal language model. In: *ICML* (2023)
24. Elhafi, A., Sinha, R., Agia, C., Schmerling, E., Nesnas, I.A., Pavone, M.: Semantic anomaly detection with large language models. *Auton. Robot* (2023)
25. Floridi, L., Chiriatti, M.: GPT-3: Its nature, scope, limits, and consequences. *MIND MACH* (2020)
26. Gao, P., Han, J., Zhang, R., Lin, Z., Geng, S., Zhou, A., Zhang, W., Lu, P., He, C., Yue, X., Li, H., Qiao, Y.: LLaMA-Adapter v2: Parameter-efficient visual instruction model. *arXiv preprint arXiv:2304.15010* (2023)
27. Groeger, J.A.: *Understanding driving: Applying cognitive psychology to a complex everyday task*. Routledge (2013)
28. Han, W., Guo, D., Xu, C.Z., Shen, J.: DME-Driver: Integrating human decision logic and 3d scene perception in autonomous driving. *arXiv preprint arXiv:2401.03641* (2024)
29. Hanselmann, N., Renz, K., Chitta, K., Bhattacharyya, A., Geiger, A.: King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients. In: *ECCV* (2022)
30. Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W.: LoRA: Low-rank adaptation of large language models. In: *CoRL* (2021)
31. Hu, S., Chen, L., Wu, P., Li, H., Yan, J., Tao, D.: St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning. In: *ECCV* (2022)
32. Hu, Y., Yang, J., Chen, L., Li, K., Sima, C., Zhu, X., Chai, S., Du, S., Lin, T., et al.: Planning-oriented autonomous driving. In: *CVPR* (2023)
33. Huang, W., Xia, F., Xiao, T., Chan, H., Liang, J., Florence, P., Zeng, A., Tompson, J., Mordatch, I., et al.: Inner monologue: Embodied reasoning through planning with language models. In: *CoRL* (2022)
34. Hudson, D.A., Manning, C.D.: Gqa: A new dataset for real-world visual reasoning and compositional question answering. In: *CVPR* (2019)
35. Ichter, B., Brohan, A., Chebotar, Y., Finn, C., Hausman, K., Herzog, A., Ho, D., Ibarz, J., Irpan, A., et al.: Do as i can, not as i say: Grounding language in robotic affordances. In: *CoRL* (2023)
36. Jaeger, B., Chitta, K., Geiger, A.: Hidden biases of end-to-end driving models. In: *ICCV* (2023)
37. Jaeger, B., Chitta, K., Geiger, A.: Hidden biases of end-to-end driving models. In: *ICCV* (2023)
38. Jelinek, F., Lafferty, J.D., Mercer, R.L.: *Basic methods of probabilistic context free grammars*. Springer, Berlin, Heidelberg (1992)
39. Jin, B., Liu, X., Zheng, Y., Li, P., Zhao, H., Zhang, T., Zheng, Y., Zhou, G., Liu, J.: Adapt: Action-aware driving caption transformer. In: *ICRA* (2023)
40. Karamcheti, S., Nair, S., Chen, A.S., Kollar, T., Finn, C., Sadigh, D., Liang, P.: Language-Driven representation learning for robotics. In: *RSS* (2023)

41. Kim, J., Misu, T., Chen, Y.T., Tawari, A., Canny, J.: Grounding human-to-vehicle advice for self-driving vehicles. In: CVPR (2019)
42. Kim, J., Rohrbach, A., Darrell, T., Canny, J., Akata, Z.: Textual explanations for self-driving vehicles. In: ECCV (2018)
43. Kojima, T., Gu, S.S., Reid, M., Matsuo, Y., Iwasawa, Y.: Large language models are zero-shot reasoners. In: NeurIPS (2022)
44. Lamb, A.M., ALIAS PARTH GOYAL, A.G., Zhang, Y., Zhang, S., Courville, A.C., Bengio, Y.: Professor forcing: A new algorithm for training recurrent networks. In: NeurIPS (2016)
45. Lavie, A., Agarwal, A.: METEOR: An automatic metric for MT evaluation with high levels of correlation with human judgments. In: ACL Workshop (2007)
46. Li, H., Sima, C., Dai, J., Wang, W., Lu, L., Wang, H., Zeng, J., Li, Z., Yang, J., Deng, H., et al.: Delving into the devils of bird’s-eye-view perception: A review, evaluation and recipe. IEEE T-PAMI (2023)
47. Li, J., Li, D., Savarese, S., Hoi, S.: BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In: ICML (2023)
48. Li, K., Chen, K., Wang, H., Hong, L., Ye, C., Han, J., Chen, Y., Zhang, W., Xu, C., Yeung, D.Y., et al.: CODA: A real-world road corner case dataset for object detection in autonomous driving. In: ECCV (2022)
49. Li, Z., Wang, W., Li, H., Xie, E., Sima, C., Lu, T., Qiao, Y., Dai, J.: Bevfomer: Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers. In: ECCV (2022)
50. Li, Z., Yu, Z., Lan, S., Li, J., Kautz, J., Lu, T., Alvarez, J.M.: Is ego status all you need for open-loop end-to-end autonomous driving? (2023)
51. Liang, J., Huang, W., Xia, F., Xu, P., Hausman, K., Ichter, B., Florence, P., Zeng, A.: Code as policies: Language model programs for embodied control. In: ICRA (2023)
52. Lin, C.Y.: Rouge: A package for automatic evaluation of summaries. In: ACL Workshop (2004)
53. Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L.: Microsoft coco: Common objects in context. In: ECCV (2014)
54. Liu, H., Li, C., Wu, Q., Lee, Y.J.: Visual instruction tuning. In: NeurIPS (2023)
55. Macadam, C.C.: Understanding and modeling the human driver. Veh. Syst. Dyn (2003)
56. Malla, S., Choi, C., Dwivedi, I., Choi, J.H., Li, J.: DRAMA: Joint risk localization and captioning in driving. In: WACV (2023)
57. Mao, J., Qian, Y., Zhao, H., Wang, Y.: GPT-Driver: Learning to drive with gpt. arXiv preprint arXiv:2310.01415 (2023)
58. Mao, J., Ye, J., Qian, Y., Pavone, M., Wang, Y.: A language agent for autonomous driving. arXiv preprint arXiv:2311.10813 (2023)
59. Marcu, A.M., Chen, L., Hünermann, J., Karnsund, A., Hanotte, B., Chidananda, P., Nair, S., Badrinarayanan, V., Kendall, A., et al.: LingoQA: Video question answering for autonomous driving. arXiv preprint arXiv:2312.14115 (2023)
60. Marr, D.: Vision: A computational investigation into the human representation and processing of visual information. The MIT Press (2010)
61. OpenAI: OpenAI: Introducing ChatGPT. <https://openai.com/blog/chatgpt> (2022)
62. Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., et al.: Training language models to follow instructions with human feedback. In: NeurIPS (2022)

63. Pan, C., Yaman, B., Nesti, T., Mallik, A., Allievi, A.G., Velipasalar, S., Ren, L.: VLP: Vision language planning for autonomous driving. arXiv preprint arXiv:2401.05577 (2024)
64. Papineni, K., Roukos, S., Ward, T., Zhu, W.J.: Bleu: a method for automatic evaluation of machine translation. In: ACL (2002)
65. Peng, Z., Wang, W., Dong, L., Hao, Y., Huang, S., Ma, S., Wei, F.: Kosmos-2: Grounding multimodal large language models to the world. arXiv preprint arXiv:2306.14824 (2023)
66. Prakash, A., Chitta, K., Geiger, A.: Multi-modal fusion transformer for end-to-end autonomous driving. In: CVPR (2021)
67. Qian, T., Chen, J., Zhuo, L., Jiao, Y., Jiang, Y.G.: NuScenes-QA: A multi-modal visual question answering benchmark for autonomous driving scenario. arXiv preprint arXiv:2305.14836 (2023)
68. Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I.: Language models are unsupervised multitask learners. OpenAI blog (2019)
69. Rana, K., Haviland, J., Garg, S., Abou-Chakra, J., Reid, I., Suenderhauf, N.: SayPlan: Grounding large language models using 3d scene graphs for scalable robot task planning. In: CoRL (2023)
70. Renz, K., Chitta, K., Mercea, O.B., Koepke, A.S., Akata, Z., Geiger, A.: Plant: Explainable planning transformers via object-level representations. In: CoRL (2022)
71. Sachdeva, E., Agarwal, N., Chundi, S., Roelofs, S., Li, J., Dariush, B., Choi, C., Kochenderfer, M.: Rank2Tell: A multimodal driving dataset for joint importance ranking and reasoning. arXiv preprint arXiv:2309.06597 (2023)
72. Seff, A., Cera, B., Chen, D., Ng, M., Zhou, A., Nayakanti, N., Refaat, K.S., Al-Rfou, R., Sapp, B.: MotionLM: Multi-agent motion forecasting as language modeling. In: ICCV (2023)
73. Shao, H., Hu, Y., Wang, L., Waslander, S.L., Liu, Y., Li, H.: LMDrive: Closed-loop end-to-end driving with large language models. arXiv preprint arXiv:2312.07488 (2023)
74. Shi, D., Tao, C., Rao, A., Yang, Z., Yuan, C., Wang, J.: Crossget: Cross-guided ensemble of tokens for accelerating vision-language transformers (2023)
75. Shi, J., Zhang, H., Li, J.: Explainable and explicit visual reasoning over scene graphs. In: CVPR (2019)
76. Spelke, E.S., Kinzler, K.D.: Core knowledge. Dev Sci (2007)
77. Sun, P., Kretschmar, H., Dotiwalla, X., Chouard, A., Patnaik, V., Tsui, P., Guo, J., Zhou, Y., Chai, Y., Caine, B., et al.: Scalability in perception for autonomous driving: Waymo open dataset. In: CVPR (2020)
78. Suo, S., Regalado, S., Casas, S., Urtasun, R.: Trafficsim: Learning to simulate realistic multi-agent behaviors. In: CVPR (2021)
79. Tampuu, A., Matiisen, T., Semikin, M., Fishman, D., Muhammad, N.: A survey of end-to-end driving: Architectures and training methods. IEEE T-NNLS (2020)
80. Teng, S., Hu, X., Deng, P., Li, B., Li, Y., Ai, Y., Yang, D., Li, L., Xuanyuan, Z., Zhu, F., et al.: Motion planning for autonomous driving: The state of the art and future perspectives. IEEE T-IV (2023)
81. Tian, X., Gu, J., Li, B., Liu, Y., Hu, C., Wang, Y., Zhan, K., Jia, P., Lang, X., Zhao, H.: DriveVLM: The convergence of autonomous driving and large vision-language models. arXiv preprint arXiv:2402.12289 (2024)
82. Toomarian, N.B., Barhen, J.: Learning a trajectory using adjoint functions and teacher forcing. Neural networks (1992)

83. Touvron, H., Martin, L., Stone, K.R., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., et al.: Llama 2: Open foundation and fine-tuned chat models. arXiv preprint arXiv:2307.09288 (2023)
84. Treiber, M., Hennecke, A., Helbing, D.: Congested traffic states in empirical observations and microscopic simulations. *Physical Review E* **62**(2) (2000)
85. Treiber, M., Hennecke, A., Helbing, D.: Congested traffic states in empirical observations and microscopic simulations. *Physical review E* (2000)
86. Vedantam, R., Lawrence Zitnick, C., Parikh, D.: Cider: Consensus-based image description evaluation. In: CVPR (2015)
87. Wang, H., Li, T., Li, Y., Chen, L., Sima, C., Liu, Z., Wang, B., Jia, P., Wang, Y., Jiang, S., et al.: OpenLane-V2: A topology reasoning benchmark for unified 3d HD mapping. In: NeurIPS Datasets and Benchmarks (2023)
88. Wang, J., Pun, A., Tu, J., Manivasagam, S., Sadat, A., Casas, S., Ren, M., Urtasun, R.: Advsim: Generating safety-critical scenarios for self-driving vehicles. In: CVPR (2021)
89. Wang, T.H., Maalouf, A., Xiao, W., Ban, Y., Amini, A., Rosman, G., Karaman, S., Rus, D.: Drive anywhere: Generalizable end-to-end autonomous driving with multi-modal foundation models. arXiv preprint arXiv:2310.17642 (2023)
90. Wang, W., Chen, Z., Chen, X., Wu, J., Zhu, X., Zeng, G., Luo, P., Lu, T., Zhou, J., Qiao, Y., Dai, J.: VisionLLM: Large language model is also an open-ended decoder for vision-centric tasks. arXiv preprint arXiv:2305.11175 (2023)
91. Wang, W., Xie, J., Hu, C., Zou, H., Fan, J., Tong, W., Wen, Y., Wu, S., Deng, H., et al.: DriveMLM: Aligning multi-modal large language models with behavioral planning states for autonomous driving. arXiv preprint arXiv:2312.09245 (2023)
92. Wang, X., Wang, D., Xu, C., He, X., Cao, Y., Chua, T.S.: Explainable reasoning over knowledge graphs for recommendation. In: AAAI (2019)
93. Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., Zhou, D.: Self-Consistency improves chain of thought reasoning in language models. In: ICLR (2023)
94. Wayve: Lingo-1. <https://wayve.ai/thinking/lingo-natural-language-autonomous-driving/> (2023)
95. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., Zhou, D.: Chain-of-thought prompting elicits reasoning in large language models. In: NeurIPS (2022)
96. Wen, C., Lin, J., Qian, J., Gao, Y., Jayaraman, D.: Keyframe-focused visual imitation learning. In: ICML (2021)
97. Wu, D., Han, W., Wang, T., Dong, X., Zhang, X., Shen, J.: Referring Multi-Object tracking. In: CVPR (2023)
98. Wu, D., Han, W., Wang, T., Liu, Y., Zhang, X., Shen, J.: Language prompt for autonomous driving. arXiv preprint arXiv:2309.04379 (2023)
99. Wu, P., Jia, X., Chen, L., Yan, J., Li, H., Qiao, Y.: Trajectory-guided control prediction for end-to-end autonomous driving: A simple yet strong baseline. In: NeurIPS (2022)
100. Xiao, G., Lin, J., Seznec, M., Wu, H., Demouth, J., Han, S.: SmoothQuant: Accurate and efficient post-training quantization for large language models. In: Proceedings of the 40th International Conference on Machine Learning (2023)
101. Xinpeng, D., Jinahua, H., Hang, X., Xiaodan, L., Xu, H., Wei, Z., Xiaomeng, L.: Holistic autonomous driving understanding by bird’s-eye-view injected multi-modal large models. In: CVPR (2024)

102. Xu, Z., Zhang, Y., Xie, E., Zhao, Z., Guo, Y., Wong, K.K., Li, Z., Zhao, H.: DriveGPT4: Interpretable end-to-end autonomous driving via large language model. arXiv preprint arXiv:2310.01412 (2023)
103. Yao, S., Yu, D., Zhao, J., Shafran, I., Griffiths, T.L., Cao, Y., Narasimhan, K.: Tree of Thoughts: Deliberate problem solving with large language models. arXiv preprint arXiv:2305.10601 (2023)
104. Yuan, J., Sun, S., Omeiza, D., Zhao, B., Newman, P., Kunze, L., Gadd, M.: RAG-Driver: Generalisable driving explanations with retrieval-augmented in-context learning in multi-modal large language model. arXiv preprint arXiv:2402.10828 (2024)
105. Zareian, A., Rosa, K.D., Hu, D.H., Chang, S.F.: Open-vocabulary object detection using captions. In: CVPR (2021)
106. Zhang, R., Han, J., Zhou, A., Hu, X., Yan, S., Lu, P., Li, H., Gao, P., Qiao, Y.: LLaMA-Adapter: Efficient fine-tuning of language models with zero-init attention. arXiv preprint arXiv:2303.16199 (2023)
107. Zhou, X., Liu, M., Zagar, B.L., Yurtsever, E., Knoll, A.C.: Vision language models in autonomous driving and intelligent transportation systems. arXiv preprint arXiv:2310.14414 (2023)
108. Zitkovich, B., Yu, T., Xu, S., Xu, P., Xiao, T., Xia, F., Wu, J., Wohlhart, P., Welker, S., et al.: RT-2: Vision-language-action models transfer web knowledge to robotic control. In: CoRL (2023)

概览

在以下附录中, 我们首先深入探讨各项讨论, 以及 DriveLM-nuScenes 和-CARLA 标注过程、图视觉问答 (GVQA) 指标、(trajectory tokenization) 的额外细节, 以及 DriveLM-nuScenes 和 Waymo 上更多关于。最后, 我们提供补充正文研究结果的额外结果和可视化。

为便于读者关注特定主题, 我们在下方提供总结:

附录 A – 引导性问题

我们整理了一系列阅读正文时可能产生的”引导性”问题并在此进一步展开(例如, ”为何将通用视觉语言模型 (VLM) 适配到驾驶领域”)。这些问题有待探索, 因此我们的回答是直觉性和经验性的。

附录 B – *DriveLM-nuScenes*

我们介绍 DriveLM-nuScenes 数据集构成、详细标注流程, 并进行问答类别的统计分析。

附录 C – *DriveLM-CARLA*

我们详细介绍 PDM-Lite 专家算法、数据集构成、图结构, 并解释数据生成和标注过程。

附录 D – *DriveLM-Metrics*

我们解释图视觉问答 (GVQA) 中各任务的指标细节, 说明其差异, 并提供将 GPT 评分 (GPT-score) 作为 P_{1-3} 视觉问答 (VQA) 任务主要指标的原因。

附录 E – *DriveLM-Agent*

我们介绍带上下文的提示 (prompting) 设计和轨迹分词 (trajectory tokenization) 的详细方案, 包括训练和评估时上下文的差异、轨迹作为句子的模式以及分词器 (tokenizer) 的超参数。

附录 F – 实验

我们提供更多实验，包括对未见物体的泛化、更多上下文设计对零样本 (zero-shot) 能力的影响、传统视觉问答 (VQA) 指标下的性能以及模型效率对比。

附录 G – 定性结果

我们展示 nuScenes、Waymo 和 CARLA 上关于上下文、问题和答案的定性示例。此外，我们在 nuScenes 上对比预测答案与真值 (ground truth) 答案及其 SPICE 和 GPT 评分，以提供对两类指标的直观认识。

附录 H – 其他相关工作

我们从两个新视角提供更多相关工作。一个是与我们的图结构推理 (graph-structure reasoning) 相似的图结构推理，另一个是更多面向自动驾驶的视觉语言基准。

A 引导性问题

Q1. 在哪些情况下，使用视觉语言模型（VLM）进行规划可能优于传统端到端自动驾驶？

自动驾驶的关键挑战之一在于泛化（generalization）到长尾（long-tail）场景，这些场景虽极少出现但至关重要。考虑到视觉语言模型（VLM）的大规模预训练、其所获取的世界知识以及大语言模型（LLM）的推理能力，预期在驾驶场景中未见或新颖但在预训练中于不相关上下文里出现过的情况下，使用视觉语言模型（VLM）进行规划将表现更佳。

Q2. 为何将通用视觉语言模型（VLM）适配到驾驶领域，而非向驾驶专用模型添加语言输入？

通用视觉语言模型（VLM）受益于从互联网提取的数十亿级视觉语言任务预训练数据，可通过在像（fine-tuning）来适配到驾驶领域。相反，驾驶专用模型仅在小型自动驾驶数据集上预训练，向其中添加来自自动驾驶领域之外的语言输入并非易事。然而，结合视觉语言模型（VLM）和驾驶专用模型的优势是一个值得探索的方向。

Q3. 开环（open-loop）规划评估能否提供有意义的结果？

在进行开环评估时，向规划模块提供自车（ego vehicle）历史作为输入妨碍了公平比较，因为仅凭这一信号就足以在现有基准上实现低误差。DriveLM 通过评估关键帧（key frames）缓解了该问题——关键帧中自车意图发生变化，自车历史并不能强指示未来行为或运动。此外，我们在分析中考虑了那些不向规划模块输入自车历史的基线方法。最后，我们引入 DriveLM-CARLA 作为未来展示闭环（closed-loop）规划结果的手段。

Q4. 为何目前没有 CARLA 上的闭环规划结果？

按照 CARLA 要求以 20 FPS 运行 4B 参数模型需要更多工程投入。这可通过在大语言模型（LLM）推理中使用蒸馏（distillation）、量化（quantization）和缓存（caching）技术来解决。另一方法是仅以 20 FPS 执行，而其他图视觉问答（GVQA）阶段以较低帧率执行。

Q5. ？

我们在正文表 5 中评述了。未经任何优化，该方法比 UniAD 慢约一个数量级。然而，通过针对 CARLA 上闭环结果所提出的优化（见 Q4），视觉语言模型（VLM）在驾驶中的实际应用应是可行的。

Q6. 长推理时间与泛化之间的权衡是什么？

大语言模型（LLM）作为广泛关注的通用课题，近年来速度已提升数个数量级，例如 [100]。类似地，近期工作表明 BLIP-2 可在保持性能的同时提速 40% [74]。此外，大多数自动驾驶研究最初都采用非实时的系统，之后由工程人员优化。我们承认运行时效率是 DriveLM 的一个局限，但希望正交研究的快速进展能缓解该问题，这超出了本项目的范围。

Q7. 为何视觉问答 (VQA) 比替代技术 (如生成式建模) 更适合训练互联网规模模型以应用于自动驾驶下游任务?

驾驶中的感知和规划都需要推理并涉及零样本 (zero-shot) 泛化。视觉语言模型 (VLM) 可能具有继承自大语言模型 (LLM) 的推理能力, 使视觉问答 (VQA) 成为将网络规模训练的优势引入自动驾驶的有前景方向。

Q8. 当今视觉语言模型 (VLM) 对视觉世界的理解和推理能力是否与大语言模型 (LLM) 对文本世界的理解能力相当?

这一点尚不明确, 但值得探索。视觉语言模型 (VLM) 以数据驱动的方式处理泛化问题, 而这种方式已在其他任务上反复被证明成功。

Q9. 为何所提出的图推理方案在视觉问答 (VQA) 中未提供非常显著的改进?

可能是简单的提示 (prompting) 方案、相对较小的基础视觉语言模型 (VLM) 或数据集中逻辑依赖不充分 (或这些因素的组合) 导致未能实现重大改进。DriveLM-CARLA 提供了一个平台来仔细研究这些因素, 并为未来图视觉问答 (GVQA) 数据集标注提供指导。

Q10. 收集 DriveLM 时应提出哪些问题?

确定正确的问题是 DriveLM 系统的关键方面。我们无法在本工作中推荐详细方案——本工作是将视觉语言模型 (VLM) 用于驾驶的开创性研究。这依赖于领域专业知识, 我们计划在未来工作中解决。参见正文表 3 中对所选方案的问题级分析。

Q11. 汽车领域的泛化是否是一个被过度渲染的话题?

驾驶场景主要由车辆、行人和骑行者构成。然而, 实际自动驾驶是安全关键型应用, 必须处理罕见物体的长尾分布以避免商业部署中的事故 [18]。此外, 对新颖物体的泛化是一个活跃且不断增长的研究领域, 如 [48, 105] 所示。虽然自动驾驶中大多数物体种类有限, 但极少数的稀有物体实际上是自动驾驶商业化的主要障碍, 这使得泛化成为重要特性。

Q12. 为何不使用视频输入?

已有研究表明, 在自动驾驶中, 由于因果混淆 (causal confusion) [96], 多帧输入并不总能带来性能提升, 这促使多篇先前工作使用单帧输入 [37, 99]。然而, 我们同意从长远来看, 多帧模型是可取的。作为概念验证, 我们在 Table 13 中提供了基于 LLaMA-Adapter-V2 [26] 改进模型的实验结果。多帧输入带来轻微改进。

Q13. 本文的技术创新点是什么?

驾驶与语言结合这一新兴领域仍缺乏标准化的数据集、任务和评估框架。我们的论文填补了这一空白。我们相信这些与提出新方法同样有价值。因此, 我们不做任何关于算法新颖性的声明, 有意构建简单基线。我们的技术创新在于任务形式的制定以及为适配通用视觉语言模型 (VLM) 到驾驶应用所准备的数据, 即使在结合现有模型的情况下也展现出有前景的结果。

B DriveLM-nuScenes

在本节中，我们介绍 DriveLM-nuScenes 的细节，包括数据集构成、收集方法和统计信息。

B.1 数据集构成

DriveLM-nuScenes 包含 **4072 帧的训练集**和 **799 帧的验证集**，包括场景级描述和帧级问答，并附带 nuScenes 数据集中多视角图像内的二维边界框（2D bounding boxes）。场景级描述描述了自车在整个视频片段中的行为。帧级问答涵盖三个不同类别：感知（perception）、预测（prediction）和规划（planning）。

- **感知**涉及与整个帧全面检查相关的查询。除本问题集中若干手动标注的问题外，我们设计提示（prompts），利用 nuScenes [6] 和 OpenLane-V2 [87] 的真值（ground truth）生成关于场景内物体观察方面的问题。
- **预测**包含一系列关于当前帧中关键物体和自车未来状态投影及其背后推理过程的查询。由于预测复杂且具有挑战性，我们手动标注答案。
- **规划**包含与当前帧中规划自车后续动作相关的问题。由于”规划”与”预测”同样具有挑战性，我们设计推理过程的提示并手动标注问题答案。

对于问答中涉及的关键物体，我们将其编码为 **c 标签（c tags）**，格式为 $\langle c, CAM, x, y \rangle$ ，其中 c 为标识符， CAM 表示物体中心点所在相机， x, y 表示该物体在对应相机坐标系中二维边界框的水平和垂直坐标。我们还在每个关键帧中提供字典，记录关键物体的更多基本信息，如边界框大小、类别、运动状态和视觉描述。数据组织形式概览如图 5 所示。




图 5: DriveLM-nuScenes 的整体构成。数据集包含场景级描述和帧级问答，可分为三部分：感知、预测和规划。物体使用 c 标签（ c tags）编码，包含标识符、相机归属及其在对应相机帧中二维边界框（2D bounding box）的中心坐标。

B.2 收集方法

在标注过程中，我们雇佣具有驾驶经验的人员执行标注任务。我们向标注人员提供 nuScenes 六个相机拼接结果作为源数据。如图 6（左）所示，我们将标注过




图6: (左) 三步标注流程。对每个视频, 我们要求标注人员逐步标注关键帧、关键物体和问答属性。(右) 质量检查与后处理流程。我们将标注数据分为批次, 每批包含 8 个视频片段及其相关标注。我们执行严格的质量检查, 后处理后最终得到 DriveLM-nuScenes 数据集的两个版本。

程分为三步: 从视频片段中选择关键帧、在这些关键帧中选择关键物体, 然后标注关键帧中的帧级问答。随后, 我们执行多轮质量检查以确保数据可靠性, 并对合格数据执行后处理流程, 如图 6 (右) 所示。以下将介绍该流程的具体细节。

关键帧选择 在此过程中, 我们要求标注人员审阅整个视频片段以确定富含场景信息且可能指示未来状态变化的关键帧。同时, 标注人员需标注自行车在整个视频片段中的行为。该部分构成场景级描述的基础。

关键物体选择 在此标注步骤中, 我们指示标注人员识别关键帧中与自动驾驶相关的物体, 称为关键物体。为确保准确性, 我们基于 nuScenes [6] 的真值 (ground truth) 类别提供预标注的边界框 (bounding boxes)。若某些未在真值中出现的物体被认为重要, 标注人员也可将其指定为关键物体。

问答标注 在问答标注过程中, 我们有两类问题: 事实性问题 (factual questions) 和开放性问题 (open-ended questions)。对于事实性问题, 我们使用基于规则的方法生成答案。对于开放性问题, 我们指示标注人员手动标注精心设计的问题。大多数手动标注问题提供选项, 我们在这种情况下包含“其他——填写”选项以确保灵活性。我们还纳入了自由形式问题, 允许标注人员针对当前帧生成自己的查询。

质量检查 我们优先保证数据质量。除了在每个标注步骤建立清晰标准并实施自动检查策略外, 我们执行严格的人工质量检查。我们将最终数据分批次组织, 每批包含 8 个视频片段及其场景级描述、从这 8 个视频片段中选择的关键帧和关键物体, 以及每个关键帧对应的问答对。我们向质检人员提供明确标准, 指示其依据这些标准评估数据合格性。对于手动标注的数据, 若某批次手动标注准确率低于预期, 我们汇总反馈问题并要求标注人员重新标注整个批次。对于从真值生成的数据, 我们指示质检人员手动调整不一致或不合理的问答对。

后处理 由于标注人员为中文母语者, 我们需在获得数据后将标注文本翻译为英文。首先, 我们使用词汇表建立中英文映射。对于未成功映射的文本, 我们利用 GPT-3.5 进行翻译, 然后对 GPT 输出执行人工检查和修正。我们还提供由 GPT-3.5 增强的版本, 使用如 Table 6 所示的提示。


```

Messages = [
  { "role": "system", "content": f"" You are an English improver. "" },
  { "role": "user", "content": f"" I have a question and answer that I need
    you to help me modify and embellish, please make a few simple changes
    to the content in written language and keep the meaning same, you only
    need to answer the changes to: {QA}""0308
  }
]

```

表 6: 用于 DriveLM-nuScenes GPT 精炼版本的提示。我们尝试了 50 种不同提示并选择此模式作为最终精炼方案。




图 7: 感知、预测和规划的问题分布：数据集中问题涵盖驾驶任务的各具体方面，大致分为感知、预测和规划三大类。大多数问题由人工标注人员标注，使其成为类人驾驶推理的合适代理。

B.3 统计与事实

本节中，我们在任务级和物体级对 DriveLM-nuScenes 问答类别进行分布分析。此外，在任务级，我们提供该分类标准下所有问答的模板。结果表明我们的问答类别丰富，涵盖自动驾驶的各个方面。此外，充足的逻辑关系足以构建图结构问答。

任务级 我们的 DriveLM-nuScenes 构建了一个涵盖自动驾驶各方面、连接人类驾驶逻辑全阶段的基准。为深入探讨该方面，我们在 Fig. 8 中展示任务级的详细问答类型分布。为更好理解，我们还提供 Table 7 中所有 P3 阶段的问答模板示例。

感知

周围物体识别

Q: 请描述当前场景。

A: 自车后方有两辆行驶中的汽车，前方有两个障碍物。




图 8: DriveLM-nuScenes 中不同任务的问题类型分布. 我们将问题分为感知、预测和规划任务, 每个任务进一步细分为更具体的问题类型。

Q: 自车左前/右后/... 方向有哪些物体?

A: 自车左前方有两个障碍物。

Q: 自车右前/左后/... 方向是否有交通锥/行驶中的汽车/...?

A: 没有。

交通要素识别

Q: 前视图中是否有交通要素?

A: 是的, 前视图中存在一些交通要素。

Q: 识别前视图中所有交通要素, 进行分类, 确定其状态, 并预测每个要素周围的边界框。输出应为列表形式: (c, s, x1, y1, x2, y2), 其中 c 表示类别, s 表示状态, x1、y1、x2、y2 为边界框左上角和右下角相对于中心点的偏移量。

A: 前视图中有三个交通要素。这些交通要素的信息为 [(road sign, go straight, 907.58, 590.67, 992.54, 630.95)...]。

重要物体识别

Q: 当前场景中有哪些重要物体? 这些物体将被纳入后续推理和驾驶决策。

A: 自车后方有一辆停放的卡车... 这些物体的 ID 为 <c1,CAM_BACK,827.5,484.2>...

Q: 当前场景中重要物体的相对位置如何?

A: <c3,CAM_FRONT,689.2,527.5> 位于 <c1,CAM_BACK,827.5,484.2> 的前方...

Q: 场景中每个重要物体在哪条车道上?

A: <c2,CAM_FRONT,820.8,473.3> 位于自车车道...

视觉描述

Q: <c2,CAM_FRONT_LEFT,415.8,580.8>/... 的视觉描述是什么?

A: 骑自行车的行人。

运动状态

Q: 位于自车前/右前/... 方向的汽车/行人/... 的状态是什么?

A: 许多汽车处于停放状态。

Q: 物体 <c1,CAM_FRONT,920.0,509.2>/... 的观测状态是什么?

A: 运动。

Q: 物体 <c1,CAM_FRONT,920.0,509.2>/... 的运动状态是什么?

A: 直行。

预测

视觉遮挡

Q: 哪个物体最可能被 <c1,CAM_FRONT,707.5,472.5>/... 遮挡? 该物体会否影响自车? 基于该物体, 自车的什么动作是危险的?

A: <c1,CAM_FRONT,840.8,507.5> 前方的物体, 会的, 加速前进。

逻辑序列

Q: 当自车到达下一个可能位置时, 自车应首先注意什么物体? 自车首先注意到的物体状态如何, 自车应采取什么动作? 自车到达下一个可能位置时应其次注意什么物体? 自车其次注意到的物体状态如何, 自车应采取什么动作? 自车第三应注意什么物体? 自车第三注意到的物体状态如何, 自车应采取什么动作?

A: 首先注意 <c2,CAM_FRONT,514.7,462.2>, 其状态为交通标志, 因此自车应减速并直行。其次注意 <c3,CAM_FRONT,950.3,613.1>, 其状态为交通标志, 因此自车应减速并直行。第三注意 <c1,CAM_FRONT,707.5,472.5>, 其状态为直行, 因此自车应减速并直行。

运动预测

Q: <c1,CAM_FRONT,920.0,509.2>/... 是否在自车运动方向上?

A: 是。

Q: <c1,CAM_FRONT,920.0,509.2>/... 的未来状态是什么?

A: 继续直行。

Q: <c2,CAM_FRONT,1223.3,598.3>/... 是否 在 <c1,CAM_BACK,514.2,503.3>/... 的运动方向上?

A: 否。

物体交互

Q: <c2,CAM_FRONT,1223.3,598.3>/... 是否 会 根据 <c1,CAM_BACK,514.2,503.3>/... 改变其运动状态?

A: 不会。

Q: 基于对 <c1,CAM_BACK,514.2,503.3>/... 的观察, <c2,CAM_FRONT,1223.3,598.3>/... 可能采取什么动作? 原因是什么?

A: 保持相同速度继续行驶, 原因是没有安全问题。

Q: 基于对 <c4,CAM_FRONT,1071.2,346.2>/... 的观察, <c1,CAM_FRONT,1126.7,515.0>/... 可能采取什么动作?

A: 保持相同速度继续行驶, 原因是没有安全问题。

可能的注意力

Q: 在此场景中, 哪个物体最可能考虑 $\langle c3, \text{CAM_FRONT}, 400.1, 717.2 \rangle / \dots$?

A: 自行车。

Q: $\langle c1, \text{CAM_BACK}, 514.2, 503.3 \rangle / \dots$ 是否会考虑 $\langle c3, \text{CAM_FRONT}, 400.1, 717.2 \rangle / \dots$?

A: 不会。

Q: 哪个物体会认为 $\langle c1, \text{CAM_FRONT}, 985.8, 516.7 \rangle / \dots$ 对其决策最相关?

A: 自行车。

Q: 除自行车外, 哪个物体会认为 $\langle c1, \text{CAM_FRONT}, 985.8, 516.7 \rangle / \dots$ 对其决策最相关?

A: $\langle c2, \text{CAM_FRONT}, 1217.5, 511.7 \rangle$ 。

信号含义

Q: $\langle c2, \text{CAM_BACK_LEFT}, 400.8, 654.2 \rangle / \dots$ 表示什么含义?

A: 禁止驶入。

Q: $\langle c2, \text{CAM_BACK_LEFT}, 400.8, 654.2 \rangle / \dots$ 是哪种交通标志?

A: 交通锥。

规划

安全/不安全动作

Q: 在此场景中, 自行车可采取哪些安全动作?

A: 不制动而逐渐减速, 保持相同速度继续行驶。

Q: 在此场景中, 自行车可采取哪些危险动作?

A: 加速并前进、突然制动、倒车、右转。

重要性排序

Q: 自行车应考虑的对象优先级顺序是什么? (按降序排列)

A: $\langle c2, \text{CAM_FRONT}, 514.7, 462.2 \rangle$, $\langle c3, \text{CAM_FRONT}, 950.3, 613.1 \rangle$, $\langle c1, \text{CAM_FRONT}, 707.5, 472.5 \rangle$ 。

目标动作

Q: 自行车目标动作是什么?

A: 直行。

规划与推理

Q: 基于 $\langle c1, \text{CAM_FRONT}, 920.0, 509.2 \rangle / \dots$, 自行车可采取什么动作? 为何采取该动作, 概率如何?

A: 动作为不制动而逐渐减速, 原因是保持安全距离, 概率高。

Q: 基于此场景中的 $\langle c3, \text{CAM_FRONT}, 1591.1, 441.8 \rangle / \dots$, 自行车最可能的动作是什么?

A: 不制动而逐渐减速。

可能碰撞

Q: 自行车直行并保持相同速度/加速直行/... 后与 $\langle c1, \text{CAM_FRONT}, 920.0, 509.2 \rangle / \dots$ 碰撞的概率是多少?

A: 低。

Q: 自行车采取什么动作可能导致与 $\langle c1, \text{CAM_FRONT}, 920.0, 509.2 \rangle / \dots$ 碰撞?

A: 加速并直行。

自行车注意力

Q: 自行车应注意的交通信号是什么?

A: 无。

Q: $\langle c1, \text{CAM_FRONT}, 920.0, 509.2 \rangle / \dots$ 是否是当前场景中自行车应考虑的对象?

A: 是。

Q: 自行车是否有必要考虑 $\langle c3, \text{CAM_FRONT}, 400.1, 717.2 \rangle / \dots$?

A: 是。

自由形式问答/评论

Q: 此情境对行驶车辆有何影响?

A: 道路场景复杂, 请减速慢行。

Q: 你对这个场景有何评价?

A: 路口有行人, 请小心礼让。

...

表 7: DriveLM-nuScenes 在任务级的问题模板. 表中类别对应图 8 中的类别。

物体级 我们还进行了一些物体级的统计分析, 因为 DriveLM-nuScenes 中的问答围绕关键物体展开。Fig. 9 (左) 展示了关键物体类型的分布。由于与交通要素相关的问题与其他类别存在显著差异, 我们分别对交通要素相关问题和其他类别的问题类型进行统计。结果如 Fig. 9 (右) 所示。




图9: (左) DriveLM-nuScenes 中关键物体的分布. 子类别从视觉描述中提取。(右) DriveLM-nuScenes 中不同关键物体相关的问题类型分布. 由于与交通要素相关的问题与其他类别差异显著, 我们分别对交通要素相关问题和其余类别进行统计。




图 10: CARLA 图的详细流程. 我们展示 DriveLM-CARLA 的完整图结构。该图包含关于道路布局、交通信号灯、停车标志和车辆的问题与答案。

C DriveLM-CARLA

在本节中，我们介绍 DriveLM-CARLA 的细节，包括数据集构成和收集方法。

C.1 数据集构成

DriveLM-CARLA 由自动生成的帧级问答对构成，这些问答对通过互联图结构组织。图结构如图 10所示。当前版本包含关于道路布局、停车标志、交通信号灯和车辆的问题。未来版本可扩展至更多类别，如静态物体、天气、交通标志等。

利用驾驶模拟器 CARLA 进行数据生成可实现无需任何人工参与的可扩展标注和数据收集。此外，数据集支持 CARLA 的各种传感器输出，包括语义分割、深度图、LiDAR 等，可用于训练不同的网络架构。图中的每个问题设计均有助于情境推理，这对回答后续问题至关重要。与 DriveLM-nuScenes 类似，每个问题可分为感知、预测或规划。对于每个问答对，除对应问题和答案外，若问答对涉及物体，我们还保存物体 ID。该 ID 随时间保持一致，便于未来研究中的物体跟踪和时序推理。此外，记录了图中父问题和子问题之间的关系，以实现图的高效遍历。

C.2 专家算法：PDM-Lite

虽然先前的 CARLA 专家算法（如 TransFuser++ [36] 使用的特权规则型专家）仅能解决 CARLA Leaderboard 1.0 中实现的场景，但 PDM-Lite [4] 旨在解决 Leaderboard 2.0 中的所有 38 个场景。它由六个不同阶段组成，总结于 Fig. 11。**路径规划.** 首先, PDM-Lite 根据排行榜模块提供的稀疏目标点 (间距可达 200m), 使用 A* 规划算法创建空间等距点形式的密集路径。该规划基于 CARLA 提供的城镇高精地图。此外, 我们将限速、到下一个交通信号灯/停车标志的距离等信息添加到待行驶路径的不同路段。为处理需要离开默认路径的场景 (例如事故、施工障碍、停放障碍、车辆开门、双向事故、双向施工障碍、双向停放障碍、双向车辆开门、为紧急车辆让行), 路径上场景将生成的路段被横向偏移至相邻车道。

智能体预测. PDM-Lite 生成动态智能体的预测, 预测时域为 2 秒, 时间分辨率为 20Hz。由于我们无法预先获知其他参与者的路径和控制指令, 我们假设它们保持先前的控制并在近期未来施加类似的操控。使用运动学自行车模型 (参数取自 [8]), PDM-Lite 基于此恒定动作假设预测其他智能体的运动, 类似于 [36] 的方法。我们仅考虑距离自车 50m 以内的参与者进行预测。

IDM 目标速度. 我们使用智能驾驶员模型 (Intelligent Driver Model, IDM) [85] 生成目标速度建议。具体而言, 原始 IDM 仅选择一辆车作为前导参与者, 而我们在自车前方向上与路径相交的所有车辆、行人、非绿色交通信号灯和停车标志上迭代应用该模型。选择前导参与者后, 我们使用 Table 8 总结的参数为每个参与者确定目标速度。我们取获得的最小速度值作为该时间步的最终目标速度建议。

仿真. 我们通过交替应用纵向控制器 (如下所述) 和运动学自行车模型, 以 20Hz 频率在 2 秒时域内模拟采用建议目标速度的轨迹。从而, 该建议被闭环地转换为自车边界框 (bounding box) 的实际期望序列。

评分. 预测所有参与者的边界框后, 我们可以检查模拟自车与其他车辆之间的边界框交集。我们相应地对自车运动进行评分: 若检测到与非前导且非追尾车辆的交集, 则拒绝 IDM 目标速度建议, 并将目标速度设为零。

控制器. 控制车辆需要三个值: 转向、油门和制动。转向值可根据自车位置、速度和路径直接估计。我们使用横向 PID 控制器 (PID controller) 实现该功能, 类似于 [36], 该方法最小化与路径上前方选定点的角度。对于油门和制动预测, 我们采用基于当前速度和目标速度提取特征的线性回归模型。




图 11: PDM-Lite. 我们的新规划器可解决 CARLA Leaderboard 2.0 的全部 38 个场景, 包含 6 个阶段, 详见 Section C.2。

表 8: IDM 的目标速度建议. PDM-Lite 使用 IDM 选择目标速度。期望净距离和期望时间间隔参数根据前导参与者类型（车辆、自行车/停车标志/交通信号灯/行人/静态物体（如施工标志））而不同。

参数	值	描述
v_0	$0.72 v_{\text{lane}}$	期望速度。限速的 72%
s_0	4.0/2.0/6.0/4.0/2.0 m	与前导智能体的期望净距离
T	0.25/0.1/0.1/0.1/0.1 s	与前导智能体的期望时间间隔
a	24.0 ms^{-2}	自车最大加速度
$b_{v \leq 6.02}$	8.7 ms^{-2}	自车最大减速度 ($v \leq 6.02$ 时)
$b_{v > 6.02}$	3.72 ms^{-2}	自车最大减速度 ($v > 6.02$ 时)
δ	4.0	加速度指数

结果. PDM-Lite 的性能在 Leaderboard 2.0 的 20 条官方验证路线上评估。三个不同种子的评估结果见 Table 9。路线 0-9 与 10-19 除天气条件外完全相同，提供了额外的性能方差度量。由于 PDM-Lite 利用特权信息，其性能方差并非源于不同的天气参数，而是源于周围交通的随机初始化。

C.3 收集方法

在本节中，我们提供数据收集和标注过程的细节。

模拟器设置 我们使用 CARLA 模拟器 (0.9.14 版本) 和 Leaderboard 2.0 [22] 生成数据集。Leaderboard 2.0 引入了两个新的大规模地图和一系列新场景，增强了训练和评估环境的多样性。Town 12 作为训练城镇，Town 13 用于评估。每个城镇覆盖 10×10 平方公里区域，包含乡村、住宅和城市等多种环境以模拟真实驾驶条件。CARLA 团队提供总计 90 条训练路线（全长 780.6 公里）和 20 条评估路线（全长 247.6 公里）。每条路线包含多个驾驶场景。我们将这些路线分割为约 150 米的短片段，并过滤掉起点和终点重合的路线。Leaderboard 2.0 中的交通管理器在自车周围初始化仅由“汽车”实体组成的随机背景交通。为增加数据集多样性，我们引入更多车辆类别，包括“卡车”、“厢式货车”、“自行车”和“摩托车”。此外，我们为每条训练和评估路线实现随机天气配置以模拟真实驾驶条件。然而，由于某些地图区域照明不足，夜间设置被排除在研究范围之外。低光照条件显著影响自动标注流程的准确性，因为难以在图像中获取某些物体的可见性信息。

数据收集 我们在每条路线上执行专家算法并收集全面的传感器数据。传感器数据包括：(1) RGB 图像、(2) LiDAR 点云、(3) 语义分割图像、(4) 深度图、(5) 鸟瞰图 (BEV) 语义分割。虽然 DriveLM-Agent 仅利用 RGB 图像，但重训练 TransFuser++ 需要额外数据进行辅助任务。此外，我们从模拟器中提取关于场景中静态和动态物体状态的特权信息，如下：

- 自车：3D 边界框、速度、制动状态、ID
- 其他车辆：3D 边界框、边界框内 LiDAR 点数、距自车距离、速度、转向、油门、制动、ID、颜色、车辆类型、车轮数、交通信号灯状态、车道信息（即车辆行驶在哪条道路和车道上）、车辆是否在交叉口内、到下一个交叉口的距离、下一个高级指令

表 9: PDM-Lite 在 CARLA 官方验证路线上的表现. 我们展示每条路线的驾驶性能, 包括驾驶评分 (DS)、违规评分 (IS)、路线完成度 (RC)、归一化驾驶评分 (NDS) 和归一化违规评分 (NIS), 以及总计 3 个种子的平均值和标准差。路线 0-9 与路线 10-19 除天气 (PDM-Lite 忽略天气) 和交通行为外完全相同。

路线	DS	RC	IS	NDS	NIS
0	14.0 $\pm$ 0.0	100.0 $\pm$ 0.0	0.14 $\pm$ 0.00	48.2 $\pm$ 0.0	0.48 $\pm$ 0.00
1	56.2 $\pm$ 37.4	71.1 $\pm$ 40.9	0.75 $\pm$ 0.18	61.9 $\pm$ 42.1	0.69 $\pm$ 0.32
2	55.3 $\pm$ 14.3	100.0 $\pm$ 0.0	0.55 $\pm$ 0.14	79.3 $\pm$ 6.8	0.79 $\pm$ 0.07
3	18.4 $\pm$ 7.8	74.7 $\pm$ 35.8	0.34 $\pm$ 0.20	38.9 $\pm$ 20.4	0.51 $\pm$ 0.07
4	59.8 $\pm$ 13.5	100.0 $\pm$ 0.0	0.60 $\pm$ 0.14	80.5 $\pm$ 6.8	0.81 $\pm$ 0.07
5	34.9 $\pm$ 9.0	68.0 $\pm$ 0.0	0.51 $\pm$ 0.13	46.2 $\pm$ 5.6	0.68 $\pm$ 0.08
6	36.4 $\pm$ 7.9	100.0 $\pm$ 0.0	0.36 $\pm$ 0.08	70.3 $\pm$ 5.1	0.70 $\pm$ 0.05
7	3.5 $\pm$ 1.8	100.0 $\pm$ 0.0	0.03 $\pm$ 0.02	25.7 $\pm$ 5.2	0.26 $\pm$ 0.05
8	15.3 $\pm$ 3.3	100.0 $\pm$ 0.0	0.15 $\pm$ 0.03	52.1 $\pm$ 3.7	0.52 $\pm$ 0.04
9	73.3 $\pm$ 18.9	100.0 $\pm$ 0.0	0.73 $\pm$ 0.19	89.8 $\pm$ 7.2	0.90 $\pm$ 0.07
10	12.8 $\pm$ 7.6	100.0 $\pm$ 0.0	0.13 $\pm$ 0.08	44.0 $\pm$ 10.2	0.44 $\pm$ 0.10
11	60.5 $\pm$ 32.0	100.0 $\pm$ 0.0	0.61 $\pm$ 0.32	79.5 $\pm$ 18.1	0.79 $\pm$ 0.18
12	52.0 $\pm$ 11.3	100.0 $\pm$ 0.0	0.52 $\pm$ 0.11	78.9 $\pm$ 6.5	0.79 $\pm$ 0.06
13	26.3 $\pm$ 15.9	49.4 $\pm$ 35.8	0.58 $\pm$ 0.07	32.2 $\pm$ 28.5	0.57 $\pm$ 0.11
14	39.4 $\pm$ 20.8	100.0 $\pm$ 0.0	0.39 $\pm$ 0.21	69.0 $\pm$ 11.0	0.69 $\pm$ 0.11
15	24.0 $\pm$ 17.2	68.0 $\pm$ 0.0	0.35 $\pm$ 0.25	35.8 $\pm$ 13.8	0.53 $\pm$ 0.20
16	42.0 $\pm$ 0.0	100.0 $\pm$ 0.0	0.42 $\pm$ 0.00	73.9 $\pm$ 0.0	0.74 $\pm$ 0.00
17	4.1 $\pm$ 1.2	95.3 $\pm$ 6.7	0.04 $\pm$ 0.01	25.6 $\pm$ 5.5	0.27 $\pm$ 0.04
18	12.1 $\pm$ 7.9	100.0 $\pm$ 0.0	0.12 $\pm$ 0.08	43.7 $\pm$ 15.6	0.44 $\pm$ 0.16
19	86.7 $\pm$ 18.9	100.0 $\pm$ 0.0	0.87 $\pm$ 0.19	94.9 $\pm$ 7.2	0.95 $\pm$ 0.07
平均	36.3 $\pm$ 28.1	91.3 $\pm$ 21.1	0.41 $\pm$ 0.28	58.5 $\pm$ 25.9	0.63 $\pm$ 0.22

- 行人：3D 边界框、边界框内 LiDAR 点数、性别、年龄、距自车距离、速度、ID、车道信息
- 交通信号灯：3D 边界框、距自车距离、状态、是否影响自车
- 停车标志：3D 边界框、距自车距离、是否影响自车
- 静态车辆（停放车辆）：3D 边界框、车道信息
- 地标（如限速标志）：3D 边界框、距自车距离、ID、文本、数值
- 天气：天气参数

语言标签 基于从模拟器提取的信息，我们使用手工制作的句子模板创建问题和答案。为增加语言多样性并防止过拟合这些句子结构，可进一步使用当前最先进的语言模型（如 GPT-4）对句子进行增强。然而，本工作中使用的是未经增强的数据集版本。

D DriveLM-Metrics

在本节中，我们详细介绍 DriveLM-Metrics。DriveLM-Metrics 可大致分为三部分： P_{1-3} 视觉问答（VQA）指标、行为任务指标和运动任务指标。

D.1 P_{1-3} 视觉问答（VQA）指标

我们使用常见视觉问答（VQA）指标评估 P_{1-3} 的性能，并引入 GPT 评分（GPT score）以更语义全面地评估问答结果。此外，鉴于问答的图结构，我们提出完整性（Completeness）评分以提供全面评估。

BLEU [64] 衡量生成文本与一个或多个参考文本之间的相似度。它通过比较生成文本与参考文本中的 n-gram 进行运算，更高的精确率表示更佳匹配。然而，BLEU 对语义细微差别和词序变化不敏感。

ROUGE_L [52] 通过模型输出与参考答案的最长公共子序列计算得分。与 BLEU 类似，ROUGE 用于评估生成结果与标准参考之间的匹配程度，主要区别在于 ROUGE 基于召回率。

METEOR [45] 综合考虑精确率、召回率、词干、同义词、词干和词序。它在模型输出和参考之间建立对齐，计算两者间的 1-gram 匹配，然后基于分块施加惩罚，提供更细致的评估。

CIDEr [86] 结合了 BLEU 和向量空间模型的要素。其核心概念是将每个句子视为文档，计算其 n-gram TF-IDF 向量，并使用余弦相似度衡量候选句与参考句之间的语义一致性。CIDEr 捕捉不同长度的 n-gram 之间的匹配，并通过 TF-IDF 加权区分不同 n-gram 的重要性。

SPICE [2] 首先使用概率上下文无关文法（Probabilistic Context-Free Grammar）[38] 将文本解析为句法依存树，然后以规则方式将依存树映射为场景图。场景图描述原始文本中的物体、属性及其关系，SPICE 分数计算为预测结果和真值生成场景图的 F-score。

GPT 评分 是由 ChatGPT 提供的指标。传统指标主要评估词级性能，可能无法捕捉语义细微差别，产生意外评估结果。利用 ChatGPT 强大的推理能力，我们使用它衡量预测质量并得出更合理的分数。ChatGPT 被提示分配 0 到 100

之间的数值分数，分数越高表示预测准确度越高。GPT 评分评估的详细提示如表 10所示。

```
Messages = [
  { "role": "system", "content": f""" An evaluator who rates my answer
    based on the correct answer. """ },
  { "role": "user", "content": f""" Rate my answer based on the correct
    answer out of 100, with higher scores indicating that the answer is closer
    to the correct answer, and you should be accurate to single digits like 62,
    78, 41, etc. This is the correct answer: {GT}. This is my answer: {Pred}.
    """}]
```

表 10: GPT 评分的提示. 这与 DriveGPT4 [102] 中使用的提示不同，但所得分数相似。

完整性 (Completeness) 提供的分数衡量与某一帧相关联的真值问题中正确回答的比例。对于每个问答，若预测答案的分数超过阈值，则该问答被视为“正确回答”并记为正确预测，否则为错误预测。然后计算准确率，即正确预测数与总预测数的比值。在我们的设置中，使用 SPICE 分数并将阈值设为 0.5。

D.2 行为任务指标

我们通过分类准确率评估行为预测，并将总体准确率分解为转向和速度分量。

分类准确率 (Classification Accuracy) 是我们用于评估行为预测任务的指标，包含行为准确率、行为速度准确率和行为转向准确率。具体而言，自车未来轨迹的真值 (ground truth) 是鸟瞰图下的一组 N 个坐标点 (x, y) ，记作 $\{(x_0, y_0), (x_1, y_1), \dots, (x_N, y_N)\}$ 。每个点表示以固定间隔时间计算未来位置相对于当前位置的偏移。然后，每个时间间隔的 x, y 距离独立计算如下：

$$\{x, y\}_{dist} = ((\{x, y\}_1 - \{x, y\}_0), \dots, (\{x, y\}_N - \{x, y\}_{N-1})) \quad (2)$$

x_{dist} 和 y_{dist} 的均值被映射到预定义的区间之一，每个区间对应速度或转向的类别，分别记为 B_{speed} 和 B_{steer} 。最后，该轨迹的速度和转向类别构成行为类别 (B_{speed}, B_{steer}) 。我们将其与。

D.3 运动任务指标

为衡量运动阶段的性能，我们使用 nuScenes 和 Waymo 基准的标准指标：平均和最终位移误差 (ADE、FDE) 以及预测轨迹的碰撞率 (Collision Rate)。

ADE 即平均位移误差 (Average Displacement Error)，表示预测轨迹与真值轨迹之间在所有预测时域上的平均 L2 距离。它是第 1、第 2 和第 3 误差的平均值。

FDE 即最终位移误差 (Final Displacement Error)，衡量预测终点与真实终点在最后预测步 (第 3) 的欧氏距离。

碰撞率 (Collision Rate) 表示预测轨迹与物体发生碰撞的测试帧数占所有测试帧的比例。正文表 2 中报告的数值是第 1、第 2 和第 3 碰撞率的平均值。

注意 **ADE**、**FDE** 和**碰撞率**的计算遵循 UniAD [32] 的设置, 而非 ST-P3 [31]。例如, 对于第 3 的 FDE 和碰撞率, UniAD 设置仅考虑该时间步的误差/碰撞率, 而 ST-P3 设置考虑 0.5、1、1.5、2、2.5、3 秒的平均误差/碰撞率。更多细节请参考 UniAD 仓库的讨论 discussion。此外需注意, 先前工作中在完整 nuScenes 验证数据集上报告的误差, 与在 DriveLM-nuScenes 验证集 (一个由仅包含意图变化关键帧组成的高难度子集) 上报告的结果不直接可比。

E DriveLM-Agent

在本节中, 我们介绍, 包括图提示 (graph prompting) 方案和轨迹分词 (trajectory tokenization) 过程。

E.1 带上下文的提示 (Prompting)

在实现方面, 遵循循环网络中普遍采用的教师强制 (teacher-forcing) 设置 [44, 82]。训练时, 对于帧中每条边 $e \in E$, 我们选取子问答。边中的子问题附加真值父问答作为上下文。训练使用所有问答对, 包括无上下文的那些。使用的目标是下一个 token 预测, 即语言建模的标准方法。推理时, 模型以交互方式多轮应用, 以获得每个子问题所需的上下文预测。具体而言, 模型按照 P_1, P_2, P_3, B, M 的顺序依次使用五个阶段的问题进行提示。在此顺序下, 模型只能在前一阶段获得预测答案后推断后续阶段的问题。

E.2 轨迹分词细节

为直接使用构建图的同一语言模型生成动作序列 (即自车未来轨迹), 我们采用 RT-2 [108] 的方法。该过程涉及连续轨迹的离散化和分词 (tokenization)。

首先, 我们分析 nuScenes 数据集中未来轨迹的分布。为有效将连续 (x, y) 坐标空间转换为离散动作集, 我们将每个坐标轴划分为 256 个离散区间。这种粒度确保足够的细节水平, 同时保持语言模型可管理的 token 数量。

每个离散化的区间对应语言模型词汇表中的一个唯一 token。我们提取词汇表中数字 token 的标识符 (ID)。为确保连贯性并保持数值表达能力, 我们在该映射过程中省略个位数 token。在剩余的数字 token 中, 选取 256 个 token ID 的子集来表示轨迹数据。此外, 引入两个特殊 token 分别标记轨迹序列的开始和结束——即轨迹开始 (SOT) token 和轨迹结束 (EOT) token。这种分词方案使我们能够将复杂轨迹信息编码为语言模型可处理的 token 序列。使用此映射词汇表, 语言模型可通过输出一系列 token 来生成预测的未来轨迹序列, 这些 token 随后被转换回坐标空间。

F 实验

在本节中, 我们介绍实验细节, 包括正文第 4 节中各子节的实现细节、视觉问答 (VQA) 部分的更多指标、更多消融实验以及计算复杂度对比。




图 12: DriveLM-Agent 的详细架构. 设计了逆映射将真实世界的自行车轨迹嵌入到 blip-2-flan-t5-xl 的 token 空间中。

F.1 实现细节

此处说明正文第 4 节中各子节实验所用的训练和验证设置实现细节。

微调细节 我们将学习率设为 0.0001，无学习率调度器，随机种子设为 1234，其他设置遵循默认 LoRA [30] 配置。对于 BLIP-2 模型，我们使用最大序列长度 400，其他超参数与官方 BLIP-2 实现保持一致。

第 4.1 节、第 4.3 节和第 4.4 节实验的实现细节

训练时，我们使用每帧的所有问答作为输入，其中部分问答带有上下文（来自 $P_{2,3}$ 、 B 和 M 阶段的问题）。上下文从真值（ground truth）中提取，遵循循环网络中普遍采用的教师强制（teacher-forcing）设置 [44,82]。至于推理，由于场景复杂度多变，每帧 P_{1-3} 问答的数量在数据集上高度不平衡，在 DriveLM-nuScenes 上方差超过 260。为平衡其影响，我们仅对每帧关联的部分问答计算图视觉问答（GVQA）分数。为提取问答子集，我们基于通常与各阶段关联的问题，为每个阶段设计一组问答模式。我们确保对所有验证帧，每个阶段至少有一个问题与设计模式匹配。在此过程中，除 P_1 阶段的问题外，其他阶段的所有问题均具有来自上一阶段问答的上下文，其中答案源自前一步的预测。两个具体的图结构示例见 Fig. 13 和 Fig. 14。

第 4.2 节实验的实现细节 模型采用与第 4.1 节、第 4.3 节和第 4.4 节相同的方案进行训练，训练集为 DriveLM-nuScenes 训练集划分。推理时，由于 Waymo 上没有标注（甚至没有问题），我们以基于规则的方式设计问题。具体而言，我们将 DriveLM-nuScenes 中感知阶段的通用问题复用于 Waymo 作为起始问题。然后，我们尝试找出答案中是否含有与 DriveLM-nuScenes 标注匹配的物体，如“行人”、“汽车”、“卡车”等。接着，基于这些匹配的物体自动生成后续问题，作为预测和规划阶段的后续问题。具体的图结构示例见 Fig. 15。

第 F.2 节实验的实现细节 对于第 F.2 节的泛化实验，我们在图中添加两个新问题：(1) 《场景中是否有人?》和 (2) 如果第一个问题的答案为“是”，则问《基于正在过马路的行人，车辆应做什么?》；如果答案为“否”，则问《自行车应做什么?》。第二个问题的答案被拼接至最终行为问题的上下文。三个示例见 Fig. 16。

F.2 对未见物体的泛化

接下来，我们评估对新颖物体的零样本（zero-shot）泛化。DriveLM-CARLA 在收集时训练集和验证集中均不含行人。我们现在生成一个新的测试集 DriveLM-CARLA-ped，仅包含场景中存在行人的帧。正确行为是停车让行。

表 11: DriveLM-CARLA 中的泛化。所有方法在包含新型行人对象的 DriveLM-CARLA-ped 上表现不佳, 但 DriveLM-Agent 可以通过在其图视觉问答 (GVQA) 图中包含行人特定问题而显著改善。移到补充材料??

方法	DriveLM-CARLA (<i>B</i>)			DriveLM-CARLA-ped (<i>B</i>)		
	准确率 ↑	速度 ↑	转向 ↑	准确率 ↑	速度 ↑	转向 ↑
TransFuser++ [36]	70.19	73.29	90.68	8.72	8.72	100.00
DriveLM-Agent	59.63	61.50	78.26	4.59	4.59	100.00
+ 行人问答	52.17	55.28	77.64	27.04	27.04	100.00
DriveLM-Agent (真值)	60.25	65.22	80.12	20.92	20.92	100.00
+ 行人问答	60.25	65.22	80.12	92.35	92.35	100.00

基线方法. 在此实验中, 我们将 DriveLM-Agent 与 TransFuser++ [36] (CARLA 的最先进方法) 进行比较。与 DriveLM-Agent 相比, TransFuser++ 使用更大的输入图像、额外的 LiDAR 传感器以及多种驾驶专用标注 (深度、语义、3D 边界框、高清地图)。然而, 由于这些任务特定的输入和输出, TransFuser++ 只能在基础 DriveLM-CARLA 数据集上训练, 无法在训练中纳入通用计算机视觉数据, 这使得泛化更具挑战性。

DriveLM-Agent. 利用视觉语言模型 (VLM) 更通用的架构优势, 我们在训练 COCO [53] 和 GQA [34] 的样本与 DriveLM-CARLA 一起纳入。我们比较多个版本: (1) 在推理时添加新的 P_1 问题——《是否有人正在过马路?》(‘+ Pedestrian QA’)。 (2) 作为上限, 推理时直接输入真值 P_{1-3} 图, 而非模型预测。更多细节请参考补充材料。

结果. 我们在 Table 11 中展示结果。我们观察到 TransFuser++ 在 DriveLM-CARLA-ped 上相较于 DriveLM-CARLA 表现不佳, 准确率从 70.19 降至仅 8.72%, 从 59.63 降至 4.59。然而, 添加行人问答使泛化设置下的性能显著提升至 27.04, 尽管常规场景下的准确率略有下降。这主要归因于视觉语言模型 (VLM) 无法完全正确检测所有行人。这表明近期发布的视觉语言模型 (VLM) [26, 65] 的巨大性能提升可支持驾驶领域更强的泛化能力。此外, 在特权设置下, 当假设图中每个问题均可获得完美上下文时, (20.92 $\rightarrow$ 92.35)。注意 DriveLM-CARLA-ped 仅包含在直道上过马路的行人, 因此所有模型在转向类别 (始终为 **straight**) 上均获得 100% 准确率。

F.3 视觉问答 (VQA) 中的更多指标结果

在 Table 12 中, 我们提供正文表 4 在 BLEU-4 [64]、METEOR [45]、CIDEr [86] 和 ROUGE-L [52] 指标下的性能。一个关键观察是不同指标反映不同的性能趋势, 且改进并非在所有指标上一致。这促使我们在视觉问答 (VQA) 评估部分使用 GPT 评分作为主要指标。

F.4 跨传感器配置的零样本泛化阶段消融

在 Table 14 中, 我们提供正文表 2 中跨传感器配置零样本泛化的更多上下文设置。一个关键观察是行为任务准确率越高, 运动任务性能越好。随着行为任务中上下文增加, 准确率提升主要源自速度准确率的改进, 最终影响 FDE 分数。

表 12: 图结构推理有助于改进视觉语言模型（VLM）的视觉问答（VQA）性能。完整性衡量一帧数据中正确回答的问题数量。不同传统指标上的改进趋势不一致，因此我们需要 GPT 评分作为主要指标，因为它能更全面地评估性能。

上下文	DriveLM-nuScenes													
	现成 BLIP-2							DriveLM-Agent						
	BLEU-4 $\uparrow$	METEOR $\uparrow$	CIDEr $\uparrow$	ROUGE_L $\uparrow$	SPICE $\uparrow$	GPT 评分 $\uparrow$	完整性 $\uparrow$	BLEU-4 $\uparrow$	METEOR $\uparrow$	CIDEr $\uparrow$	ROUGE_L $\uparrow$	SPICE $\uparrow$	GPT 评分 $\uparrow$	完整性 $\uparrow$
无图	0.022	3.317	0.1185	7.205	4.336	42.97	1.064	51.89	35.81	2.463	66.79	42.56	71.39	30.04
有图	0.022	3.882	0.0771	7.397	7.710	45.21	0.859	53.09	36.19	2.786	65.58	49.54	72.51	31.66
真值	0.022	4.397	0.0758	8.033	8.192	41.10	1.315	53.06	36.64	3.069	66.69	50.29	72.94	32.41

F.5 在 DriveLM-nuScenes 上评估更多视觉语言模型（VLM）

表 13: 在 DriveLM-nuScenes 上的更多视觉语言模型（VLM）评估。在 LLaMA-Adapter V2 的基础模型上，我们观察到使用多帧作为输入带来了轻微改进。

表 A. 基础 VLM	行为 上下文	运动 上下文	行为 (B)			运动 (M)	
			准确率 $\uparrow$	速度 $\uparrow$	转向 $\uparrow$	ADE $\downarrow$	碰撞率 $\downarrow$
blip-2-flan-t5-xl	图	B	57.49	69.89	80.63	1.74	1.89
LLaMA-Adapter V2	图	B	55.31	61.97	81.43	1.86	2.03
LLaMA-Adapter V2*	图	B	57.83	67.21	83.49	1.75	1.69

为验证所提出，我们选择 LLaMA-Adapter V2 (7B) [1]，因为它兼容单帧和多帧输入。Table 13中的 结果（在 9 个训练周期内）显示与 BLIP-2 相似的性能。

请注意，由于 DriveLM-nuScenes 中问题类型的多样性，逐个分析每个问题将耗费过高成本。

相反，我们在 Table 14中提供了每个阶段 (P_{1-3}) 有效性的消融分析以及代表性问题的逐问题分析。

我们承认，在当前问题设置下改进问答性能 (P1-3) 并非易事，且我们发现这对最终任务性能（行为和运动）影响甚微。

这启发我们，问题的设置可能值得投入更多努力探索；通过精心设计问题，模型可被”正确提示”以理解场景并更好地执行下游任务。

F.6 计算复杂度

在正文表 5中，我们提供了 DriveLM-Agent 与 UniAD-Single 的计算复杂度对比。未来的一个方向是缓存视觉 token 并批处理不同的问题模式，这可以从根本上加速推理时间。

G 定性结果

在本节中，我们展示实验的定性结果，包括在我们的 DriveLM-nuScenes 上的视觉问答（VQA）、Waymo 上跨传感器数据的泛化结果以及 DriveLM-CARLA 上对未见物体的泛化结果。

表 14: 跨传感器配置的零样本泛化。 B^* 表示使用真值行为问答作为运动任务的上下文。在 DriveLM-nuScenes 上训练后, 从 Waymo val 集中随机采样 1000 帧的结果。我们的关键观察是行为任务的准确率越高, 运动任务的性能越好。

方法	行为 运动		行为 (B)			运动 (M)	
	上下文	上下文	准确率 $\uparrow$	速度 $\uparrow$	转向 $\uparrow$	ADE $\downarrow$	FDE $\downarrow$
指令均值	-	-	-	-	-	7.98	11.41
UniAD-Single	-	-	-	-	-	4.16	9.31
BLIP-RT-2	-	-	-	-	-	2.78	6.47
DriveLM-Agent	无	B	35.70	43.90	65.20	2.76	6.59
	P_1	B	38.20	43.67	70.74	2.67	6.41
	P_2	B	39.52	44.20	78.67	2.62	6.19
	P_3	B	34.62	41.28	64.55	2.85	6.89
	P_{1-3}	B	39.73	54.29	70.35	2.63	6.17
BLIP-RT-2	-	B^*	100.0	100.0	100.0	2.41	5.79

G.1 DriveLM-nuScenes

本节展示 DriveLM-nuScenes 的定性示例。在图 13中, 我们展示了 DriveLM-nuScenes 上图视觉问答 (GVQA) 推理过程的详细示例, 涵盖 P_{1-3} 问答和行为任务。我们将预测答案与真值进行对比, 并提供 SPICE 分数和 GPT 评分。在该图中, 预测阶段的第二个问题代表了一个典型错误。由于输入单帧图像, 我们的模型常难以准确判断物体的正确运动状态。即使是人类, 这种判断也确实具有挑战性。此外, 在图 14中, 我们展示更多定性结果以呈现模型性能。

G.2 Waymo

本节展示了模型跨传感器配置的泛化能力。图 15展示了在 DriveLM-nuScenes 上训练的模型应用于 Waymo 推理时的结果。由于我们不标注 Waymo 上的数据, 问题为手动定义, 未提供真值。这些结果展示了模型的强大泛化能力。

G.3 DriveLM-CARLA

在本节中, 我们提供 CARLA 数据集的定性示例。

对未见行人场景的泛化 图 16展示了未见行人场景泛化测试集上生成的行为。第一个示例 (图 16顶部) 展示了。它随后推断出应采取的适当动作, 即停车。行为生成能够理解该上下文, 导致正确的行为模式, 自行车完全停止即为明证。另外两个示例代表了。图 16中间的示例显示模型仍检测到行人, 但未能将此检测转化为正确行为。最后的示例 (底部) 凸显了更严重的局限: 模型完全忽视了行人。在这种情况下, 从而导致其未执行任何规避或停车操作, 在真实场景中构成重大风险。

图视觉问答 (Graph Visual Question Answering) 本节展示两个使用 CARLA 数据集评估 (图 17)。我们仅展示所评估问题的子集。第一个示例中, 自行车在另一辆车后方行驶。主要任务是跟随道路并根据前车调整速度。结果表明, 尽管

Perception


Question: What are objects to the front of the ego car?

Answer: There are many **cars**, one **truck** and one **pedestrian** to the front of ego car.

GT: There are many **pedestrians**, one **trailer**, three **cars**, one **truck** to the front of the ego car.

SPICE: 0.783 **GPT score:** 40

Scene Image



Prediction

Question with pred-context: Perception Q: What are objects to the front of the ego car? Perception A: There are many cars, one truck and one pedestrian to the front of ego car. Q: What is the status of the cars that are to the front of the ego car? Answer: Many cars are moving and one is parked. GT: Three cars are moving. SPICE: 0.667 GPT score: 40	Question with pred-context: Perception Q: What are objects to the front of the ego car? Perception A: There are many cars, one truck and one pedestrian to the front of ego car. Q: What is the status of the truck that is to the front of the ego car? Answer: One truck is moving. GT: One truck is parked. SPICE: 0.667 GPT score: 0	Question with pred-context: Perception Q: What are objects to the front of the ego car? Perception A: There are many cars, one truck and one pedestrian to the front of ego car. Q: What is the status of the pedestrian that is to the front of the ego car? Answer: One pedestrian is moving and one is standing. GT: Many pedestrians are moving. SPICE: 0.667 GPT score: 10
--	--	---

Planning

Question with pred-context: Perception Q: What are objects to the front of the ego car? **Perception A:** There are many **cars**, one **truck** and one **pedestrian** to the front of ego car. **Prediction Q:** What is the status of the **cars** that are to the front of the ego car? **Prediction A:** Many **cars** are moving and one is parked. **Prediction Q:** What is the status of the **truck** that is to the front of the ego car? **Prediction A:** One **truck** is moving. **Prediction Q:** What is the status of the **pedestrian** that is to the front of the ego car? **Prediction A:** One **pedestrian** is moving and one is standing. **Q:** In this scenario, what are safe actions to take for the ego car?

Answer: Keep going at the same speed, accelerate and go ahead.

GT: Keep going at the same speed, decelerate gradually without braking.

SPICE: 1.0 **GPT score:** 50

Behavior

Question with pred-context: Perception Q: What are objects to the front of the ego car? **Perception A:** There are many **cars**, one **truck** and one **pedestrian** to the front of ego car. **Prediction Q:** What is the status of the **cars** that are to the front of the ego car? **Prediction A:** Many **cars** are moving and one is parked. **Prediction Q:** What is the status of the **truck** that is to the front of the ego car? **Prediction A:** One **truck** is moving. **Prediction Q:** What is the status of the **pedestrian** that is to the front of the ego car? **Prediction A:** One **pedestrian** is moving and one is standing. **Planning Q:** In this scenario, what are safe actions to take for the ego car? **Planning A:** Keep going at the same speed, accelerate and go ahead. **Q:** Predict the action template of the ego car.

Answer: The ego vehicle is going straight. The ego vehicle is driving fast.

GT: The ego vehicle is going straight. The ego vehicle is driving fast.

SPICE: 1.0 **GPT score:** 95

图 13: DriveLM-nuScenes 上的详细定性结果. 图提示过程可分为不同任务, 每个任务中的不同问答围绕不同物体展开。

真值数据显示 CARLA 模拟器在物体颜色标注上偶尔存在不准确。此外，模型能够识别前方车辆并基于前车推理应采取的决策。

第二个示例发生在设有停车标志的交叉路口。它正确识别出不仅需要因停车标志而停车，更重要的是因为前方有一辆摩托车。这表明。




图 14: DriveLM-nuScenes 上的更多定性结果. 图中示例展示了我们的 DriveLM-Agent 在驾驶场景中执行视觉问答 (VQA) 任务的强大能力。




图 15: Waymo 上的定性结果. 我们展示两个示例, 说明 DriveLM-Agent 对新传感器配置的泛化能力, 证明了 DriveLM-Agent 的强泛化能力。




图 16: DriveLM-CARLA 泛化测试集的定性结果. 我们展示. 第一个示例展示了成功案例, 第二个和第三个展示了模型的两常见失败情况。

H 更多相关工作

在本节中，我们补充正文中提及的相关工作。

基于图结构的推理 推理是模拟人类思维的基本形式之一，能够从一个或多个已有判断推导出新判断 [12]。许多先前的推理工作基于图方法 [5, 13, 75, 92]。XNMs [75] 利用场景图进行可解释且显式的结构化知识推理。KPRN [92] 利用知识图谱进行推理并应用于推荐系统。GoT [5] 将大语言模型（LLM）生成的信息建模为任意图，使大语言模型（LLM）推理更接近大脑机制。受这些成功尝试启发，我们尝试通过图将自动驾驶中的感知、预测和规划阶段关联起来，使模型能够掌握推理过程，并基于学到的图结构推断未见场景。

基于大语言模型（LLM）的具身规划 近期工作致力于利用大语言模型（LLM）强大的推理和泛化能力 [25, 43, 83] 服务具身人工智能系统 [23, 33, 35, 40, 51, 69, 108]。PaLM-E [23] 训练大语言模型（LLM）用于包括顺序机器人操作规划在内的各种具身任务。CaP [51] 提供了一种以机器人为中心的形式化方法，将在实际系统上执行语言模型生成的程序。RT-2 [108] 将机器人动作表示为语言 token，训练视觉语言模型输出机器人策略。这些方法展示了 LLM 在具身规划任务中的能力，启发我们将其应用于解决自动驾驶中当前泛化不足的问题，而该方向目前远未得到充分探索。

驾驶的视觉语言基准 越来越多的视觉语言数据集被提出用于自动驾驶系统 [20, 41, 42, 56, 59, 67, 71, 97, 98, 101, 107]。NuScenes-QA [67] 和 NuPrompt [98] 通过描述周围物体的位置和状态将感知信息以文本形式提供。BDD-X [42] 以自然语言描述提供自行车动作的原因。DRAMA [56] 和 Rank2Tell [71] 识别关键物体并提供相应的驾驶建议。然而，这些数据集关注场景级上下文或单个物体。DriveLM 通过以图结构组织物体级和任务级的语言标注填补了文献中的这一空白。

I 更广泛影响

我们相信本方法可加速自动驾驶领域的进展，使其直接受益于更优秀的视觉语言模型（VLM）。我们的目标是推动自动驾驶的发展，若成功将产生深远影响。我们认识到，将视觉语言模型（VLM）引入该领域需接受其伦理影响，如幻觉和高资源消耗。然而，通过改善人与自动驾驶系统之间的交互性，我们可以建立对技术的信任。这从长远来看可加速其被接受并带来更安全的交通。