

迈向高效且有效的端到端驾驶多相机编码

Jiawei Yang ^{π ,*}, Ziyu Chen ^{ρ ,*}, Yurong You^{*}, Yan Wang^{*}, Yiming Li^{*}, Yuxiao Chen^{*}, Boyi Li^{*},
Boris Ivanovic^{*}, Marco Pavone ^{ρ ,*}, Yue Wang ^{π ,*}

^{π} USC Physical Superintelligence (PSI) Lab ^{ρ} Stanford University ^{*}NVIDIA Research

项目主页: [Flex](#)

摘要—本文提出 Flex, 一种高效且有效的场景编码器 (Scene Encoder), 用于解决端到端自动驾驶中处理海量多相机数据所面临的计算瓶颈。Flex 采用少量可学习场景令牌 (scene token), 联合编码来自不同相机与时间步的所有图像令牌 (image token) 信息。在设计上, 本方法不依赖几何先验 (geometry-agnostic), 直接从数据中学习紧凑的场景表示, 无需借助先前工作中常见的显式 3D 归纳偏置 (Inductive Bias), 例如鸟瞰视角 (Bird-Eye-View, BEV)、占据 (Occupancy) 或三平面 (Tri-plane) 表示。这种整体式编码策略极大地压缩了供下游基于大语言模型 (Large Language Model, LLM) 的策略模型 (Policy Model) 使用的视觉输入。在包含 20,000 驾驶小时的大规模内部数据集 (专有数据) 上评估, 相较于最先进的方法, Flex 将推理吞吐量提升了 2.2 $\times$, 同时大幅改善驾驶性能。此外, 本文表明这些紧凑的场景令牌在没有任何显式监督的情况下涌现出场景分解能力。本文的发现挑战了“3D 先验必不可少”这一普遍假设, 证明数据驱动联合编码策略为未来的自动驾驶系统提供了一条更具可扩展性、更高效且更有效的路径。

I. 引言


视觉-语言-动作 (Vision-Language-Action, VLA) 模型 [1], [2], [3], [4] 将大语言模型 (Large Language Model, LLM) 用作强大的策略头 (Policy Head), 正在深刻变革端到端自动驾驶。这一新范式的关键挑战在于如何高效且有效地编码高带宽视觉数据 [5]。自动驾驶汽车的多相机系统通常每秒采集数十张图像, 每次前向计算会产生数千乃至数万个视觉令牌。处理如此庞大的数据流给基于 LLM 的策略模型带来沉重的计算负担, 从而构成严重瓶颈。

冗余是这一问题的核心所在。在典型驾驶场景中, 相邻广视场相机之间存在显著的空间重叠, 而时间连续性又在连续帧之间引入进一步的重复 (见图 1 顶部)。朴素的逐图像编码会增加延迟与显存占用, 更重要的是无法利用这种时空冗余。因此, 设计一个能够利用并压缩该冗余的场景编码器, 对效率与效果两方面都至关重要。


先前的工作通常通过施加强 3D 归纳偏置来应对这一复杂性。基于鸟瞰视角 (BEV) 平面 [6], [7]、体素 (Voxel) [8]、三平面 [9], [5] 或六平面 (HexPlane) [10] 的方法, 将视觉信息显式组织为一种准 3D 表示, 并预设这些几何先验对于连贯的场景理解不可或缺。虽然这些方法能够通过通过对场景进行因式分解来提升效率, 但它们也施加了一种可能限制模型性能的刚性结构。深度学习的发展已反复表明, 用可扩展、数据驱动的方案替代归纳偏置, 往往能带来更好的性能与泛化能力 [11]。这一趋势促使本文探索一种更简单、更具可扩展性的替代方案, 如图 1 所示。

本文提出 Flex, 一种灵活且几何无关的 Transformer 场景编码器, 将来自所有视角与时间步的图像联合编码

Problem: Excessive image tokens across views and time burden policy models.



Solution: Compress to obtain scene representations.



Results: Faster and Better.




图 1: 问题、方案与结果。跨时间的多相机输入会产生过多令牌, 使策略模型不堪重负。先前的方法以有限的效率和固定的粒度将令牌压缩为 2D 或 3D 场景表示。本文的 Flex 场景编码器直接从数据中学习紧凑的场景表示, 无需 3D/4D 先验或相机位姿。它同时实现了更高的效率 (41.08 vs. 18.60 clips/s) 与更好的驾驶精度 (0.76 vs. 0.80 minADE₆)。

为一组紧凑的场景令牌。具体而言, Flex 初始化少量可学习场景令牌, 将其与跨相机、跨时间的全部图像令牌拼接, 并运行一个轻量级 Transformer [12] 编码器, 利用自注意力层对所有令牌进行联合处理。编码完成后, 丢弃图像令牌, 仅保留更新后的场景令牌作为传递给基于 LLM 的策略模型的表示。这形成了一个信息寻求型瓶颈, 强制进行跨视角与跨时间的压缩, 使模型能够直接从数据中学习最优表示, 避免任何显式 3D 先验。

本文的设计刻意保持简洁, 同时兼顾效率与效果。效率源于将传递给策略模型的令牌预算 (Token Budget) 降低约 3 $\times$ 至 20 $\times$, 而策略模型通常是训练与推理成本的主要来源。效果则来自联合编码: 场景令牌会关注跨视角与时间步的所有图像, 因此冗余抑制发生在场景层面

而非图像层面。相比之下，Q-former [13] 中采用的逐图查询无法施加全局协调，往往保留全局冗余。

本文的方法出奇地有效。本文在包含 20,000 驾驶小时的大规模内部数据集上评估 Flex。相较于最先进的图像编码策略，Flex 达到了基线方法 $2.2\times$ 的推理吞吐量，同时大幅提升驾驶性能。这些结果表明，简单、数据驱动的场景编码器可以更加有效。重要的是，本文发现用自注意力联合编码整个场景对性能至关重要；更令人惊讶的是，压缩后的令牌表示展现出一种涌现能力，能够关注目的地、车道标线与安全关键区域。希望本文的工作能为端到端驾驶的场景编码提供一个新视角。

II. 相关工作

A. 端到端驾驶与相机视觉编码

端到端自动驾驶已从模块化堆叠演进为将感知与规划融合为单一可微系统的架构。近期面向规划的设计借助共享查询与 BEV 特征统一各任务（如 UniAD [7]），或在单一网络中为感知—预测—规划学习时空特征（如 ST-P3 [14]），但它们仍固守显式 3D 结构，因而需要精确的相机位姿信息。向量化的端到端方法（如 VADv2 [15]）直接消费多视角图像序列并输出动作，却未解决跨全部相机与时间步的激进令牌级压缩问题。本文的工作对这些系统形成补充：聚焦于相机编码阶段，目标是学习一组跨视角与时间联合得到的紧凑场景令牌，而不施加特定的几何骨架。

B. 自动驾驶的场景表示

海量的相机输入带来了计算瓶颈，促使近期工作采用以几何为基础的进行压缩。感知模型将图像转换为鸟瞰视角（BEV）或体积占据作为中间表示。例如，PETR [16] 与 PETRv2 [17] 注入 3D 位置编码用于纯相机 3D 检测。BEVFormer [6] 使用网格状 BEV 查询与时空 Transformer 来聚合多视角、多时间步的感知结果。BEVFusion [18] 高效地在 BEV 中统一多模态特征；SurroundOcc [19] 通过 2D 到 3D 的注意力从相机预测 3D 占据。

除 BEV 与占据之外，神经场方法提出了紧凑的因式化 3D/4D 表示。三平面将特征因式分解为三个轴对齐的平面，以实现高效的 3D 表示 [5], [9], HexPlane 与 K-Planes [20], [10], [21] 进一步将其扩展到动态场景。Instant-NGP [22] 及其变体使用多分辨率哈希编码来加速场学习 [23]。这些表示提升了速度与结构规整性，但它们预先定义了信息的基与路由方式。显式的 3D/4D 表示还要求精确的相机位姿与同步的传感器，从而提高了数据需求。此外，预设的粒度（例如网格或体素尺寸）约束了信息密度，而相机透视进一步扭曲了这种密度：近处物体占据大量像素，而远处物体则坍缩为极少的像素。因此，固定的网格/体素设计无法适应透视图像中高度非均匀的信息密度。相比之下，本文最小化与几何相关的先验，并通过对整个图像集合的数据驱动联合注意力进行压缩。本文的编码器使用少量学习到的场景查询直接从数据中发现结构，不固守任何固定的 3D 分解，并自然适应透视图像的非均匀密度。

C. 学习到的表示

计算机视觉中另有一条独立脉络，学习固定大小的查询集合来概括大型输入。Perceiver [24] 与 Perceiver IO [25]

引入从小型潜阵列到高维输入的非对称交叉注意力，将计算与输入长度解耦。Flamingo 使用 Perceiver Resampler 将图像/视频特征映射为一小组学习到的视觉令牌，供视觉-语言模型（Vision-Language Model, VLM）使用 [26]。TokenLearner 自适应地从图像中提取少量具有信息量的令牌 [27]。TiTok [28] 与 LVSM [29] 中的编码器-解码器架构利用可学习查询来实现紧凑的新视角合成与自编码任务。STORM [30] 使用可学习令牌来捕捉场景的底层运动偏置。本文的场景令牌遵循这一潜查询（Latent Query）范式，但在对驾驶至关重要的两个方面与之不同：(i) 本文用自注意力一次性联合关注全部相机与时间步（而非逐图像或基于交叉注意力）；(ii) 本文表明以规划为中心的压缩天然地产生不仅紧凑且与动作相关的令牌。这一设计带来了更强的效率—精度权衡，并有利于端到端训练。

III. 方法

本文的工作提出 Flex，一种面向自动驾驶中视觉-语言-动作（VLA）模型的场景编码器。总体目标是学习一个策略 π ，在给定观测序列 $\mathbf{O}$ 的情况下预测自车的未来轨迹 $\mathbf{Y}$ 。本文的主要贡献是一个新的场景编码器，它从海量视觉输入中产生紧凑且高度有效的场景表示，从而提升训练与推理的效率，并增强策略模型的驾驶性能。

A. 视觉-语言-动作模型

本文首先搭建一个 VLA 架构作为基线。该模型处理 RGB 图像序列与历史轨迹数据，以自回归方式预测未来轨迹。图 2-(a) 展示了整体概览。

设置与记号。 令 $\mathcal{C} = \{1, \dots, C\}$ 表示相机索引， $\mathcal{T} = \{1, \dots, T\}$ 表示固定窗口内（约覆盖 2s）的历史时间步。观测 $\mathbf{O}$ 由多相机（C）、多时间步（T）的图像 $\{I_{c,t} \in \mathbb{R}^{H \times W \times 3} \mid c \in \mathcal{C}, t \in \mathcal{T}\}$ 以及最近的自车状态历史 $\mathbf{s}_{T-h:T}$ （例如位姿/速度）组成，其中 h 为时间范围。目标是自车坐标系下的未来轨迹 $\mathbf{Y} = \{\mathbf{y}_t\}_{t=T+1}^{T+h}$ ，其中 h 为预测范围。

场景表示。 对于基线模型，场景表示直接由图像令牌导出。每张输入图像 $I_{c,t} \in \mathbb{R}^{H \times W \times 3}$ 首先被划分为图像块，并由图像编码器（例如 DINOv2 [31]）处理——本文沿用 VGGT [32] 的命名，将其称为“分块器（Patchifier）”——以产生一组 N 个令牌，在本设置中通常 $N = 640$ 。随后这些令牌被双线性下采样到更易管理的数量，例如每张图像 160 个令牌。缩放后，它们通过一个 2 层 MLP 投影层 ϕ_{proj} ，以匹配 LLM 策略头的隐藏维度 D_{llm} 。基线模型的最终场景表示 $\mathbf{S}_{baseline}$ ，是来自全部 C 个相机视角与 T 个时间步的所有处理后图像令牌直接拼接：

$$\mathbf{S}_{baseline} = \text{Concat}(\{\phi_{proj}(\text{Resize}(\text{patchifier}(I_{c,t})))\}_{c,t}) \quad (1)$$

这将产生一条长度为 $C \times T \times 160$ 的长令牌序列，给策略头带来沉重的计算负担。

轨迹编码。 本文采用两种互补的令牌化方法。(i) **连续历史。** 自车近期轨迹 $\mathbf{s}_{T-h:T}$ 由一个 MLP ϕ_{hist} 编码为单一嵌入 $\mathbf{h}_{hist}$ ，将历史压缩为一个令牌。(ii) **离散未来。** 未来轨迹 $\mathbf{Y}$ 被离散化为路径点令牌（Waypoint Token）词表，并加入 LLM 嵌入。随后策略模型将预测未来建模为一个自回归的下一令牌生成任务。在本文的前期实验中，这种编码被证明最为有效。




图 2: 方法概览。在 (a) 基线 (左) 中, 来自所有相机与时间步的数千个图像令牌被生成, 令策略模型不堪重负。在 (b) Flex (右) 中, Flex 场景编码器将图像令牌压缩为一组紧凑的场景令牌, 作为场景表示。仅有这一小组令牌被用作场景表示。特殊令牌 (Special Token) 编码各模态的起止、相机类型与时间戳信息。

策略头。本文从预训练的 LLM 主干初始化策略模型, 从而能够利用其在互联网规模数据上预训练所获得的丰富世界知识与推理能力。策略模型是一个自回归 Transformer, 以场景表示与历史令牌作为上下文来预测未来序列。该模型在预测的未来轨迹令牌上使用标准交叉熵损失进行训练。鉴于场景令牌数量庞大, 该策略模型在训练与推理成本中都占据主导地位。

B. Flex 场景编码器

概述。Flex 编码器旨在减少场景表示中过多的图像令牌。本文的核心洞察在于, 拼接后的图像令牌 $\mathbf{S}_{\text{baseline}}$ 由于相机视角之间显著的空间重叠与帧之间的时间连续性而高度冗余。为此, Flex 联合地将全部视角与时间步编码为一小组场景令牌, 迫使模型利用跨时空对应关系。这一设计既提升了效率, 也有利于学习更有效的场景表示。图 2-(b) 展示了整体概览。

联合场景编码器。本文的场景编码器是一个轻量级 Transformer, 以整体方式处理全部图像令牌。与基线相同, 输入图像首先由 DINOv2 编码器 [31] 分块。随后, 本文为这些图像令牌添加两组位置编码 (Positional Embedding): 时间步嵌入 PE_t^{time} 与相机嵌入 PE_c^{cam} 。时间步嵌入与 DiT [33] 中的类似, 相机嵌入则是按相机类型索引的可学习向量。

本文初始化一组 K 个可学习场景令牌 $\mathbf{S}^{(0)} \in \mathbb{R}^{K \times d}$, 作为查询。这些场景令牌被前置到来自所有相机与时间步的全部图像令牌序列之前。一个 L 层 Transformer 编码器 E_θ (本文取 $L = 8$) 在这条组合序列上计算完全自注意力更新:

$$[\mathbf{S}^{(L)}; \mathbf{X}^{(L)}] = E_\theta([\mathbf{S}^{(0)}; \mathbf{X}]), \quad \mathbf{S}^{(L)} \in \mathbb{R}^{K \times d}. \quad (2)$$

在最后一层之后, 本文丢弃 $\mathbf{X}^{(L)}$, 仅使用更新后的场景令牌 $\mathbf{S}^{(L)}$ 作为场景表示, 进一步记为 $\mathbf{S}_{\text{Flex}}$ 。经过到 D_{llm} 的线性投影后, 这 K 个令牌输入策略模型。

C. 交错式预测

接下来, 本文介绍自动驾驶 VLA 模型中一项重要的设计选择, 名为交错式预测。




图 3: 非交错式训练策略的对比。(a) 损失仅施加于最后一个时间步 t_0 。(b) 本文提出的非交错式设置: 损失施加于 T 个时间步 $\{t_0 - T + 1, \dots, t_0\}$ 上。为简洁起见, 特殊令牌以缩写表示。GT 表示真值 (Ground-Truth, GT)。

多样化监督。在推理时, 策略模型以 C 个相机在 T 个时间步上的输入以及单个历史令牌为条件, 生成预测轨迹。一种直接的训练设置会与此对应: 模型接收相同数量的时间步上下文外加一个历史令牌, 仅在随后的未来令牌上最小化损失, 如图 3-(a) 所示。然而, 实践表明这种方法效果不佳 (表 4f), 模型获得的监督信号有限。

本文转而提出一种交错式训练策略, 如图 3-(b) 所示。对于长度为 T 的序列, 本文在不同长度的输入上下文上施加监督: 在每个时间步 k , 模型接收截至 k 的全部图像/场景令牌以及 t_k 时刻对应的轨迹历史, 并被要求预测后续 H 个未来时间步。这样每条序列会产生 T 个监督信号, 分别来自每一个可能的前缀。在实践中, 可通过调整注意力掩码 (Attention Mask) 高效实现, 而无需切分序列。这种交错式设计迫使模型在不完整上下文的条件下预测未来, 极大地增加了训练信号的多样性, 从而实现更高效的学习。本文修改注意力掩码, 使上下文中的历史与未来轨迹令牌 (例如图 3-b 中从 $t_0 - T + 1$ 到 $t_0 - 1$ 的部分) 不参与最终预测。

采用整体式场景表示。本文的 Flex 表示 $\mathbf{S}_{\text{Flex}}$ 是单一、联合编码的表示, 因此不再与特定相机或时间存在显式映射。为解决这一问题, 本文引入一种极其有效的启发式方法: 将 K 个场景令牌均匀划分为 T 个顺序、

表 I: 系统级对比。本文比较了 minADE₆ (越低越好)、策略输入长度 (# 场景令牌)、训练成本 (A100 GPU 小时) 以及推理吞吐量 (clips/s)。Flex 实现了最优的效果—效率权衡: 误差更低、令牌更少、训练更快、吞吐量更高。对于三平面 [5], 图像块尺寸记为 $(p_x - p_y - p_z)$ 。

方法	LLM	阶段	# 相机 × # 时间	minADE ₆ ↓	# 场景令牌 ↓	训练时间 ↓ (A100 GPU 小时)	吞吐量 ↑ (clips/s)
* Triplane (8-8-8) [5]	Llama2-1B	Stage 1	4 × 6	1.046	1080 (1.2×)	4984 (2.2×)	69.62 (3.7×)
* Triplane (4-6-6) [5]	Llama2-1B	Stage 1	4 × 6	0.974	2496 (2.8×)	7960 (3.5×)	64.53 (3.5×)
In-house VLA	Qwen2-0.5B	Stage 1	2 × 9	0.818	2880 (3.2×)	4134 (1.8×)	18.60 (1.0×)
Flex (本文)	Qwen2-0.5B	Stage 1	2 × 9	0.794	900 (1.0×)	2260 (1.0×)	41.08 (2.2×)
In-house VLA	Qwen2-0.5B	Stage 1 + Stage 2	2 × 9	0.798	2880 (3.2×)	5750 (1.7×)	18.60 (1.0×)
Flex (本文)	Qwen2-0.5B	Stage 1 + Stage 2	2 × 9	0.761	900 (1.0×)	3318 (1.0×)	41.08 (2.2×)

* 本文引用 [5] 的结果主要供参考, 因为实验设置存在诸多差异, 包括 LLM 训练方式 ([5] 中从头训练 vs. 预训练)、非交错式 [5] vs. 交错式预测, 以及相机 × 时间步的不同选择 ([5] 中为 4 × 6)。

不重叠的分块, $\{\mathbf{S}_{\text{Flex}}^1, \mathbf{S}_{\text{Flex}}^2, \dots, \mathbf{S}_{\text{Flex}}^T\}$, 其中每个分块 $\mathbf{S}_{\text{Flex}}^k \in \mathbb{R}^{(K/T) \times D_{\text{llm}}}$ 。

在时间步 k 的交错式训练过程中, 策略模型以场景令牌前 k 个分块的拼接, 即 $\text{Concat}(\mathbf{S}_{\text{Flex}}^1, \dots, \mathbf{S}_{\text{Flex}}^k)$, 以及最近的历史令牌 $\mathbf{h}_{\text{hist}}$ 为条件。虽然这种划分没有为编码器提供任何显式指导, 但端到端的训练目标迫使模型学习有意义的分配。这一过程迫使场景令牌内部产生涌现的专门化, 不同分块隐式地学习捕捉每一步决策所需的信息, 如图 5 所示。

IV. 实验

A. 实验设置

数据集。本文在一个包含 20,000 小时驾驶日志的大规模内部数据集 (专有数据) 上进行训练与评估。数据集来自一支在 25 个国家、超过 1,700 座城市运行的自行车车队, 保证了高度多样性。它涵盖了广泛的驾驶场景, 包括城市与高速驾驶、各种天气、一天中的不同时段以及多样的交通密度。本文使用地理上分离的留出集进行评估, 按 90% 训练/验证与 10% 测试划分。虽然自行车配备了七个相机, 但为效率起见, 本文主要采用双相机设置 (前视广角相机与前视长焦相机)。所有视频被缩放到 320×512 的分辨率。本文还就相机输入数量进行消融研究, 以展示方法的广泛适用性。

训练与评估细节。本文采用两阶段训练策略。在阶段 1, 冻结图像分块器, 用 AdamW 优化器训练场景编码器与策略模型 300k 次迭代 (消融研究为 100k), 学习率在前 1000 次迭代内线性预热到峰值 4×10^{-4} , 随后采用余弦衰减调度。本文以 256 的全局批大小进行训练 (64 张 GPU 上每张 4 clips/GPU)。阶段 2 为端到端微调, 解冻全部模型参数。在此阶段, 学习率降至 1×10^{-5} , 训练 50k 次迭代。训练时采样 2s 的观测窗口, 评估时采样 1s, 同时保持 9 个时间步的固定时序长度。本文使用标准混合精度训练, 并在策略模型中启用激活检查点。默认情况下, 对 18 张输入图像 (2 相机 × 9 时间步) 使用总共 900 个场景令牌, 以及一个具有完全自注意力的 8 层场景编码器。

评估指标。为提供全面的对比, 本文同时从效率与效果两方面评估方法相对于基线的表现。效率以推理时每秒处理的 clips 数量衡量, 效果则以驾驶性能衡量, 采用标准 minADE_k 指标, 即 k 条预测轨迹上的最小平均位移误差 (minimum Average Displacement Error, minADE)。本文取 $k = 6$:

$$\text{minADE}_6(Y, \hat{Y}) = \min_{k \in \{1, \dots, 6\}} \frac{1}{H} \sum_{t=1}^H \left\| \hat{y}_t^{(k)} - y_t \right\|_2 \quad (3)$$

其中 y_t 为未来时间步 t 处自车的真值位置, $\hat{y}_t^{(k)}$ 为第 k 条预测位置, H 为预测范围内的时间步数量。本文进一步按 0.5s、1.0s、3.0s 与 5.0s 对 minADE₆ 进行时间上的平均。

基线方法。本文将方法与第 III-A 节所述的内部 VLA 模型进行对比, 该模型将全部多视角、多时间步图像令牌的完整扁平化序列直接输入 LLM 策略模型。这一对比使本文能够直接度量引入压缩瓶颈所带来的效率增益与性能变化。除另有说明外, 本文方法与基线使用相同的策略头 (Qwen2-0.5B [34])、轨迹令牌化器与训练调度。

B. 与现有系统的对比

本文在留出的测试集上将 Flex 与先前最先进的系统进行对比。结果如表 1 所示, 表明本文的方法在效率与效果之间实现了更优的权衡。

与本文最先进的内部 VLA 模型相比, Flex 将推理吞吐量提升了 2.2×, 同时将驾驶性能 (minADE₆) 从 0.798 提升至 0.761。相较于基线, Flex 仅需约 60% 的总训练时间。这凸显了将数千个冗余令牌传递给策略头的严重低效。

C. 消融实验

在消融研究中, 本文遵循阶段 1 策略训练所有模型, 并将训练迭代次数从 300k 降至 100k 以控制计算资源。默认情况下, 本文使用 DINOv2-base 作为图像分块器, 每张图像 50 个场景令牌 (每场景 900 个), 8 层具有联合自注意力的场景编码器, 以及 2 个相机 (前视广角与前视长焦)。本文在后续小节中分析各组件的影响。基线遵循完全相同的设置 (相同的 DINOv2-base 主干、LLM 策略头与 100k 训练迭代)。

分块器尺寸的影响。本文通过实验三种尺寸的 DINOv2 [31] (Small、Base 与 Large) 来评估图像分块器的影响, 同时保持场景编码器不变。如图 4a 所示, 从 Small 扩大到 Base 带来了驾驶性能的显著提升, 而编码延迟仅有适度增加; 从 Base 到 Large 则带来更多精度增益, 但计算开销也更大。因此, 本文在所有其他实验中采用 DINOv2-Base, 因为它在性能与效率之间达到了最佳平衡。

场景令牌数量。本文研究性能与效率如何随场景令牌数量 (K) 变化, 将 K 从 144 (每图 8 个令牌) 变化到 1152 (每图 128 个令牌)。图 4b 展示了清晰的权衡。推理吞吐量与 K 成反比, 因为策略模型的成本随输入令牌数量增长。相反, 随着场景令牌增多, 驾驶性能 (minADE₆) 近乎单调提升, 并在 $K \approx 900$ 附近趋于饱和。这形成了一条平滑的帕累托前沿, 使实践者能够针对目标吞吐量选

择 K ——这是相对于刚性图像编码的一个优势。 $K = 900$ 提供了良好的权衡。

场景编码器层数。本文对 Flex 场景编码器的深度进行消融，测试 1、2、4、8 与 16 层 Transformer 的配置。图 4c 展示了结果。从 1 层增至 8 层时性能显著提升，表明场景令牌需要足够的深度才能从数千个图像令牌中有效提取信息；但过深的编码器带来的额外收益微乎其微。因此本文默认采用 8 层。

不同设计选择的帕累托前沿。图 4d 通过绘制不同设计选择下的帕累托前沿来总结消融结果。每条曲线刻画了在单一因素变化时精度与吞吐量之间的权衡。前沿清楚地表明，本文的默认配置（红星）位于最优权衡区域附近，在不牺牲效率的前提下提供了强劲的驾驶性能。

场景编码器设计。本文在相同输出令牌预算 K 下对比四种设计：(1) **具有交叉或自注意力的独立逐图像令牌。**每张相机图像在输入策略模型之前，用其各自的一组可学习令牌独立压缩。这种方式高效，但忽略了跨时空冗余。在此设置下，本文评估了交叉注意力层（如 Q-former [13] 中所用）与自注意力层。(2) **具有交叉或自注意力的联合场景令牌。**引入一组共享的场景令牌来概括所有相机视角与时间步的信息。在交叉注意力设置中，场景令牌关注图像令牌，但图像令牌本身保持固定（即图像令牌之间、图像令牌与场景令牌之间均无自注意力）。本文研究交叉与自注意力两种机制，以理解更新场景令牌与图像令牌的重要性。表 4e 总结了结果。首先，广泛采用的逐图像令牌策略表现逊于联合编码。这在意料之中，因为它无法利用跨相机视角与时间步之间存在的互信息来获得整体式场景表示。其次，在两类方法内部，交叉注意力变体均逊于其自注意力对应版本。这些结果表明，让图像令牌在场景令牌的中介下彼此交互，对于学习有效的表示至关重要。总体而言，整体式联合编码方法被证明对 Flex 的成功不可或缺。

交错式预测。表 4f 表明，交错式对基线与 Flex 都至关重要。对基线模型而言，交错式将 minADE_0 从 0.894 降至 0.860，且不损失效率。对 Flex 而言效果更为显著：交错式将 minADE_0 从 0.991 提升至 0.833，同时保持高吞吐量（41 clips/s）。这一训练策略迫使模型从部分上下文而非始终以完整历史为条件来预测轨迹。由于使用了中间真值，它还提供了更丰富的监督信号与更强的鲁棒性。总体而言，交错式是实现样本高效学习、充分释放场景令牌编码器全部优势的关键。

对相机数量的敏感性。本文进一步考察增加输入相机数量的影响（表 4g）。本文的方法在效率与效果两方面都持续提供优于基线的增益。尤其是，吞吐量优势从 2 相机时的 $2.2\times$ 增长到 7 相机时的 $3.4\times$ ，同时保持强劲的驾驶性能。值得注意的是，随着相机数量增加，基线性能显著下降，而本文的方法保持稳定。本文将这一现象归因于两个因素。第一，从数万个原始图像令牌中学习有效策略愈发困难。第二，前视广角与前视长焦相机已经为测试集划分中的大多数驾驶场景提供了足够的覆盖，而该划分并未特别强调需要侧视或后视相机的罕见情况。探索这些场景仍是未来工作的一个有趣方向。

D. 涌现的场景分解与意图令牌

为探究场景令牌捕捉到了什么，本文通过检查场景编码器产生的注意力权重，分析它们对图像令牌的注意力。具体而言，本文在场景编码器最后一层提取场景令牌到

图像令牌的注意力，将这些值在注意力头上取平均，然后记录每个场景令牌对任一图像令牌的最大响应。这一过程给出了每个场景令牌最强注意力关联的度量，本文用它进行定量分析，并在图 5 中可视化代表性示例。

结果显示清晰的专门化。排名最高的令牌（Rank 1-3）持续突出显示自行车的目的地，表明模型将容量用于与目标相关的推理。中等排名的令牌（Rank 521）表现出扫描行为（双点注意力），将注意力沿道路向前移动，类似前瞻规划。排名较低的令牌（Rank 822）捕捉到静态但关键的结构，如车道标线。本文还注意到，与车道标线相关的令牌更多，意味着这些场景令牌是协同工作的。在末端，响应最弱的令牌（Rank 900）似乎编码位置或偏置相关的模式。其语义尚不清晰，但类似现象已在 ViT [35] 中观察到，其中某些令牌承担结构性角色（例如编码位置）而非显式内容 [23], [36], [11]。


总体而言，这一分析表明场景编码器所做的不仅是压缩视觉输入：它学会将令牌分配给具有语义意义的组件，包括目的地、运动预期、道路布局与位置上下文。涌现出的类似意图令牌，往往在目的地与地标等关键区域具有良性冗余，同时对天空或周围树木等信息量较低的区域分配更少资源。重要的是，这些行为是端到端自然形成的，没有手工先验或显式监督，表明场景令牌与图像令牌之间的联合注意力足以引发有意义的专门化。这种涌现的分解部分解释了该表示为何紧凑而有效，使 Flex 能够以显著更少的令牌实现高性能。

V. 结论

本文提出 Flex，一种面向端到端自动驾驶的简单、高效且数据驱动的场景编码器。本文的核心贡献是一个轻量级、几何无关的 Transformer，将多视角、多时间步图像联合编码为一组紧凑的可学习场景令牌。大量研究表明，编码器的联合、整体式特性对其成功至关重要；它对模型规模与传感器配置具有灵活性；压缩后的场景令牌学习到了驾驶场景涌现式、具有语义意义的分解。探索这些隐式场景令牌的可解释性与专门化将是一个引人入胜的未来方向。**局限性。**尽管 Flex 实现了强劲的效率—精度权衡，本文仍需指出，它继承了内部驾驶数据集的偏置与覆盖局限，可能对罕见的尾部场景覆盖不足。在更多样化的数据上进行更广泛的评估，并审慎考虑下游社会影响（包括跨地域的安全性及公平性），仍是未来工作的重要方向。

REFERENCES

- [1] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. J. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. S. Ryoo, G. Salazar, P. R. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, “Rt-1: Robotics transformer for real-world control at scale,” in *RSS*, 2023.
- [2] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. P. Foster, P. R. Sanketi, Q. Vuong, T. Kollar, B. Burchfiel, R. Tedrake, D. Sadigh, S. Levine, P. Liang, and C. Finn, “Openvla: An open-source vision-language-action model,” in *CoRL*, 2024.
- [3] H. Gao, Z. Wang, Y. Li, K. Long, M. Yang, and Y. Shen, “A survey for foundation models in autonomous driving,” *arXiv preprint arXiv:2402.01105*, 2024.



注意力类型	minADE ₆ (↓)	吞吐量 ↑
每图交叉注意力	0.966	47.96
每图联合注意力	0.844	47.07
交叉注意力	1.032	47.27
联合注意力	0.833	41.08

设置	minADE ₆ (↓)	吞吐量 ↑
基线 (非交错)	0.894	18.47
基线 (交错)	0.860	18.60
本文 (非交错)	0.991	41.06
本文 (交错)	0.833	41.08

(相机 × 时间)	minADE ₆ (↓)	吞吐量 ↑
基线 (2×9)	0.860	18.60
基线 [†] (4×9)	0.886	7.58
基线 [†] (7×9)	0.925	3.34
本文 (2×9), 50 tokens/img	0.833	41.08
本文 (4×9), 50 tokens/img	0.831	19.06
本文 (7×9), 32 tokens/img	0.830	11.40

图 4: 关于 Flex 设计的消融实验。本文评估了 Flex 的关键组件, 包括分块器尺寸、令牌数量、场景编码器深度、注意力类型、交错式设置与相机数量。默认配置 (红星或灰色行) 实现了强劲的精度—效率权衡。在所有设置下, Flex 相比基线都持续提升精度与吞吐量 (2×–3×)。本文方法每个数据点大约需要 650 至 1,000 A100 GPU 小时进行训练, 而基线大约需要 1,300 至 1,800 GPU 小时。[†]: 由于显存不足, 以一半批大小训练。

- X. Tian, J. Gu, B. Li, Y. Liu, Y. Wang, Z. Zhao, K. Zhan, P. Jia, X. Lang, and H. Zhao, “Drivevlm: The convergence of autonomous driving and large vision-language models,” in *CoRL*, 2024.
- B. Ivanovic, C. Saltori, Y. You, Y. Wang, W. Luo, and M. Pavone, “Efficient multi-camera tokenization with tri-planes for end-to-end driving,” *IEEE Robotics and Automation Letters*, vol. 10, no. 11, pp. 11 713–11 720, 2025.
- Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Q. Yu, and J. Dai, “Bevformer: learning bird’s-eye-view representation from lidar-camera via spatiotemporal transformers,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.
- Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang *et al.*, “Planning-oriented autonomous driving,” in *CVPR*, 2023.
- W. Tong, C. Sima, T. Wang, L. Chen, S. Wu, H. Deng, Y. Gu, L. Lu, P. Luo, D. Lin *et al.*, “Scene as occupancy,” in *ICCV*, 2023.
- Y. Huang, W. Zheng, Y. Zhang, J. Zhou, and J. Lu, “Tri-perspective view for vision-based 3d semantic occupancy prediction,” in *CVPR*, 2023.
- A. Cao and J. Johnson, “Hexplane: A fast representation for dynamic scenes,” in *CVPR*, 2023.
- T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski, “Vision transformers need registers,” in *ICLR*, 2024.
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” *NeurIPS*, 2017.
- J. Li, D. Li, S. Savarese, and S. Hoi, “Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models,” in *ICML*, 2023.
- S. Hu, L. Chen, P. Wu, H. Li, J. Yan, and D. Tao, “St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning,” in *ECCV*, 2022.
- S. Chen, B. Jiang, H. Gao, B. Liao, Q. Xu, Q. Zhang, C. Huang, W. Liu, and X. Wang, “Vadv2: End-to-end vectorized autonomous driving via probabilistic planning,” *arXiv preprint arXiv:2402.13243*, 2024.
- Y. Liu, T. Wang, X. Zhang, and J. Sun, “Petr: Position embedding transformation for multi-view 3d object detection,” in *ECCV*, 2022.
- Y. Liu, J. Yan, F. Jia, S. Li, A. Gao, T. Wang, and X. Zhang, “Petrv2: A unified framework for 3d perception from multi-camera images,” in *ICCV*, 2023.
- T. Liang, H. Xie, K. Yu, Z. Xia, Z. Lin, Y. Wang, T. Tang, B. Wang, and Z. Tang, “Bevfusion: A simple and robust lidar-camera fusion framework,” in *NeurIPS*, 2022.
- Y. Wei, L. Zhao, W. Zheng, Z. Zhu, J. Zhou, and J. Lu, “Surroundocc: Multi-camera 3d occupancy prediction for autonomous driving,” in *ICCV*, 2023.
- E. R. Chan, C. Z. Lin, M. A. Chan, K. Nagano, B. Pan, S. De Mello, O. Gallo, L. J. Guibas, J. Tremblay, S. Khamis *et al.*, “Efficient geometry-aware 3d generative adversarial networks,” in *CVPR*, 2022.
- S. Fridovich-Keil, G. Meanti, F. R. Warburg, B. Recht, and A. Kanazawa, “K-planes: Explicit radiance fields in space, time, and appearance,” in *CVPR*, 2023.
- T. Müller, A. Evans, C. Schied, and A. Keller, “Instant neural graphics primitives with a multiresolution hash encoding,” *ACM transactions on graphics (TOG)*, 2022.
- J. Yang, B. Ivanovic, O. Litany, X. Weng, S. W. Kim, B. Li, T. Che, D. Xu, S. Fidler, M. Pavone, and Y. Wang, “Emernerf: Emergent spatial-temporal scene decomposition via self-supervision,” in *ICLR*, 2024.
- A. Jaegle, F. Gimeno, A. Brock, O. Vinyals, A. Zisserman, and J. Carreira, “Perceiver: General perception with iterative attention,” in *ICML*, 2021.
- A. Jaegle, S. Borgeaud, J.-B. Alayrac, C. Doersch, C. Ionescu, D. Ding, S. Koppula, D. Zoran, A. Brock, E. Shelhamer, O. Hénaff, M. M. Botvinick, A. Zisserman, O. Vinyals, and J. Carreira, “Perceiver io: A general architecture for structured inputs & outputs,” in *ICLR*, 2022.
- J.-B. Alayrac, J. Donahue, P. Luc, A. Miech, I. Barr, Y. Hasson, K. Lenc, A. Mensch, K. Millican, M. Reynolds *et al.*, “Flamingo: a visual language model for few-shot learning,” in *NeurIPS*, 2022.
- M. S. Ryoo, A. Piergiovanni, A. Arnab, M. Dehghani, and A. Angelova, “Tokenlearner: What can 8 learned tokens do for images and videos?” in *NeurIPS*, 2021.
- Q. Yu, M. Weber, X. Deng, X. Shen, D. Cremers, and L.-C. Chen, “An image is worth 32 tokens for reconstruction and generation,” in *NeurIPS*, 2024.
- H. Jin, H. Jiang, H. Tan, K. Zhang, S. Bi, T. Zhang, F. Luan, N. Snavely, and Z. Xu, “Lvsm: A large view synthesis model with minimal 3d inductive bias,” in *ICLR*, 2025.
- J. Yang, J. Huang, Y. Chen, Y. Wang, B. Li, Y. You, M. Igl, A. Sharma, P. Karkus, D. Xu, B. Ivanovic, Y. Wang, and M. Pavone, “Storm: Spatio-temporal reconstruction model for large-scale outdoor scenes,” in *ICLR*, 2025.




图 5: 从学习到的场景令牌涌现的场景分解。底部: 本文展示了所有场景令牌排序后的平均令牌响应, 数值越大表明这些令牌对图像令牌的注意力越强。顶部: 代表性场景令牌的可视化。前三行: 排名最高的令牌 (Rank 1-3) 始终聚焦于自行车的目的地。中间两行: 中等排名的令牌 (如 Rank 512) 在道路上展现出有趣的前瞻扫描模式, 类似人类的视觉扫描, 类似于引导注视或前瞻注视策略。接下来两行: 一个排名较低的令牌 (Rank 822) 清晰地突出显示道路车道标线。有趣的是, 响应最弱的令牌 (Rank 900) 似乎捕捉到了位置偏置模式。值得注意的是, 所有这些行为都在没有显式监督的情况下自然涌现。

- [31] M. Oquab, T. Darcet, T. Moutakanni, H. V. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby *et al.*, “Dinov2: Learning robust visual features without supervision,” *Transactions on Machine Learning Research*, 2023.
- [32] J. Wang, M. Chen, N. Karaev, A. Vedaldi, C. Rupprecht, and D. Novotny, “Vggg: Visual geometry grounded transformer,” in *CVPR*, 2025.
- [33] W. Peebles and S. Xie, “Scalable diffusion models with transformers,” in *ICCV*, 2023.
- [34] A. Yang, B. Yang, B. Hui, B. Zheng, B. Yu, C. Zhou, C. Li, C. Li, D. Liu, F. Huang, G. Dong, H. Wei, H. Lin, J. Tang, J. Wang, J. Yang, J. Tu, J. Zhang, J. Ma, J. Xu, J. Zhou, J. Bai, J. He, J. Lin, K. Dang, K. Lu, K. Chen, K. Yang, M. Li, M. Xue, N. Ni, P. Zhang, P. Wang, R. Peng, R. Men, R. Gao, R. Lin, S. Wang, S. Bai, S. Tan, T. Zhu, T. Li, T. Liu, W. Ge, X. Deng, X. Zhou, X. Ren, X. Zhang, X. Wei, X. Ren, Y. Fan, Y. Yao, Y. Zhang, Y. Wan, Y. Chu, Y. Liu, Z. Cui, Z. Zhang, Z. Guo, and Z. Fan, “Qwen2 technical report,” *arXiv preprint arXiv:2407.10671*, 2024.
- [35] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16×16 words: Transformers for image recognition at scale,” in *ICLR*, 2021.
- [36] J. Yang, K. Z. Luo, J. Li, C. Deng, L. Guibas, D. Krishnan, K. Q. Weinberger, Y. Tian, and Y. Wang, “Denoising vision transformers,” in *ECCV*, 2024.