

MOTR: 基于 Transformer 的端到端多目标跟踪 (End-to-End Multiple-Object Tracking with Transformer)

Fangao Zeng^{1*}, Bin Dong^{1*}, Yuang Zhang^{2*}, Tiancai Wang^{1**},
Xiangyu Zhang¹, and Yichen Wei¹

¹ MEGVII Technology

² Shanghai Jiao Tong University

摘要 目标的时序建模是多目标跟踪 (Multiple-Object Tracking, MOT) 中的一个关键挑战。现有方法通过基于运动和外观相似性的启发式规则来关联检测结果, 从而实现跟踪。关联的后处理特性阻碍了端到端地利用视频序列中的时序变化。

本文提出了 MOTR, 它扩展了 DETR [6] 并引入了”跟踪查询 (Track Query)”来建模整个视频中的被跟踪实例。跟踪查询逐帧传递和更新, 以随时间进行迭代预测。本文提出了轨迹感知标签分配 (Tracklet-Aware Label Assignment) 来训练跟踪查询和新生目标查询。本文进一步提出了时序聚合网络 (Temporal Aggregation Network) 和集体平均损失 (Collective Average Loss) 来增强时序关系建模。在 DanceTrack 上的实验结果表明, MOTR 在 HOTA 指标上显著优于当前最优方法 ByteTrack [42], 提升了 6.5%。在 MOT17 上, MOTR 在关联性能上优于同期工作 TrackFormer [18] 和 TransTrack [29]。MOTR 可为未来时序建模和基于 Transformer 的跟踪器研究提供更强的基线。代码已开源在 <https://github.com/megvii-research/MOTR>。

Keywords: 多目标跟踪 (Multiple-Object Tracking), Transformer, 端到端 (End-to-End)

1 引言

多目标跟踪 (Multiple-Object Tracking, MOT) 预测连续图像序列中实例的轨迹 [39, 2]。现有大多数方法将 MOT 的时序关联分解为外观和运动两部分: 外观变化通常通过成对 Re-ID 相似度 [37, 43] 来衡量, 而运动则通过 IoU [4] 或卡尔曼滤波 (Kalman Filtering) [3] 等启发式规则建模。这些方法需要基于相似度匹配进行后处理, 这成为帧间时序信息流的瓶颈。本文旨在引入一个完全端到端的 MOT 框架, 联合建模运动和外观。

最近, DETR [6, 45] 被提出用于端到端目标检测。它把目标检测形式化为一个集合预测问题。如图 1(a) 所示, 目标查询 (Object Query) 作为目标的解耦表示, 被输入到 Transformer 解码器中, 与图像特征交互以更新其表示。进一步采用二分图匹配 (Bipartite Matching) 实现目标查询与真实标签之间的一对一分

* 同等贡献 (Equal contribution)。

** 通讯作者 (Corresponding author)。邮箱: wangtiancai@megvii.com




图 1: (a) DETR 通过让目标查询 (Object Query) 与图像特征交互, 并在更新后的查询与目标之间进行一对一分配, 实现端到端检测。(b) MOTR 通过更新跟踪查询进行序列集合预测。每个跟踪查询代表一个轨迹。(建议彩色查看) Best viewed in color.

配, 消除 NMS 等后处理步骤。与目标检测不同, MOT 可被视为一个序列预测问题。如何在端到端 DETR 系统中进行序列预测仍是一个开放性问题。

迭代预测在机器翻译中很常见 [30,31]。输出上下文由隐藏状态表示, 句子特征在解码器中与隐藏状态迭代交互以预测翻译结果。受机器翻译这些进展的启发, 本文直觉地将 MOT 视为一个序列集合预测问题, 因为 MOT 需要一组目标序列。每个序列对应一个目标轨迹。技术上, 本文将 DETR 中的目标查询扩展为跟踪查询 (*Track Query*) 用于预测目标序列。跟踪查询作为目标轨迹的隐藏状态, 其表示在 Transformer 解码器中被更新并用于迭代预测目标轨迹, 如图 1(b) 所示。具体而言, 跟踪查询通过帧特征的自注意力和交叉注意力进行更新。更新后的跟踪查询进一步用于预测边界框。一个目标的轨迹可从同一跟踪查询在不同帧中的所有预测获得。

为实现上述目标, 需要解决两个问题: 1) 每个跟踪查询跟踪一个目标; 2) 处理新生目标和消失目标。为解决第一个问题, 本文引入了轨迹感知标签分配 (Tracklet-Aware Label Assignment, TALA), 即一个跟踪查询的预测由具有相同身份的边界框序列监督。为解决第二个问题, 本文维护一个可变长度的跟踪查询集合。新生目标的查询被合并到该集合中, 消失目标的查询则被移除。这一过程称为出入机制 (Entrance and Exit Mechanism)。这样, MOTR 在推理过程中不需要显式的轨迹关联。此外, 跟踪查询的迭代更新使得能够同时对运动和外观进行时序建模。

为增强时序建模, 本文进一步提出了集体平均损失 (Collective Average Loss, CAL) 和时序聚合网络 (Temporal Aggregation Network, TAN)。使用 CAL 时, MOTR 在训练中以视频片段为输入, 其参数基于整个视频片段计算的总体损失进行更新。TAN 为跟踪查询引入了一条捷径, 通过 Transformer 中的键-查询机制从其先前状态聚合历史信息。

MOTR 是一个简单的在线跟踪器。它基于 DETR 进行少量标签分配上的修改即可开发。这是一个真正的端到端 MOT 框架, 不需要任何后处理步骤, 如同期工作 TransTrack [29] 和 TrackFormer [18] 中使用的轨迹 NMS 或 IoU 匹配。在 MOT17 和 DanceTrack 数据集上的实验结果表明 MOTR 取得了有竞争力的性能。在 DanceTrack [28] 上, MOTR 在 HOTA 指标上超越当前最优方法 ByteTrack [42] 6.5%, 在 AssA 指标上超越 8.1%。

本文的贡献总结如下:

- 提出了一个完全端到端的 MOT 框架 MOTR，能够以联合方式隐式学习外观和位置变化。
- 将 MOT 形式化为一个序列集合预测问题，从先前的隐藏状态生成跟踪查询，用于迭代更新和预测。
- 提出了轨迹感知标签分配 (Tracklet-Aware Label Assignment)，实现跟踪查询与目标之间的一对一分配。引入出入机制处理新生和消失的轨迹。
- 进一步提出了 CAL 和 TAN 来增强时序建模。

2 相关工作

基于 Transformer 的架构. Transformer [31]最初被引入用于机器翻译中聚合整个输入序列的信息，主要涉及自注意力和交叉注意力机制。此后，Transformer 逐渐被引入到许多领域，如语音处理 [13,7]和计算机视觉 [34,5]。最近，DETR [6]结合了卷积神经网络 (CNN)、Transformer 和二分图匹配来实现端到端目标检测。为实现快速收敛，Deformable DETR [45]将可变形注意力模块引入 Transformer 编码器和解码器。ViT [9]构建了纯 Transformer 架构用于图像分类。进一步，Swin Transformer [16]提出了移位窗口方案以在局部窗口内进行自注意力，提高了效率。VisTR [36]采用直接的端到端并行序列预测框架进行视频实例分割。

多目标跟踪. 主流的 MOT 方法主要遵循先检测后跟踪 (Tracking-by-Detection) 范式 [3,12,22,24,39]。这些方法通常首先使用目标检测器定位每帧中的目标，然后在相邻帧之间进行轨迹关联以生成跟踪结果。SORT [3]通过结合卡尔曼滤波 (Kalman Filter) [38]和匈牙利算法 (Hungarian Algorithm) [11]进行轨迹关联。DeepSORT [39]和 Tracktor [2]引入了额外的余弦距离并计算外观相似度用于轨迹关联。Track-RCNN [26]、JDE [37]和 FairMOT [43]在目标检测器之上增加了 Re-ID 分支，在联合训练框架中融合目标检测和 Re-ID 特征学习。TransMOT [8]构建了时空图 Transformer 进行关联。同期工作 TransTrack [29]和 TrackFormer [18]也开发了基于 Transformer 的 MOT 框架。与它们的直接比较请参见第 3.7 节。

迭代序列预测. 通过序列到序列 (Seq2Seq) 编码器-解码器架构预测序列在机器翻译 [30,31]和文本识别 [25]中很常见。在 Seq2Seq 框架中，编码器网络将输入编码为中间表示。然后，引入带有任务特定上下文信息的隐藏状态，与中间表示迭代交互，通过解码器网络生成目标序列。迭代解码过程包含多次迭代，每次迭代中隐藏状态解码目标序列的一个元素。

3 方法

3.1 目标检测中的查询

DETR [6]引入了一组固定长度的目标查询 (Object Query) 用于检测目标。目标查询被输入到 Transformer 解码器中，与从 Transformer 编码器提取的图像特征交互以更新其表示。进一步采用二分图匹配实现更新后的目标查询与真实标签之间的一对一分配。为明确指定用于目标检测的查询，本文将目标查询简称为“检测查询 (Detect Query)”。




图 2: 在一些典型 MOT 场景下检测查询和跟踪查询的更新过程。跟踪查询集合动态更新，长度可变。跟踪查询集合初始化为空，检测查询用于检测新生目标。所有被检测目标的隐藏状态拼接生成下一帧的跟踪查询。分配给消失目标的跟踪查询从集合中移除。

3.2 检测查询与跟踪查询

将 DETR 从目标检测适配到 MOT 时，出现两个主要问题：1) 如何通过一个跟踪查询跟踪一个目标；2) 如何处理新生目标和消失目标。本文将检测查询扩展为跟踪查询 (Track Query)。跟踪查询集合动态更新，长度可变。如图 2 所示，跟踪查询集合初始化为空，DETR 中的检测查询用于检测新生目标（在 T_2 时的目标 3）。被检测目标的隐藏状态生成下一帧的跟踪查询；分配给消失目标的跟踪查询从跟踪查询集合中移除（在 T_4 时的目标 2）。

3.3 轨迹感知标签分配

在 DETR 中，由于标签分配通过对所有检测查询与真实标签进行二分图匹配来确定，一个检测查询可能被分配给图像中的任何目标。而在 MOTR 中，检测查询仅用于检测新生目标，跟踪查询则预测所有被跟踪目标。本文引入轨迹感知标签分配 (Tracklet-Aware Label Assignment, TALA) 来解决这一问题。

TALA 包含两种策略。对于检测查询，本文将 DETR 中的分配策略修改为**仅新生目标 (Newborn-Only)**，即仅在检测查询与新生目标的真实标签之间进行二分图匹配。对于跟踪查询，本文设计了一种**目标一致 (Target-Consistent)** 分配策略——跟踪查询沿用前几帧的分配结果，因此不参与上述二分图匹配。

形式化地，记跟踪查询的预测为 $\hat{Y}_{tr}$ ，检测查询的预测为 $\hat{Y}_{det}$ ， Y_{new} 是新生目标的真实标签。跟踪查询和检测查询的标签分配结果分别记为 ω_{tr} 和 ω_{det} 。对于第 i 帧，检测查询的标签分配通过对检测查询与新生目标进行二分图匹配获得：

$$\omega_{det}^i = \arg \min_{\omega_{det}^i \in \Omega_i} \mathcal{L}(\hat{Y}_{det}^i | \omega_{det}^i, Y_{new}^i), \quad (1)$$

其中 $\mathcal{L}$ 是 DETR 中定义的成对匹配代价， Ω_i 是检测查询与新生目标之间所有二分图匹配的空间。对于跟踪查询的分配，本文合并上一帧的新生目标分配和被跟踪目标分配，即对于 $i > 1$ ：

$$\omega_{tr}^i = \omega_{tr}^{i-1} \cup \omega_{det}^{i-1}. \quad (2)$$




图 3: MOTR 的整体架构。“Enc”表示卷积神经网络骨干网络和提取每帧图像特征的 Transformer 编码器。检测查询 q_d 和跟踪查询 q_{tr} 的拼接被输入到 Deformable DETR 解码器 (Dec) 中生成隐藏状态。隐藏状态用于生成新生和被跟踪目标的预测 $\hat{Y}$ 。查询交互模块 (QIM) 以隐藏状态为输入, 生成下一帧的跟踪查询。

对于第一帧 ($i = 1$), 跟踪查询分配 ω_{tr}^1 为空集 $\emptyset$, 因为第一帧中没有被跟踪的目标。对于后续帧 ($i > 1$), 跟踪查询分配 ω_{tr}^i 是前一帧的跟踪查询分配 ω_{tr}^{i-1} 与新生目标分配 ω_{det}^{i-1} 的拼接。

在实际中, 得益于 Transformer 强大的注意力机制, TALA 策略简单而有效。对于每帧, 检测查询和跟踪查询被拼接后输入到 Transformer 解码器中更新其表示。检测查询将仅检测新生目标, 因为 Transformer 解码器中的自注意力查询交互会抑制那些检测已被跟踪目标的检测查询。这一机制类似于 DETR 中的重复去除——重复的边界框被低分数抑制。

3.4 MOTR 架构

MOTR 的整体架构如图 3 所示。视频序列被输入到卷积神经网络 (CNN) (如 ResNet-50 [10]) 和 Deformable DETR [45] 编码器中提取帧特征。

对于第一帧, 没有跟踪查询, 本文仅将固定长度的可学习检测查询 (图 3 中的 q_d) 输入到 Deformable DETR [45] 解码器中。对于后续帧, 将前一帧的跟踪查询与可学习检测查询拼接后输入到解码器中。这些查询在解码器中与图像特征交互, 生成用于边界框预测的隐藏状态。隐藏状态也被输入到查询交互模块 (Query Interaction Module, QIM) 中, 生成下一帧的跟踪查询。

在训练阶段, 每帧的标签分配如第 3.3 节所述。视频片段的所有预测被收集到预测库 $\{\hat{Y}_1, \hat{Y}_2, \dots, \hat{Y}_N\}$ 中, 并使用第 3.6 节提出的集体平均损失 (CAL) 进行监督。推理时, 视频流可在线处理并生成每帧的预测。




图 4: 查询交互模块 (QIM) 的结构。QIM 的输入是 Transformer 解码器生成的隐藏状态及相应的预测分数。在推理阶段, 根据置信度分数保留新生目标并移除消失目标。时序聚合网络 (TAN) 增强长程时序建模。

3.5 查询交互模块

本节描述查询交互模块 (Query Interaction Module, QIM)。QIM 包括目标出入机制 (Object Entrance and Exit Mechanism) 和时序聚合网络 (Temporal Aggregation Network, TAN)。

目标出入机制. 如上所述, 视频序列中的某些目标可能在中间帧出现或消失。这里介绍本文处理新生目标和消失目标的方式。对于任何帧, 跟踪查询与检测查询拼接后输入到 Transformer 解码器中, 生成隐藏状态 (见图 4 左侧)。

在训练阶段, 如果匹配的目标在真实标签中已消失, 或预测边界框与目标之间的交并比 (IoU) 低于 0.5 的阈值, 则移除消失目标的隐藏状态。这意味着如果这些目标在当前帧消失, 相应的隐藏状态将被过滤掉, 其余隐藏状态保留。对于新生目标, 根据式 1 中定义的新生目标分配 ω_{det}^i 保留相应的隐藏状态。

推理时, 使用预测的分类分数来判断新生目标的出现和被跟踪目标的消失, 如图 4 所示。对于检测查询, 保留分类分数高于进入阈值 τ_{en} 的预测, 其余隐藏状态被移除。对于跟踪查询, 如果分类分数连续 M 帧低于退出阈值 τ_{ex} , 则移除对应的隐藏状态, 其余保留。

时序聚合网络. 这里介绍 QIM 中的时序聚合网络 (Temporal Aggregation Network, TAN), 用于增强时序关系建模并为被跟踪目标提供上下文先验信息。

如图 4 所示, TAN 的输入是被跟踪目标 (目标“1”) 的过滤后隐藏状态。本文还收集上一帧的跟踪查询 q_{tr}^i 用于时序聚合。TAN 是一个经过修改的 Transformer 解码器层。来自上一帧的跟踪查询与过滤后的隐藏状态相加, 作为多头自注意力 (MHA) 的键和查询分量。单独的隐藏状态作为 MHA 的值分量。经过 MHA 后, 应用前馈网络 (FFN), 将结果与新生目标 (目标“3”) 的隐藏状态拼接, 生成下一帧的跟踪查询集合 q_{tr}^{i+1} 。

3.6 集体平均损失

训练样本对于轨迹的时序建模至关重要，因为 MOTR 从数据中学习时序变化，而非依赖卡尔曼滤波等手工设计的启发式规则。常见的训练策略（如在两帧内训练）无法生成远程目标运动的训练样本。与它们不同，MOTR 以视频片段为输入，从而能够生成远程目标运动的训练样本用于时序学习。

与逐帧计算损失不同，本文的集体平均损失（Collective Average Loss, CAL）收集多个预测 $\hat{Y} = \{\hat{Y}_i\}_{i=1}^N$ ，然后通过真实标签 $Y = \{Y_i\}_{i=1}^N$ 和匹配结果 $\omega = \{\omega_i\}_{i=1}^N$ 计算整个视频序列的损失。CAL 是整段视频序列的总体损失，按目标数量归一化：

$$\mathcal{L}_o(\hat{Y}|_{\omega}, Y) = \frac{\sum_{n=1}^N (\mathcal{L}(\hat{Y}_{tr}^i|_{\omega_{tr}^i}, Y_{tr}^i) + \mathcal{L}(\hat{Y}_{det}^i|_{\omega_{det}^i}, Y_{det}^i))}{\sum_{n=1}^N (V_i)} \quad (3)$$

其中 $V_i = V_{tr}^i + V_{det}^i$ 表示第 i 帧的真实目标总数。 V_{tr}^i 和 V_{det}^i 分别是第 i 帧中被跟踪目标和新生目标的数量。 $\mathcal{L}$ 是单帧损失，与 DETR 中的检测损失类似。单帧损失 $\mathcal{L}$ 可形式化为：

$$\mathcal{L}(\hat{Y}_i|_{\omega_i}, Y_i) = \lambda_{cls} \mathcal{L}_{cls} + \lambda_{l_1} \mathcal{L}_{l_1} + \lambda_{giou} \mathcal{L}_{giou} \quad (4)$$

其中 $\mathcal{L}_{cls}$ 是焦点损失（Focal Loss）[14]， $\mathcal{L}_{l_1}$ 表示 L1 损失， $\mathcal{L}_{giou}$ 是广义 IoU 损失（Generalized IoU Loss）[21]。 λ_{cls} 、 λ_{l_1} 和 λ_{giou} 是相应的权重系数。

3.7 讨论

基于 DETR，本文的同期工作 TransTrack [29] 和 TrackFormer [18] 也开发了基于 Transformer 的 MOT 框架。然而，本文方法与它们存在显著差异：

TransTrack 将完整轨迹建模为若干独立短轨迹片段（Tracklet）的组合。类似于先检测后跟踪范式，TransTrack 将 MOT 解耦为两个子任务：1) 在相邻两帧内检测目标对作为短轨迹片段；2) 通过 IoU 匹配将短轨迹片段关联为完整轨迹。而 MOTR 通过跟踪查询的迭代更新以端到端方式建模完整轨迹，不需要 IoU 匹配。

TrackFormer 与本文共享跟踪查询的思想。然而，TrackFormer 仍在相邻两帧内进行学习。如第 3.6 节所述，短程学习会导致时序学习能力相对较弱。因此，TrackFormer 采用轨迹 NMS 和 Re-ID 特征等启发式规则来过滤重复轨迹。与 TrackFormer 不同，MOTR 通过 CAL 和 TAN 学习更强的时序运动，从而消除了这些启发式规则的需求。与 TransTrack 和 TrackFormer 的直接比较请参见表 1。

在此需要说明，本文独立启动此项工作的时间远早于 TrackFormer 和 TransTrack 出现在 arXiv 上。鉴于它们尚未正式发表，本文将这两项工作视为同期且独立的工作，而非本文所基于的前人工作。

表 1: 与基于 Transformer 的其他 MOT 方法对比。

Method	IoU	match	NMS	ReID
TransTrack [29]	✓			
TrackFormer [18]			✓	✓
MOTR (ours)				

表 2: 所选评估数据集的统计数据。

Datasets	Class	Frame	Video	ID
DanceTrack [28]	1	106k	100	990
MOT17 [19]	1	11k	14	1342
BDD100K [41]	8	318k	1400	131k

4 实验

4.1 数据集与评估指标

数据集. 为进行全面评估, 在三个数据集上进行了实验: DanceTrack [28]、MOT17 [19] 和 BDD100k [41]。MOT17 [19] 包含 7 个训练序列和 7 个测试序列。DanceTrack [28] 是一个最近提出的多目标跟踪数据集, 具有外观一致、运动多样的特点。它包含更多用于训练和评估的视频, 从而为验证跟踪性能提供了更好的选择。BDD100k [41] 是一个自动驾驶数据集, 其 MOT 赛道包含多类目标。更多细节请参见表 2 中的数据集统计信息。

评估指标. 本文遵循标准评估协议进行评估。常用指标包括多目标跟踪高阶指标 (Higher Order Metric for Evaluating Multi-object Tracking) [17] (HOTA、AssA、DetA)、多目标跟踪准确度 (MOTA)、身份切换次数 (IDS) 和身份 F1 分数 (IDF1)。

4.2 实现细节

参照 CenterTrack [44] 的设置, MOTR 采用了多种数据增强方法, 如随机翻转和随机裁剪。输入图像的短边缩放到 800, 最大尺寸限制为 1536。在此分辨率下, Tesla V100 上的推理速度约为 7.5 FPS。以随机间隔采样关键帧以解决可变帧率问题。此外, 以概率 p_{drop} 擦除被跟踪查询以为新生目标生成更多样本, 并以概率 p_{insert} 插入假阳性跟踪查询以模拟目标消失。所有实验在 PyTorch 上使用 8 张 NVIDIA Tesla V100 GPU 进行。还提供了内存优化版本, 可在 NVIDIA 2080 Ti GPU 上训练。

MOTR 基于 Deformable-DETR [45] 和 ResNet50 [10] 构建以实现快速收敛。批量大小设为 1, 每个批次包含 5 帧的视频片段。使用 AdamW 优化器训练模型, 初始学习率为 $2.0 \cdot 10^{-4}$ 。对于所有数据集, 使用在 COCO [15] 数据集上预训练的官方 Deformable DETR [45] 权重初始化 MOTR。在 **MOT17** 上, 训练 MOTR 200 个周期, 学习率在第 100th 周期衰减为原来的十分之一。在与当前最优方法的对比中, 使用联合数据集 (MOT17 训练集和 CrowdHuman [23] 验证集) 进行训练。对于 CrowdHuman 验证集中约 5k 张静态图像, 按照 [44] 的方法应用随机平移以生成带有伪轨迹的视频片段。视频片段的初始长度为 2, 在第 50th、90th、150th 周期分别逐步增加到 3、4、5。视频片段长度的渐进增加提高了训练效率和稳定性。在消融实验中, 在不使用 CrowdHuman 数据集的情况下, 在 MOT17 训练集上训练 MOTR, 并在 2DMOT15 训练集上进行验证。在 **DanceTrack** 上, 在训练集上训练 20 个周期, 学习率在第 10th 周期衰减。在第 5th、9th、15th 周期将片段长度从 2 逐步增加到 3、4、5。在 **BDD100k** 上,

表 3: MOTR 与现有方法在 MOT17 数据集上采用私有检测协议的性能对比。粗体表示基于 Transformer 的方法中的最优结果。

Methods	HOTA↑	AssA↑	DetA↑	IDF1↑	MOTA↑	IDS↓
<i>CNN-based:</i>						
Tracktor++ [2]	44.8	45.1	44.9	52.3	53.5	2072
CenterTrack [44]	52.2	51.0	53.8	64.7	67.8	3039
TraDeS [40]	52.7	50.8	55.2	63.9	69.1	3555
QDTrack [20]	53.9	52.7	55.6	66.3	68.7	3378
GSDT [35]	55.5	54.8	56.4	68.7	66.2	3318
FairMOT [43]	59.3	58.0	60.9	72.3	73.7	3303
CorrTracker [32]	60.7	58.9	62.9	73.6	76.5	3369
GRTU [33]	62.0	62.1	62.1	75.0	74.9	1812
MAATrack [27]	62.0	60.2	64.2	75.9	79.4	1452
ByteTrack [42]	63.1	62.0	64.5	77.3	80.3	2196
<i>Transformer-based:</i>						
TrackFormer [18]	/	/	/	63.9	65.0	3528
TransTrack [29]	54.1	47.9	61.6	63.9	74.5	3663
MOTR (ours)	57.8	55.7	60.3	68.6	73.4	2439

在训练集上训练 20 个周期，学习率在第 16th 周期衰减。在第 6th 和 12th 周期将片段长度从 2 逐步增加到 3 和 4。

4.3 MOT17 上的当前最优对比

表 3 将本文方法与 MOT17 测试集上的当前最优方法进行了比较。主要将 MOTR 与基于 Transformer 的同期工作 TrackFormer [18] 和 TransTrack [29] 进行对比。本文方法获得了更高的 IDF1 分数，超过 TransTrack 和 TrackFormer 4.5%。MOTR 在 HOTA 指标上的性能比 TransTrack 高出 3.1%。在 MOTA 指标上，本文方法远优于 TrackFormer (71.9% vs. 65.0%)。有趣的是，在 MOTA 上 TransTrack 的性能优于 MOTR。推测 TransTrack 中检测和跟踪分支的解耦确实提高了目标检测性能。而在 MOTR 中，检测查询和跟踪查询通过共享的 Transformer 解码器学习，检测查询在检测被跟踪目标时受到抑制，限制了新生目标的检测性能。

与 ByteTrack [42] 等其他当前最优方法相比，MOTR 在 MOT17 数据集上存在明显差距。通常，MOT17 数据集上的最佳性能由具有良好检测性能以应对各种外观分布的跟踪器主导。此外，不同的跟踪器倾向于使用不同的检测器进行目标检测，很难公平地验证各跟踪器的运动建模能力。因此，本文认为仅凭 MOT17 数据集不足以全面评估 MOTR 的跟踪性能。接下来在具有统一外观和多样运动的 DanceTrack [28] 数据集上进一步评估跟踪性能。

4.4 DanceTrack 上的当前最优对比

最近，一个具有统一外观和多样运动的数据集 DanceTrack [28] 被提出（见表 2）。它包含更多用于评估的视频，为验证跟踪性能提供了更好的选择。在 DanceTrack 数据集上进一步进行实验，并在表 4 中与当前最优方法进行性能比较。结果表

表 4: MOTR 与现有方法在 DanceTrack[28]数据集上的性能对比。现有方法的结果来自 DanceTrack [28]。

Methods	HOTA	AssA	DetA	MOTA	IDF1
CenterTrack [44]	41.8	22.6	78.1	86.8	35.7
FairMOT [43]	39.7	23.8	66.7	82.2	40.8
QDTrack [20]	45.7	29.2	72.1	83.0	44.8
TransTrack [29]	45.5	27.5	75.9	88.4	45.2
TraDes [40]	43.3	25.4	74.5	86.2	41.2
ByteTrack [42]	47.7	32.1	71.0	89.6	53.9
MOTR (ours)	54.2	40.2	73.5	79.7	51.5

表 5: MOTR 与现有方法在 BDD100k[41]验证集上的性能对比。

Methods	mMOTA	mIDF1	IDS _w
Yu <i>et al.</i> [41]	25.9	44.5	8315
DeepBlueAI [1]	26.9	/	13366
MOTR (ours)	32.0	43.5	3493

明 MOTR 在 DanceTrack 数据集上取得了更好的性能。本文方法获得了更高的 HOTA 分数, 超越 ByteTrack 6.5%。在 AssA 指标上, 本文方法也优于 ByteTrack (40.2% *vs.* 32.1%)。而在 DetA 指标上, MOTR 不如某些当前最优方法。这意味着 MOTR 在时序运动学习方面表现良好, 但检测性能不够理想。HOTA 的大幅提升主要来自时序聚合网络和集体平均损失。

4.5 多类场景的泛化能力

基于 Re-ID 的方法 (如 FairMOT [43]) 倾向于将每个被跟踪目标 (如行人) 视为一个类别, 并通过特征相似度关联检测结果。然而, 当被跟踪目标数量非常大时, 关联将变得困难。与之不同, MOTR 中每个目标被表示为一个跟踪查询, 跟踪查询集合具有动态长度。MOTR 可以通过简单地修改分类分支的类别数来轻松处理多类预测问题。为验证 MOTR 在多类场景上的性能, 在 BDD100k 数据集上进一步进行实验 (见表 5)。BDD100k 验证集上的结果表明, MOTR 在多类场景上表现良好, 以更少的身份切换次数取得了有竞争力的性能。

4.6 消融实验

MOTR 组件. 表 6a 展示了集成不同组件的影响。将各组件集成到基线中可以逐步提升整体性能。仅使用原始目标查询会导致大量身份切换, 因为大多数目标被视为进入目标。引入跟踪查询后, 基线能够处理跟踪关联, 将 IDF1 从 1.2 提升到 49.8。进一步, 在基线上添加 TAN 使 MOTA 提升 7.8%, IDF1 提升 13.6%。在训练中使用 CAL 时, MOTA 和 IDF1 分别额外提升 8.3% 和 7.1%。这表明 TAN 结合 CAL 可以增强时序运动的学习。

集体平均损失. 探讨了 CAL 中视频序列长度对跟踪性能的影响。如表 6b 所示, 当视频片段长度从 2 逐步增加到 5 时, MOTA 和 IDF1 指标分别提升了 8.3% 和 7.1%。因此, 多帧 CAL 可以极大提升跟踪性能。多帧 CAL 可以帮助网络处

表 6: MOTR 的消融实验。所有实验均使用 ResNet50 中的单层 C5 特征。

(a) 各项贡献的影响。TrackQ: 跟踪查询。TAN: 时序聚合网络。CAL: 集体平均损失。 (b) 训练中集体平均损失中视频片段长度增加对跟踪性能的影响。

TrackQ	TAN	CAL	MOTA↑	IDF1↑	IDS↓
			-	1.2	33198
✓			37.1	49.8	562
✓	✓		44.9	63.4	257
✓		✓	47.5	56.1	417
✓	✓	✓	53.2	70.5	155

Length	MOTA↑	IDF1↑	IDS↓
2	44.9	63.4	257
3	51.6	59.4	424
4	50.6	64.0	314
5	53.2	70.5	155

(c) 训练中随机擦除跟踪查询概率 p_{drop} 的分析。 (d) 训练中随机插入假阳性概率 p_{insert} 的效果。

p_{drop}	MOTA↑	IDF1↑	IDS↓
5e-2	49.0	60.4	411
0.1	53.2	70.5	155
0.3	51.1	69.0	180
0.5	48.5	62.0	302

p_{insert}	MOTA↑	IDF1↑	IDS↓
0.1	51.2	71.7	148
0.3	53.2	70.5	155
0.5	52.1	62.0	345
0.7	50.7	57.7	444

(e) QIM 网络中 τ_{ex} 和 τ_{en} 不同组合的探索。 (f) 随机采样间隔对跟踪性能的影响。

τ_{ex}	0.6	0.6	0.6	0.5	0.6	0.7
τ_{en}	0.7	0.8	0.9	0.8	0.8	0.8
MOTA↑	52.7	53.2	53.1	53.5	53.2	52.8
IDF1↑	69.8	70.5	70.1	70.5	70.5	68.3
IDS↓	181	155	142	153	155	181

Intervals	MOTA↑	IDF1↑	IDS↓
3	53.2	64.8	218
5	50.8	62.8	324
10	53.2	70.5	155
12	53.1	69	158

理遮挡场景等困难情况。观察到重复边界框、身份切换和遮挡场景中的目标丢失显著减少。为验证这一点，图 5 提供了一些可视化结果。

擦除与插入跟踪查询. 在 MOT 数据集中，对两种情况的训练样本较少：视频序列中的目标进入和目标消失。因此，采用跟踪查询擦除和插入来模拟这两种情况，概率分别为 p_{drop} 和 p_{insert} 。表 6c 报告了训练中使用不同 p_{drop} 值的性能。当 p_{drop} 设为 0.1 时，MOTR 取得最佳性能。与进入目标类似，将前一帧传递来的预测为假阳性的跟踪查询插入到当前帧，以模拟目标消失的情况。在表 6d 中，探讨了不同 p_{insert} 对跟踪性能的影响。当 p_{insert} 从 0.1 逐步增加到 0.7 时，MOTR 在 p_{insert} 设为 0.3 时取得最高的 MOTA 分数，而 IDF1 分数呈下降趋势。

目标出入阈值. 表 6e 研究了 QIM 中目标进入阈值 τ_{en} 和退出阈值 τ_{ex} 不同组合的影响。改变目标进入阈值 τ_{en} 时，性能对 τ_{en} 不太敏感（MOTA 变化在 0.5% 以内），使用 0.8 的进入阈值可获得相对较好的性能。还进一步通过改变目标退出阈值 τ_{ex} 进行实验。结果表明，使用 0.5 的阈值比 0.6 略好。在实践中， τ_{en} 在 MOT17 测试集上使用 0.6 表现更好。

采样间隔. 在表 6f 中，评估了训练中随机采样间隔对跟踪性能的影响。当采样间隔从 2 增加到 10 时，身份切换次数从 209 显著下降到 155。在训练过程中，当帧采样间隔较小时，网络容易陷入局部最优解。适当增加采样间隔可以模拟真实



图 5: CAL 在解决 (a) 重复边界框和 (b) 身份切换问题中的效果。上排和下排分别为不使用和使用 CAL 的跟踪结果。

场景。当随机采样间隔大于 10 时，跟踪框架无法捕捉这种长程动态，导致跟踪性能相对较差。

5 局限性

MOTR 作为一种在线跟踪器，实现了端到端的多目标跟踪。得益于 DETR 架构和轨迹感知标签分配，它以联合方式隐式学习外观和位置变化。然而，它也存在若干不足。首先，新生目标的检测性能远未达到令人满意的水平（MOTA 指标上的结果不够理想）。如前面所分析的，检测查询在检测被跟踪目标时受到抑制，这可能违背目标查询的本质并限制了对新生目标的检测性能。其次，MOTR 中的查询传递逐帧进行，限制了训练过程中模型学习的效率。在实践中，VisTR [36] 中的并行解码无法处理 MOT 中的复杂场景。解决上述两个问题将是基于 Transformer 的 MOT 框架的重要研究方向。

Acknowledgements: This research was supported by National Key R&D Program of China (No. 2017YFA0700800) and Beijing Academy of Artificial Intelligence (BAAI).

参考文献

1. CodaLab Competition - CVPR 2020 BDD100K Multiple Object Tracking Challenge (Jul 2022), <https://competitions.codalab.org/competitions/24910>, [Online; accessed 19. Jul. 2022] 10
2. Bergmann, P., Meinhardt, T., Leal-Taixe, L.: Tracking without bells and whistles. In: ICCV (2019) 1, 3, 9
3. Bewley, A., Ge, Z., Ott, L., Ramos, F., Upcroft, B.: Simple online and realtime tracking. In: ICIP (2016) 1, 3
4. Bochinski, E., Eiselein, V., Sikora, T.: High-speed tracking-by-detection without using image information. In: AVSS (2017) 1
5. Camgoz, N.C., Koller, O., Hadfield, S., Bowden, R.: Sign language transformers: Joint end-to-end sign language recognition and translation. In: CVPR (2020) 3

6. Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S.: End-to-end object detection with transformers. In: ECCV (2020) [1](#), [3](#)
7. Chang, X., Zhang, W., Qian, Y., Le Roux, J., Watanabe, S.: End-to-end multi-speaker speech recognition with transformer. In: ICASSP (2020) [3](#)
8. Chu, P., Wang, J., You, Q., Ling, H., Liu, Z.: Transmot: Spatial-temporal graph transformer for multiple object tracking. arXiv preprint arXiv:2104.00194 (2021) [3](#)
9. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N.: An image is worth 16x16 words: Transformers for image recognition at scale. In: ICLR (2021) [3](#)
10. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: CVPR (2016) [5](#), [8](#)
11. Kuhn, H.W.: The hungarian method for the assignment problem. Naval research logistics quarterly **2**(1-2), 83–97 (1955) [3](#)
12. Leal-Taixé, L., Canton-Ferrer, C., Schindler, K.: Learning by tracking: Siamese cnn for robust target association. In: CVPRW (2016) [3](#)
13. Li, N., Liu, S., Liu, Y., Zhao, S., Liu, M.: Neural speech synthesis with transformer network. In: AAAI (2019) [3](#)
14. Lin, T.Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal loss for dense object detection. In: ICCV (2017) [7](#)
15. Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L.: Microsoft coco: Common objects in context. In: ECCV (2014) [8](#)
16. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin transformer: Hierarchical vision transformer using shifted windows. arXiv preprint arXiv:2103.14030 (2021) [3](#)
17. Luiten, J., Osep, A., Dendorfer, P., Torr, P., Geiger, A., Leal-Taixé, L., Leibe, B.: Hota: A higher order metric for evaluating multi-object tracking. IJCV **129**(2), 548–578 (2021) [8](#)
18. Meinhardt, T., Kirillov, A., Leal-Taixe, L., Feichtenhofer, C.: Trackformer: Multi-object tracking with transformers. arXiv preprint arXiv:2101.02702 (2021) [1](#), [2](#), [3](#), [7](#), [8](#), [9](#)
19. Milan, A., Leal-Taixé, L., Reid, I., Roth, S., Schindler, K.: Mot16: A benchmark for multi-object tracking. arXiv preprint arXiv:1603.00831 (2016) [8](#)
20. Pang, J., Qiu, L., Li, X., Chen, H., Li, Q., Darrell, T., Yu, F.: Quasi-dense similarity learning for multiple object tracking. In: CVPR (2021) [9](#), [10](#)
21. Rezatofighi, H., Tsoi, N., Gwak, J., Sadeghian, A., Reid, I., Savarese, S.: Generalized intersection over union: A metric and a loss for bounding box regression. In: CVPR (2019) [7](#)
22. Schulter, S., Vernaza, P., Choi, W., Chandraker, M.: Deep network flow for multi-object tracking. In: CVPR (2017) [3](#)
23. Shao, S., Zhao, Z., Li, B., Xiao, T., Yu, G., Zhang, X., Sun, J.: Crowdhuman: A benchmark for detecting human in a crowd. arXiv preprint arXiv:1805.00123 (2018) [8](#)
24. Sharma, S., Ansari, J.A., Murthy, J.K., Krishna, K.M.: Beyond pixels: Leveraging geometry and shape cues for online multi-object tracking. In: ICRA (2018) [3](#)
25. Shi, B., Bai, X., Yao, C.: An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. TPAMI **39**(11), 2298–2304 (2016) [3](#)
26. Shuai, B., Berneshawi, A.G., Modolo, D., Tighe, J.: Multi-object tracking with siamese track-rcnn. arXiv preprint arXiv:2004.07786 (2020) [3](#)

27. Stadler, D., Beyerer, J.: Modelling ambiguous assignments for multi-person tracking in crowds. In: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. pp. 133–142 (2022) [9](#)
28. Sun, P., Cao, J., Jiang, Y., Yuan, Z., Bai, S., Kitani, K., Luo, P.: Dancetrack: Multi-object tracking in uniform appearance and diverse motion. *arXiv preprint arXiv:2111.14690* (2021) [2](#), [8](#), [9](#), [10](#)
29. Sun, P., Jiang, Y., Zhang, R., Xie, E., Cao, J., Hu, X., Kong, T., Yuan, Z., Wang, C., Luo, P.: Transtrack: Multiple-object tracking with transformer. *arXiv preprint arXiv: 2012.15460* (2020) [1](#), [2](#), [3](#), [7](#), [8](#), [9](#), [10](#)
30. Sutskever, I., Vinyals, O., Le, Q.V.: Sequence to sequence learning with neural networks. In: *NeurIPS* (2014) [2](#), [3](#)
31. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. In: *NeurIPS* (2017) [2](#), [3](#)
32. Wang, Q., Zheng, Y., Pan, P., Xu, Y.: Multiple object tracking with correlation learning. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. pp. 3876–3886 (2021) [9](#)
33. Wang, S., Sheng, H., Zhang, Y., Wu, Y., Xiong, Z.: A general recurrent tracking framework without real data. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. pp. 13219–13228 (2021) [9](#)
34. Wang, X., Girshick, R., Gupta, A., He, K.: Non-local neural networks. In: *CVPR* (2018) [3](#)
35. Wang, Y., Kitani, K., Weng, X.: Joint object detection and multi-object tracking with graph neural networks. In: *2021 IEEE International Conference on Robotics and Automation (ICRA)*. pp. 13708–13715. IEEE (2021) [9](#)
36. Wang, Y., Xu, Z., Wang, X., Shen, C., Cheng, B., Shen, H., Xia, H.: End-to-end video instance segmentation with transformers. In: *CVPR* (2021) [3](#), [12](#)
37. Wang, Z., Zheng, L., Liu, Y., Li, Y., Wang, S.: Towards real-time multi-object tracking. In: *ECCV* (2020) [1](#), [3](#)
38. Welch, G., Bishop, G., et al.: An introduction to the kalman filter (1995) [3](#)
39. Wojke, N., Bewley, A., Paulus, D.: Simple online and realtime tracking with a deep association metric. In: *ICIP* (2017) [1](#), [3](#)
40. Wu, J., Cao, J., Song, L., Wang, Y., Yang, M., Yuan, J.: Track to detect and segment: An online multi-object tracker. In: *CVPR* (2021) [9](#), [10](#)
41. Yu, F., Chen, H., Wang, X., Xian, W., Chen, Y., Liu, F., Madhavan, V., Darrell, T.: Bdd100k: A diverse driving dataset for heterogeneous multitask learning. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (June 2020) [8](#), [10](#)
42. Zhang, Y., Sun, P., Jiang, Y., Yu, D., Yuan, Z., Luo, P., Liu, W., Wang, X.: Bytetrack: Multi-object tracking by associating every detection box. *arXiv preprint arXiv:2110.06864* (2021) [1](#), [2](#), [9](#), [10](#)
43. Zhang, Y., Wang, C., Wang, X., Zeng, W., Liu, W.: Fairmot: On the fairness of detection and re-identification in multiple object tracking. *IJCV* pp. 1–19 (2021) [1](#), [3](#), [9](#), [10](#)
44. Zhou, X., Koltun, V., Krähenbühl, P.: Tracking objects as points. In: *ECCV* (2020) [8](#), [9](#), [10](#)
45. Zhu, X., Su, W., Lu, L., Li, B., Wang, X., Dai, J.: Deformable detr: Deformable transformers for end-to-end object detection. In: *ICLR* (2020) [1](#), [3](#), [5](#), [8](#)