

PETR: 面向多视角 3D 目标检测的位置嵌入变换 (Position Embedding Transformation for Multi-View 3D Object Detection)

Yingfei Liu* Tiancai Wang* Xiangyu Zhang Jian Sun

MEGVII Technology

{liuyingfei,wangtiancai,zhangxiangyu,sunjian}@megvii.com

摘要 本文提出了用于多视角 3D 目标检测的位置嵌入变换 (Position Embedding Transformation, PETR)。PETR 将 3D 坐标的位置信息编码到图像特征中, 生成 3D 位置感知特征 (3D Position-Aware Features)。目标查询 (Object Query) 能够感知这些 3D 位置感知特征, 实现端到端 (End-to-End) 目标检测。PETR 在标准 nuScenes 数据集上达到了当前最优 (State-of-the-Art, SOTA) 性能 (NDS **50.4%**, mAP **44.1%**), 在基准测试中排名第一。该方法可作为未来研究的简洁而强大的基线。代码已开源: <https://github.com/megvii-research/PETR>。

Keywords: 位置嵌入, Transformer, 3D 目标检测

1 引言

多视角图像的 3D 目标检测因在自动驾驶系统中成本低廉而备受关注。先前的工作 [6,33,49,34,48] 主要从单目目标检测 (Monocular Object Detection) 的角度解决该问题。最近, DETR [4] 因其在端到端目标检测方面的贡献而获得了广泛关注。在 DETR [4] 中, 每个目标查询代表一个目标, 并与 Transformer 解码器中的 2D 特征交互以生成预测 (见图 1(a))。DETR3D [51] 是 DETR [4] 框架的直接扩展, 为端到端 3D 目标检测提供了一种直观的解决方案。目标查询预测的 3D 参考点通过相机参数投影回图像空间, 用于从所有相机视角采样 2D 特征 (见图 1(b))。解码器以采样特征和查询为输入, 更新目标查询的表示。

然而, DETR3D [51] 中的这种 2D 到 3D 变换会引入若干问题。首先, 参考点的预测坐标可能不够精确, 导致采样的特征偏离目标区域。其次, 仅收集投影点处的图像特征, 无法从全局视角进行表示学习。此外, 复杂的特征采样过程也阻碍了检测器的实际应用。因此, 构建一个无需在线 2D 到 3D 变换和特征采样的端到端 3D 目标检测框架仍是待解决的问题。

本文旨在基于 DETR [4] 开发一个简洁优雅的 3D 目标检测框架。我们探索将多视角 2D 特征转换为 3D 感知特征的可能性, 使目标查询能够在 3D 环境下直接更新。本文工作受隐式神经表示 (Implicit Neural Representation) [17,8,32] 相关进展的启发。在 MetaSR [17] 和 LIF [8] 中, 通过将高分辨率坐标信息编码到低分辨率特征中, 从低分辨率输入生成高分辨率 RGB 值。本文尝试通过编码

* 同等贡献 (Equal contribution)。




图 1: DETR、DETR3D 与本文提出的 PETR 对比。(a) DETR 中目标查询与 2D 特征交互进行 2D 检测。(b) DETR3D 反复将生成的 3D 参考点投影到图像平面并采样 2D 特征，在解码器中与目标查询交互。(c) PETR 通过将 3D 位置嵌入 (3D PE) 编码到 2D 图像特征中生成 3D 位置感知特征，目标查询直接与之交互，输出 3D 检测结果。

3D 位置嵌入 (3D Position Embedding) 将多视角图像的 2D 特征转换为 3D 表示 (见图 1(c))。

为实现这一目标，首先将不同视角共享的相机视锥体空间离散化为网格坐标 (Meshgrid Coordinates)，然后通过不同相机参数变换获得 3D 世界空间坐标。随后，骨干网络提取的 2D 图像特征与 3D 坐标一起输入到简单的 3D 位置编码器，生成 3D 位置感知特征 (3D Position-Aware Features)。3D 位置感知特征将在 Transformer 解码器中与目标查询交互，更新后的目标查询用于预测目标类别和 3D 边界框 (3D Bounding Boxes)。

与 DETR3D [51] 相比，本文提出的 PETR 架构具有诸多优势。它保持了原始 DETR [4] 的端到端特性，同时避免了复杂的 2D 到 3D 投影和特征采样。推理时，3D 位置坐标可以离线生成，作为额外的输入位置嵌入，更便于实际应用。

总之，本文的贡献如下：

- 提出了一种简洁优雅的多视角 3D 目标检测框架 PETR。通过编码 3D 坐标将多视角特征转换到 3D 域，目标查询可通过与 3D 位置感知特征交互进行更新并生成 3D 预测。
- 引入了一种新的用于多视角 3D 目标检测的 3D 位置感知表示。通过一个简单的隐式函数将 3D 位置信息编码到 2D 多视角特征中。
- 实验表明，PETR 在标准 nuScenes 数据集上达到了当前最优性能 (NDS 50.4%，mAP 44.1%)，在 3D 目标检测榜单上排名第一。

2 相关工作

2.1 基于 Transformer 的目标检测

Transformer [47] 是一种注意力模块，被广泛应用于建模长距离依赖关系。在 Transformer 中，特征通常与位置嵌入 (Position Embedding) 相加，以提供图像 [13, 53, 27]、序列 [15, 47, 11, 10, 54] 和视频 [1, 24, 52] 的位置信息。Transformer-XL [10] 使用相对位置嵌入编码成对标记之间的相对距离。ViT [13] 将可学习的位置嵌入添加到图像块表示中，编码不同图像块之间的距离。MViT [24] 分解了相对位置嵌入的距离计算，并对时空结构进行建模。

最近，DETR [4] 将 Transformer 引入 2D 目标检测任务，实现了端到端检测。在 DETR [4] 中，每个目标被表示为一个目标查询，通过 Transformer 解码器与

2D 图像特征交互。然而, DETR [4]存在收敛缓慢的问题。[44]将收敛缓慢归因于交叉注意力机制,并设计了仅编码器的 DETR。此外,许多工作通过添加位置先验来加速收敛。SMAC [14]为每个查询预测类似 2D 高斯分布的权重图作为空间先验。可变形 DETR (Deformable DETR) [58]将目标查询与 2D 参考点关联,并提出可变形交叉注意力以实现稀疏交互。[50,30,26]从锚点或锚框生成目标查询,利用位置先验实现快速收敛。SOLQ [12]扩展了 DETR [58],使用目标查询同时执行分类、边界框回归和实例分割。

2.2 基于视觉的 3D 目标检测

基于视觉的 3D 目标检测是从相机图像中检测 3D 边界框。许多先前的工作 [6,33,20,21,41,19,2,49,48]在图像视角下进行 3D 目标检测。M3D-RPN [2]引入了深度感知卷积 (Depth-Aware Convolution), 学习用于 3D 目标检测的位置感知特征。FCOS3D [49]将 3D 真值转换到图像视角,扩展 FCOS [46]以预测 3D 立方体参数。PGD [48]沿袭 FCOS3D [49],使用概率表示捕获深度的不确定性。这大大缓解了深度估计问题,但同时引入了更多计算开销和更大的推理延迟。DD3D [34]表明,在大规模深度数据集上进行深度预训练可以显著提升 3D 目标检测的性能。

最近,一些工作尝试在 3D 世界空间中进行 3D 目标检测。OFT [39]和 CaDDN [38]将单目图像特征映射到鸟瞰视图 (Bird's-Eye View, BEV),在 BEV 空间中检测 3D 目标。ImVoxelNet [40]在 3D 世界空间中构建 3D 体素,并采样多视角特征以获得体素表示,然后使用 3D 卷积和特定领域的检测头在室内和室外场景中检测目标。与 CaDDN [38]类似,BEVDet [18]采用 Lift-Splat-Shoot [37]将 2D 多视角特征转换为 BEV 表示,然后使用 CenterPoint [55]检测头进行 3D 目标检测。遵循 DETR [4],DETR3D [51]将 3D 目标表示为目标查询,从目标查询生成的 3D 参考点反复投影回所有相机视角并采样 2D 特征。

基于 BEV 的方法容易引入 Z 轴误差,导致在其他 3D 感知任务 (如 3D 车道线检测)上性能不佳。基于 DETR 的方法可以利用更多训练增强,从端到端建模中获得更多收益。本文方法基于 DETR,以简洁有效的方式进行 3D 目标检测。本文将 3D 位置信息编码到 2D 特征中,生成 3D 位置感知特征,目标查询可以直接与此类表示交互,无需投影误差。

2.3 隐式神经表示

隐式神经表示 (Implicit Neural Representation, INR) 通常通过多层感知机 (Multi-Layer Perceptron, MLP) 将坐标映射到视觉信号。这是建模 3D 目标 [35,9,31]、3D 场景 [32,43,5,36] 和 2D 图像 [17,8,45,42] 的高效方式。NeRF [32] 使用全连接网络表示特定场景。为合成新视角,沿相机光线的 5D 坐标作为查询输入网络,输出体密度和视角相关的发射辐射。在 MetaSR [17] 和 LIFF [8] 中,高分辨率坐标被编码到低分辨率特征中,可生成任意大小的高分辨率图像。本文方法可视为 INR 在 3D 目标检测中的扩展。2D 图像与 3D 坐标编码后获得 3D 位置感知特征,3D 空间中的锚点通过 MLP 转换为目标查询,进一步与 3D 位置感知特征交互以预测对应的 3D 目标。




图 2: 本文提出的 PETR 架构概览。多视角图像输入骨干网络（如 ResNet）提取多视角 2D 图像特征。在 3D 坐标生成器中，所有视角共享的相机视锥体空间离散化为 3D 网格，网格坐标通过不同相机参数变换得到 3D 世界空间坐标。2D 图像特征和 3D 坐标输入到提出的 3D 位置编码器中生成 3D 位置感知特征。查询生成器生成的目标查询通过 Transformer 解码器与 3D 位置感知特征交互更新，更新后的查询用于预测 3D 边界框和目标类别。

3 方法

3.1 整体架构

图 2 展示了本文提出的 PETR 的整体架构。给定来自 N 个视角的图像 $I = \{I_i \in R^{3 \times H_I \times W_I}, i = 1, 2, \dots, N\}$ ，图像输入骨干网络（如 ResNet-50 [16]）提取 2D 多视角特征 $F^{2d} = \{F_i^{2d} \in R^{C \times H_F \times W_F}, i = 1, 2, \dots, N\}$ 。在 3D 坐标生成器中，首先将相机视锥体空间离散化为 3D 网格，然后网格坐标通过相机参数变换生成 3D 世界空间坐标。3D 坐标与 2D 多视角特征一起输入到 3D 位置编码器，生成 3D 位置感知特征 $F^{3d} = \{F_i^{3d} \in R^{C \times H_F \times W_F}, i = 1, 2, \dots, N\}$ 。3D 特征进一步输入到 Transformer 解码器，与查询生成器生成的目标查询交互，更新后的目标查询用于预测目标类别和 3D 边界框。

3.2 3D 坐标生成器

为建立 2D 图像与 3D 空间之间的关联，将相机视锥体空间中的点投影到 3D 空间，因为这两个空间的点是一一对应的。与 DGSN [7] 类似，首先将相机视锥体空间离散化，生成大小为 (W_F, H_F, D) 的网格。网格中每个点可表示为 $p_j^m = (u_j \times d_j, v_j \times d_j, d_j, 1)^T$ ，其中 (u_j, v_j) 是图像中的像素坐标， d_j 是沿垂直于图像平面方向的深度值。由于网格在不同视角间共享，3D 世界空间中对应的 3D 坐标 $p_{i,j}^{3d} = (x_{i,j}, y_{i,j}, z_{i,j}, 1)^T$ 可通过反向 3D 投影计算：

$$p_{i,j}^{3d} = K_i^{-1} p_j^m \quad (1)$$

其中 $K_i \in R^{4 \times 4}$ 是第 i 个视角的变换矩阵，建立了从 3D 世界空间到相机视锥体空间的变换。如图 2 所示，变换后所有视角的 3D 坐标覆盖了场景的全景。进




图 3: 提出的 3D 位置编码器示意图。多视角 2D 图像特征输入 1×1 卷积层进行降维。3D 坐标生成器产生的 3D 坐标通过多层感知机转换为 3D 位置嵌入。3D 位置嵌入与同一视角的 2D 图像特征相加, 生成 3D 位置感知特征。最后展平 3D 位置感知特征作为 Transformer 解码器的输入。ⓕ 为展平操作。

一步按公式 2 对 3D 坐标进行归一化。

$$\begin{cases} x_{i,j} = (x_{i,j} - x_{min}) / (x_{max} - x_{min}) \\ y_{i,j} = (y_{i,j} - y_{min}) / (y_{max} - y_{min}) \\ z_{i,j} = (z_{i,j} - z_{min}) / (z_{max} - z_{min}) \end{cases} \quad (2)$$

其中 $[x_{min}, y_{min}, z_{min}, x_{max}, y_{max}, z_{max}]$ 是 3D 世界空间的感兴趣区域 (Region of Interest, RoI)。共 $H_F \times W_F \times D$ 个点的归一化坐标最终转置为 $P^{3d} = \{P_i^{3d} \in R^{(D \times 4) \times H_F \times W_F}, i = 1, 2, \dots, N\}$ 。

3.3 3D 位置编码器

3D 位置编码器的目的是将 2D 图像特征 $F^{2d} = \{F_i^{2d} \in R^{C \times H_F \times W_F}, i = 1, 2, \dots, N\}$ 与 3D 位置信息关联, 得到 3D 特征 $F^{3d} = \{F_i^{3d} \in R^{C \times H_F \times W_F}, i = 1, 2, \dots, N\}$ 。与 Meta SR [17] 类似, 3D 位置编码器可表示为:

$$F_i^{3d} = \psi(F_i^{2d}, P_i^{3d}), \quad i = 1, 2, \dots, N \quad (3)$$

其中 $\psi(\cdot)$ 是位置编码函数, 如图 3 所示。接下来描述 $\psi(\cdot)$ 的具体实现。给定 2D 特征 F^{2d} 和 3D 坐标 P^{3d} , P^{3d} 首先输入多层感知机 (MLP) 网络, 转换为 3D 位置嵌入 (Position Embedding, PE)。然后 F^{2d} 经过 1×1 卷积层变换后与 3D PE 相加, 形成 3D 位置感知特征。最后展平 3D 位置感知特征作为 Transformer 解码器的关键输入。

3D PE 分析: 为展示 3D PE 的效果, 在前视图中随机选择三个点的 PE, 并计算这些点与所有多视角 PE 之间的相似度。如图 4 所示, 靠近这些点的区域往往具有更高的相似度。例如, 选择前视图中的左侧点时, 前左视图的右侧区域响应相对更高。这表明 3D PE 隐式建立了不同视角在 3D 空间中的位置关联。

3.4 查询生成器与解码器

查询生成器: 原始 DETR [4] 直接使用一组可学习参数作为初始目标查询。DETR3D [51] 遵循可变形 DETR (Deformable-DETR) [58], 基于初始化的目




图 4: 3D 位置嵌入相似度。红色点为前视图中选择的点位。计算了这些选择位置的 PE 与所有图像视角 PE 之间的相似度，表明靠近这些选择点的区域具有更高的相似度。

标查询预测参考点。为缓解 3D 场景下的收敛困难，与 Anchor-DETR [50] 类似，首先在 3D 世界空间中初始化一组可学习的锚点，均匀分布在 0 到 1 之间。然后将 3D 锚点坐标输入到具有两个线性层的小型 MLP 网络，生成初始目标查询 Q_0 。在实践发现，采用 3D 空间中的锚点可以保证 PETR 的收敛，而采用 DETR 的设置或在 BEV 空间中生成锚点均无法达到满意的检测性能。更多细节参见实验部分。

解码器：解码器网络采用 DETR [4] 中的标准 Transformer 解码器，包含 L 个解码层。解码层中的交互过程可表示为：

$$Q_l = \Omega_l(F^{3d}, Q_{l-1}), \quad l = 1, \dots, L \quad (4)$$

其中 Ω_l 是解码器的第 l 层。 $Q_l \in R^{M \times C}$ 是第 l 层更新后的目标查询。 M 和 C 分别是查询数量和通道数。在每个解码层中，目标查询通过多头注意力和前馈网络与 3D 位置感知特征交互。经过迭代交互后，更新后的目标查询具有高层表示，可用于预测对应的目标。

3.5 检测头与损失函数

检测头主要包括用于分类和回归的两个分支。从解码器输出的更新后目标查询输入到检测头，预测目标类别的概率和 3D 边界框。回归分支预测相对于锚点坐标的偏移量。为与 DETR3D 进行公平比较，采用 Focal Loss [25] 进行分类， $L1$ 损失用于 3D 边界框回归。设 $y = (c, b)$ 和 $\hat{y} = (\hat{c}, \hat{b})$ 分别表示真值集合和预测集合。匈牙利算法 [22] 用于真值与预测之间的标签分配。设 σ 为最优分配函数，则 3D 目标检测的损失可表示为：

$$L(y, \hat{y}) = \lambda_{cls} * L_{cls}(c, \sigma(\hat{c})) + L_{reg}(b, \sigma(\hat{b})) \quad (5)$$

其中 L_{cls} 表示用于分类的 Focal Loss， L_{reg} 是用于回归的 $L1$ 损失。 λ_{cls} 是平衡不同损失的超参数。

4 实验

4.1 数据集与评价指标

在 nuScenes 基准测试 [3] 上验证本文方法。NuScenes 是一个大规模多模态数据集，包含从 6 个相机、1 个激光雷达和 5 个雷达收集的数据。该数据集包含 1000

表 1: 在 nuScenes 验证集上的最新方法对比。FCOS3D 和 PGD 的结果经过微调并使用测试时增强。DETR3D、BEVDet 和 PETR 均采用 CBGS [57]训练。† 表示从 FCOS3D 骨干网络初始化。

方法	骨干网络	尺寸	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
CenterNet	DLA	-	0.328	0.306	0.716	0.264	0.609	1.426	0.658
FCOS3D	Res-101	1600×900	0.415	0.343	0.725	0.263	0.422	1.292	0.153
PGD	Res-101	1600×900	0.428	0.369	0.683	0.260	0.439	1.268	0.185
BEVDet	Res-50	1056×384	0.381	0.304	0.719	0.272	0.555	0.903	0.257
BEVDet	Res-101	1056×384	0.389	0.317	0.704	0.273	0.531	0.940	0.250
BEVDet	Swin-T	1408×512	0.417	0.349	0.637	0.269	0.490	0.914	0.268
PETR	Res-50	1056×384	0.381	0.313	0.768	0.278	0.564	0.923	0.225
PETR	Res-50	1408×512	0.403	0.339	0.748	0.273	0.539	0.907	0.203
PETR	Res-101	1056×384	0.399	0.333	0.735	0.275	0.559	0.899	0.205
PETR	Res-101	1408×512	0.421	0.357	0.710	0.270	0.490	0.885	0.224
PETR	Swin-T	1408×512	0.431	0.361	0.732	0.273	0.497	0.808	0.185
DETR3D†	Res-101	1600×900	0.434	0.349	0.716	0.268	0.379	0.842	0.200
PETR†	Res-101	1056×384	0.423	0.347	0.736	0.269	0.448	0.844	0.202
PETR†	Res-101	1408×512	0.441	0.366	0.717	0.267	0.412	0.834	0.190
PETR†	Res-101	1600×900	0.442	0.370	0.711	0.267	0.383	0.865	0.201

个场景，官方划分为 700/150/150 个场景分别用于训练/验证/测试。每个场景包含 20 秒的视频帧，每 0.5 秒进行一次完整的 3D 边界框标注。与官方评价指标一致，报告 nuScenes 检测分数 (NDS) 和平均精度 (mAP)，以及平均平移误差 (mATE)、平均尺度误差 (mASE)、平均朝向误差 (mAOE)、平均速度误差 (mAVE) 和平均属性误差 (mAAE)。

4.2 实现细节

使用 ResNet [16]、Swin-Transformer [27] 或 VoVNetV2 [23] 作为骨干网络提取 2D 特征。C5 特征 (第 5 阶段输出) 上采样后与 C4 特征 (第 4 阶段输出) 融合生成 P4 特征。使用 1/16 输入分辨率的 P4 特征作为 2D 特征。对于 3D 坐标生成，沿深度轴采样 64 个点，采用 CaDDN [38] 中的线性递增离散化 (Linear-Increasing Discretization, LID) 方法。设 X 和 Y 轴范围为 $[-61.2m, 61.2m]$ ， Z 轴范围为 $[-10m, 10m]$ 。3D 世界空间中的 3D 坐标归一化到 $[0, 1]$ 。参考 DETR3D [51]，设 $\lambda_{cls} = 2.0$ 以平衡分类和回归。

PETR 使用 AdamW [29] 优化器训练，权重衰减为 0.01。学习率初始化为 2.0×10^{-4} ，采用余弦退火策略 [28] 衰减。采用多尺度训练策略，短边在 $[640, 900]$ 范围内随机选择，长边不超过 1600。参考 CenterPoint [55]，实例的真值在 3D 空间中随机旋转 $[-22.5^\circ, 22.5^\circ]$ 。所有实验在 8 块 Tesla V100 GPU 上训练 24 个周期 (2x schedule)，批次大小为 8。推理时不使用测试时增强方法。




图 5: PETR 的收敛性和速度分析。(a) PETR 与 DETR3D [51]的收敛对比。PETR 在初始阶段收敛较慢, 需要更长的训练周期才能完全收敛。(b) 不同骨干网络和输入尺寸下的性能与速度分析。

表 2: 在 nuScenes 测试集上的最新方法对比。* 表示使用外部数据训练。‡ 表示测试时增强。

方法	骨干网络	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
FCOS3D‡	Res-101	0.428	0.358	0.690	0.249	0.452	1.434	0.124
PGD‡	Res-101	0.448	0.386	0.626	0.245	0.451	1.509	0.127
DD3D*‡	V2-99	0.477	0.418	0.572	0.249	0.368	1.014	0.124
DETR3D*	V2-99	0.479	0.412	0.641	0.255	0.394	0.845	0.133
BEVDet	Swin-S	0.463	0.398	0.556	0.239	0.414	1.010	0.153
BEVDet*	V2-99	0.488	0.424	0.524	0.242	0.373	0.950	0.148
PETR	Res-101	0.455	0.391	0.647	0.251	0.433	0.933	0.143
PETR	Swin-T	0.450	0.411	0.664	0.256	0.522	0.971	0.137
PETR	Swin-S	0.481	0.434	0.641	0.248	0.437	0.894	0.143
PETR	Swin-B	0.483	0.445	0.627	0.249	0.449	0.927	0.141
PETR*	V2-99	0.504	0.441	0.593	0.249	0.383	0.808	0.132

4.3 与当前最优方法的对比

如表 1 所示, 首先在 nuScenes 验证集上与当前最优方法进行比较。PETR 在 NDS 和 mAP 指标上均达到了最佳性能。CenterNet [56]、FCOS3D [49] 和 PGD [48] 是典型的单目 3D 目标检测方法。与 FCOS3D [49] 和 PGD [48] 相比, 使用 ResNet-101 [16] 的 PETR 在 NDS 上分别超越了 2.7% 和 1.4%。但 PGD [48] 由于显式的深度监督, mATE 相对更低。此外, 还将 PETR 与多视角 3D 目标检测方法 DETR3D [51] 和 BEVDet [18] 进行比较, 这两种方法在统一视角下检测 3D 目标。由于 DETR3D [51] 和 BEVDet [18] 在图像尺寸和主干初始化方面采用不同设置, 分别与 PETR 进行公平比较。本文方法在 NDS 上分别超越它们 0.8% 和 1.4%。

表 2 展示了在 nuScenes 测试集上的性能对比。本文方法在 NDS 和 mAP 上均达到最佳性能。为与 BEVDet [18] 公平比较, 使用 Swin-S 骨干网络的 PETR 也采用 2112×768 的图像尺寸进行训练。结果表明, PETR 在 mAP 和 NDS 上

表 3: 3D 位置嵌入的影响。2D PE 是 DETR 中使用的标准位置嵌入。MV 是多视角位置嵌入，用于区分不同视角。3D PE 是本文提出的 3D 位置嵌入。

PE	2D	MV	3D	NDS↑	mAP↑	mATE↓	mASE↓	mAOE↓	mAVE↓	mAAE↓
1	✓			0.208	0.069	1.165	0.290	0.773	0.936	0.259
2	✓	✓		0.224	0.089	1.165	0.287	0.738	0.929	0.251
3			✓	0.356	0.305	0.835	0.238	0.639	0.971	0.237
4	✓		✓	0.351	0.305	0.838	0.283	0.633	1.048	0.256
5	✓	✓	✓	0.359	0.309	0.844	0.278	0.653	0.945	0.241

表 4: 不同相机视锥体离散化方法和不同感兴趣区域 (ROI) 范围对 3D 坐标归一化的影响分析。UD 表示均匀离散化，LID 表示线性递增离散化。

深度范围	$(x_{min}, y_{min}, z_{min}, x_{max}, y_{max}, z_{max})$	UD	LID	NDS↑	mAP↑	mATE↓
(1,51.2)	(-51.2, -51.2, -10.0, 51.2, 51.2, 10.0)	✓		0.352	0.303	0.862
(1,51.2)	(-51.2, -51.2, -5, 51.2, 51.2, 3)	✓		0.352	0.305	0.854
(1,61.2)	(-61.2, -61.2, -10.0, 61.2, 61.2, 10.0)	✓		0.358	0.308	0.850
(1,61.2)	(-61.2, -61.2, -5, 61.2, 61.2, 3)	✓		0.342	0.297	0.860
(1,51.2)	(-51.2, -51.2, -10.0, 51.2, 51.2, 10.0)		✓	0.350	0.310	0.843
(1,51.2)	(-51.2, -51.2, -5, 51.2, 51.2, 3)		✓	0.355	0.306	0.838
(1,61.2)	(-61.2, -61.2, -10.0, 61.2, 61.2, 10.0)		✓	0.359	0.309	0.839
(1,61.2)	(-61.2, -61.2, -5, 61.2, 61.2, 3)		✓	0.346	0.304	0.842

分别超越 BEVDet [18] 3.6% 和 1.8%。值得注意的是，使用 Swin-B 的 PETR 与使用外部数据的现有方法性能相当。当使用外部数据时，采用 VOVNetV2 [23] 骨干网络的 PETR 达到了 50.4% 的 NDS 和 44.1% 的 mAP。据我们所知，PETR 是首个超越 50.0% NDS 的基于视觉的方法。

还对 PETR 的收敛速度和检测速度进行了分析。首先比较了 DETR3D [51] 和 PETR 的收敛情况 (见图 5(a))。在前 12 个周期内，PETR 收敛相对较慢，最终达到了更好的检测性能，表明 PETR 需要更长的训练周期才能完全收敛。推测原因是 PETR 通过全局注意力学习 3D 关联，而 DETR3D [51] 在局部区域内感知 3D 场景。图 5(b) 进一步展示了不同输入尺寸下 PETR 的检测性能和速度。FPS 在单块 Tesla V100 GPU 上测量。在相同图像尺寸下 (如 1056×384)，PETR 的推理速度为 10.7 FPS，而 BEVDet [18] 为 4.2 FPS。需要注意的是，BEVDet [18] 的速度在 NVIDIA 3090 GPU 上测量，该 GPU 性能强于 Tesla V100。

4.4 消融实验

本节对 PETR 的一些重要组件进行消融实验。所有实验均使用 ResNet-50 骨干网络的单层 C5 特征，不使用 CBGS [57]。

3D 位置嵌入的影响。评估了不同位置嵌入 (PE) 的影响 (见表 3)。仅使用 DETR 中的标准 2D PE 时，模型只能收敛到 6.9% mAP。增加多视角先验 (将视角编号转换为 PE) 来区分不同视角，带来了轻微改进。仅使用由 3D 坐标生

表 5: PETR 各组件的消融实验。

PE 网络	NDS↑	mAP↑	mATE↓	融合方式	NDS↑	mAP↑	mATE↓
None	0.311	0.256	1.00	Add	0.359	0.309	0.839
1×1 ReLU 1×1	0.359	0.309	0.839	Concat	0.358	0.309	0.832
3×3 ReLU 3×3	0.017	0.000	1.054	Multiply	0.357	0.303	0.848

(a) 生成 3D PE 的网络结构。“None” 表示直接将归一化 3D 坐标用作 3D PE。 (b) 3D 位置编码器中 2D 多视角特征与 3D PE 的不同融合方式。

锚点	NDS↑	mAP↑	mATE↓	锚点数量	NDS↑	mAP↑	mATE↓
None	-	-	-	600	0.339	0.300	0.847
Fix-BEV	0.337	0.295	0.852	900	0.351	0.303	0.860
Fix-3D	0.343	0.303	0.864	1200	0.354	0.303	0.854
Learned-3D	0.359	0.309	0.839	1500	0.359	0.309	0.839

(c) 不同类型锚点的对比。“None” 表示遵循 DETR 不使用锚点, “Fix-BEV” 和 “Fix-3D” 分别表示在 BEV 空间和 3D 空间中生成网格锚点。 (d) 不同锚点数量的结果。探索了从 600 到 1500 的锚点数量, 更多锚点性能更好。

成的 3D PE 时, PETR 可直接达到 30.5% mAP, 表明 3D PE 提供了感知 3D 场景的强位置先验。将 3D PE 与 2D PE 和多视角先验结合可进一步提升性能。需要注意的是, 主要改进来自 3D PE, 2D PE 和多视角先验可在实践中选择性使用。

3D 坐标生成器。在 3D 坐标生成器中, 相机视锥体空间中的透视视图被离散化为 3D 网格。变换后的 3D 世界空间坐标进一步通过感兴趣区域 (RoI) 进行归一化。探索了不同离散化方法和 RoI 范围的效果 (见表 4)。均匀离散化 (UD) 与线性递增离散化 (LID) 性能相似。还尝试了几种常见的 ROI 区域, 其中 $(-61.2m, -61.2m, -10.0m, 61.2m, 61.2m, 10.0m)$ 的 RoI 范围性能最佳。

3D 位置编码器。3D 位置编码器用于将 3D 位置编码到 2D 特征中。首先探索将 3D 坐标转换为 3D 位置嵌入的 MLP 网络的效果。从表 5(a) 可以看出, 与不使用 MLP 的基线 (将 2D 特征通道数对齐到 $D \times 4$) 相比, 使用简单 MLP 的网络在 NDS 和 mAP 上分别提升了 4.8% 和 5.3%。当使用两个 3×3 卷积层时, 模型无法收敛, 因为 3×3 卷积破坏了 2D 特征与 3D 位置之间的对应关系。此外, 在表 5(b) 中比较了 2D 图像特征与 3D PE 的不同融合方式。拼接操作与相加操作性能相近, 且均优于相乘融合。

查询生成器。表 5(c) 展示了不同锚点生成查询的效果。比较了四种锚点类型: “None”、“Fix-BEV”、“Fix-3D” 和 “Learned-3D”。原始 DETR (“None”) 直接使用一组可学习参数作为目标查询, 不使用锚点。目标查询的全局特征无法使模型收敛。“Fix-BEV” 是 BEV 空间中 39×39 个固定锚点。“Fix-3D” 是 3D 世界空间中 $16 \times 16 \times 6$ 个固定锚点。“Learned-3D” 是 3D 空间中的可学习锚点。发现 “Fix-BEV” 和 “Fix-3D” 的性能均低于可学习锚点。还探索了锚点数量 (见




图 6: BEV 和图像视角下检测结果的定性分析。得分阈值为 0.25, 骨干网络为 ResNet-101。3D 边界框以不同颜色绘制以区分不同类别。




图 7: 注意力图的可视化。从对应卡车的目标查询生成的多视角注意力图, 前左视图和后左视图在注意力图上均有高响应。

表 5(d)), 范围从 600 到 1500。模型在 1500 个锚点时达到最佳性能。考虑到计算成本随锚点数量增加, 选用 1500 个锚点作为折中。

4.5 可视化

图 6 展示了一些定性检测结果。3D 边界框被投影并绘制在 BEV 空间和图像视角中。在 BEV 空间中, 预测的边界框与真值接近, 表明本文方法具有良好的检测性能。还可可视化了从目标查询生成的多视角注意力图。如图 7 所示, 即使在不同视角下, 目标查询也会关注同一目标, 表明 3D 位置嵌入可以建立不同视角间的位置关联。最后给出一些失败案例 (见图 8)。红色圆圈标记了未被检测到的小目标, 绿色圆圈标记了分类错误的目标, 错误检测主要发生在不同车辆外观高度相似时。




图8: PETR 的失败案例。红色圆圈标记了一些未被检测到的小目标, 绿色圆圈标记了分类错误的目标。

5 结论

本文为多视角 3D 目标检测提供了一种简洁优雅的解决方案。通过 3D 坐标生成和位置编码, 2D 特征可转换为 3D 位置感知特征表示。这种 3D 表示可直接融入基于查询的 DETR 架构, 实现端到端检测。该方法达到了当前最优性能, 可作为未来研究的强基线。

致谢: 本研究受国家重点研发计划 (No. 2017YFA0700800) 和北京智源人工智能研究院 (BAAI) 资助。

参考文献

1. Bertasius, G., Wang, H., Torresani, L.: Is space-time attention all you need for video understanding. arXiv preprint arXiv:2102.05095 **2**(3), 4 (2021) **2**
2. Brazil, G., Liu, X.: M3d-rpn: Monocular 3d region proposal network for object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 9287–9296 (2019) **3**
3. Caesar, H., Bankiti, V., Lang, A.H., Vora, S., Liong, V.E., Xu, Q., Krishnan, A., Pan, Y., Baldan, G., Beijbom, O.: nuscenes: A multimodal dataset for autonomous driving. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 11621–11631 (2020) **6**
4. Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S.: End-to-end object detection with transformers. In: European conference on computer vision. pp. 213–229. Springer (2020) **1, 2, 3, 5, 6**
5. Chabra, R., Lenssen, J.E., Ilg, E., Schmidt, T., Straub, J., Lovegrove, S., Newcombe, R.: Deep local shapes: Learning local sdf priors for detailed 3d reconstruction. In: European Conference on Computer Vision. pp. 608–625. Springer (2020) **3**

6. Chen, X., Kundu, K., Zhang, Z., Ma, H., Fidler, S., Urtasun, R.: Monocular 3d object detection for autonomous driving. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 2147–2156 (2016) [1](#), [3](#)
7. Chen, Y., Liu, S., Shen, X., Jia, J.: Dsgn: Deep stereo geometry network for 3d object detection. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 12536–12545 (2020) [4](#)
8. Chen, Y., Liu, S., Wang, X.: Learning continuous image representation with local implicit image function. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 8628–8638 (2021) [1](#), [3](#)
9. Chen, Z., Zhang, H.: Learning implicit fields for generative shape modeling. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 5939–5948 (2019) [3](#)
10. Dai, Z., Yang, Z., Yang, Y., Carbonell, J., Le, Q.V., Salakhutdinov, R.: Transformer-xl: Attentive language models beyond a fixed-length context. arXiv preprint arXiv:1901.02860 (2019) [2](#)
11. Devlin, J., Chang, M.W., Lee, K., Toutanova, K.: Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805 (2018) [2](#)
12. Dong, B., Zeng, F., Wang, T., Zhang, X., Wei, Y.: Solq: Segmenting objects by learning queries. Advances in Neural Information Processing Systems **34** (2021) [3](#)
13. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al.: An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929 (2020) [2](#)
14. Gao, P., Zheng, M., Wang, X., Dai, J., Li, H.: Fast convergence of detr with spatially modulated co-attention. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 3621–3630 (2021) [3](#)
15. Gehring, J., Auli, M., Grangier, D., Yarats, D., Dauphin, Y.N.: Convolutional sequence to sequence learning. In: International Conference on Machine Learning. pp. 1243–1252. PMLR (2017) [2](#)
16. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 770–778 (2016) [4](#), [7](#), [8](#)
17. Hu, X., Mu, H., Zhang, X., Wang, Z., Tan, T., Sun, J.: Meta-sr: A magnification-arbitrary network for super-resolution. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 1575–1584 (2019) [1](#), [3](#), [5](#)
18. Huang, J., Huang, G., Zhu, Z., Du, D.: Bevdet: High-performance multi-camera 3d object detection in bird-eye-view. arXiv preprint arXiv:2112.11790 (2021) [3](#), [8](#), [9](#)
19. Jørgensen, E., Zach, C., Kahl, F.: Monocular 3d object detection and box fitting trained end-to-end using intersection-over-union loss. arXiv preprint arXiv:1906.08070 (2019) [3](#)
20. Kehl, W., Manhardt, F., Tombari, F., Ilic, S., Navab, N.: Ssd-6d: Making rgb-based 3d detection and 6d pose estimation great again. In: Proceedings of the IEEE international conference on computer vision. pp. 1521–1529 (2017) [3](#)
21. Ku, J., Pon, A.D., Waslander, S.L.: Monocular 3d object detection leveraging accurate proposals and shape reconstruction. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 11867–11876 (2019) [3](#)
22. Kuhn, H.W.: The hungarian method for the assignment problem. Naval research logistics quarterly **2**(1-2), 83–97 (1955) [6](#)

23. Lee, Y., Park, J.: Centermask: Real-time anchor-free instance segmentation. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 13906–13915 (2020) [7](#), [9](#)
24. Li, Y., Wu, C.Y., Fan, H., Mangalam, K., Xiong, B., Malik, J., Feichtenhofer, C.: Improved multiscale vision transformers for classification and detection. arXiv preprint arXiv:2112.01526 (2021) [2](#)
25. Lin, T.Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal loss for dense object detection. In: Proceedings of the IEEE international conference on computer vision. pp. 2980–2988 (2017) [6](#)
26. Liu, S., Li, F., Zhang, H., Yang, X., Qi, X., Su, H., Zhu, J., Zhang, L.: Dab-detr: Dynamic anchor boxes are better queries for detr. arXiv preprint arXiv:2201.12329 (2022) [3](#)
27. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B.: Swin transformer: Hierarchical vision transformer using shifted windows. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 10012–10022 (2021) [2](#), [7](#)
28. Loshchilov, I., Hutter, F.: Sgdr: Stochastic gradient descent with warm restarts. arXiv preprint arXiv:1608.03983 (2016) [7](#)
29. Loshchilov, I., Hutter, F.: Decoupled weight decay regularization. arXiv preprint arXiv:1711.05101 (2017) [7](#)
30. Meng, D., Chen, X., Fan, Z., Zeng, G., Li, H., Yuan, Y., Sun, L., Wang, J.: Conditional detr for fast training convergence. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 3651–3660 (2021) [3](#)
31. Mescheder, L., Oechsle, M., Niemeyer, M., Nowozin, S., Geiger, A.: Occupancy networks: Learning 3d reconstruction in function space. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 4460–4470 (2019) [3](#)
32. Mildenhall, B., Srinivasan, P.P., Tancik, M., Barron, J.T., Ramamoorthi, R., Ng, R.: Nerf: Representing scenes as neural radiance fields for view synthesis. In: European conference on computer vision. pp. 405–421. Springer (2020) [1](#), [3](#)
33. Mousavian, A., Anguelov, D., Flynn, J., Kosecka, J.: 3d bounding box estimation using deep learning and geometry. In: Proceedings of the IEEE conference on Computer Vision and Pattern Recognition. pp. 7074–7082 (2017) [1](#), [3](#)
34. Park, D., Ambrus, R., Guizilini, V., Li, J., Gaidon, A.: Is pseudo-lidar needed for monocular 3d object detection? In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 3142–3152 (2021) [1](#), [3](#)
35. Park, J.J., Florence, P., Straub, J., Newcombe, R., Lovegrove, S.: Deepsdf: Learning continuous signed distance functions for shape representation. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 165–174 (2019) [3](#)
36. Peng, S., Niemeyer, M., Mescheder, L., Pollefeys, M., Geiger, A.: Convolutional occupancy networks. In: European Conference on Computer Vision. pp. 523–540. Springer (2020) [3](#)
37. Pillion, J., Fidler, S.: Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d. In: European Conference on Computer Vision. pp. 194–210. Springer (2020) [3](#)
38. Reading, C., Harakeh, A., Chae, J., Waslander, S.L.: Categorical depth distribution network for monocular 3d object detection. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 8555–8564 (2021) [3](#), [7](#)

39. Roddick, T., Kendall, A., Cipolla, R.: Orthographic feature transform for monocular 3d object detection. arXiv preprint arXiv:1811.08188 (2018) [3](#)
40. Rukhovich, D., Vorontsova, A., Konushin, A.: Imvoxelnet: Image to voxels projection for monocular and multi-view general-purpose 3d object detection. In: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. pp. 2397–2406 (2022) [3](#)
41. Simonelli, A., Bulo, S.R., Porzi, L., López-Antequera, M., Kotschieder, P.: Disentangling monocular 3d object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 1991–1999 (2019) [3](#)
42. Sitzmann, V., Martel, J., Bergman, A., Lindell, D., Wetzstein, G.: Implicit neural representations with periodic activation functions. *Advances in Neural Information Processing Systems* **33**, 7462–7473 (2020) [3](#)
43. Sitzmann, V., Zollhöfer, M., Wetzstein, G.: Scene representation networks: Continuous 3d-structure-aware neural scene representations. *Advances in Neural Information Processing Systems* **32** (2019) [3](#)
44. Sun, Z., Cao, S., Yang, Y., Kitani, K.M.: Rethinking transformer-based set prediction for object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 3611–3620 (2021) [3](#)
45. Tancik, M., Srinivasan, P., Mildenhall, B., Fridovich-Keil, S., Raghavan, N., Singhal, U., Ramamoorthi, R., Barron, J., Ng, R.: Fourier features let networks learn high frequency functions in low dimensional domains. *Advances in Neural Information Processing Systems* **33**, 7537–7547 (2020) [3](#)
46. Tian, Z., Shen, C., Chen, H., He, T.: Fcos: Fully convolutional one-stage object detection. In: Proceedings of the IEEE/CVF international conference on computer vision. pp. 9627–9636 (2019) [3](#)
47. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. *Advances in neural information processing systems* **30** (2017) [2](#)
48. Wang, T., Xinge, Z., Pang, J., Lin, D.: Probabilistic and geometric depth: Detecting objects in perspective. In: Conference on Robot Learning. pp. 1475–1485. PMLR (2022) [1](#), [3](#), [8](#)
49. Wang, T., Zhu, X., Pang, J., Lin, D.: Fcos3d: Fully convolutional one-stage monocular 3d object detection. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 913–922 (2021) [1](#), [3](#), [8](#)
50. Wang, Y., Zhang, X., Yang, T., Sun, J.: Anchor detr: Query design for transformer-based detector. arXiv preprint arXiv:2109.07107 (2021) [3](#), [6](#)
51. Wang, Y., Vitor Campagnolo, G., Zhang, T., Zhao, H., Solomon, J.: Detr3d: 3d object detection from multi-view images via 3d-to-2d queries. In: In Conference on Robot Learning. pp. 180–191 (2022) [1](#), [2](#), [3](#), [5](#), [7](#), [8](#), [9](#)
52. Wu, C.Y., Li, Y., Mangalam, K., Fan, H., Xiong, B., Malik, J., Feichtenhofer, C.: Memvit: Memory-augmented multiscale vision transformer for efficient long-term video recognition. arXiv preprint arXiv:2201.08383 (2022) [2](#)
53. Wu, K., Peng, H., Chen, M., Fu, J., Chao, H.: Rethinking and improving relative position encoding for vision transformer. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 10033–10041 (2021) [2](#)
54. Yang, Z., Dai, Z., Yang, Y., Carbonell, J., Salakhutdinov, R.R., Le, Q.V.: Xlnet: Generalized autoregressive pretraining for language understanding. *Advances in neural information processing systems* **32** (2019) [2](#)
55. Yin, T., Zhou, X., Krahenbuhl, P.: Center-based 3d object detection and tracking. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 11784–11793 (2021) [3](#), [7](#)

56. Zhou, X., Wang, D., Krähenbühl, P.: Objects as points. arXiv preprint arXiv:1904.07850 (2019) [8](#)
57. Zhu, B., Jiang, Z., Zhou, X., Li, Z., Yu, G.: Class-balanced grouping and sampling for point cloud 3d object detection. arXiv preprint arXiv:1908.09492 (2019) [7](#), [9](#)
58. Zhu, X., Su, W., Lu, L., Li, B., Wang, X., Dai, J.: Deformable detr: Deformable transformers for end-to-end object detection. arXiv preprint arXiv:2010.04159 (2020) [3](#), [5](#)