

SparseWorld: 通过稀疏场景表示的世界模型增强端到端自动驾驶

Ruoyu Wang^{1,*}, Jingke Wang^{1,*}, Yukai Ma^{1,†}, Yuehao Huang¹, Shuangming Lei¹,
Guanglin Xu², Aixue Ye², Yong Liu^{1,‡}

摘要—近来,世界模型(World Model)通过未来预测与场景理解能力的提升,显著推动了端到端自动驾驶(End-to-end Autonomous Driving)系统的发展。然而,现有驾驶世界模型通常基于稠密场景表示(Dense Scene Representation)构建,计算成本高且信息冗余。本文提出 SparseWorld——一种轻量级(Light-weight)世界模型,仅聚焦于预测场景的关键布局(Critical Layout),为端到端驾驶系统实现高效的未来预测(Future Forecasting)。SparseWorld 首先通过自回归(Autoregressive)推演(Rollout)预测未来的地图要素(Map Elements)与周围智能体(Surrounding Agents),使模型学习驾驶场景随时间的演变规律;随后利用预测的未来状态优化下游的运动预测(Motion Prediction)与轨迹规划(Trajectory Planning)。具体而言,本文提出 Sparse Dreamer,通过联合时间注意力(Temporal Attention)与空间注意力(Spatial Attention)在隐空间(Latent Space)中预测未来实例(Instance)。通过与预测的未来实例交互,运动规划器捕获更精确的运动模式,生成信息更充分、安全感知(Safety-aware)的轨迹。大量实验表明, SparseWorld 显著降低了碰撞风险(Collision Risk),在 nuScenes 数据集的开环规划(Open-loop Planning)指标上以 0.05% 的碰撞率(Collision Rate)达到 SOTA (最先进)水平。此外,在 Bench2Drive 基准测试(Benchmark)的闭环规划(Closed-loop Planning)指标上, SparseWorld 大幅超越基线(Baseline)方法。补充材料见项目主页: <https://wryzju.github.io/SparseWorld/>。

I. 引言

利用世界模型对驾驶场景的演变进行建模,可显著提升端到端自动驾驶中轨迹规划的准确性与安全性。如图 1 所示,该领域近期的研究沿两条主要方向展开。第一条方向聚焦观测预测:例如 DriveWM [1] 和 VISTA [2] 生成未来的视觉观测,以模拟即将发生的场景。第二条方向利用稠密 BEV 隐表示(Dense BEV Latent Representation)预测场景演变:例如 Drive-OccWorld [3] 采用自回归框架预测未来的占用图(Occupancy Map);与之不同, WOTE [4] 等方法跳过显式场景预测,直接利用未来的 BEV 隐特征辅助规划。尽管前景可观,上述方法仍依赖稠密未来预测,带来可观的计算开销,阻碍了在真实场景中的部署。这凸显了构建高效轻量级世界模型的迫切需求,以提升驾驶系统的实用性与可扩展性。

世界模型的灵感来自人类推理周围环境动态的能力。真实驾驶中,人类驾驶员自然只关注关键要素的未来状态,例如重要的交通参与者与道路结构,而忽略外观等无关细节。这一观察表明,对自动驾驶中的世界模型而言,仅预测场景中显著实例(Salient Instances)的未来状态,比生成整个场景的稠密表示更实用、高效且有效。

本工作得到“浙江省先进智能仓储物流装备重点实验室”(基金号:2024E10007)资助。

¹ 作者单位为浙江大学智能系统与控制研究所,中国杭州。

² 作者单位为华为 2012 实验室。

* 这些作者对本文贡献相同。

† 本工作的项目负责人。

‡ 通讯作者(邮箱: yongliu@iipc.zju.edu.cn)。




图 1: 不同驾驶世界模型(World Model)框架设计的对比。(a) 世界模型首次被引入自动驾驶,用于根据动作条件生成未来观测。(b) 提出的 BEV 隐空间世界模型能更好地保留场景的三维语义结构。(c) 本文的轻量级设计仅生成智能体与地图布局,在提升效率的同时增强了端到端规划性能。

尽管该思路直观且符合人类认知(Human Cognition),这种以实例为中心(Instance-centric)的未来预测方法仍鲜有探索。本文提出一种轻量级世界模型,通过稀疏场景表示(Sparse Scene Representation)仅预测场景的关键布局。该模型设计灵活,可无缝嵌入集成实例级检测(Instance-level Detection)的端到端自动驾驶框架,作为插件模块(Plug-in Module)使用。通过联合预测关键交通参与者的未来状态与地图要素的预期演变,所提模型显著提升了运动预测与轨迹规划的性能,促进更可靠的自动驾驶。

具体而言,本文提出 SparseWorld——一种以视觉为中心(Vision-centric)、轻量级的世界模型,用于实例级未来预测与运动规划精化,具备两个核心功能: (1) **未来场景的稀疏预测**。本文提出核心组件 Sparse Dreamer,根据历史实例与动作条件预测未来场景。将该模块与实例记忆队列(Instance Memory Queue)及运动规划器结合后, SparseWorld 以自回归方式生成稀疏表示的未来场景与未来轨迹。(2) **基于未来场景的运动规划精化**。SparseWorld 将预测未来实例的高维特征作为条件优化运动规划——这些特征提供超越简单几何表示的全面上下文。由此,运动预测器能够学习更准确、更具远见的运动模式,轨迹规划器也能学习更安全、更可靠的轨迹。此外,本文提出自适应轨迹选择(Adaptive Trajectory Selection)模块,评估不同来源的候选轨迹,并选出其中最安全的一条。

本文在 nuScenes [5] 和 Bench2Drive [6] 数据集上评估 SparseWorld。实验评估表明,在开环与闭环规划基准测

试上, SparseWorld 均能提供高保真未来预测, 相比基线方法 SparseDrive [7] 和 VAD [8] 取得统计显著的提升。与 SparseDrive 集成后, SparseWorld 在开环规划中取得 0.05% 的碰撞率, 达到 SOTA (最先进) 水平, 较基线方法降低 37.5%; 在闭环设定下, 其驾驶分数 (Driving Score) 达到 48.95, 提升了 9.9%。此外, SparseWorld 显著降低了运动预测任务中的缺失率 (Missing Rate), 并在端到端预测精度 (EPA) 指标上表现更佳。本文的主要贡献总结如下:

- 本文提出 SparseWorld——一种轻量级、以视觉为中心的世界模型, 用于预测稀疏的未来实例并优化运动规划。
- 本文提出运动规划精化 (Motion Planning Refinement) 方案以增强端到端自动驾驶: 利用未来预测优化运动预测与规划轨迹, 再通过自适应轨迹选择模块从不同来源的候选轨迹中选出最终轨迹, 确保安全且主动的决策。
- 实验结果表明, 本文方法在运动预测与开环/闭环规划上均较基线方法有显著提升。

II. 相关工作

A. 端到端自动驾驶

近期的端到端自动驾驶研究 [9–13] 学习一种统一映射, 将原始的多模态传感器观测 (Multimodal Sensor Observations) 直接转换为可执行的轨迹或控制指令 (Control Commands)。在此框架下, 早期的免感知方法 [14–16] 主要结合强化学习 (Reinforcement Learning) 与模仿学习 (Imitation Learning)。随着领域的发展, 嵌入多任务感知约束的端到端系统成为主流范式。例如, UniAD [17] 通过显式整合感知 (Perception)、预测 (Prediction) 与规划 (Planning), 并引入目标条件化 (Goal-conditioned) 规划机制, 提升了系统鲁棒性。在 VAD [8] 的基础上, VADv2 [18] 采用概率规划 (Probabilistic Planning) 范式应对驾驶决策的内在不确定性。SparseDrive [7] 通过多模态轨迹预测框架进一步优化路径生成, TTOG [19] 则在两阶段轨迹生成架构中统一了运动预测与规划。这些方法的核心思想是利用历史或当前场景信息更好地建模动态演变, 从而生成时序一致性与安全性更高的轨迹。

B. 自动驾驶世界模型

自动驾驶中的世界模型主要分为两条主线。第一条主线聚焦图像域生成器 (Image-domain Generator), 由隐空间扩散 (Latent-Diffusion) 或自回归机制驱动 [2, 20–23], 旨在直接在像素空间 (Pixel Space) 中合成多视角 (Multi-view) 未来场景。DriveDreamer [24] 最早将隐空间扩散应用于多视角驾驶视频生成, 表明动作与文本联合条件能够传达驾驶意图。DriveWM [1] 随后扩展了这一思路, 提出统一的多视角预测与开环规划接口。第二条主线是三维占用生成器 (3D Occupancy Generator), 依赖离散化的体素 (Voxel) 或连续场 [25–27], 以保证几何与运动的时空一致性 (Spatio-temporal Coherence)。OccSora [28] 与 DriveWorld [29] 通过 4D 占用扩散生成语义一致、拓扑连贯的体素网格, 将这一方向推进到数秒以上的范围。GaussianWorld [30] 则利用高斯表示从观测中建模 4D 场景演变。相比之下, UniScene [31] 采用分层生成流程: 先由 BEV 布局生成语义占用, 再通过

高斯渲染与稀疏采样转换为多模态输出, 实现可控合成。为更高效地利用未来场景动态, 本文提出一种预测智能体与地图要素的世界模型, 并将这些预测反馈给运动预测与轨迹规划进行联合优化。

III. 方法

A. 概述

图 2 展示了本文方法的整体框架。SparseWorld 集成到实例感知的端到端驾驶基线 [7, 8] 上, 主要目标有二: 一是高效预测未来实例的稀疏表示, 二是利用这些预测提升基线的运动规划性能。本文框架包含三个过程: (1) 驾驶基线: 该初始阶段从一系列历史传感器观测中推断当前实例、动作条件和轨迹。(2) Sparse Dreamer (SPD) 的未来预测 (见第 III-B 节): 该阶段中, Sparse Dreamer 以自回归方式预测未来实例。(3) 运动规划精化 (见第 III-C 节): 最后利用预测的未来实例精化运动预测和轨迹规划任务。

B. Sparse Dreamer 的未来预测

未来预测 如图 2 所示, SparseWorld 的自回归未来预测过程包含三个核心组件: (1) 实例记忆队列 (IMQ) 维护缓存仓库, 存储历史实例和预测的未来实例。(2) Sparse Dreamer (SPD) 利用 IMQ 中的实例和动作条件生成下一帧的实例。(3) 未来运动规划器 (FMP) 采用与驾驶基线运动规划器完全相同的网络架构, 从预测的未来实例中推断未来动作条件。SparseWorld 的自回归未来预测过程 $\mathcal{W}$ 可定义为:

$$\mathcal{W}(\{I_{-h}, \dots, I_0\}, \{C_{-h}, \dots, C_0\}) = \{I_1, \dots, I_f\} \quad (1)$$

其中元组 $I_t = \{(\mathcal{A}_t, \mathcal{F}_t) | t \in \{-h, -h+1, \dots, f\}\}$ 表示实例。 $\mathcal{A} = \{a^{\text{ego}}, a^{\text{agent}}, a^{\text{map}}\}$ 包含自车、周围智能体和地图要素的锚点几何信息, 而 $\mathcal{F}$ 保存其对应的特征。考虑 h 个时间步的历史动作条件序列, 表示为 $C_t = \{(v_t, \tau_t, s_t) | t \in \{-h, -h+1, \dots, 0\}\}$, 每个动作条件由自车速度 v_t 、规划轨迹 τ_t 和转向指令 s_t 组成。目标是预测长度为 f 的预测时域内的未来序列。

Sparse Dreamer 该模块是未来预测的核心模块。如图 3 所示, SPD 利用世界建模能力预测未来的稀疏实例, 包括智能体和地图要素。SPD 架构包含两个组件: (1) 全局实例对齐, 处理来自 IMQ 的 $\mathcal{A}_t = \{a_t^{\text{agent}}, a_t^{\text{map}} | t \in \{0, 1, \dots, f\}\}$, 利用 FMP 预测的轨迹和速度进行粗粒度预投影以增强未来预测; (2) SparseWorld 解码器, 采用自回归 Transformer, 输入从 IMQ 中选取的历史实例 $\{I_{t-m}, \dots, I_t | t \in \{0, 1, \dots, f\}\}$ (其中 m 表示从 IMQ 选取的历史实例长度) 以及来自 FMP 的当前动作条件 C_t , 预测未来实例 I_{t+1} 。

1) **全局实例对齐 (GIA)**. 智能体锚点 a^{agent} 包含 11 维状态信息: 中心坐标 (x, y, z) 、尺寸 (w, l, h) 、偏航表示 $(\sin \psi, \cos \psi)$ 和速度 (v_x, v_y, v_z) 。为减轻未来帧预测中的坐标变换误差, GIA 通过自车运动补偿和固有速度调整将锚点投影到粗粒度未来位置。对于动态智能体, 纳入其自身位移:

$$ce_{\text{comp}} = ce - V \Delta t \quad (2)$$

其中 $V = (v_x, v_y, v_z)$ 是智能体的线速度, Δt 是时间间隔, ce 表示锚框的中心坐标。利用来自 a^{ego} 的自车角速




图 2: SparseWorld 框架分三个顺序阶段运行。(a) 实例感知 (Instance-Aware) 端到端驾驶基线: 基线模型处理历史传感器数据, 推断智能体与地图实例、动作条件, 以及自车与周围智能体的初始轨迹。(b) 基于 Sparse Dreamer 的未来预测 (Future Forecasting): Sparse Dreamer 基于历史实例与动作条件, 以自回归方式生成未来实例。(c) 运动规划精化 (Motion Planning Refinement): 利用预测的未来实例精化初始轨迹, 再由自适应轨迹选择模块从候选轨迹中评估并选出最安全的轨迹。

度 ω_t 和来自动作条件 c_t 的规划器位移 $(\Delta x_t, \Delta y_t)$:

$$ce' = R_z(\omega_t)ce_{\text{comp}} + \begin{pmatrix} \Delta x_t \\ \Delta y_t \\ 0 \end{pmatrix} \quad (3)$$

$$\begin{pmatrix} \cos \psi' \\ \sin \psi' \end{pmatrix} = R_z^{2 \times 2}(\omega_t) \begin{pmatrix} \cos \psi \\ \sin \psi \end{pmatrix} \quad (4)$$

其中 R_z 是由角速度 ω_t 推导出的 Z 轴旋转矩阵。静态地图要素 ($V = 0$) 仅进行自车运动补偿, 由此得到空间和运动学状态更新后的投影锚点 $\mathcal{A}_t'$ 。

2) **SparseWorld 解码器 (SWD)**. SWD 由 N 个 Transformer 解码器组成, 初始解码器包含自注意力、时间交叉注意力、动作条件交叉注意力、前馈网络以及分类和精化模块, 后续解码器额外集成与预投影模块输出的交叉注意力。在时间交叉注意力操作中, 历史实例 $\{I_{t-m}, \dots, I_t \mid t \in \{0, 1, \dots, f\}\}$ 来自历史自车坐标系, 通过注入时间嵌入 $E_{\text{time}} \in \mathbb{R}^{m \times c}$ 和相对位置嵌入 $E_{\text{pos}} \in \mathbb{R}^{m \times c}$ 增强空间感知, 其中 c 表示嵌入维度。这些位置嵌入由运动规划器的轨迹提议推导而来, 编码历史帧与当前帧之间的相对位移 $(\Delta x, \Delta y)$, 提供关键的空间线索以减轻坐标变换误差。

为增强世界模型的环境理解与可控生成能力, 注入由规划器输出推导出的动作条件。参照 Drive-OccWorld [3], 这些动作条件编码为傅里叶嵌入, 集成到 SparseWorld 解码器的注意力机制中。

C. 运动规划精化

运动预测精化 世界模型预测智能体和地图要素的未来几何信息与特征, 相当于预先为运动预测器提供答案的初步近似, 为其提供更可靠的参考。具体而言, 复用驾驶基线的运动预测器, 其输入为当前实例 I_0 和历史实例 $\{I_{-h}, \dots, I_{-1}\}$ 。将历史实例替换为未来实例 $\{I_1, \dots, I_f\}$ 后, 预测器通过注意力模块聚合不同的时空上下文, 得




图 3: Sparse Dreamer 的详细结构, 它基于历史实例与预期动作条件, 以自回归方式预测下一帧的实例。

到更高质量、运动模式更多样的精化运动轨迹。精化后的运动预测既可作为驾驶基线预测的更优替代, 也可作为其有效补充。

轨迹规划精化 与运动预测精化类似, 首先通过注意力模块让自车特征与未来实例特征交互以增强自车特征, 然后采用与驾驶基线相同的轨迹规划头生成自车轨迹。为显式降低碰撞风险, 训练和推理阶段采用不同机制: 训练阶段设计安全关键损失函数, 引导模型生成低风险轨迹; 推理阶段应用自适应轨迹选择模块, 实时选择和调整最安全的候选轨迹。

1) **安全关键损失 (SCL)**. SCL 通过引入更丰富的时序和几何建模, 扩展了 VAD 中的自车-智能体碰撞约束 (Ego-Agent Collision Constraint)。具体而言: (1) SCL 利用世界模型预测的未来帧智能体位置和轨迹——这是 VAD 无法获取的信息; (2) 显式建模智能体几何, 如尺




图 4: 未来实例预测 (Future Instance Forecasting) 在多个未来时间戳下的定性结果。

表 I: nuScenes 验证集上的未来实例预测 (Future Instance Forecasting) 结果。Avg. 表示 0.5s、1.0s、1.5s 和 2.0s 时刻的平均性能，加粗数字表示最佳结果。

方法	在线建图/mAP $\uparrow$						3D 目标检测/NDS $\uparrow$					
	0s	0.5s	1.0s	1.5s	2.0s	平均	0s	0.5s	1.0s	1.5s	2.0s	平均
copy&paste	56.66	33.23	19.18	12.81	9.71	18.73	0.523	0.331	0.285	0.267	0.212	0.274
projection	56.66	48.61	38.03	27.49	21.84	33.99	0.523	0.459	0.433	0.412	0.390	0.424
SparseWorld-S	56.66	56.48	54.20	51.83	48.96	52.87	0.523	0.501	0.477	0.454	0.433	0.467

寸和朝向，而原始 VAD 实现仅考虑质心坐标。

给定未来 T 步的自车轨迹 $\tau \in \mathbb{R}^{T \times 2}$ 以及周围智能体锚点 a^{agent} 及其未来轨迹 τ^{agent} ，安全关键调整向量 $v^{adj} \in \mathbb{R}^{T \times 2}$ 定义为保证 τ 满足安全约束所需的最小扰动。对每个未来时间步，根据各自轨迹和几何属性计算自车与智能体的包围盒，自车轨迹所需的调整量由自车与智能体包围盒间的最小距离向量和安全距离阈值 θ 确定。 v^{adj} 的计算过程表示为：

$$v^{adj} = \text{SAV}(\tau, a^{agent}, \tau^{agent}, \theta) \quad (5)$$

训练阶段，调整向量由基线当前帧的 a^{agent} 和 τ^{agent} 以及 FMP 对未来帧的预测推导得出。将 v_t^{adj} 记为 v^{adj} 在时间步 t 的分量，安全关键损失 $\mathcal{L}_{scl}$ 计算为 v^{adj} 所有时间步上非零分量的平均范数。

$$\mathcal{L}_{scl} = \frac{\sum_{t=1}^T \|v_t^{adj}\|_2}{\sum_{t=1}^T 1_{\{\|v_i^{adj}\|_2 \neq 0\}}} \quad (6)$$

2) 自适应轨迹选择 (ATS) . 推理阶段考虑来自不同来源的三条候选自车轨迹：驾驶基线预测的基础轨迹、未来预测模块生成的未来轨迹，以及经安全关键损失优化的精化轨迹。对每条候选轨迹，基于基线和精化的运动预测轨迹进行碰撞检测，并计算调整向量和安全关键损失。选择安全关键损失最低且未检测到碰撞的轨迹作为最安全的执行选项；若所有候选轨迹安全性相当，则优先选择精化轨迹。最终轨迹通过对所选轨迹施加相应调整向量得到。SCL 和 ATS 的更多细节见补充材料。

表 II: nuScenes 验证集上的运动预测 (Motion Prediction) 结果。Steps 列表示评估时预测的未来轨迹长度。

方法	步数	EPA $\uparrow$	MR $\downarrow$	mADE	lmFDE $\downarrow$
UniAD [17]	12	0.456	0.151	0.71	1.02
SparseDrive-S [7]	12	0.482	0.136	0.62	0.99
SparseWorld-S (Ours)	12	0.488	0.128	0.62	0.99
VAD-Tiny [8]	6	0.598	0.121	0.79	1.08
SparseWorld-V (Ours)	6	0.619	0.113	0.78	1.03

IV. 实验

A. 实验设置

数据集 为在真实环境中评估 3D 检测、在线建图、运动预测和规划能力，在 nuScenes 数据集 [5] 上开展了大量实验。该数据集包含 1,000 个多样的驾驶场景，每个场景约 20 秒，关键帧按 2Hz 标注，划分为 700 个训练序列和 150 个验证序列。为闭环评估端到端规划性能，采用 Bench2Drive [6] 基准，其实现了兼容 CARLA Leaderboard v2.0 的评估协议。评估遵循官方标准：在 1,000 段视频的基础集上训练，并在 220 条指定路线上与既定基线对比测试。

基线 为验证 SparseWorld 的灵活性和有效性，将其集成到两个有代表性的端到端自动驾驶框架中：SparseDrive [7] 和 VAD [8]。两个框架均包含针对智能体和地图的实例感知模块，但感知范式不同：VAD 基于 BEV 的稠密感知范式构建，而 SparseDrive 采用稀疏感知框架。后文将集成后的版本分别称为 SparseWorld-S 和 SparseWorld-V，并进行全面评估。实验实现分别基于 SparseDrive-S 和 VAD-Tiny。




图 5: 自适应轨迹选择 (Adaptive Trajectory Selection) 的定性结果。当基线轨迹不可避免地导致碰撞时, 可将世界模型与规划精化器预测的轨迹作为候选备选方案, 以有效规避此类碰撞。

表 III: 端到端 (E2E) 方法在 Bench2Drive 基准上的开环与闭环结果。Effi 表示效率 (Efficiency), Comf 表示舒适性 (Comfortness), SR 表示成功率 (Success Rate), DS 表示驾驶分数 (Driving Score)。

方法	开环	闭环			
	Avg.L2↓	Effi↑	Comf↑	SR(%)↑	DS↑
AD-MLP [32]	3.64	48.45	22.63	0.00	18.05
UniAD-Tiny [17]	0.80	123.92	47.04	13.18	40.73
UniAD-Base [17]	0.73	129.21	43.58	16.36	45.81
SparseDrive-S [7]	0.87	170.21	48.63	16.71	44.54
MomAD [33]	0.82	174.91	50.98	18.11	47.91
SparseWorld-S (Ours)	0.84	173.21	50.62	18.23	48.95

任务定义 通过三项评估考察 SparseWorld 的实例预测能力及其对端到端驾驶系统的提升: (1) **智能体和地图布局预测性能**, 采用既定指标评估, 检测使用 nuScenes 检测分数 (NDS), 建图使用平均精度 (mAP); (2) **运动预测精化**, 通过最小平均位移误差 (minADE)、最小最终位移误差 (minFDE)、缺失率 (MR) 和端到端预测精度 (EPA) 等运动指标衡量; (3) **轨迹规划性能**, 通过 L2 位移误差和碰撞率等开环指标评估, 闭环评估采用 Bench2Drive 的综合指标, 包括驾驶分数 (DS)、成功率 (SR)、舒适性 (Comf) 和效率 (Effi)。

B. 主要结果

智能体与地图布局预测结果 表 I 展示了未来时刻的在线建图和 3D 检测结果。0s 处的数值表示 SparseDrive-S [7] 的感知指标, 0.5s-2s 衡量 SparseWorld 预测的性能。对比两种参考方法: (1) Copy&Paste 直接将 0s 的感知结果复用于未来时刻; (2) Projection 使用真值投影矩阵变换 0s 的检测结果。结果表明, 在 2s 处 SparseWorld 达到基线性能的 **82.8%** (3D 检测) 和 **86.4%** (在线建图), 大幅超越两种参考方法, 表明模型成功学习了场景演化动态。此外, 图 4 展示了 SparseWorld 在多种场景下从当前帧表示预测未来实例的能力, 验证了其在不同控制命令条件下生成多种合理未来实例的潜力。

运动预测结果 表 II 展示了 SparseWorld 在运动预测任务上的性能。SparseWorld 在两种架构上均持续提升运动预测器性能。与 SparseDrive-S 结合时, SparseWorld-S 达到更优的 EPA 0.488, 并将 MR 显著降至 0.128, 在保

持基线强劲的 mADE/mFDE 得分的同时展现出更全面的运动模式。对于 VAD-Tiny 基线, SparseWorld-V 在所有评估指标上均获得全面提升, 将 EPA 提升至 0.619, MR 降至 0.113。这些结果凸显了运动精化策略的有效性。

开环规划结果 如表 IV 所示, SparseWorld 对中档架构 VAD-Tiny 带来全面增强, 将平均 L2 误差从 0.78m 降至 0.59m, 碰撞率从 0.38% 降至 0.24%。此外, 在高性能的 SparseDrive-S 基线上, SparseWorld-S 展现出更优的效果, 成功将平均碰撞率从 0.08% 优化至最低的 0.05%, 达到 SOTA 性能。图 5 直观展示了自适应轨迹选择模块对轨迹的优化效果。更多实验结果见补充材料。

闭环规划结果 在 Bench2Drive 数据集上进行了具有挑战性的闭环评估, 结果详见表 III。评估覆盖 220 条路线, 每条路线包含一个代表 44 种交互类型之一的安全关键场景。SparseWorld-S 相比 SparseDrive 提升显著, 关键指标驾驶分数提高 **9.9%**, 成功率指标提升 **9.1%**。这些结果验证了 SparseWorld 作为增强模块提升端到端驾驶系统闭环性能的有效性。

与其他世界模型的对比 与当代世界模型相比, SparseWorld 在效率和有效性两方面均具有明显优势, 总结于表 V 和表 VI。效率方面, 将本文的实例级生成 (900 个智能体锚点、100 个地图锚点) 与 UniScene (图像生成, 512×1536) 和 Drive-OccWorld (占用预测, $200 \times 200 \times 16$) 进行对比。值得注意的是, 本文方法仅用 70 ms 和 4 GB 内存即可生成 4 帧实例级场景, 效率远超两种替代方案。有效性方面 (表 VI), 本文稀疏表示实现的碰撞缓解效果明显优于 Drive-OccWorld 的稠密范式。引入世界模型 (WM) 使 Drive-OccWorld 的 1.5 s 碰撞率降低 62.5%, 而本文 SparseWorld 取得了更大增益——将 VAD-Tiny 的碰撞率降低 63.6%, 并将 SparseDrive-S 的碰撞率降至 0%。这一显著差距表明, 稀疏世界模型对下游规划天然更有效, 验证了其相对稠密表示的优势。

C. 消融实验

Sparse Dreamer 消融实验 消融实验基于 SparseWorld-S 进行。如表 VII 所示, 对未来预测任务的消融研究考察了两种特征增强策略: 全局实例对齐中的未来预投影 (PP) 和 SparseWorld 解码器中历史帧的相

表 IV: nuScenes 验证集上的规划 (Planning) 结果。结果采用 VAD [8] 的评估协议得出。为公平比较, 本文按 [34] 的做法丢弃自行车状态信息。

方法	输入	主干网络	L2 (m) ↓				碰撞率 (%) ↓			
			1s	2s	3s	平均	1s	2s	3s	平均
UniAD [17]	Camera	ResNet101	0.45	0.70	1.04	0.73	0.62	0.58	0.63	0.61
Law [35]	Camera	Swin-T	0.24	0.46	0.76	0.49	0.08	0.10	0.39	0.19
MomAD [33]	Camera	ResNet50	0.31	0.57	0.91	0.60	0.01	0.05	0.22	0.09
VAD-Tiny [8]	Camera	ResNet50	0.46	0.76	1.12	0.78	0.21	0.35	0.58	0.38
SparseWorld-V (Ours)	Camera	ResNet50	0.32	0.56	0.88	0.59	0.08	0.18	0.46	0.24
SparseDrive-S [7]	Camera	ResNet50	0.29	0.58	0.96	0.61	0.01	0.05	0.18	0.08
SparseWorld-S (Ours)	Camera	ResNet50	0.33	0.62	1.01	0.65	0.00	0.01	0.13	0.05

表 V: 不同生成级别下的显存占用与推理时间。IM 表示推理显存 (Inference Memory), IPT 表示推理感知时间 (Inference Perception Time), IGT 表示推理生成时间 (Inference Generation Time)。

方法	表示	IM	IPT	IGT
Uniscene [31]	Image	23524M	-	28.29s
Drive-OccWorld [3]	Occupancy	20581M	401ms	398ms
SparseWorld-S (Ours)	Instance	4397M	174ms	70ms

表 VI: 不同世界模型 (World Model) 下的碰撞率增益。Drive-OccWorld^{wm} 表示不含世界模型的变体。

方法	表示	碰撞率 (%) ↓			
		0.5s	1.0s	1.5s	平均
Drive-OccWorld ^{wm} [3]	Occupancy	0.16	0.23	0.32	0.24
Drive-OccWorld [3]	Occupancy	0.04	0.11	0.13	0.09
VAD-Tiny [8]	Instance	0.15	0.21	0.29	0.22
SparseWorld-V (Ours)	Instance	0.05	0.08	0.12	0.08
SparseDrive-S [7]	Instance	0.01	0.02	0.03	0.02
SparseWorld-S (Ours)	Instance	0.00	0.00	0.00	0.00

表 VII: Sparse Dreamer 的消融实验。

在线建图/mAP ↑						
PE	PP	0.5s	1.0s	1.5s	2.0s	平均
✓	×	55.28	53.16	51.07	47.76	51.82
×	✓	55.11	53.36	51.30	48.54	52.08
✓	✓	56.48	54.20	51.83	48.96	52.87
3D 目标检测/NDS ↑						
PE	PP	0.5s	1.0s	1.5s	2.0s	平均
✓	×	49.19	46.68	44.27	42.10	45.54
×	✓	49.26	46.85	44.64	42.56	45.83
✓	✓	50.13	47.73	45.44	43.33	46.66

表 VIII: 运动预测 (Motion Prediction) 的消融实验。

智能体	地图	步数	EPA ↑	MR ↓	mADE ↓	mFDE ↓
×	×	6	0.598	0.121	0.79	1.08
✓	×	6	0.610	0.116	0.79	1.06
×	✓	6	0.612	0.115	0.79	1.05
✓	✓	6	0.619	0.113	0.78	1.03

对位置嵌入 (PE)。结果表明, 两种增强均对性能有正面贡献, 其中未来预投影带来的增益尤为显著。

运动预测消融实验 在 SparseWorld-V 上进行消融实验, 研究不同类型的未来实例对运动精化策略的贡献, 结果见表 VIII。结果表明智能体实例和地图实例均有效, 各自带来显著的独立提升; 二者结合时展现出协同效应, 取

表 IX: 轨迹规划 (Trajectory Planning) 的消融实验。

FIF	SCL	ATS	L2(m) ↓				碰撞率 (%) ↓			
			1s	2s	3s	平均	1s	2s	3s	平均
×	×	×	0.46	0.76	1.12	0.78	0.21	0.35	0.58	0.38
✓	×	×	0.35	0.60	0.92	0.62	0.16	0.31	0.56	0.34
✓	✓	×	0.32	0.57	0.88	0.59	0.10	0.23	0.50	0.28
✓	✓	✓	0.32	0.56	0.88	0.59	0.08	0.18	0.46	0.24

得最显著的整体增益, 并在所有指标上实现更优性能。

轨迹规划消融实验 表 IX 总结了轨迹精化策略中各组件对整体规划性能的影响。在 SparseWorld-V 中, 集成未来实例特征 (FIF) 主要有助于降低 L2 误差, 引入安全关键损失 (SCL) 则显著降低碰撞率; 此外, 自适应轨迹选择 (ATS) 在保持相近 L2 精度的同时进一步抑制碰撞, 表明其在不牺牲精度的情况下有效提升安全性。

V. 结论

本文提出的 SparseWorld 是专为实例级未来预测和运动规划精化设计的轻量高效世界模型。它首先预测高保真的未来稀疏场景表示, 随后利用这些表示增强运动预测和轨迹规划。大量实验结果一致表明, 模型准确的未来预测能力有效助力端到端自动驾驶, 显著提升了安全性和鲁棒性。

参考文献

- [1] Y. Wang, J. He, L. Fan, H. Li, Y. Chen, and Z. Zhang. "Driving into the future: Multiview visual forecasting and planning with world model for autonomous driving". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, pp. 14749–14759.
- [2] S. Gao, J. Yang, L. Chen, K. Chitta, Y. Qiu, A. Geiger, J. Zhang, and H. Li. "Vista: A generalizable driving world model with high fidelity and versatile controllability". In: *Advances in Neural Information Processing Systems* 37 (2024), pp. 91560–91596.
- [3] Y. Yang, J. Mei, Y. Ma, S. Du, W. Chen, Y. Qian, Y. Feng, and Y. Liu. "Driving in the occupancy world: Vision-centric 4d occupancy forecasting and planning via world models for autonomous driving". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 39. 9. 2025, pp. 9327–9335.
- [4] Y. Li, Y. Wang, Y. Liu, J. He, L. Fan, and Z. Zhang. "End-to-end driving with online trajectory evaluation via bev world model". In: *arXiv preprint arXiv:2504.01941* (2025).
- [5] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom. "nuscenes: A multimodal dataset for autonomous driving". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020, pp. 11621–11631.

- [6] X. Jia, Z. Yang, Q. Li, Z. Zhang, and J. Yan. "Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving". In: *Advances in Neural Information Processing Systems* 37 (2024), pp. 819–844.
- [7] W. Sun, X. Lin, Y. Shi, C. Zhang, H. Wu, and S. Zheng. "Sparsedrive: End-to-end autonomous driving via sparse scene representation". In: *arXiv preprint arXiv:2405.19620* (2024).
- [8] B. Jiang, S. Chen, Q. Xu, B. Liao, J. Chen, H. Zhou, Q. Zhang, W. Liu, C. Huang, and X. Wang. "Vad: Vectorized scene representation for efficient autonomous driving". In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, pp. 8340–8350.
- [9] H. Gao, S. Chen, B. Jiang, B. Liao, Y. Shi, X. Guo, Y. Pu, H. Yin, X. Li, X. Zhang, et al. "Rad: Training an end-to-end driving policy via large-scale 3dgs-based reinforcement learning". In: *arXiv preprint arXiv:2502.13144* (2025).
- [10] Z. Li, S. Wang, S. Lan, Z. Yu, Z. Wu, and J. M. Alvarez. "Hydra-next: Robust closed-loop driving with open-loop training". In: *arXiv preprint arXiv:2503.12030* (2025).
- [11] B. Liao, S. Chen, H. Yin, B. Jiang, C. Wang, S. Yan, X. Zhang, X. Li, Y. Zhang, Q. Zhang, et al. "Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving". In: *Proceedings of the Computer Vision and Pattern Recognition Conference*. 2025, pp. 12037–12047.
- [12] C. Sima, K. Chitta, Z. Yu, S. Lan, P. Luo, A. Geiger, H. Li, and J. M. Alvarez. "Centaur: Robust end-to-end autonomous driving with test-time training". In: *arXiv preprint arXiv:2503.11650* (2025).
- [13] C. Yuan, Z. Zhang, J. Sun, S. Sun, Z. Huang, C. D. W. Lee, D. Li, Y. Han, A. Wong, K. P. Tee, et al. "Drama: An efficient end-to-end motion planner for autonomous driving with mamba". In: *arXiv preprint arXiv:2408.03601* (2024).
- [14] M. Toromanoff, E. Wirbel, and F. Moutarde. "End-to-end model-free reinforcement learning for urban driving using implicit affordances". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2020, pp. 7153–7162.
- [15] P. Wu, X. Jia, L. Chen, J. Yan, H. Li, and Y. Qiao. "Trajectory-guided control prediction for end-to-end autonomous driving: A simple yet strong baseline". In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 6119–6132.
- [16] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl. "Learning by cheating". In: *Conference on robot learning*. PMLR. 2020, pp. 66–75.
- [17] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang, et al. "Planning-oriented autonomous driving". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 17853–17862.
- [18] S. Chen, B. Jiang, H. Gao, B. Liao, Q. Xu, Q. Zhang, C. Huang, W. Liu, and X. Wang. "Vadv2: End-to-end vectorized autonomous driving via probabilistic planning". In: *arXiv preprint arXiv:2402.13243* (2024).
- [19] L. Liu, Z. Song, H. Pan, L. Yang, and C. Jia. "Two Tasks, One Goal: Uniting Motion and Planning for Excellent End To End Autonomous Driving Performance". In: *arXiv preprint arXiv:2504.12667* (2025).
- [20] A. Hu, L. Russell, H. Yeo, Z. Murez, G. Fedoseev, A. Kendall, J. Shotton, and G. Corrado. "Gaia-1: A generative world model for autonomous driving". In: *arXiv preprint arXiv:2309.17080* (2023).
- [21] A. Hu, G. Corrado, N. Griffiths, Z. Murez, C. Gurau, H. Yeo, A. Kendall, R. Cipolla, and J. Shotton. "Model-based imitation learning for urban driving". In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 20703–20716.
- [22] F. Jia, W. Mao, Y. Liu, Y. Zhao, Y. Wen, C. Zhang, X. Zhang, and T. Wang. "Adriver-i: A general world model for autonomous driving". In: *arXiv preprint arXiv:2311.13549* (2023).
- [23] X. Li, Y. Zhang, and X. Ye. "DrivingDiffusion: layout-guided multi-view driving scenarios video generation with latent diffusion model". In: *European Conference on Computer Vision*. Springer. 2024, pp. 469–485.
- [24] X. Wang, Z. Zhu, G. Huang, X. Chen, J. Zhu, and J. Lu. "Drivedreamer: Towards real-world-drive world models for autonomous driving". In: *European conference on computer vision*. Springer. 2024, pp. 55–72.
- [25] L. Zhang, Y. Xiong, Z. Yang, S. Casas, R. Hu, and R. Urtasun. "Copilot4d: Learning unsupervised world models for autonomous driving via discrete diffusion". In: *arXiv preprint arXiv:2311.01017* (2023).
- [26] W. Zheng, W. Chen, Y. Huang, B. Zhang, Y. Duan, and J. Lu. "Occworld: Learning a 3d occupancy world model for autonomous driving". In: *European conference on computer vision*. Springer. 2024, pp. 55–72.
- [27] C. Min, D. Zhao, L. Xiao, Y. Nie, and B. Dai. "Uniworld: Autonomous driving pre-training via world models". In: *arXiv preprint arXiv:2308.07234* (2023).
- [28] L. Wang, W. Zheng, Y. Ren, H. Jiang, Z. Cui, H. Yu, and J. Lu. "Occsora: 4d occupancy generation models as world simulators for autonomous driving". In: *arXiv preprint arXiv:2405.20337* (2024).
- [29] C. Min, D. Zhao, L. Xiao, J. Zhao, X. Xu, Z. Zhu, L. Jin, J. Li, Y. Guo, J. Xing, et al. "Driveworld: 4d pre-trained scene understanding via world models for autonomous driving". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2024, pp. 15522–15533.
- [30] S. Zuo, W. Zheng, Y. Huang, J. Zhou, and J. Lu. "Gaussian-world: Gaussian world model for streaming 3d occupancy prediction". In: *Proceedings of the Computer Vision and Pattern Recognition Conference*. 2025, pp. 6772–6781.
- [31] B. Li, J. Guo, H. Liu, Y. Zou, Y. Ding, X. Chen, H. Zhu, F. Tan, C. Zhang, T. Wang, et al. "Uniscene: Unified occupancy-centric driving scene generation". In: *Proceedings of the Computer Vision and Pattern Recognition Conference*. 2025, pp. 11971–11981.
- [32] J.-T. Zhai, Z. Feng, J. Du, Y. Mao, J.-J. Liu, Z. Tan, Y. Zhang, X. Ye, and J. Wang. "Rethinking the open-loop evaluation of end-to-end autonomous driving in nusenes". In: *arXiv preprint arXiv:2305.10430* (2023).
- [33] Z. Song, C. Jia, L. Liu, H. Pan, Y. Zhang, J. Wang, X. Zhang, S. Xu, L. Yang, and Y. Luo. "Don't Shake the Wheel: Momentum-Aware Planning in End-to-End Autonomous Driving". In: *Proceedings of the Computer Vision and Pattern Recognition Conference*. 2025, pp. 22432–22441.
- [34] Z. Li, Z. Yu, S. Lan, J. Li, J. Kautz, T. Lu, and J. M. Alvarez. "Is ego status all you need for open-loop end-to-end autonomous driving?". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, pp. 14864–14873.
- [35] Y. Li, L. Fan, J. He, Y. Wang, Y. Chen, Z. Zhang, and T. Tan. "Enhancing end-to-end autonomous driving with latent world model". In: *arXiv preprint arXiv:2406.08481* (2024).