

VAD: 面向高效自动驾驶的向量化场景表示 (Vectorized Scene Representation for Efficient Autonomous Driving)

Bo Jiang^{1,*}, Shaoyu Chen^{1,*}, Qing Xu², Bencheng Liao^{1,◇}, Jiajie Chen²,
Helong Zhou², Qian Zhang², Wenyu Liu¹, Chang Huang², Xinggang Wang^{1,✉}

¹ 华中科技大学 ² 地平线机器人 (Horizon Robotics)

{bjiang, shaoyuchen, bcliao, liuwu, xgwang}@hust.edu.cn

{qing.xu, jiajie.chen, helong.zhou, qian01.zhang, chang.huang}@horizon.ai

<https://github.com/hustvl/VAD>

Abstract

自动驾驶需要对周围环境进行全面理解以实现可靠的轨迹规划。现有方法依赖密集的栅格化场景表示 (如智能体占用地图和语义地图) 来进行规划, 计算开销大且丢失了实例级结构信息。本文提出 VAD——一种端到端的向量化自动驾驶范式, 将驾驶场景建模为完全向量化的表示。所提出的向量化范式具有两个显著优势。一方面, VAD 利用向量化的智能体运动和地图元素作为显式的实例级规划约束, 有效提升了规划安全性。另一方面, VAD 摆脱了计算密集的栅格化表示和手工设计的后处理步骤, 运行速度远快于以往的端到端规划方法。VAD 在 *nuScenes* 数据集上取得了当前最优的端到端规划性能, 大幅超越此前的最佳方法。基础模型 VAD-Base 将平均碰撞率大幅降低了 29.0%, 运行速度快 2.5 $\times$ 。此外, 轻量版本 VAD-Tiny 在保持相当规划性能的同时, 极大提升了推理速度 (最高 9.3 $\times$)。我们认为 VAD 出色的性能与高效率对自动驾驶系统的实际部署至关重要。代码和模型已开源, 见<https://github.com/hustvl/VAD>。

1. 引言

自动驾驶既需要全面的场景理解来保障安全, 也需要高效率来满足实际部署需求。自动驾驶车辆需要高效地感知驾驶场景, 并基于场景信息进行合理规划。

传统自动驾驶方法 [7, 14, 23, 48] 采用模块化范式, 将感知和规划解耦为独立模块。其缺点在于, 规划模块无法访问包含丰富语义信息的原始传感器数据。由于规划完全依赖前置感知结果, 感知中的误差可能严重影响规划, 且无法在规划阶段被识别和纠正, 从而带来安全隐患。

近年来, 端到端自动驾驶方法 [2, 11, 19, 21] 以传感




图 1. 以往范式主要依赖栅格化表示 (a) 进行规划 (如语义地图、占用地图、流地图和代价地图), 计算开销大。本文提出的 VAD 完全基于向量化场景表示 (b) 进行端到端规划, 利用实例级结构信息作为规划约束和引导, 实现了优异的性能与效率。

器数据为输入进行感知, 并用一个整体模型输出规划结果。部分工作 [9, 40, 41] 直接基于传感器数据输出规划结果而不学习场景表示, 缺乏可解释性且难以优化。大多数工作 [2, 19, 21] 将传感器数据转换为栅格化场景表示 (如语义地图、占用地图、流地图和代价地图) 以进行规划。尽管直接, 栅格化表示计算开销大, 且丢失了关键的实例级结构信息。

本文提出 VAD (向量化自动驾驶, Vectorized Autonomous Driving) ——一种端到端的向量化自动驾驶范式。VAD 以完全向量化的方式对场景建模 (即向量化的智能体运动和地图), 摆脱了计算密集的栅格化表示。

我们认为向量化场景表示优于栅格化表示。向量化地图 (以边界向量和车道向量表示) 提供道路结构信息 (如交通流向、可行驶边界和车道方向), 帮助自动驾驶车辆缩小轨迹搜索空间, 规划出合理的未来轨迹。交通参与者的运动 (以智能体运动向量表示) 为碰撞避免提

* 同等贡献 (Equal contribution); ◇ 本工作期间为地平线机器人实习生; ✉ 通讯作者 (Corresponding author): xgwang@hust.edu.cn

供了实例级约束。更重要的是，向量化场景表示具有计算高效性，这对实际应用至关重要。

VAD 充分利用向量化信息以隐式和显式的方式引导规划。一方面，VAD 采用地图查询 (Map Query) 和智能体查询 (Agent Query) 从传感器数据中隐式地学习实例级地图特征和智能体运动特征，并通过查询交互提取用于规划的引导信息。另一方面，VAD 基于显式的向量化场景表示提出了三个实例级规划约束：自车-智能体碰撞约束 (Ego-Agent Collision Constraint)，用于保持自车与其他动态智能体之间横向和纵向的安全距离；自车-边界越界约束 (Ego-Boundary Overstepping Constraint)，将规划轨迹推离道路边界；以及自车-车道方向约束 (Ego-Lane Directional Constraint)，利用向量化车道方向规范自动驾驶车辆的未来运动方向。本文提出的框架和向量化规划约束有效提升了规划性能，且不会带来大的计算开销。

无需额外技巧或手工设计的后处理步骤，VAD 在具有挑战性的 nuScenes [1] 数据集上取得了当前最优 (State-of-the-Art, SOTA) 的端到端规划性能和最佳效率。与此前的最优方法 UniAD [21] 相比，基础模型 VAD-Base 将平均规划位移误差大幅降低了 30.1% (1.03m *vs.* 0.72m)，平均碰撞率降低 29.0% (0.31% *vs.* 0.22%)，同时运行速度快 $2.5\times$ (1.8 FPS *vs.* 4.5 FPS)。轻量版本 VAD-Tiny 运行速度快 $9.3\times$ (1.8 FPS *vs.* 16.8 FPS)，同时保持相当的规划性能，平均规划位移误差为 0.78m，平均碰撞率为 0.38%。我们还通过详尽的消融实验验证了各项设计选择的有效性。

本文的主要贡献总结如下：

- 我们提出 VAD——一种端到端的向量化自动驾驶范式。VAD 将驾驶场景建模为完全向量化的表示，摆脱了计算密集的密集栅格化表示和手工设计的后处理步骤。
- VAD 通过查询交互和向量化规划约束，隐式与显式地利用向量化场景信息来提升规划安全性。
- VAD 取得了 SOTA 级别的端到端规划性能，大幅超越以往方法。不仅如此，得益于向量化场景表示和简洁的模型设计，VAD 极大提升了推理速度，这对自动驾驶系统的实际部署至关重要。

我们相信自动驾驶可以完全以向量化的方式高效完成。希望 VAD 令人瞩目的表现能够向社区揭示向量化范式的潜力。

2. 相关工作

感知。 精确的驾驶场景感知是自动驾驶的基础。我们主要介绍与本文最相关的基于相机的 3D 目标检测和在线建图方法。DETR3D [47] 使用 3D 查询 (Query) 采样对应图像特征，无需非极大值抑制即可完成检测。PETR [31] 将 3D 位置编码引入图像特征，并通过注意力 (Attention) [46] 机制使用检测查询学习物体特征。近期，鸟瞰视图 (Bird's-Eye View, BEV) 表示变得流

行，极大推动了感知领域的发展 [8, 17, 26, 28, 29, 34, 51]。LSS [39] 是引入深度预测将特征从透视视图投影到 BEV 的开创性工作。BEVFormer [26] 提出了空间和时间注意力机制以更好地编码 BEV 特征图，在仅使用相机输入的条件下取得了显著的检测性能。FIERY [17] 和 BEVerse [51] 使用 BEV 特征图预测密集地图分割。HDMapNet [25] 通过后处理步骤将车道分割转换为向量化地图。VectorMapNet [32] 以自回归方式预测地图元素。MapTR [29] 识别了地图实例点的排列不变性，能够同时预测所有地图元素。LaneGAP [28] 以新颖的路径方式对车道图建模，良好地保持了车道的连续性，并为规划编码交通信息。我们借鉴 BEVFormer [26] 和 MapTR [29] 的方法，利用一组 BEV 查询、智能体查询和地图查询完成场景感知，并在运动预测和规划阶段进一步使用这些查询特征和感知结果。详见第3节。

运动预测。 传统的运动预测以感知真值 (如智能体历史轨迹和高精地图 (HD Map)) 为输入。部分工作 [3, 38] 将驾驶场景渲染为 BEV 图像，采用基于 CNN 的网络预测未来运动。另一些工作 [13, 33, 37] 使用向量化表示，并采用图神经网络 (GNN) [27] 或 Transformer [33, 37, 46] 进行学习和预测。近期的端到端方法 [15, 17, 22, 51] 联合执行感知和运动预测。部分工作 [17, 20, 51] 将未来运动视为密集占用和流，而非智能体级的未来路径点。ViP3D [15] 基于跟踪结果和高精地图预测未来运动。PIP [22] 提出了动态智能体与静态向量化地图之间的交互方案，在不依赖高精地图的条件下取得了 SOTA 性能。VAD 借鉴 [22] 的思路，通过动态智能体与静态地图元素之间的交互来学习向量化的智能体运动。

规划。 近年来，基于学习的规划方法逐渐成为主流。部分工作 [9, 40, 41] 省略感知和运动预测等中间阶段，直接预测规划轨迹或控制信号。尽管这一思路简单直接，但缺乏可解释性且难以优化。强化学习 (Reinforcement Learning) 非常适合规划任务，已成为一个有前景的研究方向 [4, 5, 45]。显式的密集代价地图 (Cost Map) 具有良好的可解释性，被广泛使用 [2, 11, 19, 44]。代价地图由感知或运动预测结果构建，或来自基于学习的模块，通常采用手工设计的规则选择代价最小的最佳规划轨迹。密集代价地图的构建计算开销大，且手工规则的使用带来了鲁棒性和泛化性问题。UniAD [21] 以目标导向的方式有效融合了各项前置任务提供的信息来辅助规划，在感知、预测和规划方面均取得了显著性能。PlanT [43] 以感知真值为输入，将场景编码为物体级表示用于规划。本文探索了向量化场景表示在规划中的潜力，摆脱了密集地图或手工设计的后处理步骤。

3. 方法

概述。 VAD 的整体框架如图2所示。给定多帧多视角图像输入，VAD 首先用骨干网络编码图像特征，并利用一组 BEV 查询将图像特征投影到 BEV 特征 [26, 39, 52]。其次，VAD 利用一组智能体查询和地图查询学习向




图 2. **VAD 整体架构**。VAD 的完整流程分为四个阶段。骨干网络（Backbone）包含图像特征提取器和 BEV 编码器（BEV Encoder），将图像特征投影到 BEV 特征。向量化场景学习（Vectorized Scene Learning）将场景信息编码到智能体查询和地图查询中，并以运动向量和地图向量表示场景。在规划推理阶段，VAD 利用自车查询（Ego Query）通过查询交互提取地图和智能体信息，并输出规划轨迹（以自车向量表示）。所提出的向量化规划约束在训练阶段规范规划轨迹。*：可选。

量化场景表示，包括向量化地图和向量化智能体运动（第3.1节）。第三，基于场景信息进行规划（第3.2节）。具体而言，VAD 使用一个自车查询（Ego Query），通过与智能体查询和地图查询的交互来学习隐式场景信息。基于自车查询、自车状态特征和高级驾驶指令，规划头（Planning Head）输出规划轨迹。此外，VAD 引入了三个向量化规划约束，在实例级别限制规划轨迹（第3.3节）。VAD 完全可微，以端到端方式训练（第3.4节）。

3.1. 向量化场景学习

感知交通参与者和地图元素是驾驶场景理解的关键。VAD 将场景信息编码到查询特征中，并通过地图向量和智能体运动向量表示场景。

向量化地图。 以往方法 [19, 21] 使用栅格化语义地图来引导规划，丢失了关键的地图实例级结构信息。VAD 利用一组地图查询 Q_m [29] 从 BEV 特征图中提取地图信息，并预测地图向量 $\hat{V}_m \in \mathbb{R}^{N_m \times N_p \times 2}$ 以及每个地图向量的类别分数，其中 N_m 和 N_p 分别表示预测的地图向量数量和每个地图向量包含的点数。考虑三种地图元素：车道线（Lane Divider）、道路边界（Road Boundary）和人行横道（Pedestrian Crossing）。车道线提供方向信息，道路边界指示可行驶区域。地图查询和地图向量均被用来提升规划性能（第3.2节和第3.3节）。

向量化智能体运动。 VAD 首先采用一组智能体查询 Q_a ，通过可变形注意力（Deformable Attention）[53] 从共享的 BEV 特征图中学习智能体级特征。智能体的属性（位置、类别分数、朝向等）由基于 MLP 的解码头从智能体查询中解码得到。为丰富智能体特征以进行运

动预测，VAD 通过注意力机制执行智能体-智能体和智能体-地图交互 [22, 37]。然后，VAD 预测每个智能体的未来轨迹，表示为多模态运动向量 $\hat{V}_a \in \mathbb{R}^{N_a \times N_k \times T_f \times 2}$ 。 N_a , N_k 和 T_f 分别表示预测的智能体数量、模态数量和未来时间戳数量。每种运动向量模态表示一种驾驶意图，VAD 为每种模态输出一个概率分数。智能体运动向量用于约束自车规划轨迹并避免碰撞（第3.3节）。同时，智能体查询作为场景信息送入规划模块（第3.2节）。

3.2. 基于交互的规划

自车-智能体交互。 VAD 利用一个随机初始化的自车查询 Q_{ego} 来学习对规划有价值的隐式场景特征。为了学习其他动态交通参与者的位置和运动信息，自车查询首先通过 Transformer 解码器（Transformer Decoder）[46] 与智能体查询交互，其中自车查询作为注意力中的查询（Query） q ，智能体查询作为键（Key） k 和值（Value） v 。自车位置 p_{ego} 和感知模块预测的智能体位置 p_a 通过单层 MLP PE_1 编码，分别作为查询位置嵌入 q_{pos} 和键位置嵌入 k_{pos} 。位置嵌入提供了智能体与自车间相对位置关系的信息。上述过程可公式化表示为：

$$\begin{aligned} Q'_{ego} &= \text{TransformerDecoder}(q, k, v, q_{pos}, k_{pos}), \\ q &= Q_{ego}, k = v = Q_a, \\ q_{pos} &= PE_1(p_{ego}), k_{pos} = PE_1(p_a). \end{aligned} \quad (1)$$

自车-地图交互。 与智能体查询交互后，更新后的自车查询 Q'_{ego} 进一步以类似方式与地图查询 Q_m 交互。




图 3. 向量化规划约束示意图。自车-智能体碰撞约束旨在保持自车与其他智能体之间的纵向安全和横向安全。自车-边界越界约束在规划轨迹过于靠近车道边界时施加惩罚。自车-车道方向约束利用距离自车最近的车道向量（右子图中的粉色车道）的方向作为先验，规范规划的运动方向。

唯一的区别是使用另一个 MLP PE_2 来编码自车和地图元素的位置。输出的自车查询 Q''_{ego} 同时包含驾驶场景的动态和静态信息。该过程公式化为：

$$\begin{aligned} Q''_{ego} &= \text{TransformerDecoder}(q, k, v, q_{pos}, k_{pos}), \\ q &= Q'_{ego}, k = v = Q_m, \\ q_{pos} &= PE_2(p_{ego}), k_{pos} = PE_2(p_m). \end{aligned} \quad (2)$$

规划头。 由于 VAD 进行无高精地图规划，需要高级驾驶指令 c 用于导航。遵循通常做法 [19, 21]，VAD 使用三种驾驶指令：左转、右转和直行。规划头将更新后的自车查询 (Q'_{ego}, Q''_{ego})、自车当前状态 s_{ego} (可选) 作为自车特征 f_{ego} ，以及驾驶指令 c 作为输入，输出规划轨迹 $\hat{V}_{ego} \in \mathbb{R}^{T_f \times 2}$ 。VAD 采用一个简单的基于 MLP 的规划头。解码过程公式化为：

$$\begin{aligned} \hat{V}_{ego} &= \text{PlanHead}(\text{ft} = f_{ego}, \text{cmd} = c), \\ f_{ego} &= [Q'_{ego}, Q''_{ego}, s_{ego}]. \end{aligned} \quad (3)$$

其中 [...] 表示拼接操作，ft 表示用于解码的特征，cmd 表示导航驾驶指令。

3.3. 向量化规划约束

基于学习到的地图向量和运动向量，VAD 在训练阶段用实例级向量化约束来规范规划轨迹 $\hat{V}_{ego}$ ，如图3所示。

自车-智能体碰撞约束。 自车-智能体碰撞约束显式地考虑自车规划轨迹与其他车辆未来轨迹的兼容性，以提升规划安全性并避免碰撞。不同于以往采用密集占用地图的方法 [19, 21]，我们使用向量化运动轨迹，既保持了良好的可解释性，又降低了计算开销。具体而言，首先通过阈值 ϵ_a 过滤低置信度的智能体预测。对于多模态

运动预测，使用置信度最高的轨迹作为最终预测。我们将碰撞约束视为自车横向和纵向的安全边界。多辆车可能在横向方向上彼此接近（如并排行驶），但在纵向方向上需要更长的安全距离。因此，我们为不同方向采用不同的智能体距离阈值 δ_X 和 δ_Y 。对于每个未来时间戳，在两个方向上找到一定范围 δ_a 内的最近智能体。然后对于每个方向 $i \in \{X, Y\}$ ，如果与最近智能体的距离 d_a^i 小于阈值 δ_i ，则该约束的损失项 $\mathcal{L}_{col}^i = \delta_i - d_a^i$ ，否则为 0。自车-智能体碰撞约束的损失可公式化表示为：

$$\begin{aligned} \mathcal{L}_{col} &= \frac{1}{T_f} \sum_{t=1}^{T_f} \sum_i \mathcal{L}_{col}^{it}, i \in \{X, Y\}, \\ \mathcal{L}_{col}^{it} &= \begin{cases} \delta_i - d_a^{it}, & \text{if } d_a^{it} < \delta_i \\ 0, & \text{if } d_a^{it} \geq \delta_i. \end{cases} \end{aligned} \quad (4)$$

自车-边界越界约束。 该约束旨在将规划轨迹推离道路边界，使轨迹保持在可行驶区域内。首先根据阈值 ϵ_m 过滤低置信度的地图预测。然后对于每个未来时间戳，计算规划路径点与其最近地图边界线之间的距离 d_{bd}^t 。该约束的损失函数公式化为：

$$\begin{aligned} \mathcal{L}_{bd} &= \frac{1}{T_f} \sum_{t=1}^{T_f} \mathcal{L}_{bd}^t, \\ \mathcal{L}_{bd}^t &= \begin{cases} \delta_{bd} - d_{bd}^t, & \text{if } d_{bd}^t < \delta_{bd} \\ 0, & \text{if } d_{bd}^t \geq \delta_{bd}, \end{cases} \end{aligned} \quad (5)$$

其中 δ_{bd} 为地图边界阈值。

自车-车道方向约束。 自车-车道方向约束源于一个先验：车辆的运动方向应与其所在车道的方向一致。方向约束利用向量化的车道方向来规范规划轨迹的运动方向。具体而言，首先根据 ϵ_m 过滤低置信度的地图预测。

方法	L2 (m) ↓				碰撞率 (%) ↓				延迟 (ms)	FPS
	1s	2s	3s	平均	1s	2s	3s	平均		
NMP [†] [49]	-	-	2.31	-	-	-	1.92	-	-	-
SA-NMP [†] [49]	-	-	2.05	-	-	-	1.59	-	-	-
FF [†] [18]	0.55	1.20	2.54	1.43	0.06	0.17	1.07	0.43	-	-
EO [†] [24]	0.67	1.36	2.78	1.60	0.04	0.09	0.88	0.33	-	-
ST-P3 [19]	1.33	2.11	2.90	2.11	0.23	0.62	1.27	0.71	628.3	1.6
UniAD [21]	0.48	0.96	1.65	1.03	0.05	0.17	0.71	0.31	555.6	1.8
VAD-Tiny	0.46	0.76	1.12	0.78	0.21	0.35	0.58	0.38	59.5	16.8
VAD-Base	0.41	0.70	1.05	0.72	0.07	0.17	0.41	0.22	224.3	4.5
VAD-Tiny [‡]	0.20	0.38	0.65	0.41	0.10	0.12	0.27	0.16	59.5	16.8
VAD-Base [‡]	0.17	0.34	0.60	0.37	0.07	0.10	0.24	0.14	224.3	4.5

表 1. 开环规划性能。VAD 在 nuScenes [1] 验证集上取得了最佳的端到端规划性能和最快的推理速度。† 表示基于 LiDAR 的方法。‡ 表示以自车状态信息为输入。在开环评估中，为公平比较我们不使用自车状态信息。ST-P3 和 VAD 的 FPS 在单张 NVIDIA Geforce RTX 3090 GPU 上测量。UniAD 的 FPS 在单张 NVIDIA Tesla A100 GPU 上测量。

然后在每个未来时间戳，找到距离规划路径点最近的车道线向量 $\hat{v}_m \in \mathbb{R}^{T_f \times 2 \times 2}$ (在一定范围 δ_{dir} 内)。最后，该约束的损失为车道向量与自车向量之间随时间平均的角度差：

$$\mathcal{L}_{\text{dir}} = \frac{1}{T_f} \sum_{t=1}^{T_f} \text{Fang}(\hat{v}_m^t, \hat{v}_{\text{ego}}^t), \quad (6)$$

其中 $\hat{v}_{\text{ego}} \in \mathbb{R}^{T_f \times 2 \times 2}$ 为规划的自车向量。 $\hat{v}_{\text{ego}}^t$ 表示从前一时间戳 $t-1$ 的规划路径点指向当前时间戳 t 的规划路径点的自车向量。 $\text{Fang}(v_1, v_2)$ 表示向量 v_1 和 v_2 之间的角度差。

3.4. 端到端学习

向量化场景学习损失。 向量化场景学习包括向量化地图学习和向量化运动预测。对于向量化地图学习，采用曼哈顿距离 (Manhattan Distance) 计算预测地图点与真值地图点之间的回归损失。此外，使用 Focal Loss [30] 作为地图分类损失。整体地图损失记为 $\mathcal{L}_{\text{map}}$ 。

对于向量化运动预测，使用 l_1 损失作为回归损失来预测智能体属性 (位置、朝向、尺寸等)，使用 Focal Loss [30] 预测智能体类别。对于每个与真值智能体匹配的智能体，预测 N_k 条未来轨迹，并以最小终点位移误差 (minFDE) 的轨迹作为代表性预测。然后计算该代表性轨迹与真值轨迹之间的 l_1 损失作为运动回归损失。使用 Focal Loss 作为多模态运动分类损失。整体运动预测损失记为 $\mathcal{L}_{\text{moto}}$ 。

向量化约束损失。 向量化约束损失由第3.3节提出的三个约束组成，即自车-智能体碰撞约束 $\mathcal{L}_{\text{col}}$ 、自车-边界越界约束 $\mathcal{L}_{\text{bd}}$ 和自车-车道方向约束 $\mathcal{L}_{\text{dir}}$ ，它们以向量化场景表示规范规划轨迹 $\hat{V}_{\text{ego}}$ 。

模仿学习损失。 模仿学习损失 (Imitation Learning Loss) $\mathcal{L}_{\text{imi}}$ 是规划轨迹 $\hat{V}_{\text{ego}}$ 与真值自车轨迹 V_{ego} 之间的 l_1 损失，旨在以专家驾驶行为引导规划轨迹。 $\mathcal{L}_{\text{imi}}$ 公式化表示为：

$$\mathcal{L}_{\text{imi}} = \frac{1}{T_f} \sum_{t=1}^{T_f} \|V_{\text{ego}}^t - \hat{V}_{\text{ego}}^t\|_1. \quad (7)$$

VAD 基于所提出的向量化规划约束进行端到端训练。端到端学习的整体损失为向量化场景学习损失、向量化规划约束损失和模仿学习损失的加权和：

$$\mathcal{L} = \omega_1 \mathcal{L}_{\text{map}} + \omega_2 \mathcal{L}_{\text{moto}} + \omega_3 \mathcal{L}_{\text{col}} + \omega_4 \mathcal{L}_{\text{bd}} + \omega_5 \mathcal{L}_{\text{dir}} + \omega_6 \mathcal{L}_{\text{imi}}. \quad (8)$$

4. 实验

我们在具有挑战性的公开 nuScenes [1] 数据集上进行实验，该数据集包含 1000 个驾驶场景，每个场景约持续 20 秒。nuScenes 共提供 140 万个 3D 边界框，涵盖 23 个类别。场景图像由 6 个摄像头捕获，水平覆盖 360° 视场角 (FOV)，关键帧以 2Hz 频率标注。遵循以往方法 [19, 21]，采用位移误差 (Displacement Error, DE) 和碰撞率 (Collision Rate, CR) 综合评估规划性能。对于闭环设定，采用 CARLA 模拟器 [12] 和 Town05 [42] 基准进行仿真。遵循以往方法 [19, 42]，使用路线完成率 (Route Completion, RC) 和驾驶分数 (Driving Score, DS) 评估规划性能。

4.1. 实现细节

VAD 使用 2 秒历史信息，规划 3 秒未来轨迹。默认采用 ResNet50 [16] 作为骨干网络编码图像特征。VAD 在纵向和横向上进行 60m × 30m 感知范围的向量化建

ID	智能体交互	地图交互	越界约束	方向约束	碰撞约束	L2 (m) ↓				碰撞率 (%) ↓			
						1s	2s	3s	平均	1s	2s	3s	平均
1	✓	-	✓	✓	✓	0.52	0.84	1.22	0.86	0.12	0.24	0.51	0.29
2	-	✓	✓	✓	✓	0.49	0.80	1.16	0.82	0.07	0.23	0.49	0.26
3	✓	✓	-	-	-	0.43	0.73	1.11	0.76	0.10	0.22	0.52	0.28
4	✓	✓	✓	-	-	0.46	0.78	1.16	0.80	0.07	0.18	0.47	0.24
5	✓	✓	-	✓	-	0.42	0.72	1.10	0.75	0.10	0.20	0.45	0.25
6	✓	✓	-	-	✓	0.44	0.75	1.11	0.77	0.12	0.23	0.44	0.26
7	✓	✓	✓	✓	✓	0.41	0.70	1.05	0.72	0.07	0.17	0.41	0.22

表 2. 设计选择的消融实验。"智能体交互"和"地图交互"表示规划模块中的自车-智能体和自车-地图查询交互。"越界约束"、"方向约束"和"碰撞约束"分别表示自车-边界越界约束、自车-车道方向约束和自车-智能体碰撞约束。

栅格化表示	向量化表示	方向约束	越界约束	L2 (m) ↓				碰撞率 (%) ↓			
				1s	2s	3s	平均	1s	2s	3s	平均
✓	-	-	-	0.43	0.72	1.08	0.74	0.22	0.36	0.58	0.39
-	✓	-	-	0.44	0.75	1.11	0.77	0.12	0.23	0.44	0.26
-	✓	✓	✓	0.41	0.70	1.05	0.72	0.07	0.17	0.41	0.22

表 3. 关于地图表示（栅格化/向量化）的消融实验。"越界约束"和"方向约束"分别表示自车-边界越界约束和自车-车道方向约束。

方法	Town05 Short		Town05 Long	
	DS ↑	RC ↑	DS ↑	RC ↑
CILRS [10]	7.47	13.40	3.68	7.19
LBC [6]	30.97	55.01	7.05	32.09
Transfuser [†] [42]	54.52	78.41	33.15	56.36
ST-P3 [19]	55.14	86.74	11.45	83.15
VAD-Base	64.29	87.26	30.31	75.20

表 4. 闭环仿真结果。VAD 在 CARLA [12] 上取得了最佳的纯视觉端到端闭环规划性能。[†]: 基于 LiDAR 的方法。

图和运动预测。VAD 有两个版本：VAD-Tiny 和 VAD-Base，其中 VAD-Base 为实验的默认模型。BEV 查询、地图查询和智能体查询的默认数量分别为 200×200 、 100×20 和 300。共有 100 个地图向量查询，每个包含 20 个地图点。特征维度和默认隐藏大小均为 256。与 VAD-Base 相比，VAD-Tiny 的 BEV 查询更少，为 100×100 。运动和地图模块的 BEV 编码器层数和解码器层数从 6 减少到 3，输入图像尺寸从 1280×720 减小到 640×360 。

训练方面，置信度阈值 ϵ_a 和 ϵ_m 设为 0.5，距离阈值 δ_a, δ_{bd} 和 δ_{dir} 分别为 3.0m、1.0m 和 2.0m。智能体安全阈值 δ_X 和 δ_Y 分别设为 1.5m 和 3.0m。使用 AdamW [36] 优化器和余弦退火 (Cosine Annealing) [35] 调度器训练 VAD，权重衰减为 0.01，初始学习率

模块	延迟 (ms)	占比
骨干网络 (Backbone)	23.2	39.0%
BEV 编码器 (BEV Encoder)	12.3	20.7%
运动模块 (Motion Module)	11.5	19.3%
地图模块 (Map Module)	9.1	15.3%
规划模块 (Planning Module)	3.4	5.7%
总计	59.5	100.0%

表 5. 各模块运行时间。推理速度以 VAD-Tiny 在单张 NVIDIA GeForce RTX 3090 GPU 上测量。

为 2×10^{-4} 。VAD 在 8 张 NVIDIA GeForce RTX 3090 GPU 上训练 60 个 epoch，每 GPU batch size 为 1。

VAD-Base 用于闭环评估。输入图像尺寸为 640×320 。遵循以往方法 [19, 42]，导航信息包括稀疏目标位置和对应的离散导航指令。这些导航信息由 MLP 编码后作为输入特征之一送入规划头。此外，我们添加了一个交通灯分类分支以识别交通信号。具体而言，它由一个 Resnet50 网络和一个基于 MLP 的分类头组成。该分支的输入是裁剪后的前视图像，对应图像的中上部分。图像特征图被展平后也送入规划头，帮助模型感知交通灯信息。




图 4. VAD 的定性结果。VAD 基于向量化场景表示以端到端方式输出规划结果，无需任何密集地图或手工设计的后处理步骤。

4.2. 主要结果

开环规划结果。 如表1所示，与此前的最优方法 [21] 相比，VAD 在性能和速度两方面均展现出巨大优势。一方面，VAD-Tiny 和 VAD-Base 分别将平均规划位移误差降低了 0.25m 和 0.31m。同时，VAD-Base 将平均碰撞率大幅降低了 29.0%。另一方面，由于 VAD 不需要诸多辅助任务（如跟踪和占用预测）和繁琐的后处理步骤，基于向量化场景表示实现了最快的推理速度。VAD-Tiny 运行速度快 9.3 $\times$ ，同时保持相当的规划性能。VAD-Base 取得了最佳规划性能，同时仍然快 2.5 $\times$ 。值得注意的是，在主要结果中，VAD 省略了自车状态特征以避免开环规划中的捷径学习（Shortcut Learning） [50]，但使用自车状态特征的 VAD 结果仍保留在表1中以供参考。

闭环规划结果。 VAD 在 Town05 Short 基准上超越了以往最优的纯视觉端到端规划方法 [19, 42]。与 ST-P3 [19] 相比，VAD 将 DS 大幅提升 9.15，RC 也有所提高。在 Town05 Long 基准上，VAD 取得了 30.31 DS，接近基于 LiDAR 的方法 [42]，同时 RC 从 56.36 显著提升至 75.20。ST-P3 [19] 取得了更好的 RC 但 DS 远不及 VAD。

4.3. 消融实验

各设计选择的有效性。 表2展示了各项设计选择的有效性。首先，由于地图能为规划提供关键引导，缺少自车-地图交互时规划距离误差显著增大 (ID 1)。其次，自车-智能体交互和自车-地图交互为自车查询提供了隐式场景特征，使自车能够了解其他车辆的驾驶意图并安全规划，缺少交互时碰撞率显著升高 (ID 1-2)。最后，任一向量化规划约束均可降低碰撞率 (ID 4-6)，当三个约束共同使用时，VAD 取得了最低的碰撞率和最

佳的规划精度 (ID 7)。

栅格化地图表示。 我们在表3中展示了使用栅格化地图表示的 VAD 变体的结果。具体而言, 该 VAD 变体使用地图查询执行 BEV 地图分割而非向量化地图检测, 更新后的地图查询以与 VAD 相同的方式用于规划 Transformer。如表3所示, 使用栅格化地图表示的 VAD 碰撞率显著更高。

各模块运行时间。 我们评估了 VAD-Tiny 各模块的运行时间, 结果如表5所示。骨干网络和 BEV 编码器占用了大部分运行时间用于特征提取和变换。运动模块和地图模块分别占总运行时间的 34.6% 用于多智能体向量化运动预测和向量化地图预测。得益于稀疏的向量化表示和简洁的模型设计, 规划模块的运行时间仅为 3.4ms。

4.4. 定性结果

我们在图4中展示了 VAD 的三个向量化场景学习与规划结果。为更好地理解场景, 我们还提供了原始环视相机图像, 并将规划轨迹投影到前视相机图像中。VAD 能够准确预测多模态智能体运动和地图元素, 并根据向量化场景表示合理地规划自车的未来运动。

5. 结论

本文探索了驾驶场景的完全向量化表示, 以及如何有效融合向量化场景信息以提升规划性能。由此产生的端到端自动驾驶范式被称为 VAD。VAD 同时实现了高性能与高效率, 这对自动驾驶系统的安全性和实际部署至关重要。希望 VAD 令人瞩目的表现能够向社区揭示向量化范式的潜力。

VAD 为其他动态智能体预测多模态运动轨迹, 我们在碰撞约束中使用置信度最高的预测来提升规划安全性。如何利用多模态运动预测进行规划, 值得未来进一步探讨。此外, 如何将其他交通信息 (如车道图、交通标志、交通灯和限速) 融入该自动驾驶系统, 也值得进一步探索。

参考文献

- [1] Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *CVPR*, 2020. 2, 5
- [2] Sergio Casas, Abbas Sadat, and Raquel Urtasun. Mp3d: A unified model to map, perceive, predict and plan. In *CVPR*, 2021. 1, 2
- [3] Yuning Chai, Benjamin Sapp, Mayank Bansal, and Dragomir Anguelov. Multipath: Multiple probabilistic anchor trajectory hypotheses for behavior prediction. *arXiv preprint arXiv:1910.05449*, 2019. 2
- [4] Raphael Chekroun, Marin Toromanoff, Sascha Hornauer, and Fabien Moutarde. Gri: General reinforced imitation and its application to vision-based autonomous driving. *arXiv preprint arXiv:2111.08575*, 2021. 2
- [5] Dian Chen, Vladlen Koltun, and Philipp Krähenbühl. Learning to drive from a world on rails. In *ICCV*, 2021. 2
- [6] Dian Chen, Brady Zhou, Vladlen Koltun, and Philipp Krähenbühl. Learning by cheating. 2020. 6
- [7] Long Chen, Lukas Platinsky, Stefanie Speichert, Błażej Osiński, Oliver Scheel, Yawei Ye, Hugo Grimmett, Luca Del Pero, and Peter Ondruska. What data do we need for training an av motion planner? In *ICRA*, 2021. 1
- [8] Shaoyu Chen, Tianheng Cheng, Xinggang Wang, Wenming Meng, Qian Zhang, and Wenyu Liu. Efficient and robust 2d-to-bev representation learning via geometry-guided kernel transformer. *arXiv preprint arXiv:2206.04584*, 2022. 2
- [9] Felipe Codevilla, Eder Santana, Antonio M López, and Adrien Gaidon. Exploring the limitations of behavior cloning for autonomous driving. In *ICCV*, 2019. 1, 2
- [10] Felipe Codevilla, Eder Santana, Antonio M López, and Adrien Gaidon. Exploring the limitations of behavior cloning for autonomous driving. 2019. 6
- [11] Alexander Cui, Sergio Casas, Abbas Sadat, Renjie Liao, and Raquel Urtasun. Lookout: Diverse multi-future prediction and planning for self-driving. In *ICCV*, 2021. 1, 2
- [12] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. Carla: An open urban driving simulator. In *CoRL*, 2017. 5, 6
- [13] Jiyang Gao, Chen Sun, Hang Zhao, Yi Shen, Dragomir Anguelov, Congcong Li, and Cordelia Schmid. Vectornet: Encoding hd maps and agent dynamics from vectorized representation. In *CVPR*, 2020. 2
- [14] David González, Joshué Pérez, Vicente Milanés, and Fawzi Nashashibi. A review of motion planning techniques for automated vehicles. *T-ITS*, 2015. 1
- [15] Junru Gu, Chenxu Hu, Tianyuan Zhang, Xuanyao Chen, Yilun Wang, Yue Wang, and Hang Zhao. Vip3d: End-to-end visual trajectory prediction via 3d agent queries. *arXiv preprint arXiv:2208.01582*, 2022. 2
- [16] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016. 5
- [17] Anthony Hu, Zak Murez, Nikhil Mohan, Sofia Dudas, Jeffrey Hawke, Vijay Badrinarayanan, Roberto Cipolla, and Alex Kendall. Fiery: Future instance prediction in bird’s-eye view from surround monocular cameras. In *ICCV*, 2021. 2
- [18] Peiyun Hu, Aaron Huang, John Dolan, David Held, and Deva Ramanan. Safe local motion planning with self-supervised freespace forecasting. In *CVPR*, 2021. 5

- [19] Shengchao Hu, Li Chen, Penghao Wu, Hongyang Li, Junchi Yan, and Dacheng Tao. St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning. In *ECCV*, 2022. 1, 2, 3, 4, 5, 6, 7
- [20] Yihan Hu, Wenxin Shao, Bo Jiang, Jiajie Chen, Siqi Chai, Zhening Yang, Jingyu Qian, Helong Zhou, and Qiang Liu. Hope: Hierarchical spatial-temporal network for occupancy flow prediction. *arXiv preprint arXiv:2206.10118*, 2022. 2
- [21] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Goal-oriented autonomous driving. *arXiv preprint arXiv:2212.10156*, 2022. 1, 2, 3, 4, 5, 7
- [22] Bo Jiang, Shaoyu Chen, Xinggang Wang, Bencheng Liao, Tianheng Cheng, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, and Chang Huang. Perceive, interact, predict: Learning dynamic and static clues for end-to-end motion prediction. *arXiv preprint arXiv:2212.02181*, 2022. 2, 3
- [23] Alex Kendall, Jeffrey Hawke, David Janz, Przemyslaw Mazur, Daniele Reda, John-Mark Allen, Vinh-Dieu Lam, Alex Bewley, and Amar Shah. Learning to drive in a day. In *ICRA*, 2019. 1
- [24] Tarasha Khurana, Peiyun Hu, Achal Dave, Jason Ziglar, David Held, and Deva Ramanan. Differentiable raycasting for self-supervised occupancy forecasting. In *ECCV*, 2022. 5
- [25] Qi Li, Yue Wang, Yilun Wang, and Hang Zhao. Hdmapnet: An online hd map construction and evaluation framework. In *ICRA*, 2022. 2
- [26] Zhiqi Li, Wenhai Wang, Hongyang Li, Enze Xie, Chonghao Sima, Tong Lu, Qiao Yu, and Jifeng Dai. Bevformer: Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers. *arXiv preprint arXiv:2203.17270*, 2022. 2
- [27] Ming Liang, Bin Yang, Rui Hu, Yun Chen, Renjie Liao, Song Feng, and Raquel Urtasun. Learning lane graph representations for motion forecasting. In *ECCV*, 2020. 2
- [28] Bencheng Liao, Shaoyu Chen, Bo Jiang, Tianheng Cheng, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Lane graph as path: Continuity-preserving path-wise modeling for online lane graph construction. *arXiv preprint arXiv:2303.08815*, 2023. 2
- [29] Bencheng Liao, Shaoyu Chen, Xinggang Wang, Tianheng Cheng, Qian Zhang, Wenyu Liu, and Chang Huang. Maptr: Structured modeling and learning for online vectorized hd map construction. *arXiv preprint arXiv:2208.14437*, 2022. 2, 3
- [30] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *ICCV*, 2017. 5
- [31] Yingfei Liu, Tiancai Wang, Xiangyu Zhang, and Jian Sun. Petr: Position embedding transformation for multi-view 3d object detection. *arXiv preprint arXiv:2203.05625*, 2022. 2
- [32] Yicheng Liu, Yue Wang, Yilun Wang, and Hang Zhao. Vectormapnet: End-to-end vectorized hd map learning. *arXiv preprint arXiv:2206.08920*, 2022. 2
- [33] Yicheng Liu, Jinghui Zhang, Liangji Fang, Qinhong Jiang, and Bolei Zhou. Multimodal motion prediction with stacked transformers. In *CVPR*, 2021. 2
- [34] Zhi Liu, Shaoyu Chen, Xiaojie Guo, Xinggang Wang, Tianheng Cheng, Hongmei Zhu, Qian Zhang, Wenyu Liu, and Yi Zhang. Vision-based uneven bev representation learning with polar rasterization and surface estimation. *CoRL*, 2022. 2
- [35] Ilya Loshchilov and Frank Hutter. Sgdr: Stochastic gradient descent with warm restarts. *arXiv preprint arXiv:1608.03983*, 2016. 6
- [36] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017. 6
- [37] Jiquan Ngiam, Benjamin Caine, Vijay Vasudevan, Zhengdong Zhang, Hao-Tien Lewis Chiang, Jeffrey Ling, Rebecca Roelofs, Alex Bewley, Chenxi Liu, Ashish Venugopal, et al. Scene transformer: A unified architecture for predicting multiple agent trajectories. *arXiv preprint arXiv:2106.08417*, 2021. 2, 3
- [38] Tung Phan-Minh, Elena Corina Grigore, Freddy A Boulton, Oscar Beijbom, and Eric M Wolff. Covernet: Multimodal behavior prediction using trajectory sets. In *CVPR*, 2020. 2
- [39] Jonah Philion and Sanja Fidler. Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d. In *ECCV*, 2020. 2
- [40] Dean A Pomerleau. Alvin: An autonomous land vehicle in a neural network. *NeurIPS*, 1988. 1, 2
- [41] Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *CVPR*, 2021. 1, 2
- [42] Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. 2021. 5, 6, 7
- [43] Katrin Renz, Kashyap Chitta, Otniel-Bogdan Mercea, A Koepke, Zeynep Akata, and Andreas Geiger. Plant: Explainable planning transformers via object-level representations. *arXiv preprint arXiv:2210.14222*, 2022. 2
- [44] Abbas Sadat, Sergio Casas, Mengye Ren, Xinyu Wu, Pranaab Dhawan, and Raquel Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *ECCV*, 2020. 2
- [45] Marin Toromanoff, Emilie Wirbel, and Fabien Moutarde. End-to-end model-free reinforcement learning for urban driving using implicit affordances. In *CVPR*, 2020. 2
- [46] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *NeurIPS*, 2017. 2, 3
- [47] Yue Wang, Vitor Campagnolo Guizilini, Tianyuan Zhang, Yilun Wang, Hang Zhao, and Justin Solomon.

- Detr3d: 3d object detection from multi-view images via 3d-to-2d queries. In *CoRL*, 2022. 2
- [48] Wenda Xu, Qian Wang, and John M Dolan. Autonomous vehicle motion planning via recurrent spline optimization. In *ICRA*, 2021. 1
- [49] Wenyuan Zeng, Wenjie Luo, Simon Suo, Abbas Sadat, Bin Yang, Sergio Casas, and Raquel Urtasun. End-to-end interpretable neural motion planner. In *CVPR*, 2019. 5
- [50] Jiang-Tian Zhai, Ze Feng, Jinhao Du, Yongqiang Mao, Jiang-Jiang Liu, Zichang Tan, Yifu Zhang, Xiaoping Ye, and Jingdong Wang. Rethinking the open-loop evaluation of end-to-end autonomous driving in nuscenes. *arXiv preprint arXiv:2305.10430*, 2023. 7
- [51] Yunpeng Zhang, Zheng Zhu, Wenzhao Zheng, Junjie Huang, Guan Huang, Jie Zhou, and Jiwen Lu. Beverse: Unified perception and prediction in birds-eye-view for vision-centric autonomous driving. *arXiv preprint arXiv:2205.09743*, 2022. 2
- [52] Brady Zhou and Philipp Krähenbühl. Cross-view transformers for real-time map-view semantic segmentation. In *CVPR*, 2022. 2
- [53] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang, and Jifeng Dai. Deformable detr: Deformable transformers for end-to-end object detection. *arXiv preprint arXiv:2010.04159*, 2020. 3