

VADv2: 基于概率规划的端到端矢量化自动驾驶

Bo Jiang^{1,*}, Shaoyu Chen^{2,*}, Hao Gao^{1,◇}, Bencheng Liao^{1,◇},
Qian Zhang², Wenyu Liu¹, Xinggang Wang^{1,✉}

¹ 华中科技大学 ² 地平线机器人

{bjiang, ghao, bcliao, liuwu, xgwang}@hust.edu.cn

{shaoyu.chen, qian01.zhang}@horizon.auto

ABSTRACT

从大规模驾驶演示中学习类人驾驶策略前景广阔，但规划的不确定性和非确定性本质使其充满挑战。现有基于学习的规划方法遵循确定性范式直接回归动作，难以应对不确定性问题。本文提出了一种用于端到端自动驾驶的概率规划模型，称为 VADv2。我们采用概率场函数对从动作空间到概率分布的映射进行建模。由于规划动作空间是高维连续时空空间且难以处理，我们首先将规划动作空间离散化为一个大型规划词表，然后将规划词表标记化为规划令牌。规划令牌与场景令牌交互，输出动作的概率分布。大规模驾驶演示被用于监督该分布。VADv2 在 CARLA Town05 基准上取得了最先进的闭环性能，显著优于现有方法，并且在最近的 Bench2Drive 基准上也处于领先地位。我们进一步在 NAVSIM 和基于大规模 3D 高斯泼溅的基准上提供了全面的评估，证明了其在实际应用中的有效性。代码开源地址：<https://github.com/hustvl/VAD>。

1 引言

端到端自动驾驶是当前重要的研究课题。真实场景中的大规模人类驾驶演示易于获取，从这些丰富的演示中学习类人驾驶策略用于车辆控制极具前景。然而，规划的不确定性和非确定性本质使得从驾驶演示中提取驾驶知识充满挑战。为说明这种不确定性，图 1 展示了两个场景并解释如下。1) 跟随另一辆车：人类驾驶员表现出多种合理的驾驶操作，如保持当前车道或变道超车。2) 与对向车辆交互：人类驾驶员面临两种可能的驾驶操作，即让行或超车。从统计角度看，动作（包括时机和速度）高度随机，受众多无法精确建模的潜在因素影响。

现有基于学习的规划方法 (Jiang et al., 2023; Hu et al., 2022c; Jia et al., 2023b; Prakash et al., 2021b; Hu et al., 2022a; Zhang et al., 2021) 遵循确定性范式直接回归动作。回归目标在 (Jiang et al., 2023; Hu et al., 2022c; Jia et al., 2023b; Prakash et al., 2021b) 中为未来轨迹，在 (Hu et al., 2022a; Zhang et al., 2021) 中为控制信号（加速度和转向）。这种范式假设驾驶场景与动作之间存在确定性关系，但事实并非如此。人类驾驶行为的方差导致回归目标的模糊性。特别是当可行解空间非凸时，*i.e.*，存在多个可行解（见图 1），确定性建模可能无法正确处理此类情况并产生中间动作，带来潜在的安全风险。

本文提出概率规划以应对规划的不确定性。我们将规划策略建模为场景条件下的非平稳随机过程，公式化为 $p(a|o)$ ，其中 o 是驾驶场景的历史和当前观测， a 是候选规划动作。与确定性规划相比，概率规划对规划中的不确定性更为鲁棒，能够对非凸可行解空间进行建模，从而实现更准确、更安全的规划。

我们采用概率场函数对从规划动作空间到概率分布的映射进行建模。由于动作空间是高维连续时空空间且难以处




图 1: 规划中存在不确定性。驾驶场景与动作之间不存在确定性关系。确定性规划无法对此类不确定性进行建模，尤其在可行解空间非凸的情况下。

* 同等贡献。◇ 工作于地平线机器人实习期间完成。✉ 通讯作者。

理, 我们首先将规划动作空间离散化为一个大型规划词表, 然后将规划词表标记化为规划令牌。规划令牌与场景令牌交互, 输出动作的概率分布。大规模驾驶演示被用于监督该分布。

概率规划还有两个额外优势。第一, 不同于确定性规划需要基于场景信息回归最优动作, 概率规划对每个动作与驾驶场景之间的相关性进行建模, 只需对不同动作进行排序并采样高分动作。这种建模方式更简单。此外, 概率规划在推理阶段具有灵活性, 输出多模态规划结果, 易于与基于规则和基于优化的规划方法结合。由于对动作空间整体分布进行建模, 可以灵活地向规划词表中添加其他候选动作并评估。

基于概率规划, 本文提出端到端驾驶模型 VADv2, 以流式方式接收环视图像序列输入, 对传感器数据和规划动作空间进行标记化, 输出动作的概率分布, 并采样一个动作控制车辆。仅使用相机传感器, VADv2 在 CARLA Town05 基准上取得了最先进的闭环性能, 显著优于现有方法, 同时最近的 Bench2Drive 基准上也处于领先地位。在 NAVSIM 和基于 3DGS 的基准上也展现出强大的规划性能。VADv2 以完全端到端方式稳定运行, 甚至不需要基于规则的包装器作为后处理步骤来避免违规。

本文贡献总结如下:

- 提出概率规划以应对规划的不确定性和非确定性本质。设计概率场来映射从动作空间到概率分布的关系, 并从大规模驾驶演示中学习动作分布。
- 基于概率规划, 提出了 VADv2——一个端到端驾驶模型, 将传感器数据和规划动作空间标记化进行交互, 输出动作的概率分布, 并采样一个动作控制车辆。
- VADv2 在多个基准的闭环和开环设置下均取得了最先进的规划性能。丰富的闭环仿真和真实部署结果验证了其在车辆控制中的有效性和稳定性。

2 相关工作

感知。感知是实现自动驾驶的第一步, 驾驶场景的统一表示有利于与下游任务的无缝集成。鸟瞰图 (Bird’s Eye View, BEV) 表示近年来已成为通用策略, 能够有效编码场景特征并进行多模态数据融合。LSS (Phillion & Fidler, 2020) 是一项开创性工作, 通过显式预测图像像素的深度来实现透视图到 BEV 的变换。而 BEVFormer (Li et al., 2022c) 则通过设计空间和时间注意力机制避免了显式深度预测。后续工作 (Li et al., 2022b; Wang et al., 2023a) 持续优化时序建模和 BEV 变换策略。在矢量化建图方面, HDMapNet (Li et al., 2022a) 通过后处理将车道分割转换为矢量地图。VectorMapNet (Liu et al., 2022) 以自回归方式预测矢量地图元素。MapTR (Liao et al., 2022; 2023b) 引入排列等价和层次化匹配策略, 显著提升了建图性能。LaneGAP (Liao et al., 2023a) 引入车道图的路径化建模。

运动预测。运动预测旨在预测其他交通参与者的未来轨迹, 辅助自车做出合理的规划决策。传统运动预测方法利用历史轨迹和高精度地图等输入预测未来轨迹 (Gao et al., 2020; Liu et al., 2021)。而最近的端到端方法 (Gu et al., 2022; Jiang et al., 2022) 联合执行感知与运动预测。部分工作 (Hu et al., 2021; Zhang et al., 2022) 将未来运动表示为稠密的占用和流场, 另一些工作 (Gu et al., 2022; Jiang et al., 2022) 则预测智能体级别的多模态轨迹。另一类工作将轨迹预测重新定义为分类问题而非回归任务。Trajeglish (Phillion et al., 2023) 引入 K-disk 采样构建紧凑的单步运动词表, 与 k-means 相比离散化误差更小。MotionLM (Seff et al., 2023) 将每个单步动作分解为纵向和横向分量, 并应用轴向对齐的均匀量化。虽然这种单步建模实现了紧凑表示和小词表, 但迭代推理可能导致误差累积并产生违反物理约束的轨迹。相比之下, VADv2 中每个动作令牌表示完整轨迹, 确保物理可行的运动基元, 实现无误差累积的一次性规划。

规划。基于学习的规划最近展现出巨大潜力, 得益于其数据驱动的特性以及随着数据量增加而带来的令人印象深刻的性能提升。早期尝试 (Codevilla et al., 2019; Prakash et al., 2021a) 采用完全黑盒的思想, 直接用传感器数据预测控制信号。但这种策略缺乏可解释性且难以优化。此外, 有大量研究将强化学习与规划相结合 (Zhang et al., 2021; Gao et al., 2025), 在

闭环仿真环境中自主探索驾驶行为。模仿学习 (Chekroun et al., 2021; Hu et al., 2022b; Ma et al., 2025) 是另一个研究方向，模型学习专家驾驶行为以获得良好的规划性能并形成接近人类的驾驶风格。

UniAD (Hu et al., 2022c) 集成多个感知和预测任务以增强规划性能。VAD (Jiang et al., 2023) 探索矢量化场景表示在规划中的潜力并摆脱稠密地图。Diffusion Planner (Zheng et al., 2025) 通过迭代扩散联合预测自车和其他智能体的运动，但依赖真值感知和高精度地图。DiffusionDrive (Liao et al., 2025) 通过截断扩散加速去噪过程；然而有限且预定义的轨迹锚点可能限制生成质量，增加锚点数量又引入额外的计算开销。GoalFlow (Xing et al., 2025) 将规划分解为目标点选择以及通过流匹配生成轨迹，但依赖单一目标点可能影响轨迹多样性，且手工设计的轨迹选择规则限制了泛化性和可扩展性。




图 2: VADv2 的整体架构。VADv2 以流式方式接收多视角图像序列输入，对传感器数据和规划动作空间进行标记化，输出动作的概率分布，并采样一个动作控制车辆。大规模驾驶演示和场景约束被用于监督预测分布。

大语言模型与自动驾驶。近期研究探索了 LLM 与自动驾驶的结合 (Sha et al., 2023; Xu et al., 2023)。一类工作利用 LLM 通过问答进行驾驶场景理解和评估 (Chen et al., 2023; Sima et al., 2024)。另一种方法更进一步，直接利用 LLM 进行规划 (Wang et al., 2023b; 2024)。然而，当前基于 LLM 的规划方法不可避免地受到推理速度的限制，这制约了其在自动驾驶应用中实时部署的实用性。VADv2 从 GPT (Achiam et al., 2023) 中汲取灵感来应对不确定性问题，该问题同样存在于语言建模中。在给定特定上下文下，下一个词是非确定的，LLM 从大规模语料库中学习上下文条件下的下一个词的概率分布，并从分布中采样一个词。受 LLM 启发，VADv2 将规划策略建模为场景条件下的非平稳随机过程。VADv2 对动作空间进行离散化生成规划词表，基于大规模驾驶演示近似概率分布，并在每一时间步从分布中采样一个动作来控制车辆。

3 VADv2

VADv2 的整体框架如图 2 所示。VADv2 以流式方式接收多视角图像序列输入，将传感器数据转换为场景令牌嵌入，输出动作的概率分布，并采样一个动作控制车辆。大规模驾驶演示和场景约束被用于监督预测分布。

3.1 场景编码器

VADv2 使用场景编码器将传感器数据转换为实例级令牌嵌入 $E_{\text{scene}} \in \mathbb{R}^{M \times D}$ 以显式提取高层信息，其中 M 是场景令牌的数量， D 是特征维度。具体而言， E_{scene} 包含四类场景令牌：地图令牌、智能体令牌、交通元素令牌和图像令牌。

BEV 编码器。首先使用 BEV 编码器 (Li et al., 2022c) 将多视角图像特征从透视视图变换为 BEV，生成 BEV 空间中的特征图。该特征图作为学习实例级地图和智能体特征的基础。

地图令牌。引入一组地图令牌 (Liao et al., 2023b) 从 BEV 特征图中学习驾驶场景的矢量化地图元素, 包括车道中心线、车道分隔线、道路边界和人行横道。

智能体令牌。此外, 采用一组智能体令牌 (Jiang et al., 2023) 来预测交通参与者的运动信息, 包括位置、朝向、尺寸、速度和未来轨迹。

交通元素令牌。交通信号在规划中也起着至关重要的作用。在 CARLA 中考虑两种类型的交通信号: 交通灯和停止标志。骨干网络提取的前视图图像特征通过 MLP 进一步编码为交通元素令牌, 随后用于预测交通信号的状态。

图像令牌。除上述实例级令牌外, 前视图图像特征也被用作图像令牌。这些图像令牌为规划提供更稠密的场景特征, 捕捉丰富的信息以补充实例级令牌。

地图令牌、智能体令牌和交通元素令牌通过相应的监督信号进行监督, 确保它们显式编码相应的高层信息。此外, 导航信息和自车状态也通过 MLP 编码为嵌入 ($E_{\text{navi}}, E_{\text{state}}$)。总之, 场景编码器将稀疏的传感器数据转换为更紧凑的高层场景特征 ($E_{\text{scene}}, E_{\text{navi}}, E_{\text{state}}$), 为后续的规划模块奠定基础。

3.2 概率规划

本文提出概率规划以应对规划的不确定性。将规划策略建模为场景条件下的非平稳随机过程, 公式化为 $p(\mathbf{a}|\mathbf{o})$, 其中 $\mathbf{o}$ 是观测到的场景信息, $\mathbf{a}$ 是动作, 表示为未来规划轨迹的路径点序列:

$$\mathbf{o} = (E_{\text{scene}}, E_{\text{navi}}, E_{\text{state}}), \quad \mathbf{a} = (x_1, y_1, x_2, y_2, \dots, x_T, y_T). \quad (1)$$

T 是路径点数量。每个路径点 (x_i, y_i) 对应一个未来时间戳 t_{i0} 。

基于大规模驾驶演示来近似规划动作空间的概率分布, 并在每个时间步从分布中采样一个动作来控制车辆。

规划动作空间是高维连续时空空间且难以处理。因此, 将其离散化为一个大型规划词表 $\mathcal{V} = \{\mathbf{a}^i\}^N$, 其中 N 是词表大小。具体而言, 收集驾驶演示中的所有规划动作作为规划动作集 $\mathcal{S}$, 并采用最远轨迹采样 (Furthest Trajectory Sampling) 选择 N 个代表性动作作为规划词表。词表采样算法如算法 1 所示。 $\mathcal{V}$ 中的每个规划动作均采样自驾驶演示, 因此自然满足自车的运动学约束, 这意味着当动作转换为控制信号 (转向、油门和制动) 时, 控制信号值不会超出可行范围。默认情况下, N 设为 4096。

假设概率 $p(\mathbf{a})$ 相对于 $\mathbf{a}$ 是连续的且对 $\mathbf{a}$ 的微小扰动不敏感, *i.e.*, $\lim_{\Delta\mathbf{a} \rightarrow 0} (p(\mathbf{a}) - p(\mathbf{a} + \Delta\mathbf{a})) = 0$ 。受 NeRF (Mildenhall et al., 2020) 的启发 (其在 5D 空间上建模连续辐射场), 我们采用概率场来建模从动作空间到概率分布的连续映射。

具体而言, 首先将每个动作 (轨迹路径点) 编码为高维规划令牌嵌入 $E(\mathbf{a})$:

$$E(\mathbf{a}) = (\Gamma(x_i), \Gamma(y_i))_{i=1}^T, \quad \Gamma(\text{pos}) = (\gamma(\text{pos}, j))_{j=0}^{L-1}, \\ \gamma(\text{pos}, j) = (\cos(\text{pos}/10000^{2\pi j/L}), \sin(\text{pos}/10000^{2\pi j/L})). \quad (2)$$

Algorithm 1: 规划词表采样算法。

Input: 规划动作集 $\mathcal{S}$, 规划词表大小 N

Output: 规划词表 $\mathcal{V}$

初始化: $\mathcal{V} \leftarrow \emptyset$

for $i = 1$ **to** $N - 1$ **do**

if $\mathcal{V} == \emptyset$ **then**

 从 $\mathcal{S}$ 中随机选择一个动作 $\mathbf{a}$

$\mathcal{V} \leftarrow \mathcal{V} \cup \{\mathbf{a}\}$ 将动作加入规划词表

$\mathcal{S} \leftarrow \mathcal{S} \setminus \{\mathbf{a}\}$ 将动作从规划动作集中移除

end

$\text{max_dis} = 0$

for 轨迹 $\mathbf{a}$ **in** $\mathcal{S}$ **do**

$\text{dis} = \text{calculate_distance}(\mathbf{a}, \mathcal{V})$

if $\text{dis} > \text{max_dis}$ **then**

$\text{max_dis} = \text{dis}$

$\hat{\mathbf{a}} = \mathbf{a}$ 更新当前最远轨迹

end

end

$\mathcal{V} \leftarrow \mathcal{V} \cup \{\hat{\mathbf{a}}\}$

end

返回: $\mathcal{V}$

calculate_distance 计算动作 $\mathbf{a}$ 的终点与集合 $\mathcal{V}$ 中所有动作终点之间的距离, 并返回这些距离中的最小值作为结果。

Γ 是一个编码函数，将每个坐标从 $\mathbb{R}$ 映射到高维嵌入空间 $\mathbb{R}^{2L}$ ，并对轨迹 $\mathbf{a}$ 的每个坐标值分别应用。pos 表示位置（指路径点的 x 或 y 坐标）。使用这些函数将连续坐标映射到更高维空间，以更好地近似更高频率的场函数。

然后，级联 Transformer 解码器 ϕ 与场景信息 E_{scene} 交互，并结合导航信息 E_{navi} 和自行车状态 E_{state} ，预测每个动作的概率：

$$p(\mathbf{a}) = \sigma(\text{MLP}(\phi(E(\mathbf{a}), E_{\text{scene}}) + E_{\text{navi}} + E_{\text{state}})). \quad (3)$$

σ 是 sigmoid 函数。在 Transformer 解码器 ϕ 中， $E(\mathbf{a})$ 作为查询， E_{scene} 作为键和值。 $E(\mathbf{a})$ 、 E_{navi} 、 E_{state} 以及 MLP 的输出具有相同的维度 $(1 \times D)$ 。

3.3 训练

使用三种监督信号训练 VADv2：分布损失、冲突损失和场景令牌损失。

分布损失。从大规模驾驶演示中学习概率分布。使用 KL 散度最小化预测分布与数据分布之间的差异：

$$\mathcal{L}_{\text{distribution}} = D_{\text{KL}}(p_{\text{data}} || p_{\text{pred}}) = \sum_{\mathbf{a} \in \mathcal{V}} p_{\text{data}}(\mathbf{a}) \cdot \log \frac{p_{\text{data}}(\mathbf{a})}{p_{\text{pred}}(\mathbf{a})}, \quad (4)$$

$p_{\text{data}}(\mathbf{a})$ 通过驾驶演示中的出现频率估计。由于 $p_{\text{data}}(\mathbf{a})$ 是固定的， $p_{\text{data}}(\mathbf{a}) \cdot \log p_{\text{data}}(\mathbf{a})$ 是常数可以省略。因此，最小化 KL 散度等价于优化交叉熵损失：

$$\mathcal{L}_{\text{distribution}} = - \sum_{\mathbf{a} \in \mathcal{V}} p_{\text{data}}(\mathbf{a}) \cdot \log p_{\text{pred}}(\mathbf{a}). \quad (5)$$

对于演示中的每一帧，从规划词表中选择与真值动作 L2 距离最小的动作作为最佳匹配动作，赋予标签 1，其他所有动作赋予 0。在所有帧上，动作 $\mathbf{a}$ 的出现频率 $p_{\text{data}}(\mathbf{a})$ 通过统计每个动作被选为最佳匹配的帧数并除以总帧数来估计。这种建模方式类似于大语言模型中使用的标准公式——真值令牌标记为 1，其余为 0，用交叉熵损失最小化预测分布与经验分布之间的差异。

冲突损失。驾驶场景约束被用于帮助模型学习重要的驾驶先验知识并正则化预测的动作分布。具体而言，如果规划词表中的某个动作与其他智能体的真值未来运动或道路边界发生冲突，则将其视为负样本，并施加相应的损失以降低其概率：

$$\mathcal{L}_{\text{conflict}} = \sum_{\mathbf{a} \in \mathcal{V}} \mathbb{1}_{\text{conflict}}(\mathbf{a}) \cdot \log p_{\text{pred}}(\mathbf{a}). \quad (6)$$

$\mathbb{1}_{\text{conflict}}(\mathbf{a})$ 为指示函数，当 $\mathbf{a}$ 发生冲突时值为 1，否则为 0。

场景令牌损失。地图、智能体和交通元素令牌通过相应的监督信号进行监督，确保它们显式编码相关的高层信息。

地图令牌的损失与 MapTRv2 (Liao et al., 2023b) 相同。采用 l_1 损失计算预测地图点与真值地图点之间的回归损失，Focal 损失用作地图分类损失。

智能体令牌的损失由检测损失和运动预测损失组成 (Jiang et al., 2023)。 l_1 损失用作回归损失以预测智能体属性（位置、朝向、尺寸等），Focal 损失用于预测智能体类别。对于每个与真值智能体匹配的智能体，预测 K 条未来轨迹，并使用最终位移误差 (minFDE) 最小的轨迹作为代表性预测。然后计算该代表性轨迹与真值轨迹之间的 l_1 损失作为运动回归损失。此外，Focal 损失被用作多模态运动分类损失。

交通元素令牌由两部分组成：交通灯令牌和停止标志令牌。一方面，将交通灯令牌送入 MLP 预测交通灯状态（黄、红、绿）以及该交通灯是否影响自行车。另一方面，将停止标志令牌也送入 MLP 预测停止标志区域与自行车之间的重叠。Focal 损失用于监督这些预测。最终损失可表示为：

$$\mathcal{L} = \mathcal{L}_{\text{distribution}} + \mathcal{L}_{\text{conflict}} + \mathcal{L}_{\text{token}}. \quad (7)$$

表 1: Town05 Long 基准上的闭环评估结果。

方法	参考文献	模态	DS $\uparrow$	RC $\uparrow$	IS $\uparrow$
Transfuser (Prakash et al., 2021b)	TPAMI'22	C+L	31.0	47.5	0.77
ThinkTwice (Jia et al., 2023b)	CVPR'23	C+L	70.9	95.5	0.75
DriveAdapter+TCP (Jia et al., 2023a)	ICCV'23	C+L	71.9	97.3	0.74
DriveMLM (Wang et al., 2023b)	arXiv'23	C+L	76.1	98.1	0.78
Roach (Zhang et al., 2021)	ICCV'21	C	41.6	96.4	0.43
ST-P3 (Hu et al., 2022b)	ECCV'22	C	11.5	83.2	-
MILE (Hu et al., 2022a)	NeurIPS'22	C	61.1	97.4	0.63
Interfuser (Shao et al., 2023)	CoRL'22	C	68.3	95.0	-
VAD (Jiang et al., 2023)	ICCV'23	C	30.3	75.2	-
Rao et al. (2024)	TIV'24	C	74.9	94.6	0.77
DriveCoT (Wang et al., 2024)	arXiv'24	C	73.6	96.8	0.76
LeapVAD (Ma et al., 2025)	arXiv'25	C	73.7	95.7	0.78
VADv2	本文	C	85.1	98.4	0.87

表 2: NAVSIM navtest 划分上的端到端规划结果（闭环指标）。

方法	参考文献	模态	NC $\uparrow$	DAC $\uparrow$	TTC $\uparrow$	Comf $\uparrow$	EP $\uparrow$	PDMS $\uparrow$
UniAD (Hu et al., 2022c)	CVPR'23	C	97.8	91.9	92.9	100	78.8	83.4
Transfuser (Prakash et al., 2021b)	PAMI'23	C+L	97.7	92.8	92.8	100	79.2	84.0
PARA-Drive (Weng et al., 2024)	CVPR'24	C	97.9	92.4	93.0	99.8	79.3	84.0
GoalFlow Xing et al. (2025)	CVPR'25	C+L	<u>98.3</u>	93.8	94.3	100	79.8	85.7
Hydra-MDP++ Li et al. (2025a)	arXiv'25	C	97.6	96.0	93.1	100	80.4	86.6
DiffusionDrive (Liao et al., 2025)	CVPR'25	C+L	98.2	96.2	94.7	100	82.2	88.1
WoTE Li et al. (2025b)	ICCV'25	C+L	98.5	96.8	<u>94.9</u>	<u>99.9</u>	81.9	88.3
Hydra-NeXt Li et al. (2025c)	arXiv'25	C+L	98.1	97.7	94.6	100	81.8	<u>88.6</u>
VADv2	本文	C	<u>98.3</u>	<u>97.4</u>	95.7	100	82.3	89.3

3.4 推理

在闭环推理中，从分布中获取驾驶策略是灵活的。直观上，在每个时间步采样概率最高的动作，并使用 PID 控制器将选中的动作转换为控制信号（转向、油门和制动）。

在实际应用中，存在更鲁棒的策略来充分利用概率分布。一个良好的实践是：采样 Top-K 动作作为候选，采用基于规则的包装器过滤候选，并使用基于优化的后求解器进行细粒度轨迹优化。此外，动作的概率反映了端到端模型的置信度，可以作为在传统规则规划控制和基于学习的规划控制之间切换的判断条件。

4 实验

4.1 实验设置

CARLA 基准。首先使用 CARLA (Dosovitskiy et al., 2017) 仿真器评估 VADv2 的性能。在广泛使用的 Town05 和 Bench2Drive Jia et al. (2024) 基准上进行闭环评估。每个基准包含若干预定义的驾驶路线。闭环推理的仿真和控制频率为 10 Hz。VADv2 以流式方式接收多视角图像序列输入，规划 3 秒的未来轨迹。轨迹由 6 个路径点组成 (*i.e.*, $T = 6$)，相邻路径点之间的时间间隔为 0.5 秒。VADv2 的默认特征维度 D 设为 256。所有实验基于 16 块 NVIDIA 4090 GPU 进行。

表 3: NAVSIMv2 基准上的端到端规划结果（扩展指标）。

方法	NC $\uparrow$	DAC $\uparrow$	DDC $\uparrow$	TL $\uparrow$	EP $\uparrow$	TTC $\uparrow$	LK $\uparrow$	HC $\uparrow$	EC $\uparrow$	EPDMS $\uparrow$
Transfuser	96.9	89.9	97.8	99.7	87.1	95.4	92.7	98.3	87.2	76.7
HydraMDP++	<u>97.2</u>	<u>97.5</u>	<u>99.4</u>	99.6	83.1	96.5	94.4	<u>98.2</u>	70.9	81.4
PRIX	98.0	95.6	99.5	99.8	87.4	97.2	97.1	98.3	87.6	84.2
VADv2	98.0	98.3	<u>99.4</u>	99.8	<u>87.1</u>	<u>96.8</u>	<u>95.2</u>	98.3	88.1	85.8

表 4: 基于 3DGS 基准上与其他方法的闭环定量对比。

方法	参考文献	CR↓	DCR↓	SCR↓	DR↓	PDR↓	HDR↓	ADD↓
TransFuser	TPAMI 22	<u>0.320</u>	<u>0.273</u>	0.047	0.235	0.188	0.047	0.263
VAD	ICCV 23	0.335	<u>0.273</u>	0.062	0.314	0.255	<u>0.059</u>	0.304
GenAD	ECCV 24	0.341	0.299	<u>0.042</u>	0.291	<u>0.160</u>	<u>0.131</u>	<u>0.265</u>
VADv2	本文	0.270	0.240	0.030	<u>0.243</u>	0.139	0.104	0.273

表 5: Bench2Drive 上的闭环结果。

方法	DS ↑	SR ↑	Eff ↑	Comf ↑
SparseDrive	44.54	16.71	170.21	<u>48.63</u>
MomAD	47.91	18.11	174.91	51.20
DriveTransformer	63.46	35.01	100.64	20.78
ETA	<u>74.33</u>	<u>48.33</u>	186.04	25.77
VADv2	76.15	50.46	<u>178.24</u>	37.81

表 6: 多模态输出消融实验。

轨迹	NC ↑	DAC ↑	TTC ↑	Comf ↑	EP ↑	PDMS ↑
Top1	98.3	97.4	95.7	100	82.3	89.3
Top2	98.2	97.3	94.8	100	<u>82.2</u>	<u>89.1</u>
Top3	98.0	96.7	94.6	99.8	82.0	88.3
Top4	97.8	96.2	93.2	<u>99.9</u>	81.7	87.6
Top5	97.4	96.1	93.5	99.7	81.4	87.5

CARLA 数据。关于为 Town05 基准生成驾驶演示数据，使用 CARLA 的官方自动驾驶智能体，通过在 Town03、Town04、Town06、Town07 和 Town10 中随机生成驾驶路线来收集训练数据。收集约 300 万个片段用于训练。对于每个片段，保存过去 1.6 秒的 6 相机环视图像序列 (10 Hz)，以及交通信号、交通参与者和自车状态等信息。此外，通过预处理 CARLA 提供的 OpenStreetMap (Haklay & Weber, 2008) 格式地图，获得矢量化地图用于训练在线建图模块。地图仅在训练期间作为真值提供，VADv2 在评估时不使用高精度地图。

NAVSIM 和基于 3DGS 的基准。为进一步验证在真实场景中的泛化能力，还在 NAVSIM、NAVSIMv2 (Dauner et al., 2024) 和基于大规模 3DGS (Kerbl et al., 2023) 的基准上评估 VADv2。收集 2000 小时真实人类驾驶演示用于训练，并利用 337 个重建的 3D 高斯泼溅 (3DGS) 环境进行闭环评估。每个环境包含一个 8 秒的场景，捕捉密集交通中的交互与潜在碰撞风险，提供了真实世界驾驶行为和多智能体交互的代表性片段。

逼真的 3DGS 重建实现了准确的智能体轨迹建模和动态环境渲染，提供了高度贴近真实世界驾驶条件的测试平台。基于 3DGS 基准的更多细节见附录 A。同时也在真实车辆上部署了 VADv2，结果见补充材料。

4.2 评估指标

在 CARLA 基准上，采用其官方闭环指标：路线完成率 (Route Completion, RC)、违规分数 (Infraction Score, IS) 和驾驶分数 (Driving Score, DS)。DS 是 RC 与 IS 的乘积，作为主要指标。在基准评估中，大多数工作采用基于规则的包装器来减少违规。为公平比较，遵循在基于学习的策略上采用基于规则包装器的常见做法，与 Transfuser (Prakash et al., 2021b) 相似。同时使用 L2 位移误差和碰撞率进行开环评估。在大多数消融实验中，默认采用开环指标，因为评估更快且更稳定。使用 CARLA 官方自动驾驶智能体在 Town05 Long 基准上生成验证集进行开环评估，结果在所有验证样本上取平均。

在 NAVSIM 基准上，采用其官方闭环指标如 PDMS。在基于 3DGS 的基准上，使用基于真实世界驾驶分析的安全关键指标：碰撞率 (Collision Ratio, CR，动态与静态碰撞率之和) 评估密集交通中的交互安全性，偏差率 (Deviation Ratio, DR，结合位置偏差率和朝向偏差率) 和平均偏差距离 (Average Deviation Distance, ADD) 共同评估轨迹与专家人类驾驶演示的一致性。

4.3 与最先进方法的对比

在 Town05 Long 基准上 (表 1)，VADv2 取得了 85.1 的 DS、98.4 的 RC 和 0.87 的 IS。相较于之前最先进的方法 DriveMLM (Wang et al., 2023b)，VADv2 在取得更高 RC 的同时，DS 显著提升 9.0。值得注意的是，VADv2 仅使用相机作为感知输入，而 DriveMLM 同时使用相机和 LiDAR。此外，与之前最佳的纯相机方法 (Rao et al., 2024) 相比，VADv2 展现出更大的优势，DS 提升高达 10.2。在 Bench2Drive 基准上 (表 5)，VADv2 也取得了最高的驾驶分数 76.15。

表 7: 设计选择的消融实验。“Dist.”: 分布损失; “Traf. Token”: 交通元素令牌。

ID	Dist. 损失	Conflict 损失	Agent 令牌	Map 令牌	Traf. 令牌	Image 令牌	L2 (m) ↓			碰撞率 (%) ↓		
							1s	2s	3s	1s	2s	3s
1		✓	✓	✓	✓	✓	1.415	2.310	3.153	0.698	0.755	0.746
2	✓		✓	✓	✓	✓	0.086	0.173	0.291	0.000	0.012	0.039
3	✓	✓		✓	✓	✓	0.089	0.190	0.327	0.015	0.047	0.085
4	✓	✓	✓		✓	✓	0.086	0.191	0.332	0.005	0.034	0.070
5	✓	✓	✓	✓		✓	0.082	0.171	0.295	0.000	0.017	0.051
6	✓	✓	✓	✓	✓		0.083	0.170	0.293	0.000	0.010	0.039
7	✓	✓	✓	✓	✓	✓	0.082	0.169	0.290	0.000	0.010	0.039

表 8: 不同规划方式和交通密度下的性能消融实验。

规划方式	交通密度	NC ↑	DAC ↑	TTC ↑	Comf ↑	EP ↑	PDMS ↑
确定性	低	98.1	97.4	95.2	99.9	83.2	89.4
概率	低	98.3	99.0	95.5	100	83.5	90.6
确定性	中	97.8	96.3	94.8	100	81.9	87.5
概率	中	98.4	96.8	95.4	100	82.3	89.0
确定性	高	97.3	95.1	93.6	100	79.8	85.8
概率	高	98.0	97.4	94.3	100	82.0	87.7

除 CARLA 系列基准外, VADv2 在 NAVSIM 和 NAVSIMv2 基准上也取得了最先进的规划性能, 如表 2 和表 3 所示。此外, 表 4 展示了基于 3DGS 基准的结果。VADv2 将碰撞率降至 0.270, 相较于 TransFuser (0.320) 提升了 15.6%, 同时保持具有竞争力的偏差率 0.243, 逼近最优记录。这些结果证明了 VADv2 在真实世界动态交互中的鲁棒安全性。

4.4 消融研究

多模态规划性能。进一步评估 VADv2 的多模态规划性能。除最高概率轨迹外, 考虑 Top-5 集合中的其他候选轨迹, 如表 6 所示。结果表明, Top-1 轨迹取得了最佳整体性能, 其他候选的性能基本与 Top-1 相当, 表明 VADv2 能够生成高质量的多模态输出。




图 4: VADv2 在 CARLA Town05 Long 基准上的定性结果。

关键模块。表 7 展示了 VADv2 关键模块的消融实验, 训练中使用了 5 万个驾驶演示片段。没有分布损失提供的专家驾驶行为监督 (ID 1), 模型在规划准确率上表现较差。冲突损失提供了关键的驾驶先验信息, 因此移除它 (ID 2) 同样影响模型的规划准确率。场景令牌将重要的场景元素编码为高维特征, 规划令牌与场景令牌交互以学习驾驶场景的动态和静态信息。当缺少任何类型的场景令牌时, 模型的规划性能都会受到影响 (ID 3-ID 6)。当模型包含上述所有设计时 (ID 7), 达到最佳规划性能。

规划鲁棒性。基于自车 20 米范围内的动态智能体数量，将交通密度分为低 (<5)、中 ($5-10$) 和高 (>10)，并在不同规划方式和密度级别下评估性能 (表 8)。对于确定性规划，遵循常见做法 (Jiang et al., 2023) 将 VADv2 的规划头修改为直接回归未来轨迹的 MLP。结果表明，概率规划始终优于确定性规划。此外，概率规划在不同密度场景下保持稳定性能，而确定性规划则表现出明显的性能下降。这些发现凸显了概率规划范式的有效性和鲁棒性。更多实验和消融见附录 A。

4.5 可视化

图 4 展示了 VADv2 的定性结果。左上图显示不同驾驶速度下的多模态规划轨迹。右上图展示了向前蠕行和向左变道。左下图展示了路口处右变道场景，同时预测了临时直行和立即变道轨迹。右下图描述了目标车道有车辆时的变道情况，VADv2 生成了多条合理轨迹。

5 结论与局限性

本文提出了 VADv2——一个基于概率规划的端到端驾驶模型。它在 CARLA 仿真器中稳定运行，取得了最先进的闭环性能，显著优于现有方法。在 NAVSIM 和基于 3DGS 基准上的全面实验进一步证明了其在复杂驾驶场景中的有效性和鲁棒性。该概率规划范式的可行性得到了初步验证。

目前，仿真器和基于 3DGS 的闭环环境仍存在局限性，如智能体行为简单和场景真实感不足，这可能会限制 VADv2 的性能。在未来的工作中，计划探索如何利用大规模专家驾驶数据进一步提升规划性能，并弥合仿真与真实部署之间的差距。

致谢

本工作得到国家自然科学基金 (NSFC No. 62276108) 的资助。

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- Raphael Chekroun, Marin Toromanoff, Sascha Hornauer, and Fabien Moutarde. Gri: General reinforced imitation and its application to vision-based autonomous driving. *arXiv preprint arXiv:2111.08575*, 2021.
- Long Chen, Oleg Sinavski, Jan Hünermann, Alice Karnsund, Andrew James Willmott, Danny Birch, Daniel Maund, and Jamie Shotton. Driving with llms: Fusing object-level vector modality for explainable autonomous driving. *arXiv preprint arXiv:2310.01957*, 2023.
- Felipe Codevilla, Eder Santana, Antonio M López, and Adrien Gaidon. Exploring the limitations of behavior cloning for autonomous driving. In *ICCV*, 2019.
- Daniel Dauner, Marcel Hallgarten, Tianyu Li, Xinshuo Weng, Zhiyu Huang, Zetong Yang, Hongyang Li, Igor Gilitschenski, Boris Ivanovic, Marco Pavone, et al. Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking. *NeurIPS*, 2024.
- Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. Carla: An open urban driving simulator. In *CoRL*, 2017.
- Hao Gao, Shaoyu Chen, Bo Jiang, Bencheng Liao, Yiang Shi, Xiaoyang Guo, Yuechuan Pu, Haoran Yin, Xiangyu Li, Xinbang Zhang, et al. Rad: Training an end-to-end driving policy via large-scale 3dgs-based reinforcement learning. *arXiv preprint arXiv:2502.13144*, 2025.
- Jiyang Gao, Chen Sun, Hang Zhao, Yi Shen, Dragomir Anguelov, Congcong Li, and Cordelia Schmid. Vectornet: Encoding hd maps and agent dynamics from vectorized representation. In *CVPR*, 2020.

- Junru Gu, Chenxu Hu, Tianyuan Zhang, Xuanyao Chen, Yilun Wang, Yue Wang, and Hang Zhao. Vip3d: End-to-end visual trajectory prediction via 3d agent queries. *arXiv preprint arXiv:2208.01582*, 2022.
- Mordechai Haklay and Patrick Weber. Openstreetmap: User-generated street maps. *IEEE Pervasive computing*, 2008.
- Anthony Hu, Zak Murez, Nikhil Mohan, Sofia Dudas, Jeffrey Hawke, Vijay Badrinarayanan, Roberto Cipolla, and Alex Kendall. Fiery: Future instance prediction in bird’s-eye view from surround monocular cameras. In *ICCV*, 2021.
- Anthony Hu, Gianluca Corrado, Nicolas Griffiths, Zak Murez, Corina Gurau, Hudson Yeo, Alex Kendall, Roberto Cipolla, and Jamie Shotton. Model-based imitation learning for urban driving. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022a.
- Shengchao Hu, Li Chen, Penghao Wu, Hongyang Li, Junchi Yan, and Dacheng Tao. St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning. In *ECCV*, 2022b.
- Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, et al. Planning-oriented autonomous driving. *CVPR2023*, 2022c.
- Xiaosong Jia, Yulu Gao, Li Chen, Junchi Yan, Patrick Langechuan Liu, and Hongyang Li. Driveadapter: Breaking the coupling barrier of perception and planning in end-to-end autonomous driving. In *ICCV*, 2023a.
- Xiaosong Jia, Penghao Wu, Li Chen, Jiangwei Xie, Conghui He, Junchi Yan, and Hongyang Li. Think twice before driving: Towards scalable decoders for end-to-end autonomous driving. In *CVPR*, 2023b.
- Xiaosong Jia, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang, and Junchi Yan. Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. In *NeurIPS*, 2024.
- Bo Jiang, Shaoyu Chen, Xinggang Wang, Bencheng Liao, Tianheng Cheng, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, and Chang Huang. Perceive, interact, predict: Learning dynamic and static clues for end-to-end motion prediction. *arXiv preprint arXiv:2212.02181*, 2022.
- Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Vad: Vectorized scene representation for efficient autonomous driving. *ICCV*, 2023.
- Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Trans. Graph.*, 42(4):139–1, 2023.
- Kailin Li, Zhenxin Li, Shiyi Lan, Yuan Xie, Zhizhong Zhang, Jiayi Liu, Zuxuan Wu, Zhiding Yu, and Jose M Alvarez. Hydra-mdp++: Advancing end-to-end driving via expert-guided hydra-distillation. *arXiv preprint arXiv:2503.12820*, 2025a.
- Qi Li, Yue Wang, Yilun Wang, and Hang Zhao. Hdmapnet: An online hd map construction and evaluation framework. In *ICRA*, 2022a.
- Yingyan Li, Yuqi Wang, Yang Liu, Jiawei He, Lue Fan, and Zhaoxiang Zhang. End-to-end driving with online trajectory evaluation via bev world model. In *ICCV*, 2025b.
- Yinhao Li, Zheng Ge, Guanyi Yu, Jinrong Yang, Zengran Wang, Yukang Shi, Jianjian Sun, and Zeming Li. Bevdepth: Acquisition of reliable depth for multi-view 3d object detection. *arXiv preprint arXiv:2206.10092*, 2022b.
- Zhenxin Li, Shihao Wang, Shiyi Lan, Zhiding Yu, Zuxuan Wu, and Jose M Alvarez. Hydra-next: Robust closed-loop driving with open-loop training. *arXiv preprint arXiv:2503.12030*, 2025c.

- Zhiqi Li, Wenhai Wang, Hongyang Li, Enze Xie, Chonghao Sima, Tong Lu, Qiao Yu, and Jifeng Dai. Bevformer: Learning bird’s-eye-view representation from multi-camera images via spatiotemporal transformers. *arXiv preprint arXiv:2203.17270*, 2022c.
- Bencheng Liao, Shaoyu Chen, Xinggang Wang, Tianheng Cheng, Qian Zhang, Wenyu Liu, and Chang Huang. Maptr: Structured modeling and learning for online vectorized hd map construction. *arXiv preprint arXiv:2208.14437*, 2022.
- Bencheng Liao, Shaoyu Chen, Bo Jiang, Tianheng Cheng, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Lane graph as path: Continuity-preserving path-wise modeling for online lane graph construction. *arXiv preprint arXiv:2303.08815*, 2023a.
- Bencheng Liao, Shaoyu Chen, Yunchi Zhang, Bo Jiang, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. Maptrv2: An end-to-end framework for online vectorized hd map construction. *arXiv preprint arXiv:2308.05736*, 2023b.
- Bencheng Liao, Shaoyu Chen, Haoran Yin, Bo Jiang, Cheng Wang, Sixu Yan, Xinbang Zhang, Xiangyu Li, Ying Zhang, Qian Zhang, et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *CVPR*, 2025.
- Yicheng Liu, Jinghui Zhang, Liangji Fang, Qinhong Jiang, and Bolei Zhou. Multimodal motion prediction with stacked transformers. In *CVPR*, 2021.
- Yicheng Liu, Yue Wang, Yilun Wang, and Hang Zhao. Vectormapnet: End-to-end vectorized hd map learning. *arXiv preprint arXiv:2206.08920*, 2022.
- Yukai Ma, Tiantian Wei, Naiting Zhong, Jianbiao Mei, Tao Hu, Licheng Wen, Xuemeng Yang, Botian Shi, and Yong Liu. Leapvad: A leap in autonomous driving via cognitive perception and dual-process thinking. *arXiv preprint arXiv:2501.08168*, 2025.
- Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis. *ECCV*, 2020.
- Jonah Philion and Sanja Fidler. Lift, splat, shoot: Encoding images from arbitrary camera rigs by implicitly unprojecting to 3d. In *ECCV*, 2020.
- Jonah Philion, Xue Bin Peng, and Sanja Fidler. Trajenglish: Traffic modeling as next-token prediction. *arXiv preprint arXiv:2312.04535*, 2023.
- Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *CVPR*, 2021a.
- Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *CVPR*, 2021b.
- Zhongyu Rao, Yingfeng Cai, Hai Wang, Yubo Lian, Yilin Zhong, Long Chen, and Yicheng Li. Enhancing autonomous driving: A low-cost monocular end-to-end framework with multi-task integration and temporal fusion. *IEEE Transactions on Intelligent Vehicles*, 2024.
- Ari Seff, Brian Cera, Dian Chen, Mason Ng, Aurick Zhou, Nigamaa Nayakanti, Khaled S Refaat, Rami Al-Rfou, and Benjamin Sapp. Motionlm: Multi-agent motion forecasting as language modeling. In *ICCV*, 2023.
- Hao Sha, Yao Mu, Yuxuan Jiang, Li Chen, Chenfeng Xu, Ping Luo, Shengbo Eben Li, Masayoshi Tomizuka, Wei Zhan, and Mingyu Ding. Languagempc: Large language models as decision makers for autonomous driving. *arXiv preprint arXiv:2310.03026*, 2023.
- Hao Shao, Letian Wang, Ruobing Chen, Hongsheng Li, and Yu Liu. Safety-enhanced autonomous driving using interpretable sensor fusion transformer. In *Conference on Robot Learning*, pp. 726–737. PMLR, 2023.

- Chonghao Sima, Katrin Renz, Kashyap Chitta, Li Chen, Hanxue Zhang, Chengen Xie, Jens Beißwenger, Ping Luo, Andreas Geiger, and Hongyang Li. Drivelm: Driving with graph visual question answering. In *ECCV*, 2024.
- Shihao Wang, Yingfei Liu, Tiancai Wang, Ying Li, and Xiangyu Zhang. Exploring object-centric temporal modeling for efficient multi-view 3d object detection. *arXiv preprint arXiv:2303.11926*, 2023a.
- Tianqi Wang, Enze Xie, Ruihang Chu, Zhenguo Li, and Ping Luo. Drivcot: Integrating chain-of-thought reasoning with end-to-end driving. *arXiv preprint arXiv:2403.16996*, 2024.
- Wenhai Wang, Jiangwei Xie, ChuanYang Hu, Haoming Zou, Jianan Fan, Wenwen Tong, Yang Wen, Silei Wu, Hanming Deng, Zhiqi Li, et al. Drivemlm: Aligning multi-modal large language models with behavioral planning states for autonomous driving. *arXiv preprint arXiv:2312.09245*, 2023b.
- Xinshuo Weng, Boris Ivanovic, Yan Wang, Yue Wang, and Marco Pavone. Para-drive: Parallelized architecture for real-time autonomous driving. In *CVPR*, 2024.
- Zebin Xing, Xingyu Zhang, Yang Hu, Bo Jiang, Tong He, Qian Zhang, Xiaoxiao Long, and Wei Yin. Goalflow: Goal-driven flow matching for multimodal trajectories generation in end-to-end autonomous driving. In *CVPR*, 2025.
- Zhenhua Xu, Yujia Zhang, Enze Xie, Zhen Zhao, Yong Guo, Kenneth KY Wong, Zhenguo Li, and Hengshuang Zhao. Drivegpt4: Interpretable end-to-end autonomous driving via large language model. *arXiv preprint arXiv:2310.01412*, 2023.
- Yunpeng Zhang, Zheng Zhu, Wenzhao Zheng, Junjie Huang, Guan Huang, Jie Zhou, and Jiwen Lu. Beverse: Unified perception and prediction in birds-eye-view for vision-centric autonomous driving. *arXiv preprint arXiv:2205.09743*, 2022.
- Zhejun Zhang, Alexander Liniger, Dengxin Dai, Fisher Yu, and Luc Van Gool. End-to-end urban driving by imitating a reinforcement learning coach. In *ICCV*, 2021.
- Yinan Zheng, Ruiming Liang, Kexin Zheng, Jinliang Zheng, Liyuan Mao, Jianxiong Li, Weihao Gu, Rui Ai, Shengbo Eben Li, Xianyu Zhan, et al. Diffusion-based planning for autonomous driving with flexible guidance. *arXiv preprint arXiv:2501.15564*, 2025.

表 9: Town05 Short 上的闭环结果。

方法	模态	DS $\uparrow$	RC $\uparrow$
CILRS	C	7.5	13.4
LBC	C	31.0	55.0
Transfuser	C+L	54.5	78.4
ST-P3	C	55.1	86.7
VAD	C	64.3	87.3
LeapVAD	C	88.2	99.5
VADv2	C	89.7	93.0

表 11: 训练片段数量的消融实验。

数量	L2 (m) $\downarrow$			碰撞率 (%) $\downarrow$		
	1s	2s	3s	1s	2s	3s
1×10^5	0.121	0.264	0.461	0.015	0.061	0.107
3×10^5	0.082	0.169	0.290	0.000	0.010	0.039
1×10^6	0.073	0.153	0.267	0.000	0.008	0.027
3×10^6	0.072	0.133	0.225	0.000	0.000	0.007

表 10: 词表大小的消融实验。

大小	L2 (m) $\downarrow$			碰撞率 (%) $\downarrow$		
	1s	2s	3s	1s	2s	3s
256	0.110	0.207	0.337	0.000	0.019	0.057
512	0.099	0.189	0.313	0.000	0.022	0.045
1024	0.093	0.175	0.293	0.000	0.020	0.044
2048	0.088	0.173	0.294	0.000	0.017	0.041
4096	0.082	0.169	0.290	0.000	0.010	0.039

表 12: 规划方式的消融实验。

规划方式	DS $\uparrow$	RC $\uparrow$	L2(m) @3s $\downarrow$	碰撞率 (%) @3s $\downarrow$
确定性	74.6	95.1	0.223	0.006
概率	85.1	98.4	0.225	0.007

A 附录

A.1 TOWN05 SHORT 基准上的闭环结果

在表 9 中总结了 VADv2 在 Town05 Short 基准上的结果。该基准评估特定驾驶行为，包括密集交通中的变道和路口前的变道。VADv2 取得了最高的 DS 分数，而 LeapVAD 虽然 RC 更高但 DS 较低，表明违规更多。总体而言，这些结果凸显了 VADv2 在挑战性场景中强大而可靠的驾驶能力。

A.2 更多消融研究

词表大小。表 10 展示了词表大小的消融实验。随着词表增大，L2 和碰撞指标均改善。更大的词表能够以更小的离散化误差更好地表示动作空间。

训练片段数量。表 11 是用于训练端到端模型的驾驶演示片段数量的消融实验。如预期，随着数据量增加，模型在 L2 和碰撞指标上表现更好。

概率 vs 确定性。Town05 Long 基准上的消融结果（表 12）表明，确定性和概率规划在开环评估中表现相似。而在闭环设置下，概率规划取得显著更好的稳定性和性能，确定性规划则难以应对规划不确定性。

词表采样。在表 13 中，报告了不同词表采样策略的离散误差和规划性能。对于 NAVSIM 中的每个训练样本，选择 L2 距离最小的词表轨迹，然后测量每时间步的 L2 误差。同时计算平均和最大 L2 误差并在所有样本上取平均。

不同策略之间的差异较小，最远轨迹采样（FTS）取得了最佳的动作空间覆盖和最强的结果。同时通过从 nuScenes 训练集中采样轨迹构建词表并在 NAVSIM 上评估，性能保持可比，表明 VADv2 能够有效跨场景泛化。

表 13: 不同词表采样策略的离散化误差与性能消融实验。

策略	平均 L2 $\downarrow$	最大 L2 $\downarrow$	NC $\uparrow$	DAC $\uparrow$	TTC $\uparrow$	Comf $\uparrow$	EP $\uparrow$	PDMS $\uparrow$
k-means	0.132	0.217	97.9	97.2	94.5	100	81.9	89.0
K-disks	0.128	0.204	98.1	97.3	94.8	100	82.2	89.1
nuScenes	0.116	0.212	98.2	97.1	95.4	100	82.5	89.1
FTS	0.102	0.181	98.3	97.6	95.1	100	82.3	89.3

表 14: 真实世界基于 3DGS 验证数据集的更多详细统计。

场景	类别	占比
晴天	天气	74.78%
夜间和雨天	天气	25.22%
拥挤道路	精细行为	6.23%
狭窄道路	精细行为	6.82%
路口	精细行为	38.58%
切入	交互场景	9.79%
人行横道	交互场景	9.20%

图 5: CARLA Town05 基准上规划词表的可视化。




表 15: 基于 3DGS 基准的更多评估细节。

方法	参考文献	参数量	延迟	碰撞率 (%)	平台
TransFuser	TPAMI 22	0.36B	118ms	0.320	RTX 4090
VAD	ICCV 23	0.36B	118ms	0.335	RTX 4090
GenAD	ECCV 24	0.38B	121ms	0.341	RTX 4090
VADv2	本文	0.40B	125ms	0.270	RTX 4090

A.3 基于 3DGS 基准的更多评估细节

表 14展示了数据集中多样且具有挑战性的测试场景，支持更鲁棒的评估。同时在不同天气条件下评估基于 3DGS 的重建质量，晴天、雨天和夜间场景的 PSNR（峰值信噪比）指标分别达到 29.5、28.8 和 28.2，展现了领先的性能水平。

表 15报告了 TransFuser 和 VAD 等基线方法的推理延迟、模型参数和硬件平台。为公平比较规划性能，所有方法使用相同的感知骨干网络，因此延迟差异主要来自规划模块设计。虽然 VADv2 的规划词表增加了一些开销，其延迟仍与其他基线相当，并显著改善了主要的碰撞率指标。

表 16提供了真实世界数据集的额外细节并与主流基准进行比较。nuScenes 以直行场景为主，NAVSIM 包含更多转弯但数据量有限，而本数据集在规模和场景多样性方面均脱颖而出。

A.4 LLM 使用声明

本文仅使用 LLM 进行语法检查和写作润色，作者对所有内容承担全部责任。

表 16: 真实世界基于 3DGS 数据集的定量分析。

数据集	时长	环境	直行	转弯
nuScenes	5.55h	城市	92.80%	7.20%
NAVSIM	120h	城市	66.40%	33.60%
本文	2000h	城市、高速、乡村	52.50%	47.50%