WA-JEPA：重新思考面向自动驾驶世界-动作建模的视频 JEPA 范式

Xinlin Wang[1 *], **Yujiao Xiang**[1,2 *], **Yuheng Zhou**[1,3 *], **Jingqi Wang**[1 *], **Minqing Huang**[1 *‡], **Jiajie Huang**[1,4], **Dongxu Wei**[1 †], **Tingguang Zhou**[1], **Xiyang Wang**[1], **Gong Chen**[1,5], **Zhi Xu**[1], **Feiyang Tan**[1], **Hangning Zhou**[1], **Mu Yang**[1]

[1]Afari Intelligent Drive [2] 电子科技大学
[3] 东南大学 [4] 北京邮电大学 [5] 天津大学

* 同等贡献，排名不分先后。† 项目负责人。‡ 通讯作者：mqhuang1211@gmail.com。

Abstract

视频联合嵌入预测架构 (V-JEPA) 通过自监督隐特征预测从视频中学习强大的时空表征。然而，V-JEPA 建立在随机掩码补全与确定性回归之上，从根本上不适合自动驾驶规划——后者要求面向未来的预测且与动作紧耦合。为此，本文重新思考 V-JEPA 范式，提出 WA-JEPA，一种专为自动驾驶规划设计的 V-JEPA 原生世界-动作模型。不同于随机时空掩码，WA-JEPA 采用混合未来掩码预训练，从观测上下文中推断未来隐变量。不同于确定性回归，本文将未来预测重构为未来隐变量上的条件流匹配，从而显著提升模型生成合理未来隐变量、服务于下游规划的能力。最后，本文提出联合未来-动作预测器，在统一的时空隐空间中同时去噪未来场景 token 与自车轨迹，使动作监督能够直接塑造与规划相关的世界表征。在 nuPlan 视频上预训练并在 NAVSIM 上微调后，WA-JEPA 在 NAVSIM-v2 上达到 91.7 EPDMS，分别超过最强的端到端与世界-动作基线 1.6 和 1.3 EPDMS；并且在未针对 HUGSIM 进行特定微调的情况下，在相同评测协议下于闭环 HUGSIM 基准上取得了最佳的 0.4462 HD-Score。这些结果验证了 V-JEPA 原生世界-动作建模作为自动驾驶规划中强大且可扩展范式的价值。代码见：https://github.com/AFARI-Research/WA-JEPA。

引言

端到端 (E2E) 自动驾驶通过学习一个将原始传感器观测直接映射为驾驶动作的统一模型，区别于传统的" 感知—规划" 流水线，从而消除模块化架构中固有的误差累积与计算低效 (Hu et al. 2023)。尽管这一理念颇具吸引力，传统 E2E 方法 (Jiang et al. 2023; Sun et al. 2025) 仍高度依赖特定领域的感知监督（例如目标检测、语义分割与占用预测），且缺乏显式推理能力，从根本上限制了其在罕见与长尾驾驶场景中的鲁棒性。

近年来，两类新兴范式试图赋予 E2E 驾驶模型更接近人类驾驶行为的推理能力。第一类是视觉-语言-动作 (VLA) 范式 (Li et al. 2025e; Xu et al. 2025a; Li et al. 2025d; Jia et al. 2026)，它利用视觉-语言模型 (VLM) 的语言理解能力，从稀疏视觉观测中作出驾驶决策。原则上，这使模型能够通过自然语言对复杂交通状况进行推理。然而，大多数 VLA 方法 (Chen, Wang, and Zhang 2025; Li et al. 2025a) 只是学习从密集视觉输入到稀疏动作输出的直接映射，存在严重的监督赤字 (Li et al. 2025d)：丰富的感知信号与极少的动作监督之间的巨大信息瓶颈，使模型难以得到充分约束。

第二类是世界-动作模型 (WAM) (Li et al. 2025d; Xia et al. 2025; Huang et al. 2026; Wang et al. 2026b; Shi et al. 2026; Liu et al. 2026a)，其思路截然不同：WAM 不再依赖语言作为推理媒介，而是借助视频生成模型的视觉推理能力 (Wan et al. 2025; HaCohen et al. 2024)——即在像素层面预测未来场景动态的能力——来引导动作决策。由于未来帧预测天然提供密集的自监督信号、且无需昂贵的感知标注，WAM 为监督赤字问题 (Li et al. 2025d) 提供了一种有前景的解决方案。关键在于，这一范式不依赖语言推理，因此可以说更贴合驾驶所涉及的视觉预见能力。然而，许多基于视频生成的 WAM 在一个由变分自编码器 (VAE) 压缩的隐空间中进行世界建模。这种语义贫乏、时空语义受限的表示空间，可能制约模型对动态演化的驾驶世界的理解与推理能力。由此引出一个问题：*我们能否丰富支撑 WAM 的隐表征的时空语义，从而赋予其更强的时空推理能力，并最终获得更优的驾驶性能？*

与此同时，世界模型研究的一个重要分支——视频联合嵌入预测架构 (V-JEPA) 家族 (Bardes et al. 2024; Assran et al. 2025)——发展出特征层面的掩码建模，用于从海量视频语料中自监督学习时空表征。这些表征能够有效迁移到广泛的下游视觉理解任务中，展现出卓越的时空语义丰富性。然而，V-JEPA 在架构上并不适合规划任务，原因有三。第一，V-JEPA 预训练对视频施加随机时空掩码，训练模型从部分掩码的上下文中预测完整特征序列。这在本质上是一个补全目标，缺乏规划所必需的面向未来的预测能力。第二，V-JEPA 通过回归来完成这种掩码预测，虽足以在其余已观测的时间上下文中填补缺失的块，却不足以生成完全未见的未来 token——后者本质上需要生成式建模。第三，尽管 V-JEPA 可以微调用于动作条件的未来预测 (Assran et al. 2025)，但距离可执行的规划仍有巨大鸿沟：现有方法需要一张目标图像，并依赖带多轮优化的模型预测控制 (MPC) 来恢复动作，远未达到交互式在线规划的要求。

本文重新思考面向自动驾驶世界-动作建模的 V-JEPA 范式。我们的目标是保留并利用 V-JEPA 强大的时空表征能力，同时从根本上为其扩展因果未来生成能力，并将其与动作联合建模。由此得到一种新颖的 V-JEPA 原生世界-动作模型范式，我们称之为 **WA-JEPA**。我们的核心技术创新包括三项关键设计：**(1) 混合未来掩码预训练**。与采用随机时空掩码训练上下文补全模型的原始 V-JEPA 不同，我们引入一种精心设计的混合未来掩码策略：模型观测过去帧并预测未来帧的时空特征。这赋予 V-JEPA 未来预测能力，使预训练目

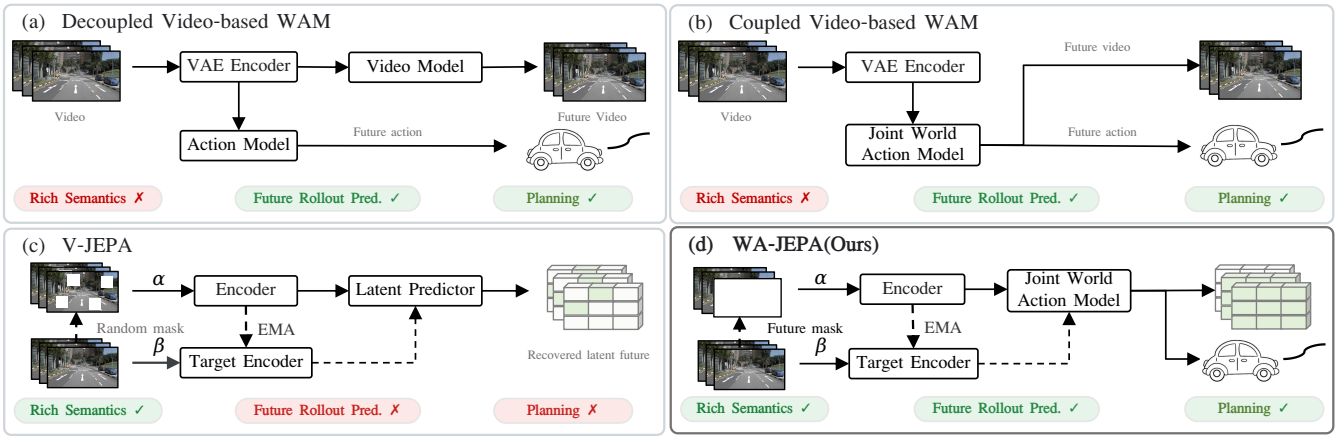


图 1: V-JEPA、基于视频的世界-动作模型与本文 WA-JEPA 的对比。本文方法通过未来帧掩码将语义表征学习与预测式世界建模连接起来。

标直接对齐规划对前向预测的需求。**(2) 基于 V-JEPA 的流匹配世界建模**。不同于原始 V-JEPA 从上下文回归掩码特征的做法，我们将未来预测重构为时空特征空间上的基于流的生成过程。这种生成式表述显著提升了模型生成合理未来的能力，为下游规划提供了更丰富的证据基础。**(3) 基于 V-JEPA 的联合世界-动作建模**。原始 V-JEPA 只对视觉观测到的世界进行建模，我们则扩展其架构，在统一的时空隐空间中联合建模世界状态与自车动作。视觉表征与动作表征之间的这种紧耦合，使得 V-JEPA 原生框架能够在单一连贯的框架内完成未来推理与决策。

本文的主要贡献总结如下：

- 本文提出 V-JEPA 原生世界-动作模型 WA-JEPA，利用 V-JEPA 强大的时空表征来强化联合世界-动作建模，显著提升自动驾驶的规划能力。
- 本文引入一系列架构创新——用于预训练的混合未来掩码、通过流匹配实现的隐空间世界建模，以及联合世界-动作建模——系统性地将 V-JEPA 架构适配到规划任务，同时精心保留其核心的表征学习优势。
- 在开环 NAVSIM-v1 与 NAVSIM-v2 基准上的大量实验确立了新的最优水平，而在闭环模拟器 HUGSIM (Zhou et al. 2024b) 上的零样本评估表明该增益能够延续到闭环驾驶。

相关工作

端到端驾驶与世界-动作模型。 E2E 驾驶将传感器观测直接映射为自车运动 (Hu et al. 2023; Jiang et al. 2023; Liao et al. 2025)，而 VLA 模型则融入语言推理或 VLM 引导的轨迹细化 (Shao et al. 2024; Hwang et al. 2024; Zhou et al. 2026; Wang et al. 2026c)。WAM 通过可学习的未来场景预测来增强直接规划 (Wang et al. 2024; Li et al. 2025c; Zhu et al. 2026; Wang et al. 2026b; Hong et al. 2026; Li et al. 2025d)。如图 1(a) 所示，现有 WAM 在世界表征的选择以及未来场景预测与动作生成的耦合方式上各有不同。特别地，耦合式基于视频的 WAM 在共享生成过程中联合建模未来视觉内容与动作，使用视频生成先验或视频隐变量 (Liu et al. 2026a; Shi et al. 2026)，如图 1(b) 所示。尽管这种耦合为未来场景生成与规划之间提供了直接接口，这些方法仍继承了视频生成隐空间的局限：其表征主要面向视觉生成与重建而优化，这可能限制语义抽象以及对与动作相关的未来状态的建模。

用于世界-动作建模的预测式表征。 近年来的世界-动作模型探索了超越像素级重建的预测式表征。Latent-WAM 使用空间感知的隐场景表征进行未来世界建模与轨迹规划 (Wang et al. 2026b)，而 DINO-WM 则从预训练 DINOv2 编码器中预测未来特征，以支持动作条件的规划 (Zhou et al. 2024a)。如图 1(c) 所示，基于 JEPA 的方法通过预测目标嵌入而非重建 (Bardes et al. 2024; Assran et al. 2025) 来学习强大的时空表征。然而，V-JEPA 主要提供预测式视觉表征，并未直接说明应如何将这些表征转换为未来动作或规划决策。Drive-JEPA 试图通过将 V-JEPA 编码器引入端到端驾驶模型来弥合这一差距，但仍依赖单独的下游轨迹规划器 (Wang et al. 2026a)。相比之下，WA-JEPA 将预测式表征学习扩展为在共享的预测式表征中联合预测未来世界特征与自车轨迹。

方法

预备知识

本文方法深受 V-JEPA 2 (Assran et al. 2025) 的启发，后者在隐空间中学习预测式表征，而非重建原始像素。如图 1 (c) 所示，给定掩码观测 α 与目标观测 β，V-JEPA 2 训练一个预测器，从上下文隐变量推断目标隐变量：

$$\min_{\theta,\psi} \left\| P_\psi(E_\theta(\alpha)) - \mathrm{sg}(E_{\bar{\theta}}(\beta)) \right\|_1, \tag{1}$$

其中 E_θ 为在线编码器，$E_{\bar{\theta}}$ 为目标编码器，P_ψ 为隐变量预测器，$\mathrm{sg}(\cdot)$ 表示停止梯度。目标编码器通过指数滑动平均 (EMA) 更新：

$$\bar{\theta} \leftarrow \mu\bar{\theta} + (1-\mu)\theta, \tag{2}$$

其中 μ 为 EMA 动量系数。

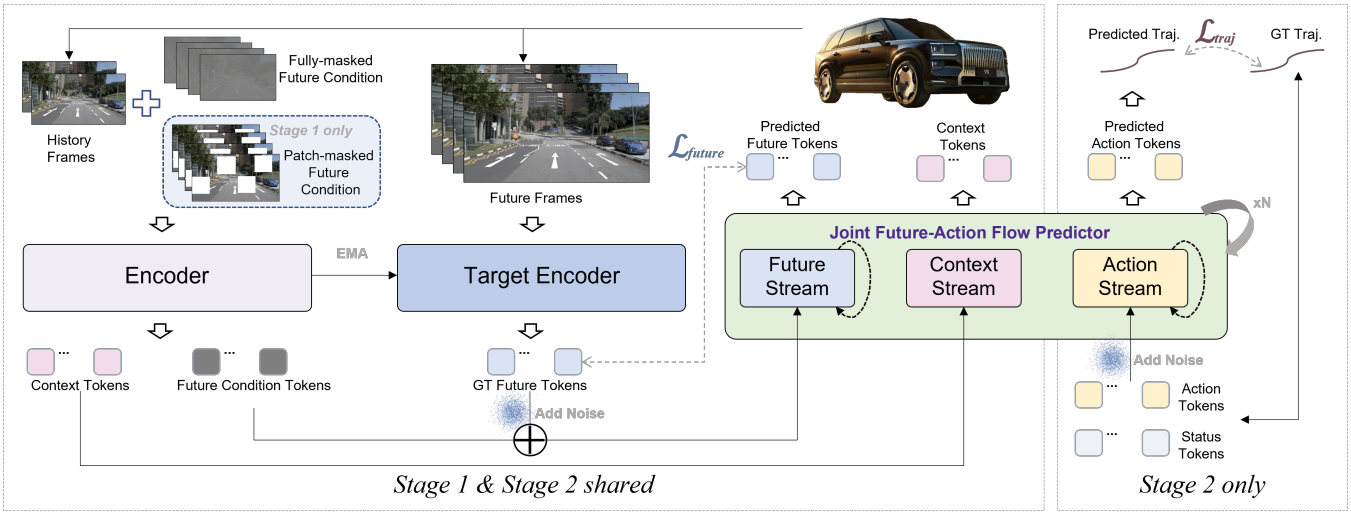


图 2: WA-JEPA 总览。第一阶段将 V-JEPA 2 适配到多视角驾驶视频，在全未来掩码与块级掩码下预测未来表征。第二阶段从该检查点初始化，并利用联合未来-动作流预测器联合预测未来场景表征与自车动作。

总览

本文将端到端自动驾驶建模为条件式的未来-动作生成。给定历史多视角观测 $\mathcal{X}_{1:H}$、自车状态 s 与历史动作 $\mathcal{Y}_{1:H}$，模型通过如下映射预测未来动作：

$$f_\theta\left(\mathcal{X}_{1:H}, s, \mathcal{Y}_{1:H}\right) \mapsto \hat{\mathcal{Y}}_{H+1:H+K} = \left\{\left(\hat{x}_k, \hat{y}_k, \hat{\phi}_k\right)\right\}_{k=1}^{K}, \tag{3}$$

其中 f_θ 表示由 θ 参数化的世界-动作模型，H 与 K 分别表示历史帧与未来帧的数量。这里，$(\hat{x}_k, \hat{y}_k)$ 与 $\hat{\phi}_k$ 表示在 K 步规划时域内第 k 个未来帧上预测的自车位置与航向。

如图 2 所示，WA-JEPA 采用两阶段训练方案。第一阶段通过混合掩码策略下的未来表征预测，将预训练的 V-JEPA 2 适配到多视角驾驶数据。第二阶段加入动作监督，并为预测器扩展动作流，从而联合预测未来场景表征与自车动作。

第一阶段：混合未来掩码预训练

第一阶段采用混合目标，在同步多视角驾驶观测上结合因果的全掩码分支与块掩码补全分支，且不使用动作监督。前者学习严格的从过去到未来的动态，后者则保留部分未来上下文以促进表征学习，并保留 V-JEPA 2 的部分掩码范式。

多视角时空编码器。 本文采用预训练的 V-JEPA 2 ViT-L 作为视觉骨干。每个训练样本包含来自 C 个同步相机的历史帧与未来帧：

$$\mathcal{X}_{1:H+K} = \left[\mathcal{X}_{1:H}, \mathcal{X}_{H+1:H+K}\right], \qquad \mathcal{X}_t = \{X_t^c\}_{c=1}^{C}, \tag{4}$$

其中 X_t^c 表示第 c 个相机在第 t 个时间步的帧。

随后，模型将每个相机流视为独立视频，并用共享的在线编码器对所有视角独立处理以生成视觉 token。训练期间，历史 token 始终保持可见，掩码只施加于未来 token。具体地，本文采用结合全未来掩码与块掩码未来补全的混合策略。全掩码将所有未来 token 指定为预测目标，因此要求仅从历史上下文进行预测。块掩码保留部分未来 token 作为可见条件，并预测其余被掩码的 token，在降低学习难度的同时保留 V-JEPA 2 的部分掩码预测风格。

由历史帧得到的输出作为上下文场景 token $\mathcal{Z}_{\text{ctx}}$：

$$\mathcal{Z}_{\text{ctx}} = E_\theta\left(\mathcal{X}_{1:H}\right). \tag{5}$$

对于未来帧，掩码模式 $M^{(m)}$（其中 $m \in \{\text{full}, \text{patch}\}$）在在线编码器之前施加，使得只有可见的未来块被提供给 E_θ。模型随后将编码得到的可见 token 与可学习掩码 token Z_{mask} 组合，构造未来条件 token：

$$Z_{\text{cond}}^{(m)} = \Phi^{(m)}\left(Z_{\text{mask}}, E_\theta\left(X_{H+1:H+K}, M^{(m)}\right)\right), \tag{6}$$

其中 $\Phi^{(m)}(\cdot)$ 表示一种掩码感知的填充-散布操作。它先用可学习掩码 token 初始化完整的未来 token 序列，再按掩码模式将编码后的可见未来 token 散布回其原始位置。在全掩码下，在线编码器不会接收任何未来块，因此 $Z_{\text{cond}}^{(\text{full})}$ 完全由可学习掩码 token 组成。

与此同时，EMA 目标编码器为未来帧提供无掩码的目标表征，得到干净的未来场景目标 $\mathcal{Z}_{\text{future}}^*$：

$$\mathcal{Z}_{\text{future}}^* = E_{\bar{\theta}}\left(\mathcal{X}_{H+1:H+K}\right). \tag{7}$$

这些目标表征仅用于为未来场景提供隐变量监督。

基于流的隐变量未来预测。 本文采用流匹配进行未来隐变量预测。本文采用干净隐变量（x-预测）参数化的条件流匹配进行未来隐变量预测。首先，我们采样与未来场景 token 维度相同的高斯噪声 $\epsilon_{\text{future}} \sim \mathcal{N}(0, I)$ 以及连续流时间 t。在时间 t 处的含噪未来场景 token $\mathcal{Z}_t$ 通过线性插值得到：

$$\mathcal{Z}_t = (1-t)\epsilon_{\text{future}} + t\mathcal{Z}_{\text{future}}^*. \tag{8}$$

未来流预测器接收历史上下文 $\mathcal{Z}_{\text{ctx}}$、未来条件 $\mathcal{Z}_{\text{cond}}$、含噪未来场景 token $\mathcal{Z}_t$ 与时间条件 t，并预测干净的未

来场景 token $\hat{\mathcal{Z}}_{\text{future}}$：

$$\hat{\mathcal{Z}}_{\text{future}} = P_\psi^{\text{future}}\left(\mathcal{Z}_{\text{ctx}}, \mathcal{Z}_{\text{cond}}, \mathcal{Z}_t, t\right). \tag{9}$$

未来流预测器采用 MMDiT（多模态扩散 Transformer）风格 (Esser et al. 2024) 的设计，主要在上下文场景 token 与未来场景 token 之间执行联合自注意力。

训练目标。 在第一阶段，模型在 nuPlan 数据集的多视角驾驶观测上进行预训练。在此阶段，模型通过干净未来隐变量预测上的均方误差 (MSE) 损失进行优化：

$$\mathcal{L}_{\text{Stage 1}} = \mathcal{L}_{\text{future}} = \frac{1}{N}\left\|\hat{\mathcal{Z}}_{\text{future}} - \text{sg}\left(\mathcal{Z}^*_{\text{future}}\right)\right\|_2^2, \tag{10}$$

其中 N 表示参与损失计算的未来场景 token 数量。该干净隐变量目标即对应上文所述条件流匹配的 x-预测参数化。

第二阶段：联合世界-动作建模

第二阶段引入动作生成流，在统一模型中联合建模未来场景表征与动作。模型使用第一阶段的预训练权重进行初始化，并通过动作监督进一步适配动作规划任务。

联合未来-动作预测器。 在第二阶段，联合预测器进一步纳入历史动作与紧凑的自车状态。它们共同作为未来动作生成的自车运动条件。与第一阶段不同，第二阶段仅使用全未来掩码，以保持与驾驶因果性质的一致性。未来图像仅用于构造未来场景隐变量预测的监督信号，不作为输入提供给学生预测器。

对于动作流，我们首先对真值未来动作进行归一化，并在归一化动作空间中构造含噪动作：

$$\begin{aligned} \tilde{\mathcal{Y}}_t &= (1-t)\epsilon_y + t\bar{\mathcal{Y}}_{H+1:H+K}, \quad \epsilon_y \sim \mathcal{N}(0, I), \\ \bar{\mathcal{Y}}_{H+1:H+K} &= \text{Norm}(\mathcal{Y}_{H+1:H+K}), \end{aligned} \tag{11}$$

其中 $\text{Norm}(\cdot)$ 表示动作归一化操作，$\bar{\mathcal{Y}}_{H+1:H+K}$ 表示归一化后的真值未来动作，ϵ_y 表示与未来动作维度相同的高斯噪声，$\tilde{\mathcal{Y}}_t$ 表示时间 t 处的含噪未来动作。

随后，含噪未来动作 $\tilde{\mathcal{Y}}_t$、历史动作 $\mathcal{Y}_{1:H}$ 与自车状态 s 分别编码并拼接，形成动作 token $\mathcal{T}_{\text{act}}$：

$$\begin{aligned} \mathcal{T}_{\text{act}} &= \text{Concat}\left[\mathcal{T}_n, \mathcal{T}_h, \mathcal{T}_s\right], \\ \mathcal{T}_n = F_n(\tilde{\mathcal{Y}}_t), &\quad \mathcal{T}_h = F_h(\mathcal{Y}_{1:H}), \quad \mathcal{T}_s = F_s(s). \end{aligned} \tag{12}$$

其中 F_n 为线性投影，F_h 与 F_s 为 MLP 编码器。

联合预测器在时间 t 处对历史上下文场景 token $\mathcal{Z}_{\text{ctx}}$、未来场景 token $\mathcal{Z}_{\text{cond}}$ 与含噪未来场景 token $\mathcal{Z}_t$，以及动作 token $\mathcal{T}_{\text{act}}$ 之间的交互进行建模。其未来场景与动作输出流分别定义为

$$\begin{aligned} \hat{\mathcal{Z}}_{\text{future}} &= P_\psi^{\text{future}}\left(\mathcal{Z}_{\text{ctx}}, \mathcal{Z}_{\text{cond}}, \mathcal{Z}_t, \text{sg}(\mathcal{T}_{\text{act}}), t\right), \\ \hat{\mathcal{Y}}_{H+1:H+K} &= P_\psi^{\text{act}}\left(\mathcal{Z}_{\text{ctx}}, \mathcal{Z}_{\text{cond}}, \mathcal{Z}_t, \mathcal{T}_{\text{act}}, t\right). \end{aligned} \tag{13}$$

这里，P_ψ^{future} 与 P_ψ^{act} 分别表示同一联合预测器的未来场景与动作输出流（而非两个独立预测器），该联合预测器同样采用 MMDiT 风格设计。在第二阶段使用的全掩码设置下，$Z_{\text{cond}} = Z_{\text{cond}}^{(\text{full})}$ 完全由可学习掩码 token 组成，因此联合预测器看不到任何未来图像内容。$\hat{\mathcal{Y}}_{H+1:H+K}$ 表示预测的归一化未来动作。我们仅在未来的场景输出流中对动作 token 施加停止梯度 $\text{sg}(\cdot)$，防止未来场景预测损失更新动作流。该设计的更多细节与分析见附录 C。

训练目标。 未来场景流沿用第一阶段定义的未来场景预测损失。该目标在动作监督微调期间保留模型的未来场景建模能力。动作流在归一化动作空间中预测去噪后的未来动作，并通过所有未来步上预测动作与真值动作之间的 MSE 进行优化：

$$\begin{aligned} \mathcal{L}_{\text{act}} &= \frac{1}{K}\sum_{k=1}^{K}\left\|\hat{\bar{\mathbf{y}}}_k - \bar{\mathbf{y}}_k\right\|_2^2, \\ \bar{\mathbf{y}}_k &= \text{Norm}\left(x_k, y_k, \phi_k\right), \end{aligned} \tag{14}$$

其中 $\bar{\mathbf{y}}_k$ 表示第 k 个未来帧上的归一化真值动作，$\hat{\bar{\mathbf{y}}}_k$ 表示对应的预测归一化动作。

最终，第二阶段的总训练目标为

$$\mathcal{L}_{\text{Stage 2}} = \lambda_{\text{future}}\mathcal{L}_{\text{future}} + \lambda_{\text{act}}\mathcal{L}_{\text{act}}. \tag{15}$$

这里，λ_{future} 与 λ_{act} 分别为未来场景损失与动作损失的加权系数。

规划推理。 在推理阶段，模型仅以历史多视角观测、历史动作与自车状态作为输入。未来场景隐变量与归一化未来动作由高斯噪声初始化。在每个采样步，联合预测器估计它们的干净端点，这些端点被转换为沿线性流路径的速度并进行迭代积分。此过程不需要任何未来图像或真值未来动作。

采样完成后，预测的归一化动作被变换回原始动作空间，得到最终未来动作：

$$\hat{\mathcal{Y}}_{H+1:H+K} = \text{Norm}^{-1}\left(\hat{\bar{\mathcal{Y}}}_{H+1:H+K}\right). \tag{16}$$

这里，$\text{Norm}^{-1}(\cdot)$ 表示动作反归一化操作。

实验

实验设置

数据集、基准与指标。 在第一阶段，模型在 nuPlan 的多视角驾驶视频上预训练；第二阶段在官方 NAVSIM `navtrain` 划分上训练。评估在留出的 `navtest` 划分上，于 NAVSIM-v1 与 NAVSIM-v2 (Dauner et al. 2024; Cao et al. 2025) 下进行，使用官方 PDMS 与 EPDMS 分数及其子指标，其定义见附录 D。

实现细节。 模型以 256×512 分辨率接收来自左、前、右、后四个相机的四帧历史画面，并以 2 Hz 预测八个动作。视觉编码器由第一阶段预训练的 V-JEPA 2 ViT-L 骨干初始化。未来场景流与动作流使用 AdamW、bfloat16 精度与 DeepSpeed ZeRO-2 联合优化。第一阶段与第二阶段分别使用 64 与 32 块 NVIDIA A800 GPU，每 GPU 批大小为 4。编码器、场景投影器与联合预测器的学习率分别为 1×10^{-5}、1×10^{-4} 与 1.5×10^{-4}，权重衰减为 0.04。在推理阶段，WA-JEPA 联合未来-动作预测器使用 4 个采样步。我们使用一组固定的 10 个种子评估其随机预测并报告均值，而确定性基线仅评估一次。详细设置见附录 C。

方法	骨干	NC↑	DAC↑	DDC↑	TLC↑	EP↑	TTC↑	LK↑	HC↑	EC↑	EPDMS* ↑	EPDMS↑
端到端方法												
TransFuser (Chitta et al. 2022)	RegNetY-3.2GF	96.9	89.9	97.8	99.7	87.1	95.4	92.7	98.3	87.2	76.7	–
ARTEMIS (Feng et al. 2025)	ResNet-34	98.3	95.1	98.6	99.8	81.5	97.4	96.5	98.3	–	83.1	–
Hydra-MDP++ (Li et al. 2025b)	V2-99	98.8	97.8	99.1	100	84.0	95.3	70.1	–	96.8	84.1	–
DiffusionDrive (Liao et al. 2025)	ResNet-34	98.2	95.9	99.4	99.8	87.5	97.3	96.8	98.3	87.7	–	84.5
Drive-JEPA (Wang et al. 2026a)	ResNet-34	98.8	97.4	99.0	99.8	83.5	98.0	96.2	98.1	85.6	85.4	–
Drive-JEPA† (Wang et al. 2026a)	ViT-L	98.4	98.6	99.1	99.8	88.4	97.8	97.6	97.9	84.8	87.8	–
DiffusionDriveV2 (Zou et al. 2025)	ResNet-34	97.7	96.6	99.2	99.8	88.9	97.2	96.0	97.8	91.0	85.5	87.5
DriveSuprim (Yao et al. 2025)	V2-99	97.8	97.9	99.5	99.9	90.6	97.1	96.6	98.3	77.9	86.0	–
SparseDriveV2 (Sun et al. 2026)	ResNet-34	98.1	98.1	99.6	99.8	91.1	97.3	96.9	98.2	78.4	86.7	90.1
VLA 方法												
ReCogDrive (Li et al. 2025e)	InternVL3	98.3	95.2	99.5	99.8	87.1	97.5	96.6	98.3	86.5	83.6	–
WAM-Flow (Xu et al. 2025b)	Janus-1.5B	98.5	94.5	99.5	99.8	86.9	96.8	97.4	97.6	73.9	84.7	–
WAM-Diff (Xu et al. 2025a)	LLaDA-V	99.0	98.4	99.3	99.9	87.0	98.6	96.2	98.1	78.5	–	89.7
世界-动作与世界模型方法												
DriveVLA-W0 (Li et al. 2025d)	Emu3-8B	98.5	99.1	98.0	99.7	86.4	98.1	93.2	97.9	58.9	86.1	–
DriveWorld-VLA (Jia et al. 2026)	InternVL	98.6	99.1	99.6	99.8	87.4	97.9	97.0	97.8	78.6	–	86.8
CoWorld-VLA (Huang et al. 2026)	Qwen3	99.1	97.0	99.6	99.9	87.9	98.5	97.7	98.2	86.2	86.2	90.0
DreamerAD (Yang et al. 2026)	Transformer-1.3B	98.0	97.2	99.5	99.8	87.8	97.4	97.5	98.3	72.4	–	87.7
Latent-WAM (Wang et al. 2026b)	DINOv2-B	98.1	97.3	99.6	99.8	87.7	97.3	97.6	98.1	87.3	–	89.3
DriveFuture (Hong et al. 2026)	V2-99	98.8	99.1	99.6	99.9	86.6	98.4	96.4	98.3	74.8	86.4	89.9
Discrete-WAM (Yao et al. 2026)	Transformer-1B	98.5	98.2	99.7	99.8	90.5	97.9	97.2	98.3	78.1	87.0	90.4
WA-JEPA（本文）	ViT-L	99.4	98.2	99.7	99.9	87.8	98.9	98.3	98.3	88.1	**88.0**	**91.7**

表 1: 在 NAVSIM-v2 `navtest` 上与现有最优方法的对比。方法按建模范式分组。骨干列出各方法使用的主视觉或视觉-语言骨干网络。† 表示使用了辅助模拟器衍生监督的结果。EPDMS* 指在修正人类参考惩罚过滤聚合之前得到的分数，而 EPDMS 报告修正后的分数。

	WA-JEPA	LTF	DrivoR	UniAD	VAD
全部 436 个场景					
NC	**0.6856**	0.4428	0.5217	0.6555	0.4117
DAC	**0.9635**	0.9275	0.9559	0.9320	0.9028
TTC	**0.6120**	0.3751	0.4620	0.5156	0.2798
Comf.	0.6620	0.9478	0.9390	0.6633	**0.9534**
PDMS	**0.5717**	0.3653	0.4475	0.4940	0.2831
RC	**0.5689**	0.3804	0.4721	0.4383	0.3006
HD-Score	**0.4462**	0.2310	0.3252	0.3124	0.1393
按难度级别划分的 HD-Score					
简单 (n=80)	**0.7977**	0.6608	0.7799	0.6395	0.4197
中等 (n=157)	**0.5563**	0.1547	0.2911	0.3718	0.0849
困难 (n=96)	**0.3060**	0.1204	0.2000	0.2099	0.0770
极端 (n=103)	0.1362	0.1167	**0.1407**	0.0632	0.0626

表 2: HUGSIM 上的零样本闭环结果。数值采用 $[0, 1]$ 区间；数值越大越好，每行最优结果加粗。

基线。 我们在兼容的输入模态与评测协议下，将 WA-JEPA 与代表性的 E2E、VLA 与 WAM 基线进行比较。

与现有方法对比

定量结果。 如表 1 所示，WA-JEPA 在 NAVSIM-v2 上达到 91.7 EPDMS，比表现最佳的 E2E 方法 SparseDriveV2 高出 1.6，比表现最佳的 WAM 方法 Discrete-WAM 高出 1.3。在 NAVSIM-v1（表 3）上，WA-JEPA 取得了 91.8 PDMS。

方法	NC↑	DAC↑	TTC↑	Comf.↑	EP↑	PDMS↑
端到端方法						
TransFuser	97.7	92.8	92.8	100	79.2	84.0
DiffusionDrive	98.2	96.2	94.7	100	82.2	88.1
Drive-JEPA	98.7	96.2	95.5	100	82.9	89.0
VLA 方法						
ReCogDrive	97.9	97.3	94.9	100	87.3	90.8
WAM-Flow	99.2	98.3	97.0	99.7	82.3	90.3
WAM-Diff	99.1	98.3	96.5	99.9	84.4	91.0
世界-动作与世界模型方法						
CoWorld-VLA	99.1	96.9	96.4	100	83.9	89.9
DriveVLA-W0	98.7	99.1	95.3	99.3	83.3	90.2
DriveWorld-VLA	99.1	98.2	96.1	100	85.9	91.3
DriveLaW	99.0	97.1	96.7	100	81.3	89.1
DriveFuture	98.8	99.1	95.4	100	84.2	90.7
WA-JEPA（本文）	99.5	98.3	97.7	100	85.0	**91.8**

表 3: 在 NAVSIM-v1 `navtest` 上的对比。

零样本闭环泛化。 我们在 436 个 HUGSIM 场景 (Zhou et al. 2024b) 上将 WA-JEPA 与 LTF (Chitta et al. 2022)、DrivoR (Kirby et al. 2026)、UniAD (Hu et al. 2023) 与 VAD (Jiang et al. 2023) 进行对比。WA-JEPA 的两个训练阶段既未使用 HUGSIM 渲染的观测，也未使用其四个源数据集中的任何一个；DrivoR 同样满足

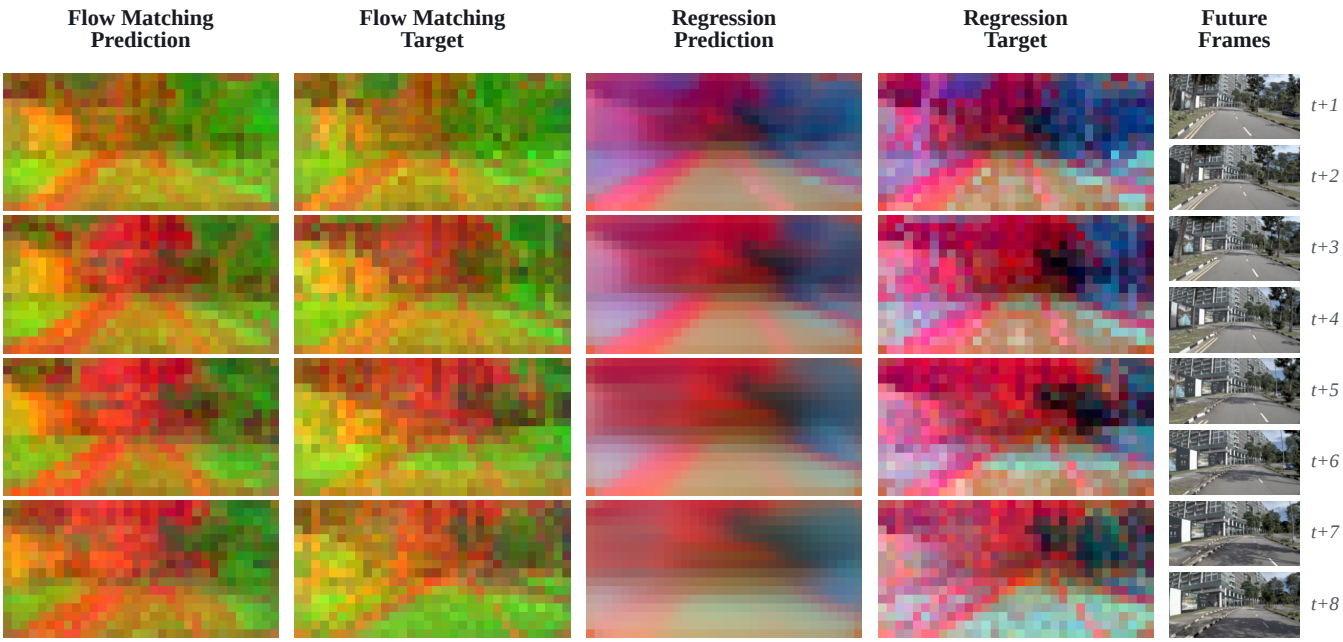


图 3: 流匹配 (FM) 与直接回归 (Reg.) 的未来隐变量预测的以目标为参照的 PCA 可视化。对于每种方法，分别对其 EMA 目标表征拟合 PCA 基，并同时应用于目标与预测隐变量。每张图表示两个连续的未来帧。

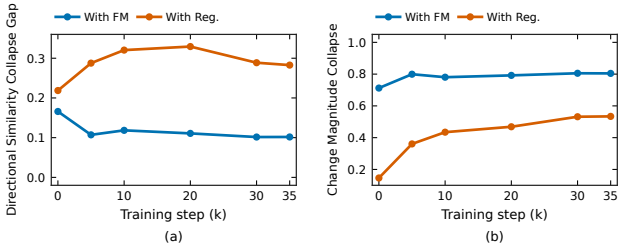


图 4: 流匹配 (FM) 与直接回归 (Reg.) 的时序表征保持情况。方向相似性坍缩间隙越低、变化幅度坍缩越接近 1，表示对目标时序动态的保持越好。

源数据集互斥。所有方法都遵循附录 A 中详述的共同协议，共享相同的场景、控制器、指令、聚合方式与指标实现，同时保留各自的原始传感器配置。

如表 2 所示，WA-JEPA 取得了最佳的 NC、DAC、TTC、PDMS、RC 与 HD-Score，将 HD-Score 从 0.3252 提升到 0.4462。这一结果表明，联合世界-动作预训练能够有效迁移到闭环控制，其中在中等级别与困难级别上增益最大。

定性评估。 定性结果见附录 B，包括闭环 HUGSIM 回放与 NAVSIM 轨迹对比。

消融研究

视觉编码器初始化。 表 4(a) 隔离了视觉编码器的贡献。所有变体都直接进行第二阶段训练、不经过任何第一阶段预训练，因此各模型共享相同的第二阶段架构、训练数据与优化协议，仅在编码器初始化方式上不同。公开发布的 V-JEPA 2 权重达到 89.5 EPDMS，比最强的替代方案 MAE 与 DINOv3 高出 5.7 EPDMS，而三种图像级自监督与视觉-语言初始化彼此相差在 0.7 EPDMS 以内。因此，这一差距源于 V-JEPA 2 的预训练目标，而非图像级目标之间的选择，这促使我们采用 V-JEPA 2 编码器作为世界-动作模型的骨干。

第一阶段掩码策略。 表 4(b) 消融了第一阶段的掩码设计。第一行直接使用原始预训练的 V-JEPA 2 检查点、不经过我们在 nuPlan 上的第一阶段预训练，作为无第一阶段的基线，其 EPDMS 为 89.5。仅施加块掩码即可将 EPDMS 提升至 91.0，因为它为表征学习提供了部分未来上下文；而全掩码通过强制严格的因果从过去到未来预测达到 91.3。结合两种策略可获得 91.7 的最佳性能，分别比单独变体高出 0.7 与 0.4。这表明块掩码与全掩码提供了互补的训练信号。

第二阶段场景-动作耦合与未来预测。 表 4(c) 消融了第二阶段的场景-动作建模与未来隐变量监督。第一个级联基线仅通过交叉注意力使用历史隐特征，得到 89.9 EPDMS。加入独立的基于流的未来预测器、并通过相同的交叉注意力设计注入其预测的未来隐变量，可将 EPDMS 提升至 90.8。在联合建模下，无显式未来隐变量监督的基线达到 91.1。加入直接回归会使 EPDMS 降至 90.7，而基于流的未来预测则取得 91.7 的最佳结果。这些结果表明，未来场景预测与联合场景-动作建模是互补的，而预测目标的选择同样重要。

未来表征分析。 为考察两种预测目标如何影响未来表征，图 4 报告了两个以目标为参照的指标。方向相似性坍缩间隙衡量预测相对目标表征的过度跨步相似性（越低越好），而变化幅度坍缩衡量预测相对目标的时序变

编码器	EPDMS↑
MAE	83.8
SigLIP2	83.1
DINOv3	83.8
V-JEPA 2	**89.5**

(a) 编码器

块掩码	全掩码	EPDMS↑
		89.5
✓		91.0
	✓	91.3
✓	✓	**91.7**

(b) 第一阶段预训练

联合	未来预测		EPDMS↑
	FM	Reg.	
			89.9
	✓		90.8
✓			91.1
✓		✓	90.7
✓	✓		**91.7**

(c) 第二阶段组件

表 4: NAVSIM-v2 `navtest` 上的消融实验。(a) 视觉编码器选择。(b) 第一阶段的掩码策略。第一行表示跳过第一阶段预训练、直接使用原始预训练 V-JEPA 2 进行第二阶段训练的基线。(c) 第二阶段的联合未来-动作预测器与未来预测方法。FM 与 Reg. 分别表示流匹配与直接回归。第一行表示仅动作的第二阶段基线，其从第一阶段检查点初始化，并以动作监督微调，不含联合场景-动作建模或未来预测。

化（越接近 1 越好）。详细定义见附录 E。与直接回归相比，流匹配将方向相似性坍缩间隙从 0.30 降至 0.10，并将变化幅度坍缩从 0.45 提升到 0.80。图 3 提供了互补的定性证据：流匹配在预测时域内保留了更清晰的空间结构，而直接回归则逐渐趋于平滑。

结论

本文提出了 WA-JEPA，一种 V-JEPA 原生世界-动作模型，将 V-JEPA 2 从视觉表征学习扩展到面向自动驾驶的未来预测式规划。通过结合混合未来掩码预训练、基于流匹配的未来隐变量预测以及联合未来-动作建模，WA-JEPA 在共享的时空隐空间中学习未来场景动态与动作。WA-JEPA 在 NAVSIM-v2 `navtest` 上达到 91.7 EPDMS，并在 436 个 HUGSIM 闭环场景上取得 0.4462 HD-Score，展现出强大的开环规划能力与零样本闭环泛化能力。

参考文献

Assran, M.; Bardes, A.; Fan, D.; Garrido, Q.; Howes, R.; Komeili, M.; Muckley, M.; Rizvi, A.; Roberts, C.; Sinha, K.; Zholus, A.; Arnaud, S.; Gejji, A.; Martin, A.; Hogan, F. R.; Dugas, D.; Bojanowski, P.; Khalidov, V.; Labatut, P.; Massa, F.; Szafraniec, M.; Krishnakumar, K.; Li, Y.; Ma, X.; Chandar, S.; Meier, F.; LeCun, Y.; Rabbat, M.; and Ballas, N. 2025. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. arXiv:2506.09985.

Bardes, A.; Garrido, Q.; Ponce, J.; Chen, X.; Rabbat, M.; LeCun, Y.; Assran, M.; and Ballas, N. 2024. Revisiting Feature Prediction for Learning Visual Representations from Video. arXiv:2404.08471.

Cao, W.; Hallgarten, M.; Li, T.; Dauner, D.; Gu, X.; Wang, C.; Miron, Y.; Aiello, M.; Li, H.; Gilitschenski, I.; Ivanovic, B.; Pavone, M.; Geiger, A.; and Chitta, K. 2025. Pseudo-Simulation for Autonomous Driving. arXiv:2506.04218.

Chen, Y.; Wang, Y.; and Zhang, Z. 2025. Drivinggpt: Unifying driving world modeling and planning with multi-modal autoregressive transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 26890–26900.

Chitta, K.; Prakash, A.; Jaeger, B.; Yu, Z.; Renz, K.; and Geiger, A. 2022. TransFuser: Imitation with Transformer-Based Sensor Fusion for Autonomous Driving. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. doi:10.1109/TPAMI.2022.3200245.

Dauner, D.; Hallgarten, M.; Li, T.; Weng, X.; Huang, Z.; Yang, Z.; Li, H.; Gilitschenski, I.; Ivanovic, B.; Pavone, M.; Geiger, A.; and Chitta, K. 2024. NAVSIM: Data-Driven Non-Reactive Autonomous Vehicle Simulation and Benchmarking. arXiv:2406.15349.

Esser, P.; Kulal, S.; Blattmann, A.; Entezari, R.; Müller, J.; Saini, H.; Levi, Y.; Lorenz, D.; Sauer, A.; Boesel, F.; et al. 2024. Scaling rectified flow transformers for high-resolution image synthesis. In *Forty-first international conference on machine learning*.

Feng, R.; Xi, N.; Chu, D.; Wang, R.; Deng, Z.; Wang, A.; Lu, L.; Wang, J.; and Huang, Y. 2025. ARTEMIS: Autoregressive End-to-End Trajectory Planning with Mixture of Experts for Autonomous Driving. arXiv:2504.19580.

HaCohen, Y.; Chiprut, N.; Brazowski, B.; Shalem, D.; Moshe, D.; Richardson, E.; Levin, E.; Shiran, G.; Zabari, N.; Gordon, O.; Panet, P.; Weissbuch, S.; Kulikov, V.; Bitterman, Y.; Melumian, Z.; and Bibi, O. 2024. LTX-Video: Realtime Video Latent Diffusion. *arXiv preprint arXiv:2501.00103*.

Hong, Y.; Zhou, X.; Li, Y.; Zhou, X.; Liu, L.; Luo, Y.; Xu, S.; Yang, L.; and Song, Z. 2026. DriveFuture: Future-Aware Latent World Models for Autonomous Driving. arXiv:2605.09701.

Hu, Y.; Yang, J.; Chen, L.; Li, K.; Sima, C.; Zhu, X.; Chai, S.; Du, S.; Lin, T.; Wang, W.; Lu, L.; Jia, X.; Liu, Q.; Dai, J.; Qiao, Y.; and Li, H. 2023. Planning-Oriented Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 17853–17862.

Huang, M.; Xiang, Y.; Liang, Z.; Huang, J.; Wang, J.; Xu, Z.; Tan, F.; Zhou, H.; Yang, M.; and Che, G. 2026. Coworld-vla: Thinking in a multi-expert world model for autonomous driving. *arXiv preprint arXiv:2605.10426*.

Hwang, J.-J.; Xu, R.; Lin, H.; Hung, W.-C.; Ji, J.; Choi, K.; Huang, D.; He, T.; Covington, P.; Sapp, B.; Zhou, Y.; Guo, J.; Anguelov, D.; and Tan, M. 2024. EMMA: End-to-End Multimodal Model for Autonomous Driving. arXiv:2410.23262.

Jia, F.; Liu, L.; Song, Z.; Jia, C.; Ye, H.; Hao, X.; and Chen, L. 2026. DriveWorld-VLA: Unified Latent-Space World Modeling with Vision–Language–Action for Autonomous Driving. arXiv:2602.06521.

Jiang, B.; Chen, S.; Xu, Q.; Liao, B.; Chen, J.; Zhou, H.; Zhang, Q.; Liu, W.; Huang, C.; and Wang, X. 2023. VAD: Vectorized Scene Representation for Efficient Autonomous Driving. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 8306–8316.

Kirby, E.; Boulch, A.; Xu, Y.; Yin, Y.; Puy, G.; Zablocki, E.; Bursuc, A.; Gidaris, S.; Marlet, R.; Bartoccioni, F.; Cao, A.-Q.; Samet, N.; Vu, T.-H.; and Cord, M. 2026. Driving on Registers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

Li, J.; Zhang, B.; Jin, X.; Deng, J.; Zhu, X.; and Zhang, L. 2025a. ImagiDrive: A Unified Imagination-and-Planning Framework for Autonomous Driving. *arXiv preprint arXiv:2508.11428*.

Li, K.; Li, Z.; Lan, S.; Xie, Y.; Zhang, Z.; Liu, J.; Wu, Z.; Yu, Z.; and Alvarez, J. M. 2025b. Hydra-MDP++: Advancing End-to-End Driving via Expert-Guided Hydra-Distillation. arXiv:2503.12820.

Li, Y.; Fan, L.; He, J.; Wang, Y.; Chen, Y.; Zhang, Z.; and Tan, T. 2025c. Enhancing End-to-End Autonomous Driving with Latent World Model. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

Li, Y.; Shang, S.; Liu, W.; Zhan, B.; Wang, H.; Wang, Y.; Chen, Y.; Wang, X.; An, Y.; Tang, C.; Hou, L.; Fan, L.; and Zhang, Z. 2025d. DriveVLA-W0: World Models Amplify Data Scaling Law in Autonomous Driving. arXiv:2510.12796.

Li, Y.; Xiong, K.; Guo, X.; Li, F.; Yan, S.; Xu, G.; Zhou, L.; Chen, L.; Sun, H.; Wang, B.; Ma, K.; Chen, G.; Ye, H.; Liu, W.; and Wang, X. 2025e. ReCogDrive: A Reinforced Cognitive Framework for End-to-End Autonomous Driving. arXiv:2506.08052.

Liao, B.; Chen, S.; Yin, H.; Jiang, B.; Wang, C.; Yan, S.; Zhang, X.; Li, X.; Zhang, Y.; Zhang, Q.; and Wang, X. 2025. DiffusionDrive: Truncated Diffusion Model for End-to-End Autonomous Driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 12037–12047.

Liu, M.; Zhang, D.; Liu, J.; Cui, J.; Xie, H.; Chen, G.; Ye, H.; Yang, M. Y.; Nex, F.; and Cheng, H. 2026a. Driveva: Video action models are zero-shot drivers. *arXiv preprint arXiv:2604.04198*.

Shao, H.; Hu, Y.; Wang, L.; Song, G.; Waslander, S. L.; Liu, Y.; and Li, H. 2024. LMDrive: Closed-Loop End-to-End Driving with Large Language Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 15120–15130.

Shi, C.; Xu, J.; Shi, S.; Sheng, K.; Zhang, B.; and Jiang, L. 2026. DriveWAM: Video Generative Priors Enable Scalable World-Action Modeling for Autonomous Driving. *arXiv preprint arXiv:2605.28544*.

Sun, W.; Lin, X.; Chen, K.; Pei, Z.; Li, X.; Shi, Y.; and Zheng, S. 2026. SparseDriveV2: Scoring is All You Need for End-to-End Autonomous Driving. arXiv:2603.29163.

Sun, W.; Lin, X.; Shi, Y.; Zhang, C.; Wu, H.; and Zheng, S. 2025. SparseDrive: End-to-End Autonomous Driving via Sparse Scene Representation. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, 8795–8801.

Wan, T.; Wang, A.; Ai, B.; Wen, B.; Mao, C.; Xie, C.-W.; Chen, D.; Yu, F.; Zhao, H.; Yang, J.; et al. 2025. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*.

Wang, L.; Yang, Z.; Bai, C.; Zhang, G.; Liu, X.; Zheng, X.; Long, X.-X.; Lu, C.-T.; and Lu, C. 2026a. DriveJEPA: Video JEPA Meets Multimodal Trajectory Distillation for End-to-End Driving. arXiv:2601.22032.

Wang, L.; Zheng, Y.; Chen, Q.; Li, S.; Zhang, Y.; Xing, Z.; Zhang, Q.; Li, X.; Qian, D.; Yang, P.; Dong, Y.; Hao, C.; Ye, X.; Han, J.; Pan, Y.; and Zhao, D. 2026b. Latent-WAM: Latent World Action Modeling for End-to-End Autonomous Driving. arXiv:2603.24581.

Wang, X.; Wang, X.; Zhou, T.; Chen, G.; Gui, X.; Xu, Z.; Wu, X.; Tan, F.; Zhou, H.; and Yang, M. 2026c. ChainFlow-VLA: Causal Flow Planning with Vision-Language Models. arXiv:2605.23270.

Wang, X.; Zhu, Z.; Huang, G.; Chen, X.; Zhu, J.; and Lu, J. 2024. DriveDreamer: Towards Real-World-Drive World Models for Autonomous Driving. In *Computer Vision – ECCV 2024*, 55–72.

Xia, T.; Li, Y.; Zhou, L.; Yao, J.; Xiong, K.; Sun, H.; Wang, B.; Ma, K.; Chen, G.; Ye, H.; et al. 2025. Drivelaw: Unifying planning and video generation in a latent driving world. *arXiv preprint arXiv:2512.23421*.

Xu, M.; Cui, J.; Cai, F.; Shang, H.; Zhu, Z.; Luan, S.; Xu, Y.; Zhang, N.; Li, Y.; Cai, J.; and Zhu, S. 2025a. WAM-Diff: A Masked Diffusion VLA Framework with MoE and Online Reinforcement Learning for Autonomous Driving. arXiv:2512.11872.

Xu, Y.; Cui, J.; Cai, F.; Zhu, Z.; Shang, H.; Luan, S.; Xu, M.; Zhang, N.; Li, Y.; Cai, J.; and Zhu, S. 2025b. WAM-Flow: Parallel Coarse-to-Fine Motion Planning via Discrete Flow Matching for Autonomous Driving. arXiv:2512.06112.

Yang, P.; Zheng, Y.; Xing, Z.; Zhang, Q.; Qian, D.; Wang, L.; Zhang, Y.; Guo, S.; Xia, Z.; Chen, Q.; Han, J.; Xu, L.; Pan, Y.; and Zhao, D. 2026. DreamerAD: Efficient Reinforcement Learning via Latent World Model for Autonomous Driving. arXiv:2603.24587.

Yao, W.; Li, Z.; Lan, S.; Wang, Z.; Sun, X.; Alvarez, J. M.; and Wu, Z. 2025. DriveSuprim: Towards Precise Trajectory Selection for End-to-End Planning. arXiv:2506.06659.

Yao, Z.; Liu, H.; Jiang, Y.; Zhu, Z.; Guo, Z.; Wang, J.; Liu, T.; Cui, J.; Yang, K.; Xie, H.; Zhao, J.; Chen, G.; and Ye, H. 2026. Discrete-WAM: Unified Discrete Vision-Action Token Editing for World-Policy Learning. arXiv:2606.05645.

Zhou, G.; Pan, H.; LeCun, Y.; and Pinto, L. 2024. Dino-wm: World models on pre-trained visual features enable zero-shot planning. *arXiv preprint arXiv:2411.04983*.

Zhou, H.; Lin, L.; Wang, J.; Lu, Y.; Bai, D.; Liu, B.; Wang, Y.; Geiger, A.; and Liao, Y. 2024. HUGSIM: A Real-Time, Photo-Realistic and Closed-Loop Simulator for Autonomous Driving. *arXiv preprint arXiv:2412.01718*.

Zhou, X.; Han, X.; Yang, F.; Ma, Y.; Tresp, V.; and Knoll, A. 2026. OpenDriveVLA: Towards End-to-End Autonomous Driving with Large Vision Language Action Model. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(16): 13782–13790.

Zhu, J.; Jia, Z.; Gao, T.; Deng, J.; Li, S.; Zhang, L.; Liu, F.; Jia, P.; and Lang, X. 2026. Other Vehicle Trajectories Are Also Needed: A Driving World Model Unifies Ego-Other Vehicle Trajectories in Video Latent Space. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(16): 13934–13942.

Zou, J.; Chen, S.; Liao, B.; Zheng, Z.; Song, Y.; Zhang, L.; Zhang, Q.; Liu, W.; and Wang, X. 2025. DiffusionDriveV2: Reinforcement Learning-Constrained Truncated Diffusion Modeling in End-to-End Autonomous Driving. arXiv:2512.07745.

A. HUGSIM 闭环评估

协议。 436 个场景涵盖四个源数据集与四个难度级别；难度分布见正文表 2，数据集分布见表 6。所有方法使用相同的场景、真值驾驶指令、聚合方式以及 HUGSIM 控制器与评估器。具体地，我们使用提交版本 `ead17f2` 的 HUGSIM，该版本应用了 PR #57 中引入的轨迹-航向坐标顺序修正。传感器配置遵循各原始方法：LTF 使用三个前视相机，其余方法使用四个。

我们使用这一固定的代码快照对所有评估方法重新打分，确保控制器与指标实现一致。DrivoR 最初是在包含 345 个场景的早期 HUGSIM 版本上评估的，而本文评估使用当前的 436 个场景集合。因此，其已发表分数与本文报告的结果不直接可比。对于 DrivoR，我们报告在 NAVSIM 训练集与验证集联合数据上训练、且不含 SimScale 引入的额外模拟训练数据的变体。相比之下，WA-JEPA 的第二阶段仅使用 NAVSIM 训练集。

聚合稳健性。 在每个难度级别内，我们先在源数据集内部对场景均匀平均，再对四个数据集均匀平均，与 HUGSIM 基准一致。单个总体 HD-Score 通过按场景数量 (80/157/96/103) 对四个难度级别加权得到，遵循该基准的后续工作。表 5 报告了两种替代规则：对四个数据集均匀平均，以及对全部 436 个场景均匀平均。正文中的方法排序在两种规则下均不变。

分数据集结果。 表 6 分别报告了每个 HUGSIM 源数据集的 HD-Score。四个数据集均未用于第一阶段或第二阶段训练。WA-JEPA 在每个数据集上都取得了最高 HD-Score，表明其在多样化视觉域上具有一致的源数据集互斥泛化能力。

聚合方式	WA-JEPA	LTF	DrivoR	UniAD	VAD
主规则	**0.4462**	0.2310	0.3252	0.3124	0.1393
数据集均匀	**0.4483**	0.2300	0.3246	0.3085	0.1304
场景均匀	**0.4464**	0.2243	0.3194	0.3082	0.1266

表 5: 三种聚合规则下的 HD-Score。*主规则*为上文所述的规则；其余两行分别对四个数据集与全部 436 个场景均匀平均。每行最优结果加粗。

数据集	n	WA-JEPA	LTF	DrivoR	UniAD	VAD
nuScenes	88	**0.4725**	0.3334	0.3830	0.3405	0.2069
KITTI-360	113	**0.2963**	0.0969	0.2175	0.0550	0.0272
Waymo	108	**0.5542**	0.2478	0.4025	0.4372	0.1376
PandaSet	127	**0.4702**	0.2419	0.2955	0.4012	0.1500

表 6: 436 个 HUGSIM 场景上的分数据集 HD-Score。n 表示场景数量。每行最优结果加粗。

B. 定性结果

HUGSIM 闭环回放。 图 5 展示了转弯、遭遇对向来车与超车等场景中的零样本闭环回放。尽管 HUGSIM 渲染与训练数据之间存在视觉域差异，WA-JEPA 仍能沿可行驶走廊行驶，并在全部四个源数据集上对反应式智能体保持横向间距。

NAVSIM 轨迹预测。 图 6 展示了第二阶段在 NAVSIM 上的代表性预测。在转弯、岔路口与闸口导航、停车与直行场景中，预测轨迹在机动方向与整体几何上与参考一致，仅存在微小的局部偏差。

统计量	EPDMS
种子数量	10
均值	91.7014
标准差	0.0531
标准误	0.0168
95% t-置信区间	[91.6634, 91.7393]
中位数	91.6960
范围	[91.6294, 91.8070]

表 7: 主 WA-JEPA 实验在一组固定的十个种子上的种子级 EPDMS 波动。

C. 补充实验细节

停止梯度设计细节。 尽管场景输出流在前向传播中会以动作 token 为条件，但场景预测损失的梯度在动作 token 接口处被阻断，因此不会更新动作流。相比之下，动作输出流会关注可微的历史上下文与未来场景 token，使动作监督能够通过联合交互模块塑造学习到的场景表征。这种非对称梯度设计在保留未来场景预测的同时，促使场景表征捕获与自车规划相关的未来动态。

推理细节与种子级波动。 WA-JEPA 流预测器使用 4 个采样步。对于所有涉及随机噪声初始化的实验，我们使用一组固定的十个种子。对于每个种子，我们重新初始化采样噪声并运行完整评估，同时保持模型参数、场景与推理设置不变。所有子指标与 EPDMS 都针对每个种子独立计算，其中 EPDMS 遵循式 (21)。我们报告它们在四舍五入前的算术平均值。

如表 7 所示，主 WA-JEPA 实验的平均 EPDMS 为 91.7014，四舍五入后正文报告为 91.7。无随机噪声初始化的方法仅评估一次，而所有复现基线使用其原生的推理流程。

D. NAVSIM 评估指标

评估遵循官方 NAVSIM 协议，所有分数由伪模拟器在 `navtest` 上计算。本节定义正文表 1 与 3 中使用的每个子指标与聚合规则。

子指标。 NAVSIM-v1 使用五个子指标：*无过错碰撞* (NC)，若自车引发碰撞则为 0，否则为 1（自车不承担责任的碰撞，例如被追尾，予以排除）；*可行驶区域合规* (DAC)，若自车足迹任何部分离开可行驶区域则为 0，否则为 1；*碰撞时间* (TTC)，在自车与周围智能体的匀速投影下，若回放过程中的最小碰撞时间始终高于安全阈值则为 1；*舒适性* (Comf.)，当纵向与横向加速度、加加速度与横摆角速度保持在由数据集估计的人类驾驶边界内时为 1；以及 *自车进度* (EP)，即自车沿路线中心线行驶距离与特权 PDM-Closed 规划器行驶距离之比，裁剪到 $[0, 1]$。

NAVSIM-v2 额外引入：*行驶方向合规* (DDC)，对逆向当前车道标称方向的行驶进行惩罚，惩罚力度随违规程度分级；*交通灯合规* (TLC)，若自车在红灯下越过停止线则为 0，否则为 1；*车道保持* (LK)，衡量自车在时域内是否保持在指定车道走廊内；*历史舒适性* (HC)，联合评估过去轨迹与规划轨迹上的舒适边界，从而惩罚规划边界处的突变；以及 *扩展舒适性* (EC)，衡量伪模拟两个阶段之间运动学特征的一致性，从而惩罚在回放间发生剧烈变化的轨迹。

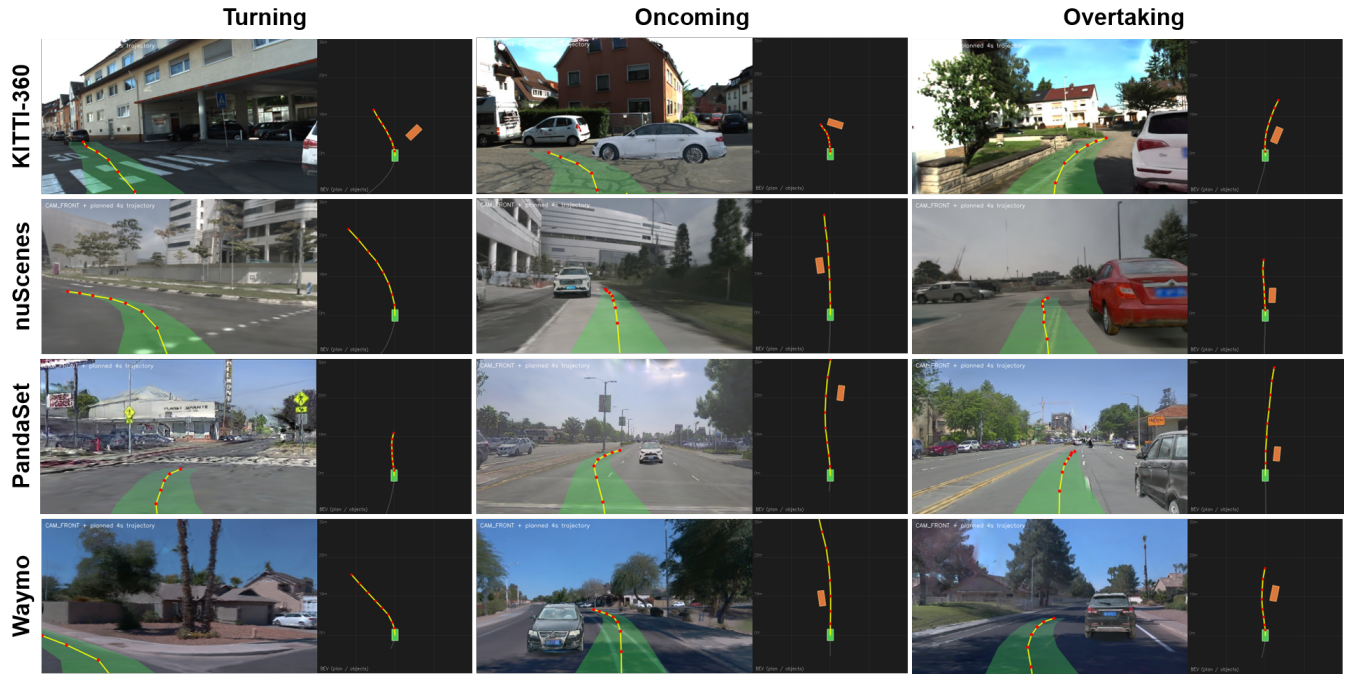


图 5: WA-JEPA 在 HUGSIM 上的零样本闭环回放。行对应四个源数据集，列对应三种场景类型。每对图显示前相机与投影的 4 s 规划（左），以及带规划轨迹与检测物体的 BEV 视图（右）。绿色区域表示可行驶走廊，黄-红曲线为规划轨迹，绿色框为自车，橙色框为其他智能体。

聚合。 子指标被分为乘法惩罚 $\mathcal{M}_{\text{pen}}$ 与加权平均 $\mathcal{M}_{\text{avg}}$。NAVSIM-v1 预测驾驶模型分数 (PDMS) 为

$$\text{PDMS} = \underbrace{\text{NC} \cdot \text{DAC}}_{\mathcal{M}_{\text{pen}}} \cdot \frac{5\,\text{TTC} + 2\,\text{Comf.} + 5\,\text{EP}}{12}, \quad (17)$$

因此一次安全违规即会把分数归零，而其余各项在安全裕度、舒适性与进度之间进行权衡。

NAVSIM-v2 扩展 PDMS (EPDMS) 在聚合子指标之前额外施加一个人类参考惩罚过滤器。设 $s_{i,m}^{\text{agent}}$ 与 $s_{i,m}^{\text{human}}$ 分别表示场景 i 中指标 m 的智能体分数与人类参考分数。对于原始的第一阶段伪模拟场景，修正后的子指标定义为

$$\tilde{s}_{i,m} = \text{filter}_m\left(s_{i,m}^{\text{agent}}, s_{i,m}^{\text{human}}\right) = \begin{cases} 1, & \substack{m \in \mathcal{M}_{\text{filt}},\\ s_{i,m}^{\text{human}}=0,} \\ s_{i,m}^{\text{agent}}, & \text{otherwise}, \end{cases} \quad (18)$$

其中 $\mathcal{M}_{\text{filt}} = \{\text{NC}, \text{DAC}, \text{DDC}, \text{TLC}, \text{EP}, \text{TTC}, \text{LK}, \text{HC}\}$。合成的第二阶段伪模拟场景不使用该过滤器，EC 随后由配对回放计算。因此，该过滤器并不会移除场景；它只是在人类参考同样违规时，抑制该指标特定的惩罚。

使用过滤后的子指标，每个场景的扩展分数为

$$q_i = \tilde{s}_{i,\text{NC}}\tilde{s}_{i,\text{DAC}}\tilde{s}_{i,\text{DDC}}\tilde{s}_{i,\text{TLC}} \times \frac{5\tilde{s}_{i,\text{EP}} + 5\tilde{s}_{i,\text{TTC}} + 2\tilde{s}_{i,\text{LK}} + 2\tilde{s}_{i,\text{HC}} + 2\tilde{s}_{i,\text{EC}}}{16}. \quad (19)$$

最终的基准 EPDMS 遵循官方两阶段 NAVSIM-v2 聚合。设 $\mathcal{G}$ 表示官方映射组，$\mathcal{I}_{g,b}^{(r)}$ 表示在伪模拟阶段 $r \in \{1,2\}$ 中分配给分支 $b \in \{1,2\}$ 的场景，α_i 为提供的场景权重。定义

$$\bar{q}_{g,b}^{(r)} = \frac{\sum_{i \in \mathcal{I}_{g,b}^{(r)}} \alpha_i q_i}{\sum_{i \in \mathcal{I}_{g,b}^{(r)}} \alpha_i}. \quad (20)$$

所报告的分数为

$$\text{EPDMS} = \frac{100}{|\mathcal{G}|} \sum_{g \in \mathcal{G}} \frac{1}{2} \sum_{b=1}^{2} \bar{q}_{g,b}^{(1)} \bar{q}_{g,b}^{(2)}. \quad (21)$$

EPDMS* 与 EPDMS。 所有修正后的 NAVSIM-v2 结果均使用提交版本 `359c7f7` 的官方 NAVSIM devkit 计算，该版本在应用人类参考过滤器后重新计算乘法项与加权项。EPDMS* 表示使用修复前评估器得到的分数，而 EPDMS 表示使用该修正协议得到的分数。因此，两种设置分别报告，且仅在相同评测协议内进行比较。

E. 时序表征指标

我们评估预测的未来场景 token 是否保持相应 EMA 目标 token 的时序变化。与正文一致，对比使用两个以目标为参照的指标：方向相似性坍缩间隙（越低越好）与变化幅度坍缩（越接近 1 越好）。两者都在投影后的场景 token 空间中计算。

动态 token 选择。 设 $\hat{\mathbf{z}}_{i,r,t}$ 与 $\mathbf{z}_{i,r,t}$ 分别表示预测实例 i、相机-空间位置 r 与未来 token 步 t 处的预测特征与目标特征。为防止静态区域主导统计量，我们按目标

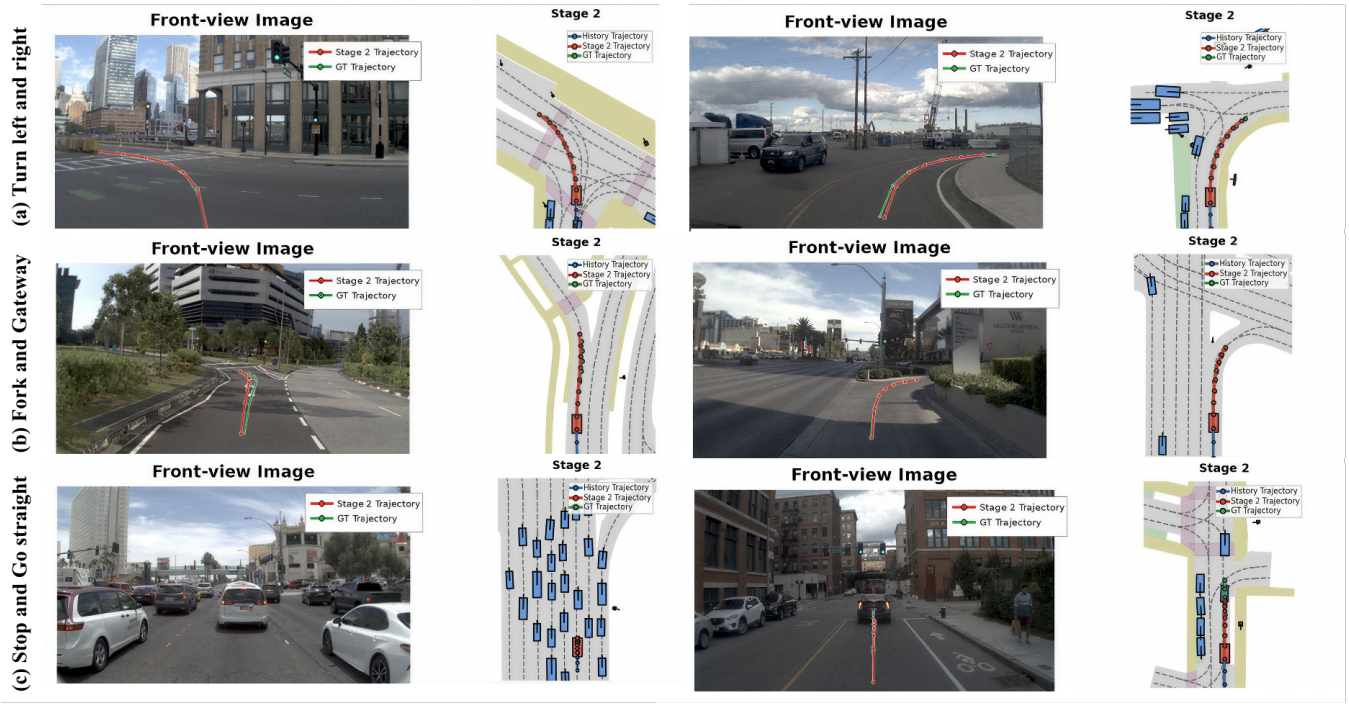


图 6: 代表性 NAVSIM 场景上的轨迹预测：(a) 左转与右转，(b) 岔路口与闸口导航，(c) 停车与直行。

的平均相邻步变化对位置排序，

$$s_{i,r} = \frac{1}{F-1}\sum_{t=0}^{F-2} \|\mathbf{z}_{i,r,t+1} - \mathbf{z}_{i,r,t}\|_2\,, \qquad \mathcal{A}_i = \mathrm{TopK}_r(s_{i,r}). \tag{22}$$

同一目标选择的集合 $\mathcal{A}_i$ 同时用于两种方法与两个指标。选择针对每个预测实例独立进行。

方向相似性坍缩间隙。 对于特征序列 $\mathbf{q}$，定义所选位置上所有不同未来步有序对上的平均余弦相似度为

$$C(\mathbf{q}) = \frac{1}{N_{\cos}}\sum_i \sum_{r\in\mathcal{A}_i}\sum_{t\neq u} \cos\left(\mathbf{q}_{i,r,t}, \mathbf{q}_{i,r,u}\right),$$

$$\cos(\mathbf{a},\mathbf{b}) = \frac{\mathbf{a}^\top\mathbf{b}}{\max(\|\mathbf{a}\|_2,\epsilon)\max(\|\mathbf{b}\|_2,\epsilon)}, \quad \epsilon = 10^{-6}. \tag{23}$$

其中 $N_{\cos}$ 为有效项的数量。所报告的指标为

$$\Delta_{\mathrm{dir}} = C(\widehat{\mathbf{z}}) - C(\mathbf{z}). \tag{24}$$

正值表明预测的未来步比目标彼此更相似，因此表现出额外的方向坍缩。相应地，值越低表示相对目标的时序保持越好，如正文所述。

变化幅度坍缩。 我们还比较平均相邻步特征变化，

$$D(\mathbf{q}) = \frac{1}{N_\Delta}\sum_i \sum_{r\in\mathcal{A}_i}\sum_{t=0}^{F-2} \|\mathbf{q}_{i,r,t+1} - \mathbf{q}_{i,r,t}\|_2\,, \qquad R_\Delta = \frac{D(\widehat{\mathbf{z}})}{\max(D(\mathbf{z}),\epsilon)}. \tag{25}$$

尽管正文称之为变化幅度坍缩，R_Δ 实际上是一个比值：$R_\Delta = 1$ 表示预测保持了目标的平均时序变化，而低于 1 的值表示变化不足。因此，对于正文报告的比较而言，越接近 1 越好。

评估协议。 两种目标使用相同的投影特征空间、目标选择的位置，以及对所有有效预测实例与 token 对的全局平均。对于流匹配，指标由采样训练流时间处的单步 x-预测计算，不运行多步推理采样器；回归则从其直接隐变量预测评估。正文中的汇总值为原始记录指标在共同的 0–36k 训练区间上的算术平均。对于标准设置，八个未来帧配合 tubelet 大小 2 得到 $F = 4$ 个未来 token 步，并从四相机场景 token 网格中选择 $K = 64$ 个目标动态位置。