

去噪扩散概率模型 (Denoising Diffusion Probabilistic Models)

Jonathan Ho
UC Berkeley
jonathanho@berkeley.edu

Ajay Jain
UC Berkeley
ajayj@berkeley.edu

Pieter Abbeel
UC Berkeley
pabbeel@cs.berkeley.edu

摘要

本文利用扩散概率模型 (diffusion probabilistic model) ——一类受非平衡热力学启发的潜变量模型——实现了高质量的图像合成。最佳结果来自对加权变分界的训练，该变分界依据扩散概率模型与带朗之万动力学的去噪分数匹配之间的新联系而设计；模型天然支持渐进式无损解压方案，可解释为自回归解码的推广。在无条件 CIFAR10 数据集上，获得 9.46 的初始分数 (IS) 与 3.17 的弗雷歇初始距离 (FID)，达到当前最优。在 256×256 LSUN 上，样本质量与 ProgressiveGAN 相当。实现见 <https://github.com/hojonathanho/diffusion>。

1 引言

近年来，各类深度生成模型已在多种数据模态上展现出高质量的样本。生成对抗网络 (GAN)、自回归模型、流模型与变分自编码器 (VAE) 合成了令人瞩目的图像与音频样本 [14, 27, 3, 58, 38, 25, 10, 32, 44, 57, 26, 33, 45]；能量建模与分数匹配也取得显著进展，生成的图像可与 GAN 相媲美 [11, 55]。




图 1: CelebA-HQ 256×256 (左) 与无条件 CIFAR10 (右) 上的生成样本




图 2: 本文所考虑的带向图模型。

本文介绍扩散概率模型 (diffusion probabilistic model) 的进展 [53]。扩散概率模型 (简称“扩散模型”) 是参数化马尔可夫链, 通过变分推断训练, 在有限时间内生成与数据匹配的样本。链的转移经学习以逆转扩散过程——扩散过程是按采样相反方向逐步向数据加噪、直至信号被破坏的马尔可夫链。当扩散由少量高斯噪声构成时, 将采样链的转移也设为条件高斯即已足够, 从而得到尤为简单的神经网络参数化。

扩散模型定义直接、训练高效, 但就目前所知, 此前尚无证据表明其能生成高质量样本。本文证明扩散模型确实能生成高质量样本, 有时甚至优于其他类型生成模型已发表的结果 (章节 4)。此外, 本文表明扩散模型的特定参数化在训练时与多噪声水平的去噪分数匹配等价、在采样时与退火朗之万动力学等价 (章节 3.2) [55, 61]。本文的最佳样本质量即由该参数化取得 (章节 4.2), 故将此等价性视为主要贡献之一。

尽管样本质量出色, 本文模型的似然并不比其他基于似然的模型有竞争力 (但确实优于针对能量模型与分数匹配用退火重要性采样所得的大估计值 [11, 55])。本文发现, 模型的无损码长大部分用于描述不可感知的图像细节 (章节 4.3)。本文以有损压缩的视角对此现象作更精细的分析, 并表明扩散模型的采样过程是一种渐进式解码, 类似于沿某种比特序的自回归解码, 该比特序极大推广了自回归模型通常所能实现的范畴。

2 背景

扩散模型 [53] 是形如 $p_\theta(\mathbf{x}_0) := \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}$ 的潜变量模型, 其中 $\mathbf{x}_1, \dots, \mathbf{x}_T$ 是与数据 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 同维度的潜变量。联合分布 $p_\theta(\mathbf{x}_{0:T})$ 称为反向过程, 定义为从 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$ 出发、转移为学习的条件高斯的马尔可夫链:

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t), \quad p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)) \quad (1)$$

扩散模型区别于其他类型潜变量模型之处在于, 近似后验 $q(\mathbf{x}_{1:T}|\mathbf{x}_0)$ (称为前向过程或扩散过程) 固定为一条马尔可夫链, 按方差调度 $\beta_1, \dots, \beta_T$ 逐步向数据添加高斯噪声:

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}), \quad q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \quad (2)$$

训练通过优化负对数似然的常规变分分界进行:

$$\mathbb{E}[-\log p_\theta(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] =: L \quad (3)$$

前向过程方差 β_t 可通过重参数化学习 [33], 也可作为超参数保持常数; 反向过程的表达力部分由 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 中条件高斯的选取保证, 因为当 β_t 较小时两过程具有相同的函数形式 [53]。前向过程的一个显著性质是允许在任意时间步 t 以闭式采样 $\mathbf{x}_t$: 使用记号 $\alpha_t := 1 - \beta_t$ 与 $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$, 有

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (4)$$

因此可通过随机梯度下降优化 L 的随机项来实现高效训练。进一步改进来自重写 L (3) 以降方差:

$$\mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} + \sum_{t \geq 1} \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} \underbrace{- \log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{L_0} \right] \quad (5)$$

(详见 Appendix A。各项的标签用于 章节 3。)Equation (5) 使用 KL 散度直接比较 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 与前向过程后验，后者在条件于 $\mathbf{x}_0$ 时可解析求解：

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I}), \quad (6)$$

$$\text{where } \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t \quad \text{and} \quad \tilde{\beta}_t := \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t \quad (7)$$

因此，Eq. (5) 中所有 KL 散度都是高斯之间的比较，可用闭式表达式以 Rao-Blackwellized 方式计算，而非高方差的蒙特卡洛估计。

3 扩散模型与去噪自编码器

扩散模型看似是一类受限的潜变量模型，但实现中有大量自由度。须选择前向过程的方差 β_t 、模型架构及反向过程的高斯分布参数化。为引导这些选择，本文建立扩散模型与去噪分数匹配之间新的显式联系 (章节 3.2)，进而得到扩散模型简化、加权的变分界训练目标 (章节 3.4)。最终，模型设计由简洁性与实证结果共同支撑 (章节 4)。下文按 Eq. (5) 的项分类讨论。

3.1 前向过程与 L_T

本文忽略前向过程方差 β_t 可经重参数化学习这一事实，而将其固定为常数 (详见 章节 4)。因此，在本文实现中，近似后验 q 无可学习参数， L_T 在训练期间为常数，可忽略。

3.2 反向过程与 $L_{1:T-1}$

下面讨论 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t))$ ($1 < t \leq T$) 中的选择。首先，将 $\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}$ 设为未经训练的时变常数。实验上， $\sigma_t^2 = \beta_t$ 与 $\sigma_t^2 = \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t$ 结果相近。前者对 $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 最优，后者对 $\mathbf{x}_0$ 确定地取单点时最优。二者为极端选择，分别对应按坐标单位方差数据下反向过程熵的上下界 [53]。

其次，为表示均值 $\boldsymbol{\mu}_\theta(\mathbf{x}_t, t)$ ，本文基于下述对 L_t 的分析提出特定参数化。当 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I})$ 时，可写为：

$$L_{t-1} = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2 \right] + C \quad (8)$$

其中 C 为不依赖 θ 的常数。可见 $\boldsymbol{\mu}_\theta$ 最直接的参数化是预测 $\tilde{\boldsymbol{\mu}}_t$ (前向过程后验均值) 的模型。但可将 Eq. (4) 重参数化为 $\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}) = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}$ ($\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$)，并应用前向过程后验公式 (7)，从而进一步展开 Eq. (8)：

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{1}{2\sigma_t^2} \left\| \tilde{\boldsymbol{\mu}}_t \left(\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}), \frac{1}{\sqrt{\bar{\alpha}_t}}(\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}) - \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}) \right) - \boldsymbol{\mu}_\theta(\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}), t) \right\|^2 \right] \quad (9)$$

$$= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}) - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\boldsymbol{\epsilon} \right) - \boldsymbol{\mu}_\theta(\mathbf{x}_t(\mathbf{x}_0, \boldsymbol{\epsilon}), t) \right\|^2 \right] \quad (10)$$

Equation (10) 表明，给定 $\mathbf{x}_t$ 时 $\boldsymbol{\mu}_\theta$ 须预测 $\frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\boldsymbol{\epsilon} \right)$ 。由于 $\mathbf{x}_t$ 作为模型输入可用，可选择参数化

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \tilde{\boldsymbol{\mu}}_t \left(\mathbf{x}_t, \frac{1}{\sqrt{\bar{\alpha}_t}}(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)) \right) = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) \quad (11)$$

其中 $\boldsymbol{\epsilon}_\theta$ 是用于从 $\mathbf{x}_t$ 预测 $\boldsymbol{\epsilon}$ 的函数逼近器。从 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 采样 $\mathbf{x}_{t-1}$ 即计算 $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ ，其中 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。完整采样过程 Algorithm 2 类似于朗之万动力学，其中 $\boldsymbol{\epsilon}_\theta$ 充当数据密度的学习梯度。此外，在参数化 (11) 下，Eq. (10) 简化为：

$$\mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, t) \right\|^2 \right] \quad (12)$$

Algorithm 1 训练

```

1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$ 
4:    $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   Take gradient descent step on
        $\nabla_{\theta} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\theta}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, t)\|^2$ 
6: until converged

```

Algorithm 2 采样

```

1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\bar{\alpha}_t}} \left( \mathbf{x}_t - \frac{1 - \bar{\alpha}_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 

```

该式类似于按 t 索引的多噪声尺度上的去噪分数匹配 [55]。由于 Eq. (12) 等于类朗之万反向过程 (11) 变分界的 (一项)，可见优化类似去噪分数匹配的目标即等价于用变分推断拟合类朗之万动力学采样链的有限时间边际。

总之，可训练反向过程均值函数逼近器 $\boldsymbol{\mu}_{\theta}$ 预测 $\tilde{\boldsymbol{\mu}}_t$ ，也可通过修改参数化使其预测 $\boldsymbol{\epsilon}_0$ 。（亦可预测 $\mathbf{x}_0$ ，但本文在实验初期发现这会导致较差的样本质量。）本文已表明， $\boldsymbol{\epsilon}$ 预测参数化既类似朗之万动力学，又将扩散模型的变分界简化为类似去噪分数匹配的目标。即便如此，它仍只是 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 的另一种参数化，本文在 章节 4 中通过对比预测 $\boldsymbol{\epsilon}$ 与预测 $\tilde{\boldsymbol{\mu}}_t$ 的消融实验验证其有效性。

3.3 数据缩放、反向过程解码器与 L_0

本文假设图像数据由 $\{0, 1, \dots, 255\}$ 中的整数构成，线性缩放至 $[-1, 1]$ 。这确保神经网络反向过程从标准正态先验 $p(\mathbf{x}_T)$ 出发，作用于缩放一致的输入。为获得离散对数似然，将反向过程的最后一项设为独立离散解码器，其由高斯 $\mathcal{N}(\mathbf{x}_0; \boldsymbol{\mu}_{\theta}(\mathbf{x}_1, 1), \sigma_1^2 \mathbf{I})$ 导出：

$$p_{\theta}(\mathbf{x}_0|\mathbf{x}_1) = \prod_{i=1}^D \int_{\delta_{-}(x_0^i)}^{\delta_{+}(x_0^i)} \mathcal{N}(x; \mu_{\theta}^i(\mathbf{x}_1, 1), \sigma_1^2) dx \quad (13)$$

$$\delta_{+}(x) = \begin{cases} \infty & \text{if } x = 1 \\ x + \frac{1}{255} & \text{if } x < 1 \end{cases} \quad \delta_{-}(x) = \begin{cases} -\infty & \text{if } x = -1 \\ x - \frac{1}{255} & \text{if } x > -1 \end{cases}$$

其中 D 为数据维度，上标 i 表示提取某一坐标。（也可改用于更强的解码器如条件自回归模型，但留待后续工作。）与 VAE 解码器和自回归模型中使用的离散化连续分布类似 [34, 52]，此处选择确保变分界是离散数据的无损码长，无需向数据加噪或将缩放操作的雅可比矩阵纳入对数似然。采样结束时，无噪声地显示 $\boldsymbol{\mu}_{\theta}(\mathbf{x}_1, 1)$ 。

3.4 简化训练目标

在定义上述反向过程与解码器后，由 Eqs. (12) and (13) 派生各项构成的变分界对 θ 显然可微，可直接用于训练。但本文发现，在如下变分界变体上训练对样本质量有益（且实现更简单）：

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\epsilon}} \left[\left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\theta}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, t) \right\|^2 \right] \quad (14)$$

其中 t 在 1 与 T 之间均匀取值。 $t = 1$ 情形对应 L_0 ，其中离散解码器定义 (13) 中的积分以高斯概率密度函数乘以区间宽度近似，忽略 σ_1^2 与边缘效应。 $t > 1$ 情形对应 Eq. (12) 的未加权版本，与 NCSN 去噪分数匹配模型所用损失加权类似 [55]。（ L_T 未出现，因为前向过程方差 β_t 固定。）Algorithm 1 给出采用该简化目标的完整训练过程。

由于简化目标 (14) 丢弃了 Eq. (12) 中的加权，它是加权变分界，相比标准变分界 [18, 22] 强调重建的不同方面。特别地，章节 4 中的扩散过程设置使简化目标降低小 t 对应损失项的权重。这些项训练网络去噪极少量噪声的数据，降低其权重可使网络专注于 t 较大时的更难去噪任务，因此有益。实验将表明该重加权带来更好的样本质量。

4 实验

所有实验均设 $T = 1000$ ，使采样所需的神经网络评估次数与先前工作一致 [53, 55]。前向过程方差设为常数，从 $\beta_1 = 10^{-4}$ 线性增至 $\beta_T = 0.02$ 。这些常数相对缩放至 $[-1, 1]$ 的数据

表 1: CIFAR10 结果。NLL 以每维比特 (bits/dim) 计。

模型	IS	FID	NLL 测试 (训练)
条件			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
无条件			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	L , learned diagonal Σ
Sparse Transformer [7]			L , fixed isotropic Σ
PixelIQN [43]	5.29	49.46	$2.80 \ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67 ± 0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	3.17	≤ 3.75 (3.72)

表 2: 无条件 CIFAR10 反向过程参数化与训练目标消融。空白项训练不稳定, 生成的样本较差、分数超出范围。

目标	IS	FID
$\tilde{\mu}$ 预测 (基线)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	—	—
ϵ 预测 (本文)		
L , learned diagonal Σ	—	—
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_\theta\ ^2$ (L_{simple})	9.46 ± 0.11	3.17



图 3: LSUN Church 样本。FID=7.89




图 4: LSUN Bedroom 样本。FID=4.90

取较小值, 确保反向与前向过程函数形式近似相同, 同时使 $\mathbf{x}_T$ 处的信噪比尽可能小 (本文实验中 $L_T = D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})) \approx 10^{-5}$ 每维比特)。

为表示反向过程, 本文使用类似未掩码 PixelCNN++ 的 U-Net 主干 [52, 48], 全程使用组归一化 [66]。参数跨时间共享, 时间以 Transformer 正弦位置嵌入 [60] 传入网络。在 16×16 特征图分辨率上使用自注意力 [63, 60]。细节见 Appendix B。

4.1 样本质量

表 1 给出 CIFAR10 上的初始分数、FID 分数与负对数似然 (无损码长)。凭借 3.17 的 FID 分数, 本文的无条件模型取得了优于文献中大多数模型的样本质量, 包括类条件模型。FID 分数按惯例相对训练集计算; 相对测试集计算时分数为 5.24, 仍优于文献中许多训练集 FID 分数。

本文发现, 按预期, 在真实变分界上训练能得到比简化目标更优的码长, 但后者样本质量最佳。CIFAR10 与 CelebA-HQ 256×256 样本见 图 1, LSUN 256×256 样本见 图 3 与 图 4 [71], 更多样本见 Appendix D。

4.2 反向过程参数化与训练目标消融

表 2 展示反向过程参数化与训练目标对样本质量的影响 (章节 3.2)。本文发现, 基线选项预测 $\tilde{\mu}$ 仅在真实变分界上训练时表现良好, 而非未加权均方误差——后者是类似 Eq. (14) 的简化目标。本文还发现, 学习反向过程方差 (将参数化的对角 $\Sigma_\theta(\mathbf{x}_t)$ 纳入变分界) 相比固定方差会导致训练不稳定、样本质量较差。按本文所提预测 ϵ , 在固定方差的变分界上训练时与预测 $\tilde{\mu}$ 表现相近, 但在简化目标上训练时好得多。

Algorithm 3 发送 $\mathbf{x}_0$

```

1: Send  $\mathbf{x}_T \sim q(\mathbf{x}_T|\mathbf{x}_0)$  using  $p(\mathbf{x}_T)$ 
2: for  $t = T - 1, \dots, 2, 1$  do
3:   Send  $\mathbf{x}_t \sim q(\mathbf{x}_t|\mathbf{x}_{t+1}, \mathbf{x}_0)$  using  $p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})$ 
4: end for
5: Send  $\mathbf{x}_0$  using  $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 

```

Algorithm 4 接收

```

1: Receive  $\mathbf{x}_T$  using  $p(\mathbf{x}_T)$ 
2: for  $t = T - 1, \dots, 1, 0$  do
3:   Receive  $\mathbf{x}_t$  using  $p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})$ 
4: end for
5: return  $\mathbf{x}_0$ 

```

4.3 渐进式编码

表 1 还给出本文 CIFAR10 模型的码长。训练与测试之间差距至多 0.03 每维比特，与其他基于似然的模型报告的差距相当，表明扩散模型未过拟合（最近邻可视化见 Appendix D）。尽管如此，本文的无损码长虽优于针对能量模型与分数匹配用退火重要性采样报告的大估计值 [11]，但与其他类型基于似然的生成模型相比仍缺乏竞争力 [7]。

由于样本质量仍然很高，本文得出结论：扩散模型具有使其成为优秀有损压缩器的归纳偏置。将变分界各项 $L_1 + \dots + L_T$ 视为码率、 L_0 视为失真，本文样本质量最高的 CIFAR10 模型的码率为 **1.78** 每维比特、失真为 **1.97** 每维比特，对应 0 至 255 尺度上均方根误差 0.95。无损码长中超过一半用于描述不可感知的失真。

渐进式有损压缩 为更深入探究模型的率失真行为，引入镜像 Eq. (5) 形式的渐进式有损编码：见 Algorithms 3 and 4。该编码假定存在某种过程（如最小随机编码 [19, 20]），对任意分布 p 与 q （接收方预先只知道 p ），可用平均约 $D_{\text{KL}}(q(\mathbf{x}) \parallel p(\mathbf{x}))$ 比特传输样本 $\mathbf{x} \sim q(\mathbf{x})$ 。对 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 应用 Algorithms 3 and 4，按序传输 $\mathbf{x}_T, \dots, \mathbf{x}_0$ ，总期望码长等于 Eq. (5)。接收方在任意时刻 t 拥有完整的部分信息 $\mathbf{x}_t$ ，可渐进估计：

$$\mathbf{x}_0 \approx \hat{\mathbf{x}}_0 = (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(\mathbf{x}_t)) / \sqrt{\bar{\alpha}_t} \quad (15)$$

该式由 Eq. (4) 导出。（随机重建 $\mathbf{x}_0 \sim p_\theta(\mathbf{x}_0|\mathbf{x}_t)$ 同样有效，但此处不考虑，因为它使失真更难以评估。）图 5 给出 CIFAR10 测试集上的率失真曲线。在每时刻 t ，失真按均方根误差 $\sqrt{\|\mathbf{x}_0 - \hat{\mathbf{x}}_0\|^2/D}$ 计算，码率按截至时刻 t 已收到的累计比特数计算。在率失真曲线的低码率区域，失真急剧下降，表明大部分比特确实分配给了不可感知的失真。




图 5: 无条件 CIFAR10 测试集率失真随时间变化。失真以 $[0, 255]$ 尺度上的均方根误差度量。详见表 4。

渐进生成 本文还运行由随机比特渐进解压给出的渐进无条件生成过程。换言之，在使用 Algorithm 2 从反向过程采样的同时预测反向过程结果 $\hat{\mathbf{x}}_0$ 。图 6 and 10 展示反向过程进程中 $\hat{\mathbf{x}}_0$ 的样本质量。大尺度图像特征先出现，细节最后出现。图 7 展示在冻结 $\mathbf{x}_t$ （不同 t ）下的随机预测 $\mathbf{x}_0 \sim p_\theta(\mathbf{x}_0|\mathbf{x}_t)$ 。当 t 较小时，除精细细节外均保留；当 t 较大时，仅保留大尺度特征。这些或许是概念压缩的迹象 [18]。

与自回归解码的联系 注意到变分界 (5) 可重写为：

$$L = D_{\text{KL}}(q(\mathbf{x}_T) \parallel p(\mathbf{x}_T)) + \mathbb{E}_q \left[\sum_{t \geq 1} D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) \right] + H(\mathbf{x}_0) \quad (16)$$

（推导见 Appendix A。）现考虑将扩散过程长度 T 设为数据的维度，定义前向过程使 $q(\mathbf{x}_t|\mathbf{x}_0)$ 将全部概率质量放在 $\mathbf{x}_0$ 掩码掉前 t 个坐标后的结果上（即 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ 掩码掉第 t 个坐标），



图 6: 无条件 CIFAR10 渐进生成 ($\hat{x}_0$ 随时间变化, 从左至右)。附录中给出扩展样本与随时间变化的样本质量指标 (图 10 and 14)。




图 7: 当条件于同一潜变量时, CelebA-HQ 256×256 样本共享高层属性。右下象限为 x_t , 其余象限为 $p_\theta(x_0|x_t)$ 的样本。

令 $p(x_T)$ 将全部质量放在空白图像上, 并 (为论证起见) 令 $p_\theta(x_{t-1}|x_t)$ 为表达力完全的条件分布。在这些选择下, $D_{KL}(q(x_T) \parallel p(x_T)) = 0$, 最小化 $D_{KL}(q(x_{t-1}|x_t) \parallel p_\theta(x_{t-1}|x_t))$ 会训练 p_θ 原样复制坐标 $t+1, \dots, T$, 并在给定 $t+1, \dots, T$ 时预测第 t 个坐标。因此, 用这种特定扩散训练 p_θ 即训练自回归模型。

因此可将高斯扩散模型 (2) 解释为一种具有广义比特序的自回归模型, 该比特序无法通过重排数据坐标来表达。先前工作表明, 此类重排会引入影响样本质量的归纳偏置 [38], 故推测高斯扩散起类似作用, 或许效果更强, 因为向图像添加高斯噪声可能比掩码噪声更自然。此外, 高斯扩散长度不必等于数据维度; 例如本文用 $T = 1000$, 小于实验中 $32 \times 32 \times 3$ 或 $256 \times 256 \times 3$ 图像的维度。高斯扩散可缩短以快速采样, 亦可加长以增强模型表达力。

4.4 插值

可在潜空间中以 q 为随机编码器插值源图像 $x_0, x'_0 \sim q(x_0)$, 即 $x_t, x'_t \sim q(x_t|x_0)$, 再由反向过程将线性插值的潜变量 $\bar{x}_t = (1 - \lambda)x_0 + \lambda x'_0$ 解码到图像空间, $\bar{x}_0 \sim p(x_0|\bar{x}_t)$ 。实际效果是使用反向过程去除对源图像损坏版本线性插值产生的伪影, 如图 8 (左) 所示。为不同 λ 固定噪声, 使 x_t 与 x'_t 保持不变。图 8 (右) 展示原始 CelebA-HQ 256×256 图像 ($t = 500$) 的插值与重建。反向过程产生高质量重建, 以及平滑变化姿态、肤色、发型、表情与背景 (但不含眼镜) 等属性的合理插值。 t 越大插值越粗糙、变化越多, $t = 1000$ 时产生全新样本 (附录 图 9)。

5 相关工作

扩散模型虽可能类似流模型 [9, 46, 10, 32, 5, 16, 23] 与 VAE [33, 47, 37], 但其设计使 q 无参数、顶层潜变量 x_T 与数据 x_0 的互信息几乎为零。本文的 ϵ 预测反向过程参数化建立了扩散模型与多噪声水平去噪分数匹配及采样用退火朗之万动力学之间的联系 [55, 56]。不过, 扩散模型可直接评估对数似然, 且训练过程用变分推断显式训练朗之万动力学采样器 (详见 Appendix C)。该联系还有反向推论: 某种加权形式的去噪分数匹配等价于训练类朗之万采样器的变分推断。学习马尔可夫链转移算子的其他方法包括注入训练 (infusion training) [2]、变分回退 (variational walkback) [15]、生成随机网络 [1] 等 [50, 54, 36, 42, 35, 65]。



图 8: CelebA-HQ 256×256 图像经 500 步扩散的插值。

借由分数匹配与能量建模之间的已知联系，本文工作可能对能量模型的其他近期研究有启示 [67–69, 12, 70, 13, 11, 41, 17, 8]。本文的率失真曲线在变分界的一次评估中随时间计算，让人联想到退火重要性采样一次运行中随失真率变化计算率失真曲线 [24]。本文的渐进解码论证可见于卷积 DRAW 及相关模型 [18, 40]，也可能导向自回归模型子尺度排序或采样策略的更一般设计 [38, 64]。

6 结论

本文展示了使用扩散模型生成的高质量图像样本，并发现了扩散模型与训练马尔可夫链的变分推断、去噪分数匹配、退火朗之万动力学（进而推及能量模型）、自回归模型及渐进式有损压缩之间的联系。由于扩散模型对图像数据似乎具有出色的归纳偏置，期待在后续工作中研究其与其他数据模态中的效用，以及作为其他类型生成模型和机器学习系统组件的用途。

更广泛的影响

本文关于扩散模型的工作与现有其他类型深度生成模型（如提升 GAN、流模型、自回归模型等样本质量的努力）范围相当。本文代表了将扩散模型打造成该技术家族中普遍有用工具的进展，因此可能放大生成模型对更广阔世界已经（以及将要）产生的影响。

遗憾的是，生成模型存在众多众所周知的恶意用途。样本生成技术可被用于出于政治目的伪造知名人物的图像与视频。虽然在软件工具问世前很久就有人工制作伪造图像，但本文这类生成模型使该过程更容易。所幸，CNN 生成的图像目前存在可被检测的细微缺陷 [62]，但生成模型的改进可能使检测越发困难。生成模型还反映其训练数据集中存在的偏见。由于许多大型数据集由自动化系统从互联网收集，消除这些偏见很困难，尤其当图像未标注时。若在这些数据集上训练的生成模型产生的样本在互联网上大量传播，这些偏见只会被进一步强化。

另一方面，扩散模型可能对数据压缩有用。随着数据分辨率提高、全球互联网流量增长，压缩对确保互联网对广大受众可及可能至关重要。本文工作可能促进对未标注原始数据的表征学习，以服务从图像分类到强化学习的大量下游任务；扩散模型也可能在艺术、摄影与音乐等创造性用途中变得可行。

Acknowledgments and Disclosure of Funding

本工作得到 ONR PECASE 与 NSF 研究生研究奖学金（资助号 DGE-1752814）的支持。谷歌 TensorFlow 研究云（TFRC）提供了 Cloud TPU。

参考文献

- [1] Guillaume Alain, Yoshua Bengio, Li Yao, Jason Yosinski, Eric Thibodeau-Laufer, Saizheng Zhang, and Pascal Vincent. GSNs: generative stochastic networks. *Information and Inference: A Journal of the IMA*, 5(2):210–249, 2016.
- [2] Florian Bordes, Sina Honari, and Pascal Vincent. Learning to generate samples from noise through infusion training. In *International Conference on Learning Representations*, 2017.
- [3] Andrew Brock, Jeff Donahue, and Karen Simonyan. Large scale GAN training for high fidelity natural image synthesis. In *International Conference on Learning Representations*, 2019.
- [4] Tong Che, Ruixiang Zhang, Jascha Sohl-Dickstein, Hugo Larochelle, Liam Paull, Yuan Cao, and Yoshua Bengio. Your GAN is secretly an energy-based model and you should use discriminator driven latent sampling. *arXiv preprint arXiv:2003.06060*, 2020.
- [5] Tian Qi Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems*, pages 6571–6583, 2018.
- [6] Xi Chen, Nikhil Mishra, Mostafa Rohaninejad, and Pieter Abbeel. PixelSNAIL: An improved autoregressive generative model. In *International Conference on Machine Learning*, pages 863–871, 2018.
- [7] Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever. Generating long sequences with sparse transformers. *arXiv preprint arXiv:1904.10509*, 2019.

- [8] Yuntian Deng, Anton Bakhtin, Myle Ott, Arthur Szlam, and Marc’Aurelio Ranzato. Residual energy-based models for text generation. *arXiv preprint arXiv:2004.11714*, 2020.
- [9] Laurent Dinh, David Krueger, and Yoshua Bengio. NICE: Non-linear independent components estimation. *arXiv preprint arXiv:1410.8516*, 2014.
- [10] Laurent Dinh, Jascha Sohl-Dickstein, and Samy Bengio. Density estimation using Real NVP. *arXiv preprint arXiv:1605.08803*, 2016.
- [11] Yilun Du and Igor Mordatch. Implicit generation and modeling with energy based models. In *Advances in Neural Information Processing Systems*, pages 3603–3613, 2019.
- [12] Ruiqi Gao, Yang Lu, Junpei Zhou, Song-Chun Zhu, and Ying Nian Wu. Learning generative ConvNets via multi-grid modeling and sampling. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 9155–9164, 2018.
- [13] Ruiqi Gao, Erik Nijkamp, Diederik P Kingma, Zhen Xu, Andrew M Dai, and Ying Nian Wu. Flow contrastive estimation of energy-based models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7518–7528, 2020.
- [14] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, pages 2672–2680, 2014.
- [15] Anirudh Goyal, Nan Rosemary Ke, Surya Ganguli, and Yoshua Bengio. Variational walkback: Learning a transition operator as a stochastic recurrent net. In *Advances in Neural Information Processing Systems*, pages 4392–4402, 2017.
- [16] Will Grathwohl, Ricky T. Q. Chen, Jesse Bettencourt, and David Duvenaud. FFDJORD: Free-form continuous dynamics for scalable reversible generative models. In *International Conference on Learning Representations*, 2019.
- [17] Will Grathwohl, Kuan-Chieh Wang, Joern-Henrik Jacobsen, David Duvenaud, Mohammad Norouzi, and Kevin Swersky. Your classifier is secretly an energy based model and you should treat it like one. In *International Conference on Learning Representations*, 2020.
- [18] Karol Gregor, Frederic Besse, Danilo Jimenez Rezende, Ivo Danihelka, and Daan Wierstra. Towards conceptual compression. In *Advances In Neural Information Processing Systems*, pages 3549–3557, 2016.
- [19] Prahladh Harsha, Rahul Jain, David McAllester, and Jaikumar Radhakrishnan. The communication complexity of correlation. In *Twenty-Second Annual IEEE Conference on Computational Complexity (CCC’07)*, pages 10–23. IEEE, 2007.
- [20] Marton Havasi, Robert Peharz, and José Miguel Hernández-Lobato. Minimal random code learning: Getting bits back from compressed model parameters. In *International Conference on Learning Representations*, 2019.
- [21] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs trained by a two time-scale update rule converge to a local Nash equilibrium. In *Advances in Neural Information Processing Systems*, pages 6626–6637, 2017.
- [22] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2017.
- [23] Jonathan Ho, Xi Chen, Aravind Srinivas, Yan Duan, and Pieter Abbeel. Flow++: Improving flow-based generative models with variational dequantization and architecture design. In *International Conference on Machine Learning*, 2019.
- [24] Sicong Huang, Alireza Makhzani, Yanshuai Cao, and Roger Grosse. Evaluating lossy compression rates of deep generative models. In *International Conference on Machine Learning*, 2020.
- [25] Nal Kalchbrenner, Aaron van den Oord, Karen Simonyan, Ivo Danihelka, Oriol Vinyals, Alex Graves, and Koray Kavukcuoglu. Video pixel networks. In *International Conference on Machine Learning*, pages 1771–1779, 2017.
- [26] Nal Kalchbrenner, Erich Elsen, Karen Simonyan, Seb Noury, Norman Casagrande, Edward Lockhart, Florian Stimberg, Aaron van den Oord, Sander Dieleman, and Koray Kavukcuoglu. Efficient neural audio synthesis. In *International Conference on Machine Learning*, pages 2410–2419, 2018.

- [27] Tero Karras, Timo Aila, Samuli Laine, and Jaakko Lehtinen. Progressive growing of GANs for improved quality, stability, and variation. In *International Conference on Learning Representations*, 2018.
- [28] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4401–4410, 2019.
- [29] Tero Karras, Miika Aittala, Janne Hellsten, Samuli Laine, Jaakko Lehtinen, and Timo Aila. Training generative adversarial networks with limited data. *arXiv preprint arXiv:2006.06676v1*, 2020.
- [30] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen, and Timo Aila. Analyzing and improving the image quality of StyleGAN. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8110–8119, 2020.
- [31] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- [32] Diederik P Kingma and Prafulla Dhariwal. Glow: Generative flow with invertible 1x1 convolutions. In *Advances in Neural Information Processing Systems*, pages 10215–10224, 2018.
- [33] Diederik P Kingma and Max Welling. Auto-encoding variational Bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- [34] Diederik P Kingma, Tim Salimans, Rafal Jozefowicz, Xi Chen, Ilya Sutskever, and Max Welling. Improved variational inference with inverse autoregressive flow. In *Advances in Neural Information Processing Systems*, pages 4743–4751, 2016.
- [35] John Lawson, George Tucker, Bo Dai, and Rajesh Ranganath. Energy-inspired models: Learning with sampler-induced distributions. In *Advances in Neural Information Processing Systems*, pages 8501–8513, 2019.
- [36] Daniel Levy, Matt D. Hoffman, and Jascha Sohl-Dickstein. Generalizing Hamiltonian Monte Carlo with neural networks. In *International Conference on Learning Representations*, 2018.
- [37] Lars Maaløe, Marco Fraccaro, Valentin Liévin, and Ole Winther. BIVA: A very deep hierarchy of latent variables for generative modeling. In *Advances in Neural Information Processing Systems*, pages 6548–6558, 2019.
- [38] Jacob Menick and Nal Kalchbrenner. Generating high fidelity images with subscale pixel networks and multidimensional upscaling. In *International Conference on Learning Representations*, 2019.
- [39] Takeru Miyato, Toshiki Kataoka, Masanori Koyama, and Yuichi Yoshida. Spectral normalization for generative adversarial networks. In *International Conference on Learning Representations*, 2018.
- [40] Alex Nichol. VQ-DRAW: A sequential discrete VAE. *arXiv preprint arXiv:2003.01599*, 2020.
- [41] Erik Nijkamp, Mitch Hill, Tian Han, Song-Chun Zhu, and Ying Nian Wu. On the anatomy of MCMC-based maximum likelihood learning of energy-based models. *arXiv preprint arXiv:1903.12370*, 2019.
- [42] Erik Nijkamp, Mitch Hill, Song-Chun Zhu, and Ying Nian Wu. Learning non-convergent non-persistent short-run MCMC toward energy-based model. In *Advances in Neural Information Processing Systems*, pages 5233–5243, 2019.
- [43] Georg Ostrovski, Will Dabney, and Remi Munos. Autoregressive quantile networks for generative modeling. In *International Conference on Machine Learning*, pages 3936–3945, 2018.
- [44] Ryan Prenger, Rafael Valle, and Bryan Catanzaro. WaveGlow: A flow-based generative network for speech synthesis. In *ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 3617–3621. IEEE, 2019.
- [45] Ali Razavi, Aaron van den Oord, and Oriol Vinyals. Generating diverse high-fidelity images with VQ-VAE-2. In *Advances in Neural Information Processing Systems*, pages 14837–14847, 2019.
- [46] Danilo Rezende and Shakir Mohamed. Variational inference with normalizing flows. In *International Conference on Machine Learning*, pages 1530–1538, 2015.
- [47] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. In *International Conference on Machine Learning*, pages 1278–1286, 2014.

- [48] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 234–241. Springer, 2015.
- [49] Tim Salimans and Durk P Kingma. Weight normalization: A simple reparameterization to accelerate training of deep neural networks. In *Advances in Neural Information Processing Systems*, pages 901–909, 2016.
- [50] Tim Salimans, Diederik Kingma, and Max Welling. Markov Chain Monte Carlo and variational inference: Bridging the gap. In *International Conference on Machine Learning*, pages 1218–1226, 2015.
- [51] Tim Salimans, Ian Goodfellow, Wojciech Zaremba, Vicki Cheung, Alec Radford, and Xi Chen. Improved techniques for training gans. In *Advances in Neural Information Processing Systems*, pages 2234–2242, 2016.
- [52] Tim Salimans, Andrej Karpathy, Xi Chen, and Diederik P Kingma. PixelCNN++: Improving the PixelCNN with discretized logistic mixture likelihood and other modifications. In *International Conference on Learning Representations*, 2017.
- [53] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, pages 2256–2265, 2015.
- [54] Jiaming Song, Shengjia Zhao, and Stefano Ermon. A-NICE-MC: Adversarial training for MCMC. In *Advances in Neural Information Processing Systems*, pages 5140–5150, 2017.
- [55] Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems*, pages 11895–11907, 2019.
- [56] Yang Song and Stefano Ermon. Improved techniques for training score-based generative models. *arXiv preprint arXiv:2006.09011*, 2020.
- [57] Aaron van den Oord, Sander Dieleman, Heiga Zen, Karen Simonyan, Oriol Vinyals, Alex Graves, Nal Kalchbrenner, Andrew Senior, and Koray Kavukcuoglu. WaveNet: A generative model for raw audio. *arXiv preprint arXiv:1609.03499*, 2016.
- [58] Aaron van den Oord, Nal Kalchbrenner, and Koray Kavukcuoglu. Pixel recurrent neural networks. *International Conference on Machine Learning*, 2016.
- [59] Aaron van den Oord, Nal Kalchbrenner, Oriol Vinyals, Lasse Espeholt, Alex Graves, and Koray Kavukcuoglu. Conditional image generation with PixelCNN decoders. In *Advances in Neural Information Processing Systems*, pages 4790–4798, 2016.
- [60] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017.
- [61] Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural Computation*, 23(7):1661–1674, 2011.
- [62] Sheng-Yu Wang, Oliver Wang, Richard Zhang, Andrew Owens, and Alexei A Efros. Cnn-generated images are surprisingly easy to spot...for now. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2020.
- [63] Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7794–7803, 2018.
- [64] Auke J Wiggers and Emiel Hoogeboom. Predictive sampling with forecasting autoregressive models. *arXiv preprint arXiv:2002.09928*, 2020.
- [65] Hao Wu, Jonas Köhler, and Frank Noé. Stochastic normalizing flows. *arXiv preprint arXiv:2002.06707*, 2020.
- [66] Yuxin Wu and Kaiming He. Group normalization. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 3–19, 2018.
- [67] Jianwen Xie, Yang Lu, Song-Chun Zhu, and Yingnian Wu. A theory of generative convnet. In *International Conference on Machine Learning*, pages 2635–2644, 2016.
- [68] Jianwen Xie, Song-Chun Zhu, and Ying Nian Wu. Synthesizing dynamic patterns by spatial-temporal generative convnet. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7093–7101, 2017.

- [69] Jianwen Xie, Zilong Zheng, Ruiqi Gao, Wenguan Wang, Song-Chun Zhu, and Ying Nian Wu. Learning descriptor networks for 3d shape synthesis and analysis. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 8629–8638, 2018.
- [70] Jianwen Xie, Song-Chun Zhu, and Ying Nian Wu. Learning energy-based spatial-temporal generative convnets for dynamic patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2019.
- [71] Fisher Yu, Yinda Zhang, Shuran Song, Ari Seff, and Jianxiong Xiao. LSUN: Construction of a large-scale image dataset using deep learning with humans in the loop. *arXiv preprint arXiv:1506.03365*, 2015.
- [72] Sergey Zagoruyko and Nikos Komodakis. Wide residual networks. *arXiv preprint arXiv:1605.07146*, 2016.

补充信息

LSUN LSUN 数据集的 FID 分数见 表 3。带 * 的分数由 StyleGAN2 作为基线报告，其余分数由各自作者报告。

表 3: LSUN 256×256 数据集的 FID 分数

模型	LSUN Bedroom	LSUN Church	LSUN Cat
ProgressiveGAN [27]	8.34	6.42	37.52
StyleGAN [28]	2.65	4.21*	8.53*
StyleGAN2 [30]	-	3.86	6.93
Ours (L_{simple})	6.36	7.89	19.75
Ours ($L_{\text{simple, large}}$)	4.90	-	-

渐进式压缩 章节 4.3 中的有损压缩论证仅是概念验证，因为 Algorithms 3 and 4 依赖如最小随机编码 [20] 的过程，而后者对高维数据并不可行。这些算法充当 Sohl-Dickstein et al. [53] 变分界 (5) 的压缩解释，尚不是实用压缩系统。

表 4: 无条件 CIFAR10 测试集率失真数值 (配合 图 5)

反向过程时间 ($T - t + 1$)	码率 (每维比特)	失真 (RMSE [0, 255])
1000	1.77581	0.95136
900	0.11994	12.02277
800	0.05415	18.47482
700	0.02866	24.43656
600	0.01507	30.80948
500	0.00716	38.03236
400	0.00282	46.12765
300	0.00081	54.18826
200	0.00013	60.97170
100	0.00000	67.60125

A 扩展推导

下面给出 Eq. (5) (扩散模型的降方差变分界) 的推导。该内容出自 Sohl-Dickstein et al. [53], 此处仅为完整起见收录。

$$L = \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \quad (17)$$

$$= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \quad (18)$$

$$= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} - \log \frac{p_\theta(\mathbf{x}_0|\mathbf{x}_1)}{q(\mathbf{x}_1|\mathbf{x}_0)} \right] \quad (19)$$

$$= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \cdot \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)} - \log \frac{p_\theta(\mathbf{x}_0|\mathbf{x}_1)}{q(\mathbf{x}_1|\mathbf{x}_0)} \right] \quad (20)$$

$$= \mathbb{E}_q \left[-\log \frac{p(\mathbf{x}_T)}{q(\mathbf{x}_T|\mathbf{x}_0)} - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right] \quad (21)$$

$$= \mathbb{E}_q \left[D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T)) + \sum_{t \geq 1} D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right] \quad (22)$$

以下为 L 的另一种形式。虽难以估计，但对 章节 4.3 中的讨论有用。

$$L = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \quad (23)$$

$$= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t)} \cdot \frac{q(\mathbf{x}_{t-1})}{q(\mathbf{x}_t)} \right] \quad (24)$$

$$= \mathbb{E}_q \left[-\log \frac{p(\mathbf{x}_T)}{q(\mathbf{x}_T)} - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t)} - \log q(\mathbf{x}_0) \right] \quad (25)$$

$$= D_{\text{KL}}(q(\mathbf{x}_T) \parallel p(\mathbf{x}_T)) + \mathbb{E}_q \left[\sum_{t \geq 1} D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) \right] + H(\mathbf{x}_0) \quad (26)$$

B 实验细节

本文神经网络架构沿用 PixelCNN++ [52] 的主干，即基于 Wide ResNet [72] 的 U-Net [48]。为使实现更简单，将权重归一化 [49] 替换为组归一化 [66]。32 × 32 模型使用四档特征图分辨率 (32 × 32 至 4 × 4)，256 × 256 模型使用六档。所有模型在每个分辨率层有两个卷积残差块，并在卷积块之间的 16 × 16 分辨率处设置自注意力块 [6]。扩散时间 t 通过向每个残差块加入 Transformer 正弦位置嵌入 [60] 指定。CIFAR10 模型有 3570 万参数，LSUN 与 CelebA-HQ 模型有 1.14 亿参数。还通过增加滤波器数量训练了约 2.56 亿参数的大型 LSUN Bedroom 模型变体。

所有实验均使用 TPU v3-8 (约等于 8 块 V100 GPU)。CIFAR 模型在批大小 128 下以每秒 21 步训练 (800k 步约 10.6 小时完成训练)，采样一批 256 张图像需 17 秒。CelebA-HQ/LSUN (256²) 模型在批大小 64 下以每秒 2.2 步训练，采样一批 128 张图像需 300 秒。CelebA-HQ 训练 0.5M 步，LSUN Bedroom 训练 2.4M 步，LSUN Cat 训练 1.8M 步，LSUN Church 训练 1.2M 步。大型 LSUN Bedroom 模型训练 1.15M 步。

除早期为使网络规模适配内存限制而作的最初超参数选择外，大部分超参数搜索用于优化 CIFAR10 样本质量，随后将结果设置迁移到其他数据集：

- β_t 调度从常数、线性、二次三类中选取，均约束 $L_T \approx 0$ 。未作扫掠而直接设 $T = 1000$ ，并选择从 $\beta_1 = 10^{-4}$ 到 $\beta_T = 0.02$ 的线性调度。
- CIFAR10 的 dropout 率在 {0.1, 0.2, 0.3, 0.4} 中扫掠后设为 0.1。CIFAR10 不使用 dropout 时样本较差，令人联想到未正则化 PixelCNN++ 的过拟合伪影 [52]。其他数据集未扫掠，dropout 率设为 0。
- CIFAR10 训练时使用随机水平翻转；尝试过有无翻转两种训练，发现翻转可略微提升样本质量。除 LSUN Bedroom 外的所有数据集也使用随机水平翻转。
- 实验初期尝试过 Adam [31] 与 RMSProp，最终选择前者。超参数保持标准值。学习率未扫掠，设为 2×10^{-4} ；对 256 × 256 图像降至 2×10^{-5} ，因用较大学习率训练似乎不稳定。
- CIFAR10 批大小设为 128，更大图像设为 64。未对这些值扫掠。
- 对模型参数使用衰减系数 0.9999 的 EMA。未对该值扫掠。

最终实验训练一次，并在整个训练过程中评估样本质量。样本质量分数与对数似然按训练过程中 FID 最小值报告。CIFAR10 上分别用 OpenAI [51] 与 TTUR [21] 仓库的原始代码，在 50000 个样本上计算初始分数与 FID。LSUN 上用 StyleGAN2 [30] 仓库的代码，在 50000 个样本上计算 FID。CIFAR10 与 CelebA-HQ 按 TensorFlow Datasets 提供的方式加载 (<https://www.tensorflow.org/datasets>)，LSUN 用 StyleGAN 代码准备。数据集划分 (或未划分) 沿用在生成建模语境中引入其使用的论文的标准做法。所有细节可在源码发布中找到。

C 相关工作讨论

本文的模型架构、前向过程定义与先验在细微但重要的方面不同于 NCSN [55, 56], 从而提升样本质量; 值得注意的是, 本文直接将采样器作为潜变量模型训练, 而非训练后再事后添加。更详细地说:

1. 本文使用带自注意力的 U-Net; NCSN 使用带膨胀卷积的 RefineNet。通过加入 Transformer 正弦位置嵌入使所有层以 t 为条件, 而非仅在归一化层 (NCSNv1) 或仅在输出处 (v2)。
2. 扩散模型在前向过程的每一步按 $\sqrt{1-\beta_t}$ 因子缩放数据, 使加噪时方差不增长, 从而为神经网络反向过程提供缩放一致的输入。NCSN 省略该缩放因子。
3. 与 NCSN 不同, 本文的前向过程会破坏信号 ($D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})) \approx 0$), 确保先验与 $\mathbf{x}_T$ 的聚合后验紧密匹配。此外与 NCSN 不同, 本文 β_t 很小, 确保前向过程可由条件高斯马尔可夫链逆转。这两个因素都防止采样时出现分布偏移。
4. 本文的类朗之万采样器系数 (学习率、噪声尺度等) 由前向过程 β_t 严格推导。因此训练过程直接训练采样器在 T 步后匹配数据分布: 即用变分推断将采样器作为潜变量模型训练。相比之下, NCSN 的采样器系数事后手工设定, 其训练过程不保证直接优化采样器的质量指标。

D 样本

更多样本 图 11, 13, 16, 17, 18, 与 19 展示在 CelebA-HQ、CIFAR10 与 LSUN 数据集上训练的扩散模型生成的未经挑选的样本。

潜变量结构与反向过程随机性 采样时, 先验 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 与朗之万动力学均为随机的。为理解第二类噪声源的意义, 对 CelebA 256×256 数据集, 在条件于同一中间潜变量的情况下采样多幅图像。图 7 展示共享潜变量 $\mathbf{x}_t$ ($t \in \{1000, 750, 500, 250\}$) 的反向过程 $\mathbf{x}_0 \sim p_\theta(\mathbf{x}_0|\mathbf{x}_t)$ 的多次抽取。为此, 从先验的一次抽取出发运行单条反向链。在中间时间步, 链被拆分以采样多幅图像。若链在 $\mathbf{x}_{T=1000}$ 处先验抽取后即拆分, 样本差异显著; 但若在更多步之后再拆分, 样本共享性别、发色、眼镜、饱和度、姿态与面部表情等高层属性。这表明 $\mathbf{x}_{750}$ 等中间潜变量编码了这些属性, 尽管它们并不可感知。

从粗到细插值 图 9 展示随潜空间插值前扩散步数变化, 一对 CelebA 256×256 源图像之间的插值。增加扩散步数会破坏源图像更多结构, 模型在反向过程中补全。由此可在精细与粗糙两种粒度上插值。极限情形下, 0 步扩散的插值在像素空间混合源图像; 而 1000 步扩散后源信息丢失, 插值成为全新样本。




图 9: 改变潜变量混合前扩散步数的从粗到细插值。





图 10: 无条件 CIFAR10 渐进采样质量随时间变化



图 11: CelebA-HQ 256×256 生成样本



(a) 像素空间最近邻



(b) Inception 特征空间最近邻

图 12: CelebA-HQ 256×256 最近邻, 在面部周围 100×100 裁剪区域上计算。生成样本在最左列, 训练集最近邻在其余各列。




图 13: 无条件 CIFAR10 生成样本






图 14: 无条件 CIFAR10 渐进生成



(a) 像素空间最近邻



(b) Inception 特征空间最近邻

图 15: 无条件 CIFAR10 最近邻。生成样本在最左列, 训练集最近邻在其余各列。



图 16: LSUN Church 生成样本。FID=7.89



图 17: LSUN Bedroom 生成样本 (大型模型)。FID=4.90




图 18: LSUN Bedroom 生成样本 (小型模型)。FID=6.36



图 19: LSUN Cat 生成样本。FID=19.75