

告别基于学习的车辆运动规划的误区

Parting with Misconceptions about Learning-based Vehicle Motion Planning

Daniel Dauner^{1,2} Marcel Hallgarten^{1,3} Andreas Geiger^{1,2} Kashyap Chitta^{1,2}

¹University of Tübingen

²Tübingen AI Center

³Robert Bosch GmbH

https://github.com/autonomousvision/tuplan_garage

Abstract: nuPlan 的发布标志着车辆运动规划研究进入新时代，提供了首个大规模真实世界数据集及评测方案，要求同时具备精确短期规划与长时域自车预测（Ego-forecasting）能力。现有系统难以同时满足这两项需求。事实上，本文发现这些任务存在根本性错配，应独立处理。本文进一步评估当前领域内闭环（Closed-loop）规划研究现状，揭示基于学习（Learning-based）方法在复杂真实场景（Scenario）中的局限性，以及简单基于规则（Rule-based）先验（如通过车道图（Lane graph）搜索算法选择中心线（Centerline））的价值。更令人惊讶的是，对于开环（Open-loop）子任务，本文观察到仅使用该中心线作为场景上下文（即忽略所有地图及其他智能体信息）即可取得最佳结果。综合这些见解，本文提出一个极为简单高效的规划器，其性能超越大量竞争对手，赢得 2023 年 nuPlan 规划挑战赛。

Keywords: 运动规划 (Motion Planning), 自动驾驶 (Autonomous Driving), 数据驱动仿真 (Data-driven Simulation)

1 引言

尽管基于学习的系统在车辆运动规划研究中取得了成功 [1, 2, 3, 4, 5]，但缺乏标准化的大规模基准数据集阻碍了其从研究向应用的转移 [6, 7, 8]。最近发布的 nuPlan 数据集和仿真器 [9]（包含 1300 小时真实世界车辆运动数据的集合）改变了这一现状，推动了新一代基于学习的运动规划器的发展，这些规划器有望减少人工设计工作并提升可扩展性。借助这一新基准，在大规模、开源、数据驱动的车辆运动规划仿真器上进行了首次严格的实证分析，包括使用官方指标对一组全面的最先进（SoTA）规划器 [10, 11, 12] 进行评测。分析得出了若干令人惊讶的发现：

开环评测与闭环评测不一致。 大多数基于学习的规划器通过监督学习任务进行训练，即预测自车在给定目标位置条件下的未来运动。将这一设定称为自车预测（ego-forecasting）[2, 3, 13, 14]。在 nuPlan 中，规划器可以通过两种方式进行评测：（1）开环评测，使用基于距离的指标衡量自车预测精度；或（2）闭环评测，在仿真中使用通行进度或碰撞率等指标评估实际驾驶性能。开环评测缺乏动态反馈，与闭环驾驶的相关性可能很低，这一点先前在简陋的 CARLA 仿真器上已得到证明 [15, 16]。本文的主要贡献在于揭示两种评测方案之间存在负相关性。基于学习的规划器擅长自车预测，但难以制定安全的闭环规划，而基于规则的规划器则呈现相反的趋势。

基于规则的规划具有泛化能力。 令人惊讶地发现，二十多年前建立的基于规则的规划基线 [17] 在闭环评测指标上超越了所有最先进的基于学习的方法。这与大多数基于学习的规划器研究中普遍使用的动机性主张相矛盾，即认为基于规则的规划难以泛化。此前这仅在更简单的基准上得到过验证 [4, 10, 11]。因此，当前大多数基于学习的规划研究仅与其他学习方法进行比较，忽略了基于规则的基线 [3, 5, 18]。

中心线即可满足自车预测需求。 实现了一个简陋的基于学习的规划基线，该基线不融入场景中其他智能体的任何信息，仅根据期望路线的中心线表示对自车状态进行外推。该基线在

开环评测上树立了新的最先进水平。它不需要复杂的场景表示（例如车道图、向量化地图、栅格化地图、分词化目标），而这些恰是先前研究的核心课题 [10, 11, 12]。这些先前的研究均未考虑简单的仅含中心线的表示作为基线，或许是因为其过于简单。

本文的贡献如下：(1) 论证并分析了规划中开环与闭环评测方案之间的不一致性。(2) 提出了一种轻量级扩展的 IDM [17]，具有实时能力，达到了最先进的闭环性能。(3) 通过一个仅以当前动态状态和中心线为条件的开环规划器进行实验，表明其性能优于具有复杂输入表示的复杂模型。(4) 通过将两种模型结合为混合规划器，建立了一个简单的基线，该基线优于其他 24 种（通常是基于学习的）竞争方法，并在 2023 年 nuPlan 挑战赛中获胜。

2 相关工作

基于规则的规划。 基于规则的规划器提供结构化、可解释的决策框架 [17, 19, 20, 21, 22, 23, 24, 25, 26]。它们采用显式规则决定自动驾驶车辆行为（例如，当物体正前方时制动）。基于规则规划的奠基性方法是智能驾驶员模型（Intelligent Driver Model, IDM [17]），该模型旨在跟随前车行驶并保持安全距离。

已存在一些 IDM 的扩展方法 [27]，专注于实现高速公路换道。然而，这并非本文目标。相反，我们扩展 IDM，通过执行多个具有不同超参数的策略并评分以选择最优方案。

已有研究还将基于规则的决策与学习组件（learned components）结合，例如学习型智能体预测（agent forecasts）[28]、可供性指示器（affordance indicators）[23, 24]、基于代价的模仿学习（cost-based imitation learning）[4, 29, 30, 31, 32] 或采用基于规则安全过滤（safety filtering）的学习型规划 [33]。这些混合规划器（hybrid planners）通常预测未来环境状态，从而做出知情且应变的驾驶决策。这种预测可以是以智能体为中心的（agent-centric）[34, 35, 36]（为每个参与者确定轨迹），也可以是以环境为中心的（environment-centric）[4, 31, 30, 29, 37, 38]（涉及占据地图或代价地图）。此外，预测可以以自车规划（ego-plan）为条件，建模自车对场景未来的影响 [39, 40, 41, 42]。我们采用以智能体为中心的预测模块，比现有方法简单得多，使其能作为新发布的 nuPlan 框架的起点。

自车预测。 自车预测方法不同于预测性规划（predictive planning），利用观测数据直接确定未来轨迹。自车预测方法包括利用 LiDAR 扫描 [44, 45]、RGB 图像 [46, 47, 48, 49, 14, 50] 或二者兼用 [13, 51, 5, 52] 的端到端方法（end-to-end methods）[43]，以及涉及低维输入（如鸟瞰图（Bird’s eye view, BEV）栅格或状态向量）的模块化方法 [24, 53, 11, 54, 55, 56]。一项同期研究引入朴素 MLP，输入当前动态状态，在无场景上下文输入的情况下在 nuScenes 数据集上取得有竞争力的自车预测结果 [57, 58]。上述发现补充了这些结果，不同之处在于在 2023 年 nuPlan 挑战赛场景测试分布中对长期（8 秒）自车预测进行评估 [9]。结果表明，在此设置下，完全移除场景上下文（如 [58] 所述）有害，而简单中心线上下文表示足以取得强劲的开环性能。

3 自车预测与规划是错位的

本节介绍数据驱动仿真器 nuPlan [9] 的相关背景。我们描述两个基线模型进行初步实验，证明尽管自车预测与规划常被视为相关任务，但基于 nuPlan 的定义，二者并不对齐。一项任务的改进往往导致另一项任务性能下降。

3.1 背景

nuPlan 仿真器。 nuPlan 仿真器是首个公开的真实世界规划基准，支持运动规划器的快速原型开发与测试。nuPlan 通过数据驱动仿真 [59, 60, 61, 62, 63, 64, 65] 尽可能构建接近真实驾驶环境的仿真场景。该方法从包含 1,300 小时真实驾驶数据的预记录数据集中提取道路地图、交通模式和物体属性（位置、朝向和速度）。这些要素用于初始化场景——15 秒的仿真，用于评估开环和闭环驾驶性能。因此，在仿真中，方法依赖详细的高精地图信息和真值感知，即不考虑定位误差、地图缺陷或检测错误。开环仿真中，整个日志仅作回放（自车与其他交通参与者均如此）。相反，闭环仿真中，自车由被测试的规划器控制。闭环仿真有两




图 1: 规划与自车预测对比。展示一个 nuPlan 场景, 灰色区域为可行驶区域, 黑色虚线为原始人类轨迹。每张快照中显示 **自车智能体** 及其 **预测**。(左) 观察到 IDM 预测 (受限于基于规则的中心线) 与人类轨迹之间存在显著偏移, 导致开环得分较低。(中、右) 仿真 0.5 秒后, 学习型 PDM-Open 规划器积累自身误差, 最终偏离道路, 导致闭环得分欠佳。

个版本: 非反应式, 所有其他交通参与者沿原始轨迹回放; 反应式, 其他车辆使用下文详述的智能驾驶员模型 (Intelligent Driver Model, IDM) 规划器 [17]。

评估指标. nuPlan 提供三个官方评估指标: 开环得分 (OLS, Open-Loop Score)、闭环非反应式得分 (CLS-NR, Closed-Loop Score Non-Reactive) 和闭环反应式得分 (CLS-R, Closed-Loop Score Reactive)。尽管 CLS-NR 和 CLS-R 计算方式相同, 但二者背景交通行为不同。每个得分是子得分的加权平均, 再乘以一组惩罚项。OLS 的子得分考虑长时间 (8 秒) 内的平均和最终位移误差与航向误差。此外, 若预测误差超过阈值, 该场景的 OLS 得分为零。类似地, CLS 的子得分包括碰撞时间、沿专家路线的通行进度、限速合规性和舒适度。乘法性 CLS 惩罚项包括过错碰撞、可行驶区域或行驶方向违规、以及未取得通行进度。这些惩罚会导致 CLS 大幅降低, 通常在碰撞等情况下场景得分归零。值得注意的是, CLS 主要依赖短期动作而非一致的长时规划。所有得分 (含 OLS/CLS) 范围为 0 到 100, 越高越好。鉴于 nuPlan 指标的复杂构成, 详细描述参见补充材料。

智能驾驶员模型. 简单规划基线 IDM [17] 不仅模拟 CLS-R 评估中的非自车车辆, 也作为自车规划基线。nuPlan 地图以图结构提供, 中心线段作为节点。通过图搜索算法选定一组待跟随节点后, IDM 沿所选中心线推断纵向轨迹。给定当前纵向位置 x 、速度 v 以及沿中心线到前车的距离 s , 它迭代应用以下策略计算纵向加速度:

$$\frac{dv}{dt} = a \left(1 - \left(\frac{v}{v_0} \right)^\delta - \left(\frac{s^*}{s} \right)^2 \right). \quad (1)$$

加速度极限 a 、目标速度 v_0 、安全距离 s^* 和指数 δ 均为手动选取。直观而言, 该策略使用加速度 a 行驶, 除非速度已接近 v_0 或前车距离仅为 s^* 。更多细节及超参数选择参见补充材料。

3.2 错位证明

基于中心线的自车预测. 现提出预测驾驶员模型 (开环), 即 PDM-Open, 这是一个用于预测未来航点的简单多层感知机 (MLP, Multi-Layer Perceptron)。该 MLP 的输入为由 IDM 提取的中心线 ($\mathbf{c}$) 和自车历史 ($\mathbf{h}$)。为适应 nuPlan 中的高速 (最高 15 m/s) 和自车预测时域 (最长 8 秒), 中心线以 1 米分辨率采样, 最长 120 米。同时, 自车历史包含过去两秒内车辆的位置、速度和加速度, 以 5Hz 采样。 $\mathbf{c}$ 和 $\mathbf{h}$ 分别线性投影为 512 维特征向量, 拼接后输入具有两个 512 维隐藏层的 MLP ϕ_{open} , 输出为 8 秒时域内每 0.5 秒一个的未来航点, 表示为 $\mathbf{w}_{\text{open}} = \phi_{\text{open}}(\mathbf{c}, \mathbf{h})$ 。模型在 177k 样本的训练数据集上使用 L_1 损失训练 (详见 Section 4)。按设计, PDM-Open 比现有学习型规划器 [10, 12] 简单得多。

开环得分与闭环得分对比. 在 Table 1 中, 我们使用 nuPlan 指标对 IDM 和 PDM-Open 基线进行基准测试。展示两种不同最大加速度值的 IDM 变体 (默认 $a = 1.0\text{ms}^{-2}$ 和 $a = 0.1\text{ms}^{-2}$) 以及四种基于不同输入

心线	史状态	环反应式得分 (CLS-R) ↑	环非反应式得分 (CLS-NR) ↑	环得分 (OLS) ↑
----	-----	------------------	--------------------	-------------




图 2: 架构。PDM-Closed 选择中心线、预测环境并生成多种候选轨迹，经仿真和评分后进行轨迹选择。PDM-Hybrid 模块利用 PDM-Closed 的中心线、轨迹和自车历史预测偏移量，仅修正长时域航点，从而限制学习模型在闭环仿真中的影响。

提升 OLS 但损害 CLS。IDM 表现出强闭环性能，而 PDM-Open 在开环中优于 IDM，即使仅使用当前自车状态作为输入（第一行）。过去自车状态（历史）仅带来微小改善且导致 CLS 下降。最重要的是，加入中心线显著提升自车预测性能。CLS 与 OLS 之间清晰的权衡表明自车预测与规划目标之间的错位。考虑到当前规划文献 [3, 10, 12, 11] 中自车预测使用日益增多，这种 nuPlan 上的反向相关性出乎意料。尽管自车预测对驾驶性能并非必需，nuPlan 挑战赛同时要求高 OLS 和 CLS。

Fig. 1 展示 OLS 与 CLS 指标之间的错位。在所场景中，基于规则 IDM 选择了与人类驾驶员不同的车道，但能在整个仿真中保持在道路上，从而获得高 CLS 但低 OLS。相反，学习型 PDM-Open 沿人类驾驶员所选车道生成预测，因而获得高 OLS。然而，随着仿真中短期预测误差累积 [66, 67]，模型轨迹偏离可行驶区域，最终导致 CLS 欠佳。

3.3 方法

现结合模型预测控制中的若干概念扩展 IDM，包括预测、候选轨迹生成、仿真、评分和选择，如 Fig. 2（上）所示。称该模型为 PDM-Closed。注意，第一步仍需通过图搜索找到沿路线的车道序列并提取其中心线，与 IDM 规划器相同。

预测。 nuPlan 仿真器为每个动态智能体（如车辆或行人）提供朝向向量和速度。采用简单有效的恒速预测 [68, 69, 70]，时域 F 为 8 秒，频率 10Hz。

候选轨迹生成。 校准 IDM 规划器时，我们发现选择单一目标速度超参数 (v_0) 存在权衡，在不同场景中可能导致激进驾驶或通行进度不足。因此，以五个不同目标速度实现 IDM 策略生成一组候选轨迹，即速度限制的 $\{20\%, 40\%, 60\%, 80\%, 100\%\}$ 。每个目标速度还结合三种

方法	表示	闭环反应式得分 (CLS-R) $\uparrow$	闭环非反应式得分 (CLS-NR) $\uparrow$	开
Urban Driver [10]	Polygon	50	53	
GC-PGP [12]	Graph	55	59	
PlanCNN [11]	Raster	72	73	
IDM [17]	Centerline	77	76	
PDM-Open	Centerline	54	50	
PDM-Closed	Centerline	92	93	
PDM-Hybrid	Centerline	92	93	
PDM-Hybrid*	Graph	92	93	
<i>Log Replay</i>	<i>GT</i>	<i>80</i>	<i>94</i>	

表 2: **Val14 基准.** 我们展示了多种规划器的闭环反应式/非反应式得分 (CLS-R/CLS-NR)、开环得分 (OLS) 以及运行时间 (毫秒)。我们列出了每种规划器使用的输入表示 (表示)。PDM-Hybrid 实现了强大的自行车预测 (OLS) 和规划 (CLS) 能力。* 这是 PDM-Hybrid 的一个初步版本, 它将 PDM-Closed 与 GC-PGP [12] 结合, 用于我们的在线排行榜提交 (Table 3)。

横向中心线偏移量 ($\pm 1\text{m}$ 和 0m), 共生成 $N = 15$ 条候选轨迹。为避免后续阶段的计算开销, 候选轨迹采用缩减时域 H 步, 对应 4 秒、10Hz。

仿真. nuPlan 中的轨迹通过迭代从 LQR 控制器 [71] 获取动作并使用运动学自行车模型 [72, 73] 推进自行车来仿真。使用相同参数和该两阶段流程的快速重实现来仿真候选轨迹, 从而基于闭环中的预期运动评估各候选轨迹。

评分. 每条仿真后的候选轨迹根据交通规则合规性、通行进度和舒适度进行评分。通过考虑具有横向和纵向多样性的候选轨迹, 规划器可避免与预测智能体碰撞, 并纠正控制器未能准确跟踪预期轨迹时可能产生的偏移。此外, 评分函数与 nuPlan 评估指标高度相似。更多细节参见补充材料。

轨迹选择. 最后, PDM-Closed 选择得分最高的候选轨迹, 并使用相应 IDM 策略将其扩展至完整预测时域 F 。若最佳轨迹预计在 2 秒内发生碰撞, 则输出被紧急制动操作覆盖。

提升长时域精度. 为整合 PDM-Open 的精确自行车预测能力与 PDM-Closed 的精准短期动作, 现提出 PDM 的混合版本, 即 PDM-Hybrid。具体而言, PDM-Hybrid 使用学习模块 PDM-Offset 预测 PDM-Closed 航点的偏移量, 如 Fig. 2 (下) 所示。

实践中, nuPlan 使用的 LQR 控制器在闭环中确定动作时仅依赖轨迹的前 2 秒。因此, 仅对长时域航点 (即默认 2 秒后, 称为修正时域 C) 施加修正, 使 PDM-Hybrid 能够保持闭环规划性能。最终规划器输出航点 (至预测时域 F) $\{\mathbf{w}_{\text{Hybrid}}^t\}_{t=0}^F$, 由下式给出:

$$\mathbf{w}_{\text{Hybrid}}^t = \mathbf{w}_{\text{Closed}}^t + \mathbb{1}_{[t>C]} \phi_{\text{Offset}}^t(\mathbf{w}_{\text{Closed}}, \mathbf{c}, \mathbf{h}). \quad (2)$$

其中 $\mathbf{c}$ 和 $\mathbf{h}$ 是中心线和历史 (与 PDM-Open 的输入相同)。 $\{\mathbf{w}_{\text{Closed}}^t\}_{t=0}^F$ 是 PDM-Closed 的航点, 作为混合方法的输入, ϕ_{Offset} 是一个 MLP。其架构与 ϕ_{Open} 相同, 但增加了一个线性投影以将 $\mathbf{w}_{\text{Closed}}$ 作为额外输入。

PDM-Hybrid 具有高度模块化设计, 可在不同需求出现时替换单个组件。例如, 补充材料展示了使用不同开环模块的结果。鉴于其整体简洁性, 一个值得探索的方向是将模块化且可微分的算法作为组件融入其中, 如 [34] 所示。另一个有趣方向是将这些模块整合到统一的多任务架构中。此类探索留作未来工作。

4 实验

本节介绍我们提出的基准测试并展示我们方法的驾驶性能。

Val14 基准. 我们提供了标准化的训练和评估数据划分。训练使用 nuPlan 中的所有 70 种场景类型, 每种类型限制最多 4k 个场景, 总计约 177k 个训练场景。评估方面, 我们使用排行榜所考虑的 14 种场景类型中的 100 个场景, 共 1,118 个场景。尽管存在轻微的样本不平衡 (并非全部 14 种类型均有 100 个可用场景), 我们的验证划分与在线排行榜评估一致 (Table 2 和 Table 3), 证实了我们的 Val14 基准作为在线测试集代理指标的适用性。

基线方法. 我们在研究中纳入了若干采用自车预测 (ego-forecasting) 进行规划的最先进 (SoTA) 方法。Urban Driver [10] 使用 PointNet 层编码多边形 (polygon)，并在多头注意力块之后通过线性层预测轨迹。我们的研究使用了在开环 (open-loop) 设置下训练的 Urban Driver 实现。GC-PGP [12] 基于受路径约束的车道图遍历对轨迹提案进行聚类，然后返回最可能的聚类中心。PlanCNN [11] 使用 CNN 从栅格化 (rasterized) 网格特征预测航点，无需自车状态输入。它与该领域的开创性工作 ChauffeurNet [8] 有若干相似之处。赢得 nuPlan 竞赛的 PDM-Hybrid 初版使用了 GC-PGP 作为其自车预测组件，我们将此版本作为基线纳入。我们在补充材料中提供了该版本的完整描述。

实验结果. 我们的实验结果列于 Table 2。PlanCNN 在学习型规划器中取得了最佳的闭环得分 (CLS)，这可能是由于其从输入中移除自车状态的设计选择，以开环得分 (OLS) 换取增强的 CLS。与社区在预测和规划中日益偏好基于图和向量的场景表示不同 [74, 11, 75, 76]，这些结果表明栅格 (raster) 表示在闭环任务中并无明显劣势，且 PlanCNN 还提供了更低的运行时间。令人惊讶的是，我们研究中最简单的基于规则的方法 IDM 超越了最佳学习型规划器 PlanCNN。此外，我们观察到 PDM-Closed 在 CLS 方面相较于 IDM 的优势：得益于 Section 3 中的思想，得分从 76-77 提升至 92-93。令人惊讶的是，PDM-Open 仅使用中心线 (centerline) 和自车状态作为输入，便以仅 7ms 的运行时间达到了最高的 OLS 86。我们观察到 PDM-Open 在精确的长时域车道跟随方面优于其他方法，详见补充材料。接下来，尽管 PDM-Closed 的 OLS 42 不尽人意，但 PDM-Hybrid 成功地将 PDM-Closed 与 PDM-Open 结合起来。PDM-Hybrid 的中心线版本和图版本在我们的评估中取得了相同的分数。然而，最终的中心线版本使用 PDM-Open 替代 GC-PGP，在推理时更为高效。最后，输出真值 (GT) 自车未来轨迹的特权方法 (日志回放, log replay) 未能取得完美的 CLS，部分原因是 nuPlan 框架的 LQR 控制器偶尔会偏离所提供的轨迹。PDM-Hybrid 通过基于预期控制器输出评估提案来补偿这一不足，使其在闭环评估中达到或超越日志回放的表现。

挑战赛. 在 2023 年 nuPlan 挑战赛中，PDM-Hybrid 的初版 (图版本) 在 25 支参赛队伍中排名第一。排行榜取闭环反应式得分 (CLS-R)、闭环非反应式得分 (CLS-NR) 和开环得分 (OLS) 的均值。虽然开环性能略逊一筹，但闭环性能表现出色，最终取得了总体最先进 (SoTA) 得分。遗憾的是，由于排行榜已关闭，我们最终使用更简单的 PDM-Open 模块替代 GC-PGP 的 PDM-Hybrid 中心线版本无法进行基准测试。所有顶尖竞争者均将学习型自车预测与基于规则的后求解器或后处理相结合，以提升挑战赛中的 CLS 性能 [77, 78, 79]。因此，我们预计未来会出现更多混合方法。

重要的是，我们的提交在 Val14 基准 (Table 2) 和官方排行榜 (Table 3) 上记录到了几乎相同的分数。请注意，排行榜上的 Urban Driver 和 IDM 结果由 nuPlan 团队提供，因此它们可能使用了与我们 Table 2 中的实现不同的训练数据和超参数。

消融实验. 我们通过 Table 4 中的消融实验探讨了我们的设计选择。Table 4a 展示了 PDM-Hybrid 在不同修正时域 (correction horizon, C) 从 0s 到 3s 下的闭环反应式得分 (CLS-R) 和开环得分 (OLS)。对全部航点应用航点修正 (即 $C = 0$) 在 OLS 上优于 PDM-Open (87 vs. 86, 见 Table 2)，但与默认值 $C = 2$ 相比，CLS-R 显著下降。另一方面，当从轨迹更深位置开始修正时 (例如 $C = 3$)，OLS 出现明显下降，而对 CLS-R 的影响极小。

对于 PDM-Closed (Table 4b)，我们与基础规划器在三种场景下比较 CLS-R 和运行时间 (ms)：移除横向中心线偏移 (lat.)、纵向 IDM 提案 (lon.) 和环境预测 (cast.)。我们的分析表明，移除提案会降低 CLS-R 效果但加快运行时间。当排除用于创建和评估提案的预测机制时，性能显著下降。然而，运行时间几乎保持不变，表明了简单预测机制的有效性。

方法	闭环反应式得分 (CLS-R) ↑	闭环非反应式得分 (CLS-NR) ↑	开环得分 (OLS) ↑	综合得分 ↑
PDM-Hybrid*	93	93	83	90
hoplan	89	88	85	87
pegasus_multi_path	82	85	88	85
Urban Driver [10]	68	70	86	75
IDM [17]	72	75	29	59

表 3: 2023 nuPlan 挑战赛.

C	闭环反应式得分 (CLS-R)	方法	开环得分 (OLS)	方法	运行时间	开环得分 (OLS) ↑
0.0s		基线		基线		86
2.0s		92 横向	84	较短中心线	55	84
2.5s		92 纵向	84	较粗中心线	64	86
3.0s		92 预测	72	较小 MLP	90	84

(a) PDM-Hybrid (b) PDM-Closed (c) PDM-Open

表 4: **消融研究.** 我们展示了闭环反应式得分 (CLS-R)、开环得分 (OLS) 和运行时间 (毫秒)。我们研究了 (a) PDM-Hybrid 的不同修正时域, (b) 忽略 PDM-Closed 的子模块, 以及 (c) 输入和架构选择对 PDM-Open 的影响。灰色高亮的默认配置实现了最佳权衡。

对于 PDM-Open (Table 4c), 我们测试了三种变体: 更短的中心线 (30m vs. 120m)、更稀疏的中心线 (每 10m vs. 每 1m) 以及更小的 MLP (隐藏维度从 512 缩减至 256)。更小的 MLP 和更短的中心线长度均导致性能下降, 但与完全忽略中心线相比 (Table 1, OLS=72), 影响相对较小。与此同时, 更稀疏的中心线的影响可以忽略不计。

5 讨论

尽管基于规则的规划常因泛化能力有限而受到批评, 但我们的结果表明, 在最接近真实世界评估的闭环 nuPlan 任务中, 该方法表现出色。值得注意的是, 开环成功在某种程度上需要以闭环性能为代价。因此, 模仿训练的自车预测方法在闭环中表现不佳。这表明基于规则的规划器仍然具有潜力, 值得进一步探索。同时, 鉴于模仿方法在直接使用时表现不佳, 它们在 nuPlan 上仍有改进空间。

结合闭环规划和开环自车预测的优势, 本文提出了一种混合模型。然而, 这并未增强闭环驾驶性能; 相反, 它提升了开环性能——同时执行完全相同的驾驶操控。得出的结论是: 将精确的开环自车预测视为实现长期规划目标的先决条件是一种误导。

认识到自车预测在可解释性和评估类人行为方面的潜在重要性, 本文建议将评估聚焦于与闭环驾驶相关的短时段 (e.g., 2 秒)。当前的 nuPlan OLS 定义要求单模态的 8 秒自车预测, 这可能仅对其他应用场景有用, 例如为数据驱动交通仿真中的背景智能体设定目标, 或更好地分配计算资源 (e.g. 优先处理自车预期行驶区域的感知或预测)。我们反对将开环指标作为规划性能的主要指标 [18]。

局限性. 尽管我们在已有 IDM 模型基础上取得了显著改进, 但 PDM 仍无法执行车道变更操控。车道变更尝试常导致自车处于两车道之间时发生碰撞, 从而根据 nuPlan 指标产生高额惩罚。PDM 依赖高精地图和精确的离线感知 [80, 9], 这在真实驾驶场景中可能不可用。虽然基于学习的方法已在真实世界部署中得到验证 [81, 33, 8], 但对基于规则的方案而言仍是一个重大挑战。此外, 除留出测试集外, 本文实验并未专门评估模型在遇到分布偏移 (如未见过的城镇或新型场景类型) 时的泛化能力。所有实验均在单一仿真器 nuPlan 上进行。因此, 有必要认识到 nuPlan 数据驱动仿真方法固有的局限性。当规划器比人类驾驶日志推进更快时, 仿真中自车前方会突然出现物体。对于 CLS-NR, 车辆像现实中观测到的那样独立运动, 忽略自车智能体, 从而导致过于激进的行为。相反, CLS-R 背景智能体依赖 IDM 并严格遵循中心线, 导致不切实际的被动行为。在未来的工作中开发更精细的反应式环境具有很高价值。

结论. 本文揭示了基于学习的车辆运动规划中普遍存在的误区。基于上述见解, 我们提出了 PDM-Hybrid, 它在 IDM 基础上结合了学习得到的自车预测组件。该方法超越了一众竞争对手, 在 2023 年 nuPlan 竞赛中夺得冠军。

致谢

Andreas Geiger 获得了 ERC Starting Grant LEGO-3D (850533)、BMW 项目 KI Delta Learning (项目编号 19A19013O) 以及 DFG EXC 编号 2064/1 (项目编号 390727645) 的资助。Kashyap Chitta 获得了德国联邦教育与研究部 (BMBF) Tübingen AI Center (FKZ: 01IS18039A) 的资助。感谢国际马克斯·普朗克智能系统研究院 (IMPRS-IS) 对 Kashyap Chitta 的支持。同时感谢 Pat Karnchanachari 和 Gianmarco Bernasconi 在榜单提交中帮助解决技术问题, 感谢 Niklas Hanselmann 的校对, 以及 Andreas Zell 的有益讨论。

参考文献

- [1] F. Codevilla, M. Miiller, A. López, V. Koltun, and A. Dosovitskiy. End-to-end driving via conditional imitation learning. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2018.
- [2] F. Codevilla, E. Santana, A. M. López, and A. Gaidon. Exploring the limitations of behavior cloning for autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019.
- [3] N. Rhinehart, R. McAllister, K. Kitani, and S. Levine. PRECOG: prediction conditioned on goals in visual multi-agent settings. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2019.
- [4] W. Zeng, W. Luo, S. Suo, A. Sadat, B. Yang, S. Casas, and R. Urtasun. End-to-end interpretable neural motion planner. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [5] K. Chitta, A. Prakash, B. Jaeger, Z. Yu, K. Renz, and A. Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE Trans. on Pattern Analysis and Machine Intelligence (PAMI)*, 2022.
- [6] M. Bojarski, D. D. Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, J. Zhang, X. Zhang, J. Zhao, and K. Zieba. End to end learning for self-driving cars. *arXiv.org*, 1604.07316, 2016.
- [7] A. Kendall, J. Hawke, D. Janz, P. Mazur, D. Reda, J. M. Allen, V. D. Lam, A. Bewley, and A. Shah. Learning to drive in a day. *arXiv.org*, abs/1807.00412, 2018.
- [8] M. Bansal, A. Krizhevsky, and A. S. Ogale. Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst. In *Proc. Robotics: Science and Systems (RSS)*, 2019.
- [9] H. Caesar, J. Kabzan, K. S. Tan, W. K. Fong, E. M. Wolff, A. H. Lang, L. Fletcher, O. Beijbom, and S. Omari. nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2021.
- [10] O. Scheel, L. Bergamini, M. Wolczyk, B. Osiński, and P. Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.
- [11] K. Renz, K. Chitta, O.-B. Mercea, A. S. Koepke, Z. Akata, and A. Geiger. Plant: Explainable planning transformers via object-level representations. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [12] M. Hallgarten, M. Stoll, and A. Zell. From Prediction to Planning With Goal Conditioned Lane Graph Traversals. *arXiv.org*, 2302.07753, 2023.

- [13] A. Prakash, K. Chitta, and A. Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [14] K. Chitta, A. Prakash, and A. Geiger. Neat: Neural attention fields for end-to-end autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021.
- [15] F. Codevilla, A. M. Lopez, V. Koltun, and A. Dosovitskiy. On offline evaluation of vision-based driving models. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2018.
- [16] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun. CARLA: An open urban driving simulator. In *Proc. Conf. on Robot Learning (CoRL)*, 2017.
- [17] M. Treiber, A. Hennecke, and D. Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 2000.
- [18] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang, L. Lu, X. Jia, Q. Liu, J. Dai, Y. Qiao, and H. Li. Planning-oriented autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [19] S. Thrun, M. Montemerlo, H. Dahlkamp, D. Stavens, A. Aron, J. Diebel, P. Fong, J. Gale, M. Halpenny, G. Hoffmann, K. Lau, C. M. Oakley, M. Palatucci, V. R. Pratt, P. Stang, S. Strohband, C. Dupont, L. Jendrossek, C. Koelen, C. Markey, C. Rummel, J. van Niekerk, E. Jensen, P. Alessandrini, G. R. Bradski, B. Davies, S. Ettinger, A. Kaehler, A. V. Nefian, and P. Mahoney. Stanley: The robot that won the DARPA grand challenge. *Journal of Field Robotics (JFR)*, 23(9):661–692, 2006.
- [20] A. Bacha, C. Bauman, R. Faruque, M. Fleming, C. Terwelp, C. Reinholtz, D. Hong, A. Wicks, T. Alberi, D. Anderson, et al. Odin: Team victortango’s entry in the darpa urban challenge. *Journal of Field Robotics (JFR)*, 25(8), 2008.
- [21] J. J. Leonard, J. P. How, S. J. Teller, M. Berger, S. Campbell, G. A. Fiore, L. Fletcher, E. Frazzoli, A. S. Huang, S. Karaman, O. Koch, Y. Kuwata, D. Moore, E. Olson, S. Peters, J. Teo, R. Truax, M. R. Walter, D. Barrett, A. Epstein, K. Maheloni, K. Moyer, T. Jones, R. Buckley, M. E. Antone, R. Galejs, S. Krishnamurthy, and J. Williams. A perception-driven autonomous urban vehicle. *Journal of Field Robotics (JFR)*, 25(10): 727–774, 2008.
- [22] C. Urmson, J. Anhalt, D. Bagnell, C. Baker, R. Bittner, M. Clark, J. Dolan, D. Duggins, T. Galatali, C. Geyer, et al. Autonomous driving in urban environments: Boss and the urban challenge. *Journal of Field Robotics (JFR)*, 25(8), 2008.
- [23] C. Chen, A. Seff, A. L. Kornhauser, and J. Xiao. Deepdriving: Learning affordance for direct perception in autonomous driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, pages 2722–2730, 2015.
- [24] A. Sauer, N. Savinov, and A. Geiger. Conditional affordance learning for driving in urban environments. In *Proc. Conf. on Robot Learning (CoRL)*, 2018.
- [25] H. Fan, F. Zhu, C. Liu, L. Zhang, L. Zhuang, D. Li, W. Zhu, J. Hu, H. Li, and Q. Kong. Baidu apollo EM motion planner. *arXiv.org*, 1807.08048, 2018.
- [26] A. Sadat, M. Ren, A. Pokrovsky, Y. Lin, E. Yumer, and R. Urtasun. Jointly learnable behavior and trajectory planning for self-driving vehicles. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2019.

- [27] A. Kesting, M. Treiber, and D. Helbing. General lane-changing model mobil for car-following models. *Transportation Research Record*, 1999(1), 2007.
- [28] R. Chekroun, T. Gilles, M. Toromanoff, S. Hornauer, and F. Moutarde. Mbappe: Mcts-built-around prediction for planning explicitly. *arXiv.org*, 2309.08452, 2023.
- [29] A. Cui, A. Sadat, S. Casas, R. Liao, and R. Urtasun. Lookout: Diverse multi-future prediction and planning for self-driving. In *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2021.
- [30] S. Casas, A. Sadat, and R. Urtasun. Mp3: A unified model to map, perceive, predict and plan. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [31] A. Sadat, S. Casas, M. Ren, X. Wu, P. Dhawan, and R. Urtasun. Perceive, predict, and plan: Safe motion planning through interpretable semantic representations. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020.
- [32] Z. Huang, P. Karkus, B. Ivanovic, Y. Chen, M. Pavone, and C. Lv. Dtp: Differentiable joint conditional prediction and cost evaluation for tree policy planning in autonomous driving. *arXiv.org*, 2310.05885, 2023.
- [33] T. Phan-Minh, F. Howington, T.-S. Chu, M. S. Tomov, R. E. Beaudoin, S. U. Lee, N. Li, C. Dicle, S. Findler, F. Suarez-Ruiz, et al. Driveirl: Drive in real life with inverse reinforcement learning. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [34] P. Karkus, B. Ivanovic, S. Mannor, and M. Pavone. Diffstack: A differentiable and modular control stack for autonomous vehicles. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [35] M. H. Danesh, P. Cai, and D. Hsu. Leader: Learning attention over driving behaviors for planning under uncertainty. In *Proc. Conf. on Robot Learning (CoRL)*, 2022.
- [36] Z. Huang, H. Liu, J. Wu, and C. Lv. Differentiable integrated motion prediction and planning with learnable cost function for autonomous driving. *arXiv.org*, 2207.10422, 2022.
- [37] B. Wei, M. Ren, W. Zeng, M. Liang, B. Yang, and R. Urtasun. Perceive, attend, and drive: Learning spatial attention for safe self-driving. *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.
- [38] S. Hu, L. Chen, P. Wu, H. Li, J. Yan, and D. Tao. St-p3: End-to-end vision-based autonomous driving via spatial-temporal feature learning. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2022.
- [39] H. Song, W. Ding, Y. Chen, S. Shen, M. Y. Wang, and Q. Chen. Pip: Planning-informed trajectory prediction for autonomous driving. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2020.
- [40] N. Rhinehart, J. He, C. Packer, M. A. Wright, R. McAllister, J. E. Gonzalez, and S. Levine. Contingencies from observations: Tractable contingency planning with learned behavior models. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.
- [41] Y. Chen, P. Karkus, B. Ivanovic, X. Weng, and M. Pavone. Tree-structured policy planning with learned behavior models. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.

- [42] Z. Huang, H. Liu, and C. Lv. Gameformer: Game-theoretic modeling and learning of transformer-based interactive prediction and planning for autonomous driving. *arXiv.org*, 2303.05760, 2023.
- [43] L. Chen, P. Wu, K. Chitta, B. Jaeger, A. Geiger, and H. Li. End-to-end autonomous driving: Challenges and frontiers. *arXiv.org*, 2306.16927, 2023.
- [44] N. Rhinehart, R. McAllister, and S. Levine. Deep imitative models for flexible inference, planning, and control. In *Proc. of the International Conf. on Learning Representations (ICLR)*, 2020.
- [45] A. Filos, P. Tigas, R. McAllister, N. Rhinehart, S. Levine, and Y. Gal. Can autonomous vehicles identify, recover from, and adapt to distribution shifts? In *Proc. of the International Conf. on Machine learning (ICML)*, 2020.
- [46] H. Xu, Y. Gao, F. Yu, and T. Darrell. End-to-end learning of driving models from large-scale video datasets. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, pages 3530–3538, 2017.
- [47] D. Chen, B. Zhou, V. Koltun, and P. Krähenbühl. Learning by cheating. In *Proc. Conf. on Robot Learning (CoRL)*, 2019.
- [48] E. Ohn-Bar, A. Prakash, A. Behl, K. Chitta, and A. Geiger. Learning situational driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [49] A. Behl, K. Chitta, A. Prakash, E. Ohn-Bar, and A. Geiger. Label efficient visual abstractions for autonomous driving. In *Proc. IEEE International Conf. on Intelligent Robots and Systems (IROS)*, 2020.
- [50] P. Wu, X. Jia, L. Chen, J. Yan, H. Li, and Y. Qiao. Trajectory-guided control prediction for end-to-end autonomous driving: A simple yet strong baseline. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [51] D. Chen and P. Krähenbühl. Learning from all vehicles. In *CVPR*, 2022.
- [52] B. Jaeger, K. Chitta, and A. Geiger. Hidden biases of end-to-end driving models. *Proc. of the IEEE International Conf. on Computer Vision (ICCV)*, 2023.
- [53] N. Hanselmann, K. Renz, K. Chitta, A. Bhattacharyya, and A. Geiger. King: Generating safety-critical driving scenarios for robust imitation via kinematics gradients. In *Proc. of the European Conf. on Computer Vision (ECCV)*, 2022.
- [54] M. Vitelli, Y. Chang, Y. Ye, A. Ferreira, M. Wołczyk, B. Osiński, M. Niendorf, H. Grimmer, Q. Huang, A. Jain, et al. Safetynet: Safe planning for real-world self-driving vehicles using machine-learned policies. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2022.
- [55] S. Pini, C. S. Perone, A. Ahuja, A. S. R. Ferreira, M. Niendorf, and S. Zagoruyko. Safe real-world autonomous driving by learning to predict and plan with a mixture of experts. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [56] J. Cheng, Y. Chen, X. Mei, B. Yang, B. Li, and M. Liu. Rethinking imitation-based planner for autonomous driving. *arXiv.org*, 2309.10443, 2023.
- [57] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.

- [58] J.-T. Zhai, Z. Feng, J. Du, Y. Mao, J.-J. Liu, Z. Tan, Y. Zhang, X. Ye, and J. Wang. Rethinking the open-loop evaluation of end-to-end autonomous driving in nuscen. *arXiv.org*, 2305.10430, 2023.
- [59] M. Althoff, M. Koschi, and S. Manzing. Commonroad: Composable benchmarks for motion planning on roads. In *Proc. IEEE Intelligent Vehicles Symposium (IV)*, 2017.
- [60] L. Bergamini, Y. Ye, O. Scheel, L. Chen, C. Hu, L. D. Pero, B. Osinski, H. Grimmer, and P. Ondruska. Simnet: Learning reactive self-driving simulations from real-world observations. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2021.
- [61] S. Suo, S. Regalado, S. Casas, and R. Urtasun. Trafficsim: Learning to simulate realistic multi-agent behaviors. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [62] Z. Zhong, D. Rempe, D. Xu, Y. Chen, S. Veer, T. Che, B. Ray, and M. Pavone. Guided conditional diffusion for controllable traffic simulation. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [63] D. Xu, Y. Chen, B. Ivanovic, and M. Pavone. Bits: Bi-level imitation for traffic simulation. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [64] Z. Zhang, A. Liniger, D. Dai, F. Yu, and L. Van Gool. TrafficBots: Towards world models for autonomous driving simulation and motion prediction. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [65] L. Feng, Q. Li, Z. Peng, S. Tan, and B. Zhou. Trafficgen: Learning to generate diverse and realistic traffic scenarios. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [66] S. Ross, G. J. Gordon, and D. Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Conference on Artificial Intelligence and Statistics (AISTATS)*, 2011.
- [67] A. Prakash, A. Behl, E. Ohn-Bar, K. Chitta, and A. Geiger. Exploring data aggregation in policy learning for vision-based urban autonomous driving. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [68] S. Poddar, C. Mavrogiannis, and S. S. Srinivasa. From crowd motion prediction to robot navigation in crowds. *arXiv preprint arXiv:2303.01424*, 2023.
- [69] C. Schöller, V. Aravantinos, F. Lay, and A. Knoll. What the constant velocity model can teach us about pedestrian motion prediction. *IEEE Robotics and Automation Letters*, 5(2):1696–1703, 2020.
- [70] H. Wu, T. Phong, C. Yu, P. Cai, S. Zheng, and D. Hsu. What truly matters in trajectory prediction for autonomous driving? *arXiv preprint arXiv:2306.15136*, 2023.
- [71] Y. Tassa, N. Mansard, and E. Todorov. Control-limited differential dynamic programming. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2014.
- [72] R. Rajamani. *Vehicle dynamics and control*. Springer Science & Business Media, 2011.
- [73] P. Polack, F. Althé, B. d’Andréa Novel, and A. de La Fortelle. The kinematic bicycle model: A consistent model for planning feasible trajectories for autonomous vehicles? In *Proc. IEEE Intelligent Vehicles Symposium (IV)*, 2017.

- [74] N. Deo, E. M. Wolff, and O. Beijbom. Multimodal Trajectory Prediction Conditioned on Lane-Graph Traversals. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.
- [75] N. Nayakanti, R. Al-Rfou, A. Zhou, K. Goel, K. S. Refaat, and B. Sapp. Wayformer: Motion forecasting via simple and efficient attention networks. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [76] A. Cui, S. Casas, K. Wong, S. Suo, and R. Urtasun. Gorela: Go relative for viewpoint-invariant motion forecasting. In *Proc. IEEE International Conf. on Robotics and Automation (ICRA)*, 2023.
- [77] Y. Hu, K. Li, P. Liang, J. Qian, Z. Yang, H. Zhang, W. Shao, Z. Ding, W. Xu, and Q. Liu. Imitation with spatial-temporal heatmap: 2nd place solution for nuplan challenge. *arXiv.org*, 2306.15700, 2023.
- [78] W. Xi, L. Shi, and G. Cao. An imitation learning method with data augmentation and post processing for planning in autonomous driving. URL https://opendrivelab.com/e2ead/AD23Challenge/Track_4_pegasus_weitao.pdf.
- [79] Z. Huang, H. Liu, X. Mo, and C. Lyu. Gameformer planner: A learning-enabled interactive prediction and planning framework for autonomous vehicles. URL https://opendrivelab.com/e2ead/AD23Challenge/Track_4_AID.pdf.
- [80] C. R. Qi, Y. Zhou, M. Najibi, P. Sun, K. Vo, B. Deng, and D. Anguelov. Offboard 3d object detection from point cloud sequences. In *Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [81] O. Scheel, L. Bergamini, M. Wolczyk, B. Osinski, and P. Ondruska. Urban driver: Learning to drive from real-world demonstrations using policy gradients. In *Proc. Conf. on Robot Learning (CoRL)*, 2021.