

# 离线强化学习中用于精确能量引导 扩散采样的对比能量预测

Cheng Lu<sup>\*1</sup> Huayu Chen<sup>\*1</sup> Jianfei Chen<sup>1</sup> Hang Su<sup>1</sup> Chongxuan Li<sup>2</sup> Jun Zhu<sup>1,3</sup>

## 摘要

引导采样是在真实世界任务中应用扩散模型的重要方法,它在采样过程中嵌入人类定义的引导。本文考虑引导由(未归一化)能量函数定义的一般设定。该设定的主要挑战是:扩散采样过程中的中间引导由采样分布与能量函数共同定义,未知且难以估计。为此,本文提出中间引导的精确公式化,以及名为对比能量预测(Contrastive Energy Prediction, CEP)的新训练目标,以学习精确引导。在无限模型容量与数据样本下,本文方法保证收敛到精确引导,而先前方法无法做到。本文将应用于离线强化学习(RL)验证有效性。D4RL 基准上的大量实验表明本文方法优于现有 SOTA 算法。本文还提供将 CEP 应用于图像合成的示例,以展示 CEP 在高维数据上的可扩展性。代码见 <https://github.com/thu-ml/CEP-energy-guided-diffusion>。

## 1. 引言

扩散模型(Sohl-Dickstein et al., 2015; Ho et al., 2020; Song et al., 2021b; Karras et al., 2022)取得了令人瞩目的成功。在真实世界任务中应用扩散模型的关键在于将人类可控性嵌入采样过程。在扩散模型中引入人类偏好的常见范式是引导采样,包括分类器引导(Dhariwal & Nichol, 2021)、无分类器引导(Ho & Salimans, 2021)以及其他引导方法(Nichol et al., 2021; Ho et al., 2022c; Zhao et al., 2022)。借助引导采样,扩散模型可以实现出色的文生图生成(Saharia et al., 2022b)、视频生成(Ho et al., 2022c;a; Yang et al., 2022; Zhou et al., 2022)、可控文本生成(Li et al., 2022)、逆向分子设计(Bao et al., 2022b)以及强化学习(Janner et al., 2022; Chen et al., 2022; Ajay et al., 2022)。

<sup>\*</sup> 同等贡献 <sup>1</sup> 清华大学计算机科学与技术系、AI 研究院、BNRist 中心、清华-博世联合机器学习中心、THBI 实验室 <sup>2</sup> 中国人民大学高瓴人工智能学院; 大数据管理与分析方法北京市重点实验室, 北京, 中国 <sup>3</sup> 琶洲实验室(黄埔), 广州, 中国. 通讯作者: Jun Zhu <dcszj@tsinghua.edu.cn>.

分类器引导与无分类器引导都处理条件采样问题,即训练过程中存在带额外条件变量的成对数据(Dhariwal & Nichol, 2021; Graikos et al., 2022; Rombach et al., 2022)。然而,有时难以通过条件变量描述人类偏好,本文只能通过标量函数嵌入偏好。此类函数的例子包括:强化学习中的奖励函数或预训练 Q 函数(Janner et al., 2022; Chen et al., 2022)、对话系统中的人类反馈(Ziegler et al., 2019)、图像合成中样本特征与指定特征的余弦相似度(Kwon & Ye, 2022),或视频合成中采样帧与上一帧之间的  $L_2$  距离(Ho et al., 2022c)。在这些情况下,本文希望利用人类偏好来操纵期望分布,并通过带额外引导的扩散采样抽取样本,而由于没有提供实际条件,难以直接使用分类器引导或无分类器引导。

本文考虑一个涵盖上述所有情形的一般形式。设  $q(\mathbf{x})$  是  $\mathcal{X} \subseteq \mathbb{R}^d$  上的未知数据分布。本文的目标是从以下分布中采样:

$$p(\mathbf{x}) \propto q(\mathbf{x})e^{-\beta\mathcal{E}(\mathbf{x})}, \quad (1)$$

其中  $\mathcal{E}(\cdot)$  是从  $\mathcal{X} \in \mathbb{R}^d$  到  $\mathbb{R}$  的能量函数,且本文可以计算每个数据点的  $\mathcal{E}(\mathbf{x})$ 。 $\beta \geq 0$  是用于控制能量强度的逆温度。 $p(\mathbf{x})$  的高密度区域近似为  $q(\mathbf{x})$  与  $e^{-\beta\mathcal{E}(\mathbf{x})}$  两者高密度区域的交集。因此,本文可以通过将期望性质嵌入能量函数  $\mathcal{E}(\cdot)$  来引入可控性。能量函数  $\mathcal{E}(\cdot)$  的选择非常灵活:本文只需保证  $q(\mathbf{x})e^{-\beta\mathcal{E}(\mathbf{x})}$  在  $\mathbf{x} \in \mathcal{X}$  上的积分有限。本文还可以通过能量函数  $\mathcal{E}(\cdot, c)$  引入额外的条件变量  $c$ 。特别地,令  $\beta = 1$  且  $\mathcal{E}(\mathbf{x}, c) = -\log q(c|\mathbf{x})$ , 目标分布  $p(\mathbf{x})$  就变为条件分布  $q(\mathbf{x}|c)$ , 从而将经典条件采样问题作为特例恢复。

由于  $p(\mathbf{x})$  未归一化,从  $p(\mathbf{x})$  采样通常是困难的。现有工作(Janner et al., 2022; Zhao et al., 2022; Ho et al., 2022c; Chung et al., 2022; Kavar et al., 2022)利用预训练扩散模型  $q_g(\mathbf{x}) \approx q(\mathbf{x})$ , 并应用带有与  $\mathcal{E}(\cdot)$  相关的额外引导项的扩散采样,该引导项称为能量引导。然而,此前提出的所有能量引导要么在扩散过程中被手动或任意定义,而且最终样本是否服从期望分布  $p(\mathbf{x})$  也未经研究。事实上,本文表明以往的能量引导采样器都是不精确的,即它们无法保证收敛到  $p(\mathbf{x})$ 。据本文所知,如何利用预训练扩散模型  $q_g(\mathbf{x})$  从精确的  $p(\mathbf{x})$  中抽取样本在很大程度上仍是开放问题。

本文分析并推导了从 Eq. (1) 中的  $p(\mathbf{x})$  进行扩散采样所需引导的精确形式。与以往工作不同,本文表明采样

过程中扩散数据空间内的精确引导完全由原始数据空间中的能量函数  $\mathcal{E}(\cdot)$  决定。精确能量引导具有难以处理的形式, 无法直接计算, 因此本文提出一种名为对比能量预测 (CEP) 的新训练方法, 利用来自  $q(\mathbf{x})$  的样本作为训练数据来估计该引导。CEP 通过在一组噪声扰动的数据样本内比较能量  $\mathcal{E}(\cdot)$ , 并使用其软能量标签作为监督信号来训练引导模型。本文从理论上证明, 最优学习模型的梯度正是所需的能量引导, 因此最终样本保证服从  $p(\mathbf{x})$ 。在  $\mathcal{E}(\cdot)$  对应于经典条件采样情形的一种特殊形式下, 本文进一步表明 CEP 可理解为分类器引导方法的一种替代性对比方法。

为了验证 CEP 的有效性与其可扩展性, 本文选取 Eq. (1) 的两个重要应用: 离线强化学习 (RL) 与图像合成。对于离线 RL, 本文将经典的约束策略优化问题 (Peters et al., 2010; Peng et al., 2019) 形式化为 Q 引导策略优化, 并在主流 D4RL (Fu et al., 2020) 基准上评估本文方法。大量实验表明, 在大多数任务中本文方法优于现有 SOTA 算法, 尤其是在 AntMaze 等困难任务中。对于图像合成, 本文在 ImageNet 上从定量与定性两方面将 CEP 与经典分类器引导 (Dhariwal & Nichol, 2021) 进行条件样本质量对比, 发现两种方法性能几乎相当。本文还提供了能量引导图像合成的示例, 以影响采样图像的颜色外观, 从而验证 CEP 的灵活性。

## 2. 背景

本文首先介绍扩散模型的基础知识, 以及作为从分布 (1) 采样的重要动机与应用的离线 RL。

### 2.1. 扩散 (概率) 模型

扩散 (概率) 模型 (Sohl-Dickstein et al., 2015; Ho et al., 2020; Song et al., 2021b) 是强大的生成模型。给定数据集  $\{\mathbf{x}_0^{(i)}\}_{i=1}^N$ , 其中包含来自未知数据分布  $q_0(\mathbf{x}_0)$  的  $D$  维随机变量  $\mathbf{x}_0$  的  $N$  个样本, 扩散模型在时间 0 到  $T > 0$  的过程中逐步向  $\mathbf{x}_0$  添加高斯噪声直至  $\mathbf{x}_T$ 。转移分布  $q_{t0}(\mathbf{x}_t|\mathbf{x}_0)$  满足

$$q_{t0}(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t|\alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I}), \quad (2)$$

其中  $\alpha_t, \sigma_t > 0$ 。记  $q_t(\mathbf{x}_t)$  为  $\mathbf{x}_t$  在时间  $t$  的边缘分布。在时间  $T$ , 转移分布满足  $q_T(\mathbf{x}_T|\mathbf{x}_0) \approx q_T(\mathbf{x}_T) \approx \mathcal{N}(\mathbf{x}_T|0, \bar{\sigma}^2\mathbf{I})$ , 其中  $\bar{\sigma} > 0$  且与  $\mathbf{x}_0$  无关。因此, 扩散模型从  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{x}_T|0, \bar{\sigma}^2\mathbf{I})$  出发, 通过求解从  $T$  到 0 的反向过程来恢复原始数据  $\mathbf{x}_0$ 。反向过程也可以是扩散 ODE (Song et al., 2021b):

$$\frac{d\mathbf{x}_t}{dt} = f(t)\mathbf{x}_t - \frac{1}{2}g^2(t)\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t), \quad (3)$$

其中  $f(t) = \frac{d\log\alpha_t}{dt}$ ,  $g^2(t) = \frac{d\sigma_t^2}{dt} - 2\frac{d\log\alpha_t}{dt}\sigma_t^2$  (Kingma et al., 2021), 唯一未知的项是分布  $q_t$  在每个时间  $t$  的得分函数  $\nabla_{\mathbf{x}_t} \log q_t(\cdot)$ 。因此, 扩散模型训练由  $\theta$  参数化的神经网络  $\epsilon_\theta(\mathbf{x}_t, t)$  来估计缩放后的得分函数, 即  $-\sigma_t\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ , 训练目标为 (Ho et al., 2020; Song

et al., 2021b)

$$\begin{aligned} & \min_{\theta} \mathbb{E}_{t, \mathbf{x}_t} [\omega(t) \|\epsilon_\theta(\mathbf{x}_t, t) + \sigma_t \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)\|_2^2] \\ & \Leftrightarrow \min_{\theta} \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\omega(t) \|\epsilon_\theta(\mathbf{x}_t, t) - \epsilon\|_2^2] \end{aligned} \quad (4)$$

其中  $\mathbf{x}_0 \sim q_0(\mathbf{x}_0)$ 、 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 、 $t \sim \mathcal{U}([0, T])$ 、 $\mathbf{x}_t = \alpha_t\mathbf{x}_0 + \sigma_t\epsilon$ , 且  $\omega(t)$  是权重函数, 通常设为  $\omega(t) \equiv 1$  (Ho et al., 2020)。因此, 训练完扩散模型后, 通常有  $\epsilon_\theta(\mathbf{x}_t, t) \approx -\sigma_t\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$ 。用  $\epsilon_\theta$  替换得分函数后, 本文可以通过一些专用求解器 (Song et al., 2021a; Lu et al., 2022b) 求解相应的扩散 ODE, 从而快速采样  $\mathbf{x}_0$ 。

### 2.2. 离线强化学习中的约束策略优化

考虑由元组  $\langle \mathcal{S}, \mathcal{A}, P, r, \gamma \rangle$  描述的马尔可夫决策过程 (MDP)。 $\mathcal{S}$  是状态空间,  $\mathcal{A}$  是动作空间。 $P(\mathbf{s}'|\mathbf{s}, \mathbf{a})$  与  $r(\mathbf{s}, \mathbf{a})$  分别是转移函数与奖励函数。 $\gamma \in (0, 1]$  是常数折扣因子。在离线 RL 中, 给定一个静态数据集  $\mathcal{D}^\mu$ , 其中包含行为智能体  $\mu(\mathbf{a}|\mathbf{s})$  与环境之间的交互历史  $\{\mathbf{s}, \mathbf{a}, r, \mathbf{s}'\}$ 。目标是在上述 MDP 中仅利用从数据集学到的知识, 最大化模型策略  $\pi_\theta(\mathbf{a}|\mathbf{s})$  的期望累积奖励。

以往工作 (Peters et al., 2010; Peng et al., 2019) 将离线 RL 形式化为约束策略优化:

$$\max_{\pi} \mathbb{E}_{\mathbf{s} \sim \mathcal{D}^\mu} [\mathbb{E}_{\mathbf{a} \sim \pi(\cdot|\mathbf{s})} Q_\psi(\mathbf{s}, \mathbf{a}) - \frac{1}{\beta} D_{\text{KL}}(\pi(\cdot|\mathbf{s}) \|\mu(\cdot|\mathbf{s}))], \quad (5)$$

其中  $Q_\psi$  是动作评估模型, 通过估计当前策略  $\pi$  的 Q 函数  $Q^\pi(\mathbf{s}, \mathbf{a}) := \mathbb{E}_{\mathbf{s}_1=\mathbf{s}, \mathbf{a}_1=\mathbf{a}; \pi} [\sum_{n=1}^{\infty} \gamma^n r(\mathbf{s}_n, \mathbf{a}_n)]$  来指示决策  $(\mathbf{s}, \mathbf{a})$  的质量。 $\beta$  是逆温度系数。Eq. (5) 中的第一项用于执行策略优化, 第二项表示策略约束。

可以证明, (5) 中的最优策略  $\pi^*$  满足:

$$\pi^*(\mathbf{a}|\mathbf{s}) \propto \mu(\mathbf{a}|\mathbf{s}) e^{\beta Q_\psi(\mathbf{s}, \mathbf{a})}, \quad (6)$$

这属于一般分布族 (1)。因此, 从最优策略  $\pi^*$  采样可以通过预训练扩散行为模型  $\mu_g(\mathbf{a}|\mathbf{s}) \approx \mu(\mathbf{a}|\mathbf{s})$  的能量引导采样来实现, 这促使本文提出精确的能量引导采样方法。

## 3. 精确能量引导采样

为对 Eq. (1) 进行能量引导采样, 采样过程中的引导需要保证最终样本服从期望分布  $p(\mathbf{x})$ 。本节提出这种能量引导的精确形式化表述, 并提出一种新训练目标来估计该引导。所有证明见附录 D。

### 3.1. 中间能量引导的精确形式化表述

下面本文正式分析如何通过扩散模型从 Eq. (1) 中采样。

重写  $p_0 := p$  与  $q_0 := q$ 。目标分布为

$$p_0(\mathbf{x}_0) \propto q_0(\mathbf{x}_0) e^{-\beta \mathcal{E}(\mathbf{x}_0)}. \quad (7)$$




Figure 1. 扩散过程中  $q_t(\mathbf{x}_t)$ 、 $e^{-\mathcal{E}_t(\mathbf{x}_t)}$  与  $p_t(\mathbf{x}_t)$  密度函数 (未归一化) 的一个二维高斯混合示例, 其中  $p_t(\mathbf{x}_t) \propto q_t(\mathbf{x}_t)e^{-\mathcal{E}_t(\mathbf{x}_t)}$ 。

设  $q_t(\mathbf{x}_t)$  为由 Eq. (2) 定义、从  $q_0(\mathbf{x}_0)$  出发的前向扩散过程在时间  $t$  的边缘分布。假设本文拥有一个预训练扩散模型  $q_0^{\theta}(\mathbf{x}_0) \approx q_0(\mathbf{x}_0)$ , 它通过在每个时间  $t \in [0, T]$  学习由  $\theta$  参数化的噪声预测模型  $\epsilon_{\theta}(\mathbf{x}_t, t) \approx -\sigma_t \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$  获得。根据 Eq. (3), 从  $p_0$  抽取样本需要从  $p_0$  (而非  $q_0$ ) 出发的扩散过程在每个中间时间  $t$  的相应得分函数  $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 。本文的第一个关键结果揭示了从  $q_0$  与  $p_0$  出发的扩散过程中相应得分函数之间的关系, 总结如下:

**定理 3.1** (中间能量引导). 设  $q_0$  与  $p_0$  如 Eq. (7) 中所定义。对于  $t \in (0, T]$ , 令

$$p_{t0}(\mathbf{x}_t|\mathbf{x}_0) := q_{t0}(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t|\alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I}). \quad (8)$$

记  $q_t(\mathbf{x}_t) := \int q_{t0}(\mathbf{x}_t|\mathbf{x}_0)q_0(\mathbf{x}_0)d\mathbf{x}_0$  与  $p_t(\mathbf{x}_t) := \int p_{t0}(\mathbf{x}_t|\mathbf{x}_0)p_0(\mathbf{x}_0)d\mathbf{x}_0$  为时间  $t$  的边缘分布, 并定义

$$\mathcal{E}_t(\mathbf{x}_t) := \begin{cases} \beta\mathcal{E}(\mathbf{x}_0), & t = 0, \\ -\log \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[e^{-\beta\mathcal{E}(\mathbf{x}_0)}], & t > 0. \end{cases} \quad (9)$$

则  $q_t$  与  $p_t$  满足

$$p_t(\mathbf{x}_t) \propto q_t(\mathbf{x}_t)e^{-\mathcal{E}_t(\mathbf{x}_t)}, \quad (10)$$

且它们的得分函数满足

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \underbrace{\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)}_{\approx -\epsilon_{\theta}(\mathbf{x}_t, t)/\sigma_t} - \underbrace{\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)}_{\text{energy guidance (intractable)}}. \quad (11)$$

Theorem 3.2 揭示了此前未注意到的中间分布  $p_t$  的精确形式: 尽管对所有  $t > 0$ ,  $p_t$  都被定义为难以处理的边缘分布, 但它们仍可写成与 Eq. (7) 相同的形式, 正比于 (扩散后的) 数据分布  $q_t$  与指数能量项  $e^{-\mathcal{E}_t(\mathbf{x}_t)}$  的乘积。由于该能量在扩散过程中定义, 本文将  $\mathcal{E}_t(\cdot)$  称为中间能量。根据 Eq. (9), 中间能量完全由时间 0 处的能量函数  $\mathcal{E}(\mathbf{x}_0)$  决定。Figure 1 给出了一个示例, 从中本文得出几点观察: (1)  $p_t(\mathbf{x}_t)$  偏好同时具有高数据密度  $q_t(\mathbf{x}_t)$  与高能量密度  $e^{-\mathcal{E}_t(\mathbf{x}_t)}$  的区域; (2) 经过前向扩散过程,  $p_t$  与  $q_t$  都逐渐变为标准高斯分布, 这保证本

文可以从相同的噪声分布  $p_T \approx q_T \approx \mathcal{N}(0, \sigma^2\mathbf{I})$  出发反向运行扩散过程; (3) 随着  $t$  增大, 能量函数  $\mathcal{E}_0(\mathbf{x}_0)$  也被“扩散”为中间能量函数  $\mathcal{E}_t(\mathbf{x}_t)$ 。特别地,  $\mathcal{E}_T(\mathbf{x}_T)$  几乎等于常数函数, 因此  $\nabla_{\mathbf{x}_T} \mathcal{E}_T(\mathbf{x}_T) \approx 0$ 。

Eq. (11) 中的结果直接定义了一种从  $p_0(\mathbf{x}_0)$  进行引导采样的原理性方法。也就是说, 只要同时知道  $\nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t)$  与  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$ , 就可以用 Eq. (3) 进行采样。前者已由预训练扩散模型  $\epsilon_{\theta}$  给出。剩下的问题是估计后一个得分  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$ , 本文称之为中间能量引导。由于 Eq. (9) 中的对数期望形式以及  $\mathcal{E}(\mathbf{x}_0)$  可能具有复杂形式, 对  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$  的无偏估计通常并不平凡。据本文所知, 估计精确的中间能量引导仍是一个开放问题。本文提出一种基于学习的新方法作为初步尝试, 通过比较来自  $q_t$  的样本能量来学习能量引导, 详见下文。

### 3.2. 通过对比能量预测学习能量引导

设  $K > 1$  为正整数。令  $\mathbf{x}_0^{(1)}, \dots, \mathbf{x}_0^{(K)}$  为来自  $q_0(\mathbf{x}_0)$  的  $K$  个 i.i.d. 样本,  $\epsilon^{(1)}, \dots, \epsilon^{(K)}$  为服从  $p(\epsilon) = \mathcal{N}(\epsilon|\mathbf{0}, \mathbf{I})$  的  $K$  个 i.i.d. 高斯样本。令  $t \sim \mathcal{U}(0, T)$  为随机采样的时间步。对每个  $i = 1, \dots, K$ , 令  $\mathbf{x}_t^{(i)} := \alpha_t \mathbf{x}_0^{(i)} + \sigma_t \epsilon^{(i)}$ , 其中  $\alpha_t, \sigma_t$  在 Eq. (8) 中定义。假设中间能量  $\mathcal{E}_t(\cdot)$  由参数为  $\phi$  的网络  $f_{\phi}(\cdot, t) : \mathbb{R}^d \rightarrow \mathbb{R}$  逼近。本文提出求解如下问题来学习  $f_{\phi}$ , 其解的性质在 Theorem 3.2 中刻画:

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ \underbrace{-\sum_{i=1}^K e^{-\beta\mathcal{E}(\mathbf{x}_0^{(i)})}}_{\text{soft energy label}} \log \underbrace{\frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}}}_{\text{predicted label}} \right]. \quad (12)$$

**定理 3.2.** 在无限模型容量与数据样本下, 对所有  $K > 1$  与  $t \in [0, T]$ , 问题 (12) 中的最优  $f_{\phi^*}$  满足  $\nabla_{\mathbf{x}_t} f_{\phi^*}(\mathbf{x}_t, t) = \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$ 。

根据 Theorem 3.2, 本文确实可以通过求解问题 (12) 来训练能量引导模型  $f_{\phi}$ , 并通过估计 Eq. (11) 中的能量引导来使用  $f_{\phi}$  的梯度进行引导采样。下面给出 Theorem 3.2 的直观解释。为估计能量引导  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\cdot)$ , 只需保证  $f_{\phi}$  是  $\mathcal{E}_t(\cdot)$  的相对比例值, 因此在  $K$  个样本内对  $f_{\phi}$  做相对比较即可, 而无须用绝对值直接训练  $f_{\phi}$ 。基于这一观察, 本文在问题 (12) 中采用交叉熵损失, 其中  $K$  个干净样本  $\mathbf{x}_0^{(i)}$  的能量  $\mathcal{E}(\mathbf{x}_0^{(i)})$  是软监督标签,  $K$  个噪声样本  $\mathbf{x}_t^{(i)}$  的能量预测  $f_{\phi}(\mathbf{x}_t^{(i)}, t)$  的 softmax 是预测标签。由于该目标具有对比性, 本文将 Eq. (12) 中提出的方法命名为对比能量预测 (CEP)。

尽管问题 (12) 中的最优解是精确的, 但由于指数项  $e^{-\beta\mathcal{E}(\mathbf{x}_0^{(i)})}$  未归一化, 训练过程中有时会遭遇数值问题。例如, 假设  $\mathcal{E}(\mathbf{x}_0)$  是可能在某个数据点处含有“尖峰”的复杂函数, 指数项会在训练中大幅放大此类不稳定



性。为应对该问题, 本文进一步对  $K$  个样本上的能量函数做归一化, 使用自归一化能量标签, 并将优化问题定义为:

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K \underbrace{\frac{e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)})}}{\sum_{j=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(j)})}}}_{\text{self-normalized energy label}} \log \underbrace{\frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}}}_{\text{predicted label}} \right]. \quad (13)$$

这样的自归一化目标可以确保软能量标签位于  $[0, 1]$  内, 且各项之和恰好为 1。虽然该目标相对于问题 (12) 中的原始目标可能存在偏差, 但本文的经验表明它能大幅提升数值稳定性, 有助于获得良好的收敛结果。此外, 可以通过增大  $K$  来减小目标中的偏差。当  $K \rightarrow \infty$  时, (13) 中的目标与 (12) 中的目标等价, 因为  $\sum_{\mathbf{x}_0} e^{-\beta \mathcal{E}(\mathbf{x}_0)} = \mathbb{E}_{q_0(\mathbf{x}_0)}[e^{-\beta \mathcal{E}(\mathbf{x}_0)}]$  是  $p_0$  的归一化常数。因此, 在计算与内存预算允许时, 实践中更偏好较大的  $K$ 。

#### 4. 与以往引导采样方法的比较

下面本文将 CEP 与以往的引导采样方法进行比较。本文表明, 所有以往的能量引导采样器都是不精确的; 并且对于能量函数的一种特例 (对应于条件采样问题), CEP 是分类器引导的一种对比替代方法。

##### 4.1. 以往能量引导采样器均不精确

本节表明, 针对 Eq. (7) 的以往能量引导采样器都是不精确的, 不能保证收敛到  $p_0$ 。不失一般性, 本文聚焦于固定时间  $t \in (0, T]$ 。Table 1 总结了相关关系。

**用于能量预测的 MSE。** 许多现有能量引导方法 (Jan-ner et al., 2022; Bao et al., 2022b) 使用均方误差 (MSE) 目标来训练能量模型  $f_{\phi}(\mathbf{x}_t, t)$ , 并使用其梯度作为能量引导。训练目标为:

$$\min_{\phi} \mathbb{E}_{q_{0t}(\mathbf{x}_0, \mathbf{x}_t)} [\|f_{\phi}(\mathbf{x}_t, t) - \mathcal{E}_0(\mathbf{x}_0)\|_2^2] \quad (14)$$

在无限模型容量下, 最优  $f_{\phi}$  满足:

$$f_{\phi}^{\text{MSE}}(\mathbf{x}_t, t) = \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0)]$$

然而, 根据 Eq. (9), 真实能量函数满足

$$\begin{aligned} \mathcal{E}_t(\mathbf{x}_t) &= -\log \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [e^{-\mathcal{E}_0(\mathbf{x}_0)}] \\ &\geq \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0)] = f_{\phi}^{\text{MSE}}(\mathbf{x}_t, t), \end{aligned}$$

且等号仅在  $t = 0$  时成立。因此, MSE 能量函数  $f_{\phi}^{\text{MSE}}$  对所有  $t > 0$  都是不精确的。此外, 本文在附录 E 中证明,  $f_{\phi}^{\text{MSE}}$  的梯度相对于真实引导  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$  也是不精确的。




Figure 2. 一个比较不同能量引导采样算法的二维示例, 变化不同的逆温度  $\beta$ 。

**扩散后验采样。** 还存在一些免训练的能量引导采样算法, 例如重建引导 (Ho et al., 2022c) 与扩散后验采样 (Chung et al., 2022)。这些方法的基本思想是在数据预测形式 (Kingma et al., 2021) 中复用预训练扩散模型:

$$\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0] \approx \hat{\mathbf{x}}_{\theta}(\mathbf{x}_t, t) := \frac{\mathbf{x}_t - \sigma_t \epsilon_{\theta}(\mathbf{x}_t, t)}{\alpha_t},$$

然后按如下方式定义中间能量函数:

$$f_{\theta}^{\text{DPS}}(\mathbf{x}_t, t) := \mathcal{E}_0(\hat{\mathbf{x}}_{\theta}(\mathbf{x}_t, t)) \approx \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]).$$

然而, 本文在附录 E 中证明  $\nabla_{\mathbf{x}_t} f_{\theta}^{\text{DPS}} \neq \nabla_{\mathbf{x}_t} \mathcal{E}_t$ , 因此它也是不精确的。

**二维示例。** 本文进一步在二维示例上比较不同的能量引导采样方法, 如图 2 所示, 并在附录 L 中提供更多二维结果。实验表明, 本文方法优于所有提及的方法, 尤其在逆温度  $\beta$  较大时。

Table 1. 能量引导采样算法之间的比较。

| 方法       | 能量最优解                                                                                     | 精确引导 |
|----------|-------------------------------------------------------------------------------------------|------|
| CEP (本文) | $-\log \mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [e^{-\mathcal{E}_0(\mathbf{x}_0)}]$ | ✓    |
| MSE      | $\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0)]$            | ✗    |
| DPS      | $\mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)}[\mathbf{x}_0])$             | ✗    |

#### 4.2. 与对比学习及分类器引导的关系

本节考虑本文方法的一种特殊情形，其中能量函数  $\mathcal{E}_0(\mathbf{x}_0)$  针对给定条件变量  $c$  定义为负对数似然  $-\log q_0(c|\mathbf{x}_0)$ ，且  $\beta = 1$ 。此时，期望分布为：

$$p_0(\mathbf{x}_0) \propto q_0(\mathbf{x}_0)q(c|\mathbf{x}_0) \propto q(\mathbf{x}_0|c).$$

与 Eq. (7) 中所考虑的问题 ( $p_0(\mathbf{x}_0)$  难以采样) 不同，这里本文假设可以从  $p_0(\mathbf{x}_0) = q_0(\mathbf{x}_0|c)$  中采样。在此假设下，本文在附录 F 中证明，本文提出的 CEP (见 Eq. (12)) 等价于

$$\mathbb{E}_{t, \epsilon^{(1:K)}} \mathbb{E}_{\prod_{i=1}^K q_0(\mathbf{x}_0^{(i)}, c^{(i)})} \left[ -\sum_{i=1}^K \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(j)}, t)}} \right], \quad (15)$$

其中  $(\mathbf{x}_0^{(i)}, c^{(i)})$  是来自  $q_0(\mathbf{x}_0, c)$  的  $K$  个成对数据样本。注意内部期望与 InfoNCE 目标 (Oord et al., 2018) 形式相同，广泛用于多模态数据的对比学习，例如 CLIP (Radford et al., 2021) (其中  $f_\phi$  表示余弦相似度)。此外，Nichol et al. (2021) 使用上述目标，在每个  $t$  为文本-图像对训练一个 CLIP，并将其梯度作为扩散模型文生图采样的引导。因此，在可以从  $p_0(\mathbf{x}_0) = q_0(\mathbf{x}_0|c)$  采样的假设下，这种引导可视为 Eq. (12) 中 CEP 的一种特例。

此外，若  $c$  是共有  $M$  个可能取值 (类别) 的离散变量，则从  $q_0(\mathbf{x}_0|c)$  采样的另一种引导采样方法是分类器引导 (Dhariwal & Nichol, 2021)，它优化如下目标：

$$\mathbb{E}_{t, \epsilon^{(1:K)}} \mathbb{E}_{\prod_{i=1}^K q_0(\mathbf{x}_0^{(i)}, c^{(i)})} \left[ -\sum_{i=1}^K \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^M e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(j)}, t)}} \right], \quad (16)$$

Eq. (15) 与 Eq. (16) 之间最显著的区别在于训练目标分母中的归一化轴。分类器引导旨在对给定数据  $\mathbf{x}_t^{(i)}$  分类条件，因此该目标可理解为在所有  $c^{(j)}$  上归一化的分类损失。CEP 试图对指定条件  $c^{(i)}$  在数据内比较，因此该目标可理解为在所有  $\mathbf{x}_t^{(j)}$  上归一化的对比损失。

理论上，给定无限数据与模型容量，分类器引导与 CEP 都能保证精确引导。实验上，本文在第 6 节中表明两种方法性能相当接近。然而，传统分类器引导无法应用于能量引导采样，因为不存在一组可归一化的条件  $c$ ，而本文提出的方法可以。因此，本文认为 CEP 可视为条件采样中分类器引导的一种对比替代方法，但其形式更一般，可以推广到能量引导采样问题。

## 5. 离线强化学习的 Q 引导策略优化

本节展示本文方法如何应用于离线 RL，包括 Section 5.1 中的问题形式化、Section 5.2 与 Section 5.3 中的算法方法，以及 Section 5.4 中的实验结果。Appendix I.1 提供了伪代码。

### 5.1. 问题形式化

回顾 Eq. (6)，本文期望的策略  $\pi^*$  满足  $\pi^*(\mathbf{a}|\mathbf{s}) \propto \mu(\mathbf{a}|\mathbf{s}) e^{\beta Q_\psi(\mathbf{s}, \mathbf{a})}$ ，其中行为策略  $\mu(\mathbf{a}|\mathbf{s})$  是扩散模型。为了通过扩散采样从  $\pi^*$  中采样动作，本文在时间  $t = 0$  记  $\mu_0 := \mu$ 、 $\pi_0 := \pi$ 、 $\mathbf{a}_0 := \mathbf{a}$ 。然后本文构造一个前向扩散过程，将  $\mu_0$  与  $\pi_0$  同时扩散到相同的噪声分布，其中  $\pi_{t0}(\mathbf{a}_t|\mathbf{a}_0, \mathbf{s}) := \mu_{t0}(\mathbf{a}_t|\mathbf{a}_0, \mathbf{s}) = \mathcal{N}(\mathbf{a}_t|\alpha_t \mathbf{a}_0, \sigma_t^2 \mathbf{I})$ 。

根据 Theorem 3.1，遵循离线 RL 文献中的惯例，将分布  $q$  替换为  $\mu$ 、 $p$  替换为  $\pi$ 、能量函数  $\mathcal{E}$  替换为  $-Q$ ，则噪声扰动动作  $\mathbf{a}_t$  的边缘分布  $\mu_t$  与  $\pi_t$  满足：

$$\pi_t(\mathbf{a}_t|\mathbf{s}) \propto \mu_t(\mathbf{a}_t|\mathbf{s}) e^{\mathcal{E}_t(\mathbf{s}, \mathbf{a}_t)}. \quad (17)$$

$\mathcal{E}_t(\mathbf{s}, \mathbf{a}_t)$  是由学习到的动作评估模型  $Q_\psi(\mathbf{s}, \mathbf{a}_0)$  决定的中间能量函数。具体地， $\mathcal{E}_t(\mathbf{s}, \mathbf{a}_t) = \log \mathbb{E}_{\mu_{0t}(\mathbf{a}_0|\mathbf{a}_t, \mathbf{s})} [e^{\beta Q_\psi(\mathbf{s}, \mathbf{a}_0)}]$ ，且  $\mathcal{E}_0(\mathbf{s}, \mathbf{a}_0) = \beta Q_\psi(\mathbf{s}, \mathbf{a}_0)$ 。

本文现在考虑如何估计  $\pi_t(\mathbf{a}|\mathbf{s})$  的得分函数，从而可以按照 Eq. (3) 从  $\pi_0$  采样动作。由 Eq. (17)，可得：

$$\nabla_{\mathbf{a}_t} \log \pi_t(\mathbf{a}_t|\mathbf{s}) = \underbrace{\nabla_{\mathbf{a}_t} \log \mu_t(\mathbf{a}_t|\mathbf{s})}_{\approx -\epsilon_\theta(\mathbf{a}_t|\mathbf{s}, t)/\sigma_t} + \underbrace{\nabla_{\mathbf{a}_t} \mathcal{E}_t(\mathbf{s}, \mathbf{a}_t)}_{\approx f_\phi(\mathbf{s}, \mathbf{a}_t, t)}. \quad (18)$$

至此，本文已将经典约束策略优化问题 (5) 形式化为能量引导采样，其中  $\nabla_{\mathbf{a}_t} \mathcal{E}_t(\mathbf{s}, \mathbf{a}_t)$  是所需的引导。由于该引导由 Q 函数决定，本文将这种方法命名为 Q 引导策略优化 (QGPO)。QGPO 需要训练三个神经网络以估计目标得分函数  $\nabla_{\mathbf{a}_t} \log \pi_t(\mathbf{a}_t|\mathbf{s})$ ：(1) 用于建模行为策略  $\mu(\mathbf{a}|\mathbf{s})$  的状态条件扩散模型  $\epsilon_\theta(\mathbf{a}_t|\mathbf{s}, t)$ ，对此本文完全遵循 Chen et al. (2022)；(2) 用于在  $t = 0$  时定义中间能量函数  $\mathcal{E}_t$  的动作评估模型  $Q_\psi(\mathbf{s}, \mathbf{a})$  (Section 5.3)；(3) 用于在  $t > 0$  时估计  $\mathcal{E}_t(\mathbf{s}, \mathbf{a}_t, t)$  并引导扩散采样过程的能量模型  $f_\phi(\mathbf{s}, \mathbf{a}_t, t)$  (Section 5.2)。

### 5.2. 支持集内对比能量预测

假设本文已经有一个用于估计 Q 函数  $Q^\pi(\mathbf{s}, \mathbf{a})$  的动作评估模型  $Q_\psi(\mathbf{s}, \mathbf{a})$ 。根据 Theorem 3.2， $f_\phi(\mathbf{s}, \mathbf{a}_t, t)$  可以通过本文提出的 CEP 来训练。将 Eq. (12) 重写为在所有分布上以状态  $\mathbf{s}$  为条件，学习  $f_\phi$  的问题变为：

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{\mu(\mathbf{s})} \mathbb{E}_{\prod_{i=1}^K \mu(\mathbf{a}^{(i)}|\mathbf{s}) p(\epsilon^{(i)})} \left[ -\sum_{i=1}^K \frac{e^{\beta Q_\psi(\mathbf{s}, \mathbf{a}^{(i)})}}{\sum_{j=1}^K e^{\beta Q_\psi(\mathbf{s}, \mathbf{a}^{(j)})}} \log \frac{e^{f_\phi(\mathbf{s}, \mathbf{a}_t^{(i)}, t)}}{\sum_{j=1}^K e^{f_\phi(\mathbf{s}, \mathbf{a}_t^{(j)}, t)}} \right], \quad (19)$$

| 数据集           | 环境             | CQL   | BCQ   | IQL   | SfBC  | DD    | Diffuser | D-QL  | D-QL@1 | QGPO (本文)   |
|---------------|----------------|-------|-------|-------|-------|-------|----------|-------|--------|-------------|
| Medium-Expert | HalfCheetah    | 62.4  | 64.7  | 86.7  | 92.6  | 90.6  | 79.8     | 96.1  | 94.8   | 93.5 ± 0.3  |
| Medium-Expert | Hopper         | 98.7  | 100.9 | 91.5  | 108.6 | 111.8 | 107.2    | 110.7 | 100.6  | 108.0 ± 2.5 |
| Medium-Expert | Walker2d       | 111.0 | 57.5  | 109.6 | 109.8 | 108.8 | 108.4    | 109.7 | 108.9  | 110.7 ± 0.6 |
| Medium        | HalfCheetah    | 44.4  | 40.7  | 47.4  | 45.9  | 49.1  | 44.2     | 50.6  | 47.8   | 54.1 ± 0.4  |
| Medium        | Hopper         | 58.0  | 54.5  | 66.3  | 57.1  | 79.3  | 58.5     | 82.4  | 64.1   | 98.0 ± 2.6  |
| Medium        | Walker2        | 79.2  | 53.1  | 78.3  | 77.9  | 82.5  | 79.7     | 85.1  | 82.0   | 86.0 ± 0.7  |
| Medium-Replay | HalfCheetah    | 46.2  | 38.2  | 44.2  | 37.1  | 39.3  | 42.2     | 47.5  | 44.0   | 47.6 ± 1.4  |
| Medium-Replay | Hopper         | 48.6  | 33.1  | 94.7  | 86.2  | 100.0 | 96.8     | 100.7 | 63.1   | 96.9 ± 2.6  |
| Medium-Replay | Walker2d       | 26.7  | 15.0  | 73.9  | 65.1  | 75.0  | 61.2     | 94.3  | 75.4   | 84.4 ± 4.1  |
| 平均 (运动类)      |                | 63.9  | 51.9  | 76.9  | 75.6  | 81.8  | 75.3     | 86.3  | 75.6   | 86.6        |
| Default       | AntMaze-umaze  | 74.0  | 78.9  | 87.5  | 92.0  | -     | -        | 68.6  | 69.4   | 96.4 ± 1.4  |
| Diverse       | AntMaze-umaze  | 84.0  | 55.0  | 62.2  | 85.3  | -     | -        | 53.0  | 56.4   | 74.4 ± 9.7  |
| Play          | AntMaze-medium | 61.2  | 0.0   | 71.2  | 81.3  | -     | -        | 0.0   | 1.0    | 83.6 ± 4.4  |
| Diverse       | AntMaze-medium | 53.7  | 0.0   | 70.0  | 82.0  | -     | -        | 18.4  | 14.8   | 83.8 ± 3.5  |
| Play          | AntMaze-large  | 15.8  | 6.7   | 39.6  | 59.3  | -     | -        | 10.6  | 15.8   | 66.6 ± 9.8  |
| Diverse       | AntMaze-large  | 14.9  | 2.2   | 47.5  | 45.5  | -     | -        | 4.2   | 1.6    | 64.8 ± 5.5  |
| 平均 (AntMaze)  |                | 50.6  | 23.8  | 63.0  | 74.2  | -     | -        | 25.8  | 26.5   | 78.3        |
| # 动作候选数       |                | 1     | 100   | 1     | 32    | 1     | 1        | 50    | 1      | 1           |
| # 扩散步数        |                | -     | -     | -     | 15    | 100   | 100      | 5     | 5      | 15          |

Table 2. D4RL 基准的评估数值 (按 Fu et al. (2020) 的建议进行归一化)。本文报告训练结束时算法在 5 个随机种子上的性能均值与标准差。每个任务中距最大值 5% 以内的数值已加粗标出。为确保评估指标一致, 本文重新运行了 Diffusion-QL 的实验。详见 Appendix I。

其中  $t \sim \mathcal{U}(0, T)$ ,  $\mathbf{a}_t = \alpha_t \mathbf{a} + \sigma_t \epsilon$ ,  $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 。

求解上述问题的一个难点在于, 本文无法获得指定  $\mathbf{s}$  的真实分布  $\mu(\mathbf{a}|\mathbf{s})$ 。尽管本文可以在给定离线数据集  $\mathcal{D}^\mu$  时从联合分布  $\mu(\mathbf{s}, \mathbf{a})$  或边缘分布  $\mu(\mathbf{s})$  中采样数据, 但这些数据样本不能直接用于估计问题 (19) 中的目标。这是因为对比学习需要针对单个  $\mathbf{s}$  从  $\mu(\mathbf{a}|\mathbf{s})$  中取得  $K > 1$  个独立动作样本, 而在  $\mathbf{s}$  是连续变量的情况下, 本文在  $\mathcal{D}^\mu$  中只有一个这样的动作。

为解决该问题, 本文提出使用已经学到的行为模型  $\mu_\theta(\mathbf{a}_t|\mathbf{s}, t)$  预先生成支持动作集  $\mathcal{D}^{\mu_\theta}$ 。具体地, 对行为数据集  $\mathcal{D}^\mu$  中的每个状态  $\mathbf{s}$ , 本文从  $\mu_\theta(\cdot|\mathbf{s})$  中采样  $K$  个支持动作  $\{\hat{\mathbf{a}}^{(i)}\}_K$ , 并将这些动作与状态  $\mathbf{s}$  成对存储在  $\mathcal{D}^{\mu_\theta}$  中。然后本文用  $\mathcal{D}^{\mu_\theta}$  估计 (19) 中的目标:

$$\min_{\phi} \mathbb{E}_{t, \mathbf{s}, \epsilon} - \sum_{i=1}^K \frac{e^{\beta Q_\psi(\mathbf{s}, \hat{\mathbf{a}}^{(i)})}}{\sum_{j=1}^K e^{\beta Q_\psi(\mathbf{s}, \hat{\mathbf{a}}^{(j)})}} \log \frac{e^{f_\phi(\mathbf{s}, \hat{\mathbf{a}}_t^{(i)}, t)}}{\sum_{j=1}^K e^{f_\phi(\mathbf{s}, \hat{\mathbf{a}}_t^{(j)}, t)}} \quad (20)$$

其中  $\hat{\mathbf{a}}^{(i)}$ 、 $\hat{\mathbf{a}}^{(j)}$  是  $\mathcal{D}^{\mu_\theta}(\mathbf{s})$  的支持动作。由于问题 (20) 是在支持动作集而非真实数据集中优化的, 本文将这种方法称为支持集内 CEP。

### 5.3. 支持集内 Softmax Q 学习

本文现在详细讨论如何训练动作评估模型  $Q_\psi \approx Q^\pi$ 。理想情况下, 本文可以使用典型的 Bellman 式自举方法计算  $Q_\psi$  (Wang et al., 2022b; Goo & Niekum, 2022) 的均方误差 (MSE) 训练目标:

$$\mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a}) = r(\mathbf{s}, \mathbf{a}) + \gamma \mathbb{E}_{\mathbf{s}' \sim P(\cdot|\mathbf{s}, \mathbf{a}), \mathbf{a}' \sim \pi(\cdot|\mathbf{s}')} Q_\psi(\mathbf{s}', \mathbf{a}'). \quad (21)$$

然而, 在实际中计算  $\mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a})$  可能非常耗时, 因为它需要在训练过程中从扩散模型  $\pi$  中采样。因此, 本文利用生成的支持动作集  $\mathcal{D}^{\mu_\theta}$  来避免重复从扩散模型采样。具体地, 本文通过重要性采样估计  $\mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a})$ :

$$\mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a}) \approx r(\mathbf{s}, \mathbf{a}) + \gamma \frac{\sum_{\hat{\mathbf{a}}'} e^{\beta Q_\psi(\mathbf{s}', \hat{\mathbf{a}}')} Q_\psi(\mathbf{s}', \hat{\mathbf{a}}')}{\sum_{\hat{\mathbf{a}}'} e^{\beta Q_\psi(\mathbf{s}', \hat{\mathbf{a}}')}}. \quad (22)$$

### 5.4. 实验结果

本文在 Table 2 中将 QGPO 与多个相关工作在多个 D4RL (Fu et al., 2020) 任务上的性能进行对比。其中, MuJoCo locomotion 任务是离线 RL 中流行的基准, 主要目标是驱动不同机器人尽可能快地向前移动。数据集可能包含专家级与中级策略决策数据的混合 (Medium-Expert)、由单一中级策略生成的决策数据 (Medium), 以及由大量中级策略生成的多样化决策数据 (Medium-Replay)。Antmaze 任务通常被认为是基于 RL 的方法的困难任务。它们的目标是在多个预先指定的迷宫 (Umaze, Medium, Large) 中导航一个蚂蚁机器人。学习到的策略直接输出八维电机扭矩, 以控制蚂蚁机器人在每个自由度上的电机运动。因此, Antmaze 任务要求策略同时执行底层运动控制与高层导航。

从 Table 2 可以看出, 在大多数任务中, 本文方法优于所引用的基线, 尤其是在 Antmaze-Large 等困难任务中。基线包括 CQL (Kumar et al., 2020)、BCQ (Fujimoto et al., 2019) 与 IQL (Kostrikov et al., 2022) 等采用类高斯策略的传统 SOTA 算法。本文还纳入离线 RL 中采用基于扩散策略的最新进展。Diffuser (Janner et al.,



| 条件 | 分辨率     | 扩散步数 | FID           | sFID        | 精确率         | 召回率         |
|----|---------|------|---------------|-------------|-------------|-------------|
| ✓  | 128×128 | 250  | 3.17 / 2.97   | 5.17 / 5.09 | 0.78 / 0.78 | 0.59 / 0.59 |
| ✓  | 128×128 | 25   | 6.15 / 5.98   | 6.97 / 7.04 | 0.79 / 0.78 | 0.51 / 0.51 |
| ✓  | 256×256 | 250  | 4.74 / 4.59   | 5.23 / 5.25 | 0.82 / 0.82 | 0.52 / 0.52 |
| ✓  | 256×256 | 25   | 5.58 / 5.44   | 5.25 / 5.32 | 0.82 / 0.81 | 0.48 / 0.49 |
| ✗  | 256×256 | 250  | 32.53 / 33.03 | 7.23 / 6.99 | 0.56 / 0.56 | 0.65 / 0.65 |

Table 3. CEP 引导 (左) 与分类器引导 (右) 对图像样本质量的影响。

2022) 考虑使用集成 Eq. (14) 中基于 MSE 方法的能量引导方法。另一方面, Decision Diffuser (DD, Ajay et al. (2022)) 探索使用无分类器引导 (Ho & Salimans, 2021)。Diffusion-QL (D-QL, Wang et al. (2022b)) 追踪从行为扩散策略采样的动作的梯度, 以引导生成的动作走向高 Q 值区域。StBC (Chen et al., 2022) 简单地 从多个行为动作候选中重采样, 以预测的 Q 值作为采样权重。注意, 这种重采样技巧也为 Diffusion-QL 所采用。本文还研究了一种去除重采样技巧的 Diffusion-QL 变体 (D-QL@1), 以更好地反映扩散策略生成的决策质量。

## 6. 使用 CEP 的图像合成示例

### 6.1. 类条件图像合成中的结果

本文在 ImageNet 的图像合成任务上定量评估本文提出的方法 (见 Eq. (15)), 结果如 Table 3 所示。本文方法取得了与经典分类器引导 (Dhariwal & Nichol, 2021) 大致相当的结果。本文还在 Appendix O 中, 在固定随机种子下定性比较本文提出的 CEP 引导与分类器引导所生成的采样图像, 结果显示两者生成的样本在视觉上几乎完全相同。除训练目标外, 本文方法与 Dhariwal & Nichol (2021) 使用完全相同的网络结构、训练流程与评估方法, 且未进行任何超参数调优。这些结果经验性地表明, 在 ImageNet 图像合成任务中, 本文方法可作为分类器引导的几乎同等性能的替代方案。


### 6.2. 能量引导图像合成

本节展示如何通过连续能量函数 (如 Eq. (1) 所述) 而非 Section 6.1 中的离散类条件来控制图像合成。本文在  $t = 0$  数据空间中定义能量函数, 用于指示图像的整体颜色外观:

$$\mathcal{E}(\mathbf{x}) := -\|h(\mathbf{x}) - h_{\text{tar}}\|_1, \quad (23)$$

其中  $h(\mathbf{x})$  表示图像  $\mathbf{x}$  中每个像素的色相值, 可通过色调-饱和度-强度 (HSI) 分解 (Shapiro et al., 2001) 计算。 $h(\mathbf{x})$  定义在范围为  $[0, 2\pi]$  的角度空间中, 其中红色位于角度 0, 绿色位于  $2\pi/3$ , 蓝色位于  $4\pi/3$ , 在  $2\pi$  处再次为红色。因此, 通过将目标色相  $h_{\text{tar}}$  设置为相应的角度值, 可以评估图像在视觉上接近“纯色”图像的程度。

基于这样的能量函数定义, 本文训练了三个能量引导模型来控制采样图像的整体颜色外观。Figure 3 给出了

Figure 3. 红色、绿色与蓝色颜色引导下的样本, 改变引导尺度  $s$  (固定随机种子)。

示例。通过在不同引导模型之间切换, 并像 Dhariwal & Nichol (2021); Ho & Salimans (2021) 一样调节引导尺度来控制引导效果, 本文可以有效控制图像的颜色外观。如果扩散先验是条件模型, 生成的图像可能具有不同的背景 (例如沙漠、森林与天空), 从而在保证保真度的同时满足不同的颜色外观偏好。更多示例见 Appendix N。

## 7. 结论

本文正式考虑了以下采样问题: 扩散模型在数据分布上预训练, 但目标采样分布被能量函数所修改。本文表明, 可以通过在原始采样过程中添加额外的能量引导来实现该目标。本文进一步提出一种名为对比能量预测 (CEP) 的新训练目标, 用于训练能量模型以估计此类引导。与以往的能量引导方法相比, 本文提出的 CEP 引导是精确的, 因为它能保证收敛到期望分布。本文将所提方法应用于多个下游任务, 以验证其有效性与可扩展性。实验结果表明, 本文方法在离线 RL 中优于现有引导方法, 并在条件图像合成中与经典分类器引导大致相当。

## 致谢

本文工作得到国家重点研发计划 (2020AAA0106302) 资助; 国家自然科学基金项目 (Nos. 62061136001, 61620106010, 62076145, U19B2034, U1811461, U19A2081, 6197222, 62106120, 62076145) 资助; 清华大学国强研究院资助; 清华大学高性能计算中心支持。J.Z 同时受新基石科学基金会 XPLOER 奖资助。C.

Li 同时受北京市科技新星计划资助。

## 参考文献

- Ajay, A., Du, Y., Gupta, A., Tenenbaum, J., Jaakkola, T., and Agrawal, P. Is conditional generative modeling all you need for decision-making? arXiv preprint arXiv:2211.15657, 2022.
- Bao, F., Li, C., Zhu, J., and Zhang, B. Analytic-DPM: An analytic estimate of the optimal reverse variance in diffusion probabilistic models. In International Conference on Learning Representations, 2022a.
- Bao, F., Zhao, M., Hao, Z., Li, P., Li, C., and Zhu, J. Equivariant energy-guided sde for inverse molecular design. arXiv preprint arXiv:2209.15408, 2022b.
- Chen, H., Lu, C., Ying, C., Su, H., and Zhu, J. Offline reinforcement learning via high-fidelity generative behavior modeling. arXiv preprint arXiv:2209.14548, 2022.
- Chen, N., Zhang, Y., Zen, H., Weiss, R. J., Norouzi, M., and Chan, W. Wavegrad: Estimating gradients for waveform generation. In International Conference on Learning Representations, 2021a.
- Chen, N., Zhang, Y., Zen, H., Weiss, R. J., Norouzi, M., Dehak, N., and Chan, W. Wavegrad 2: Iterative refinement for text-to-speech synthesis. In International Speech Communication Association, pp. 3765–3769, 2021b.
- Chung, H., Kim, J., Mccann, M. T., Klasky, M. L., and Ye, J. C. Diffusion posterior sampling for general noisy inverse problems. arXiv preprint arXiv:2209.14687, 2022.
- Dhariwal, P. and Nichol, A. Q. Diffusion models beat GANs on image synthesis. In Advances in Neural Information Processing Systems, volume 34, pp. 8780–8794, 2021.
- Fu, J., Kumar, A., Nachum, O., Tucker, G., and Levine, S. D4rl: Datasets for deep data-driven reinforcement learning. arXiv preprint arXiv:2004.07219, 2020.
- Fujimoto, S., van Hoof, H., and Meger, D. Addressing function approximation error in actor-critic methods. In Dy, J. and Krause, A. (eds.), Proceedings of the 35th International Conference on Machine Learning, volume 80 of Proceedings of Machine Learning Research, pp. 1587–1596, Stockholm, Sweden, 10–15 Jul 2018. PMLR. URL <http://proceedings.mlr.press/v80/fujimoto18a.html>.
- Fujimoto, S., Meger, D., and Precup, D. Off-policy deep reinforcement learning without exploration. In Proceedings of the 36th International Conference on Machine Learning, volume 97 of Proceedings of Machine Learning Research, pp. 2052–2062. PMLR, 09–15 Jun 2019.
- Goo, W. and Niekum, S. Know your boundaries: The necessity of explicit behavioral cloning in offline rl. arXiv preprint arXiv:2206.00695, 2022.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. Generative adversarial networks. Communications of the ACM, 63(11):139–144, 2020.
- Graikos, A., Malkin, N., Jojic, N., and Samaras, D. Diffusion models as plug-and-play priors. arXiv preprint arXiv:2206.09012, 2022.
- Gu, S., Chen, D., Bao, J., Wen, F., Zhang, B., Chen, D., Yuan, L., and Guo, B. Vector quantized diffusion model for text-to-image synthesis. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10696–10706, 2022.
- Hinton, G. E. Training products of experts by minimizing contrastive divergence. Neural computation, 14(8):1771–1800, 2002.
- Ho, J. and Salimans, T. Classifier-free diffusion guidance. In NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications, 2021.
- Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. In Advances in Neural Information Processing Systems, volume 33, pp. 6840–6851, 2020.
- Ho, J., Chan, W., Saharia, C., Whang, J., Gao, R., Gritsenko, A., Kingma, D. P., Poole, B., Norouzi, M., Fleet, D. J., et al. Imagen video: High definition video generation with diffusion models. arXiv preprint arXiv:2210.02303, 2022a.
- Ho, J., Saharia, C., Chan, W., Fleet, D. J., Norouzi, M., and Salimans, T. Cascaded diffusion models for high fidelity image generation. Journal of Machine Learning Research, 23(47):1–33, 2022b.
- Ho, J., Salimans, T., Gritsenko, A., Chan, W., Norouzi, M., and Fleet, D. J. Video diffusion models. arXiv preprint arXiv:2204.03458, 2022c.
- Hoogeboom, E., Satorras, V. G., Vignac, C., and Welling, M. Equivariant diffusion for molecule generation in 3D. In International Conference on Machine Learning, pp. 8867–8887. PMLR, 2022.



- Janner, M., Du, Y., Tenenbaum, J., and Levine, S. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, 2022.
- Karras, T., Aittala, M., Aila, T., and Laine, S. Elucidating the design space of diffusion-based generative models. *arXiv preprint arXiv:2206.00364*, 2022.
- Kawar, B., Elad, M., Ermon, S., and Song, J. Denoising diffusion restoration models. *arXiv preprint arXiv:2201.11793*, 2022.
- Kingma, D. P. and Welling, M. Auto-encoding variational bayes. In *International Conference on Learning Representations*, 2014.
- Kingma, D. P., Salimans, T., Poole, B., and Ho, J. Variational diffusion models. In *Advances in Neural Information Processing Systems*, 2021.
- Kostrikov, I., Nair, A., and Levine, S. Offline reinforcement learning with implicit Q-learning. In *International Conference on Learning Representations*, 2022.
- Kumar, A., Fu, J., Tucker, G., and Levine, S. Stabilizing off-policy q-learning via bootstrapping error reduction. *CoRR*, abs/1906.00949, 2019. URL <http://arxiv.org/abs/1906.00949>.
- Kumar, A., Zhou, A., Tucker, G., and Levine, S. Conservative Q-learning for offline reinforcement learning. *arXiv preprint arXiv:2006.04779*, 2020.
- Kwon, G. and Ye, J. C. Diffusion-based image translation using disentangled style and content representation. *arXiv preprint arXiv:2209.15264*, 2022.
- Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.
- Li, X. L., Thickstun, J., Gulrajani, I., Liang, P., and Hashimoto, T. B. Diffusion-LM improves controllable text generation. *arXiv preprint arXiv:2205.14217*, 2022.
- Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N. M. O., Erez, T., Tassa, Y., Silver, D., and Wierstra, D. Continuous control with deep reinforcement learning. *ICLR*, 2016.
- Liu, J., Li, C., Ren, Y., Chen, F., and Zhao, Z. Diff-singer: Singing voice synthesis via shallow diffusion mechanism. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pp. 11020–11028, 2022.
- Lu, C., Zheng, K., Bao, F., Chen, J., Li, C., and Zhu, J. Maximum likelihood training for score-based diffusion odes by high order denoising score matching. In *International Conference on Machine Learning*, pp. 14429–14460. PMLR, 2022a.
- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., and Zhu, J. Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps. *arXiv preprint arXiv:2206.00927*, 2022b.
- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., and Zhu, J. Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models. *arXiv preprint arXiv:2211.01095*, 2022c.
- Meng, C., Gao, R., Kingma, D. P., Ermon, S., Ho, J., and Salimans, T. On distillation of guided diffusion models. *arXiv preprint arXiv:2210.03142*, 2022a.
- Meng, C., Song, Y., Song, J., Wu, J., Zhu, J.-Y., and Ermon, S. SDEdit: Image synthesis and editing with stochastic differential equations. In *International Conference on Learning Representations*, 2022b.
- Nair, A., Gupta, A., Dalal, M., and Levine, S. Awac: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- Nichol, A., Dhariwal, P., Ramesh, A., Shyam, P., Mishkin, P., McGrew, B., Sutskever, I., and Chen, M. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. *arXiv preprint arXiv:2112.10741*, 2021.
- Nie, W., Vahdat, A., and Anandkumar, A. Controllable and compositional generation with latent-space energy-based models. *Advances in Neural Information Processing Systems*, 34:13497–13510, 2021.
- Oord, A. v. d., Li, Y., and Vinyals, O. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.
- Pandey, K., Mukherjee, A., Rai, P., and Kumar, A. DiffuseVAE: Efficient, controllable and high-fidelity generation from low-dimensional latents. *arXiv preprint arXiv:2201.00308*, 2022.
- Pearce, T., Rashid, T., Kanervisto, A., Bignell, D., Sun, M., Georgescu, R., Macua, S. V., Tan, S. Z., Momennejad, I., Hofmann, K., et al. Imitating human behaviour with diffusion models. In *Deep Reinforcement Learning Workshop NeurIPS 2022*, 2022.

- Peng, X. B., Kumar, A., Zhang, G., and Levine, S. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. arXiv preprint arXiv:1910.00177, 2019.
- Peters, J., Mulling, K., and Altun, Y. Relative entropy policy search. In Twenty-Fourth AAAI Conference on Artificial Intelligence, 2010.
- Poole, B., Jain, A., Barron, J. T., and Mildenhall, B. Dreamfusion: Text-to-3d using 2d diffusion. arXiv preprint arXiv:2209.14988, 2022.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., et al. Learning transferable visual models from natural language supervision. In International Conference on Machine Learning, pp. 8748–8763. PMLR, 2021.
- Ramesh, A., Dhariwal, P., Nichol, A., Chu, C., and Chen, M. Hierarchical text-conditional image generation with CLIP latents. arXiv preprint arXiv:2204.06125, 2022.
- Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B. High-resolution image synthesis with latent diffusion models. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10684–10695, 2022.
- Saharia, C., Chan, W., Chang, H., Lee, C., Ho, J., Salimans, T., Fleet, D., and Norouzi, M. Palette: Image-to-image diffusion models. In ACM SIGGRAPH 2022 Conference Proceedings, pp. 1–10, 2022a.
- Saharia, C., Chan, W., Saxena, S., Li, L., Whang, J., Denton, E., Ghasemipour, S. K. S., Ayan, B. K., Mahdavi, S. S., Lopes, R. G., et al. Photorealistic text-to-image diffusion models with deep language understanding. arXiv preprint arXiv:2205.11487, 2022b.
- Salimans, T. and Ho, J. Progressive distillation for fast sampling of diffusion models. In International Conference on Learning Representations, 2022.
- Shapiro, L. G., Stockman, G. C., et al. Computer vision, volume 3. Prentice Hall New Jersey, 2001.
- Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., and Ganguli, S. Deep unsupervised learning using nonequilibrium thermodynamics. In International Conference on Machine Learning, pp. 2256–2265. PMLR, 2015.
- Song, J., Meng, C., and Ermon, S. Denoising diffusion implicit models. In International Conference on Learning Representations, 2021a.
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., and Poole, B. Score-based generative modeling through stochastic differential equations. In International Conference on Learning Representations, 2021b.
- Theis, L., Salimans, T., Hoffman, M. D., and Mentzer, F. Lossy compression with gaussian diffusion. arXiv preprint arXiv:2206.08889, 2022.
- Wang, T., Zhang, B., Zhang, T., Gu, S., Bao, J., Baltrusaitis, T., Shen, J., Chen, D., Wen, F., Chen, Q., et al. Rodin: A generative model for sculpting 3d digital avatars using diffusion. arXiv preprint arXiv:2212.06135, 2022a.
- Wang, Z., Novikov, A., Zolna, K., Merel, J. S., Springenberg, J. T., Reed, S. E., Shahriari, B., Siegel, N., Gulcehre, C., Heess, N., and de Freitas, N. Critic regularized regression. In Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M., and Lin, H. (eds.), Advances in Neural Information Processing Systems, volume 33, pp. 7768–7778. Curran Associates, Inc., 2020.
- Wang, Z., Hunt, J. J., and Zhou, M. Diffusion policies as an expressive policy class for offline reinforcement learning. arXiv preprint arXiv:2208.06193, 2022b.
- Wu, L., Gong, C., Liu, X., Ye, M., and Liu, Q. Diffusion-based molecule generation with informative prior bridges. arXiv preprint arXiv:2209.00865, 2022.
- Xiao, Z., Yan, Q., and Amit, Y. Exponential tilting of generative models: Improving sample quality by training and sampling from latent energy. arXiv preprint arXiv:2006.08100, 2020.
- Xu, M., Yu, L., Song, Y., Shi, C., Ermon, S., and Tang, J. Geodiff: A geometric diffusion model for molecular conformation generation. arXiv preprint arXiv:2203.02923, 2022.
- Yang, R., Srivastava, P., and Mandt, S. Diffusion probabilistic modeling for video generation. arXiv preprint arXiv:2203.09481, 2022.
- Zeng, X., Vahdat, A., Williams, F., Gojcic, Z., Litany, O., Fidler, S., and Kreis, K. Lion: Latent point diffusion models for 3d shape generation. arXiv preprint arXiv:2210.06978, 2022.
- Zhang, Q. and Chen, Y. Fast sampling of diffusion models with exponential integrator. arXiv preprint arXiv:2204.13902, 2022.

- Zhang, Q., Tao, M., and Chen, Y. gddim: Generalized denoising diffusion implicit models. arXiv preprint arXiv:2206.05564, 2022.
- Zhao, M., Bao, F., Li, C., and Zhu, J. Egsde: Unpaired image-to-image translation via energy-guided stochastic differential equations. arXiv preprint arXiv:2207.06635, 2022.
- Zhong, Y., Liu, H., Liu, X., Bao, F., Shen, W., and Li, C. Deep generative modeling on limited data with regularization by nontransferable pre-trained models. arXiv preprint arXiv:2208.14133, 2022.
- Zhou, D., Wang, W., Yan, H., Lv, W., Zhu, Y., and Feng, J. Magicvideo: Efficient video generation with latent diffusion models. arXiv preprint arXiv:2211.11018, 2022.
- Zhu, J., Chen, N., and Xing, E. P. Bayesian inference with posterior regularization and applications to infinite latent svms. *The Journal of Machine Learning Research*, 15(1):1799–1847, 2014.
- Ziegler, D. M., Stiennon, N., Wu, J., Brown, T. B., Radford, A., Amodei, D., Christiano, P., and Irving, G. Fine-tuning language models from human preferences. arXiv preprint arXiv:1909.08593, 2019.



## A. 局限性与更广泛的影响

与其他深度生成建模方法类似, 能量引导扩散采样可能被用于生成“深度伪造”等有害内容, 并可能反映和放大训练数据集中存在的不受欢迎的社会偏见。

## B. 相关工作

**扩散模型及其应用。** 扩散模型 (也称为基于得分的生成模型) (Sohl-Dickstein et al., 2015; Ho et al., 2020; Song et al., 2021b; Karras et al., 2022) 是新兴的强生成模型, 并在多种任务上取得了令人瞩目的成功, 例如语音合成 (Liu et al., 2022; Chen et al., 2021a;b)、高分辨率图像合成 (Dhariwal & Nichol, 2021; Ho et al., 2022b)、图像编辑 (Meng et al., 2022b; Saharia et al., 2022a; Zhao et al., 2022)、文生图生成 (Saharia et al., 2022b; Nichol et al., 2021; Ramesh et al., 2022; Rombach et al., 2022; Gu et al., 2022)、分子生成 (Xu et al., 2022; Hoogeboom et al., 2022; Wu et al., 2022)、3-D 形状生成 (Zeng et al., 2022; Poole et al., 2022; Wang et al., 2022a)、视频生成 (Ho et al., 2022c;a; Yang et al., 2022; Zhou et al., 2022) 与数据压缩 (Theis et al., 2022; Kingma et al., 2021; Lu et al., 2022a)。扩散模型的采样方法包括免训练快速采样器 (Song et al., 2021a; Bao et al., 2022a; Lu et al., 2022b;c; Zhang & Chen, 2022; Zhang et al., 2022) 与基于蒸馏的采样器 (Salimans & Ho, 2022; Meng et al., 2022a)。

**作为先验的扩散模型。** 已有许多工作将预训练扩散模型作为先验分布  $q(\mathbf{x})$ , 并旨在从 Eq. (1) 中采样。Graikos et al. (2022) 提出一种免训练采样方法, 直接利用约束 (Eq. (1) 中的  $\mathcal{E}(\cdot)$ ), 可用于近似求解旅行商问题; Poole et al. (2022) 使用预训练 2-D 扩散模型并优化 3-D 参数以进行 3-D 形状生成; Kavar et al. (2022); Chung et al. (2022) 使用预训练扩散模型求解线性及一些特殊的非线性逆问题, 如图像修复、去模糊与去噪; Zhao et al. (2022); Bao et al. (2022b) 使用人工设计的中间能量引导进行图像到图像转换与逆分子设计。然而, 所有这些现有方法都无法保证最终样本服从 Eq. (1) 中的期望分布  $p(\mathbf{x})$ 。

**可控生成。** 为了将人类偏好与可控性嵌入深度生成模型的采样过程, 许多近期工作 (Nie et al., 2021; Li et al., 2022; Pandey et al., 2022) 通过一些学习得到的条件模型操控潜空间的采样过程, 并利用获得的潜码生成期望的样本。这类生成器包括变分自编码器 (Kingma & Welling, 2014) 与生成对抗网络 (Goodfellow et al., 2020)。然而, 现有在扩散模型中实现可控生成的方法主要聚焦于条件引导。本文在 Eq. (1) 中考虑的问题可以另外理解为一种将人类可控性嵌入扩散模型采样过程的通用形式。

**离线强化学习。** 离线强化学习通常需要调和两个相互冲突的目标: 在最大化期望  $Q$  值的同时保持在行为策略附近。为了保持与可能多样的行为策略一致, 近期研究 (Janner et al., 2022; Goo & Niekum, 2022; Wang et al., 2022b; Chen et al., 2022; Ajay et al., 2022; Pearce et al., 2022) 发现扩散模型是一种强大的生成工具, 在行为建模方面往往优于之前的高斯分布 (Peng et al., 2019; Wang et al., 2020; Nair et al., 2020) 或 VAE (Fujimoto et al., 2019; Kumar et al., 2019) 等生成方法。在如何生成最大化学习所得  $Q$  函数的动作方面, 不同方法采取不同做法。Diffuser (Janner et al., 2022) 旨在模仿分类器引导方法 (Dhariwal & Nichol, 2021), 提出使用如 Eq. (14) 所述的引导方法, 但未对所提方法的收敛性质进行详细讨论。另一方面, 决策扩散器 (DD, Ajay et al. (2022)) 探索使用无分类器引导。Diffusion-QL 追踪从行为扩散策略采样得到的动作的梯度, 以引导生成的动作作用于高  $Q$  值区域。SfBC (Chen et al., 2022) 与 Diffusion-QL 使用相同的技巧, 即利用预测的  $Q$  值作为采样权重, 从多个行为动作候选中重新采样动作。其他工作 (Goo & Niekum, 2022; Pearce et al., 2022) 仅将扩散模型用于纯行为克隆, 因此不需要最大化  $Q$  值。与先前工作相比, 本文旨在研究如何精确训练能量引导模型, 并将其用于引导基于扩散的决策过程中的采样过程。

## C. 关于 Eq. (1) 的动机

Eq. (1) 中的形式在各种设定下都具有一般性与普遍性, 例如基于 Gibbs 分布的专家乘积 (Hinton, 2002)、后验正则化贝叶斯推断 (Zhu et al., 2014)、生成模型的指数倾斜 (Xiao et al., 2020)、使用预训练模型正则化在有限数据上训练深度生成模型 (Zhong et al., 2022)、强化学习中的约束策略优化 (Peng et al., 2019; Ziegler et al., 2019) 以及逆问题 (Chung et al., 2022)。本节给出该目标的一个动机示例。

设  $q(\mathbf{x})$  为未知的数据分布,  $\mathcal{E}(\mathbf{x})$  为本文希望最小化的损失函数。本文希望优化生成模型  $p(\mathbf{x})$ , 使得从  $p(\mathbf{x})$  中采样的样本具有尽可能小的损失  $\mathcal{E}(\mathbf{x})$ ; 同时, 本文还用数据分布  $q(\mathbf{x})$  正则化模型  $p(\mathbf{x})$ , 以提高多样性并避免坍塌

解。目标可以表示为:

$$\min_p \mathbb{E}_{p(\mathbf{x})}[\mathcal{E}(\mathbf{x})] + \frac{1}{\beta} D_{\text{KL}}(p(\mathbf{x}) \parallel q(\mathbf{x})), \quad (24)$$

其中  $D_{\text{KL}}(p(\mathbf{x}) \parallel q(\mathbf{x}))$  是正则化项,  $\beta$  是超参数。只需对  $p$  求导并令其为零, 即可得到最优  $p^*$  满足

$$p^*(\mathbf{x}) \propto q(\mathbf{x}) e^{-\mathcal{E}(\mathbf{x})}, \quad (25)$$

其形式与 Eq. (1) 完全一致。

## D. 证明与补充理论

### D.1. 带条件变量的 CEP

假设能量函数为  $\mathcal{E}(\mathbf{x}_0, c)$ , 其中包含一个额外的条件变量  $c$ , 且  $c$  服从分布  $q(c)$ 。本文旨在用参数为  $\phi$  的神经网络  $f_\phi(\cdot, c, t) : \mathbb{R}^d \rightarrow \mathbb{R}$  学习中间能量引导。

**无条件先验下的 CEP。** 假设先验分布  $q_0(\mathbf{x})$  是无条件的。本文旨在对每个给定的  $c$ , 从

$$p_0(\mathbf{x}_0|c) \propto q_0(\mathbf{x}_0) e^{-\beta \mathcal{E}(\mathbf{x}_0, c)}, \quad (26)$$

中采样。对  $q(c)$  取期望后, Eq. (12) 中的目标为

$$\min_{\phi} \mathbb{E}_{q(c)} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)}, c)} \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right]. \quad (27)$$

**条件先验下的 CEP。** 假设先验分布  $q_0(\mathbf{x}|c)$  以  $c$  为条件。本文旨在对每个给定的  $c$ , 从

$$p_0(\mathbf{x}_0|c) \propto q_0(\mathbf{x}_0|c) e^{-\beta \mathcal{E}(\mathbf{x}_0, c)}, \quad (28)$$

中采样。对  $q(c)$  取期望后, Eq. (12) 中的目标为

$$\min_{\phi} \mathbb{E}_{q(c)} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)}|c)} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)}, c)} \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right]. \quad (29)$$

此外, 本文可以为  $i = 1, \dots, K$  抽取  $K$  个样本对  $(\mathbf{x}_0^{(i)}, c^{(i)})$ , 上述目标变为

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{\prod_{i=1}^K q_0(\mathbf{x}_0^{(i)}, c^{(i)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)}, c^{(i)})} \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(j)}, t)}} \right]. \quad (30)$$

注意分子中的项  $(\mathbf{x}_t^{(i)}, c^{(i)}) \sim q_t(\mathbf{x}_t^{(i)}, c^{(i)})$  是从联合分布中采样的样本; 而分母中的项  $(\mathbf{x}_t^{(j)}, c^{(j)}, t) \sim q_t(\mathbf{x}_t^{(j)})q(c^{(j)})$  是独立样本。该形式与对比学习目标 (Oord et al., 2018) 高度相似, 本文将在附录 F 中讨论二者之间的联系。总之, 条件先验下的 CEP 可以被视为带软能量标签的对比学习的一种推广版本。

### D.2. 多时间步的 CEP

用 Eq. (12) 训练引导模型需要对每个时间  $t$  有  $K$  个  $\mathbf{x}_t$  样本。如果使用  $M$  个  $t \in (0, T]$  的样本, 则  $\mathbf{x}_t$  的样本总数为  $KM$ 。然而, 对于图像等高维数据, 内存预算有限, 本文希望在每个时间  $t$  使用尽可能多的样本。本节提出一种替代目标, 可以利用来自不同时间  $t$  的  $K$  个样本  $\mathbf{x}_t$ 。因此, 本文只需要  $K$  个  $t$  的样本与  $K$  个  $\mathbf{x}_t$  的样本即可降低内存成本。本文在下文正式提出该目标, 并在附录 D.5 中给出证明。

**定理 D.1 (多时间步的 CEP).** 设  $t^{(1)}, \dots, t^{(K)}$  是来自  $p(t)$  的  $K$  个 i.i.d. 样本。对每个  $i = 1, \dots, K$ , 令  $\mathbf{x}_t^{(i)} := \alpha_{t^{(i)}} \mathbf{x}_0^{(i)} + \sigma_{t^{(i)}} \epsilon^{(i)}$ , 其中  $\alpha_t, \sigma_t$  在 Eq. (8) 中定义。定义目标:

$$\min_{\phi} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \underbrace{\sum_{i=1}^K \left( e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)})} \right)}_{\text{能量标签}} \log \underbrace{\frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, t^{(j)})}}}_{\text{预测标签}} \right]. \quad (31)$$

在无限模型容量与数据样本下, 对所有  $K > 1$  与  $t \in [0, T]$ , Eq. (31) 中最优的  $f_{\phi^*}$  满足

$$\nabla_{\mathbf{x}_t} f_{\phi^*}(\mathbf{x}_t, t) = \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t). \quad (32)$$

下面本文还给出带条件变量的能量函数对应的目标。

**多时间步下无条件先验的 CEP。** 目标为

$$\min_{\phi} \mathbb{E}_{q(c)} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)}, c)} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, c, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, c, t^{(j)})}} \right]. \quad (33)$$

**多时间步下条件先验的 CEP。**

$$\min_{\phi} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{\prod_{i=1}^K q_0(\mathbf{x}_0^{(i)}, c^{(i)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)}, c^{(i)})} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, c^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, c^{(j)}, t^{(j)})}} \right]. \quad (34)$$

同样注意, 分子中的项  $(\mathbf{x}_t^{(i)}, c^{(i)}, t^{(i)}) \sim q(\mathbf{x}_t^{(i)}, c^{(i)}, t^{(i)})$  是从联合分布中采样的样本; 而分母中的项  $(\mathbf{x}_t^{(j)}, c^{(j)}, t^{(j)}) \sim q(\mathbf{x}_t^{(j)}, t^{(j)})q(c^{(j)})$  是独立样本。

### D.3. Theorem 3.1 的证明

Proof. 假设  $p_0(\mathbf{x}_0)$  的归一化常数为

$$Z = \int q_0(\mathbf{x}_0) e^{-\beta \mathcal{E}(\mathbf{x}_0)} d\mathbf{x}_0 = \mathbb{E}_{q_0(\mathbf{x}_0)} [e^{-\beta \mathcal{E}(\mathbf{x}_0)}],$$

则本文有

$$p_0(\mathbf{x}_0) = \frac{q_0(\mathbf{x}_0) e^{-\beta \mathcal{E}(\mathbf{x}_0)}}{Z}$$

根据定义, 本文有

$$\begin{aligned} p_t(\mathbf{x}_t) &= \int p_{t0}(\mathbf{x}_t | \mathbf{x}_0) p_0(\mathbf{x}_0) d\mathbf{x}_0 \\ &= \int p_{t0}(\mathbf{x}_t | \mathbf{x}_0) q_0(\mathbf{x}_0) \frac{e^{-\beta \mathcal{E}(\mathbf{x}_0)}}{Z} d\mathbf{x}_0 \\ &= \int q_{t0}(\mathbf{x}_t | \mathbf{x}_0) q_0(\mathbf{x}_0) \frac{e^{-\beta \mathcal{E}(\mathbf{x}_0)}}{Z} d\mathbf{x}_0 \\ &= q_t(\mathbf{x}_t) \int q_0(\mathbf{x}_0 | \mathbf{x}_t) \frac{e^{-\beta \mathcal{E}(\mathbf{x}_0)}}{Z} d\mathbf{x}_0 \\ &= \frac{q_t(\mathbf{x}_t) \mathbb{E}_{q_0(\mathbf{x}_0 | \mathbf{x}_t)} [e^{-\beta \mathcal{E}(\mathbf{x}_0)}]}{Z} \\ &= \frac{q_t(\mathbf{x}_t) e^{-\mathcal{E}_t(\mathbf{x}_t)}}{Z} \end{aligned}$$

从而本文有

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t) - \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$$

□

#### D.4. Theorem 3.2 的证明

Proof. 由于  $q_{t0}(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t|\alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I})$ , 本文将 Eq. (12) 重写为

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{q_{t0}(\mathbf{x}_t^{(1:K)}|\mathbf{x}_0^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta\mathcal{E}(\mathbf{x}_0^{(i)})} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}} \right].$$

将  $q_{0t}(\mathbf{x}_0, \mathbf{x}_t) = q_t(\mathbf{x}_t)q_{0t}(\mathbf{x}_0|\mathbf{x}_t)$  重写并将条件期望  $q_{0t}(\mathbf{x}_0|\mathbf{x}_t)$  移入内层, 本文有

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - \sum_{i=1}^K \mathbb{E}_{q_{0t}(\mathbf{x}_0^{(i)}|\mathbf{x}_t^{(i)})} \left[ e^{-\beta\mathcal{E}(\mathbf{x}_0^{(i)})} \right] \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}} \right].$$

根据 Eq. (9), 本文有  $\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [e^{-\beta\mathcal{E}(\mathbf{x}_0)}] = e^{-\mathcal{E}_t(\mathbf{x}_t)}$ , 因此上述目标等价于

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}} \right]. \quad (35)$$

对每个  $t$  与  $\mathbf{x}_t^{(1:K)}$ , 对  $i = 1, \dots, K$ , 定义

$$\begin{aligned} a_i(\mathbf{x}_t^{(1:K)}, t) &:= \frac{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}}{\sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}}, \\ b_i(\mathbf{x}_t^{(1:K)}, t) &:= \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t)}}, \\ c(\mathbf{x}_t^{(1:K)}, t) &:= \sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})} > 0, \end{aligned}$$

则 Eq. (35) 等价于

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - c(\mathbf{x}_t^{(1:K)}, t) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t) \right) \right].$$

对每个固定的  $t$  与  $\mathbf{x}_t^{(1:K)}$ , 由于  $\sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) = \sum_{i=1}^K b_i(\mathbf{x}_t^{(1:K)}, t) = 1$ , 根据 Gibbs 不等式, 本文有

$$- \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t) \right) \geq - \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) \log \left( a_i(\mathbf{x}_t^{(1:K)}, t) \right),$$

因此本文有

$$\begin{aligned} & \mathbb{E}_{p(t)} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - c(\mathbf{x}_t^{(1:K)}, t) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t) \right) \right] \\ & \geq \mathbb{E}_{p(t)} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - c(\mathbf{x}_t^{(1:K)}, t) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t) \log \left( a_i(\mathbf{x}_t^{(1:K)}, t) \right) \right], \end{aligned}$$

等号当且仅当对每个  $t \in (0, T]$  以及  $q_t(\mathbf{x}_t^{(1:K)})$  支撑空间中的每个  $\mathbf{x}_t^{(1:K)}$  成立,

$$b_i(\mathbf{x}_t^{(1:K)}, t) = a_i(\mathbf{x}_t^{(1:K)}, t), \quad i = 1, \dots, K,$$

因此在无限数据与模型容量下, 最优的  $\phi^*$  满足

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t)}}{\sum_{j=1}^K e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t)}} = \frac{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}}{\sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}},$$



因此对每个  $i = 1, \dots, K$ ,

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t)}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}} = \frac{\sum_{j=1}^K e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t)}}{\sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}},$$

由于  $\mathbf{x}_t^{(1:K)}$  与  $t$  的任意性, 对任意  $\mathbf{x}_t^{(i)}$ 、 $\mathbf{x}_t^{(j)}$ , 本文有

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t)}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}} = \frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t)}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}}.$$

因此, 存在一个不依赖  $\mathbf{x}_t$  的常数  $C_t$ , 使得

$$e^{-f_{\phi^*}(\mathbf{x}_t, t)} = C_t \cdot e^{-\mathcal{E}_t(\mathbf{x}_t)} \propto e^{-\mathcal{E}_t(\mathbf{x}_t)},$$

从而  $\nabla_{\mathbf{x}_t} f_{\phi^*}(\mathbf{x}_t, t) = \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$ . □

#### D.5. Theorem D.1 的证明

直观上, Theorem D.1 可以通过将  $(\mathbf{x}_t, t)$  视为一个整体随机变量, 以类似 Theorem 3.2 的方式加以证明。下面本文给出正式证明。

Theorem D.1 的证明. 由于  $q_{t0}(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t|\alpha_t\mathbf{x}_0, \sigma_t^2\mathbf{I})$ , 本文将 Eq. (31) 重写为

$$\min_{\phi} \mathbb{E}_{q(t^{(1:K)})} \mathbb{E}_{q(\mathbf{x}_0^{(1:K)}, \mathbf{x}_t^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)})} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t^{(j)})}} \right].$$

将  $q(\mathbf{x}_0, \mathbf{x}_t) = q_t(\mathbf{x}_t)q_{0t}(\mathbf{x}_0|\mathbf{x}_t)$  重写并将条件期望  $q_{0t}(\mathbf{x}_0|\mathbf{x}_t)$  移入内层, 本文有

$$\min_{\phi} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - \sum_{i=1}^K \mathbb{E}_{q_{0t(i)}(\mathbf{x}_0^{(i)}|\mathbf{x}_t^{(i)})} \left[ e^{-\beta \mathcal{E}(\mathbf{x}_0^{(i)})} \right] \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t^{(j)})}} \right].$$

根据 Eq. (9), 本文有  $\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [e^{-\beta \mathcal{E}(\mathbf{x}_0)}] = e^{-\mathcal{E}_t(\mathbf{x}_t)}$ , 因此上述目标等价于

$$\min_{\phi} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - \sum_{i=1}^K e^{-\mathcal{E}_t(i)(\mathbf{x}_t^{(i)})} \log \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t^{(j)})}} \right]. \quad (36)$$

对每个  $t^{(1:K)}$  与  $\mathbf{x}_t^{(1:K)}$ , 对  $i = 1, \dots, K$ , 定义

$$\begin{aligned} a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) &:= \frac{e^{-\mathcal{E}_t(i)(\mathbf{x}_t^{(i)})}}{\sum_{j=1}^K e^{-\mathcal{E}_t(j)(\mathbf{x}_t^{(j)})}}, \\ b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) &:= \frac{e^{-f_{\phi}(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi}(\mathbf{x}_t^{(j)}, t^{(j)})}}, \\ c(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) &:= \sum_{j=1}^K e^{-\mathcal{E}_t(j)(\mathbf{x}_t^{(j)})} > 0, \end{aligned}$$

则 Eq. (36) 等价于

$$\min_{\phi} \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ - c(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \right) \right].$$

对每个固定的  $t^{(1:K)}$  与  $\mathbf{x}_t^{(1:K)}$ , 由于  $\sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) = \sum_{i=1}^K b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) = 1$ , 根据 Gibbs 不等式, 本文有

$$- \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \right) \geq - \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \log \left( a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \right),$$

因此本文有

$$\begin{aligned} & \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ -c(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \log \left( b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \right) \right] \\ & \geq \mathbb{E}_{p(t^{(1:K)})} \mathbb{E}_{q_t(\mathbf{x}_t^{(1:K)})} \left[ -c(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \sum_{i=1}^K a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \log \left( a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) \right) \right], \end{aligned}$$

等号当且仅当对每个  $t^{(1:K)}$  以及  $q_t(\mathbf{x}_t^{(1:K)})$  支撑空间中的每个  $\mathbf{x}_t^{(1:K)}$  成立,

$$b_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}) = a_i(\mathbf{x}_t^{(1:K)}, t^{(1:K)}), \quad i = 1, \dots, K,$$

因此在无限数据与模型容量下, 最优的  $\phi^*$  满足

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t^{(i)})}}{\sum_{j=1}^K e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t^{(j)})}} = \frac{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}}{\sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}},$$

因此对每个  $i = 1, \dots, K$ ,

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t^{(i)})}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}} = \frac{\sum_{j=1}^K e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t^{(j)})}}{\sum_{j=1}^K e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}},$$

由于  $\mathbf{x}_t^{(1:K)}$  与  $t^{(1:K)}$  的任意性, 对任意  $\mathbf{x}_t^{(i)}$ 、 $\mathbf{x}_t^{(j)}$ , 本文有

$$\frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(i)}, t^{(i)})}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(i)})}} = \frac{e^{-f_{\phi^*}(\mathbf{x}_t^{(j)}, t^{(j)})}}{e^{-\mathcal{E}_t(\mathbf{x}_t^{(j)})}}.$$

因此, 存在一个不依赖  $\mathbf{x}_t$  的常数  $C_t$ , 使得

$$e^{-f_{\phi^*}(\mathbf{x}_t, t)} = C_t \cdot e^{-\mathcal{E}_t(\mathbf{x}_t)} \propto e^{-\mathcal{E}_t(\mathbf{x}_t)},$$

从而  $\nabla_{\mathbf{x}_t} f_{\phi^*}(\mathbf{x}_t, t) = \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$ . □

## E. 与现有能量引导采样算法的比较

首先, 本文可以轻松计算 MSE (Janner et al., 2022; Bao et al., 2022b) 与 DPS (Ho et al., 2022c; Chung et al., 2022) 中所用能量引导的梯度, 并将结果总结在 Table 4 中。下面本文提出这些方法之间更深入的联系。

**能量的比较。** 精确能量函数为

$$\mathcal{E}_t(\mathbf{x}_t) = -\log \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ e^{-\mathcal{E}_0(\mathbf{x}_0)} \right].$$

交换 log 函数与期望的次序, 本文可以导出 MSE 中所用的能量:

$$\mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t) = -\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ \log \left( e^{-\mathcal{E}_0(\mathbf{x}_0)} \right) \right] = \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0)].$$

进一步交换  $\mathcal{E}_0$  函数与期望的次序, 本文可以导出 DPS 中所用的能量:

$$\mathcal{E}_t^{\text{DPS}}(\mathbf{x}_t) = \mathcal{E}_0 \left( \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathbf{x}_0] \right).$$

直观上, 交换非线性函数与期望的次序会引入额外的近似误差, 且误差取决于非线性函数的复杂程度。由于  $\log(\cdot)$  是简单的凹函数, 而  $\mathcal{E}_0(\cdot)$  可能相当复杂, DPS 的近似误差可能相当大, 这可以解释为什么在图 2 与图 6 中 DPS 的采样结果明显差于 CEP。

Table 4. 能量引导采样算法之间的比较。

| 方法       | 能量最优解                                                                                     | 引导最优解                                                                                                                                                                                                                                              | 精确引导 |
|----------|-------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| CEP (本文) | $-\log \mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [e^{-\mathcal{E}_0(\mathbf{x}_0)}]$ | $\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [-e^{\mathcal{E}_t(\mathbf{x}_t)-\mathcal{E}_0(\mathbf{x}_0)} \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0 \mathbf{x}_t)]$                                                                       | ✓    |
| MSE      | $\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0)]$            | $\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0 \mathbf{x}_t)]$                                                                                                        | ✗    |
| DPS      | $\mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)}[\mathbf{x}_0])$             | $\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)} \left[ \left( (\nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0 \mathbf{x}_t)}[\mathbf{x}_0]))^\top \mathbf{x}_0 \right) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0 \mathbf{x}_t) \right]$ | ✗    |

引导的比较。精确引导为

$$\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t) = \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ -e^{\mathcal{E}_t(\mathbf{x}_t)-\mathcal{E}_0(\mathbf{x}_0)} \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t) \right]. \quad (37)$$

而 MSE 的引导为

$$\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t) = \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)].$$

而 DPS 的引导为

$$\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{DPS}}(\mathbf{x}_t) = \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ \left( (\nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]))^\top \mathbf{x}_0 \right) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t) \right].$$

下面本文讨论这三个函数之间的关系。

对  $e^{\mathcal{E}_t(\mathbf{x}_t)-\mathcal{E}_0(\mathbf{x}_0)} \approx 1 + \mathcal{E}_t(\mathbf{x}_t) - \mathcal{E}_0(\mathbf{x}_0)$  取泰勒展开, 本文有

$$\begin{aligned} \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t) &\approx \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [(-1 - \mathcal{E}_t(\mathbf{x}_t) + \mathcal{E}_0(\mathbf{x}_0)) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)] \\ &= \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\mathcal{E}_0(\mathbf{x}_0) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)] \\ &= \nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t), \end{aligned}$$

其中倒数第二个等号利用了事实  $\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)] = 0$ 。因此,  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t)$  的引导是在假设  $\mathcal{E}_t(\mathbf{x}_t) \approx \mathcal{E}_0(\mathbf{x}_0)$  下对真实能量引导的一阶近似, 该假设仅对接近 0 的  $t$  成立。然而, 如图 1 所示, 对于接近  $T$  的  $t$ ,  $\mathcal{E}_t$  与  $\mathcal{E}_0$  相差很大, 因此用  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t)$  进行引导采样在  $T$  附近可能产生较大的引导误差, 这可以解释为什么 MSE 比 CEP 更差, 尤其是在  $\beta$  较大时。

进一步对  $\mathcal{E}_0(\mathbf{x}_0)$  在  $\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]$  处取泰勒展开, 本文有

$$\mathcal{E}_0(\mathbf{x}_0) \approx \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]) + (\nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]))^\top (\mathbf{x}_0 - \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0])$$

进而本文可以用下式进一步近似  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t)$ :

$$\begin{aligned} \nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t) &\approx \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ \left( (\nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]))^\top \mathbf{x}_0 \right) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t) \right] \\ &\quad + \left( (\mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]) - \nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]))^\top (\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]) \right) \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)] \\ &= \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ \left( (\nabla \mathcal{E}_0(\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]))^\top \mathbf{x}_0 \right) \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t) \right] \\ &= \nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{DPS}}(\mathbf{x}_t), \end{aligned}$$

其中倒数第二个等号利用了事实  $\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [\nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)] = 0$ 。因此,  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{DPS}}(\mathbf{x}_t)$  的引导是在假设  $\mathbf{x}_0 \approx \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)}[\mathbf{x}_0]$  下对  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t)$  的进一步一阶近似, 该假设同样仅对接近 0 的  $t$  成立。然而, 由于  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{MSE}}(\mathbf{x}_t)$  本身也只是对精确引导  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$  的近似,  $\nabla_{\mathbf{x}_t} \mathcal{E}_t^{\text{DPS}}(\mathbf{x}_t)$  与  $\nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t)$  之间的差异可能相当大。

**更多实验结果。** 本文还在二维实验与离线 RL 实验中进一步比较 CEP、MSE 与 DPS。所有结果均表明, 在经验上 CEP 的性能显著优于 MSE, 而 MSE 显著优于 DPS。详情参见附录 L 与附录 I.3。

## F. 与对比学习的关系

给定条件变量  $c$ , 假设  $(\mathbf{x}_0, c) \sim q_0(\mathbf{x}_0, c)$ , 本文用参数为  $\phi$  的神经网络  $f_\phi(\cdot, c, t) : \mathbb{R}^d \rightarrow \mathbb{R}$  学习中间能量引导。本节证明: 对于一种特殊的能量函数 ( $\beta = 1$  且  $\mathcal{E}(\mathbf{x}_0) = -\log q_0(c|\mathbf{x}_0)$ ), Eq. (12) 中 CEP 的目标等价于传统对比 InfoNCE 目标 (对固定的  $t$ )。

**定理 F.1.** 如果  $\beta = 1$  且  $\mathcal{E}(\mathbf{x}_0) = -\log q_0(c|\mathbf{x}_0)$ , 则 Eq. (12) 中对所有可能的  $c$  求和的目标等价于

$$\mathbb{E}_{t, \epsilon^{(1:K)}} \mathbb{E}_{\prod_{i=1}^K q_0(\mathbf{x}_0^{(i)}, c^{(i)})} \left[ - \sum_{i=1}^K \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(i)}, t)}} \right], \quad (38)$$

Proof. 首先, 对固定的  $c$ , Eq. (12) 变为

$$\min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K q_0(c|\mathbf{x}_0^{(i)}) \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right].$$

对  $c$  取积分后, 变为

$$\begin{aligned} & \min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_c \sum_{i=1}^K q_0(c|\mathbf{x}_0^{(i)}) \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right] \\ \Leftrightarrow & \min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K \sum_c q_0(c|\mathbf{x}_0^{(i)}) \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right] \\ \Leftrightarrow & \min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K \mathbb{E}_{q(c|\mathbf{x}_0^{(i)})} \left[ \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c, t)}} \right] \right] \\ \Leftrightarrow & \min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K \mathbb{E}_{q(c^{(i)}|\mathbf{x}_0^{(i)})} \left[ \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(i)}, t)}} \right] \right] \\ \Leftrightarrow & \min_{\phi} \mathbb{E}_{p(t)} \mathbb{E}_{q_0(\mathbf{x}_0^{(1:K)}, c^{(1:K)})} \mathbb{E}_{p(\epsilon^{(1:K)})} \left[ - \sum_{i=1}^K \log \frac{e^{-f_\phi(\mathbf{x}_t^{(i)}, c^{(i)}, t)}}{\sum_{j=1}^K e^{-f_\phi(\mathbf{x}_t^{(j)}, c^{(i)}, t)}} \right] \end{aligned}$$

□

注意上述目标假设本文可以从  $q_0(\mathbf{x}_0, c)$  中采样, 这意味着本文可以从  $p_0(\mathbf{x}_0) = q_0(\mathbf{x}_0|c)$  中采样。然而, 对于一般的能量函数, 这样的假设难以保证, 本文无法从  $p_0(\mathbf{x}_0)$  中采样, 而只能从  $q_0(\mathbf{x}_0)$  中采样。因此, CEP 可以被理解为传统对比目标的一种推广版本, 既适用于扩散模型中的条件采样, 也适用于能量引导采样。

## G. 逆温度与引导尺度之间的关系

引导采样中一个广泛使用的技巧是引入一个额外的超参数  $s$ , 称为“引导尺度” (Dhariwal & Nichol, 2021), 并在引导采样过程中将  $p_t$  的得分函数替换为  $\tilde{p}_t$ , 如下所示:

$$\nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{x}_t) := \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t) - s \cdot \nabla_{\mathbf{x}_t} \mathcal{E}_t(\mathbf{x}_t) \quad (39)$$

根据 Eq. (37), 上式等价于

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log \tilde{p}_t(\mathbf{x}_t) &= \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t) - s \cdot \mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} \left[ -e^{\mathcal{E}_t(\mathbf{x}_t) - \mathcal{E}_0(\mathbf{x}_0)} \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t) \right] \\ &= \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t) + s \cdot \frac{\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [e^{-\beta \mathcal{E}(\mathbf{x}_0)} \nabla_{\mathbf{x}_t} \log q_{0t}(\mathbf{x}_0|\mathbf{x}_t)]}{\mathbb{E}_{q_{0t}(\mathbf{x}_0|\mathbf{x}_t)} [e^{-\beta \mathcal{E}(\mathbf{x}_0)}]}. \end{aligned}$$

注意改变  $s$  与改变  $\beta$  的影响是不同的: 改变  $s$  会线性地影响引导强度, 而改变  $\beta$  会影响关于指数项的引导。因此,  $s$  与  $\beta$  是两个不同的超参数, 本文可以一起调节它们。



经验上, 本文发现在简单的二维实验中, 仅改变  $\beta$  就足以保证收敛到期望分布  $p(\mathbf{x})$ 。然而, 在图像合成与强化学习等复杂任务中, 仅改变  $\beta$  无法保证良好的性能, 因此较大的  $s$  是必要的。本文对此的解释假设是: 所使用的神经网络表达能力不足, 当  $\beta$  增大且任务变得更加复杂时, 模型容量接近饱和, 因此本文必须依赖免训练的方法来放大引导效果 (Appendix I.2)。

## H. E-MSE 能量引导

本节提出一种学习能量引导的 CEP 替代方法。为确保存在精确的收敛点, 本文在原始的基于 MSE 的训练目标 (Eq. (14)) 中加入指数激活, 并将其命名为 E-MSE:

$$\min_{\phi} \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_t} [\|\exp(f_{\phi}(\mathbf{x}_t, t)) - \exp(\beta \mathcal{E}(\mathbf{x}_0))\|_2^2] \quad (40)$$

这样的训练目标也能保证收敛到从  $p(\mathbf{x})$  采样所需的精确能量引导。如 Figure 6 所示, 本文发现与基于 MSE 的引导方法相比, CEP 与 E-MSE 引导都能在二维设定下生成更准确的样本, 尤其是当  $\beta$  较大时。然而, E-MSE 引导的一个主要缺点是 Eq. (40) 由于孤立的指数项而数值不稳定。特别是, 在 RL 设定中, 能量函数  $\mathcal{E}$  不再归一化在  $[0, 1]$  范围内, 而是由可能带有噪声的神经网络  $Q_{\psi}$  定义, E-MSE 引导通常倾向于逊于 CEP, 甚至逊于 MSE 引导 (Table 6)。

## I. 离线 RL 的实验细节

### I.1. QGPO 的伪代码

Algorithm 1 用于离线 RL 的 Q 引导策略优化 (QGPO)

---

```

Initialize the diffusion behavior model  $\epsilon_\theta$ , the action evaluation model  $Q_\psi$  and the intermediate energy model  $f_\phi$ 
// 训练行为模型
for each gradient step do
    Sample  $B$  data points  $(\mathbf{s}, \mathbf{a})$  from  $\mathcal{D}^\mu$ ,  $B$  Gaussian noises  $\epsilon$  from  $\mathcal{N}(0, \mathbf{I})$  and  $B$  time  $t$  from  $\mathcal{U}(0, T)$ 
    Perturb  $\mathbf{a}$  according to  $\mathbf{a}_t := \alpha_t \mathbf{a} + \sigma_t \epsilon$ 
    Update  $\theta \leftarrow \theta - \lambda_\theta \nabla_\theta \sum [\|\epsilon_\theta(\mathbf{a}_t | \mathbf{s}, t) - \epsilon\|_2^2]$ 
end for
// 生成支持动作集
for each state  $\mathbf{s}$  in  $\mathcal{D}^\mu$  do
    Sample  $K$  support actions  $\hat{\mathbf{a}}^{(1:K)}$  from  $\mu_\theta(\cdot | \mathbf{s})$  and store them as  $\mathcal{D}^{\mu_\theta}(\mathbf{s})$ 
end for
// 训练动作评估模型与能量引导模型
for each gradient step do
    Sample  $B$  data points  $(\mathbf{s}, \mathbf{a}, r, \mathbf{s}')$  from  $\mathcal{D}^\mu$ ,  $B$  Gaussian noises  $\epsilon$  from  $\mathcal{N}(0, \mathbf{I})$  and  $B$  time  $t$  from  $\mathcal{U}(0, T)$ 
    Retrieve support action sets  $\hat{\mathbf{a}}^{(1:K)}$  and  $\hat{\mathbf{a}}'^{(1:K)}$  respectively from  $\mathcal{D}^{\mu_\theta}(\mathbf{s})$  and  $\mathcal{D}^{\mu_\theta}(\mathbf{s}')$ 
    Calculate the target Q-value  $\mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a}) = r(\mathbf{s}, \mathbf{a}) + \gamma \sum_{\hat{\mathbf{a}}'} \left[ \frac{e^{\beta_Q Q_\psi(\mathbf{s}', \hat{\mathbf{a}}')}}{\sum_{\hat{\mathbf{a}}} e^{\beta_Q Q_\psi(\mathbf{s}', \hat{\mathbf{a}}')}} Q_\psi(\mathbf{s}', \hat{\mathbf{a}}') \right]$  and detach gradient
    Update  $\psi \leftarrow \psi - \lambda_\psi \nabla_\psi \sum [\|Q_\psi(\mathbf{s}, \mathbf{a}) - \mathcal{T}^\pi Q_\psi(\mathbf{s}, \mathbf{a})\|_2^2]$ 
    Perturb  $\hat{\mathbf{a}}$  according to  $\hat{\mathbf{a}}_t := \alpha_t \hat{\mathbf{a}} + \sigma_t \epsilon$ 
    Update  $\phi \leftarrow \phi + \lambda_\phi \nabla_\phi \sum_i \left[ \frac{e^{\beta_Q Q_\psi(\mathbf{s}, \hat{\mathbf{a}}_i)}}{\sum_j e^{\beta_Q Q_\psi(\mathbf{s}, \hat{\mathbf{a}}_j)}} \log \frac{e^{f_\phi(\hat{\mathbf{a}}_i, t | \mathbf{s}, t)}}{\sum_j e^{f_\phi(\hat{\mathbf{a}}_j, t | \mathbf{s}, t)}} \right]$ 
end for

```

---

### I.2. QGPO 的实验细节

对于离线 RL 基准, 本文的方法需要对每个任务训练三个神经网络, 即基于扩散的行为模型  $s_\theta$ 、动作评估模型  $Q_\psi$  与能量引导模型  $f_\phi$ 。本文首先给出训练上述每个组件的实验细节, 然后讨论如何将这些组件组合起来进行策略评估。

**训练行为模型。** 本文行为模型的架构与训练方法完全遵循 [Chen et al. \(2022\)](#)。网络架构类似于 U-Net, 但将空间卷积改为密集连接, 使其兼容向量化的数据表示。Janner et al. (2022) 与 Pearce et al. (2022) 也采用了类似的网络架构。本文使用 Adam 优化器 (学习率为 1e-4) 训练行为模型 600k 个梯度步, 批大小为 4096。至于数据扰动方法, 本文采用 ([Song et al., 2021b](#)) 中的默认 VPSDE 设置, 并使用线性调度。Eq. (8) 中的  $\alpha_t$  与  $\sigma_t$  为:

$$\alpha_t = -\frac{\beta_1 - \beta_0}{4} t^2 - \frac{\beta_0}{2} t, \quad \sigma_t = \sqrt{1 - \alpha_t^2}, \quad \beta_0 = 0.1, \beta_1 = 20. \quad (41)$$

**训练动作评估模型。** 动作评估模型是带有 256 个隐藏单元与 ReLU 激活的 3 层 MLP。本文使用 Adam 优化器 (学习率为 3e-4) 训练动作评估模型 500k 个梯度步, 批大小为 256。本文在 Eq. (22) 中对 MuJoCo Locomotion 任务设置  $\beta_Q = 1$  与  $K = 16$ , 对 AntMaze 任务设置  $\beta_Q = 20$  与  $K = 32$ 。训练前, 本文遵循 [Kostrikov et al. \(2022\)](#) 对任务奖励进行归一化。本文还使用诸如软更新 ([Lillicrap et al., 2016](#)) 与双网络 ([Fujimoto et al., 2018](#)) 等标准技巧来稳定 Q 学习。

**训练能量引导模型。** 能量引导模型是带有 256 个隐藏单元与 SiLU 激活的 4 层 MLP。本文用 Adam 优化器 (学习率为 3e-4) 训练它 1M 个梯度步, 批大小为 256。支持动作集的大小与训练动作评估模型时使用的相同 (MuJoCo Locomotion 为  $K = 16$ , AntMaze 为  $K = 32$ ), 不过本文在所有任务中都设置  $\beta = 3$ 。

**评估。** 本文在 5 次独立试验上运行所有实验, 并报告其平均性能。对每次试验, 本文额外在多个测试种子 (对于 MuJoCo Locomotion 为 10 个, 对于 AntMaze 为 100 个) 上收集平均评估得分。为了从学习得到的基于扩散的策略中采样, 本文采用扩散采样中的最新进展, 即 DPM-Solver ([Lu et al., 2022b](#))。本文使用二阶采样器, 并在扩散步数为 15 时报告性能得分。本文对扩散步数进行了消融研究 (Figure 5), 发现扩散步数为 10 时已经能取得同

样好的性能, 而扩散步数为 5 时仅略逊于 15 个扩散步。注意本文只对评估中的扩散步数进行了消融。支持动作集仍然使用 15 个扩散步生成。本文还采用了引导扩散采样 (Dhariwal & Nichol, 2021; Ho & Salimans, 2021) 中广泛使用的技巧, 即调节超参数  $s$  以放大采样过程中的引导效果, 方法是将 Eq. (18) 中的能量引导乘以引导尺度  $s$ 。为选择动作采样的最优能量引导尺度  $s$ , 本文在评估期间对 MuJoCo Locomotion 的 [1.0, 2.0, 3.0, 5.0, 8.0, 10.0] 与 AntMaze 任务的 [1.0, 1.5, 2.0, 2.5, 3.0, 4.0] 进行扫描 (Figure 4)。报告得分所用的引导尺度列在 Table 5 中。




Figure 4. D4RL 基准中引导尺度的消融。




Figure 5. 评估中扩散步数的消融。

### I.3. 其他基线的实验细节

Diffusion-QL。本文使用 Diffusion-QL 的官方实现 (<https://github.com/Zhendong-Wang/Diffusion-Policies-for-Offline-RL>) 与默认超参数设置, 重新运行 Diffusion-QL 的所有实验, 以确保评估指标一致。本文遵循 Fu et al. (2020), 在每次训练结束时报告 5 次独立试验的平均得分, 而不是像 Wang et al. (2022b) 那样报告训练期间的最大性能得分。此外, 本文注意到 Diffusion-QL 在评估中采用了重采样技术。具体来说, 在评估期间, 学习得到的策略首先生成 50 个不同的动作候选, 然后选择一个具有最高 Q 值的动作执行。本文经验上发现, 这种技术对于在 MuJoCo Locomotion 任务中取得良好性能很重要。然而, 该技术难以反映重采样前采样动作的真实质量, 且计算开销较大, 因此本文额外进行了消融研究, 在评估中移除重采样过程, 并使用单个动作候选 (Table 2 与 Appendix M 中的 Diffusion-QL@1)。

|                          |                  |                     |               |
|--------------------------|------------------|---------------------|---------------|
| Locomotion-Medium-Expert | Walker2d<br>5.0  | Halfcheetah<br>3.0  | Hopper<br>2.0 |
| Locomotion-Medium        | Walker2d<br>10.0 | Halfcheetah<br>10.0 | Hopper<br>8.0 |
| Locomotion-Medium-Replay | Walker2d<br>5.0  | Halfcheetah<br>8.0  | Hopper<br>3.0 |
| AntMaze-Fixed            | Umaze<br>3.0     | Medium<br>4.0       | Large<br>3.0  |
| AntMaze-Diverse          | Umaze<br>1.0     | Medium<br>3.0       | Large<br>2.0  |

Table 5. 不同任务中使用的引导尺度  $s$ 

| 环境         | MSE  | E-MSE | RS   | CEP  |
|------------|------|-------|------|------|
| Locomotion | 68.0 | 58.1  | 76.9 | 86.6 |
| AntMaze    | 46.4 | 24.5  | 63.0 | 78.3 |

Table 6. 不同能量引导方法与重采样技术的消融研究。

**CEP 引导的消融。** 本文研究所提引导方法的三种变体。具体而言, 一种基于 MSE 的引导方法如 Eq. (14) 所述 (在 Janner et al. (2022) 中也被类似使用), 一种 E-MSE 引导方法如 Eq. (40) 所述, 以及一种遵循 Chen et al. (2022) 的基于重采样的方法。对于 MSE 与 E-MSE 引导, 本文仅改变能量引导模型的训练目标, 而保持其他超参数不变。对于基于重采样的方法, 则不需要能量引导模型。在评估期间, 每个决策步本文首先从行为策略模型  $\mu_\theta(\mathbf{a}|\mathbf{s})$  中采样 50 个随机动作候选, 然后通过  $Q_\psi$  选择预测 Q 值最高的一个动作执行。

## J. 二维实验的实验细节

为了在低维数据空间中进行无条件能量引导采样, 本文的方法需要独立训练两个神经网络, 即一个生成扩散模型与一个能量引导模型。与离线 RL 不同,  $t = 0$  数据空间的能量函数是预先定义的 (如 Figure 6 所示), 不需要训练。本文共生成 1M 个数据点作为训练集。每个数据点包含一个二维数据样本  $\mathbf{x}$  与一个表示其能量的浮点数  $e$ 。

**训练扩散生成模型。** 生成扩散模型是隐藏层尺寸为 [512, 512, 512, 512, 256] 且带 SiLU 激活的 5 层 MLP。本文用 Adam 优化器 (学习率为  $1e-4$ ) 训练该网络 750 个 epoch, 批大小为 1 ( $K = 4096$ )。至于数据扰动方法, 本文采用 (Song et al., 2021b) 中的默认 VPSDE 设置, 并使用线性调度。Eq. (8) 中的  $\alpha_t$  与  $\sigma_t$  为:

$$\alpha_t = -\frac{\beta_1 - \beta_0}{4}t^2 - \frac{\beta_0}{2}t, \quad \sigma_t = \sqrt{1 - \alpha_t^2}, \quad \beta_0 = 0.1, \beta_1 = 20. \quad (42)$$

**训练能量引导模型。** 能量引导模型是带有 512 个隐藏单元与 SiLU 激活的 4 层 MLP。本文用 Adam 优化器 (学习率为  $3e-4$ ) 训练它 750 个 epoch, 批大小同样为 4096。

**引导采样。** 为了进行引导采样, 本文采用扩散采样中的最新进展, 即 DPM-Solver (Lu et al., 2022b)。本文使用二阶采样器与 25 个扩散步。本文在所有实验中将引导尺度  $s$  固定为 1。

## K. 图像合成的实验细节

本文完全遵循 Dhariwal & Nichol (2021) 训练与评估用于图像合成的能量引导扩散模型, 未进行任何超参数调优或网络架构更改。对于生成扩散先验, 本文使用发布于 <https://github.com/openai/guided-diffusion> 的预训练 ImageNet 模型。对于能量引导模型, 本文采用与 Dhariwal & Nichol (2021) 相同的 U-Net 架构, 但对条件图像合成将训练目标改写为 Eq. (15), 对能量引导图像合成改写为 Eq. (13)。本文的 ImageNet 128 能量引导模型以 256 的批大小 (分布在 8 个 GPU 上) 训练 300k 个梯度步。ImageNet 256 能量引导模型训练 500k 步。采样时, 本文默认使用 250 个扩散步, 除非本文使用 25 步的 DDIM (Song et al., 2021a) 采样器。

对于能量引导图像合成任务, 本文设置  $\beta = 50$ 。当图像的平均饱和度低于 0.1 时, 会在 Eq. (23) 中定义的  $t = 0$

数据空间能量函数上添加惩罚项。该惩罚主要用于避免生成低饱和度 (过亮) 的图像, 从而使不同颜色模型引导的样本更具区分度。本文分别令三个引导模型的  $h_{\text{tar}}$  为  $0$ (红色)、 $2\pi/3$ (绿色) 与  $4\pi/3$ (蓝色)。



## L. 更多二维结果




Figure 6. 二维实验中不同能量引导方法的散点图。E-MSE 是本文提出的作为 MSE 引导 (Appendix H) 变体的另一种方法。





Figure 7. 当  $\beta = 10$  时对比学习得到的中间能量模型的可视化。

## M. 离线强化学习的训练曲线





## N. 能量引导图像合成的更多结果




Figure 9. 使用条件扩散先验的颜色引导消融。从左到右依次为引导尺度  $[0.0, 0.25, 0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 5.0, 10.0]$  递增下的样本。





Figure 10. 使用无条件扩散先验的颜色引导消融。从左到右依次为引导尺度  $[0.0, 0.25, 0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 5.0, 10.0]$  递增下的样本。



## O. CEP 引导与分类器引导的比较



分类器引导 (Dhariwal &amp; Nichol, 2021)

能量引导 (本文)

Figure 11. 使用不同引导方法的条件  $256 \times 256$  ImageNet 模型的样本。随机种子在不同实验间固定。类别为 279: 北极狐、323: 君主斑蝶、386: 非洲象、130: 火烈鸟、852: 网球、933: 芝士汉堡、562: 喷泉、417: 气球、90: 吸蜜鹦鹉、992: 食用菌。