

量化布尔贝叶斯网络

——一种逻辑图模型的理论实验 *

Greg Coppola
coppola.ai
Research. Develop. Meme.

2024 年 2 月 11 日

Contents

1 贡献	3
2 动机	4
2.1 大语言模型	4
2.2 认知科学	5
3 背景	5
3.1 一阶逻辑	5
3.2 贝叶斯网络	6
4 一种新颖的语义角色演算	7
4.1 动机	7
4.2 语言定义	8
4.3 量化与蕴涵	10
4.3.1 统计推理	10
4.3.2 谓词蕴涵链接	10
4.3.3 合取谓词蕴涵	11

*作者感谢 ChatGPT 在本工作的研究、校对和公式编写方面提供的帮助。

5	命题图	12
5.1	马尔可夫假设	12
5.2	惰性图存储	12
5.3	布尔代数	13
5.4	二分图	13
5.5	合取节点	14
5.5.1	确定性定义	14
5.5.2	高层特征	14
5.6	析取节点	14
5.6.1	确定性定义	14
5.6.2	学习的析取模型	15
5.6.3	析取与线性指数的相似性	15
5.6.4	关于线性模型的使用	15
6	蕴涵图	16
6.1	以有限手段做无限使用	16
6.2	图操作	16
6.3	抽象与后向替换	16
6.4	命题因子与上下文	17
6.5	推理时的命题图创建	17
6.6	特征函数	17
7	推理	18
7.1	概率查询	18
7.2	边际化	18
7.3	迭代信念传播	18
7.4	消息传递计算	19
8	实验	20
8.1	逻辑结构	20
8.1.1	方法	20
8.1.2	结果	20
8.2	消息传播	21
9	推理的复杂度	23
9.1	可证明的精确推理	23
9.2	经验上成功的迭代信念传播	25
9.3	加速析取	25
9.4	加速合取	26

10 与其他逻辑模型的对比	26
11 实现	27
12 未来工作	27

1 贡献

我们提出**量化布尔贝叶斯网络** (Quantified Boolean Bayesian Network, 简称 *QBBN*)，这是一种源自贝叶斯网络家族 [Pearl, 1988, Neapolitan, 2003] 的模型，其构建和分析旨在为逻辑与统计推理提供一种统一理论。具体而言，本文的工作做出了以下贡献：

- **逻辑与概率推理的统一模型**

我们提供了一种单一的数据结构——*QBBN*，能够同时实现：

- **统计推理** —— *QBBN* 是一种图模型，可以回答概率查询 [Koller and Friedman, 2009]，即用于信息检索 [Shannon, 1948]。
- **逻辑推理** —— 我们展示了 *QBBN* 如何精确嵌入一个更大的一致且完备的逻辑演绎系统 [Gentzen, 1934]，该系统适用于一阶演算 [Frege, 1879]。

完备性证明概述见 [Coppola, 2024a]。

- **一种无幻觉的生成式模型**

QBBN 展示了如何创建未标注文本(的潜在逻辑形式)的生成式模型。与大语言模型 [Bahdanau et al., 2014, Vaswani et al., 2017, Radford et al., 2018] 类似，*QBBN* 是生成式的，因此可用于压缩数据 [Sutskever, 2023]。但是，*QBBN* 不会产生幻觉。它进行一致的推理（即确保对于所有问题 x ，有 $P(x) + P(\neg x) = 1$ ），并且能够像任何贝叶斯网络一样，用因果性来解释其推理过程。

- **非常高效的贝叶斯推理**

一般来说，贝叶斯网络中的推理是难解的，即对于 N 个随机变量，复杂度为 $\Omega(2^N)$ [Neapolitan, 2003]。我们将贝叶斯网络节点划分为 **and** 和 **or** 布尔门，并采用了虽无保证但经验上收敛的迭代信念传播 [Murphy et al., 1999, Smith and Eisner, 2008]，使得推理不仅是易解的，而且是非常高效的——单次完整的近似信念传播只需要 $O(N2^n)$ 的时间，其中 N 是涉及的网络变量数量， n 是任何 **and** 或 **or** 门中输入连接数量的上界。此外，我们还讨论了将因子计算成本从 $O(2^n)$ 降至 $O(n)$ 的可能性。

- **快思考与慢思考**

据我们所知，本文首次给出了所谓快思考与慢思考 [Kahneman, 2011] 之间区别的数学解释。该解释基于自然演绎演算的证明论，既符合我们的图公式化表述，也符合人类经验。作为一般推理的特例，我们分析了规划问题，[LeCun, 2023] 曾指出大语言模型无法很好地支持这一任务。[Coppola, 2024a] 包含了快思考与慢思考的分析，而本文则包含相关的模型细节。

- **依存树上的演算**

从经验上看，标注依存树 [Eisner, 1996] 是最容易解析的句法形式化。传统上，将语言解析到完备且一致的演算需要使用一阶逻辑演算 [Steedman, 1996]，但字面意义上翻译到一阶演算需要对参数施加不必要的位置顺序，这种顺序对知识编码并无帮助。通过定义一个更接近键值型标注依存结构的完备演算，我们发现更容易编码知识，并且最小化了表层形式与解释之间的距离。

2 动机

2.1 大语言模型

量化布尔贝叶斯网络旨在弥补大语言模型 [Bahdanau et al., 2014, Sutskever et al., 2014, Vaswani et al., 2017, Devlin et al., 2018, Radford et al., 2018] 的以下缺陷。

幻觉 虽然大语言模型因其从未标注文本中学习复杂知识甚至某些推理的能力而广受欢迎，但用户对大语言模型的主要经验性抱怨是幻觉问题 [Sutskever and Huang, 2023]。即，当由人类评估者判断时，大语言模型可能返回“不被训练集支持”的答案。这种不可靠性极大地限制了吞吐量，因为它要求用户对大语言模型的所有输出进行二次检查。

推理 另一个众所周知的问题是，大语言模型无法进行逻辑推理，且不具备逻辑一致的世界观 [Steedman, 2022, Hinton, 2023]。我们认为，大语言模型的这两个问题是直接相关的。也就是说，大语言模型会返回不被训练集支持的答案，正是因为它不理解因果性。如果一种知识数据结构能够解释其推理过程，并且只基于有效推理返回答案，那么它就不可能返回不被训练集支持的答案，从而不可能产生幻觉。

规划 [LeCun, 2023] 指出，大语言模型的一个问题是它们似乎无法正确地规划。本文提出将“完备的”演绎规则集理解为 [Prawitz, 1965] 中的规则集，并由此将规划分析为简单推理（参见 [Coppola, 2024a] 以及正在准备的工作）加上 $\vee$ -消去。也就是说，规划是前向推理与分情况推理的混合，这恰

恰是一种比一般推理更简单的推理形式，因为它不会使用一般定理证明中的所有规则。

2.2 认知科学

我们也有兴趣理解人类思维和人类推理。[Chomsky, 1957] 提出寻找人类语言多样性背后的一种通用语法。从某种意义上说，表层形式背后的逻辑语言可能是唯一真正的通用语言 [Montague, 1973, Steedman, 1996]。因此，理解这种逻辑语言及其如何与逻辑推理和概率推理相互作用，是认知科学研究者的核心关注点。

3 背景

3.1 一阶逻辑

解释力

在科学哲学中，如今已不言自明地认为所有数学和科学都可以用一阶逻辑（或其扩展）来表达（参见 [Pelletier, 2000] 及其参考文献）。因此，我们说一阶逻辑足够建模人类推理。扩展包括二阶逻辑和模态逻辑 [Prawitz, 1965]，但我们将这些留待未来工作，为简单起见，本文专注于一阶逻辑。

语言和演绎规则

全称量化与蕴涵 全称量化的方法由 $\forall$ 表示，蕴涵由 $\rightarrow$ 符号表示。二者关键性地协同工作，例如在表达苏格拉底的经典三段论所有人都会死时：

$$\forall \mathbf{x}, \text{man}(\mathbf{x}) \rightarrow \text{mortal}(\mathbf{x}) \quad (1)$$

这条规则授权了无限数量的推理。例如，对于 $\text{man}(\mathbf{c}_{jack})$ ，我们可以推断 $\text{mortal}(\mathbf{c}_{jack})$ ；对于 $\text{man}(\mathbf{c}_{arjun})$ ，我们推断 $\text{mortal}(\mathbf{c}_{arjun})$ ，以此类推。这就是语言如何以有限手段做出无限使用，详见第 6.1 节。

逻辑连接词 在我们的系统中，有两个逻辑连接词被指定为布尔类型，对应于一般布尔代数中的两种运算。

and 第一个连接词是且，用 $\wedge$ 表示，如：

$$\text{man}(\mathbf{c}_{jack}) \wedge \text{mortal}(\mathbf{c}_{jack}) \quad (2)$$

这表示 $\text{man}(\mathbf{c}_{jack})$ 且 $\text{mortal}(\mathbf{c}_{jack})$ 都为真。

or 第二个连接词是或，用 $\vee$ 表示，如：

$$man(\mathbf{c}_{jack}) \vee mortal(\mathbf{c}_{jack}) \quad (3)$$

这表示这些项中至少有一个为真，可能两个都为真。

否定 在大多数逻辑表述中，陈述的否定用符号 $\neg$ 表示。例如，要说神并非必死，我们可以写 $\neg mortal(\mathbf{c}_{God})$ 。在我们的网络中，否定的概念起着至关重要的作用，但没有特定的否定连接点，因为每个布尔变量都同时代表为真和为假的概率。

完备性与一致性

对任何逻辑演算，我们有在该演算中可证的概念。这需要对照模型解释来评估，后者说明什么是真的。如果一个逻辑中所有可证的都是真的，则该逻辑是一致的。如果所有真的都是可证的，则该逻辑是完备的。[Gödel, 1930] 证明了一阶演算的一致性与完备性。本文的一个基本洞见是：只要我们能证明新逻辑的一致性和完备性（我们已在 [Coppola, 2024a] 及正在准备的工作中概述），我们就可以自由地使用比一阶逻辑更实用的形式化体系——即基于语义角色的图统计模型。

3.2 贝叶斯网络

马尔可夫图模型

如果存在一组因子 $\{\alpha\}_F$ 和因子函数 Ψ_α 使得分布 $P([\mathbf{p}_1, \dots, \mathbf{p}_N])$ 可以写为 [Sutton and McCallum, 2011]：

$$P([\mathbf{p}_1, \dots, \mathbf{p}_N]) = Z^{-1} \prod_{\alpha \in F} \Psi_\alpha(\{\mathbf{p}\}_\alpha) \quad (4)$$

则称分布 $P([\mathbf{p}_1, \dots, \mathbf{p}_N])$ 根据因子图 G_F 因子分解。这里， $\{\mathbf{p}\}_\alpha$ 是因子 α 中所有变量 $\mathbf{p}$ 的集合， Z 是一个归一化常数，确保概率之和为 1。在一般图模型中，进行归一化以及相关的边际化需要 $\Omega(2^N)$ 的时间。

布尔网络

QBBN 被刻意设计为布尔网络，其中所有命题变量 $\mathbf{p}$ 被建模为取值真（用 1 表示）或假（用 0 表示）。注意，虽然 $P(\mathbf{p} = z)$ 是一个概率 ($z \in \{0, 1\}$)，但 $\mathbf{p}$ 可能的取值是布尔值。

马尔可夫逻辑网络

[Richardson and Domingos, 2006] 使用图布尔统计网络来对受一阶演算演绎约束的句子进行评分。一般马尔可夫网络中的推理是 $\#P$ -完全的 [Roth, 1996], 即复杂度为 $\Omega(2^N)$ 。由于精确推理是不可解的, [Richardson and Domingos, 2006] 通过马尔可夫链蒙特卡洛 [Gilks et al., 1996] 采样使用近似推理。我们提出了一个类似效果的模型, 但通过使用无收敛保证的信念传播大幅缩短了运行时间。鉴于当前大语言模型每天需要处理的大量推理请求, 这一点具有实际意义。

传统贝叶斯网络

有向无环图 传统的贝叶斯网络是一种有向图模型, 其中每个因子将 α 个输入变量 $\mathbf{a}_i$ 映射到一个输出变量 $\mathbf{z}$:

$$\Psi(\mathbf{z} \mid \mathbf{a}_1, \dots, \mathbf{a}_n) \quad (5)$$

对于每一对 $(\mathbf{z}, \mathbf{a})$, 我们将 $\mathbf{z}$ 称为子节点 (或结论), 将 $\mathbf{a}$ 称为父节点 (或假设)。因子的有向性质产生了两个明确的推理方向: 前向, 信息从原因传递到结果; 以及后向, 信息从结果 (观测) 向后传递到原因 (假设)。

复杂度 一般贝叶斯网络中的推理也是 $\#P$ -完全的 [Cooper, 1990], 甚至可证明的近似也是 NP -难的 [Roth, 1996]。困难在于因子图中无向环上的边际化 [Neapolitan, 2003, Koller and Friedman, 2009]。尽管如此, 循环信念传播 (我们此后称为迭代信念传播), 虽然不能保证收敛, 但已在多种情境中被经验性地发现收敛 [Murphy et al., 1999, Smith and Eisner, 2008]。信念传播的复杂度在第 9 节中有详细讨论。

贝叶斯网络中的量化

全称量化的类似概念已在板块模型 [Koller and Friedman, 2009] 中得到研究, 其中共享模板结构的节点可以共享权重。我们也采用了这种参数共享, 但从逻辑角度将其视为量化。

4 一种新颖的语义角色演算

4.1 动机

我们已经说过, 一阶逻辑的演算是完备的、一致的, 并且足以表达数学和科学。然而, 一阶逻辑的语言与最容易解析得到的标注依存解析相差甚远 [Eisner, 1996, McDonald et al., 2005, Zhang and Nivre, 2011]。例如,

[Lewis and Steedman, 2013] 展示了如何将句子 *Shakespeare wrote Macbeth* 通过功能类别系统翻译为一阶语言公式：

$$wrote_{arg_0:PER,arg_1:BOOK}(\mathbf{c}Shakespeare, \mathbf{c}Macbeth) \quad (6)$$

我们的观察是，这里参数的书写顺序是一个人为痕迹——传统上一阶逻辑需要在纸上书写，而用于计算目的时，只要知道参数标签，参数的书写顺序是无关的。我们改用如下键值演算形式化：

$$(wrote, \{arg_0 : \mathbf{c}Shakespeare, arg_1 : \mathbf{c}Macbeth\}) \quad (7)$$

即，忽略参数顺序，使用键值映射来索引参数更为简便。实际上，如下文所述，如果忽略顺序、只使用函数名和标注键值对，编码蕴涵会更加容易。此外，这种公式化与注意力节点的工作方式相吻合：注意力函数可以描述为将查询和一组键值对映射到输出 [Vaswani et al., 2017]。在注意力网络中，这些对象都是向量，而在这里它们是符号。需要明确的是，我们并非声称从表层结构到逻辑结构不需要任何记录工作。我们可以将每个标注依存与范畴语法 [Bar-Hillel, 1953] 中相应的函数应用关联起来。然而，如果我们可以自由地发明更灵活的逻辑演算（例如键值演算），只要我们能证明一致性、完备性和充分性，那么解析方面和知识表示方面的流程都可以大幅简化。

4.2 语言定义

一种键值演算 假设我们可以获得如图 1 所示的标注依存解析。通过对该




图 1: 一种标注依存解析。没有标签就无法做语义，因此这是能够支持语义的最简单结构。

解析进行句法分析，我们能提取出以下大致形式的谓词：

$$(\text{SEND}, \left\{ \begin{array}{l} \text{SUBJ} : \text{John}, \\ \text{DOBJ} : \text{a letter}, \\ \text{IOBJ} : \text{Sally} \end{array} \right\}) \quad (8)$$

通过尽可能贴近裸依存结构来定义谓词，我们免去了管理任意线性顺序所需的记录工作，如：

$$send_{subj,doobj,ioobj}(\text{John}, \text{a letter}, \text{Sally}) \quad (9)$$

出于节省空间的考虑，本文中有时仍使用一阶风格的写法，希望其键值翻译意图是清楚的。

真值 布尔真值有两个：真，写作 1；假，写作 0。在我们的图模型中，查询涉及的主要节点都是关于命题（通常记作 $\mathbf{p}$ ）的取值。我们可以查询 $P(\mathbf{p} = 1)$ 和 $P(\mathbf{p} = 0)$ 的概率。也就是说，我们假设每个命题要么确定为真，要么确定为假，而我们不知道是哪一个，但可以赋予一个 $[0, 1]$ 中的概率。

实体 一个实体由字符串 e 标识，对应于我们信息检索数据库中的对象，例如 *Taylor Swift*、*Beyonce*、*USA*、*China*。

类型 一个类型 τ 由字符串标识。我们假设每个实体具有非负数量的类型。在信息检索中，一些相关的类型包括 *business*、*individual*、*group*、*book* 或 *product*。通常类型可以从上下文中清晰得知，我们一般会省略 τ 不写。

常量 一个常量（或常量引用）是实体标识符和类型的二元组 (e, τ) 。常量指向某个特定的实体。例如，实体 *USA* 具有类型 *COUNTRY*，因此其常量引用为：

$$\mathbf{c}_{usa} = \mathbf{constant}(\text{USA}, \text{COUNTRY}) \quad (10)$$

变量 一个变量由类型 τ 定义。

$$\mathbf{x}_{country} = \mathbf{variable}(\text{COUNTRY}) \quad (11)$$

变量可以被同类型的任何常量实例化。

函数名 一个函数名 f 是一个字符串，例如 *LIKE* 或 *DATE*。

参数 一个参数 a_τ 是一个对象，它封装了一个常量 $\mathbf{c}_\tau$ 或一个变量 $\mathbf{x}_\tau$ 。给定一个参数，可以判断它封装的是哪种类型的对象（ $\mathbf{c}_\tau$ 或 $\mathbf{x}_\tau$ ），并能恢复封装的对象。

角色标签 每个角色标签 r 是一个来自有限集合的字符串，例如 *SUBJ*、*DOBJ* 或 *IOBJ*。角色标签用于索引参数在函数中所扮演的参数位置。一个标注参数是角色和参数的二元组 (r, a) 。

角色集与映射 一组角色的集合 $\mathbf{r} = \{r\}_{r \in \mathbf{r}}$ 称为角色集。一个角色-参数映射是一个映射 $\mathbf{m}_\mathbf{r} = \{(r, a)\}_{r \in \mathbf{r}}$ ，其中角色集为 $\mathbf{r}$ 。 $\mathbf{m}$ 中的开放角色是那些 a 封装了变量的二元组 (r, a) 。填充角色是那些 a 封装了常量的二元组。

谓词 一个谓词的类型由函数名和角色标签集合的二元组定义。

$$\tau(\mathbf{q}) = (f, \mathbf{r}) \quad (12)$$

一个谓词实例是函数名和角色-参数映射的二元组：

$$\mathbf{q} = (f, \mathbf{m}_r) \quad (13)$$

谓词的一个例子是：

$$\mathbf{q} = (\text{LIKE}, \{\text{SUB} : \mathbf{x}_{jack}, \text{OBJ} : \mathbf{x}_{jill}\}) \quad (14)$$

$\mathbf{q}$ 没有真值，我们不能询问 $P(\mathbf{q} = 1)$ ，因为它存在开放角色和未绑定变量 $\mathbf{x}_{jack}$ 和 $\mathbf{x}_{jill}$ 。只有当这些变量被指向特定实体的常量替换后，我们才拥有可以估计概率的真值。

命题 具有零个开放角色的谓词称为命题，通常记作 $\mathbf{p}$ ，例如：

$$\mathbf{p} = (\text{LIKE}, \{\text{SUB} : \mathbf{c}_{jack1}, \text{OBJ} : \mathbf{c}_{jill1}\}) \quad (15)$$

由于没有开放角色，命题是完全基化的，因此具有概率，我们可以询问 $P(\mathbf{p} = 1)$ 。例如，在本例中，我们可以询问特指的 $\text{like}(\mathbf{c}_{jack1}, \mathbf{c}_{jill1})$ 是否成立。

4.3 量化与蕴涵

4.3.1 统计推理

在传统的一阶演算中， $\forall x, A(x) \rightarrow B(x)$ 表示 B 总是跟随 A 。我们希望用统计概念来推广 $\forall$ ，即 $\Psi x, A(x) \rightarrow B(x)$ ，其含义为：更一般地， B 以某种概率跟随 A 。这样，我们可以选择从数据中估计 Ψ 。

4.3.2 谓词蕴涵链接

示例 我们引入一个二元约会的运行示例，其中有一个二分图，包含两种类型的实体：类型为 $\mathbf{x}_{jack}$ 和类型为 $\mathbf{x}_{jill}$ 的实体，我们关注的谓词是：

$$(\text{DATE}, \{\text{SUBJ} : \mathbf{x}_{jack}, \text{DOBJ} : \mathbf{x}_{jill}\}) \quad (16)$$

当 $\mathbf{x}_{jack}$ 正在约会 $\mathbf{x}_{jill}$ 时，该谓词返回真。现在，如果 $\mathbf{x}_{jack}$ 喜欢 $\mathbf{x}_{jill}$ ，他们更有可能约会。我们可以在键值演算中将其表示为：

$$\Psi[\mathbf{x}_{jack}, \mathbf{x}_{jill}] \left(\text{LIKE}, \left\{ \begin{array}{l} \text{SUBJ} : \mathbf{x}_{jack}, \\ \text{DOBJ} : \mathbf{x}_{jill}, \end{array} \right\} \right) \rightarrow \left(\text{DATE} \left\{ \begin{array}{l} \text{SUBJ} : \mathbf{x}_{jack}, \\ \text{DOBJ} : \mathbf{x}_{jill}, \end{array} \right\} \right) \quad (17)$$

我们也可以表示相关的链接：如果 $\mathbf{x}_{jill}$ 喜欢 $\mathbf{x}_{jack}$ ，则 $\mathbf{x}_{jack}$ 和 $\mathbf{x}_{jill}$ 更有可能约会：

$$\Psi[\mathbf{x}_{jack}, \mathbf{x}_{jill}] \left(\text{LIKE}, \left\{ \begin{array}{l} \text{SUBJ} : \mathbf{x}_{jill}, \\ \text{DOBJ} : \mathbf{x}_{jack}, \end{array} \right\} \right) \rightarrow \left(\text{DATE} \left\{ \begin{array}{l} \text{SUBJ} : \mathbf{x}_{jack}, \\ \text{DOBJ} : \mathbf{x}_{jill}, \end{array} \right\} \right) \quad (18)$$

角色集映射 对比 17 与 18，我们看到 17 在前提和结论中保持相同的角色-参数分配：

$$\{\text{SUBJ} : \text{SUBJ}, \text{DOBJ} : \text{DOBJ}\} \quad (19)$$

在 18 中，角色被颠倒了：

$$\{\text{SUBJ} : \text{DOBJ}, \text{DOBJ} : \text{SUBJ}\} \quad (20)$$

为了允许两种可能性，我们在任何结论 $\mathbf{q}_c$ 与前提 $\mathbf{q}_a$ 之间引入角色集映射，它是一个映射 $\{r, s\}$ ，其中每个条目 (r, s) 表示 $\mathbf{q}_a$ 中角色 r 的参数应被用于填充 $\mathbf{q}_c$ 中的角色 s 。

谓词蕴涵链接 一个谓词蕴涵链接是一个三元组：

$$\Psi(\mathbf{q}_a, \mathbf{q}_c, \{r, s\}) \quad (21)$$

其中 $\mathbf{q}_a$ 和 $\mathbf{q}_c$ 是谓词， $\{r, s\}$ 是二者之间适当的角色映射。在当前的实现中，我们要求 $\mathbf{q}_a$ 和 $\mathbf{q}_c$ 中的所有开放角色都被填充，且 $\mathbf{q}_a$ 的开放角色数量不超过 $\mathbf{q}_c$ 。

4.3.3 合取谓词蕴涵

动机 从高层视角来看，蕴涵链接对应于特征的模式，我们可以训练这些模式并在命题因子上复用。假设我们想对这些特征使用线性模型，或是为了可解释性，或是为了更快的速度。线性模型的普遍问题在于，它们无法分离所有函数。例如，如果以朴素方式解释问题， $\mathbf{xor}$ 无法被分离 [Minsky and Papert, 1969]。然而，如果允许我们合取（或组合，或取输入的布尔组合）输入特征，那么例如 $\mathbf{xor}$ 可以被分离。在约会场景中，在现代语境下， $\mathbf{x}_{jack}$ 和 $\mathbf{x}_{jill}$ 只有互相喜欢才会约会。为了表示这一点，我们需要一个仅在 *both like*($\mathbf{x}_{jack}, \mathbf{x}_{jill}$) 和 *like*($\mathbf{x}_{jill}, \mathbf{x}_{jack}$) 同时成立时才激活的特征：

$$\Psi[\mathbf{x}_{jack}, \mathbf{x}_{jill}] [\{like(\mathbf{x}_{jack}, \mathbf{x}_{jill}) \wedge like(\mathbf{x}_{jill}, \mathbf{x}_{jack})\} \rightarrow date(\mathbf{x}_{jack}, \mathbf{x}_{jill})] \quad (22)$$

我们在第 5.5 节讨论合取在产生高层特征中的作用。

形式化 设 q_{a_i} 是多个谓词，我们使用 h 作为谓词群组（有序列表）的简写：

$$h_a = [q_{a_1}, \dots, q_{a_n}]$$

设 q_c 是一个结论谓词，定义合取蕴涵 $\Psi(h_a, q_c)$ 为：

$$\Psi(h_a, q_c) = [(h_{a_1}, q_c, \{r, s\}_{a_1}) \wedge \dots \wedge (h_{a_n}, q_c, \{r, s\}_{a_n})] \quad (23)$$

这里，我们假设每个 $\{r, s\}_{a_i}$ 适合将 h_{a_i} 的开放角色匹配到 q_c 。形式 23 使我们能够陈述像 22 这样的推理链接。

5 命题图

5.1 马尔可夫假设

图模型的一个本质特征是它做出了马尔可夫假设：图中的每个变量在给定其邻居的值的条件下，独立于所有其他节点。由于边是有向的，节点的邻居是其父节点和子节点。在我们的贝叶斯网络中，图中的每个因子具有如下形式：

$$\Psi(z \mid z_{a_1}, \dots, z_{a_n}) \quad (24)$$

在这种情况下，我们说 z 是每个 z_{a_i} 的子节点，每个 z_{a_i} 是 z 的父节点。反过来， z 也可以对其子节点产生影响：

$$\Psi(z_c \mid z, z_{b_1}, \dots, z_{b_{n-1}}) \quad (25)$$

这里 z_{b_i} 是 z_c 的其他父节点。马尔可夫假设表明：如果我们知道了 z 的父节点和子节点的值，我们就知道了确定 z 所需的一切，即 z 在给定邻居的条件下独立于网络中所有其他节点。

5.2 惰性图存储

全图是无界的 对于无界的实体集合，存在无界数量的可能命题 p ，其中许多命题永远不会相关。例如，考虑谓词是美利坚合众国总统。这在实践中只适用于一个人，但原则上可以适用于数十亿人。因此，将所有可能的命题存储在硬盘上是不可能的。

存储概率与动态计算概率 系统中对于估计命题 p 的概率有两种选择。第一种是命题的概率在查询发出之前就已计算好。例如，对于 x_{person} 是美利坚合众国总统，可以为占据这一位置的独特个体在长期存储中设为真。对于任何其他入，我们可以使用通用推理，例如只有一个总统、现在总统是别人等，来回答否。




图 2: 一种在 *and* 门和 *or* 门之间交替的布尔网络。

马尔可夫假设的使用 在 Ψ_{or} 的训练过程中, 我们只训练假设完全观察数据的局部因子, 这不需要创建完整的命题图, 只需识别相关因子 (参见第 6 节)。在推理过程中, 我们从第 6 节描述的蕴涵图动态地在运行时创建命题图。由于马尔可夫假设和全称量化的机制, 对于任何命题 $\mathbf{p}$, 我们可以精确确定哪些其他命题与确定 $\mathbf{p}$ 相关。

5.3 布尔代数

出于逻辑完备性和计算效率的考虑, 我们将图分为两种连接点或因子类型:

1. 合取因子, 记作 Ψ_{and}
2. 析取因子, 记作 Ψ_{or} 。

图中的计算在二者之间交替: 合取因子 Ψ_{and} 馈入析取因子 Ψ_{or} , 反之亦然, 如图 2 所示。

5.4 二分图

由于因子类型 Ψ_{and} 和 Ψ_{or} 总是交替出现, 我们得到一个二分图。设 $\mathbf{p}_1, \dots, \mathbf{p}_n$ 均为命题。则称

$$\mathbf{g} = \{\mathbf{p}_1 \wedge \dots \wedge \mathbf{p}_n\} \quad (26)$$

为命题群组, 其解释为合取的。图中存在两种类型的变量:

1. $\mathbf{p}$, 表示一个单一命题

2. g , 表示一个合取命题群组

对于图模型中的许多目的（如消息传递计算），我们可以忽略节点是 g 还是 p ，将通用图节点统一称为 z 。需理解的是，每个 z 实际上封装了一个 g 或 p ，并且我们随时可以从任何 z 获取其底层类型或底层值。

5.5 合取节点

5.5.1 确定性定义

合取因子 Ψ_{and} 通过 **and** 门定义：

$$and(p_1, \dots, p_n) = p_1 \wedge \dots \wedge p_n \quad (27)$$

则：

$$\Psi_{and}(g \mid p_1, \dots, p_n) = \begin{cases} 1 & \text{若 } g == and(p_1, \dots, p_n), \\ 0 & \text{否则} \end{cases} \quad (28)$$

这既用于完备性证明，也用于学习模型中。

5.5.2 高层特征

值得思考的是， Ψ_{and} 因子总是确定性的，即即使在进行统计推理时，我们也不训练该因子。一种合理性解释是，直观上 **and** 的作用是创建高层特征，然后在这些特征之间学习关系。这类似于多层网络 [Rumelhart et al., 1986, LeCun et al., 1989] 所学习的高层特征的离散对应物。例如，假设我们获得 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 和 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 的信息作为预测 $date(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 的简单特征。假设相关的高层特征是 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill}) \wedge like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ ，一种选择是将这些特征输入多层网络，该网络能够以可微分的方式学习该特征。但这一高层特征实际上表现为一种涌现行为。这导致了可解释性问题 [Hinton et al., 2015, Ribeiro et al., 2016, Lundberg and Lee, 2017]。*QBBN* 为可解释性提供了另一种诠释：特征必须被显式合取才能发挥作用。问题不在于解释模型，而在于首先构建模型，因为构成逻辑”语言”的个体函数名和角色标签是潜在的 [Steedman, 1996]，并且可能通过类似于生成模型中类别分裂 [Petrov et al., 2006] 的方式被发现。

5.6 析取节点

5.6.1 确定性定义

用于完备性证明（另见 [Coppola, 2024a]）的确定性析取因子 Ψ_{or} 通过 **or** 门定义：

$$or(g_1, \dots, g_n) = g_1 \vee \dots \vee g_n \quad (29)$$

or 的确定性版本用于完备性证明，并在任何时候需要精确的逻辑 or 时使用：

$$\Psi_{or}(\mathbf{p} \mid \mathbf{g}_1, \dots, \mathbf{g}_n) = \begin{cases} 1 & \text{若 } \mathbf{p} == or(\mathbf{g}_1, \dots, \mathbf{g}_n), \\ 0 & \text{否则} \end{cases} \quad (30)$$

当进行统计推理时，我们学习该模型，详见第 5.6.2 节。

5.6.2 学习的析取模型

对于学习模型，我们使用线性指数模型来建模 Ψ_{or} 。对于具有布尔特征 $\mathbf{g}_1, \dots, \mathbf{g}_n$ 的布尔变量 $\mathbf{p}$ ，因子势具有如下形式：

$$\Psi_{or}(\mathbf{p} \mid \mathbf{g}_1, \dots, \mathbf{g}_n) = \exp \left\{ \sum_{i=1}^n \mathbf{w} \cdot \phi(\mathbf{p}, \mathbf{g}_i) \right\} \quad (31)$$

这里， $\mathbf{w}$ 是权重向量， $\phi(\mathbf{p}, \mathbf{g}_i)$ 是第 6.6 节讨论的特征。概率 $P(\mathbf{p} \mid \mathbf{g}_1, \dots, \mathbf{g}_n)$ 通过对 $\mathbf{p} \in \{0, 1\}$ 的两个可能值做归一化得到：

$$P(\mathbf{p} = p \mid \mathbf{g}_1, \dots, \mathbf{g}_n) = \frac{\Psi_{or}(p \mid \mathbf{g}_1, \dots, \mathbf{g}_n)}{\Psi_{or}(1 \mid \mathbf{g}_1, \dots, \mathbf{g}_n) + \Psi_{or}(0 \mid \mathbf{g}_1, \dots, \mathbf{g}_n)} \quad (32)$$

5.6.3 析取与线性指数的相似性

为强调线性指数模型与析取 Ψ_{or} 之间的相似性，考虑如何使用对数线性模型实现 or 。即 Y 对 X_1 和 X_2 的依赖关系可表达为：

$$P(Y = 1 \mid X_1, X_2) = \frac{1}{1 + \exp(-(\beta_0 + \beta_1 X_1 + \beta_2 X_2))} \quad (33)$$

若设 $\beta_0 = -0.5$ （负偏置）， $\beta_1 = \beta_2 = 1$ ，则该模型在 $X_1 = 1$ 或 $X_2 = 1$ 时预测 $Y = 1$ ，否则 $Y = 0$ 。即它实现了 or ，且此技术可扩展到 $n > 2$ 的情况。

5.6.4 关于线性模型的使用

有人可能会问，在已有多层网络和注意力等先进网络的情况下，出于任何原因使用线性模型是否过于简单化。在这个上下文中使用非线性网络当然值得研究。然而，我们重申，合取门的作用正是创建目前由多层网络 [Rumelhart et al., 1986] 实现的高层特征。线性权重易于解释，有利于人机对齐。此外，对于 Ψ_{or} 的某些定义，如第 9.3 节讨论的噪声或门，更新可以是快速的，即由于输入的独立性为 $O(n)$ 而非 $O(2^n)$ 。我们留待未来工作判断是否有任何 Ψ_{or} 的 $O(n)$ 模型在实践中是有用的。

6 蕴涵图

6.1 以有限手段做无限使用

乔姆斯基以喜欢引用洪堡特的名言而闻名：语言以有限手段做无限使用 [Chomsky, 1965]。蕴涵图通过定义谓词模式而非具体实体之间关系的权重，使我们能够基于有限的参数 Ψ 为无界数量的命题 $\mathbf{p}$ 估计概率。即，我们学习 $\mathbf{x}_{jack}$ 喜欢 $\mathbf{x}_{jill}$ 与 $\mathbf{x}_{jack}$ 约会 $\mathbf{x}_{jill}$ 之间的一般链接，这可以应用于 $\mathbf{c}_{jack1}$ 、 $\mathbf{c}_{jack2}$ 、 $\mathbf{c}_{jill1}$ 或 $\mathbf{c}_{jill2}$ 等，从而以有限手段做无限使用。

6.2 图操作

构建 蕴涵图由我们希望在模型中训练权重的所有相关合取谓词蕴涵的集合构建：

$$\mathcal{K} = \{\Psi(\mathbf{h}, \mathbf{q})\} \quad (34)$$

谓词的后向链接 由此，我们可以恢复谓词 $\mathbf{q}$ 的所有谓词蕴涵链接的后向集合：

$$B_{\Psi}(\mathbf{q}) = \{\Psi(\mathbf{h}, \mathbf{q}') \in \mathcal{K} \mid \mathbf{q}' = \mathbf{q}\} \quad (35)$$

也可以定义前向集合，但为简单起见，我们仅考虑 B_{Ψ} 。

6.3 抽象与后向替换

抽象 对于任何角色集为 $\mathbf{r}$ 的命题 $\mathbf{p}$ ，我们可以抽象 $\mathbf{r}$ 中的任何角色子集以揭示一个谓词 $\mathbf{q}$ 。例如，对于命题：

$$\mathbf{p} = (\text{LIKE}, \{\text{SUBJ} : \mathbf{c}_{jack1}, \text{DOBJ} : \mathbf{c}_{jill1}\}) \quad (36)$$

抽象掉 $\{\text{SUBJ}, \text{DOBJ}\}$ 将得到：

$$\mathbf{q} = (\text{LIKE}, \{\text{SUBJ} : \mathbf{x}_{jack}, \text{DOBJ} : \mathbf{x}_{jill}\}) \quad (37)$$

虽然一次性抽象所有变量可被视为标准抽象，我们可以以 $2^n - 1$ 种不同方式进行部分抽象，因为 $\mathbf{p}$ 不被包括为自身的抽象（它没有开放角色）。若 $\mathbf{q}$ 是 $\mathbf{p}$ 的一个抽象，我们记为 $\mathbf{q} \in \mathbf{p}$ 。

后向替换 假设 $\mathbf{q}$ 是 $\mathbf{p}$ 的一个抽象，即 $\mathbf{q} \in \mathbf{p}$ 。又假设 $\Psi(\mathbf{h}, \mathbf{q})$ 是一个蕴涵链接。我们可以定义：

$$\text{backfill}(\mathbf{p}, \Psi(\mathbf{h}, \mathbf{q})) = \text{唯一的 } \mathbf{g} \text{ 使得 } \Psi(\mathbf{h}, \mathbf{q}) \text{ 将 } \mathbf{g} \text{ 链接到 } \mathbf{p} \quad (38)$$

此函数可被计算，因为对于蕴涵图中的每个 $\Psi(\mathbf{h}, \mathbf{q})$ ，我们为每个 $\mathbf{q}_a \in \mathbf{h}$ 和 $\mathbf{q}$ 存储了角色映射对 $\{r, s\}$ 。

6.4 命题因子与上下文

命题因子 假设有一个命题 p ，它包含抽象 q ，该抽象匹配蕴涵链接 $\Psi(h, q)$ 。我们可以调用 $backfill(p, \Psi(h, q))$ 获得某个 g ，它是 h 的一个实例，通过沿着链接 $\Psi(h, q)$ 向后跟踪得到。 $g = p_1 \wedge \dots \wedge p_n$ 是命题的合取，因此具有概率，不像 h 只是一个谓词。这些对象被绑定在一个因子中：

$$factor(p, \Psi(h, q)) = (p, \Psi(h, q), g) \quad (39)$$

该因子既包含因果相关的命题群组 g ，也包含用于链接 g 与 p 的蕴涵链接 $\Psi(h, q)$ 。

命题因子上下文 对于给定的命题 p ，其因子上下文为：

$$CONTEXT(p) = \bigcup_{q \in p} \bigcup_{h \in B_\Psi(q)} factor(p, \Psi(h, q)) \quad (40)$$

这是通过从所有抽象谓词 $q \in p$ 取所有后向蕴涵链接而创建的所有因子的集合。因子上下文是用于为 or 门 Ψ_{or} 评分的线性指数学习模型的输入。

马尔可夫假设 就马尔可夫假设而言，节点 p 在给定其因子上下文的条件下独立于其所有祖先。即因子上下文包含根据当前理论 p 的所有直接原因的集合。

6.5 推理时的命题图创建

当我们对一个查询 p 感兴趣时，必须在推理时动态地构建相关命题图，因为我们无法存储所有命题。假设我们对某个目标查询 p 感兴趣，为简单起见，当前假设它只有祖先、没有后代。我们可以确定 $CONTEXT(p)$ ，这将获得作为 p 的父节点的所有合取节点 g 。每个 $g_z = p_{z_1} \wedge \dots \wedge p_{z_n}$ 是 p_{z_i} 的合取，对每个我们可以递归调用 $CONTEXT(p_{z_i})$ ，依此类推，直到创建出所有与 p 相关的命题的命题图。由于马尔可夫假设，任何未通过此遍历到达的节点都与 p 无关。在图的构建过程中，我们可以进行记录，为每个发现的 p 和 g 存储前向链接（将节点链接到其子节点）和后向链接（将节点链接到其父节点）。这些都在第 7 节描述的推理时使用。

6.6 特征函数

特征函数 $\phi(p, g)$ 刻画了结论 p 与假设 g 之间的蕴涵链接：

$$\phi(p = p, g = g) = (p, \Psi(h, q), g) \quad (41)$$

即特征 $\phi(p = p, g = g)$ 是一个三元组，表示：

1. $\mathbf{p}$ 在 $\phi(\mathbf{p} = p, \mathbf{g} = g)$ 中取的值 $p \in \{0, 1\}$ 。
2. 用于从 $\mathbf{g}$ 到达 $\mathbf{p}$ 的蕴涵链接 $\Psi(\mathbf{h}, \mathbf{q})$ 。
3. $\mathbf{g}$ 在 $\phi(\mathbf{p} = p, \mathbf{g} = g)$ 中取的值 $g \in \{0, 1\}$ 。

我们通常简写为 $\phi(\mathbf{p}, \mathbf{g})$ ，并假设 $\Psi(\mathbf{h}, \mathbf{q})$ 是隐含的。同一 $\mathbf{p}$ 和 $\mathbf{g}$ 确实可能拥有多个链接，这将产生多个特征。整个因子上下文的特征向量是各个命题因子的并集。

7 推理

7.1 概率查询

我们关注概率查询，它由两部分组成：

- 查询变量：网络中所有变量的一个子集 $\{\mathbf{p}\}_Q$ 。
- 证据：网络中随机变量的一个子集 $\{\mathbf{p}\}_E$ ，被观测到具有值 $\{p\}_E$ 。

任务是计算后验分布：

$$P(\{\mathbf{p}\}_Q \mid \{\mathbf{p}\}_E = \{p\}_E) \quad (42)$$

7.2 边际化

当存在既非查询也非证据的未观测变量 $\{\mathbf{p}\}_U$ 时，利用边际化将这些变量从联合概率分布中求和消除。边际化过程由下式表示：

$$P(\{\mathbf{p}\}_Q \mid \{\mathbf{p}\}_E) = \sum_{\{\mathbf{p}\}_U} P(\{\mathbf{p}\}_Q, \{\mathbf{p}\}_U \mid \{\mathbf{p}\}_E) \quad (43)$$

一般地，在贝叶斯网络中，该过程精确计算乃至可证明近似的复杂度均为 $\Omega(2^N)$ [Cooper, 1990, Roth, 1996]。

7.3 迭代信念传播

图模型中的推理可以使用信念传播 [Koller and Friedman, 2009, Neapolitan, 2003, Bishop, 2006] 进行。如果图中包含无向环（通常是如此），精确信念传播是不可解的。然而，经验结果表明循环信念传播（我们称其为迭代信念传播）尽管没有理论保证，但在经验上确实收敛良好 [Murphy et al., 1999, Smith and Eisner, 2008]。我们在第 9 节详细讨论该操作的复杂度，在第 8 节讨论收敛结果。

7.4 消息传递计算

记号 我们实现了 [Pearl, 1988] 提出的信念传播算法的变体, 在 [Neapolitan, 2003] 中有详细描述。在此公式化中, 我们有 π 值和 λ 值, 以及 π 消息和 λ 消息。对于因子计算, 我们区分了单一命题 $\mathbf{p}$ 和命题群组 $\mathbf{g}$ 。然而, 对于消息传递计算, 我们采用统一记号: $\mathbf{p}$ 和 $\mathbf{g}$ 节点都可以视为统一的节点 $\mathbf{z}$, 它可以封装任一类型, 消息传递计算对类型是无感知的。我们用 $\mathbf{c}$ 规范地指代 $\mathbf{z}$ 的子节点, 用 $\mathbf{a}$ 指代 $\mathbf{z}$ 的父节点。

计算 此处给出的版本涉及对 z 的父节点或子节点的指数复杂度 $O(2^n)$ 求和。在第 9 节中, 我们讨论了 Ψ_{or} 因子的独立性如何使某些分布 (如噪声或) 能够将 $O(2^n)$ 的更新在线性 $O(n)$ 时间内完成。

值 $\pi(z) \in \mathbb{R}$ 称为 $\mathbf{z} = z$ 的 π 值, 表示网络中前向流动的信念——从原因到结果:

$$\pi(z) = \sum_{a_1, \dots, a_n} \left(P(z \mid a_1, \dots, a_n) \prod_{a_i} \pi_{\mathbf{z}}(a_i) \right). \quad (44)$$

$\lambda(z) \in \mathbb{R}$ 称为 $\mathbf{z} = z$ 的 λ 值, 表示网络中后向流动的信念——从结果到原因:

$$\lambda(z) = \prod_{\mathbf{c}} \lambda_{\mathbf{c}}(z) \quad (45)$$

这两个值经归一化后组合计算后验概率:

$$P(z \mid \{p\}_E) = \alpha \lambda(z) \pi(z) \quad (46)$$

消息 $\pi_{\mathbf{z}}(a) \in \mathbb{R}$ 是 $\mathbf{a}$ 向其子节点 $\mathbf{z}$ 传递的消息:

$$\pi_{\mathbf{z}}(a) = \pi(a) \prod_{(\mathbf{y} \in \mathbf{z}) - \mathbf{a}} \lambda_{\mathbf{y}}(z) \quad (47)$$

$\lambda_{\mathbf{c}}(z) \in \mathbb{R}$ 是 $\mathbf{c}$ 向其父节点 $\mathbf{z}$ 传递的消息, 其中 $\mathbf{b}_i$ 是 $\mathbf{c}$ 的其他父节点:

$$\lambda_{\mathbf{c}}(z) = \sum_{\mathbf{c}} \left[\sum_{b_1, b_2, \dots, b_n} \left(P(c \mid z, b_1, b_2, \dots, b_n) \prod_{b_i} \pi_{\mathbf{c}}(b_i) \right) \lambda(c) \right] \quad (48)$$

8 实验

8.1 逻辑结构

8.1.1 方法

合成数据 我们使用合成数据训练模型。目标是展示 *QBBN* 能够学习模型，并研究使用迭代信念传播的推理。

示例世界 我们研究运行示例中的问题：存在二分集合的两个变量 $\mathbf{x}_{jack}$ 和 $\mathbf{x}_{jill}$ ，我们关心 $date(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 是否成立。这是第 4.3.2 节讨论的问题，关于这个世界的理论图模型如图 2 所示。对于任何 $\mathbf{x}_{jack}$ ， $lonely(\mathbf{x}_{jack})$ 以 30% 的概率为真。对于任何 $\mathbf{x}_{jill}$ ， $exciting(\mathbf{x}_{jill})$ 以 60% 的概率为真。对于任何 $\mathbf{x}_{jack}, \mathbf{x}_{jill}$ ， $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 成立当且仅当 $lonely(\mathbf{x}_{jack}) \vee exciting(\mathbf{x}_{jill})$ 。对于任何 $\mathbf{x}_{jill}, \mathbf{x}_{jack}$ ， $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 以 40% 的概率为真。对于任何 $\mathbf{x}_{jack}, \mathbf{x}_{jill}$ ， $date(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 成立当且仅当 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 且 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 。

训练 我们在 4096 个随机生成的合成示例上进行训练。使用非常基础的随机梯度下降实现，学习率固定，无平均。这种简单估计存在一些误差，但这些实验主要是为了检查迭代信念传播的行为。

信念传播收敛 在每种情况下，我们：1) 设置一些证据（可能不设），2) 进行 k 轮迭代信念传播，轮数在所有图的 x 轴上绘制。在所有情况下，第 0 次迭代显示先验概率，之后我们设置观测变量或不操作。如果设置观测变量，我们从该变量进行向外扇出消息传递：首先从改变后的节点沿图向上进行 λ 后向消息传递，然后从根节点向下进行 π 前向消息传递，每次扇出计为一个迭代。在这种情况下，我们观察图随迭代的演变。如果不设置观测变量，则仅进行完整的前向-后向传递，以观察网络在没有新信息时不会改变。

8.1.2 结果

无证据 首先，我们研究在未设置任何变量的情况下的模型推理。图 3 展示了模型中的基线概率，与我们能进行的手工计算验证结果一致，仅因梯度下降的粗糙实现存在一些噪声。 $P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill}))$ 是 $P(lonely(\mathbf{x}_{jack})) = 0.3$ 和 $exciting(\mathbf{x}_{jill}) = 0.6$ 上的噪声或：

$$P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill}) = 1) = 1 - (1 - 0.3)(1 - 0.6) = 0.72$$

网络估计值为 0.78，我们认为是梯度下降的噪声导致。 $P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill}))$ 和 $P(like(\mathbf{x}_{jill}, \mathbf{x}_{jack}))$ 是独立的（即使在底层世界中也是如此），因此：

$$P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill}) \wedge like(\mathbf{x}_{jill}, \mathbf{x}_{jack})) = P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill})) \cdot P(like(\mathbf{x}_{jill}, \mathbf{x}_{jack}))$$

即 $0.72 \cdot 0.4 = 0.29$ ，而网络估计值为 0.31。我们重申，这些实验主要关注消息传递，改进 SGD 估计的方法有很多且已广为人知。




图 3: 网络的先验状态，没有任何观测。

仅前向 在图 4 中,我们假设 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 为真,这会影响 $P(date(\mathbf{x}_{jack}, \mathbf{x}_{jill}))$, 但不影响 $P(like(\mathbf{x}_{jack}, \mathbf{x}_{jill}))$ (它是独立的), 也不影响其祖先。

前向和后向 在图 5 中, 我们假设 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 为真, 这会同时影响其父节点和子节点 (涉及许多变量), 但不影响 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ (它是独立的)。

仅后向 在图 6 中, 我们假设 $date(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 为真, 这通过 Ψ_{and} 门后向推理到 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 和 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 。 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 的推理也更新了对其祖先 $lonely(\mathbf{x}_{jack})$ 和 $exciting(\mathbf{x}_{jill})$ 的信念。

8.2 消息传播

方法 我们已看到 QBBN 结合迭代信念传播可以在逻辑结构上进行推理。现在我们考察信念在图中的距离传播。为此, 我们仅考虑单个变量 $\mathbf{x}_{jack}$ 和一系列一元谓词 $\alpha_0, \dots, \alpha_N$, 其中 $N = 10$ 。 $\alpha_0(\mathbf{x}_{jack})$ 由 50% 的掷硬币决定。然后, 对于 $i \geq 1$, 我们确定性地设置 $\alpha_i(\mathbf{x}_{jack}) = \alpha_{i-1}(\mathbf{x}_{jack})$ 。即虽然 $\alpha_0(\mathbf{x}_{jack})$ 是随机的, 但如果知道 $\alpha_{i-1}(\mathbf{x}_{jack})$ 或 $\alpha_{i+1}(\mathbf{x}_{jack})$ 的值, 则 $i \geq 1$




图 4: 假设 $like(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 为真。仅进行前向推理。




图 5: 假设 $like(\mathbf{x}_{jack}, \mathbf{x}_{jill})$ 为真。前向和后向推理。




图 6: 假设 $date(\mathbf{x}_{jill}, \mathbf{x}_{jack})$ 为真。仅进行后向推理。

的 $\alpha_i(\mathbf{x}_{jack})$ 可以确定性地获知。我们考察当观测到 $\alpha_0(\mathbf{x}_{jack})$ 或 $\alpha_N(\mathbf{x}_{jack})$ 为真时，信念如何变化。

结果 图 7 展示了网络中每个节点的先验概率，约为 50%，如上所述存在一些噪声。图 8 展示了当观测到 $\alpha_0(\mathbf{x}_{jack}) = 1$ 时的情况：信息以总共一次迭代沿网络前向传播。图 9 展示了当观测到 $\alpha_N(\mathbf{x}_{jack}) = 1$ 时的情况：信息沿网络后向传播，速度为每次迭代一个新节点改变，总共需要二十次迭代。注意，对于每个变量 $\alpha_i(\mathbf{x}_{jack})$ ($i \geq 1$)，还存在一个仅含单个元素 $\{\alpha_{i-1}(\mathbf{x}_{jack})\}^\wedge$ 的中间“合取”节点。我们认为存在比重复扇出更高效的信念传播管理方式，但留待未来工作。

9 推理的复杂度

9.1 可证明的精确推理

一般贝叶斯网络中的推理对于 N 个变量为 $\Omega(2^N)$ ，甚至可证明的近似也是 $\Omega(2^N)$ [Cooper, 1990, Roth, 1996]。




图 7: 展示 $\alpha_i(\mathbf{x}_{jack})$ 网络的先验状态。在未获得任何信息之前，我们对所有 i 的期望为 $P(\alpha_i(\mathbf{x}_{jack})) = 0.5$ 。




图 8: 观测到 $\alpha_0(\mathbf{x}_{jack}) = 1$ 后，信念在一次传递中前向传播。




图 9: 观测到 $\alpha_N(\mathbf{x}_{jack}) = 1$ 后, 信念以每次迭代一个节点变化的速度后向传播, 注意中间存在合取节点, 给收敛时间增加了一个常数因子。

9.2 经验上成功的迭代信念传播

迭代信念传播 (文献中称为循环信念传播) 不能保证收敛 [Neapolitan, 2003, Koller and Friedman, 2009], 但在一系列研究中已被发现在实践中收敛 [Smith and Eisner, 2008, Murphy et al., 1999, Gormley et al., 2015]。同时, 我们在实验中也观察到其收敛。这种情况下推理的主要成本是 π 和 λ 表 (见第 7 节) 中消息和值的计算。使用或许朴素的实现——其中边际化是精确的 (见 44 和 48) ——运行时间为 $O(2^n)$, n 为因子的输入数量。然后, 单次信念传播遍历 N 个节点各一次, 总时间为 $O(N2^n)$, 经验上需要 k 轮才能收敛。然而, 可能可以加速 Ψ_{and} 和 Ψ_{or} 两种门, 如下所述。

9.3 加速析取

概述 Ψ_{or} 因子在我们进行统计推理时是学习的, 因子

$$\Psi_{or}(\mathbf{p} \mid \mathbf{g}_1, \dots, \mathbf{g}_n)$$

对 $\mathbf{p}$ 的每个建模原因 $\mathbf{g}_i$ 有 n 个输入。从概念上讲, 结果有无限数量的潜在原因, 我们理想上不希望仅因消息传递复杂度而限制 n 。

重要性采样 一种选择是学习无限数量 n 的权重，但在推理时仅考虑最相关的子集。即在线性指数模型 31 中，我们可以检测出 $m < n$ 个线性贡献中哪些将具有最大效应，并仅在这些上进行边际化，成本为 $O(2^m) < O(2^n)$ 。此策略将是重要性采样 [Wilkinson, 2005] 的一种变体。

线性时间析取 [Neapolitan, 2003] 列出了至少一种析取模型——噪声或模型，其消息传递计算为 $O(n)$ ，而非 $O(2^n)$ （其中 n 为因子输入数量）。我们留待未来工作判断该模型或具有类似扩展性质的其他模型在实践中是否可用。

9.4 加速合取

合取 Ψ_{and} 门中消息更新的复杂度在输入数量 n 上为 $O(2^n)$ 。然而，**and** 门可以组织为每个大小为 2 的 **and** 门的二叉树，树高为 $\log_2(n)$ ，这种情况下评估 n 个输入的总工作量仅为 $O(n)$ 。但这会增加消息传递的量，所以我们留待未来工作评估这是否有益。

10 与其他逻辑模型的对比

AlphaGeometry [Trinh et al., 2024] 提出了一个经过训练用于解决几何奥林匹克问题的模型。我们观察到这类问题纯粹是数学性的，因此可以由普通的确定性定理证明器解决。因此，使用大语言模型似乎是自动定理证明领域一种可能的效率改进，这无疑是一个值得考虑的有趣方向。相比之下，我们的工作侧重于逻辑推理与统计推理之间的一般关系。我们对简单与复杂推理类型的分析 [Coppola, 2024a] 表明，日常推理与数学所需的复杂数学推理之间存在差异：具体而言，在复杂证明中，假设会改变，这需要某种记录工作或分情况推理。这表明为什么我们可能不希望为典型的信息检索进行完整的定理证明，而应专注于那些快速的推理。另外，我们的工作旨在适用于所有语言，并分析所有语言的逻辑和概率本质。此外，我们以基于 [Prawitz, 1965] 的完备且一致的演算对 *QBBN* 的分析，使我们能够理解当前已实现的逻辑规则与可以实现的规则之间的区别，从而为后续研究提供了清晰、有原则的纲领。

Self-Discover [Zhou et al., 2024] 使用一种称为 *self-discover* 的技术来学习作者所称的因果推理。该工作似乎依赖于复杂的计算模块，虽然看似复杂但未被列出。另外，尚不清楚该方法如何扩展到在包含每个可能命题一个变量的图中保证逻辑一致性或概率一致性，而这将是一个巨大且确实无界的数量。我们的工作中没有复杂模块，所有方程都在本文中给出。同时，我们使用的经过深入研究的贝叶斯网络系统 [Pearl, 1988] 为我们提供了一个理解一致性的框架，这是非平凡的且包含许多有用的结果和定理。

11 实现

QBBN 的实现称为 *BAYES STAR*, 可在 [Coppola, 2024b] 找到。该实现使用 *Rust* 编程语言编写, 以 *REDIS* 进行存储, 包含本文讨论的每个示例的训练和推理代码。

12 未来工作

从未标注文本学习 我们已说明 *QBBN* 能够编码知识, 且不会产生幻觉, 这相比大语言模型 [Bahdanau et al., 2014, Vaswani et al., 2017, Radford et al., 2018] 是一个优势。然而, 与大语言模型相比的困难在于, *QBBN* 不能以同样的直接 *n*-gram 语言模型方式学习, 而必须引用逻辑形式——这在训练数据中未被观察到, 被视为潜在的, 必须通过期望最大化 [Dempster et al., 1977] 来学习。

信念传播 我们使用了循环信念传播 (称为迭代信念传播), 它虽无收敛保证, 但已被相当广泛地研究 [Murphy et al., 1999, Smith and Eisner, 2008, Gormley et al., 2015], 且我们的实验中也发现其收敛。然而, 更大图的收敛性以及加速信念传播的策略仍需研究。

逻辑语言特性 我们已展示足够多的 *QBBN* 底层逻辑语言来编码基本的一阶语句。但仍有组合语义学 [Montague, 1970] (展示较大部分的含义如何由较小部分构成) 和内涵语义学 [Montague, 1973] (展示句子背后的概念本身可以作为参数) 等主题有待探索。

参考文献

- [Bahdanau et al., 2014] Bahdanau, D., Cho, K., and Bengio, Y. (2014). Neural Machine Translation by Jointly Learning to Align and Translate. *CoRR*, abs/1409.0473.
- [Bar-Hillel, 1953] Bar-Hillel, Y. (1953). A Quasi-Arithmetical Notation for Syntactic Description. *Language*, 29(1):47–58.
- [Bishop, 2006] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [Chomsky, 1957] Chomsky, N. (1957). *Syntactic Structures*. Mouton, The Hague.

- [Chomsky, 1965] Chomsky, N. (1965). *Aspects of the Theory of Syntax*. MIT Press, Cambridge, MA. Available online: <https://mitpress.mit.edu>.
- [Cooper, 1990] Cooper, G. F. (1990). The Computational Complexity of Probabilistic Inference Using Bayesian Belief Networks. *Artificial Intelligence*, 42(2-3):393–405.
- [Coppola, 2024a] Coppola, G. (2024a). A Mathematical Explanation for “Thinking Fast and Slow”. Bitcoin Ordinal NFT `72494446539c7fcb73becde763fc4bbbf0686b9c30cd8188e50861ccde0a5c83i0`.
- [Coppola, 2024b] Coppola, G. (2024b). Bayes-Star: An Implementation of a Quantified Boolean Bayesian Network. <https://github.com/gregorycoppola/bayes-star>.
- [Dempster et al., 1977] Dempster, A. P., Laird, N. M., and Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological)*, 39(1):1–38.
- [Devlin et al., 2018] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*.
- [Eisner, 1996] Eisner, J. (1996). Three new probabilistic models for dependency parsing: An exploration. In *Proceedings of the 16th conference on Computational linguistics-Volume 1*, pages 340–345. Association for Computational Linguistics.
- [Frege, 1879] Frege, G. (1879). *Begriffsschrift, a Formula Language, Modeled Upon That of Arithmetic, for Pure Thought*. Friedrich Frommann Verlag (Günther Holzboog).
- [Gentzen, 1934] Gentzen, G. (1934). Untersuchungen über das logische schließen. *Mathematische Zeitschrift*, 39:176–210, 405–431.
- [Gilks et al., 1996] Gilks, W. R., Richardson, S., and Spiegelhalter, D. J., editors (1996). *Markov Chain Monte Carlo in Practice*. Chapman and Hall/CRC.
- [Gödel, 1930] Gödel, K. (1930). On the completeness of the calculus of logic. *Monatshefte für Mathematik und Physik*, 37:349–360.

- [Gormley et al., 2015] Gormley, M. R., Dredze, M., and Eisner, J. (2015). Approximation-aware dependency parsing by belief propagation. *Transactions of the Association for Computational Linguistics*, 3:489–501.
- [Hinton, 2023] Hinton, G. (2023). “Godfather of Artificial Intelligence” talks impact and potential of AI. CBS Mornings, YouTube. Accessed: 2023-12-26, Timestamp: 1318 seconds.
- [Hinton et al., 2015] Hinton, G. E., Vinyals, O., and Dean, J. (2015). Distilling the knowledge in a neural network. *NIPS Deep Learning and Representation Learning Workshop*.
- [Kahneman, 2011] Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux, New York.
- [Koller and Friedman, 2009] Koller, D. and Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT Press.
- [LeCun, 2023] LeCun, Y. (2023). From Machine Learning to Autonomous Intelligence. Ludwig-Maximilians-Universität München, YouTube. Accessed: 2024-01-29.
- [LeCun et al., 1989] LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1989). Handwritten digit recognition: Applications of neural networks. In *NeurIPS*.
- [Lewis and Steedman, 2013] Lewis, M. and Steedman, M. (2013). Combined distributional and logical semantics. *Transactions of the Association for Computational Linguistics*, 1:179–192.
- [Lundberg and Lee, 2017] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *NeurIPS*.
- [McDonald et al., 2005] McDonald, R., Pereira, F., Ribarov, K., and Hajič, J. (2005). Non-projective dependency parsing using spanning tree algorithms. In *Proceedings of the conference on Human Language Technology and Empirical Methods in Natural Language Processing*, pages 523–530.
- [Minsky and Papert, 1969] Minsky, M. and Papert, S. (1969). *Perceptrons: An Introduction to Computational Geometry*. MIT Press.
- [Montague, 1970] Montague, R. (1970). Universal grammar. *Theoria*, 36:373–398. Reprinted in Thomason, Richmond H. (ed.), *Formal Philosophy: Selected Papers of Richard Montague*, pp. 7–27, Yale University Press, 1974.

- [Montague, 1973] Montague, R. (1973). The Proper Treatment of Quantification in Ordinary English. *Approaches to Natural Language*, pages 221–242.
- [Murphy et al., 1999] Murphy, K., Weiss, Y., and Jordan, M. I. (1999). Loopy belief propagation for approximate inference: An empirical study. In *Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence (UAI1999)*, pages 467–476. AUAI.
- [Neapolitan, 2003] Neapolitan, R. E. (2003). *Learning Bayesian Networks*. Prentice Hall.
- [Pearl, 1988] Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann.
- [Pelletier, 2000] Pelletier, F. J. (2000). A history of natural deduction and elementary logic textbooks. *Logical consequence: Rival approaches*, 1:105–138.
- [Petrov et al., 2006] Petrov, S., Barrett, L., Thibaux, R., and Klein, D. (2006). Learning accurate, compact, and interpretable tree annotation. In *Association for Computational Linguistics*, pages 433–440. Association for Computational Linguistics.
- [Prawitz, 1965] Prawitz, D. (1965). *Natural Deduction: A Proof-Theoretical Study*. Stockholm Studies in Philosophy 3. Almqvist & Wiksell, Stockholm; Göteborg; Uppsala. Acta Universitatis Stockholmiensis.
- [Radford et al., 2018] Radford, A., Narasimhan, K., Salimans, T., and Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training.
- [Ribeiro et al., 2016] Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). ”why should i trust you?” explaining the predictions of any classifier. In *KDD*, pages 1135–1144.
- [Richardson and Domingos, 2006] Richardson, M. and Domingos, P. (2006). Markov logic networks. *Machine learning*, 62:107–136.
- [Roth, 1996] Roth, D. (1996). On the hardness of approximate reasoning. *Artificial Intelligence*, 82:273–302.
- [Rumelhart et al., 1986] Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323:533–536.

- [Shannon, 1948] Shannon, C. E. (1948). A Mathematical Theory of Communication. *Bell System Technical Journal*, 27:379–423, 623–656.
- [Smith and Eisner, 2008] Smith, D. and Eisner, J. (2008). Dependency parsing by belief propagation. In Lapata, M. and Ng, H. T., editors, *Proceedings of the 2008 Conference on Empirical Methods in Natural Language Processing*, pages 145–156, Honolulu, Hawaii. Association for Computational Linguistics.
- [Steedman, 1996] Steedman, M. (1996). *Surface Structure and Interpretation*. The MIT Press.
- [Steedman, 2022] Steedman, M. (2022). 2022 NLP Symposium. AI Quorum, YouTube. Accessed: 2023-12-29, Timestamp: 7 seconds.
- [Sutskever, 2023] Sutskever, I. (2023). An observation on generalization. Simons Institute, YouTube. Accessed: 2024-01-29.
- [Sutskever and Huang, 2023] Sutskever, I. and Huang, J. (2023). AI Today and Vision of the Future. 999,999 Views, YouTube. Accessed: 2023-12-26, Timestamp: 1966 seconds.
- [Sutskever et al., 2014] Sutskever, I., Vinyals, O., and Le, Q. V. (2014). Sequence to sequence learning with neural networks. *Advances in Neural Information Processing Systems*, 27.
- [Sutton and McCallum, 2011] Sutton, C. and McCallum, A. (2011). An Introduction to Conditional Random Fields. *Foundations and Trends in Machine Learning*, 4(4):267–373.
- [Trinh et al., 2024] Trinh, T. H., Wu, Y., Le, Q. V., He, H., and Luong, T. (2024). Solving olympiad geometry without human demonstrations. *Nature*, 625:476–482.
- [Vaswani et al., 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention Is All You Need. In *Advances in Neural Information Processing Systems*, volume 30.
- [Wilkinson, 2005] Wilkinson, L. (2005). *The Grammar of Graphics*. Springer, 2 edition.
- [Zhang and Nivre, 2011] Zhang, Y. and Nivre, J. (2011). Transition-based dependency parsing with rich non-local features. In *Proceedings of the*

*49th Annual Meeting of the Association for Computational Linguistics:
Human Language Technologies*, pages 188–193.

[Zhou et al., 2024] Zhou, P., Pujara, J., Ren, X., Chen, X., Cheng, H.-T.,
Le, Q. V., Chi, E. H., Zhou, D., Mishra, S., and Zheng, H. S. (2024).
Self-discover: Large language models self-compose reasoning structures.